

Engagement de Spotify a partir de Metadatos: Síntesis de Experimentos

2 de agosto de 2026

Resumen

Este documento es la síntesis viva de las campañas de predicción de ajuste de gusto (taste-fit); los informes markdown de `experiments/` son el registro primario. El objetivo activo es una señal binaria de *rotación* — ¿ganó una pista una escucha repetida, $\text{play_count} \geq 2$? — predicha a partir de los *metadatos intrínsecos* de una pista solamente (género, artista, popularidad de artista/pista, número de seguidores, año de lanzamiento, tipo de lanzamiento) sobre el corpus de escucha del usuario. La métrica principal es el área bajo la curva ROC (AUC); el objetivo de regresión de magnitud de engagement con el que abrió el laboratorio ($\text{play_count} \times \text{completion_ratio}$, transformado con $\log 1p$) se conserva como un campo científico documentado pero ya no se entrega. El embedding conductual de co-escucha y todos los campos de reproducción/curación quedan deliberadamente excluidos del conjunto de rasgos. Se incorporan abajo cinco campañas de jun-2026; convergen en un único hallazgo — la identidad categórica de artista/género/álbum leída por árboles de gradient boosting supera a toda modalidad densa y a toda familia densa de distancia/margen — y coronaron al primer campeón registrado y promovible del proyecto, `xgboost-classifier-rotation`, con AUC 0,7429 sobre el corpus original DS-META. Tres campañas de jun-12 luego re-plantearon la pregunta de familia sobre un corpus 2026 mayor (un dataset completo de 64-d, 23 529 filas): un bake-off de cuatro familias de clasificadores en el que `xgboost-classifier` vuelve a ganar (AUC 0,7204), `catboost` le sigue dentro de banda, y un `pyramid-mlp` denso queda último; un barrido de seis geometrías de arquitectura que cierra la familia de redes densas para AUC *refutando* la hipótesis de presupuesto; y un bake-off de topología de un nuevo `burn-deep-classifier` en Rust/`burn` que, al alimentar los one-hots de identidad en *crudo*, repara la calibración de la red densa por completo ($\log\text{-loss } 2,0 \rightarrow 0,62$) y eleva su AUC ~ 2 bandas hasta 0,7038 — pero aún queda $\sim 1\text{--}2$ bandas por debajo del nivel de los árboles, con los embeddings de entidad aprendidos famélicos por la baja cardinalidad de identidad. Una séptima campaña luego cierra ese hilo: una re-ejecución pareada del bake-off de topología sobre una matriz de *mayor* cardinalidad de identidad (tope de artista $60 \rightarrow 300$, género $40 \rightarrow 120$) invierte el ranking — `embeddings` ahora *supera* a `mlp` (un vuelco de $+0,0130$ que revierte el resultado previo, confirmando la hipótesis de inanición) — y eleva la red al nivel de los árboles dentro del dataset (AUC 0,7192, dentro de ~ 1 banda de `catboost`), la primera ANN en superar la barra de guardado de rotación, guardada como `burn-deep-embeddings-highvocab`. Una octava campaña luego sondea la palanca inversa y la refuta: el clásico truco de Facebook GBDT $\rightarrow$ LR generalizado a GBDT $\rightarrow$ MLP — entrenar una cabeza fresca sobre los índices de hoja one-hot del árbol campeón congelado — queda $1,8\text{--}2,4$ bandas de ruido *por debajo* del campeón xgboost puro (mejor AUC de cabeza 0,6978) con calibración muy rota, una séptima confirmación convergente de que las representaciones aprendidas apiladas sobre los árboles no ayudan. Una novena campaña luego sondea hasta dónde puede llegar la palanca vigente de resolución de identidad: un barrido de tope de vocabulario sobre el GBDT puro, manteniendo la config campeona congelada y moviendo *solo* la cardinalidad de one-hots de artista/género, halla la palanca *en gran medida agotada* — el primer salto ($60/40 \rightarrow 300/120$) lleva la ganancia, y pasado 300/120 cada paso paga solo retornos

sub-banda; xgboost alcanza un nuevo mejor AUC de linaje single-split 0,7349 en 1000/300 (solo +0,005, ~ 0.4 banda, sobre el ancla — ningún guardado disparó), **catboost** lo sigue, y el punto de vocabulario completo no pudo construirse (techo de memoria del host). La Sección 6 consolida por qué las redes neuronales artificiales rinden estructuralmente peor sobre esta matriz de rasgos densa en one-hot, cómo la red consciente de la representación resuelve el diagnóstico, y cómo suficiente resolución de identidad finalmente hace que la topología de embeddings rinda. Se consolida además una línea de trabajo paralela — recomendación de *pista siguiente* (next-track), evaluada sobre una partición de sesiones sin fugas por recall@10 (Secciones 8–10): un blend de fusión de rankings GRU×Markov supera la barra de co-escucha de primer orden en $\sim +61\%$ de recall@10, y añadir una tercera rama content-kNN sobre un espacio de ítems rico PCA-192 (R+M+C) es la fila «mejor registrada» actual con recall@10 0,1859; una campaña posterior de ajuste-a-la-literatura la supera luego con una *proyección de contenido aprendida* supervisada ($R'+M+C'$) con recall@10 0,2117, robusta a la semilla y endurecida en dos particiones — el primer modelo de ranking de pista siguiente registrado, promovido y servible (Secciones 11–13). Su tarea, métricas y campeón no tienen relación con las tablas de rotación y nunca deben leerse contra ellas. Se incorporan después dos campañas finales de arquitectura de pista siguiente, ambas nulos: una GRU de *torre doble* entrenada conjuntamente sobre pares de vistas causales del prefijo de sesión no logra superar a una torre única emparejada en parámetros al 0,098 % (el cuarto nulo independiente de combinador aprendido, y el que responde a la objeción de «entrenad la fusión de extremo a extremo»), y un *pre-codificador* por paso aprendido no solo es inútil sino activamente *perjudicial* en una torre única (−0,0140 de R@10, con el IC por debajo de cero) — pérdida que una lectura contrafactual de interpretabilidad rastrea hasta la rectificación de media onda de un latente centrado en cero, que borra exactamente su mitad negativa (`frac_exact_zero` 0,5327 = `frac_negative_coords` 0,5327). Un análisis de potencia medido reencuadra luego los cinco nulos de arquitectura: con $n = 1431$ el semiancho del IC de bootstrap pareado es 0,0124 de R@10 mientras una familia de arquitectura completa abarca solo 0,028, así que los daños grandes se detectaron con fiabilidad mientras las victorias moderadas nunca fueron detectables — y *holisticness@10* existe en tres generaciones de código mutuamente no comparables, razón por la cual el tablero de pista siguiente sigue denominado en R@10 (Secciones 15–17). Se incorporan seis campañas más de pista siguiente: una frontera nativa de *MMR* λ que es la primera palanca de *holisticness* confirmada del registro y resuelve unánimemente su pregunta de mecanismo (la diversificación sónica des-concentra artistas en 8 de 8 ramas); una métrica de *despliegue* construida a propósito que devuelve un sexto nulo de arquitectura en el régimen de despliegue, donde la varianza por semilla domina la identidad del modelo; un memorándum de investigación cuyos supervivientes son todos cambios de *condicionamiento por evidencia* y no de capacidad, reportado en un registro más bajo porque nada en él se ejecutó; **markov_gate**, un cambio de nueve líneas en tiempo de puntuación que hace que la rama de Markov se abstenga en el 55,6 % de las consultas sin evidencia de bigramas, con un valor de +0,0203 / +0,0196 de recall@10 en dos particiones disjuntas (R@10 0,2320, la mejor del registro) y con los buckets cálidos de evidencia idénticos byte a byte; la refutación-con-mecanismo del regularizador anti-eager de entrenamiento, cuyos márgenes se calibraron desde la distribución equivocada y son demostrablemente inertes; la primera palanca de des-eagering que *funciona*, un tope duro por artista que no puede ser superado en puntuación y cambia relevancia literal por relevancia graduada (`artist_conc` 0,692→0,113 con *music@10 al alza*, endurecido en dos particiones); y una campaña de profundidad de pila de etapas que cierra la rama serie del eje de arquitectura en *ambas* superficies de evaluación, cuya rama de mejor ajuste tiene la pérdida de validación más baja de su lote y recupera 55 aciertos menos.

1. Introducción

Este documento es la síntesis viva de las campañas de experimentos; los informes markdown de `experiments/` son el registro primario. Cada sección transcribe (nunca recalcula) los resultados

cuantitativos de una campaña, preserva sus identificadores de ejecución y de dataset de forma literal para trazabilidad, y añade la motivación y la interpretación que los informes escuetos omiten.

Tarea y objetivo. El laboratorio predice el *ajuste de gusto* a partir de los metadatos intrínsecos de una pista sobre el corpus de escucha del usuario. Abrió con un objetivo de regresión de magnitud de engagement — `play_count` $\times$ `completion_ratio`, entrenado contra una transformación $\log 1p$ y remapeado con `expm1` — pero el 2026-06-08 el objetivo activo giró a una señal binaria de *rotación*: `play_count` ≥ 2 , es decir, ¿ganó la pista una escucha repetida (Sección 3)? La rotación es la entrada accionable al término de deseabilidad por pista del Playlist Pathfinder, es mucho más aprendible que la magnitud de engagement (los árboles alcanzan $AUC \approx 0,73$ en rotación frente a $R^2 \approx 0,3$ en engagement), y con una tasa base cercana al 44,5 % está naturalmente repartida para la búsqueda de caminos. El engagement se conserva como campo científico documentado, pero la rotación es el objetivo entregado y toda tabla de abajo es sobre él.

Métricas. Como el objetivo es binario, la métrica principal es el área bajo la curva ROC (AUC, mejor cuanto más alto), la cantidad por la que la tabla de clasificación (Tabla 1) ordena y por la que el grupo de mejores modelos auto-promueve; se reporta junto a log-loss, exactitud y el puntaje de Brier. No obstante, coexisten dos regímenes de métrica distintos en las campañas de rotación. Las campañas abrieron con una lectura de *regresión* — error absoluto medio (MAE), RMSE y R^2 sobre la escala $[0, 1]$ de $P(\text{rotación})$ — y solo después adoptaron la lectura honesta de *clasificación* una vez que el framework ganó un modo binario. El MAE se conserva en la tabla histórica de regresión (Tabla 4) para significancia de banda dentro de familia, pero se documenta allí como *degenerado* sobre un objetivo binario: un SVR de tubo- ϵ puede publicar un MAE engañosamente bajo siendo peor que predecir la media (Sección 5.2), una ilusión que las métricas de clasificación disuelven. Las métricas de porcentaje absoluto (MAPE/medAPE) son indefinidas sobre rotación, ya que la mitad de las etiquetas son exactamente cero. La tabla histórica de engagement, donde el MAE *sí* es la métrica principal natural, se preserva en `PROJECT-FACTS.md`; sus números viven en la escala de engagement $\log 1p$ y no son comparables con nada de abajo.

Rasgos. El espacio de rasgos son los *metadatos intrínsecos* de una pista solamente: género, artista, popularidad de artista/pista, número de seguidores, año de lanzamiento, número de artistas acreditados y tipo de lanzamiento. Las modalidades de embedding denso (word2vec de co-escucha, texto-contenido, acústica y el latente del song-autoencoder de la Sección 5.1) son señales *conductuales o descriptivas*, no identidad categórica, y los predictores basados en payload sobre los one-hots de metadatos son los modelos canónicos aquí. Críticamente, la receta es *libre de fugas*: los campos de reproducción que mecánicamente constituyen o aproximan el objetivo — `play_count`, `completion_ratio`, `skip_rate`, `shuffle_rate`, `distinct_sessions`, y el campo `engagement` degradado mismo — y los campos de curación conductualmente enredados quedan todos excluidos por defecto.

Tres matrices de rasgos. Las tres primeras campañas corrieron sobre el corpus original *DS-META* (12 256 filas, solo metadatos). Las campañas de jun-12 corrieron sobre un corpus 2026 mayor, el dataset *completo de 64-d* (`ds-20260609-204419-p64-s42`, 23 529 filas, 177 columnas: 64 latentes PCA song-AE + 7 numéricos + 106 one-hots de identidad con topes de vocabulario artista 60 / género 40 — la matriz *vocab-60/40*). Una campaña final de jun-12 (Sección 6.8) re-ejecutó sobre una variante *high-vocab* (`ds-20260612-143014-p64-s42`, *mismas* 23 529 filas / semilla de partición 42 / PCA64, difiriendo *solo* en la cardinalidad de identidad: tope de artista 60 $\rightarrow$ 300,

género 40 $\rightarrow$ 120; 497 columnas incluyendo 426 one-hots — artista 301, género 121, tipo-álbum 4). **Estas son tres matrices no comparables:** DS-META difiere del corpus completo de 64-d tanto en tamaño (12 256 frente a 23 529 filas) como en conjunto de rasgos (solo metadatos frente a +64 latentes AE), y las matrices 60/40 y high-vocab difieren en cardinalidad de identidad (177 frente a 497 columnas). Por tanto los números de AUC nunca deben leerse entre ellas — ni contra el campeón DS-META de 0,7429, ni entre las tablas 60/40 y high-vocab. Cada matriz lleva su propia tabla (Tablas 1, 2 y 3); nada regresó cuando el xgboost 60/40 aterriza en 0,7204, y toda familia puntúa *más alto* sobre la matriz high-vocab más ancha porque la granularidad de identidad extra es señal genuina.

2. Trasfondo: familias de modelos y métricas

Esta sección da la teoría mínima para un lector que conoce ML pero no este repositorio. Está anclada a PROJECT-FACTS.md y crece solo cuando una nueva familia de predictores o métrica entra en los informes.

Las familias en juego.

Árboles de gradient boosting (xgboost, xgboost-classifier, catboost-classifier, ngboost-classifier)

Un ensamble aditivo de árboles poco profundos, cada uno ajustado al gradiente residual de la etapa previa. Como *regresor* su salida es un promedio de hoja, acotado por el rango de los objetivos de entrenamiento; como *clasificador* emite una probabilidad calibrada a través de un enlace logístico, la forma que gana en rotación. Los árboles parten sobre columnas individuales, así que leen los one-hots dispersos de identidad de artista/género/álbum de una pista *sin pérdida* y capturan interacciones no lineales sin cruces de rasgos manuales — la razón por la que dominan este corpus. **catboost** es una variante GBDT de ordered boosting con árboles simétricos (oblivious) y manejo categórico nativo; sobre este corpus es la segunda familia de árboles legítima, co-líder *en banda* con xgboost. **ngboost** es una variante de boosting de gradiente natural que ajusta una *distribución* predictiva completa; su maquinaria probabilística, pagada con aprendices base poco profundos, le cuesta poder de ranking crudo aquí. El costo de la familia GBDT en general es un ajuste no determinista (el submuestreo y el muestreo de columnas cargan una semilla RNG interna), así que dos ejecuciones con distintas semillas difieren levemente. El campeón registrado **xgboost-classifier-rotation** es de esta familia.

Regresión logística. Log-odds lineal pasado por una sigmoide: un clasificador lineal determinista, regularizado con ℓ_2 . Es el *piso lineal* natural para un objetivo binario — el análogo de ridge en el mundo de la regresión — y sirve como control barato y reproducible sobre el arnés. Al ser una única frontera lineal en un espacio de rasgos denso, difumina la identidad categórica dispersa que los árboles explotan, y aterriza muy por debajo de ellos en rotación.

SVM de kernel / SVC (svc con kernels rbf / lineal / poly / sigmoide). Un clasificador de máximo margen que opera sobre distancias inducidas por kernel entre puntos. Como *regresor* (SVR) sobre un objetivo binario el tubo ϵ -insensible degenera — el origen de la trampa del MAE binario de la Sección 5.2; como *clasificador* de probabilidad propio (SVC) la divergencia se desvanece pero todo kernel aún pierde ante los árboles, porque un modelo de distancia densa / margen grande no puede leer one-hots de identidad dispersos como lo hace una partición de árbol alineada a ejes. El kernel sigmoide es el más débil y es el eco de refutación documentado.

Pyramid-MLP (pyramid-mlp-classifier). Una red neuronal artificial feed-forward con una pila de capas ocultas que se estrecha en “pirámide”, activaciones ReLU y un optimizador Adam, ajustada sobre la matriz de rasgos escalada con StandardScaler. Es el único aprendizaje *denso* (cada-entrada-a-cada-unidad-oculta) del proyecto sobre rotación. Como desarrolla en extenso la Sección 6, una red densa es exactamente el régimen que los datos de gusto densos en one-hot combaten: debe aprender pesos densos sobre una entrada mayormente-cero, y aterriza última en el bake-off con una calibración reventada que un barrido de arquitectura prueba que es estructural, no un artefacto de presupuesto.

Red consciente de la representación (burn-deep-classifier). Un clasificador feed-forward en Rust/burn construido para reparar las patologías del pyramid-MLP. Parte la matriz de rasgos en un bloque continuo *estandarizado* (64 PCA + 7 numéricos) y un conjunto de grupos de one-hots de identidad en *crudo* (sin estandarizar; artista, género, tipo-álbum), de modo que el escalador nunca convierte categorías raras en picos atípicos (Sección 6.2). Un enum `topology` selecciona entre un `mlp` denso plano sobre las entradas concatenadas, `embeddings` aprendidos por grupo, y una partición `wide_deep` (una ruta lineal ancha sobre los one-hots junto a una ruta profunda sobre el bloque continuo). Como reporta la Sección 6.7, la representación de one-hots en crudo arregla la calibración por completo y eleva el AUC ~ 2 bandas sobre la pirámide, pero la red aún queda ~ 1 – 2 bandas por debajo del nivel de los árboles, y las variantes de embeddings no ganan nada porque las cardinalidades de identidad aquí son demasiado bajas para alimentarlas.

Red de trasplante AE (burn-ae-classifier). Una red en Rust/burn de dos fases. La Fase 1 pre-entrena un autoencoder para reconstruir el vector de rasgos *completo* ensamblado — el bloque continuo estandarizado junto a los one-hots de identidad en *crudo*, $D=177$ — por error cuadrático medio; la Fase 2 trasplanta el encoder entrenado a un clasificador softmax profundo (encoder $\rightarrow$ latente $\rightarrow$ cabeza $\rightarrow$ logits) y lo afina de extremo a extremo con entropía cruzada. Una bandera `freeze_encoder` elige un extractor de rasgos fijo frente a afinar. Prueba si un pre-entrenamiento de reconstrucción *no supervisado* entrega al clasificador un latente que los one-hots crudos no le den ya a una red desde cero; como reporta la Sección 6.9, no lo hace — el latente reconstructivo es agnóstico a la tarea, y la familia empatiza con el `mlp burn-deep` plano sin alcanzar el nivel de los árboles.

Blend Autoencoder-XGBoost (autoencoder-xgboost). Un ensemble ponderado $\hat{y} = w \cdot \hat{y}_{\text{ae}} + (1 - w) \cdot \hat{y}_{\text{xgb}}$ que combina un regresor sobre un latente de song-autoencoder precomputado de 64 dimensiones con un modelo XGBoost de metadatos, con el peso w ajustado en un holdout de entrenamiento. Su propósito era probar si el latente AE denso lleva señal de rotación que los one-hots de metadatos pierden; no lo hace, y el ajustador correctamente lleva $w \rightarrow 0$, colapsando el ensemble a XGBoost solo-metadatos (Sección 5.1).

Por qué un objetivo binario hace degenerado al MAE. Para un objetivo continuo, el error absoluto medio es un resumen fiel de cuán lejos quedan las predicciones de la verdad. Sobre un objetivo $\{0, 1\}$ no lo es: un modelo puede minimizar el MAE abrazando las etiquetas sin importar cómo las *ordena* o *calibra*. Un SVR con un tubo $\epsilon=0,1$ ajusta sus salidas a un escalón de dos niveles cerca de $\{0, 1, 0, 9\}$, quedando solo $\sim 0,1$ de cada etiqueta — un MAE bajo — mientras su ranking es inútil (R^2 negativo). Las métricas que importan para una señal binaria de ajuste de gusto son por tanto las de clasificación:

AUC (área bajo la curva ROC). La probabilidad de que un positivo aleatorio se ordene por

encima de un negativo aleatorio; 0,5 es azar, 1,0 es perfecto. Es libre de umbral y de escala, depende solo del *orden* de las probabilidades predichas, y es exactamente la propiedad que el Pathfinder necesita de su término de deseabilidad. Es la métrica principal y la clave de ordenamiento de la tabla.

Log-loss. La log-verosimilitud negativa de las etiquetas bajo las probabilidades predichas; castiga los errores *confiados* severamente y así premia la calibración, no solo el ranking.

Puntaje de Brier. El error cuadrático medio entre la probabilidad predicha y la etiqueta $\{0, 1\}$ — una medida de calibración-y-refinamiento sobre la escala natural $[0, 1]$, mejor cuanto más bajo.

Un modelo que gana en AUC y log-loss y Brier, como lo hace el campeón, gana en ranking y calibración a la vez; el artefacto del MAE binario que adula a un SVR degenerado no aparece en ninguno de ellos. La misma tríada luego expone la patología opuesta en una red densa (Sección 6): un modelo puede publicar un AUC respetable — ranking genuino — mientras su log-loss y Brier son catastróficos, es decir, ordena aceptablemente pero está *confiadamente equivocado*.

Una nota sobre el objetivo logarítmico histórico. El objetivo de regresión inaugural del laboratorio, engagement, es de cola pesada y no negativo, así que se entrenó contra una transformación $\log 1p$ y se remapeó con $\exp m1$. Ese par de transformación carga un peligro — un modelo no acotado en espacio logarítmico puede producir una gran predicción logarítmica positiva que $\exp m1$ amplifica a un valor enorme, la “explosión de $\exp m1$ ” — razón por la cual las familias acotadas por construcción (árboles, kernels rbf) se prefieren sobre las no acotadas (modelos lineales, MLPs) sobre ese objetivo. El engagement sigue siendo un campo documentado y su tabla vive en PROJECT-FACTS.md, pero ya no es el objetivo entregado, así que el peligro de explosión es ahora una nota histórica al pie más que una restricción de diseño viva.

3. El giro a rotación: de la magnitud de engagement a una señal binaria de ajuste de gusto

El 2026-06-08 el objetivo activo giró de la magnitud de engagement a una señal binaria de *rotación*, definida como $\text{play_count} \geq 2$ — ¿ganó la pista una escucha repetida? La rotación es la entrada accionable al término W_FIT del Playlist Pathfinder, donde una deseabilidad por pista en $[0, 1]$ sesga el camino A*; una probabilidad de rotación calibrada es un `fit_norm` más limpio que una estimación de engagement $\log 1p$ -entonces- $\exp m1$. La rotación también resulta ser mucho más aprendible que la magnitud de engagement (los árboles de gradient boosting alcanzan $AUC \approx 0,73$ en rotación frente a $R^2 \approx 0,3$ en engagement) y está naturalmente repartida para la búsqueda de caminos, con una tasa base cercana al 44,5 %. El engagement se conserva como campo científico documentado pero ya no es el objetivo entregado.

El giro es decisivo para cómo debe leerse cada número de abajo. La rotación vive sobre la escala $[0, 1]$, así que su MAE/R^2 *no* son comparables con la tabla de engagement preservada en PROJECT-FACTS.md; y como la mitad de las etiquetas de rotación son exactamente cero, las métricas de porcentaje absoluto (MAPE/medAPE) son indefinidas para esas filas. Por tanto coexisten dos regímenes de métrica distintos en las campañas de rotación: una lectura temprana de *regresión* (MAE, RMSE, R^2 , unidades P(rotación)) y la lectura honesta posterior de *clasificación* (AUC, log-loss, exactitud, Brier). Como muestran las campañas de abajo, la elección de métrica no es

cosmética — bajo MAE un SVR de kernel puede *parecer* competitivo siendo peor que predecir la media, una ilusión que las métricas de clasificación disuelven.

4. Tablas de clasificación de rotación

Cuatro tablas. Las dos primeras son sobre el corpus original DS-META, una por régimen de métrica; la tercera y la cuarta son sobre el corpus completo de 64-d de 2026 mayor. **Ninguna de las tres tablas de AUC es comparable con las otras** — se sitúan sobre tres matrices de rasgos no comparables (DS-META solo metadatos; la matriz *vocab-60/40* completa de 64-d; y la matriz *high-vocab* completa de 64-d, que comparte el corpus, las filas y la partición 60/40 pero eleva los toques de cardinalidad de identidad). Cada tabla lleva sus propias referencias dentro del dataset y nunca debe leerse entre ellas (véase la nota “Tres matrices de rasgos” de la Introducción). La tabla de AUC DS-META lleva el primer campeón de rotación registrado y promovible del proyecto; la tabla 60/40 lleva la definición xgboost registrada del nuevo corpus; la tabla high-vocab lleva la primera ANN en superar la barra de guardado de rotación (Sección 6.8). Finalmente, **todo AUC en las cuatro tablas se mide sobre una partición train/test aleatoria**; una partición cronológica (entrenar-en-anterior, probar-en-posterior) cuenta una historia marcadamente distinta — los números de abajo son cotas superiores del ranking de la misma era, y la habilidad honesta de predicción hacia adelante sobre este corpus es ~ 0.11 de AUC más baja (Sección 7).

Cuadro 1: Rotación, régimen de *clasificación*, **corpus DS-META** — ordenado por AUC (mejor cuanto más alto). El campeón es la única definición registrada y auto-promovida. Datasets: DS-META `ds-20260609-141622-p1-s42` (115 cols, solo metadatos, pca floor); la fila de 178 cols añade las 64 columnas de latente song-AE (`ds-20260608-204402-p64-s42`). Banda de ruido de AUC $2\sigma = 0,0126$.

Modelo	Dataset	AUC	log-loss	exactitud	¿Registrado?
xgboost-classifier (campeón)	DS-META	0.7429	0.5883	0.6846	sí (rango 1)
xgboost-classifier (178, +latente AE)	p64-s42	0.7350	0.6045	0.6818	no
svc (poly $d=3$, mejor no-árbol)	DS-META	0.6855	0.6452	0.6450	no
logistic ($C=1$, piso lineal)	DS-META	0.6762	0.6329	0.6491	no
svc (rbf)	DS-META	0.6722	0.6469	0.6426	no
svc (lineal)	DS-META	0.6363	0.6535	0.6373	no
svc (sigmoide, peor)	DS-META	0.6255	0.6673	0.6267	no

5. Campañas

5.1. Blend de latente-autoencoder + XGBoost: una modalidad muerta, aislada

Motivación. Esta fue la primera campaña sobre el objetivo de rotación girado. La hipótesis era que un latente de song-autoencoder precomputado de 64 dimensiones (de la colección Qdrant `spotify_tracks_song_ae`) lleva la *identidad* de una pista de una forma que los one-hots de metadatos no, y que mezclar un regresor sobre el latente AE con un modelo XGBoost de metadatos — $\hat{y} = w \cdot \hat{y}_{ae} + (1 - w) \cdot \hat{y}_{xgb}$, con el peso w ajustado en un holdout de entrenamiento — podría superar a XGBoost-metadatos solo. Las seis ramas corrieron sobre `ds-20260608-204402-p64-s42`

Cuadro 2: Rotación, régimen de *clasificación*, **nuevo corpus completo de 64-d** — ordenado por AUC (mejor cuanto más alto). Dataset `ds-20260609-204419-p64-s42` (23 529 filas, 177 cols: 64 PCA song-AE + 7 numéricos + 106 one-hots de identidad). **No comparable con la Tabla 1:** distinto tamaño de corpus y conjunto de rasgos; la única referencia intra-corpus válida es el punto `xgboost` 0,7204, que el `bake-off` reprodujo byte a byte. La config por defecto del ganador se guarda como la definición del nuevo corpus. El mejor del barrido de semilla única (profundidad 8, lr 0.03, 0,7261) está +0,0057 sobre el defecto — dentro de banda — así que se marca para confirmar con 3 semillas, no se promueve. El log-loss del `pyramid-mlp` es su techo de calibración documentado (Sección 6); las filas `burn-deep-classifier` son la red consciente de la representación en Rust/`burn` que lo repara (log-loss $\rightarrow \sim 0.62$) pero aún queda por debajo del nivel de los árboles, así que ninguna se registra (Sección 6.7). Banda de AUC $2\sigma \approx 0,0126$ (estimación del corpus antiguo, aproximada aquí).

Modelo	max_depth/lr	AUC	log-loss	exactitud	Nota
xgboost-classifier (ganador, guardado)	6 / 0.05	0.7204	0.6075	0.6585	registrado
xgboost-classifier (mejor barrido, 1 semilla)	8 / 0.03	0.7261	0.6044	0.6651	marcado,
catboost-classifier (2º árbol, en banda)	6 / 0.05	0.7111	0.6132	0.6560	−0,0093,
burn-deep-classifier (mlp, mejor ajuste)	lr 0.0005 / [128,64]	0.7038	0.6221	0.6521	mejor AN
burn-deep-classifier (mlp, ganador Fase 1)	lr 0.001 / [128,64]	0.7001	0.6211	0.6470	red densa
burn-ae-classifier (trasplante AE, mejor)	enc[128,64]/clf[128,64]	0.6972	0.6216	0.6496	−0,0066 v
ngboost-classifier	—	0.6917	0.6293	0.6392	~ 2.3 band
pyramid-mlp-classifier (mejor arch-scan)	[512,256]	0.6792	2.0584	0.6326	red densa
pyramid-mlp-classifier (bake-off, 300 iter)	[256,128,64]	0.6781	2.4085	0.6326	red densa

(64 latente AE + 114 metadatos = 178 cols, 12,256 filas, 9,805/2,451 en semilla 42), variando solo la rama AE (kNN en $k \in \{10, 25, 50, 100, 200\}$, más una rama ridge-sobre-latente).

Resultados. Las seis ejecuciones (`run-20260609-131545-e34e4` y hermanas) tuvieron éxito, y todas devolvieron métricas de blend idénticas byte a byte — MAE 0.38789, R^2 0.191, RMSE 0.4475 — porque el ajustador de peso llevó $w \rightarrow 0$ en cada rama. El único eje que se movió fue el error autónomo de la rama AE mae_{ae} , que creció monótonamente con el tamaño de la vecindad, de 0.4259 en $k = 10$ a 0.4702 en $k = 200$ (la rama ridge aterrizó en 0.4623, entre $k = 100$ y $k = 200$). La Figura 1 muestra la curva contra las tres referencias horizontales que importan: incluso la mejor lectura AE ($k = 10$, 0.4259) nunca alcanza el árbol solo-metadatos (0.3879), ni siquiera el `xgboost` de solo-latente-AE registrado (0.4098).

Interpretación. El colapso a $w = 0$ es la respuesta correcta, no un bug a arreglar: dada una rama AE estrictamente peor que la rama XGB en el holdout, el peso convexo óptimo *es* cero. El único valor real de la arquitectura fue que *aisló* el latente en una rama que el ajustador podía descartar, recuperando un resultado más limpio que alimentar el latente a un XGBoost unificado — lo que de hecho *diluye* el árbol (MAE 0.3965 con las 64 columnas de latente presentes frente a 0.3879 con ellas descartadas). El latente song-AE se une así a la co-escucha, el texto-contenido y los rasgos acústicos como una modalidad densa que pierde ante los one-hots de identidad categórica. La única salvedad en su momento era honestidad sobre la significancia: la ventaja de 0,3879 frente a 0,3965 es de solo 0,0086 de MAE sobre un objetivo $[0, 1]$, y la banda de ruido de rotación estaba entonces sin medir — así que la campaña reportó el número pero no afirmó victoria significativa y no promovió nada. *Fuente:* `2026-06-09-ae-xgboost-blend.md`.

Cuadro 3: Rotación, régimen de *clasificación*, **matriz high-vocab completa de 64-d** — ordenado por AUC (mejor cuanto más alto). Dataset **ds-20260612-143014-p64-s42** (23 529 filas, 497 cols: 64 PCA song-AE + 9 numéricos + 426 one-hots de identidad — artista 301, género 121, tipo-álbum 4). **No comparable con las Tablas 1 o 2:** comparte el corpus, las filas y la partición 60/40 pero eleva la cardinalidad de identidad (tope de artista 60 → 300, género 40 → 120), así que toda familia se re-ejecutó aquí para un ranking fresco dentro del dataset. Los árboles subieron sobre la matriz más ancha (xgboost 0,7204 → 0,7299, catboost 0,7111 → 0,7252). El **burn-deep-classifier** guardado (**embeddings**) es la primera ANN en alcanzar el nivel de los árboles dentro del dataset y superar la barra de guardado de rotación (Sección 6.8); xgboost es el líder dentro del dataset pero ninguna regla de guardado de árbol disparó esta campaña. Banda de AUC $2\sigma \approx 0,0126$ (estimación del corpus antiguo, aproximada aquí).

Modelo	config	AUC	log-loss	exactitud	Nota
xgboost-classifier (líder intra-dataset)	d6 / lr0.05	0.7299	0.6022	0.6719	no registrado
catboost-classifier (2º árbol)	defaults	0.7252	0.6068	0.6649	−0,0047, en b
burn-deep-classifier (embeddings, mejor Fase 2)	ed8 / lr0.0005	0.7228	0.6105	0.6645	nivel árboles;
burn-deep-classifier (embeddings, <i>guardado</i>)	ed16 / lr0.001	0.7192	0.6087	0.6694	registrado (hi
burn-deep-classifier (mlp)	lr0.001	0.7129	0.6166	0.6617	−0,0063 vs er
burn-deep-classifier (wide_deep)	lr0.001	0.7061	0.6256	0.6526	rezagado, aml

Cuadro 4: Rotación, régimen de *regresión*, **corpus DS-META** — ordenado por MAE sobre la escala $[0, 1]$ de $P(\text{rotación})$ (mejor cuanto más bajo). El líder XGBoost solo-metadatos es la rama **mae_xgb** reproducida dentro de cada ejecución de blend; nunca se guardó como definición autónoma. La fila SVM-poly se lista por completitud y está *refutada*: su MAE más bajo es el artefacto del tubo- ϵ de la Sección 5.2, su R^2 es negativo. Banda de ruido de MAE $2\sigma = 0,0086$.

Modelo	MAE	RMSE	R^2	Fuente
XGBoost solo-metadatos (latente AE descartado)	0.3879	0.4475	0.191	ae-blend / svm
xgboost sobre latente+metadatos combinados	0.3965	—	0.166	giro rotación
xgboost sobre solo-latente AE (64 cols)	0.4098	—	0.132	giro rotación
svm (poly, artefacto tubo- ϵ — REFUTADO)	0.3814	0.5303	−0,137	svm

5.2. SVM de kernel sobre rotación: una refutación, y la trampa del MAE binario

Motivación. Descartado el latente, esta campaña probó si algún kernel SVM (rbf / lineal / poly / sigmoide) produce un predictor de rotación competitivo con el líder XGBoost solo-metadatos y — solo si alguno pasaba — si añadía señal ortogonal en un blend ponderado por grilla. La matriz de metadatos se redujo al pca floor en un dataset nuevo (**ds-20260609-141622-p1-s42**, 115 cols), con dos hermanas de semilla de partición (semillas 17 y 101) construidas para medir la banda de ruido, y el campeón reproducido como control (**run-20260609-141717-9a8ba-autoencoder-xgboost**, peso de blend 0). Un resultado secundario fue el entregable central de la campaña: la **primera banda de ruido de rotación medida**.

Resultados. A través de las tres semillas de partición del control XGBoost solo-metadatos (s42 0.387891, s17 0.393072, s101 0.396417) la desviación estándar muestral es $\sigma_{\text{split}} = 0,00430$, dando una banda de significancia 2σ de **0.0086 de MAE** sobre la escala $[0, 1]$. Esto zanja re-




Figura 1: El latente song-AE no lleva ninguna señal de rotación que los one-hots de metadatos no lleven ya mejor. El error autónomo kNN mae_{ae} sube monótonamente conforme se ensancha la vecindad (la señal del latente es más fuerte en vecindades locales estrechas y se diluye hacia la tasa base), e incluso su mejor punto queda por encima tanto del árbol de solo-latente-AE como del árbol solo-metadatos. El ajustador de peso correctamente lleva el peso del blend a cero, así que el ensamble colapsa a XGBoost solo-metadatos.

troactivamente la pregunta abierta de la campaña previa: la ventaja de 0,3879 frente a 0,3965 es $\Delta 0,0086 \approx 1$ -banda (probablemente mejor, no confiada), mientras que la brecha de 0,3879 frente a 0,4098 (solo-latente-AE) es $\sim 2,5$ -banda y por tanto real. En cuanto a las ramas SVM, rbf, lineal y poly publicaron todas MAE dentro de la banda del control (0.381–0.390), *más bajo* que el campeón en el caso poly (0.3814) — pero cada una de ellas es peor-que-la-media en R^2 ($-0,13$ a $-0,20$), con RMSE 0.53–0.54 contra el 0.4475 del árbol. El SVR sigmoide divergió de plano: MAE 0.624, RMSE 1.531, $R^2 -8,48$, con predicciones alcanzando 24.7 sobre un objetivo $[0, 1]$ — la clásica explosión del SVR-sigmoide no acotado. La Figura 2 contrasta las dos vistas de métrica directamente.

Interpretación. El MAE de SVR bajo es una degeneración de la métrica sobre un objetivo binario. Con un tubo- ϵ de ancho 0,1 sobre etiquetas $\{0, 1\}$, el SVR colapsa a una función escalón de dos niveles anclada cerca de las clases correctas — cada fila queda a unos 0,1 de su etiqueta, así que el MAE es pequeño, mientras que la calibración y el ranking quedan destruidos (R^2 negativo). La métrica que importa para el `fit_norm` del Pathfinder (ranking y calibración, es decir R^2 /RMSE/AUC) dice que el SVM pierde decisivamente. Peor aún, los dos blends de la etapa 2 (`run-20260609-143114-528ef-blend` y su gemelo `lgbm`) ajustaron pesos de exactamente $[0, 0, 1, 0]$ — la grilla, optimizando el mismo MAE de validación degenerado, *seleccionó mal SVM puro* y descartó el árbol, lo opuesto al auto-deshabilitado visto en la campaña de blend. La lección es contundente: un objetivo de blend por-grilla-por-MAE es en sí inseguro sobre un objetivo binario. Nada se registró ni promovió; el SVM de kernel se volvió la quinta familia de régimen denso en perder ante la identidad one-hot sobre este corpus. *Fuente: 2026-06-09-sum-kernel-rotation.md.*




Figura 2: Sobre un objetivo binario, un MAE de SVR bajo es un artefacto, no habilidad. Con $\epsilon = 0,1$ sobre un objetivo $\{0, 1\}$ el SVR ajusta sus salidas a los bordes del tubo- ϵ (un escalón duro de dos niveles, $p_{50} \approx 0,10$, $p_{90} \approx 0,90$), así que cada fila queda solo $\sim 0,1$ de su etiqueta y el MAE (izquierda) lee competitivo. El R^2 honesto (derecha) lo expone: cada kernel es peor que predecir la media. El sigmoide está fuera de escala en $R^2 = -8,48$.

5.3. El bake-off honesto de AUC y el primer campeón de AUC

Motivación. La campaña SVM expuso que el MAE es la lente equivocada para un objetivo binario. Mientras tanto el framework había ganado un modo de clasificación (`domain.toml task = binary`, métrica principal AUC, mejor cuanto más alto; el grupo de mejores modelos ordena por AUC y auto-promueve la ejecución superior). Esta campaña re-ejecutó la comparación sobre ese pie honesto: xgboost-classifier contra logistic y un barrido de cuatro kernels SVC, todos sobre DS-META, más una rama de 178 columnas con el latente AE re-añadido para zanjar la cuestión de dilución del latente sobre el eje AUC, y tres semillas de control para medir la banda de ruido de AUC. La hipótesis — un sexto test del hallazgo convergente — era que xgboost-classifier gana y toda familia densa pierde.

Resultados. Las nueve ejecuciones tuvieron éxito. La config campeona (`run-20260609-172920-6 27d6-xgboost-classifier`, hiperparámetros de control, semilla 42) alcanzó **AUC 0.7429** (log-loss 0.5883, exactitud 0.6846, Brier 0.2017) y se registró como `xgboost-classifier-rotation` y se auto-promovió a mejores-modelos rango 1 — el primer campeón de rotación del proyecto guardado, puntuado por AUC y promovible. La primera banda de ruido de AUC medida viene de las tres semillas de control (s42 0.742934, s17 0.730659, s101 0.734469, media 0.736020): $\sigma_{\text{AUC}} = 0,00628$, $2\sigma = \mathbf{0.0126}$ (Figura 4). Esta banda es una métrica distinta de la banda de 0.0086 de MAE y no la reemplaza. Toda familia densa perdió por muchas bandas — `svc-poly` 0.6855, `logistic` 0.6762, `svc-rbf` 0.6722, `svc-linear` 0.6363, `svc-sigmoid` 0.6255 — un rango de 4.6 a 9.3 bandas de ruido por debajo del campeón (Figura 3). La rama de 178 columnas (latente AE re-añadido) puntuó 0.7350, $-0,0079$ por debajo del campeón solo-metadatos — la misma dirección dilutiva que el resultado de regresión, pero dentro de la banda de AUC, así que neutral-tirando-a-dilutivo en una semilla única.




Figura 3: La métrica de clasificación honesta confirma el hallazgo convergente por sexta vez. xgboost-classifier lee la identidad dispersa de artista/género/álbum de los one-hots sin pérdida; las familias densas de distancia/margen (logistic y los cuatro kernels SVC) difuminan esa identidad en un espacio de rasgos denso y aterrizan de 4.6 a 9.3 bandas de ruido más abajo. La franja sombreada es la banda $2\sigma = 0,0126$ bajo el campeón; ningún retador llega a una banda de él.

Interpretación. Reencuadrar la rotación como clasificación hizo dos cosas a la vez. Disolvió la ilusión del SVR de la Sección 5.2 — bajo AUC, log-loss y Brier, cada kernel SVC es ahora visiblemente peor que los árboles, todos en la misma dirección, así que el artefacto del tubo- ϵ que hacía parecer competitivo el MAE del SVR simplemente se desvanece. Y confirmó que la métrica solo fue siempre un problema para la *justicia de la comparación*; la familia densa siempre fue la perdedora. Notablemente svc-sigmoid no colapsa al azar bajo clasificación (mantiene AUC 0.6255 en vez de explotar): un objetivo de probabilidad propio quita la divergencia no acotada que arruinó la ejecución SVR-sigmoide. El hallazgo convergente ahora se sostiene sobre una métrica honesta: la señal de ajuste de gusto vive en la *identidad* de artista/género/álbum, capturada por one-hots dispersos y explotada por árboles, no en modelos densos de distancia o margen. La palanca restante es la *resolución* de identidad — elevar los topes de vocabulario para que la cola `artist=__other__` obtenga columnas reales — no nuevas modalidades ni familias. La próxima campaña planificada es un barrido de hiperparámetros del campeón ahora que la familia y la métrica están zanjadas. Fuente: 2026-06-09-rotation-classification.md.

5.4. Bake-off de cuatro familias sobre el nuevo corpus completo de 64-d, y un barrido xgboost de depth/lr

Motivación. Las tres primeras campañas corrieron sobre el corpus original DS-META. Esta campaña re-planteó la pregunta de familia sobre el corpus 2026 mayor — “todo el embedding de 64-d”, la matriz completa de 177 columnas (ds-20260609-204419-p64-s42, 23 529 filas, 64 PCA song-AE + 7 numéricos + 106 one-hots de identidad) — poniendo cuatro familias de clasificadores cara a cara con defectos de registro, semilla 42: xgboost-classifier, catboost-classifier, ngboost-classifier y un pyramid-mlp-classifier denso. Las tres últimas son *familias nuevas en este proyecto*. El ganador luego se ganó un barrido de `max_depth`×`learning_rate`. La única




Figura 4: La primera banda de ruido de AUC de rotación medida. Tres semillas de partición de datos de la config campeona registrada dan $\sigma_{\text{AUC}} = 0,0063$ y una banda de significancia 2σ de 0,0126. En términos relativos es de hecho más estrecha que la banda de MAE (0.85 % frente a 1.10 % de coeficiente de variación), como se espera de una métrica de rango sobre 2,451 filas de prueba. La banda solo importa para la decisión sub-banda de dilución del latente; campeón y retardadores están separados por muchas bandas.

referencia intra-corpus válida es una ejecución preexistente sobre este dataset (run-20260609-2047 26-439d8-xgboost-classifier, AUC 0,7204); nada aquí puede leerse contra el campeón DS-META de 0,7429 (distinto corpus y conjunto de rasgos).

Resultados. Las cuatro ramas del bake-off tuvieron éxito (Tabla 5; Figura 5). **xgboost-classifier** (run-20260612-115909-840c0-xgboost-classifier) ganó con AUC 0,7204, reproduciendo la referencia intra-corpus byte a byte (0,7204383403) — la puerta de determinismo pasó. **catboost-classifier** (run-20260612-115909-c7ef6-catboost-classifier) siguió en 0,7111, −0,0093 detrás — *dentro* de la banda ~ 0.0126 , así que co-líder y la segunda familia de árboles legítima, no una pérdida. **ngboost-classifier** (run-20260612-115909-d725b-ngboost-classifier) aterrizó en 0,6917 (~ 2.3 bandas atrás), y el **pyramid-mlp-classifier** denso (run-20260612-115909-ea698-pyramid-mlp-classifier) fue último en 0,6781 — con un log-loss de 2,4085 y Brier 0,3251 muy por encima de los ~ 0.60 – 0.63 / ~ 0.21 de los árboles, el diagnóstico diseccionado en la Sección 6.

Cuadro 5: Fase 1 — el bake-off de cuatro familias sobre el nuevo corpus completo de 64-d (ds-20260609-204419-p64-s42, semilla 42, defectos de registro). Las cuatro tuvieron éxito. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador en negrita; mejor celda por métrica en negrita.

Rama / run id	Predictor	AUC	log-loss	exactit
C0 (run-20260612-115909-840c0-xgboost-classifier)	xgboost-classifier	0.7204	0.6075	0.658
A1 (run-20260612-115909-c7ef6-catboost-classifier)	catboost-classifier	0.7111	0.6132	0.656
A2 (run-20260612-115909-d725b-ngboost-classifier)	ngboost-classifier	0.6917	0.6293	0.639
A3 (run-20260612-115909-ea698-pyramid-mlp-classifier)	pyramid-mlp-classifier	0.6781	2.4085	0.632




Figura 5: El orden de familias sobrevive al cambio de corpus. Sobre la matriz completa de 64-d de 2026 mayor las dos familias de árboles de gradient boosting lideran (**xgboost** ganando, **catboost** co-líder dentro de la banda 2σ sombreada bajo el ganador); **ngboost** queda ~ 2.3 bandas atrás; el **pyramid-mlp** denso es último, el mismo hallazgo convergente visto sobre DS-META en la Figura 3.

El ganador se ganó un barrido de Fase 2 sobre $\text{max_depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0.03, 0.05, 0.1\}$ (datos en forma de tabla en el informe fuente; Figura 6). La profundidad es el eje dominante: cada celda de profundidad-4 está en el fondo (0.7074–0.7119), y la esquina profundidad-8 / lr-0.03 encabeza la grilla en 0,7261 (`run-20260612-120207-2dd3d-xgboost-classifier`, log-loss 0,6044). Un learning rate alto (0.1) perjudica consistentemente tanto el AUC como la calibración. Pero la brecha mejor-vs-defecto (+0.0057) está *dentro* de la banda, así que la config por defecto profundidad-6/lr-0.05 se guardó como la definición del nuevo corpus y la celda profundidad-8/lr-0.03 se marcó para una confirmación de 3 semillas en vez de promoverse.

Interpretación. El hallazgo convergente sobrevive intacto al cambio de corpus: sobre un corpus distinto y mayor con el latente AE presente, las dos familias de árboles vuelven a liderar y la red densa vuelve a ser última. **catboost** se gana su lugar como segunda familia de árboles legítima (co-líder en banda) — un miembro de diversidad-de-árboles / segunda-opinión, no una ganancia de AUC sobre **xgboost**. **ngboost** paga por su maquinaria distribucional: los aprendices base poco profundos (`base_max_depth` 3) sub-ajustan la matriz de 177 columnas densa en one-hot. El AUC de último lugar del pyramid-MLP *más* su log-loss reventado son la firma de red densa; el bake-off leyó el log-loss como un artefacto de sub-entrenamiento de 300 iteraciones y prescribió más presupuesto — una hipótesis que la campaña siguiente prueba y refuta. *Fuente: 2026-06-12-classifier-bakeoff-p64.md.*

5.5. Barrido de arquitectura del Pyramid-MLP: refutando la hipótesis de presupuesto

Motivación. El bake-off marcó el último lugar del pyramid-MLP (AUC 0,6781, log-loss 2,4085) como un artefacto de sub-entrenamiento por el tope de 300 iteraciones, prescribiendo “subir `max_iter` para que la red converja”. Este seguimiento prueba ese mecanismo directamente: seis geometrías de pirámide, todas con `max_iter` subido a **800**, α 1×10^{-4} , learning rate 1×10^{-3} ,




Figura 6: El barrido xgboost `max_depth`×`learning_rate` sobre el nuevo corpus. La profundidad es la palanca (el AUC sube monótonamente por el eje de profundidad a los learning rates lentos), y un learning rate rápido perjudica. La mejor celda (profundidad 8, lr 0.03, recuadrada) alcanza 0,7261 pero solo +0,0057 sobre el defecto — dentro de la banda 2σ — así que la config por defecto permanece guardada y la mejor celda espera un confirm de 3 semillas.

semilla 42, sobre el mismo dataset — de modo que la comparación refleja *arquitectura*, no presupuesto. ¿Alguna geometría, dado el presupuesto para converger, eleva la familia densa a un AUC competitivo?

Resultados. Refutado en todo aspecto (Tabla 6; Figuras 7 y 8). **Ninguna rama alcanzó el tope de 800:** cada geometría se auto-detuvo en **73–100 iteraciones** vía la tolerancia de meseta de pérdida `n_iter_no_change` de sklearn — muy por debajo incluso del viejo tope de 300, así que el presupuesto nunca fue la restricción vinculante. El indicio decisivo: la rama de re-línea-base M0 ([256,128,64], la geometría del bake-off ahora en `max_iter` 800) reprodujo el AUC de la ejecución sub-entrenada hasta todos los dígitos — 0,6780926 frente a 0,6780926 — porque corrió las mismas 73 iteraciones. Subir el tope de 300 a 800 no cambió nada. La mejor geometría convergida fue M1 [512,256] con AUC 0,6792 (run-20260612-123155-0ace5), un empate estadístico con el defecto sub-entrenado (+0,0011 $\approx$ cero) y ~ 3.3 bandas por debajo de xgboost. Toda la familia aterriza en una franja de AUC de 0.0080 de ancho (0.6712–0.6792), enteramente dentro de una banda de ruido — el ranking de geometría no es resoluble en una semilla única — con el log-loss (2.06–2.78) y Brier (0.32–0.34) reventados al mismo nivel que el defecto sub-entrenado en cada rama. Ninguna definición se guardó (por debajo de la barra de guardado 0.683).

Interpretación. La refutación es limpia y doble: ni el presupuesto de entrenamiento (cada rama se auto-detiene muy por debajo del tope; M0 reproduce el AUC sub-entrenado hasta todos los dígitos) ni la arquitectura (las seis geometrías dentro de una banda) mueven la familia densa. El log-loss alto no es por tanto una trayectoria de entrenamiento truncada sino un genuino *techo de calibración* a estos hiperparámetros — la meseta elegida por el optimizador. Con las propias perillas de la familia densa agotadas, la restricción vinculante debe estar en otra parte: en la *representación* de entrada, el tema de la Sección 6. La tendencia direccional dentro de familia — más ancho-y-poco-profundo levemente favorecido (M1 arriba), profundidad/capacidad levemente dañina (M5 ancha-profunda última) — es consistente con una red densa luchando por encaminar

Cuadro 6: El barrido de arquitectura de seis geometrías del pyramid-MLP (ds-20260609-204419-p64-s42, max_iter 800, alpha 1×10^{-4} , lr 1×10^{-3} , semilla 42), ordenado por AUC. Las seis tuvieron éxito; *ninguna* alcanzó el tope de 800 iteraciones — cada una se auto-detuvo en el conteo de iteraciones listado. Mejor celda por métrica en negrita.

Rama	Capas ocultas	AUC	log-loss	Brier	Iters (de 800)
M1 ancha-poco profunda	[512, 256]	0.6792	2.0584	0.3216	75
M0 re-línea-base	[256, 128, 64]	0.6781	2.4085	0.3251	73
M4 estrechamiento suave	[384, 307, 246]	0.6777	2.7764	0.3292	87
M2 pirámide profunda	[256, 128, 64, 32]	0.6737	2.7631	0.3303	100
M3 estrechamiento fuerte	[512, 169, 56]	0.6736	2.7031	0.3365	89
M5 ancha-profunda	[512, 307, 184, 111]	0.6712	2.6457	0.3348	84

señal a través de 106 one-hots dispersos: capas extra añaden capacidad para memorizar y difuminar, no para separar. La familia está cerrada para AUC sobre este conjunto de rasgos; no re-escanear geometría ni presupuesto. *Fuente: 2026-06-12-pyramid-mlp-arch-scan.md.*

6. Por qué las redes neuronales artificiales rinden peor sobre datos de gusto densos en one-hot

El pyramid-mlp denso es la única red neuronal artificial en las campañas de rotación, y a lo largo de dos campañas de jun-12 aterriza última con un patrón de fallo distintivo. Esta sección consolida, rigurosamente, *por qué* — anclando cada afirmación en la evidencia de las campañas. La versión corta es el *hallazgo convergente* documentado del proyecto: sobre esta matriz de rasgos la restricción vinculante es la *representación* de entrada, y una red densa es la única clase de modelo estructuralmente desajustada a ella. Construimos el argumento en cinco partes y cerramos con el siguiente paso motivado.

6.1. La matriz de rasgos es mayormente identidad dispersa

La matriz completa de 64-d tiene 177 columnas, y su *composición* es toda la historia. **106 de las 177 columnas son one-hots dispersos de identidad**: artista ($\times 61$), genre_primary ($\times 41$) y album_type ($\times 4$). Solo 71 columnas son continuas — los 64 latentes PCA song-AE y 7 campos numéricos de metadatos (popularidades, número de seguidores, año de lanzamiento, número de artistas acreditados). Para una pista dada exactamente una columna de artista, una de género y una de tipo-álbum está activa; el resto de las 106 son cero. La matriz está, por construcción, dominada por un bloque mayormente-cero de indicadores mutuamente excluyentes.

Un árbol de gradient boosting lee este bloque *sin pérdida y barato*: una única partición alineada a ejes sobre la columna `artist=X` divide los datos exactamente sobre esa identidad, sin forzar ninguna interacción entre los one-hots y sin costo pagado por las columnas que son cero. Capturar “las pistas del artista *X* en el género *Y* rotan” le cuesta al árbol dos particiones anidadas. Una red densa no puede hacer esto. Debe aprender un peso *denso* desde cada una de las 106 entradas mayormente-cero hacia cada unidad oculta, y luego extraer una combinación no lineal — gastando capacidad y señal de gradiente modelando la estructura de un bloque que el árbol maneja con una comparación. Este es precisamente el régimen en el que los árboles dominan estructuralmente a las redes densas, y es el *hallazgo convergente* del proyecto, ahora observado a través de cuatro




Figura 7: Ambas perillas de la familia densa están agotadas. *Izquierda*: las seis geometrías aterrizan dentro de una única banda 2σ alrededor del defecto sub-entrenado — la arquitectura no es la restricción vinculante. *Derecha*: cada geometría se auto-detiene en 73–100 iteraciones, muy por debajo incluso del viejo tope de 300 (por no hablar del subido a 800), así que el *presupuesto* de entrenamiento tampoco fue nunca la restricción vinculante. El optimizador alcanza una meseta de pérdida de la que no puede escapar a este learning rate y se detiene. La restricción vinculante es la *representación* de entrada.

modalidades de rasgos y cinco familias de modelos: la señal de ajuste de gusto la lleva la identidad de artista/género, capturada por one-hots y explotada por árboles, no por atributos descriptivos ni modelos de distancia/margen/densos. El pyramid-MLP es simplemente el turno de la familia densa de perder ante ella.

6.2. La estandarización convierte categorías raras en picos atípicos

La red densa se alimenta con una matriz escalada con StandardScaler, y la estandarización interactúa patológicamente con los one-hots dispersos. Una columna one-hot para una categoría presente en una fracción p de filas tiene media p y desviación estándar $\sqrt{p(1-p)}$. Estandarizarla mapea las filas “encendidas” a

$$z_{\text{on}} = \frac{1-p}{\sqrt{p(1-p)}} = +\sqrt{\frac{1-p}{p}}, \quad z_{\text{off}} = \frac{0-p}{\sqrt{p(1-p)}} = -\sqrt{\frac{p}{1-p}}.$$

Para una categoría *rara* — la cola larga de artistas y géneros, donde p es pequeño — el valor “encendido” $+\sqrt{(1-p)/p}$ se vuelve un gran pico positivo (para $p = 0,01$ es $\approx +9,9$), mientras el valor “apagado” queda en un diminuto negativo $-\sqrt{p/(1-p)} \approx -0,1$. Cada identidad rara llega por tanto a la red como un atípico ocasional y enorme sobre su propio eje. Las unidades ReLU con Adam a learning rate 1×10^{-3} oscilan fuerte sobre estos picos — una única activación de categoría rara produce una gran pre-activación que el optimizador persigue — y la cabeza softmax/sigmoide se satura, emitiendo probabilidades cerca de 0 o cerca de 1 sobre evidencia delgada. Los árboles son inmunes: un umbral de partición sobre un one-hot es invariante a cualquier reescalado monótono,

así que el pico del escalador no les hace nada. Este es un contribuyente mecánico directo a la calibración reventada documentada a continuación.

6.3. La firma diagnóstica: ranking genuino, calibración rota

El fallo de la red densa tiene una firma precisa y reproducible en las métricas — y *no* es el fallo de un modelo débil. El pyramid-MLP publica $AUC \approx 0,68$ (0.6781 en el bake-off, 0.6792 el mejor en el barrido de arquitectura): señal de ranking genuina, bien por encima de la línea de azar de 0.5, solo ~ 3 bandas por debajo de los árboles. Pero *al mismo tiempo* su log-loss es $\approx 2,0$ – $2,8$ y su Brier $\approx 0,32$ – $0,34$, contra el log-loss $\approx 0,60$ – $0,63$ y el Brier $\approx 0,21$ de los árboles (Figura 8). Un predictor de tasa base constante (siempre emitiendo $p \approx 0,445$) puntúa un log-loss de solo $\approx 0,69$. **El log-loss de la red de 2.0–2.8 es así mucho peor que la línea base aleatoria, mientras que el 0.61 de xgboost está muy por debajo de ella.**




Figura 8: El diagnóstico de red densa: la red está confiadamente equivocada, no meramente débil. *Izquierda:* en AUC el pyramid-MLP genuinamente ordena ($\approx 0,68$, bien por encima del azar, ~ 3 bandas bajo los árboles) — hay señal real en su ordenamiento. *Derecha:* pero su log-loss ($\approx 2,0$ – $2,8$) es mucho *peor* que la línea base de tasa base aleatoria ($\approx 0,69$, punteada), mientras los árboles quedan muy por debajo de ella ($\approx 0,61$). Un modelo que ordena aceptablemente pero puntúa un log-loss peor-que-el-azar está emitiendo probabilidades confiadas y mal calibradas.

Esta combinación — ranking aceptable, log-loss peor-que-el-azar — significa que la red está *confiadamente equivocada*: empuja muchas predicciones a los extremos saturados (cerca de 0 o cerca de 1) del lado equivocado de la etiqueta, y el log-loss castiga cada error confiado así severamente. Está mal calibrada, no débil: el ordenamiento está ahí, pero las probabilidades adjuntas a ese ordenamiento son inutilizables como un `fit_norm`. El mecanismo es exactamente la saturación por pico del escalador de la Sección 6.2. Contrasta con los árboles, cuyas salidas de frecuencia de hoja están calibradas por construcción: una hoja que reporta probabilidad q es la frecuencia empírica de rotación de las filas de entrenamiento que caen en ella, así que las probabilidades del árbol son honestas por diseño — la razón por la que gana en log-loss y Brier además de AUC.

6.4. Optimización frente a representación: la restricción vinculante

Una objeción natural es que la red está meramente sub-optimizada — muy pocas iteraciones, la geometría equivocada. El barrido de arquitectura (Sección 5.5) descarta ambas. Sobre el eje de *presupuesto*, cada una de las seis geometrías se auto-detiene en 73–100 iteraciones, muy por debajo incluso del viejo tope de 300 (por no hablar del subido a 800): el optimizador alcanza una meseta de pérdida de la que no puede escapar, así que más presupuesto no compra nada — la rama de re-línea-base M0 reprodujo el AUC sub-entrenado hasta todos los dígitos porque corrió las mismas 73 iteraciones. Sobre el eje de *arquitectura*, las seis geometrías aterrizan dentro de una única banda de ruido, y la mejor geometría convergida reproduce el AUC sub-entrenado a cuatro dígitos (0.6792 frente a 0.6781). Ambas perillas internas a la familia densa están por tanto agotadas. Por eliminación, la restricción vinculante no es ni presupuesto ni arquitectura sino la *representación* de entrada — los one-hots crudos de la Sección 6.1, que la red no puede consumir como lo hace un árbol. Este es el diagnóstico que apunta a topologías conscientes de la representación (embeddings de entidad, wide-and-deep) como la única palanca sin probar, ya que están diseñadas precisamente para reemplazar one-hots crudos con una representación densa aprendida.

6.5. PCA ya se ha anticipado al trabajo no lineal de la red

Hay una segunda razón por la que la red densa tiene poco que hacer. Los 64 latentes PCA song-AE ya son una compresión *lineal, decorrelacionada* de un embedding de 1536 dimensiones: PCA ha extraído la estructura lineal dominante y entregado a la red componentes ortogonales con la mayor parte de la varianza lineal fácil ya separada. Cualquier interacción no lineal que una capa oculta pudiera descubrir en ese bloque ha sido en gran medida anticipada; poca estructura no lineal queda para que la profundidad de la red explote. La evidencia es directa: una regresión logística simple alcanza AUC 0.676 sobre este corpus y el MLP convergido alcanza 0.679 — un empate técnico. Una red ReLU multicapa no compra esencialmente nada sobre una única frontera lineal, que es exactamente lo que uno espera cuando el bloque continuo ya está linealmente pre-condicionado y el bloque categórico es la parte que lleva señal que la red no puede leer.

6.6. La pregunta abierta y el siguiente paso motivado

El diagnóstico es ahora agudo: el techo de la red densa lo fija su incapacidad de consumir identidad one-hot cruda, no el presupuesto, la arquitectura ni el bloque continuo. Eso aísla una única pregunta abierta y comprobable — *¿puede una topología consciente de la representación cerrar la brecha con los árboles?* Los dos ingredientes que apuntan al diagnóstico directamente son (i) **embeddings de entidad** para los grupos de identidad (artista, género, tipo-álbum), que reemplazan cada bloque one-hot disperso con un vector denso de baja dimensión aprendido — el arreglo estándar para categóricos de alta cardinalidad en redes, eliminando tanto el problema de pesos-densos-sobre-ceros de la Sección 6.1 como el problema del pico del escalador de la Sección 6.2; y (ii) una partición **wide-and-deep** — una ruta lineal ancha sobre los one-hots (para que la identidad se lea directamente, como la lee el árbol) junto a una ruta profunda sobre el bloque continuo. Una implementación en Rust/**burn** de tal red consciente de la representación — el **burn-deep-classifier** — se construyó precisamente para responder esta pregunta. La Sección 6.7 reporta sus resultados, y resuelven el diagnóstico limpiamente: la patología de calibración fue de hecho un artefacto de representación y está arreglada, pero la brecha de AUC con los árboles solo se *estrecha*, no se cierra.

Fuentes: 2026-06-12-classifier-bakeoff-p64.md, 2026-06-12-pyramid-mlp-arch-scan.md.

6.7. Resuelto: el burn-deep-classifier arregla la calibración pero no la brecha de AUC

Motivación. Las subsecciones precedentes dejaron una única pregunta abierta aguda: el techo de la red densa lo fija su incapacidad de consumir identidad one-hot cruda, así que *¿puede una topología consciente de la representación cerrar la brecha con los árboles?* El **burn-deep-classifier** — una red enteramente en Rust/**burn** — se construyó para responderla. Su diseño apunta directamente a las dos patologías diagnosticadas: mantiene los one-hots de identidad en *crudo* (estandarizando solo el bloque continuo de 64 PCA + 7 numéricos), de modo que el mecanismo de pico del escalador de la Sección 6.2 nunca dispara, y expone un enum **topology** sobre un **mlp** denso plano, **embeddings** de entidad aprendidos, y una partición **wide_deep**. La Fase 1 comparó las tres topologías (épocas 250, patience 20, early-stop sobre log-loss de validación, hidden [128, 64], embed_dim 8, lr 1×10^{-3} , batch 256); la Fase 2 ajustó al ganador. Las nueve ejecuciones corrieron sobre el mismo dataset completo de 64-d (ds-20260609-204419-p64-s42) y tuvieron éxito limpiamente.

Resultados. El titular es la recuperación de calibración (Figura 9). Cada topología aterriza en log-loss 0,621–0,628 y Brier 0,217–0,220 — de lleno en el régimen ~ 0.60 – 0.63 / ~ 0.21 de los árboles — contra el log-loss 2,0–2,4 y Brier 0,33 de la pirámide sklearn. **La patología de calibración está arreglada por completo.** Sobre el eje de topología (Tabla 7), el **mlp** plano gana con AUC 0,7001, con **embeddings** (0,6934) y **wide_deep** (0,6918) ambos dentro de la banda $2\sigma = 0,0126$ de él y entre sí — **embeddings** roza a **wide_deep** por un sub-banda +0,0016. El ajuste **mlp** de la Fase 2 (Tabla 8) tope en AUC 0,7038 (lr 5×10^{-4} , [128, 64]): la grilla de 6 celdas completa es una franja de 0,0081 de ancho (0,6957–0,7038), cada celda [128, 64] supera a cada celda [256, 128], y la mejor config es solo +0,0037 (dentro de banda) sobre el ganador de la Fase 1, así que la config **mlp** de la Fase 1 se mantiene. En 0,7038 la red queda $-0,0073$ bajo **catboost** (~ 0.6 banda) y $-0,0166$ bajo **xgboost** (~ 1.3 bandas); por debajo de la barra de guardado ~ 0.71 , así que ninguna definición se persistió.

Cuadro 7: Fase 1 — el bake-off de topología del **burn-deep-classifier** (ds-20260609-204419-p64-s42, params fijos: épocas 250, patience 20, hidden [128, 64], embed_dim 8, dropout 0.1, lr 1×10^{-3} , batch 256, relu; el único eje es **topology**). Las tres tuvieron éxito. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador en negrita; mejor celda por métrica en negrita.

Rama / run id	Topología	AUC	log-loss	exactitud	Brier
T-mlp (run-20260612-140116-41fc9-burn-deep-classifier)	mlp	0.7001	0.6211	0.6470	0.2170
T-emb (run-20260612-140116-0eda4-burn-deep-classifier)	embeddings	0.6934	0.6251	0.6436	0.2180
T-wd (run-20260612-140116-e85be-burn-deep-classifier)	wide_deep	0.6918	0.6281	0.6407	0.2190

Interpretación. El resultado resuelve la pregunta abierta de la Sección 6.6 en dos partes, y las dos respuestas apuntan en direcciones opuestas. Primero, el veredicto de *calibración* se revierte: el log-loss peor-que-el-azar del pyramid-MLP de la Sección 6.3 fue un artefacto de *representación* — one-hots crudos aplastados en el estandarizador — no una propiedad intrínseca de las redes densas sobre datos de gusto, y una red que mantiene los one-hots crudos está calibrada en el régimen de los árboles. La lectura anterior de “calibración rota es un techo fijo” se sostiene solo para la representación pirámide-sklearn. El AUC también se recuperó: el 0,7038 de la red burn es +0,025 sobre la mejor pirámide convergida (0,6792), ~ 2 bandas de ganancia genuina de poder de ranking, así que la conclusión previa de que “la familia MLP está cerrada para AUC en $\approx 0,68$ ” se revisa — una red Rust de one-hots crudos alcanza ~ 0.70 . Segundo, y en contra de la lectura

Cuadro 8: Fase 2 — ajuste de la topología `mlp` ganadora, una grilla `1r×hidden` (otros params fijos). Las seis tuvieron éxito, ordenadas por AUC; ganador en negrita, mejor celda por métrica en negrita. Toda la grilla está dentro de una banda de ruido, cada celda `[128, 64]` supera a cada celda `[256, 128]`, y la mejor ganancia sobre el ganador de la Fase 1 (+0,0037) es sub-banda — así que la config de la Fase 1 es la config de registro.

Run id	lr	hidden	AUC	log-loss	exactitud	Brier
<code>run-20260612-140211-6575a-burn-deep-classifier</code>	0.0005	[128,64]	0.7038	0.6221	0.6521	0.2172
<code>run-20260612-140211-21ad5-burn-deep-classifier</code>	0.002	<code>[128,64]</code>	0.6997	0.6227	0.6532	0.2174
<code>run-20260612-140211-18c9e-burn-deep-classifier</code>	0.001	<code>[128,64]</code>	0.6996	0.6213	0.6447	0.2175
<code>run-20260612-140211-fecb0-burn-deep-classifier</code>	0.0005	<code>[256,128]</code>	0.6966	0.6232	0.6424	0.2179
<code>run-20260612-140211-4c359-burn-deep-classifier</code>	0.002	<code>[256,128]</code>	0.6963	0.6245	0.6460	0.2183
<code>run-20260612-140211-0f4e1-burn-deep-classifier</code>	0.001	<code>[256,128]</code>	0.6957	0.6252	0.6424	0.2187

optimista, el arreglo de representación *no* alcanza el nivel de los árboles: en 0,7038 la red aún queda ~ 1 banda bajo `catboost` y ~ 1.3 bajo `xgboost`. La brecha se estrechó dramáticamente (de las ~ 3.3 bandas de la pirámide a ~ 1) pero no se cerró, así que el hallazgo convergente sobrevive intacto — los árboles aún leen los one-hots dispersos de identidad un pelo más efectivamente que incluso una red de one-hots crudos. La comparación de topología lo afila: que el `mlp` plano supere tanto a la variante de embedding como a la wide-deep es la *misma* lección de “la identidad ya está en los one-hots” que enseñaron las campañas de árboles, ahora reproducida dentro de la familia ANN — los embeddings aprendidos por grupo tienen poco que añadir sobre 61 one-hots de artista y 41 de género, y la palanca vigente para la red (como para los árboles) es la *resolución* de identidad: elevar los topes de vocabulario y la topología de embeddings debería por fin empezar a rendir — una predicción que la re-ejecución high-vocab de la Sección 6.8 luego confirma, volcando **embeddings** por encima de `mlp` y elevando la red al nivel de los árboles. Ninguna definición se guardó aquí (por debajo de la barra ~ 0.71); la red es una línea base densa fuerte, ahora honesta, y un miembro de ensamble natural por su sesgo inductivo decorrelacionado, no un campeón. *Fuente: 2026-06-12-burn-deep-topology.md.*

6.8. Confirmado: elevar la cardinalidad de identidad eleva la red de embeddings al nivel de los árboles

Motivación. La Sección 6.7 cerró con una predicción aguda y comprobable: la topología de **embeddings** de entidad perdió ante el `mlp` plano *solo* porque las cardinalidades de identidad (artista 61, género 41) eran demasiado bajas para alimentar un embedding aprendido, así que elevar los topes de vocabulario debería voltear el ranking. Esta campaña es la re-ejecución pareada que lo prueba directamente. Se construyó una matriz nueva (`ds-20260612-143014-p64-s42`) *idéntica* al dataset 60/40 completo de 64-d de la Sección 6.7 — mismas 23 529 filas, misma semilla de partición 42, PCA64 idéntico byte a byte — difiriendo en *un* eje solo: la cardinalidad de identidad, con el tope de artista elevado $60 \rightarrow 300$ (50,4% de cobertura) y `genre_primary` $40 \rightarrow 120$ (78,8%). Es una *tercera* matriz no comparable (497 columnas: 64 PCA + 9 numéricos + 426 one-hots — artista 301, género 121, tipo-álbum 4 — frente a las 177 de la matriz 60/40), así que todas las métricas aquí son referencias frescas dentro del dataset y nunca deben leerse contra las tablas 60/40 o DS-META. La pregunta titular: con la cardinalidad $5\times$ (artista) y $3\times$ (género) mayor, ¿ahora **embeddings** supera a `mlp`? La Fase 0 re-ejecutó los dos árboles para un nivel de árboles dentro del dataset; la Fase 1 re-ejecutó el bake-off de topología (la rama embeddings ahora en




Figura 9: La red consciente de la representación resuelve la pregunta abierta de la Sección 6.6. *Izquierda:* las tres topologías están dentro de una banda 2σ entre sí; el **mlp** plano gana y los **embeddings** de entidad apenas rozan a **wide_deep**, porque a estas cardinalidades de identidad (artista 61, género 41, tipo-álbum 4) los embeddings aprendidos están famélicos — rinden a cientos-o-miles de categorías, no docenas (una hipótesis que la Sección 6.8 confirma elevando los topes). *Derecha:* el titular. Mantener los one-hots en *crudo* baja el log-loss del $\approx 2,0$ de la pirámide sklearn (confiadamente mal calibrada, peor que la línea base aleatoria) a $\approx 0,62$, al régimen de los árboles — una confirmación limpia de que la patología de calibración fue un artefacto de representación, no una propiedad intrínseca de las redes sobre estos datos.

embed_dim 16, ya que la mayor cardinalidad justifica una tabla más ancha); la Fase 2 ajustó la topología ganadora sobre embed_dim $\times$ lr.

Resultados. El ranking **se volteó** (Tabla 9; Figura 10). **embeddings** (run-20260612-143411-e8d b6-burn-deep-classifier) gana con AUC 0,7192, con **mlp** en 0,7129 (+0,0063) y **wide_deep** último en 0,7061 (+0,0131). Sobre la matriz 60/40 **mlp** había superado a **embeddings** por +0,0067; aquí **embeddings** supera a **mlp** por +0,0063 — un **vuelco de** +0,0130 a favor del embedding, cruzando la banda, la reversión cualitativa que la hipótesis de inanición predijo. La Fase 0 muestra que ambos árboles también subieron sobre la matriz más ancha: xgboost 0,7204 $\rightarrow$ 0,7299 (+0,0095, run-2026 0612-143411-02fda-xgboost-classifier, log-loss 0,6022) y catboost 0,7111 $\rightarrow$ 0,7252 (+0,0141, run-20260612-143411-8f15e-catboost-classifier), así que el vocabulario alto es señal genuina para *toda* familia — no le entrega al embedding una ventaja única, *desbloquea* una topología que antes estaba famélica. El ajuste de la Fase 2 sobre embed_dim $\times$ lr (mejor embed_dim 8 / lr 5×10^{-4} , AUC 0,7228, run-20260612-143508-3310f-burn-deep-classifier) muestra que la victoria vino de *habilitar* embeddings más un learning rate más lento, no de una tabla más ancha: el AUC es monótono-decreciente en embed_dim al lr lento (ed8 0,7228 > ed16 0,7210 > ed32 0,7200, un rango sub-banda de $\sim 0,0028$), así que embed_dim ya está saturado en 8. La mejor celda ajustada supera al ganador de la Fase 1 por solo +0,0036 (sub-banda), así que la regla de decisión guardó la config de la *Fase 1* (embeddings, embed_dim 16, lr 1×10^{-3}) como **burn-deep-embeddings-highvocab**. Un gemelo de determinismo reprodujo la ejecución de la Fase 1 a cuatro dígitos (0,71923 frente a 0,71923). En 0,7192 la red guardada queda $-0,0060$ bajo catboost (< 1 banda) y $-0,0107$ bajo

xgboost, dentro de la banda de la segunda familia de árboles — la primera ANN en alcanzar el nivel de los árboles dentro del dataset y superar la barra de guardado de rotación.

Cuadro 9: Fase 1 — el bake-off de topología del **burn-deep-classifier** sobre la matriz **high-vocab** (ds-20260612-143014-p64-s42, params fijos: épocas 250, patience 20, hidden [128, 64], embed_dim 16, dropout 0.1, lr 1×10^{-3} , batch 256, relu; el único eje es **topology**). Las tres tuvieron éxito. El ranking *revierte* el resultado 60/40 de la Tabla 7: **embeddings** ahora gana. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador en negrita; mejor celda por métrica en negrita.

Topología / run id	Topología	AUC	log-loss	exactitud	
T-emb (run-20260612-143411-e8db6-burn-deep-classifier)	embeddings	0.7192	0.6087	0.6694	0.2114
T-mlp (run-20260612-143411-01d7b-burn-deep-classifier)	mlp	0.7129	0.6166	0.6617	0.2108
T-wd (run-20260612-143411-7d117-burn-deep-classifier)	wide_deep	0.7061	0.6256	0.6526	0.2114

Cuadro 10: Fase 2 — ajuste de la topología **embeddings** ganadora, una grilla embed_dim×lr (hidden [128, 64], otros params fijos), ordenada por AUC; ganador en negrita, mejor celda por métrica en negrita. El AUC es monótono-decreciente en embed_dim a lr 5×10^{-4} (la tabla ya está saturada en ancho 8), y lr 5×10^{-4} supera a lr 1×10^{-3} en todo ancho. La mejor ganancia sobre el ganador de la Fase 1 (+0,0036) es sub-banda, así que la config de la Fase 1 es la config de registro.

embed_dim	lr	AUC	log-loss	exactitud	Brier
8	0.0005	0.7228	0.6105	0.6645	0.2114
16	0.0005	0.7210	0.6088	0.6711	0.2108
32	0.0005	0.7200	0.6100	0.6657	0.2114
8	0.001	0.7193	0.6092	0.6643	0.2112
16	0.001	0.7192	0.6087	0.6666	0.2110
32	0.001	0.7183	0.6097	0.6668	0.2114

Interpretación. Esto resuelve la pregunta abierta de la Sección 6.7 *confirmada*: la pérdida anterior de la topología de embedding fue un artefacto de inanición por baja cardinalidad, no un límite intrínseco, y elevar los topes voltea el ranking exactamente como se predijo. Dos salvedades honestas mantienen la afirmación calibrada. Primera, el margen single-split emb-vs-mlp (+0,0063) es en sí sub-banda, así que la *magnitud* de la reversión necesita un confirm de 3 particiones; lo decisivo es la *dirección* — todo el ranking se reordenó, con la rama de embedding pasando del fondo del ranking 60/40 a la cima de este. Segunda, el vocabulario alto ayuda a *todos*: los árboles ganaron tanto como (catboost) o más que la rama de embedding, así que la lectura correcta es “mayor resolución es mejor señal para toda familia, y específicamente desbloquea la topología de embedding”, no “embeddings ahora ganan de plano” — xgboost en 0,7299 sigue siendo el líder dentro del dataset, ~0,0107 (~1 banda) sobre la red guardada. Pero el arco cualitativo que recorrió la Sección 6 ahora cierra limpiamente: una red densa que consume one-hots crudos está calibrada en el régimen de los árboles (Sección 6.7), y dada *suficiente* resolución de identidad su topología de embedding alcanza el nivel de los árboles — la palanca vigente de “la resolución de identidad es la palanca”, demostrada. El log-loss (~0.61) y el Brier (~0.21) se mantienen en el régimen calibrado de los árboles todo el tiempo, así que no hay penalización de calibración por la victoria. Una nota de higiene de datos: el reporte de redundancia del manifiesto high-vocab marca 21 colinealidades




Figura 10: La resolución de identidad cierra el hilo de trampas-ANN. *Izquierda:* la comparación pareada **embeddings**-frente-a-**mlp** a través de las dos cardinalidades. Sobre la matriz 60/40 **mlp** gana por +0,0067; sobre la matriz high-vocab **embeddings** gana por +0,0063 — un vuelco de +0,0130 que revierte el ranking y confirma el diagnóstico de inanición: con la cardinalidad de artista 5× y la de género 3× mayor la tabla de embeddings por fin tiene suficientes identidades distintas para aprender una geometría de bajo rango útil en vez de colapsar casi constante. *Derecha:* el ranking de AUC de cinco familias dentro del dataset sobre la matriz high-vocab. La red **embeddings** guardada (0,7192) alcanza el fondo del nivel de los árboles (sombreado: desde una banda bajo **catboost** hasta **xgboost**) — la primera ANN en hacerlo — mientras **xgboost** (0,7299) sigue siendo el líder dentro del dataset.

one-hot casi perfectas género↔artista (p.ej. `genre_primary=australian psych` $\equiv$ `artist=Tame Impala`, correlación 1,000; 19 más $\geq 0,957$), un artefacto de admitir géneros raros llevados por un único artista recién admitido; los árboles y los regularizadores de la red lo absorben sin patología de ejecución observada, pero conviene saberlo antes de leer importancias de one-hots individuales sobre esta matriz. El **burn-deep-embeddings-highvocab** guardado se marca para el best-model-selector como la primera ANN de nivel de árboles y un candidato natural de diversidad de familia. *Fuente: 2026-06-12-high-vocab-topology.md.*

6.9. Una segunda red consciente de la representación: el trasplante AE confirma el techo

Motivación. La Sección 6.7 estableció que una red que mantiene los one-hots de identidad en *crudo* está calibrada en el régimen de los árboles pero aún tope ~ 1 banda bajo los árboles. Una pregunta natural siguiente es si una *representación no supervisada aprendida* de las mismas entradas — en vez de las entradas crudas mismas — eleva la red más. El **burn-ae-classifier** lo prueba: la Fase 1 pre-entrena un autoencoder para reconstruir el vector de rasgos ensamblado completo (bloque continuo estandarizado junto a los one-hots crudos, $D=177$) por MSE, la Fase 2 trasplanta el encoder a un clasificador softmax y afina. Esta campaña es la primera caracterización de la familia — un barrido de 13 configs sobre la matriz 60/40 completa de 64-d (ds-20260609-204419-p64-s42, semilla 42) sobre tamaño de latente, profundidad/ancho de cabeza,

activación y la bandera `freeze_encoder`, leído contra el campeón `xgboost` intra-corpus (0,7204) y el `mlp burn-deep` comparable (0,7038).

Resultados. La capacidad no importa para esta familia sobre rotación (Tabla 11; Figura 11). Las 12 configs afinadas abarcan una única franja de 0,0054 de ancho (0,69175–0,69719), enteramente dentro de la banda $2\sigma = 0,0126$ — un empate plano a través de un rango de latente de $4 \times$ (32 a 128), a través de profundidad y ancho de cabeza, y a través de activación. La mejor nominal (cfg3, enc[128, 64]/clf[128, 64], AUC 0,69719) supera la línea base 0,69225 por solo +0,00494 (sub-banda), e incluso la sonda lineal pura (cfg2, clf[], 0,69175) está solo −0,00544 por debajo de ella: una única capa lineal sobre el latente afinado ya captura esencialmente toda la habilidad de la familia. El único efecto fuera de banda es una *trampa*: congelar el encoder pre-entrenado por MSE es seguro bajo una cabeza poco profunda (cfg11, 0,69530, en banda) pero *colapsa* bajo una cabeza profunda (cfg10, 0,68210, −0,0151 ≈ 1.2 bandas, la peor fila). `relu` roza a `gelu` y `silu` por un margen sub-banda. La calibración es sana en todo momento (log-loss ~ 0.62 , Brier ~ 0.22 — el régimen de los árboles), así que es un miembro denso calibrado legítimo, solo que no un contendiente de AUC: la mejor config queda ~ 1.8 bandas bajo `xgboost` y es *estadísticamente igual* al `mlp burn-deep` plano (−0,0066, sub-banda). Ninguna definición se guardó.




Figura 11: La red de trasplante AE confirma el techo de la red densa sobre dos ejes. *Izquierda*: las 12 configs afinadas colapsan sobre una única franja de 0,0054 de ancho dentro de la banda de ruido, muy por debajo del `mlp burn-deep` comparable (discontinua, 0,7038) y el campeón `xgboost` (verde, 0,7204) — tamaño de latente, profundidad/ancho de cabeza y activación son todas palancas agotadas; la capacidad está saturada en la config más pequeña probada. *Derecha*: el único efecto real. Congelar el encoder pre-entrenado por MSE es seguro bajo una cabeza (casi-)lineal (cfg11, en banda) pero *colapsa* el modelo bajo una cabeza profunda (cfg10, −0,0151 ≈ 1.2 bandas): una cabeza profunda apilada sobre una representación congelada y agnóstica a la tarea simplemente sub-ajusta la etiqueta, porque los gradientes que habrían re-formado el encoder hacia el objetivo están bloqueados. El afinado de extremo a extremo (el defecto de registro) evita la trampa.

Interpretación. El pre-entrenamiento AE compra un init rápido y estable pero *ningún* AUC sobre una red de one-hots crudos desde cero: como el objetivo de reconstrucción es puramente descriptivo (MSE sobre el vector ensamblado), el latente que entrega al clasificador es agnóstico a la tarea, y ninguna cantidad de capacidad de encoder/latente/cabeza lo convierte en poder de ranking de nivel de árboles. Esta es la misma lección de “una representación aprendida aguas abajo de los one-hots de identidad no añade nada que los árboles no tengan ya” — la dilución

del latente AE de la Sección 5.1 y la inanición de embeddings de entidad de la Sección 6.7 — ahora reproducida en una tercera familia densa. El colapso-por-congelar es una trampa citable: un extractor de rasgos óptimo para MSE no es óptimo para la etiqueta, así que una cabeza profunda sobre un encoder congelado apila capacidad inútil y sub-ajusta. Si la familia se revisita alguna vez, la palanca es el *objetivo* de pre-entrenamiento (supervisado o contrastivo), no su tamaño. La familia está cerrada para AUC sobre rotación tal como está configurada. *Fuente: 2026-06-15-burn-ae-classifier-capacity-scan.md.*

6.10. Refutado: una cabeza de embedding de hojas GBDT no puede recuperar el árbol que generó sus rasgos

Motivación. El hilo ANN de arriba cerró con una lección limpia — una representación aprendida alimentada aguas abajo de los one-hots de identidad no compra poder de ranking que los árboles no tengan ya (la dilución del latente AE de la Sección 5.1; los embeddings de entidad famélicos salvo alta cardinalidad, Sección 6.7). Esta campaña somete esa lección a estrés en su punto más duro con el clásico truco de Facebook GBDT→LR, generalizado a GBDT→MLP. El árbol campeón congelado — la config registrada `xgboost-classifier-rotation-p64`, *duramente congelada*, no un ajustable — emite, para cada fila, el índice de la hoja en la que cae en cada uno de sus 500 árboles boosteados; esos índices se codifican one-hot en la propia partición axial aprendida del árbol ($\sim 10k$ columnas de pertenencia a hoja), y una cabeza fresca (una cabeza lineal logística ℓ_2 , o un MLP poco profundo) se entrena encima. La entrada a la cabeza es así la *propia* partición del árbol; la hipótesis — un séptimo test del hallazgo convergente — era que ni siquiera esto *superaría* al árbol puro, siendo la refutación esperada el hallazgo citable. Todas las ramas corrieron sobre la matriz 60/40 completa de 64-d (`ds-20260609-204419-p64-s42`, semilla 42); la única referencia válida es el campeón intra-dataset 0,7204, nunca los números DS-META 0,7429 o high-vocab 0,7299 (matrices distintas).

Resultados. Refutado exactamente como se predijo (Tabla 12; Figura 12). El control C0 (`run-20260615-151551-f2911-xgboost-classifier`) reprodujo el campeón hasta los 16 dígitos (0,7204383403100314), así que la puerta de determinismo pasó y los tratamientos son interpretables. Cada cabeza luego tope *por debajo* del árbol puro por más de una banda de ruido: GBDT→lineal con AUC 0,6978 ($-0,0227$, ~ 1.8 bandas), GBDT→MLP[256,128] con 0,6921 (~ 2.2 bandas), GBDT→MLP[128] con 0,6897 (~ 2.4 bandas) — la mejor de ellas está ella misma 0,0100 por debajo del umbral de refutación (campeón – banda = 0,7078). La rama de empate-en-banda (que habría disparado un spot-check de 3 semillas) y la rama de victoria ($> 0,7330$) nunca se dispararon; ninguna definición se guardó. La cabeza lineal — la receta literal de Facebook — es la mejor de las tres, y añadir capacidad MLP sobre los one-hots de hoja no recupera el árbol, consistente con el encuadre original de la receta como un truco *lineal* barato. Peor que el déficit de AUC, *cada cabeza está muy mal calibrada*: log-loss 0,8162–1,3119 y Brier 0,2603–0,2951 contra el 0,6075 / 0,2109 del árbol. La cabeza logística ℓ_2 al inverso- $C=1$ por defecto está sub-regularizada sobre $\sim 10k$ indicadores de hoja dispersos — lleva un puñado de pesos de hoja a magnitudes grandes y emite probabilidades sobre-confiadas, la misma firma de sobre-confianza pirámide-sklearn (log-loss muy por encima del de los árboles mientras el AUC solo queda modestamente detrás) vista en la Sección 6.3, y una bandera roja de calibración para el best-model-selector en caso de que alguna de estas ejecuciones se considere alguna vez para el grupo.

Interpretación. La refutación es decisiva y mecánica. El scoring aditivo de valores de hoja del árbol ya pondera cada hoja *conjuntamente* a través de 500 rondas de boosting con shrinkage; recodificar esas hojas como indicadores de pertenencia one-hot y ajustar una cabeza *post-hoc* descarta




Figura 12: La pila de embedding de hojas queda refutada sobre ambos ejes. *Izquierda*: cada rama GBDT→cabeza tope por debajo del árbol campeón puro en AUC — la mejor (GBDT→lineal, 0,6978) está ella misma una banda completa por debajo del umbral de refutación (la línea discontinua en campeón $-2\sigma = 0,7078$; la franja sombreada es la banda). *Derecha*: y cada cabeza está mal calibrada, con log-loss 0,82–1,31 muy por encima del régimen de los árboles (0,61, punteada) y pasado la línea base de tasa base aleatoria (0,69, discontinua) para las dos peores. Aprender una cabeza sobre los propios índices de hoja one-hot del árbol es estrictamente más lossy que leer directamente las sumas de valores de hoja del árbol.

la estructura de boosting y la re-estima peor. Los one-hots de hoja son una vista estrictamente más lossy de un árbol que ya puntúa mejor directamente — la cabeza densa ni siquiera puede recuperar el árbol que generó sus propios rasgos. Esta es la misma familia que la dilución del latente AE (Sección 5.1) y el techo de cabeza-densa (Sección 6), llevada a su límite: aquí la *entrada* de la cabeza es la partición óptima del árbol, y aún tope ~ 2 bandas por debajo. Re-ajustar la regularización de la cabeza podría domar la sobre-confianza pero no puede cerrar un déficit de AUC de ~ 1.8 bandas, así que la familia de cabeza-de-hojas está cerrada para rotación. Esta es la séptima confirmación convergente de que la palanca durable es la *resolución* de identidad (elevar topes de vocabulario, que ya elevó xgboost a 0,7299 sobre la matriz high-vocab), no nuevas cabezas ni representaciones apiladas sobre el árbol. *Fuente: 2026-06-15-gbd-t-leaf-head-ceiling-probe.md*.

6.11. El barrido de tope de vocabulario de resolución de identidad: una palanca en gran medida agotada

Motivación. Cada campaña de arriba cierra sobre la misma palanca vigente — la *resolución* de identidad: elevar los topes de vocabulario de artista/género para que la cola `__other__` obtenga columnas one-hot reales, lo que ya elevó xgboost de 0,7204 (60/40) a 0,7299 (300/120, Sección 6.8) y volteó la red de embedding al nivel de los árboles. Pero solo existían *dos* puntos sobre esa curva tope→AUC, y el extremo alto era el récord de linaje. Esta campaña mapea dónde deja de rendir la palanca. Mantiene la config registrada `xgboost-classifier-rotation-p64 congelada` (catboost defaults como rama secundaria), mantiene *todo lo demás* fijo — mismo corpus de 23 529 filas, misma semilla de partición 42 (18 823 entrenamiento / 4706 prueba), mismo PCA64, mismo bloque de campos — y mueve el *único* eje `vocab_top_n`, añadiendo tres puntos de tope más alto: 500/200 (777 cols), 1000/300 (1377 cols) y el vocabulario completo, 5594/962 (6633 cols). La hipótesis a

discriminar: *saturación* (ganancia por paso $<$ una banda) frente a *reversión* (el AUC baja conforme las columnas de artista singleton inyectan varianza memorizable).

Resultados. Las ocho ejecuciones lanzadas tuvieron éxito; los controles reprodujeron ambas anclas a cuatro dígitos (xgboost 60/40 0,72044 frente a la referencia 0,7204, $\Delta + 0,00004$; xgboost 300/120 0,72988 frente a 0,7299, $\Delta - 0,00002$), así que toda la curva se sitúa bajo una medición consistente (Tabla 13; Figura 13). xgboost subió a un nuevo mejor de linaje single-split de 0,73490 en 1000/300 (run-20260615-163803-e75be-xgboost-classifier), pero la estructura de pasos cuenta la historia real: el salto 60 $\rightarrow$ 300 fue $+0,00944$ ($+0,75$ banda), luego 300 $\rightarrow$ 500 fue *plano* ($-0,00022$, dentro del ruido) y 500 $\rightarrow$ 1000 fue $+0,00524$ ($+0,42$ banda). El mejor punto está solo $+0,00502$ (~ 0.40 banda) sobre el ancla 0.7299 — una mejora *sub-banda*, muy corta de los $+0,0126$ que requeriría una superación confiada. catboost sigue a xgboost cualitativamente en cada tope (0,71105 $\rightarrow$ 0,72516 $\rightarrow$ 0,72372 $\rightarrow$ 0,72633), quedando ~ 0.005 – 0.009 por debajo de él en todo momento y subiendo igual de suave después de 300/120 — su manejo categórico nativo *no* escala mejor en alta cardinalidad. El punto de vocabulario completo (6633 cols) en el tope de la curva **no pudo construirse**: dos intentos POST cada uno devolvió un id de build pero murió a mitad de materialización contra el techo de memoria del host (~ 2.3 GB libres de 15 GB bajo carga concurrente), dejando ningún dataset y ningún artefacto. Ese es un techo de infraestructura, *no* un resultado de modelado, y el extremo superior de la curva se registra como no medido.




Figura 13: La palanca de resolución de identidad está en gran medida agotada. Manteniendo la config campeona congelada y moviendo solo el tope de one-hots de artista/género, la curva tope $\rightarrow$ AUC sube abruptamente en el primer salto (60/40 $\rightarrow$ 300/120, $+0,75$ banda) y luego *se estanca*: 300 $\rightarrow$ 500 es plano ($-0,00022$, dentro del ruido) y 500 $\rightarrow$ 1000 recupera solo $+0,42$ banda, así que la nueva mejor de linaje single-split (0,73490 en 1000/300) supera el ancla 300/120 por solo $+0,00502$ (~ 0.40 banda, dentro del sobre sombreado $+2\sigma$ y por tanto una mejora *sub-banda*). catboost (discontinua) sigue a xgboost en cada tope, ~ 0.005 – 0.009 por debajo — el manejo categórico nativo no compra ventaja de alta cardinalidad. El punto de vocabulario completo (6633 cols, $\times$ rojo) está *no medido*: su build chocó con un techo de memoria del host en ambos intentos, un fallo de infraestructura más que un resultado de modelado.

Interpretación. El veredicto es un limpio “no saturada, no revertida, pero disminuyendo”. Nin-

gún punto interior cayó una banda completa bajo el ancla (el más bajo, 500/200, es $-0,00022$), así que la hipótesis de reversión no dispara — las columnas de artista singleton en alta cardinalidad *no* dañan el árbol, consistente con el prior de no-exploración del proyecto de que las particiones alineadas a ejes toleran one-hots colineales y mayormente-cero simplemente no partiendo sobre los inútiles. Pero las ganancias pasado el primer salto son todas sub-banda y oscilan arriba y abajo dentro del sobre $2\sigma = 0,0126$: la curva pasado 300/120 se lee mejor como una meseta plana con jitter single-split que como una subida monótona, que es exactamente por qué la regla de decisión guarda un save detrás de una superación de ≥ 1 banda más un confirm de 3 semillas. El $+0,00502$ del mejor punto está en la ventana de “probablemente mejor, necesita confirmación”, así que **el confirm de 3 semillas no disparó y ninguna definición se guardó**; el campeón DS-META cross-matrix (0,7429) mantiene el rango 1 sin cambios, y el punto 1000/300 se auto-promovió a mejores-modelos rango 3 sin desplazar a ningún modelo registrado. La lectura honesta para trabajo futuro: la *altura* cruda del tope de vocabulario es una palanca en gran medida agotada sobre este corpus — el gran pago fue el primer salto, ya registrado. El acuerdo de catboost lo sella: dos familias de árboles independientes dicen que las columnas marginales pasado 300/120 llevan poca señal independiente. La señal de rotación residual es la parte conductual/contextual que ninguna cardinalidad de metadatos de canción puede capturar, así que el trabajo de identidad debería girar de topes más grandes a resolución *de calidad* — interacciones de seguidores-de-artista / popularidad, jerarquía de género — y la guía vigente de “la resolución de identidad es la palanca” debería leerse ahora “débil y estancándose pasado 300/120, con el extremo superior aún no medido pendiente de un build ancho sobre un host quiescente”. *Fuente: 2026-06-15-vocab-cap-scan-gbdt.md.*

6.12. Leyendo las redes: autoencoders dispersos por modelo

Motivación. Todo resultado hasta ahora se ha leído de la tabla de clasificación — AUC, log-loss, Brier. Pero dos redes pueden publicar AUC idéntico mientras tallan la entrada en representaciones internas muy distintas, una distinción que la tabla no puede ver. Esta campaña abre esa caja. Primero porta un *autoencoder disperso por modelo* (POST /api/interp/model-sae) a la familia **burn-deep-classifier** (la cabeza SAE existía antes solo para un regresor), de modo que la promoción ahora auto-encola una lectura de interpretabilidad: un SAE 2×-sobrecapado (11 0,0015, 40 épocas) se ajusta sobre las activaciones de cada capa oculta, sus átomos se sondan por *conceptos* interpretables, y la *decodabilidad* lineal de la rotación se mide capa por capa. El primer uso compara dos geometrías con AUC fijo sobre la matriz canónica completa de 64-d (ds-20260609-204419-p64-s42, semilla 42): una **pyramid** que se estrecha [256, 128, 64] contra una **rect** uniforme [128, 128, 128], difiriendo *solo* en la forma oculta.

Resultados. Las dos redes están **estadísticamente empatadas** en AUC (pyramid 0,69857, rect 0,69937; $\Delta 0,0008 \ll$ banda) — ambas en el nivel del **mlp burn-deep** registrado y ~ 1.7 bandas bajo el campeón xgboost. También capturan la *misma cantidad* de señal decodable: la decodabilidad lineal de la rotación apenas se eleva sobre la entrada cruda ($\sim 0.111 \rightarrow \sim 0.12$) para ambas. La diferencia es puramente en *disposición* (Figura 14). Los conceptos interpretables de la pirámide hacen pico en su capa media de 128-d (72) y luego comprimen $\sim 40\%$ en el cuello de botella de 64-d (42); la red uniforme los reparte más uniformemente y *retiene* más hasta el final ($17 \rightarrow 66 \rightarrow 54$), porque tiene el ancho para hacerlo. Ninguna red está famélica — ambas utilizan plenamente cada átomo SAE (0 muertos / 0 raros), dan esencialmente a cada segmento de identidad (~ 103 – $105/105$) un átomo separador dedicado, y reconstruyen $> 96\%$ de la varianza de activación — así que la brecha de conteo-de-conceptos es asignación genuina, no capacidad. Un control sin early-stop confirmó una trampa registrada: corridas a las 100 épocas completas con patience 0, ambas redes de 3 capas sobreajustan (AUC $-0,015$, log-loss revienta a 0,96–1,22); el régimen calibrado

$\sim 0.699 / 0.625$ se recupera solo *porque* las ejecuciones de producción hacen early-stop. **Las redes burn-deep más profundas necesitan patience.**




Figura 14: Con AUC igual, dos geometrías disponen la misma señal de forma distinta — una diferencia representacional invisible a la tabla. La **pyramid** que se estrecha [256, 128, 64] (azul) hace pico de sus conceptos interpretables-por-SAE en la capa media de 128-d (72) y exprime $\sim 40\%$ de ellos en el cuello de 64-d (42); la **rect** uniforme [128, 128, 128] (gris) reparte sus conceptos y retiene más hasta la capa de salida (17 $\rightarrow$ 66 $\rightarrow$ 54). Ambas redes utilizan plenamente cada átomo y decodan la rotación al mismo techo ~ 0.12 , así que la pirámide *consolida* su estructura interpretable en un cuello de botella comprimido mientras la red uniforme mantiene un conjunto de conceptos más amplio — mismo AUC, distinta asignación.

Interpretación. Con igual poder de ranking la pirámide consolida su estructura interpretable en un cuello de botella que se estrecha mientras la red uniforme la distribuye, y ambas meramente re-expresan la decodabilidad ~ 0.11 de la entrada cruda en vez de fabricar nueva señal de gusto. El SAE confirma así, mecánicamente, lo que la tabla solo implica: las redes densas no están encontrando estructura que los árboles pierdan; están re-empaquetando la misma señal de identidad en una representación que el AUC no puede distinguir. Este patrón de “misma señal, distinta asignación” recurre a través de familias en vocabulario más alto (Sección 6.13). *Fuente: 2026-07-12-pyramid-vs-rect-sae.md.*

6.13. La capacidad es una palanca agotada en vocabulario alto, y qué ve el SAE

Motivación. La matriz high-vocab (Sección 6.8) fue donde la red de embedding alcanzó primero el nivel de los árboles, pero nunca se ajustó en profundidad/ancho. Esta campaña plantea la pregunta directa: ¿la *capacidad* — ancho o profundidad — eleva la familia ANN a través de la brecha restante de ~ 0.2 – 0.6 banda con los árboles sobre esa matriz (ds-20260612-143014-p64-s42, 497 cols)? Dos escaleras de geometría de un eje, lr fijo en el mejor registrado de cada topología: una escalera **embeddings** (ed8, lr 5×10^{-4}) y una escalera **mlp** (lr 1×10^{-3}), cada una escalonando [128, 64] (control) $\rightarrow$ [256, 128] (más ancha) $\rightarrow$ [256, 128, 64] (más profunda). Cada rama promovida también obtiene el SAE por modelo de la Sección 6.12, para una lectura de representación cross-familia en vocabulario alto.

Resultados. **TECHO** — la capacidad está saturada para ambas topologías (Tabla 14;

Figura 15). Ni ensanchar ni profundizar supera su propio control [128,64] por más de una banda; la mejor config sigue siendo la **embeddings** registrada $\text{ed8}/\text{lr}5 \times 10^{-4}/[128,64]$ (reproducida aquí en 0,72274, $\Delta -0,0001$). Profundizar **embeddings** a tres capas activamente *perjudica* ($-0,0152 \approx 1.2$ bandas, el único movimiento fuera de banda); profundizar **mlp** ayuda un toque sub-banda ($+0,0057$). Crucialmente, el mejor **mlp** (B6, 0,71800) cierra a menos de $+0,0047$ del mejor **embeddings** (B1, 0,72274): en sus mejores geometrías las dos topologías empatan dentro de una banda, así que **la capacidad, no el mecanismo de embeddings, fue la palanca** — la lectura anterior de “embeddings gana en vocabulario alto” es un empate en banda, y la familia ANN sigue $\sim 0.2\text{--}0.6$ banda bajo el nivel de los árboles (catboost 0,7252, xgboost 0,7299). La definición guardada **burn-deep-embeddings-highvocab** y el campeón están ambos sin cambios; la mejor rama se promovió para el registro como **emb-128-64-ed8-highvocab**.




Figura 15: La capacidad es una palanca agotada para la red densa en vocabulario alto. Manteniendo lr en el mejor de cada topología y escalonando la geometría oculta $[128,64] \rightarrow [256,128] \rightarrow [256,128,64]$, ni la escalera **embeddings** (azul) ni la **mlp** (gris) supera su propio control por una banda; una tercera capa **embeddings** *perjudica* por 0,0152 (~ 1.2 bandas, el único movimiento fuera de banda), porque la profundidad extra diluye una entrada de embedding de entidad aprendida ya peor condicionada. El mejor **mlp** cierra a menos de $+0,0047$ del mejor **embeddings**, así que las dos familias empatan dentro de una banda — la capacidad, no el mecanismo de embeddings, fue la palanca — y todo el nivel ANN se mantiene $\sim 0.2\text{--}0.6$ banda bajo el nivel de los árboles dentro del dataset (sombreado, catboost 0,7252 hasta xgboost 0,7299).

Interpretación. El SAE por modelo explica *por qué* ambos movimientos fallan. El par cross-familia empatado en AUC — **embeddings** [128,64] (0,72274) y **mlp** [256,128,64] (0,71800) — se estanca en el *mismo* techo de decodabilidad (capa de pico test R^2_{target} 0,149 frente a 0,141) y ambos dan a los 245 segmentos de identidad un átomo separador dedicado; la diferencia es solo de disposición. El ganador alcanza el techo con pocos conceptos construidos monótonamente ($33 \rightarrow 75$, $\Sigma 108$), mientras que el **mlp** más profundo/ ancho forma casi $2\times$ los conceptos ($55 \rightarrow 113 \rightarrow 32$, $\Sigma 200$) que hacen pico en su capa media y *colapsan* a través de su cuello — el mismo patrón de consolidación-frente-a-proliferación de la Sección 6.12, ahora reproducido a través de familias e invisible al AUC. Y la penalización de $-0,0152$ de embeddings-profundos es dilución, no inanición:

esa rama tiene 0 átomos muertos y utilización plena pero una *entrada* de embedding de entidad aprendida más débil (R^2_{target} 0,123 frente al 0,133 del ganador), y su profundidad extra nunca la recupera (la decodabilidad baja a mitad de tronco). Esta es la cara mecánica del techo de capacidad: una tercera capa sobre una tabla de embedding aprendida diluye el ranking en vez de afilarlo. Tanto este barrido como el barrido de tope de vocabulario GBDT (Sección 6.11) apuntan igual — la *calidad* de resolución de identidad, no la capacidad cruda del modelo o del vocabulario, es la palanca restante. *Fuente: 2026-07-12-high-vocab-capacity-scan.md.*

7. Deriva de gusto: la tabla de clasificación es una cota superior de la predicción hacia adelante

Motivación. Todo AUC en este documento se mide sobre una partición train/test *aleatoria*, que deja que una pista descubierta en un período dado aterrice a ambos lados de la partición. Eso responde “¿puede el modelo ordenar pistas de la misma era que sus datos de entrenamiento?” — pero la pregunta desplegada mira hacia adelante: *¿reproduciré una canción que descubra a continuación?* Esta campaña la plantea honestamente añadiendo una capacidad de partición cronológica de primera clase al constructor (`split_order_field` en la petición de build): las filas se ordenan por un campo de payload (aquí `first_played`), las más tempranas van a entrenamiento y las más tardías a prueba, y PCA, vocabulario e imputación se ajustan todos solo sobre las filas de entrenamiento tempranas, así que la partición es libre de fugas. Se construyeron cuatro datasets desde la colección activa `spotify_tracks_song_ae` — completo e intrínseco, cada uno aleatorio y cronológico — y el campeón más un barrido de modelos se evaluaron sobre la partición nativa de cada dataset. Si el AUC colapsa bajo la partición cronológica, el gusto deriva y la tabla sobreestima la habilidad real hacia adelante.

Resultados. **El gusto no es estacionario** (Tabla 15; Figura 16). El build completo-aleatorio reproduce el campeón registrado a cinco dígitos (0,73490), validando los builds frescos; el build cronológico de los *mismos* rasgos lo baja a 0,61894 — un colapso de +0,116 (≈ 9 bandas de ruido). La caída es de 0,109–0,116 para *cada* familia de modelos (`catboost` 0,72889→0,61294, `logistic` 0,72141→0,61234), así que es el dato/gusto, no una peculiaridad de modelo. Los one-hots de identidad apenas ayudan hacia adelante: *descartarlos* (el build intrínseco) cuesta solo ~ 0.02 cronológico (0,61894→0,59858) frente a ~ 0.025 aleatorio — mayormente memorizan artistas de la misma era. Un `xgboost` ponderado por recencia (sobre-ponderando descubrimientos recientes) recupera solo +0,003 (sub-banda), así que la deriva no es un simple efecto de recencia. Y la lectura walk-forward — entrenar sobre `first_played < Y`, probar sobre el año Y — aterriza en 0,59–0,67 para cada año individual de 2019 a 2026, *nunca* cerca de la línea base aleatoria 0,735, y más historia de entrenamiento no cierra la brecha. Un re-particionado fuera-del-framework de los rasgos preexistentes construidos aleatoriamente concuerda a ~ 0.007 de AUC (0,626), y controlar por censura-a-la-derecha (restringiendo la prueba cronológica a pistas con ≥ 180 días de oportunidad de reproducción) apenas lo mueve (0,62579→0,62319) — así que la penalización es no-estacionariedad genuina, no el corrimiento de tasa base de pistas recientes mecánicamente-menos-rotadas.

Interpretación. El mecanismo es la rotación de identidad, y ata todo el documento. La rotación la conduce la *identidad* de artista/género en one-hots (el hallazgo convergente de cada campaña de arriba); en una partición cronológica el período de prueba está lleno de artistas recién descubiertos que eran no vistos en entrenamiento y caen en `__other__`, así que el modelo debe recaer en la señal acústica/metadatos intrínseca más débil — que tope cerca de 0,60. Eso es exactamente por qué elevar topes de vocabulario (Sección 6.11) y añadir capacidad de red (Sección 6.13) son palancas agotadas para la habilidad hacia adelante: solo afilan la *memorización* de la misma era,




Figura 16: El AUC de la tabla de clasificación es una cota superior de la predicción hacia adelante. *Izquierda*: pasar de una partición aleatoria a una cronológica (entrenar-antes / probar-después) baja el AUC en ~ 0.11 para *cada* familia de modelos — la penalización es el dato, no un modelo. *Derecha*: la lectura walk-forward (entrenar sobre `first_played < Y`, probar sobre el año `Y`) aterriza en 0,59–0,67 cada año y nunca se acerca a la línea base aleatoria 0,735 (verde), siguiendo el nivel cronológico $\sim 0,619$ (rojo discontinuo) en su lugar; más historia acumulada no cierra la brecha. La habilidad hacia adelante de “¿reproduciré una canción que descubra a continuación?” sobre este corpus es ~ 0.62 – 0.63 , ~ 0.11 por debajo de la tabla de partición aleatoria.

que no transfiere. Es también la historia de misma-señal que cuentan los SAEs por modelo — decodabilidad lineal ~ 0.14 sin átomo de gusto monosemántico limpio (Secciones 6.12, 6.13): quita la memorización de identidad y queda poca señal de gusto generalizable. La lectura práctica: todo AUC registrado es una cota superior del ranking de misma era, no de la habilidad hacia adelante; un modelo desplegado necesita re-entrenamiento periódico porque el gusto deriva; y la única palanca que movería el AUC *hacia adelante* es señal intrínseca generalizable más rica (mejor acústica, estructura cross-artista), ya que la resolución de identidad y la capacidad de modelo están ambas agotadas y son solo-de-la-misma-era. Esto no revierte ningún número de la tabla — los AUC de partición aleatoria son mediciones válidas del ranking de misma era — pero reencuadra lo que significan. *Fuente: 2026-07-12-taste-drift-temporal-split.md*.

8. Recomendación de pista siguiente: la tarea, la barra de Markov y el campeón de fusión

Toda campaña de arriba apunta a la señal binaria de *rotación*. Las secciones restantes incorporan una línea de trabajo *separada* — recomendación de *pista siguiente* (next-track) — cuya tarea, métricas y campeón no tienen relación con las tablas de rotación y nunca deben leerse contra ellas. Esta sección consolida las cuatro campañas que establecieron la tarea, su barra base y su campeón de fusión; las dos secciones que siguen (Secciones 9 y 10) desarrollan los ejes de representación de ítems y familia de modelos y coronan la fila «mejor registrada» actual.

Tarea y partición. La tarea es *recuperación* (retrieval) del siguiente ítem: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente. Se evalúa sobre una única partición cronológica sin fugas *next-distinct* del artefacto de secuencias seq-20260713-014226 (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba en el corte 2024-08-24). La **tasa de ítems fríos es 0.55** — más de la mitad de las pistas objetivo de las sesiones de prueba nunca aparecen en ninguna sesión de entrenamiento — así que el recall absoluto es modesto *por construcción* y cada resultado se lee contra la barra base incumbente, no una barra absoluta.

Métricas. La métrica principal es **recall@10** (R@10, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al rango recíproco medio (MRR) y, desde 2026-07-14, los diagnósticos de *relevancia graduada* de primera clase: *artist@10* / *genre@10* (un candidato del top-diez comparte el artista / género primario de la verdad) y *artist_mrr*. Todos los intervalos de confianza aquí son IC bootstrap al 95 % sobre 2000 remuestreos de las 1431 sesiones de prueba, y el estadístico decisivo es el Δ *pareado* por sesión contra una referencia nombrada (la barra de Markov, un ancla GRU del mismo espacio, o el campeón). Las métricas graduadas son el marcador honesto: el campeón acierta el *artista* correcto en el top diez $\sim 32\%$ de las veces y el *género* correcto $\sim 40\%$, mucho más útil que el número de recall exacto de $\sim 17\%$ que impone la tasa de ítems fríos. Desde 2026-07-20 la tabla también incluye **music@10**, una métrica graduada continua de tipo “suena parecido” (Sección 13): el coseno máximo medio, en un espacio intrínseco balanceado de distancia musical, entre la siguiente pista verdadera y los diez candidatos — un superconjunto suave de recall@10, solo de visualización (la métrica principal sigue siendo recall@10). Desde 2026-07-22 el tablero también lleva una suite *solo de visualización* de holisticidad de sesión (*artist_adj@10* / *mood_coh@10* / *ild@10*; Sección 14), que no reordena el tablero pero toma la huella del campeón como la fila más artist-eager.

La barra de Markov. La referencia contra la que se mide cada rama es el modelo de co-ocurrencia de *Markov* de primer orden (B2: un **track_bigram** solo de entrenamiento con back-off por artista/género, el término de transición que la app hermana ya despacha) con R@10 0,1069, MRR 0,0694. Los pisos de popularidad (B0) y recencia (B1) quedan cerca de cero (R@10 0,0007). Una *victoria* de tabla requiere superar la referencia en *ambos* R@10 y MRR más allá de los tests de paired- Δ / IC marginal, seguido de un confirm por reproducción.

La Tabla 16 es la tabla vigente de «mejor registrada» de pista siguiente. El campeón *row* actual — y, desde 2026-07-18, un modelo *registrado, promovido y servible* — es una *proyección de contenido aprendida* supervisada, $R'+M+C'$, sobre el espacio de ítems PCA-192 (Secciones 11–11.2): las ramas GRU y content-kNN recuperan en un mapa métrico InfoNCE del espacio de ítems ajustado hacia la adyacencia de pista siguiente. Supera al z-blend de tres ramas $R+M+C$ sobre el mismo espacio (Sección 10.2), que había destronado al z-blend de dos ramas $R+M$ sobre el espacio AE-64 (Sección 8.3). Desde 2026-07-18 la familia de secuencias lleva un contrato de servicio de ranking, así que el campeón es servible vía `POST /api/models/blend-gru-markov-content-proj/predict` (rango 1 del grupo de mejores modelos); los blends anteriores debajo de él, y las ramas en solitario, siguen siendo referencias fuera del servidor. Desde 2026-07-25 el tablero lleva además tres puntos de dato de arquitectura *refutados*: el control de capacidad de GRU única más ancho, la mejor rama de torre doble y la mejor rama de pre-codificador en torre única (Secciones 15–16). Se listan porque *acotan* sus ejes, no porque sean candidatos: ninguno supera la línea base de GRU única según el estadístico *pareado* y ninguno se registró. Desde 2026-07-27c la fila superior del tablero es el campeón *con compuerta de evidencia* (Sección 21): hacer que la rama de Markov se abstenga

en el 55,6 % de las consultas donde no tiene evidencia de bigramas eleva el recall@10 a 0,2320 (332 de 1431), con IC pareado sobre cero en dos particiones disjuntas y con MRR y ambas métricas graduadas al alza. Es la mejor cifra de recall de esta línea de trabajo, y es *solo* una recomendación de promoción — nada se registró ni se promovió — así que el campeón servible que va debajo queda sin cambios. Sobre la métrica principal efectiva en el servidor, y sobre por qué este tablero sigue denominado en Recall@10 a lo largo de tres generaciones de holisticidad, véase la Sección 17.2.

8.1. El barrido de secuencias: una GRU-infonce empata con la barra de Markov

Motivación. La campaña inaugural de la instancia planteó la pregunta fundacional: ¿un modelo de secuencias con contexto de sesión — una GRU/LSTM sobre el prefijo ordenado, prediciendo el latente song-AE de 64 dimensiones de la siguiente pista y recuperando por coseno — supera al modelo de transición de Markov de primer orden que la app hermana ya despacha, *hacia adelante*, sobre la partición de sesiones sin fugas? Cuatro ramas cruzaron la celda recurrente (GRU, LSTM), la capacidad (`hidden` 128, 256) y, decisivamente, la función de pérdida (regresión coseno frente a InfoNCE contrastiva), todas sobre `seq-20260713-014226` a 60 épocas.

Resultados. Ninguna rama superó la barra. La regla de decisión requería superar a B2 en *ambos* R@10 y MRR más allá de IC no solapados; la mejor rama (M3, GRU `hidden128` InfoNCE) alcanzó un *empate* estadístico con la barra de Markov en R@10 (0,0894, el IC del paired- Δ incluye cero) pero *perdió* en MRR (0,0388 frente a 0,0694) y recall@20. La palanca dominante fue la función de pérdida: InfoNCE fue $\approx 2,3\times$ el coseno en R@10 (0,0894 frente a 0,0391), mientras que la capacidad (`h256`) y la celda LSTM apenas movieron las ramas coseno (todas ~ 0.038 – 0.041).

Interpretación. Un latente-más-un-solo-salto-coseno es una ruta más difícil a la *pista* siguiente *exacta* que un bigrama de co-escucha: el bigrama memoriza directamente “qué sigue a qué”, mientras que la GRU debe aterrizar cerca del punto correcto en un espacio de contenido de 64-d y luego recuperar, perdiendo en el ranking preciso (MRR). El hallazgo es consistente con el resultado de deriva de gusto del laboratorio padre — 0,55 de ítems fríos, comportamiento guiado por identidad/adyacencia — y fijó la agenda: InfoNCE es la pérdida base, y la rama natural siguiente es un *blend* de las puntuaciones de candidatos de la GRU con el bigrama de Markov. *Fuente:* `2026-07-13-nexttrack-sequence-sweep.md`.

8.2. Barrido de topología: profundidad, anchura y dirección son una palanca agotada

Motivación. Con la pérdida fijada en InfoNCE, este barrido aisló la *topología* de red: ¿la profundidad (capas apiladas), la anchura (`hidden` 256), una pila residual entre capas o la bidireccionalidad elevan el modelo de secuencias por encima de la barra de Markov? Como una RNN bidireccional bajo teacher forcing por paso filtraría ítems futuros, la rama bidireccional usó un objetivo leak-free de último ítem (codificar el prefijo completo, predecir solo el siguiente ítem retenido).

Resultados. Refutado. Ninguna rama superó la barra en ambas métricas. La mejor rama (anchura `h256`, R@10 0,0957) es un *empate* en R@10 y pierde en MRR (0,0411 frente a 0,0694). La profundidad es plana de $1 \rightarrow 2$ capas (0,0894 $\rightarrow$ 0,0922, dentro de banda) y *perjudica* con 3 capas (0,0825, fuera de banda por debajo de la barra); la pila residual sobre profundidad-2/h256 no añadió nada. La rama bidireccional colapsó (0,0482), pero esto es un artefacto del *objetivo*, no un veredicto sobre la direccionalidad: el objetivo leak-free de último ítem aporta ~ 1 objetivo de entrenamiento por sesión frente a los ~ 13 pares de siguiente-paso del teacher forcing, así que entrenó con $\sim 13\times$ menos señal.

Interpretación. La arquitectura no es la palanca para pista siguiente en este corpus. La señal transferible de recuperación por latente se estanca en $R@10 \sim 0.09-0.10$ a través de profundidad, anchura, residual y dirección, por debajo del bigrama de co-escucha — consistente con todo el arco: la función de pérdida movió la aguja y la capacidad/topología no. La única palanca inexplorada restante era el encuadre de candidatos / la fusión, que la campaña siguiente accionó decisivamente. *Fuente: 2026-07-13-nexttrack-topology-scan.md.*

8.3. El campeón de fusión GRU×Markov, y por qué más ensamblado falla

Motivación. El barrido y el escaneo de topología coincidieron en que la mejor GRU individual solo *empata* con la barra de Markov en $R@10$ mientras pierde en MRR. Esta campaña preguntó si *combinar* modelos supera la barra, y hasta dónde llega el ensamblado. Se definieron tres ramas, cada una emitiendo puntuaciones de candidatos sobre todo el vocabulario: **M** = el bigrama de Markov solo de entrenamiento (la barra), **R** = la recurrencia GRU-infonce-h256, y **A** = un MLP ANN de bolsa-de-prefijo (un gemelo feed-forward de R). Se combinaron con un z-blend ponderado y, como alternativa aprendida, un stacker XGB (un meta-aprendiz GBDT sobre rasgos por candidato).

Resultados. El **z-blend R+M** ($\alpha=0,5$) *supera la barra de forma decisiva*: $R@10$ 0,1726 [0,154, 0,192], MRR 0,0963, un Δ pareado sobre Markov de +0,0657 [+0,049, +0,083] (IC enteramente por encima de cero) — $\sim +61\%$ de $R@10$, $+39\%$ de MRR — en una meseta robusta a lo largo de $\alpha \in [0,25, 0,75]$ y reproducido a través de tres semillas (0,1705 / 0,1726 / 0,1726). Se registró como el predictor **seq-blend** y la definición **blend-gru-markov**, el primer campeón de pista siguiente. Más ensamblado luego *no logró* mejorarlo (Tabla 17): R+A+M (0,1684) es levemente peor, R+A ($\approx$ GRU sola, 0,0894) es mucho peor, y ambas variantes del stacker XGB (M+R 0,1020; M+R+A 0,0887) apenas superan a Markov sola.

Interpretación. La victoria es sobre *diversidad* de señal, no número de modelos. La GRU (similitud de latente) y Markov (conteos de co-ocurrencia) ordenan pistas correctas *distintas*, así que fusionarlas aproximadamente duplica la tasa de acierto; amontonar más del *mismo* tipo de señal — otro predictor neuronal de latente (A), redundante con R — no añade nada. El stacker XGB aprendido *rinde por debajo* del z-blend simple, en contra de la intuición habitual de que “apilar supera a mezclar”: su entrenamiento puntual binario-con-negativos no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas. El margen restante está acotado por la tasa de ítems fríos de 0,55 y requiere *señal genuinamente nueva*, no más fusión de modelos — la hipótesis que la campaña de relevancia graduada prueba a continuación. *Fuente: 2026-07-14-nexttrack-blend-and-ensemble.md.*

8.4. Métricas de relevancia graduada y nuevos aprendices base: el contenido es la única señal aditiva

Motivación. Dos hilos en una campaña. (A) Hacer que la evaluación acredite aterrizar la *banda/ambiente* correcto aunque la pista exacta esté mal — la observación de que “la primera elección normalmente no es la pista exacta, pero el artista normalmente es correcto” — promoviendo *artist@k*, *genre@k* y *artist_mrr* a métricas de primera clase cableadas de extremo a extremo (**seq_common.eval_from_scores** $\rightarrow$ **Metrics / MetricsSpec** de Rust $\rightarrow$ **domain.toml** $\rightarrow$ UI). (B) Probar aprendices base leak-free genuinamente nuevos — **C** = content-kNN (coseno del latente song-AE de cada candidato al prefijo, sin entrenamiento), **M2** = un trigram de Markov de segundo orden con back-off, e **I** = un item2vec SGNS solo de entrenamiento — evaluados tanto en las métricas exactas como en las nuevas graduadas.

Resultados. La ruta de la métrica exacta fue idéntica byte a byte (claves puramente aditivas); el campeón reprodujo R@10 0,1726 / MRR 0,0963 exactamente. Ningún aprendiz base nuevo superó la barra en solitario (M2 0,1076 $\approx$ M 0,1069; el trigramas cae al bigrama — las sesiones son demasiado cortas para disparar; item2vec 0,0517 es la rama más débil). Mezclado en el campeón, **el contenido es la única señal aditiva: R+M+C** (añadiendo la rama de contenido) es el mejor blend en MRR (0,0963 $\rightarrow$ 0,1014), artist@10 (0,3215 $\rightarrow$ 0,3298) y artist_mrr, y empata al campeón en R@10 exacto (Δ pareado +0,0014, IC cruza cero). item2vec *arrastra* el blend (R+M+I 0,1349); el trigramas es neutral.

Interpretación. content-kNN ordena pistas cuasi-correctas *distintas* (similitud de ambiente por latente) frente a la GRU (recurrencia de sesión) y Markov (co-ocurrencia), justo la diversidad que la campaña de fusión predijo que necesitaría la señal nueva. Sobre el espacio AE-64 la rama de contenido solo *empató* al campeón en recall exacto mientras elevaba las métricas graduadas — así que se llevó adelante como la tercera rama graded-preferred, no como un nuevo campeón exacto. Ese “empate” se vuelve una *victoria* cuando el espacio de ítems es más rico (Sección 10): sobre PCA-192 la misma construcción R+M+C es la más fuerte registrada. El item2vec de co-escucha y el trigramas de Markov no añadieron nada en estos datos. *Fuente: 2026-07-14-nexttrack-graded-relevance-and-new-legs.md.*

9. Recomendación de pista siguiente: el bake-off de compresión de la representación de ítems

Toda campaña de arriba apunta a la señal binaria de *rotación*. Esta sección incorpora el primer informe de una línea de trabajo *separada* — recomendación de *pista siguiente* (next-track) — cuya tarea, métricas y campeón no tienen relación con las tablas de rotación y nunca deben leerse contra ellas. La tarea es recuperación: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente. Se evalúa sobre una partición cronológica *next-distinct* sin fugas (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba en el corte 2024-08-24; tasa de ítems fríos 0.55), y su métrica principal es **recall@10** (R@10, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al rango recíproco medio (MRR) y los diagnósticos de acierto de categoría artist@10 / genre@10 / artist_mrr. Todos los intervalos de confianza aquí son IC bootstrap al 95 % sobre 2000 remuestreos de las 1431 sesiones de prueba. El campeón vigente de esta línea — la referencia contra la que se lee esta campaña — es un *z-blend* R+M de fusión de rankings (blend-gru-markov, $\alpha=0,5$) de una GRU de secuencias con un modelo de co-ocurrencia de Markov de primer orden sobre el espacio multimodal song-autoencoder de 64-dim (spotify_tracks_song_ae, “AE-64”), con R@10 0,173 [0,154, 0,192], MRR 0,096, confirmado con tres semillas. *Motivación.* El espacio de ítems del campeón — un latente AE de 64-dim — fue una elección temprana arbitraria, y la GRU de secuencias predice *hacia* y recupera *sobre* cualquier geometría que ese espacio imponga. Esta campaña pregunta qué *compresión* es el mejor espacio para la GRU: PCA lineal frente al autoencoder no lineal, cada uno a dimensión latente 32 / 64 / 128. Se hornearon cinco espacios alternativos desde la *misma* fuente de contenido leak-safe de 384-dim (spotify_tracks_content), cada uno ajustado sin supervisión sobre los 23 529 ítems usando solo campos intrínsecos de contenido/acústica/catálogo (texto-384 + numéricos z-scored + acústicas af_* + multi-hot de género/tipo-álbum), nunca un campo conductual o de objetivo. Cada espacio se evaluó luego bajo un readout GRU *congelado* (gru-infonce-h256: arch=gru, loss=infonce, hidden=256, una capa, dropout 0.1, 40 épocas, lr 1×10^{-3} , batch 128, $k=10$), de modo que el espacio latente de ítems es el único eje que se mueve. La apuesta del diseño era que

la pérdida de reconstrucción de peso igual por bloque del AE *preservaría* los pequeños bloques de acústica/catálogo que la varianza global dominada por texto de PCA muriera de hambre; la hipótesis nula era que la dimensión, no el compresor, fija el techo. Cada artefacto pasó una puerta de paridad idéntica (mismas 7154 sesiones / 19 402 ítems / partición / corte), así que la comparación es de igual a igual, y el paired- Δ es la diferencia de R@10 por sesión contra el control AE-64 del mismo lote.

Resultados. La puerta de paridad pasó: el control AE-64 reprodujo su R@10 registrado 0,0957 $\in [0,081, 0,112]$, así que el ranking es válido. Los seis espacios entrenaron limpiamente (Tabla 18; Figura 17). **PCA-128** (spotify_tracks_song_pca128, artefacto seq-20260715-030509; ejecución run-20260715-042100-a1d9d) es el ganador GRU-individual con R@10 0,1146, un paired- Δ de +0,0189 [+0,0042, +0,0335] sobre el control AE-64 — un IC *enteramente por encima de cero*, la única rama que supera el control significativamente — y también encabeza MRR (0,0489), artist@10 (0,3326) y artist_mrr (0,2644). PCA-64 es el segundo (0,1041, paired- Δ cruzando cero: un empate). Los dos espacios de 32-dim (AE-32 0,0545, PCA-32 0,0412) quedan muy por debajo del control de 64-dim, ambos con IC de paired- Δ enteramente por debajo de cero. La sonda content-kNN sin entrenamiento (una recuperación coseno pura en cada espacio, última columna del informe) es plana en ~ 0.06 a través de los seis espacios y *no* sigue el ranking de la GRU: el R@10 de sonda de PCA-128 (0,0636) empata exactamente el control AE-64 (0,0636), y AE-32 encabeza la sonda (0,0720) pese a quedar casi-último bajo la GRU.




Figura 17: La dimensión latente, no el compresor, es la palanca. Ambas series suben abruptamente de dim 32 a 64; PCA (azul) luego sigue subiendo hasta 128 y *sobrepasa* al AE, mientras que el AE (gris) se estanca — su punto de 128-dim (0,0929) de hecho cae por debajo de su propio control de 64-dim (0,0957). En dim 32 el AE roza a PCA, un cruce de baja capacidad que se revierte una vez que la dim es generosa. El control AE-64 (anillo rojo) es el espacio de ítems del campeón; el ganador PCA-128 (estrella verde) es la única rama cuyo IC del paired- Δ supera cero. Las barras de error son IC bootstrap al 95 %; los IC vecinos se solapan, así que la victoria descansa en el test *pareado*, no en los intervalos marginales.

La victoria GRU-individual, sin embargo, **no** sobrevive al blend de producción. Re-fusionar la rama GRU PCA-128 ganadora con la rama de Markov (seq-blend, $\alpha=0,5$, semilla 1337; ejecución

run-20260715-044920-36dce) puntúa R@10 0,1670 [0,148, 0,187], MRR 0,0923 — *por debajo* del blend campeón AE-64 (0,173, MRR 0,096) en ambas métricas, con IC solapados. Por la regla de decisión esto no es un evento de tabla: nada se promovió, el blend campeón AE-64 se mantiene, y PCA-128 se lleva adelante solo como el espacio base sancionado de la Fase 2.

Interpretación. Cuatro cosas se siguen. Primera, **la dimensionalidad latente es la palanca dominante y el compresor es secundario**: para PCA la tendencia es monótona ($0,041 \rightarrow 0,104 \rightarrow 0,115$ a través de dim 32/64/128), y 32 dims mueren de hambre el espacio sin importar el método. Segunda, la **hipótesis de preservación acústica del diseño queda refutada**: en dim generosa el PCA lineal supera al AE no lineal ($\text{PCA-128} > \text{AE-128}$, $\text{PCA-64} \geq \text{AE-64}$), y aunque AE-32 preserva los bloques numérico/acústico casi a la perfección queda cerca del fondo — así que la preservación acústica es irrelevante para la recuperación de pista siguiente. Lo que ayuda es una geometría objetivo *ordenada por varianza y decorrelacionada* (PCA-128 captura EVR acumulado 0,982) que la GRU encuentra más fácil de regresar que los latentes de peso igual enredados del AE; el ordenamiento por varianza global de PCA es una ventaja aquí, no la desventaja que la hipótesis asumía. Tercera, la ventaja del AE es un fenómeno puramente de *baja capacidad* ($\text{AE-32} > \text{PCA-32}$): el cuello de botella no lineal empaca más estructura utilizable en 32 dims, pero la ventaja se evapora y se revierte una vez que la dim es generosa. Cuarta, la sonda content-kNN plana que no sigue el ranking de la GRU es una *divergencia señalada*: la riqueza de recuperación intrínseca de estos espacios es similar, así que la ganancia de PCA-128 viene de la *aprendibilidad* de su geometría objetivo para la GRU entrenada, no de un espacio demostrablemente más rico en lo absoluto — que es exactamente por qué la regla de decisión lo señaló en vez de auto-promoverlo. La salvedad de peso para el trabajo aguas abajo es el resultado del blend: una rama GRU claramente más fuerte (0,1146 vs 0,096) no compró *nada* en el blend, porque la rama de Markov es independiente de la representación y las pistas extra que la mejor GRU recupera evidentemente se solapan con lo que Markov ya aporta. **Las ganancias de representación medidas sobre la GRU individual no se trasladan automáticamente al blend de producción**, así que el eje de compresión es progreso genuino para el modelo individual pero esencialmente agotado para el blend. *Fuente: 2026-07-15-nexttrack-compression-representation-bakeoff.md.*

10. Pista siguiente Fase 1b/2: el techo de dimensión, el barrido de familia de modelos y el campeón R+M+C

El bake-off de compresión (Sección 9) halló que la *dimensión* latente es la palanca dominante y dejó a PCA aún subiendo en 128. Dos campañas de seguimiento localizaron el techo de dimensión, luego barrieron la familia de modelos sobre los espacios elegidos — y, en el proceso, coronaron una nueva fila «mejor registrada».

10.1. El techo de dimensión de compresión: PCA hace pico en 192

Motivación. Con la dimensión establecida como la palanca, este tramo extendió el barrido de PCA hacia arriba (PCA-192, PCA-256) para localizar el óptimo real antes de que la Fase 2 comprometiera un espacio base, y añadió AE-192 para probar si $\text{PCA} \geq \text{AE}$ se sostiene a mayor dimensión. El protocolo fue idéntico: todas las reps ajustadas desde la fuente leak-safe `spotify_tracks_content`, evaluadas bajo el *mismo* readout congelado `gru-infonce-h256`, cada nuevo artefacto de secuencias pasando la puerta de paridad exacta; la referencia es PCA-128 (run-20260715-042100-a1d9d), el ganador de la Fase 1, y el Δ pareado por sesión se mide contra ella.

Resultados. La curva de R@10 frente a dimensión de PCA **hace pico en ~192** (R@10 0,1230) y

se revierte hacia 256 (0,1167); no seguía subiendo. La tendencia completa es $32 \rightarrow 0,041$, $64 \rightarrow 0,104$, $128 \rightarrow 0,115$, **192** $\rightarrow 0,123$, $256 \rightarrow 0,117$ (Figura 18). PCA-192 es el óptimo puntual, pero su Δ pareado frente a PCA-128 es $+0,0084$ $[-0,0007, +0,0189]$ — falla la barra de “IC enteramente por encima de cero” por 0,0007, un pelo — así que por la regla mecánica **PCA-128 se mantiene como la base de la Fase 2**, con PCA-192 marcado como el candidato a confirmar-y-promover. $\text{PCA} \geq \text{AE}$ se sostiene con fuerza y la brecha es máxima en 192 (PCA-192 0,123 frente a AE-192 0,098); el AE se estanca plano en ~ 0.09 – 0.10 desde dim 64 hacia arriba.




Figura 18: Se encuentra el techo de dimensión. Extendiendo el barrido de compresión de la Figura 17 a PCA-192/256 y AE-192, la curva PCA (azul) hace pico en ~ 192 (R@10 0,123) y se revierte hacia 256, mientras que el AE (gris) se estanca plano en ~ 0.09 – 0.10 y nunca lo alcanza — la brecha $\text{PCA} \geq \text{AE}$ es máxima en 192. PCA-192 es el óptimo puntual (estrella verde) pero su Δ pareado sobre PCA-128 roza cero, así que PCA-128 (la base marcada) se mantiene como la base individual de la Fase 2. Las barras de error son IC bootstrap al 95 % sobre las 1431 sesiones de prueba.

Interpretación. La varianza extra más allá de ~ 192 (PCA-256 captura EVR acumulado 0,997) son dimensiones de baja señal / ruido que la GRU no puede explotar y que diluyen levemente la geometría objetivo. La meseta plana del AE reconfirma la hipótesis de preservación acústica refutada del bake-off a mayor dimensión: su objetivo de reconstrucción de peso igual sigue gastando capacidad en los pequeños bloques numérico/acústico (reconstrucción $R^2 \approx 0,999$ en 192) en lugar de la estructura de texto/catálogo de alta varianza que la GRU necesita. Como antes, la sonda content-kNN sin entrenamiento sigue plana (~ 0.064 – 0.070) y no reproduce el pico de la GRU, así que el óptimo de dimensión es sobre la *aprendibilidad* del objetivo, no la riqueza intrínseca de recuperación. *Fuente: 2026-07-15b-nexttrack-compression-dim-extension.md.*

10.2. El barrido de familia de modelos y el nuevo campeón, R+M+C sobre PCA-192

Motivación. Con el eje de compresión zanjado (base PCA-128, candidato PCA-192), esta campaña barrió la *familia* de modelos sobre los espacios elegidos: ¿una celda recurrente distin-

ta (LSTM), un MLP agregado no recurrente (ANN) o un stacker XGB *aprendido* superan al z-blend fijo GRU×Markov — y añadir la tercera rama content-kNN (R+M+C) sobre el espacio PCA *rico* finalmente supera al campeón? Una configuración fija corrió a través de todas las ramas; solo variaron la familia de modelos y la representación, y el servidor se serializó (`--max-runs 1`) para evitar la trampa de sobresuscripción de hilos.

Resultados. Una **nueva fila «mejor registrada»**: el **z-blend R+M+C sobre PCA-192** (GRU × Markov solo de entrenamiento × content-kNN, tercios iguales) alcanza R@10 0,1859 [0,166, 0,207], MRR 0,1025, un Δ pareado sobre el campeón previo de +0,0133 [+0,0007, +0,0259] — enteramente por encima de cero, sin regresión de MRR (Tabla 19; Figura 19). La rama de contenido es genuinamente aditiva sobre el espacio rico, superando al R+M del mismo espacio en +0,0154 (PCA-128) / +0,0147 (PCA-192), ambos IC por encima de cero — *más fuerte* que el R+M+C de AE-64 que solo empató (Sección 8.4), porque el espacio más rico y de mayor EVR hace que la rama de contenido rinda. El **stacker XGB aprendido rinde muy por debajo** del z-blend fijo (0,080–0,087, perdiendo incluso ante su propia rama base GRU individual), reconfirmando la campaña de fusión; la **LSTM es el mejor modelo individual** (PCA-128 0,1272, Δ pareado sobre la GRU +0,0126, IC por encima de cero) pero muy por debajo de los blends; y la base individual de la Fase 2 **se mantiene en PCA-128** (la ventaja de la GRU-192 aún roza cero).




Figura 19: El barrido de familia de modelos de la Fase 2. El z-blend fijo es el combinador de referencia: R+M+C sobre PCA-192 (verde) es la nueva fila campeona, la rama de contenido es genuinamente aditiva sobre el espacio rico, y el stacker XGB aprendido (rojo) rinde muy por debajo — pierde incluso ante su propia rama base GRU individual. LSTM roza a GRU como el mejor modelo individual (gris) pero queda muy por debajo de los blends. La barra de Markov de primer orden (0,107) es la referencia incumbente; la fila campeona está en 0,186.

La coronación, y sus dos salvedades honestas. El candidato a evento de tabla se confirmó reproduciendo la rama GRU-192 cinco veces (la original más cuatro re-ejecuciones) y recalculando R+M+C cada vez; el Δ pareado sobre el campeón previo fue +0,0133 [+0,0007, +0,0259] en *cada*

re-ejecución, con la ventaja de MRR intacta, así que R+M+C sobre PCA-192 se registró como la nueva fila campeona. Dos salvedades viajan con la coronación y no deben omitirse. Primera, **la dispersión de reproducción fue exactamente cero** porque el entrenamiento de `seq-nexttrack` es determinista en esta CPU — los cinco checkpoints GRU-192 fueron idénticos byte a byte — así que la confirmación verificó *determinismo, no robustez a la semilla*; la única incertidumbre cuantificada es el bootstrap de partición única. Segunda, **el límite inferior del Δ pareado es +0,0007**: la coronación supera cero por un pelo en una única partición. La coronación es real según el criterio pre-acordado, pero el margen sobre el campeón previo es delgado, y endurecerla requiere una segunda partición de prueba sin fugas (o ramas con semillas variadas una vez que el blend se generalice a tres ramas).

Interpretación. El hilo de compresión-más-familia-de-modelos queda por lo demás cerrado: PCA-128 es la base individual, la LSTM es el mejor modelo individual, el stacker aprendido está muerto como combinador, y el z-blend fijo es el combinador de referencia. El resultado de peso es que *el contenido es la única rama que añade señal de ranking genuinamente nueva, y rinde más sobre el espacio PCA de mayor EVR* — la excepción a la regla vigente de que las ganancias de modelo individual / representación no se trasladan al blend (el par R+M sobre los espacios PCA ricos solo empata al campeón AE-64). La brecha de productización persiste: el campeón es solo de entrenamiento y fuera del servidor, así que el campeón previo R+M sobre AE-64 sigue siendo el ancla desplegable hasta que el blend de tres ramas se registre con un subcomando `predict`.
Fuente: 2026-07-15c-nexttrack-phase2-model-sweep.md.

11. Pista siguiente: la proyección de contenido aprendida, su registro y endurecimiento en dos particiones

El campeón R+M+C (Sección 10.2) llevaba dos salvedades delgadas — una confirmación por reproducción solo-determinista y un límite inferior del paired- Δ de solo +0,0007 — y su margen estaba acotado por la tasa de ítems fríos de 0,55, que solo la señal *nueva* puede atacar. Tres campañas de finales de julio coronaron, registraron y endurecieron un campeón genuinamente nuevo. Esta sección incorpora las dos primeras (la victoria y su productización); los hilos de vector de ítem y music@10 siguen en las Secciones 12 y 13.

11.1. La campaña de ajuste-a-la-literatura: una proyección de contenido supervisada gana

Motivación. Guiada por un estudio de la literatura establecida de recomendación en sesión (la línea de session-kNN de Jannach–Ludewig, reglas secuenciales / Markov factorizado, trucos de entrenamiento de GRU4Rec, fusión de rankings y learning-to-rank, recomendación en sesión consciente de contenido / arranque en frío), esta campaña pre-registró tres niveles de métodos clásicos y preguntó cuáles mejoran realmente el ajuste a *este* problema — una tarea de *recuperación* de pista siguiente distinta, de un solo usuario, basada en sesión, con 55 % de objetivos fríos. Todas las ramas se midieron fuera del servidor sobre el artefacto campeón PCA-192 `seq-20260715-131139`, reutilizando el driver sancionado que reproduce al campeón (R+M+C 0,1859) exactamente; el estadístico de decisión es el Δ pareado por sesión contra ese campeón.

Resultados — la única victoria. Una **proyección de contenido aprendida** supervisada es una nueva fila «mejor registrada». Ajustar un mapa métrico lineal W del espacio de contenido PCA-192 hacia la adyacencia de pista siguiente (InfoNCE sobre pares consecutivos de entrenamiento, auto-bucles descartados) y luego recuperar *ambas* la rama de contenido (C') y la GRU (R') en

ese espacio proyectado da **z-blend** $R'+M+C'R@10$ 0,2117 [0,191, 0,233], **MRR** 0,1220 — un Δ pareado sobre el campeón de +0,0259 [+0,012, +0,041], enteramente por encima de cero (Tabla 20). A diferencia de la coronación $R+M+C$ es **robusta a la semilla** (tres semillas; Δ pareado +0,026 / +0,025 / +0,029, todos IC > 0) y **alcanza ítems fríos**: la rama de contenido proyectada C' puntúa objetivos fríos 0,152 $\approx$ cálidos 0,151, frente a los cálidos 0,226 / fríos 0,010 de Markov, así que alcanza la mayoría fría del 55 %. El mapa simétrico único supera al two-tower direccional, y rango-192 = rango-64 (la ganancia es la supervisión, no la capacidad). Como efecto secundario, la GRU individual proyectada R' ($\sim 0,176$) casi iguala al blend campeón *antiguo* y aplasta al mejor individual previo (LSTM 0,127).

Las vías que se cerraron. Toda otra dirección no logró superar al z-blend fijo, como el estudio predijo para un corpus de un solo usuario y con muchos fríos (Tabla 21). El suavizado principiado de Markov (descuento absoluto + un piso de continuación de Kneser–Ney) es una ganancia en solitario real pero minúscula (0,1069 $\rightarrow$ 0,1104) que se diluye en el blend (−0,0021, IC cruza 0). Un combinador consciente de ranking no tiene margen honesto: incluso los pesos *oráculo*, ajustados sobre las etiquetas de prueba, alcanzan solo 0,1901 (+0,0042, cruza 0), y la fusión RRF *perjudica* el recall (−0,029, IC<0). Un kNN de sesión V-SKNN con puerta es solo-cálido frente al 55 % de fríos y *arrastra* el blend (−0,038, IC<0). Y los negativos por importancia de GRU4Rec dan un tick en solitario dentro del ruido (+0,005) que también se diluye (−0,0014, empate). **La única ganancia aditiva viene de señal nueva, no de fusión más astuta.**

Interpretación. La proyección de contenido supervisada es la primera señal nueva genuinamente aditiva desde la propia rama de contenido, y funciona por la razón que el estudio señaló: el contenido es el único canal con alcance a fríos, y reemplazar la geometría PCA no supervisada y ordenada por varianza por una ajustada al objetivo eleva *ambas* ramas que la comparten. Los métodos prestados vistosos son callejones sin salida aquí porque o rebarajan las mismas tres ramas (sin margen sobre el z-blend, incluso para el oráculo) o importan una suposición colaborativa que el corpus de un solo usuario viola. *Fuente: 2026-07-18-nexttrack-literature-fit-campaign.md.*

11.2. Registro, el barrido de objetivo / rango / τ , y endurecimiento en segunda partición

Motivación. La victoria de la proyección aterrizó como driver fuera del servidor. Este seguimiento la implementó como capacidad de primera clase del predictor **seq-blend** (hiperparámetros **projection**, **projection_rank**, **projection_objective**, **projection_tau**, ...), luego reprodujo la victoria on-server, la registró + promovió, y corrió un barrido de ablación pre-aprobado.

Registro. El run de verificación (run-20260718-191539-1b89c-seq-blend, default de la definición = InfoNCE / rango completo / τ 0,07) reprodujo el driver fuera del servidor a cuatro decimales — $R@10$ 0,21174, **MRR** 0,12199 — y se promovió vía la API como **blend-gru-markov-content-proj**, con la matriz de proyección horneada en el directorio del modelo para servicio. **GET /api/best-models** lo confirma en **rango 1** (0,21174), por encima del campeón servible previo **blend-gru-markov-content** (rango 2, 0,18588); es servible vía **POST /api/models/blend-gru-markov-content-proj/predict**.

El barrido. La regla de decisión — re-promover solo una config que supere al default en *ambos* $R@10$ y **MRR** por más que la banda de ruido de $\sim \pm 0,015$ — confirma el default (Tabla 22). **InfoNCE** $\gg$ **BPR** es el eje más agudo: ambas celdas BPR (0,1579, 0,1523) caen $\sim 0,055$ bajo el default y aterrizan *por debajo incluso del viejo campeón* $R+M+C$ (0,1859). **Rango completo** $\geq$ **rango-64** (−0,006, un empate). Y τ es **levemente sensible y monótona hacia arriba** (0,05 $\rightarrow$ 0,1929, 0,07 $\rightarrow$ 0,2117, 0,10 $\rightarrow$ 0,2229) — pero la celda superior nominal τ -0,10 supera al default por solo +0,0112 en recall, *dentro* de la banda, así que es un empate y el default se

MANTUVO. A diferencia del eje de reponderación de la Sección 11.1, aquí las métricas graduadas *siguen* al recall, porque el barrido mueve la *calidad de señal* en vez de refusionar ramas fijas.

Endurecimiento en segunda partición. La coronación se midió sobre una única partición sin fugas; un pase solo-de-validación la re-corrió (más los dos blends de referencia) sobre una **segunda partición disjunta y sin fugas** seq-20260718-211238 — una banda cronológica de holdout-temprano 60–80 % sobre el mismo espacio PCA-192, con espacio de ítems idéntico byte a byte, ventana de prueba disjunta en índice y tiempo respecto al test 80–100 % de la partición campeona, con una **tasa de ítems fríos de 0,64** (vs 0,55). Por construcción el R@10 absoluto aterrizó por debajo del 0,212 de la primera partición; el veredicto es el Δ pareado (Tabla 23; Figura 20). La regla de decisión (Δ pareado vs R+M+C con IC enteramente > 0 y MRR sin regresión) se cumple: Δ pareado +0,0426 [+0,0280, +0,0573], MRR +0,0234. El margen es *más ancho* aquí que en la primera partición (+0,0259) — en una partición más fría las ramas Markov / content-kNN de la coronación alcanzan menos objetivos y la rama C' de la proyección, que alcanza fríos, carga proporcionalmente más de la victoria. La coronación está ahora endurecida en dos particiones disjuntas sin fugas, resolviendo ambas salvedades de R+M+C.




Figura 20: La ventaja de la proyección *se ensancha* en la partición más fría. Sobre la partición canónica con 0.55 de fríos el campeón de proyección supera a la coronación R+M+C por Δ pareado +0,0259; sobre una partición disjunta y más fría de holdout-temprano con 0.64 de fríos el margen *crece* a +0,0426 (ambos IC enteramente > 0). El R@10 absoluto es menor en la partición más fría por construcción; el veredicto es el Δ pareado. La rama C' que alcanza fríos carga proporcionalmente más de la victoria donde hay más objetivos fríos.

Fuente: 2026-07-18b-nexttrack-projection-registration-and-scan.md.

12. Pista siguiente: exploración de representación del vector de ítem

Motivación. El eje de compresión (Secciones 9 y 10.1) halló que la *dimensión* latente domina pero nunca preguntó si la *composición* del vector de ítem de 192-d — el PCA de 4 bloques de

peso igual (texto / numérico / acústico / categórico) — es en sí misma un lastre. Un preflight de ratio de varianza explicada (EVR) dijo que podría serlo: el presupuesto de varianza de entrada crudo es 44 % acústico + 43 % numérico frente a solo 2.5 % texto (el texto está L2-normalizado, así que su escala por dimensión es minúscula), así que el PCA-192 de matriz completa gasta **87 % de su presupuesto de varianza** reconstruyendo los bloques numérico + acústico a $R^2 = 1,000$ mientras que el bloque de texto portador de señal alcanza solo $R^2 = 0,717$; la estandarización por columna (whitening) voltea el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905) (Figura 21). Se construyeron ocho espacios de latentes de ítems alternativos con puerta de paridad respecto a la partición campeona (solo difiere `item_latents.f32`) y cada uno se evaluó bajo *dos* readouts: **(A)** la proyección campeona `blend-gru-markov-content-proj` (el techo del espacio bajo la receta ganadora) y **(C)** la GRU individual congelada `gru-infonce-h256` (calidad de representación cruda). Solo-validación; nada promovido.




Figura 21: Por qué el vector de ítem es un lastre para un modelo crudo — y por qué la proyección es el arreglo. El PCA-192 de peso igual ordena las dimensiones por varianza cruda, así que 87 % de su presupuesto capturado reconstruye los bloques numérico + acústico conductualmente inertes (popularidad / era / volumen) mientras que el bloque de texto portador de señal (2.5 % de la varianza de entrada cruda, L2-normalizado) queda infra-preservedo (R^2 0,717). La estandarización por columna voltea el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905). La proyección InfoNCE aprendida aprende esta misma reponderación de los datos.

Veredicto. **Readout A:** ninguna variante supera al campeón PCA-192 con IC del Δ pareado enteramente > 0 (V3 std-noaco +0,0049 y V5 balanced +0,0042 cruzan 0; V4 textcat -0,0168 y V6 sonic-64 -0,0182 regresan). **Readout C:** seis de ocho variantes superan a la GRU congelada con IC del Δ pareado enteramente > 0 (+0,025 a +0,036). Así que la geometría cruda *es* un lastre — suprimir las direcciones ruidosas eleva la GRU cruda en ~20–29 % relativo — **pero la ganancia es absorbida por completo por la proyección**, que ya reponderó esas direcciones de los datos. El whitening y la proyección aprendida son el mismo arreglo, y el campeón ya lo accionó. El eje graduado se mueve más limpiamente que el recall exacto (el whitening eleva el `genre@10` de la GRU congelada a ~0,47; un espacio solo-texto publica los máximos de `artist@10` / `genre@10` de readout A), y la métrica continua `music@10` (Sección 13) corrobora: el




Figura 22: El lastre de representación es real para la GRU *cruda* pero *absorbido* por la proyección campeona. Seis de ocho espacios de whitening / drop-acústico / métricos elevan la GRU congelada (readout C, verde; los seis con IC del paired- Δ enteramente > 0), pero ninguno eleva la proyección campeona (readout A, azul; los dos espacios nominalmente positivos cruzan 0, y V4/V6 regresan significativamente). El mapa InfoNCE aprendido ya reponderó fuera las direcciones acústicas / numéricas ruidosas: el whitening y la proyección son el mismo arreglo.

campeón de proyección la lidera (0,4538) sobre R+M+C (0,4491), y es plana a través de las ocho representaciones ($\sim 0,447-0,460$). Una precaución: dejar caer numérico+acústico *por completo* (V4) perjudica al campeón aunque ayude a la GRU cruda, así que conservar numérico y hacer whitening / dejar caer solo acústico. *Fuente: 2026-07-18c-nexttrack-representation-exploration.md.*

13. Pista siguiente: la métrica de distancia musical music@10

Motivación. El recall@10 exacto es implacable sobre un corpus de un solo usuario con 55 % de fríos. Esta campaña introduce una métrica graduada *continua* de tipo “suena parecido”, **music@10**, y la back-fillea a través de cada run de pista siguiente. Es la media sobre casos de prueba del mejor coseno (máximo), en un espacio intrínseco *balanceado* de distancia musical (spotify_tracks_content_metric: una fusión con pesos por bloque, parcialmente whitened, del latente song-AE de 64-d whitened, el embedding de texto de nombre/tag de 384-d, cinco numéricos de metadatos, y un prototipo AE por género), entre la siguiente pista verdadera y los diez candidatos recuperados. Un top-diez que contiene la verdad exacta puntúa 1,0, así que music@10 es un *superconjunto suave* de recall@10; es solo de visualización (la métrica principal sigue siendo recall@10).

Resultados. music@10 se recalculó offline y de forma no destructiva a través de los 53 runs de pista siguiente (desde el `predictions.json` almacenado de cada run y su `items.json` de dataset, sobre la partición compartida de 1431 casos). **Correlaciona** con recall@10 ($r = 0,609$) pero está lejos de ser redundante, y corona a un ganador *distinto* (Tabla 25; Figura 23). El campeón de

recall@10 es un run **seq-blend** (0,223), pero las predicciones *más cercanas musicalmente* vienen de **seq-nexttrack** — que regresa directamente el latente de contenido de la siguiente pista y recupera por coseno — con mejor music@10 0,482 y la media de familia más alta (0,448). El piso **seq-popularity** es correctamente el peor (0,185), confirmando que la métrica no está trivialmente saturada.




Figura 23: music@10 frente a recall@10 a través de los 53 runs de pista siguiente, un punto por run, coloreado por familia de predictor. Los dos ejes correlacionan ($r = 0,609$) pero coronan ganadores distintos — el campeón de recall@10 (un run **seq-blend** en 0,223) no es el más cercano musicalmente, que es un run **seq-nexttrack** (music@10 0,482) que regresa el latente de contenido y recupera por coseno. music@10 es solo de visualización; recall@10 sigue siendo la métrica principal.

Interpretación. music@10 es una vista genuinamente distinta y no saturada de la calidad de pista siguiente: premia la proximidad *sónica*, que la métrica de acierto exacto ignora. El desacople recall-versus-music tiene un mecanismo limpio — un modelo que regresa el latente de contenido (**seq-nexttrack**) aterriza *cerca* de la verdad en el espacio de contenido incluso cuando falla la pista exacta, así que sus fallos “suenan bien” más a menudo que los del blend. Por eso la métrica es solo de visualización y no debe volverse silenciosamente un objetivo de selección; la promoción aún ordena por recall@10. Hereda una circularidad leve del dial *balanced* (el bloque de texto embebe el nombre del artista; el bloque de género es un prototipo de género), así que premia parcialmente la proximidad de mismo-artista / género. *Fuente: 2026-07-20-musical-distance-metric.md.*

14. Next-track: métricas de holisticidad de sesión y las palancas anti-eager (MMR λ / eager β)

Motivación. Una queja cualitativa recurrente sobre los mejores blends es que sus predicciones se sienten “demasiado album-eager / de tipo bigrama” — repiten como loro el artista actual en lugar de curar una continuación holística. Esta campaña cuantifica ese síntoma con una nueva suite *solo de visualización* de métricas de *holisticidad de sesión*, pone a prueba la hipótesis del usuario

de que *la GRU supera a la LSTM porque es más eager* (más ansiosa por repetir el artista actual), y mide si dos nuevas palancas de la Fase 2 reducen esa eagerness a un costo de recall aceptable: un re-ranqueo MMR en evaluación (`mmr_lambda`) y un regularizador anti-eager de entrenamiento (`eager_beta`). Es un pase de medición / exploratorio: no se promueve nada, la métrica principal sigue siendo Recall@10 y la decisión sobre el objetivo de holisticidad se difiere explícitamente al usuario. Cada rama corre sobre la partición *canónica* PCA-192 del campeón `seq-20260715-131139` (1431 sesiones de test; tasa de ítems fríos 0,55), y el campeón reprodujo exactamente su Recall@10 de registro 0,2117 (0,21174).

Las nuevas métricas de holisticidad solo de visualización. Cableadas de extremo a extremo junto a `music@10` (`seq_common.eval_from_scores` → Rust → `domain.toml` → UI); la métrica principal no cambia.

artist_adj@10 (↓). Fracción del top-10 que comparte el artista de la pista *semilla* — la tasa de “repite como loro el artista actual”. **Menor es mejor.**

album_adj@10. Lo mismo sobre (artista, álbum); **omitida en este dataset** porque su `items.json` no lleva el campo de álbum (esperado, no un error — cubierto por un dataset separado que sí lleva álbum).

mood_coh@10 (↑). Coseno medio del top-10 al centroide de mood del prefijo en el espacio content-metric; mayor es más coherente en mood.

ild@10 (↑). Diversidad intra-lista (distancia sónica media por pares) del top-10; mayor es menos duplicativo.

suffix_recall@10 / cont_prec@10. Cobertura de continuación multi-paso, producida solo por el arnés bajo demanda `seq_continuation_eval.py` (Fase E, abajo), no por los runs normales.

La puerta de sanidad pasó: `music@10` / `mood_coh@10` / `ild@10` se pueblan en todos los runs de blend y GRU, de modo que los vectores content-metric cargaron y las palancas MMR / mood / ild están vivas, no son no-ops. Ambas palancas nuevas están APAGADAS por defecto y verificadas byte-idénticas al estar apagadas.

Resultados — la huella de holisticidad (Fase A). La Tabla 26 toma la huella de la familia de modelos. **La eagerness sigue a Recall@10 dentro de la familia de blends** — el campeón (Recall@10 0,2117) es el modelo *más* artist-eager medido (`artist_adj@10` 0,610), con R+M a continuación (0,579) — pero la eagerness vive en la pata de *Markov*, no en la RNN: la barra de Markov de primer orden por sí sola ya está en 0,543, mientras que la GRU / LSTM individuales quedan mucho más abajo, en `artist_adj@10` $\approx$ 0,345. Así que los blends compran su ventaja en Recall@10 siendo artist-adyacentes (de tipo bigrama), que es exactamente lo que la suite de holisticidad señala. Las RNN individuales son, en cambio, los modelos *coherentes en mood y de baja eagerness* (el mayor `mood_coh@10`, el menor `artist_adj@10` entre modelos reales). Crucialmente, las métricas *no se juegan trivialmente*: el suelo de popularidad maximiza `ild@10` (0,898) y minimiza `artist_adj@10` (0,003) pero puntúa $\approx$ 0 recall y `mood_coh@10` *negativo* — se maximizan siendo aleatorio, así que los modelos de baja eagerness / alta diversidad con sentido son las RNN individuales reales.

GRU frente a LSTM (Fase B) — la hipótesis no se sostiene. Con los hiperparámetros igualados (h256, InfoNCE, 40 épocas, lr 1×10^{-3}), la GRU y la LSTM quedan estadísticamente *empatadas*: Recall@10 0,1230 frente a 0,1188 ($\Delta +0,0042$, dentro de la banda $\pm 0,015$), y `artist_adj@10` 0,347

frente a 0,344 (un +0,003 despreciable). La GRU no es mediblemente más eager que la LSTM en esta partición, así que la hipótesis “la GRU gana porque repite el artista actual con más fuerza” queda **refutada aquí**.

La palanca MMR λ (Fase C) — la palanca fuerte. MMR es un re-ranqueo puramente en evaluación, así que los cuatro runs de entrenamiento por- λ lanzados originalmente fueron *cancelados* (no experimentos fallidos); el barrido se computó offline desde el único checkpoint del campeón (la celda $\lambda=\text{off}$ reprodujo exactamente el Recall@10 0,2117 del campeón). A medida que λ cae de off hacia 0,3 (Tabla 27; Figura 24), Recall@10 baja — lo *único* que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (des-eagering). $\lambda=0,9$ es **esencialmente gratis**: el Δ de recall es $-0,0014$, bien dentro de la banda $\pm 0,015$ (un empate), pero ya eleva ild@10 $0,406 \rightarrow 0,436$ y recorta la eagerness $0,610 \rightarrow 0,603$. $\lambda \approx 0,7$ sacrifica ~ 2 puntos de recall ($\Delta -0,0181$, justo fuera de la banda) por una gran ganancia de ild@10 ($0,406 \rightarrow 0,520$) y una caída real de eagerness ($0,610 \rightarrow 0,571$). Un efecto colateral notable: **music@10 sube monótonamente** a medida que se diversifica ($0,454 \rightarrow 0,492$) — cercanía sónica y diversidad de lista no están en tensión; solo se sacrifica el recall exacto.




Figura 24: El trade-off de MMR λ sobre el campeón de pista siguiente. A medida que λ cae de off hacia 0,3, Recall@10 (rojo, eje izquierdo) baja — lo único que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (eje derecho; más diverso, menos artist-eager) y music@10 incluso *sube*. $\lambda=0,9$ queda dentro de la banda de empate de recall $\pm 0,015$ pero ya eleva ild@10 en 0,030; $\lambda \approx 0,7$ compra una gran ganancia de ild@10 y des-eagering real por ~ 2 puntos de recall. MMR es la palanca de holisticidad fuerte; β (Tabla 28) es débil.

El regularizador anti-eager β (Fase D) — la palanca débil. Una penalización de entrenamiento sobre la predicción casi-copia del latente de la pista actual (*eager_margin* 0,0) apenas mueve la aguja (Tabla 28): a lo largo de β 0 a 0,2, artist_adj@10 solo se desplaza $0,347 \rightarrow 0,340$ ($\Delta -0,0074$) e ild@10 solo $0,454 \rightarrow 0,458$, con Recall@10 plano (las cuatro dentro de $\pm 0,015$). La GRU individual ya es de baja eagerness (0,347), así que queda poco comportamiento de copia para penalizar — β no es una palanca de holisticidad útil en estos ajustes.

Continuación multi-paso (Fase E). El arnés bajo demanda (`seq_continuation_eval.py -m 3`

-k 10, 1172 casos de continuación) muestra que la GRU *supera* al bigrama de Markov en ambas métricas multi-paso (Tabla 29): la ventaja de la RNN *se ensancha* más allá de la pista siguiente inmediata, porque la co-ocurrencia de un solo paso del bigrama no se compone en buenas continuaciones de 3 pasos, mientras que el estado de secuencia aprendido de la GRU sí — la imagen especular del tablero de un solo paso, donde el blend con bigrama gana el Recall@10 crudo.

Interpretación y la decisión diferida. La campaña entrega un relato mecanístico limpio del síntoma de eagerness: proviene de la pata de bigrama de Markov (que repite como loro el artista actual vía co-ocurrencia cruda), no de la pata neural, así que cualquier des-eagring futuro debería apuntar al bigrama / la fusión, no a la RNN. De las dos nuevas palancas, el re-ranqueo MMR en evaluación es la palanca *fuerte* y el regularizador β de entrenamiento es *débil*. No se promueve nada — la métrica principal sigue siendo Recall@10 y el campeón no cambia — pero $\lambda \approx 0,9$ **queda señalado como una mejora de holisticidad casi gratis para una futura decisión de promoción del usuario** (Recall@10 empate dentro del ruido, ild@10 0,406→0,436, eagerness 0,610→0,603), con $\lambda \approx 0,7$ como el punto de operación de “des-eagring significativo por ~ 2 puntos de recall”; adoptar cualquiera de los dos requiere una decisión del usuario más una confirmación de 3 semillas / run nativo. El regularizador β no se recomienda como palanca en estos ajustes. *Fuente: 2026-07-22-session-holisticness-and-antieager-levers.md.*

15. Pista siguiente: la fusión de torre doble refutada — el cuarto nulo de combinador

Motivación. Para el 2026-07-25 el registro ya tenía tres nulos independientes de *combinador aprendido*: el stacker XGB (0,080 a 0,087, *por debajo* de su propia rama GRU base; Sección 10.2), la fusión de rangos recíprocos ($-0,029$) e incluso pesos de blend ajustados en test de forma *oracular* ($+0,004$, con el IC cruzando cero; Sección 11.1). Los tres eran combinadores **post-hoc, a nivel de puntuación**, lo que dejaba en pie una objeción obvia: *por supuesto* que falla un combinador atornillado encima — hay que entrenar la fusión de extremo a extremo para que las partes se co-adapten. Esta campaña ejecuta exactamente esa objeción, a nivel de *representación*, de forma conjunta y desde cero.

El vehículo es un predictor nuevo, **seq-dualgru**: dos torres recurrentes *independientes* (pesos separados) leen el prefijo en paralelo sobre *vistas causales* configurables, sus estados ocultos por paso se concatenan y una cabeza MLP los fusiona en el latente predicho de la siguiente pista. Se exponen tres vistas, todas estrictamente causales en el paso t : **latent** (el vector de ítem crudo), **delta** (la diferencia entre pasos, con $x_{-1} = 0$) y **cummean** (el centroide acumulado de la sesión — la cantidad a partir de la cual se construyó la rama MLP agrupada **seq-ann**). Es crucial que reutiliza **seq_nexttrack.make_batches** y **step_loss** literalmente, de modo que objetivo, batching, parada temprana y evaluación son byte a byte los de la familia, y no incorpora modo bidireccional (una pasada hacia atrás filtraría el objetivo de *teacher forcing*).

La hipótesis era nítida: dos torres deberían superar a una *solo si ven información genuinamente distinta*; dos torres sobre la misma vista **latent** deberían reducirse a un efecto de capacidad o de ensamblado implícito que una GRU única más ancha compra más barato. El diseño cruza por tanto el *triángulo superior completo* de la matriz de vistas $\{\text{latent}, \text{delta}, \text{cummean}\}^2$ (seis celdas con **fusion_layers** = 1) con un eje de *profundidad de fusión* (dos celdas con **fusion_layers** = 0, una lectura puramente lineal de los estados concatenados) y — el eje que le faltaba al escaneo de topología previo (Sección 8.2) — un **control de capacidad de GRU única emparejado en parámetros**. Los recuentos de parámetros se re-midieron instanciando las clases reales con **latent_dim** = 192: el control C1 (h425, 871 017 parámetros) coincide con las seis ramas duales de

`fusion_layers = 1` (871 872) al 0,098 %, y es un 10 % *mayor* que las ramas de `fusion_layers = 0` (789 696) — deliberadamente generoso con la torre única.

La barra honesta. Se pre-registraron dos tableros por *separado*, para que el veredicto científico y el evento de tablero no pudieran intercambiarse a posteriori. En **Recall@10** la barra para un modelo único autónomo es el tablero de modelo único 0,123, *no* el blend campeón de tres ramas 0,212 — comparar un modelo entrenado contra una fusión de tres ramas sería un error de categoría, y usar la torre doble como rama R' exige un cambio de código en **seq-blend**, explícitamente fuera de alcance. En **holisticness@10** la regla de corona lleva un piso de recall anti-degenerado (véase más abajo). Las diez ejecuciones corren sobre la partición canónica seq-20260715-131139 con semilla 1337, ejecutadas de una en una en un único worker remoto, y la línea base C0 reprodujo su Recall@10 de registro 0,12299 (176 de 1431) *exactamente*.

Resultados. La Tabla 30 es el lote. **Ninguna rama va en negrita como ganadora porque no hay ganadora:** la línea base de GRU única mantiene el mejor Recall@10 del lote, y ni una de las ocho ramas duales la supera con el IC del Δ pareado enteramente por encima de cero — seis pierden sin ambigüedad y dos (el par con `fusion_layers = 0`) empatan. La regla de refutación pre-registrada se activó.

La capacidad tampoco era la palanca omitida. El control emparejado en parámetros C1 (h425, 871 017 parámetros — $2,2\times$ C0) obtiene 0,12089 frente al 0,12299 de C0, con un Δ pareado de $-0,0021$ que cruza cero. Esto cubre un hueco real: la *anchura* de GRU única solo se había escaneado sobre el espacio AE de 64 dimensiones (Sección 8.2), y el espacio rico PCA-192 estaba sin probar. Se comporta igual, así que **la anchura de GRU única queda ahora cerrada también en PCA-192, como ya lo estaba en AE-64**. Como C1 es una coincidencia genuina al 0,098 % en parámetros con las ramas de `fusion_layers = 1`, el nulo no puede reatribuirse a «la capacidad habría ayudado»: demostrablemente no lo habría hecho.

Atribución de vistas: la complementariedad es real, pero cae en el par equivocado. El triángulo completo de vistas es lo que vuelve esto decidible mecánicamente en lugar de un juicio de valor, y la respuesta es genuinamente sorprendente (Tabla 31, Figura 25). El par que el diseño nominó como su mejor esperanza — **latent + cummean** — *no* es complementario: empató con su padre latent/latent y solo supera al padre de solo centroide, es decir, la torre de latentes crudos carga con la celda entera y la torre de centroide es peso muerto. Lo mismo ocurre con **latent + delta**. Pero **delta + cummean** *sí* es complementario: supera a *ambos* padres con IC por encima de cero. Leído en conjunto: el mecanismo de co-adaptación que proponía la hipótesis **funciona** de verdad; simplemente ocurre que **la vista latent cruda ya subsume todo lo que llevan las otras dos**. Una GRU sobre latentes crudos integra internamente el movimiento entre pasos y la media acumulada, de modo que emparejarla con un cálculo explícito de cualquiera de los dos es redundante — mientras que dos vistas *empobrecidas* sí tienen información no solapada que agrupar, a un nivel absoluto desesperado (0,08665). Esa es una explicación mecanicista limpia del nulo, no una mera ausencia de efecto.

La cabeza MLP de fusión es activamente perjudicial, no solo inútil. Ambas ramas con `fusion_layers = 0` superan a sus gemelas de `fusion_layers = 1` con el IC del Δ pareado por encima de cero (+0,0161 en latent/latent, +0,0203 en latent/cummean) con un 10 % *menos* de parámetros — así que quitar la cabeza vuelve el modelo mediblemente mejor en *ambos* regímenes de vista. Mecánicamente esto encaja con todo el arco de la familia: el objetivo es recuperación coseno/InfoNCE en el espacio latente de ítems, así que el trabajo de la cabeza es aterrizar *en* esa geometría, y una capa no lineal extra de anchura 256 entre el estado recurrente y una lectura métrica solo añade una deformación que la pérdida debe después deshacer. El intercambio corre




Figura 25: La matriz completa de emparejamiento de vistas con `fusion_layers = 1`, una ejecución por celda. Toda celda dual queda *por debajo* de la línea base de GRU única (0,12299), y el orden es monótono en cuánta vista `latent` cruda contiene el par: ambas-latent es la mejor, ambas-delta la peor. El triángulo inferior nunca se ejecutó (el emparejamiento es simétrico por construcción) y se enmascara en gris en lugar de reflejarse, de modo que la escala de color refleja solo celdas medidas. El gradiente es el hallazgo: una torre recurrente sobre latentes crudos ya calcula lo que `delta` y `cummean` hacen explícito.

al revés en holisticidad (ambas ramas `f0` tienen H menor, con el IC de ΔH por debajo de cero): la deformación extra de las ramas `f1` difunde el top-diez (más ild, menos `artist_adj`) a costa de los aciertos exactos. La regla adoptada es `fusion_layers = 0` **por defecto**, confirmada luego una tercera vez (Tabla 34).

Holisticidad y recall están anticorrelacionados, y el piso de recall se ganó su lugar. Cinco ramas elevan `holisticness@10` con el IC del ΔH por encima de cero, culminando en el 0,19715 de D-CC (+0,055) — que en la métrica de corona desnuda habría quedado segundo en todo el tablero. Pero D-CC aterriza 95 de 1431 aciertos exactos frente a los 176 de la línea base. El orden del lote por H es casi el *inverso* de su orden por recall (Figura 26), de modo que **las cinco ganadoras en ΔH incumplen el piso de recall pre-registrado de $\pm 0,015$** y la regla de corona nunca se activó. Sin ese piso la campaña habría «ganado la corona» con un modelo un 46 % peor en su trabajo real — precisamente el modo de fallo degenerado de `mood-session` (H 0,2332 con Recall@10 0,0238) que el piso se escribió para bloquear. Con la evidencia actual, **la holisticidad sin restricciones se maximiza prediciendo peor**, así que cualquier objetivo futuro de holisticidad en este corpus debe ser uno *restringido*.

Interpretación. No se registró nada ni se promovió nada; el campeón, la tabla de clasificación y los pines quedan intactos. Lo que compra la campaña es un *cierre*: el nulo de combinador es ahora robusto en todo el espacio de diseño de combinadores en este corpus — post-hoc a nivel de puntuación (de tres formas) *y* a nivel de representación entrenado conjuntamente con un control




Figura 26: Por qué la regla de corona necesita un piso de recall duro. A lo largo de las diez ramas, holistiness@10 corre casi exactamente *al revés* que Recall@10: las cinco ramas que superan el tramo de ΔH con IC por encima de cero (verde) son las cinco más *alejadas por debajo* de la línea base en recall exacto, y las cinco caen fuera del piso de $\pm 0,015$ (sombreado). El cuadrado hueco es el modelo incumbente `mood-session` que motivó el piso: la mayor holisticidad del registro con 34 de 1431 pistas siguientes correctas. Los valores de H son de la generación de 3 factores (Sección 17).

emparejado en parámetros — lo que consolida materialmente que «el z-blend fijo de tercios iguales es el combinador de referencia». Dos sub-hallazgos genuinos sobreviven al nulo (la cabeza MLP de fusión perjudicial, y la complementariedad `delta+cummean`), y la maquinaria en sí es sólida: 10 de 10 ejecuciones exitosas, el nuevo predictor entrena, converge y evalúa con paridad exacta respecto a la familia, y D-LL-f0 incluso obtiene el mejor MRR del lote (0,05631 frente al 0,05341 de C0) — la única métrica en la que lidera una rama dual. Según la disciplina de la banda de ruido eso es «al menos igual, probablemente ni mejor ni peor», no una victoria.

Un hallazgo de procedencia que revisa dos números previos. Antes del lote se descubrió que el directorio del worker remoto en vivo estaba *obsoleto*: su `seq_common.py` no tenía `holisticness_at_k` en absoluto, `seq_nexttrack.py` difería del hub por md5 y faltaban por completo tres módulos `seq_*.py`. Tras refrescar y verificar que toda la familia era md5-idéntica al hub, C0 devolvió 0,12299, idéntico bit a bit al valor de registro del hub — y *no* el 0,1201957 que habían devuelto dos ejecuciones remotas anteriores (`run-20260723-002044-af11a`, `-17cf8`). El «desplazamiento de $-0,0028$ por orden de reducción entre hosts» que aquellas ejecuciones sugerían queda por tanto **retirado: era una diferencia de código, no un efecto de host**. Sus números de recall pertenecen a un estado de código superado y no son comparables en código con lotes posteriores; siguen siendo válidos como las mediciones de eagerness β para las que se tomaron (Tabla 28), ya que esas conclusiones descansan en comparaciones intra-lote. La lección general — un checkout remoto divergente produce un *número equivocado*, no una caída — es ahora una comprobación previa permanente. *Fuente: 2026-07-25-nexttrack-dual-tower-fusion-scan.md*.

16. Pista siguiente: el pre-codificador por paso refutado, y el mecanismo del rectificador

Motivación. El nulo de torre doble cerró la asimetría de vistas *deterministas*: **delta** y **cummean** son funciones con pérdida de lo que una torre de latentes crudos ya posee, así que emparejarlas no compra nada. Esta campaña plantea la versión estrictamente más fuerte: ¿una re-incrustación **aprendida** por paso, que *no* es función de información que la torre ya tenga, amplía útilmente el espacio de hipótesis? El eje es una re-incrustación no lineal delante de la recurrencia, $[\text{Linear}(d_{\text{in}}, w), \text{ReLU}, \text{Dropout}] \times \text{pre_layers}$, aplicada por paso temporal (estrictamente causal), con el **input_size** de la GRU pasando a ser w .

La hipótesis tiene un filo analítico inusualmente nítido. La propia transformación de entrada de una GRU *ya es lineal* ($W_i x$ por compuerta), y un pre-codificador *lineal* con $w \geq d_{\text{in}}$ es exactamente igual de expresivo que una GRU desnuda, puesto que $W_i(Vx) = (W_i V)x$ sin restricción de rango. **La ReLU es por tanto el único cambio de expresividad**, lo que significa que no hace falta una ejecución de control con pre-codificador lineal y que un nulo no puede despacharse como «el pre-codificador era redundante por construcción». El movimiento decisivo del diseño es la **ablación de torre única** S1 — un MLP256→GRU256 contra una GRU simple emparejada en parámetros — porque sin ella cualquier resultado de torre doble es ininterpretable: ¿pre-codificador, o segunda torre?

Diez ejecuciones, la misma partición canónica, el mismo worker remoto único, cero fallos. Dos puertas de reproducción pasaron *bit a bit*: C0 devolvió Recall@10 0,12299091544374564 (176 de 1431, idéntico hasta el último dígito, una séptima reproducción), confirmando que la edición de **pre_hidden** no perturbó la ruta de código por defecto de la familia; y C3, la rama de torre doble desnuda, devolvió 0,10272536687631029, exactamente su valor de registro, validando todos los veredictos duales.

Resultados. La Tabla 32 es el lote y la Figura 27 el veredicto de un vistazo. Ni una de las seis ramas con pre-MLP supera la línea base con el IC del Δ pareado por encima de cero: cinco pierden sin ambigüedad, una empata. **Y la ablación decisiva no solo empata: pierde:** S1 en 0,10901 frente al 0,12299 de C0, con $\Delta -0,0140$ y el IC enteramente por debajo de cero, 156 aciertos contra 176. Puesto que aquí un pre-codificador lineal es demostrablemente neutro en expresividad, **la re-incrustación con ReLU está destruyendo información del prefijo que la propia transformación de entrada lineal con compuertas de la GRU preservaba.**

La curva de dosis es plana, y la colocación es irrelevante. Barriendo **pre_hidden_b** por $\{0, 128, 256, 384\}$ con **fusion_layers** = 1 (Tabla 33), todo par adyacente cruza cero y también lo hacen los extremos — un eje **plano**, lo que por la cláusula pre-registrada habría bloqueado el registro incluso si alguna regla de victoria se hubiera activado. Nótese, sin embargo, que el orden *nominal* es descendente-y-luego-plano, nunca ascendente: toda rama dosada queda por debajo de la dual desnuda. Junto con la pérdida significativa de S1, el signo de este eje es consistentemente negativo en ambas torres y en las cuatro anchuras, así que no hay pico interior que perseguir. La simetría es igualmente un no-factor: T1 (asimétrica, una torre desnuda) contra T4 (ambas torres rectificadas) cruza cero en recall, así que mantener desnuda la torre A no es determinante a esta dosis.

El único positivo sólido: la regresión de profundidad de fusión, medida por tercera vez y mayor. T1-f0 supera a T1 por +0,0266 con el IC por encima de cero, frente al +0,016 y +0,020 medidos en los dos regímenes de vista de torre doble (Tabla 34). El mecanismo se sostiene y se afila: cada capa no lineal extra entre el estado recurrente y la lectura métrica añade una deformación que la pérdida InfoNCE debe deshacer, y *cuanta más no linealidad se haya añadido ya en el lado de*




Figura 27: El veredicto del pre-codificador. Δ Recall@10 de bootstrap pareado por sesión contra la línea base reproducida, una fila por rama; la franja sombreada es la banda práctica de empate de $\pm 0,015$. Ni una rama con pre-codificador alcanza un IC enteramente por encima de cero. La fila decisiva es S1 — la torre única, la única rama cuyo resultado es atribuible sin ambigüedad al pre-codificador — que pierde sin paliativos. Como un pre-codificador *lineal* a esta anchura es demostrablemente neutro en expresividad, el rectificador es la única causa candidata.

entrada, más cuesta la deformación del lado de salida. Nótese además que T1-f0 — la única rama con pre-codificador que empata con la línea base — es exactamente la rama que tiene *a la vez* una torre A desnuda y `fusion_layers = 0`: la ruta más corta y sin deformar desde los latentes crudos hasta la lectura. `fusion_layers = 0` es el valor por defecto de la familia, punto.

El mecanismo, medido en lugar de inferido. El argumento analítico señalaba al rectificador como única causa candidata; una lectura de interpretabilidad posterior lo *midió* (Figura 28). El control decisivo fue un tap contrafactual que el motor de autoencoder disperso no puede expresar: el *propio* mapa afín del modelo con la ReLU eliminada. Leyendo la decodificabilidad de género de la siguiente pista en el mismo paso (11 184 filas de prueba de sonda, 25 clases, error estándar pareado $\leq 0,0065$): el latente crudo puntúa 0,4033, el mapa afín 0,4084 (**neutro**, $\sim 0,8\sigma$, exactamente como predice $W_i(Vx) = (W_iV)x$) y el tap rectificado 0,3700 ($\sim 5,9\sigma$: **la ReLU es toda la pérdida**). La prueba definitiva es aritmética: `frac_exact_zero` en el tap rectificado es 0,5327, que coincide con el `frac_negative_coords` del tap afín, 0,5327, hasta cuatro dígitos. El rectificador borra *precisamente* la mitad negativa, dejando ~ 120 unidades vivas para 192 direcciones con signo — *menos coordenadas vivas que dimensiones tiene la entrada*. Los latentes PCA-192 están centrados en cero y son casi simétricos por construcción, y con $w = 256$ (solo $1,33\times$ la dimensión de entrada) no hay ni de lejos suficiente sobrecompletitud para re-codificar el semiespacio descartado, a diferencia de los embeddings anchos donde viven normalmente los MLP con ReLU. El daño sobrevive a la recurrencia: dentro de un mismo modelo, `tower_b` (alimentada rectificada) puntúa 0,3929 frente a su *gemela idéntica* `tower_a` (alimentada cruda) con 0,4183, $\sim 3,9\sigma$ — y `tower_a` reproduce la GRU simple autónoma (0,4235), que es exactamente lo que exige «la torre desnuda *rescata*».




Figura 28: El mecanismo del rectificador, medido. Decodificabilidad de género de la siguiente pista en cada tap de representación, incluido uno contrafactual que el motor de interpretabilidad no puede expresar: el propio mapa afín del modelo con la ReLU eliminada. En el lado de entrada el mapa afín es *gratis* ($\sim 0,8\sigma$) y la ReLU es el coste *entero* ($\sim 5,9\sigma$); tras la recurrencia el daño persiste ($\sim 3,9\sigma$ entre dos torres idénticas que solo difieren en si su entrada fue rectificada), mientras que la torre alimentada en crudo reproduce la GRU simple autónoma. `frac_exact_zero` en el tap rectificado (0,5327) coincide con el `frac_negative_coords` del tap afín (0,5327) hasta cuatro dígitos: la rectificación de media onda de un latente centrado en cero borra exactamente la mitad negativa, dejando ~ 120 unidades vivas para 192 direcciones con signo.

Interpretación, y una salvedad honesta sobre los controles. Este es el quinto nulo consecutivo de arquitectura, y cierra el *lado de entrada* como el nulo de vistas cerró la dirección de vistas de entrada: junto con los cuatro nulos de combinador aprendido, añadir maquinaria de representación *alrededor* de una GRU única sobre un buen espacio latente no ayuda en este corpus, mientras que toda ganancia real del registro vino de mejorar el *propio espacio latente* (la proyección de contenido InfoNCE, PCA-192) o del z-blend fijo. El eje queda ahora acotado cuantitativamente: mejor rama con pre-codificador 0,12369, un empate; dosis plana hasta el doble de la dimensión de entrada; colocación irrelevante; interacción con la profundidad de fusión resuelta. La salvedad es que el *control de anchura emparejado en parámetros resultó un instrumento más débil de lo supuesto*: C1 (h297) llegó a 0,11321, perdiendo él mismo contra C0, y los puntos de anchura del lote corren $176 \rightarrow 162 \rightarrow 173 \rightarrow 179$ aciertos en h256 / h297 / h425 / h454 — no monótonos, abarcando 0,0119 de recall sin tendencia. «La anchura de GRU única es plana en PCA-192» sobrevive como afirmación de *tendencia* (h454 empata con h256), pero el ruido entre anchuras es de $\sim \pm 0,01$ en una sola partición, aproximadamente dos tercios de la banda de ruido. **Un control emparejado en anchura que es él mismo una única ejecución sin replicar no es un anclaje de capacidad fiable a esta magnitud de efecto** — razón por la cual importa que el veredicto de S1 descansa en la comparación con C0, reproducida hasta el último dígito. Una segunda salvedad queda sin desenredar: el pre-MLP termina en **Dropout**, de modo que las ramas con pre-codificador reciben dropout a la *entrada* de la GRU que las ramas desnudas no tienen, y la pérdida de S1 podría

deberse en parte a sobre-regularización más que al rectificador — separarlos exige un parámetro `pre_dropout` que todavía no existe. *Fuente: 2026-07-26-nexttrack-pre-encoder-scan.md.*

17. Pista siguiente: leyendo el registro — potencia estadística y las generaciones de holisticidad

De los lotes del 2026-07-25/26 emergieron dos hechos transversales que cambian cómo debe leerse cada número anterior. Ninguno es un resultado sobre un modelo; ambos son resultados sobre el *instrumento de medida*, y su lugar es aquí y no enterrados en una sola campaña.

17.1. Los nulos están limitados por potencia, y esa es una afirmación distinta

Todo veredicto de pista siguiente de este documento descansa en un bootstrap pareado por sesión sobre las mismas 1431 sesiones de prueba. Ese n tiene una resolución medible. Promediado sobre las nueve comparaciones pareadas del lote del pre-codificador, el semiancho del IC al 95 % es 0,0124 en Recall@10 (0,0128 sobre las nueve del lote de torre doble, así que la cifra es estable), y $\sim 0,0018$ en *holisticness*@10. Compárense ahora con el *rango completo* de una familia de arquitectura: 0,028 en Recall@10 y 0,0031 en *holisticness*@10 (Tabla 35). El cociente es toda la historia: el rango completo de una familia mide solo $\sim 2,3$ anchos de resolución en recall y $\sim 1,9$ en *holisticidad*, de modo que de ocho ramas adyacentes son separables aproximadamente **dos niveles** en Recall@10 y **uno** en *holisticness*@10. Resolver una diferencia de 0,005 en Recall@10 a esta precisión exigiría $n \approx 1431 \cdot (0,0124/0,005)^2 \approx 8800$ sesiones de prueba, seis veces lo que aporta la partición (Figura 29).




Figura 29: Los nulos de arquitectura están limitados por potencia. El semiancho del IC de bootstrap pareado cae como $1/\sqrt{n}$; con el $n = 1431$ de la partición vale 0,0124 en Recall@10, mientras que una familia de arquitectura completa abarca solo 0,028. Resolver una diferencia de 0,005 exigiría ~ 8800 sesiones de prueba. La lectura honesta de los cinco nulos de arquitectura se sigue de inmediato: *los daños grandes se detectaron con fiabilidad; las victorias moderadas nunca fueron detectables.*

La lectura honesta de los cinco nulos de arquitectura se sigue directamente, y no es la que da una mirada superficial. Lo que estas campañas establecieron con firmeza es que las arquitecturas probadas no entregan ganancias *grandes*, y que varias de ellas hacen *daño* real — los daños son los resultados bien potenciados, porque son grandes (S1 $-0,0140$; la regresión de `fusion_layers` $+0,0266$; seis de ocho ramas duales por debajo de la línea base). Lo que las campañas *no* pueden establecer es la ausencia de una ganancia moderada: una mejora genuina de $+0,005$ — que sobre una línea base de $0,123$ sería un respetable 4% relativo — habría sido invisible por construcción. Así que «la fusión de torre doble queda refutada» y «el pre-codificador queda refutado» deben leerse como *ningún efecto grande, y ningún efecto de la magnitud hipotetizada*, no como «estas arquitecturas no funcionan». La consecuencia práctica es una regla de priorización más que una salvedad: en esta partición, más ramas de arquitectura son un mal uso de las ejecuciones sea cual sea su resultado, porque todo el rango dinámico del espacio de diseño apenas duplica el error de medición. O se amplía n , o se pasa a ejes cuyos efectos sean grandes — que es, empíricamente, exactamente lo que han entregado los ejes de representación y supervisión (el $+0,0259$ de la proyección de contenido es el doble del semiancho, y el $+0,0426$ del endurecimiento en segunda partición, el triple).

17.2. Tres generaciones de `holisticness@10`, y por qué el tablero se denomina en recall

El compuesto *holisticness@10* se revisó dos veces en cuatro días, y los valores almacenados **no son comparables entre los cortes**:

Gen. 1 — 3 factores (hasta 2026-07-24). El producto desnudo

$$\text{clamp}(\text{mood_coh}, 0) \times \text{ild} \times (1 - \text{artist_adj}),$$

que no lleva *ningún término de corrección en absoluto*. Los valores caen en $0,063$ a $0,233$ — la columna de la Tabla 30.

Gen. 2 — 4 factores, anclada (2026-07-25). Multiplica por un factor de anclaje (*grounding*) de `music@10`,

$$\text{clamp}((\text{music@10} - 0,185)/0,815, 0, 1).$$

Como `music@10` cae al mismo compás que el recall, esto cancela las «victorias» por des-eagerización que premiaba la forma de 3 factores; los valores caen en $0,044$ a $0,050$ — la columna de la Tabla 32.

Gen. 3 — consciente de la concentración (2026-07-26). La `eagerness` pasa a ser $\max(\text{artist_adj}, \text{artist_conc})$ y el piso de anclaje sube $0,185 \rightarrow 0,34$. Los valores caen cerca de $0,009$ a $0,025$.

Cada faceta se almacena por fila, así que cualquier generación es recalculable a posteriori (el ayudante `rescore_holisticness.py` lo hace para las ejecuciones a las que puede llegar), y la Tabla 36 re-deriva las tres para un corte representativo. Dos consecuencias importan al leer este documento. Primera, **una columna de holisticidad debe llevar siempre la etiqueta de su generación**, porque el efecto de generación empequeñece al efecto de modelo: todo valor de 3 factores supera mecánicamente a todo valor de 4 factores, ya que el factor de anclaje multiplica por $\sim 0,3$. Segunda, y más importante, **los tableros de recall y de holisticidad apuntan en direcciones opuestas en todas las generaciones**. El blend campeón — $0,21174$ de Recall@10,

303 de 1431 — queda *último* en la Tabla 36 bajo las tres fórmulas, porque es el modelo más artist-eager del registro; lideran la rama degenerada `cummean/cummean` y `mood-session`. La generación 3 degradó `mood-session` de primero a un cero genuino, pero *no* arregló la rama degenerada de torre doble, así que el piso de recall de $\pm 0,015$ sigue siendo obligatorio en cualquier afirmación de holisticidad.

Qué es la métrica principal, y por qué ordena este documento. Para completar el cuadro: la clave `[metrics].primary` de `domain.toml`, y el `primary_metric` del grupo de mejores modelos, han marcado ambos `holisticness@10` desde 2026-07-23, así que la métrica principal *efectiva en el servidor* ya no es `Recall@10`. Las afirmaciones de las secciones anteriores de pista siguiente de que «la métrica principal sigue siendo `Recall@10`» eran ciertas cuando se escribieron y quedan superadas *para el servidor*. Aun así, este documento sigue denominando la tabla de clasificación de pista siguiente (Tabla 16) y cada veredicto de campaña en **Recall@10**, y lo hace deliberadamente: es la moneda de comparabilidad del registro, es estable en las tres generaciones de la métrica y — como muestra la Tabla 36 — un orden por holisticidad situaría último al campeón servible. La holisticidad se reporta en todo el documento como columna diagnóstica etiquetada y marcada con su generación. *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md, 2026-07-26-nexttrack-pre-encoder-scan.md.*

18. Pista siguiente: la frontera de MMR λ : la primera palanca de corona confirmada

Motivación. La Sección 14 dejó una bandera pendiente: un re-ordenamiento MMR en tiempo de evaluación con $\lambda \approx 0,9$ era «la única palanca de `holisticness` casi gratuita del registro», medida en un barrido *offline* sobre un checkpoint almacenado y diferida explícitamente a una decisión del usuario. Esta campaña es la confirmación nativa, y se diseñó para resolver además una segunda pregunta *de mecanismo* pre-registrada, no simplemente para volver a medir el mando: ¿la diversificación sónica des-concentra **artistas** (H1, «responsiva») o las pistas del mismo artista están lo bastante separadas en el espacio de la métrica de contenido como para que la penalización de diversidad deje intacta la eagerness (H2, «pegajosa»)? La respuesta decide si una penalización explícita de diversidad de artista es la secuela indicada o una redundante.

Qué se está maximizando. Las diez ramas se puntúan bajo la corona *viva* de cuatro factores, tomada literalmente de `predictors/seq_common.py`:

$$\begin{aligned} H = & \text{máx}(\text{mood_coh}, 0) \times \text{ild} \\ & \times (1 - \text{clamp}(\text{máx}(\text{artist_adj}, \text{artist_conc}), 0, 1)) \\ & \times \text{clamp}((\text{music}@10 - 0,34)/0,66, 0, 1), \end{aligned}$$

con cada faceta como la *media sobre filas* y el producto tomado *de los agregados* — la generación 3 de la Sección 17.2. Dos anclas enmarcan el lote: **A**, el campeón de recall $R' + M + C'$ (H 0,008603, con su factor de eagerness ligado por `artist_conc` 0,691653), y **B**, el mejor modelo *único* en la corona viva, `gru-infonce-h256` (H 0,024538). La barra a superar es el máximo histórico de corona entre ramas sanas, $H_{\text{bar}} = 0,024872$, en manos de un control de capacidad h425 (`run-20260725-143502-be11b-seq-nexttrack`). Todas las ramas usan la partición canónica `seq-20260715-131139`; no hizo falta trabajo de dataset.

Por qué este lote es inusualmente afilado. λ es un parámetro *solo de evaluación*: los pesos entrenados son idénticos bit a bit entre las ramas de un mismo modelo, así que $\lambda = 1,0$ es una compuerta de identidad bit a bit y cada Δ es una comparación pareada al máximo. Ambos controles reprodujeron sus anclas exactamente (303 y 176 aciertos de 1431, con MRR coincidiendo a $3,1 \times 10^{-11}$), y el H de cada rama fue *recalculado* desde el `predictions.json` almacenado por una única ruta de código, de modo que el sesgo de redondeo por fila se cancela en cada Δ (recalculado contra almacenado coincidió a $7,4 \times 10^{-8}$ y $2,1 \times 10^{-7}$). Una tercera compuerta — MMR activo — exigía que el ild de cada rama con $\lambda < 1$ difiriera del de su propio control por mucho más de 1×10^{-6} , que es el detector registrado de que MMR se vuelva silenciosamente inocuo cuando el índice de la métrica de contenido es inalcanzable. Ninguna rama fue inocua.

Resultados. La Tabla 37 es la frontera, y la Figura 30 la dibuja. Las ramas se clasifican por una regla pre-registrada: **NIVEL-1 GRATIS** significa ΔH sobre cero con el Δ de recall abarcando cero y $|\Delta \text{recall}| \ll 0,015$; **NIVEL-2 CON PRECIO** significa una ganancia real de H a un costo de recall que el IC ve; **NIVEL-3 RECHAZADA** significa Δrecall por debajo de $-0,03$.




Figura 30: **Izquierda:** la frontera de λ en el plano recall $\times$ corona. Cada motor traza un camino a medida que λ baja desde 1,0; el color es el nivel pre-registrado (verde NIVEL-1 GRATIS, azul NIVEL-2 CON PRECIO, rojo NIVEL-3 RECHAZADA, gris control). Tres ramas de la GRU única superan la barra histórica de corona 0,024872 con un recall cuyo IC pareado abarca cero — el primer movimiento de corona genuinamente gratuito del registro. El camino del campeón alcanza un H comparable solo tras pagar recall que el IC ve, y sus dos mejores puntos de H quedan rechazados como degenerados. **Derecha:** la pregunta de mecanismo. H1 exigía $|\Delta \text{artist_conc}| \geq |\Delta \text{artist_adj}|$; H2 exigía la razón por debajo de 0,5 (zona sombreada). Medida en 1,59 a 3,06 en 8 de 8 ramas, así que H2 queda refutada por un factor de 3 a 6 en la dirección contraria — y la razón se encoge monótonamente al bajar λ , es decir, la des-concentración fácil se compra primero y el mecanismo se satura.

Interpretación. MMR es una palanca de corona real, y la primera del registro. Cada una de las ocho ramas con $\lambda < 1$ eleva H con el IC enteramente sobre cero. Lo que hace legítima la ganancia, en lugar de un artefacto del compuesto, es que *tres* de los cuatro factores mejoran a la vez: ild sube (0,4536→0,5314 en la GRU, 0,4064→0,8146 en el campeón), la eagerness baja y — la parte portante — music@10 también sube (0,4558→0,4747). Una palanca que elevara H

degradando la relevancia quedaría cancelada por el factor de anclaje; esta no, y esa es exactamente la distinción que el umbral se escribió para imponer tras las patologías de `cummean/cummean` y `seq-mood`.

H1 se confirma unánimemente y H2 queda refutada, lo que *cancela* la secuela que la campaña previa había pre-registrado. En 8 de 8 ramas $\Delta_{\text{artist_conc}} \leq \Delta_{\text{artist_adj}}$ (ambas negativas) con una razón de 1,59 a 3,06. Las pistas del mismo artista *sí* son vecinas cercanas en el espacio de la métrica de contenido, así que una penalización de similitud máxima des-concentra artistas como efecto colateral, sin ninguna noción explícita de artista en ninguna parte. Por tanto el MMR sónico *es* una palanca de des-eagering, y portar la `artist_penalty` explícita de `seq-mood` al blend — la secuela H2 pre-registrada — ya no es el siguiente paso indicado. Queda archivada como *complemento*, porque `artist_adj` cae $\sim 2,5\times$ más despacio que `artist_conc` y se convierte en la faceta que liga a λ bajo.

La faceta que liga cambia, y eso localiza el final de la palanca. En el campeón el cambio de `artist_conc` a `artist_adj` ocurre entre $\lambda 0,7$ y $\lambda 0,5$; en la GRU ya ha ocurrido a $\lambda 0,9$. Una vez que liga `artist_adj`, el factor $(1 - \text{eager})$ es el rígido y cada punto adicional de recall compra progresivamente menos corona — la razón estructural de que la frontera de la GRU se aplane donde lo hace, y una predicción de que empujar por debajo de $\sim \lambda 0,7$ en la GRU es mal negocio. B3 es la confirmación: el H más alto medido en cualquier parte (0,034171) al costo de perder el empate de recall.

El punto de operación promocionable es la sonda de pool. B4 ($\lambda 0,7$, `mmr_pool` 50) es la mejor rama NIVEL-1 con H 0,030355 — $+22,1\%$ sobre H_{bar} y 5,4 semianchos medidos por encima — y supera a B2 en H por $+0,000889$ con el IC sobre cero a un recall que abarca, de modo que su puesto está *resuelto*, no es nominal. B2 ($\lambda 0,8$) era la hipótesis de promoción pre-registrada del diseño y se cumplió casi exactamente como se proyectó (0,0321 previsto frente a 0,029458 medido, con un costo de recall *menor* que el proyectado). Nada se promocionó: se registraron seis definiciones, cada una con la nota «NO PROMOCIONADA — confirmación de robustez + aprobación del usuario pendientes». La tabla de recall queda intacta: **ninguna rama mejora el recall**; MMR solo lo cuesta.

El segundo eje, `mmr_pool`, cierra como mando de ajuste fino y no como eje. Limitar el conjunto de candidatos a 50 recupera recall (Δ frente a pool 200 $+0,005584$, IC sobre cero, como se hipotetizó — un tope acota cuán lejos puede llegar MMR buscando diversidad) pero devuelve H ($-0,003838$, IC bajo cero). No gana a λ fijo; se mueve por la *misma* frontera. Lo que le gana una línea en el registro es la comparación cruzada anterior: el tope alcanza un punto ligeramente *mejor* que el ajuste puro de λ más cercano. Prefiérase λ para movimiento grueso y el pool para ajuste fino en un λ elegido.

El contraste campeón/GRU se resuelve a favor de la salud de los factores, no del margen para des-eagerizar. El diseño planteó esto como la pregunta portante: el campeón es $1,9\times$ más eager, así que un des-eagering absoluto dado vale allí $\sim 2,1\times$ más H relativo — y sin embargo arranca $2,85\times$ por detrás, y la brecha se *ensancha* bajo diversificación (H 0,015289 frente a 0,034171 a $\lambda 0,7$). Las facetas dicen por qué: el `mood_coh` del campeón **se derrumba** al diversificar (0,3982 $\rightarrow$ 0,2378 a $\lambda 0,3$, -40%) mientras el de la GRU apenas se mueve (-4%). El recall del campeón proviene de la adyacencia de artista — la rama de bigramas de Markov, según la Sección 14 — así que diversificar alejándose del artista semilla también lo saca del vecindario de ánimo del prefijo. Paga dos veces. **El valor de MMR escala con la salud de los otros tres factores, no con el margen para des-eagerizar**, y ningún λ cierra la brecha de corona del campeón.

Dos hallazgos de instrumento, uno de ellos una advertencia sobre el registro mismo. Primero, **el instrumento de pesos compartidos es 3 a 33× más afilado que el suelo de ruido de la familia de arquitecturas:** los semianchos medidos van de 0,000382 a 0,002476 en ΔH frente al 0,0018 conservador de la familia, con el número de sesiones cuyo hit@10 cambió siquiera tan bajo como 9. La rama A1 estaba pre-registrada como «probablemente IRRESOLUBLE» y se resolvió a 4,8 semianchos medidos. Las palancas en tiempo de evaluación deben por tanto presupuestar su efecto mínimo detectable a partir del *emparejamiento*, no de la cifra de arquitectura de la Sección 17.1 — los dos regímenes difieren en más de un orden de magnitud, y confundirlos deja sin potencia a toda una clase de experimentos baratos. El corolario tranquiliza en la otra dirección: el barrido *offline* de λ del 2026-07-22 proyectó recall 0,2103 / 0,1936 / 0,1642 / 0,1097 y los runs nativos devolvieron 0,21034 / 0,19357 / 0,16422 / 0,10971 — cuatro de cuatro a cuatro decimales, lo que valida el driver offline como instrumento de *cribado*.

Segundo, se encontró a la fuerza una nueva trampa de infraestructura que califica retroactivamente parte del registro: **un worker remoto ejecutando una imagen binaria (deleted) descarta silenciosamente claves de métrica que su estructura no conoce.** La compuerta de completitud de métricas falló en el primer intento con `artist_conc_at_k` ausente, aunque los predictores eran idénticos en md5 al hub y el propio `metrics.json` del worker llevaba el campo: el *demonio* del worker se había iniciado un día antes de que el campo existiera, `rsync` había reemplazado el archivo en disco pero no la imagen en ejecución, y la imagen antigua deserializó las métricas del predictor en una estructura sin el campo, lo descartó y publicó el conjunto filtrado **sin error**. `holisticness@10` fue correcto en todo momento porque el predictor calcula H él mismo antes de que el servidor lo vea — que es exactamente lo que hizo invisible el defecto. Todos los runs remotos de una ventana de cuatro horas del 2026-07-26 perdieron `artist_conc_at_k`, y por eso la concentración citada para el ancla B era una *reconstrucción* a partir de `top_k_ids` y el mapa de artistas del dataset. Esa reconstrucción queda ahora validada de forma independiente: los valores emitidos nativamente (0,6916530786551751 y 0,35591272614333413) coinciden con las reconstrucciones de la herramienta de re-puntuación hasta el último dígito. Remedios: ciclar el demonio siempre que se añada un campo de métrica; el `rsync` del binario no basta. *Fuente: 2026-07-26-nexttrack-mmr-lambda-frontier.md.*

19. Pista siguiente: despliegues autorregresivos: una métrica de generación y cinco barridos que dicen no

Motivación. Esta campaña la provocó una *preferencia del usuario*, no una métrica. Sobre una playlist real de 135 pistas el usuario prefirió con claridad el recorrido de 20 pasos de un motor sobre el de otro, mientras `holisticness@10` puntuaba esos dos recorridos con 0,003 de diferencia. Esa brecha es el punto: toda métrica del registro — `recall@10`, `holisticness@10` y sus cuatro facetas, `music@10`, incluso el evaluador multi-paso de continuación — puntúa *una* lista ordenada producida a partir de un prefijo *real*. Ninguna alimenta al modelo con su propia salida. Un recorrido de 20 pasos hace exactamente eso, así que un fallo de trayectoria — un despliegue cuya energía decae hasta que una semilla de fiesta se ha convertido en un bajón — es estructuralmente invisible para todas ellas. Es la primera campaña de este documento que construye un instrumento para el régimen de *despliegue*, y es el ancestro directo de la superficie de caminata de la Sección 23.

Qué se construyó. Cuatro cosas, todas fuera de la ruta de entrenamiento.

hold@N, una métrica de generación. Por eje legible a en {energía, valencia, acousticness, tem-

po},

$$\text{fade}_a = \frac{|\text{mean}(2.^{\text{a}} \text{ mitad}) - \text{mean}(1.^{\text{a}} \text{ mitad})|}{\text{band}_a},$$

y entonces

$$\text{hold@N} = 1 - \text{clamp}(\text{mean}_a(\text{fade}_a) + \text{stasis}, 0, 1).$$

Las bandas por eje se calibran sobre 2135 sesiones *reales* de entrenamiento (desvanecimiento de energía p10 0,0141, p50 0,0769, p90 0,1963; tempo 1,28, 8,05, 22,43), de modo que ejes con unidades incompatibles se combinan y «un desvanecimiento grande» significa grande *en relación con cómo escucha realmente este oyente*. Las sesiones reales no son planas — el desvanecimiento mediano de energía es 0,077 — así que una métrica que premiara el desvanecimiento nulo pondría a un generador antinaturalmente rígido por encima del oyente al que imita.

stasis, el término anti-gaming. Una métrica de puro desvanecimiento es degenerada: veinte pistas casi idénticas se desvanecen en 0 y puntúan 1,0, que es la misma patología que obliga a `holisticness@10` a llevar un umbral de recall *externo*. `stasis` pone el umbral *dentro* de la métrica penalizando pasos más pequeños que el salto p10 del propio oyente, y se verificó sobre un aplanamiento sintético (se-mueve-con-naturalidad 1,000, en-tu-umbral 1,000, medio-umbral 0,500, apenas-se-mueve 0,048).

Un evaluador offline de despliegue. `seq_continuation_eval.py --rollout` puntúa sesiones de *prueba* muestreadas **importando** el bucle de generación de la ruta de servicio en lugar de reimplementarlo, de modo que una puntuación offline describe los recorridos que el laboratorio sirve de verdad; la refactorización se verificó idéntica byte a byte. Es a demanda y muestreada porque un despliegue cuesta **steps** pasadas de vocabulario completo por sesión frente a la única de la ruta principal ($\sim 20\times$).

Una lectura para el laboratorio de playlists. Una tarjeta de informe de ánimo, un gráfico comparativo de forma del recorrido y diagnósticos `passed_over` por paso, con las facetas de `holisticness` relegadas a un bloque de detalle plegado.

Resultados. La Tabla 38 recoge cinco barridos, 120 despliegues pareados y 240 recorridos, bajo un bootstrap pareado sobre *semillas* más un jackknife de dejar-una-semilla-fuera. La política de despliegue se congeló todo el tiempo en los valores por defecto del laboratorio (20 pasos, penalización de artista 2, ancla 1, temperatura 0 — determinista, así que una semilla es una muestra y no hay varianza de despliegue).

Interpretación. **El desvanecimiento en despliegue no separa a esta familia.** A partición de entrenamiento igualada las dos arquitecturas empatan *dos veces*; sobre las propias playlists del usuario el par que prefirió empató; y el único efecto que sobrevive es de **nivel de checkpoint** dentro de una arquitectura (S4c), y no se traslada al régimen de playlists. La media de `hold@20` sobre las mismas 39 semillas aleatorias es 0,6488 / 0,6309 para los dos checkpoints de torre doble frente a 0,5983 / 0,5266 para los dos de GRU única — así que la aparente victoria de arquitectura de S3 se descompone en una componente de arquitectura no significativa (+0,05) y una componente de *checkpoint* significativa (+0,072). Dos modelos `seq-nexttrack` difieren entre sí más de lo que la torre doble difiere de la GRU única a partición igualada, y el checkpoint que el laboratorio de playlists preselecciona por defecto resulta ser el peor sostenedor de los cuatro. La comparación original del usuario era el mejor sostenedor contra el peor.

Combinado con los cinco nulos de arquitectura previos, este es un sexto, y es la forma más fuerte disponible, porque la réplica de siempre a esos nulos era que «recall@10 no puede ver la

calidad de la sesión». No puede; y cuando mira un instrumento construido para el régimen de despliegue, tampoco hay nada allí.

La varianza por semilla domina la identidad del modelo, y ese es el hallazgo operativo. Las brechas individuales sobre *un* par de modelos van de +0,39 a -0,27, mientras la diferencia media a nivel de modelo sobre las playlists del usuario es +0,004. Qué semilla se le dé al generador importa mucho más que cuál de estos modelos genere. Dos consecuencias: preferir servir un *conjunto* y dejar que el oyente elija antes que cazar un generador mejor, y presupuestar ≥ 40 semillas para cualquier comparación futura de despliegue — entre 8 y 12 no resuelven nada con esta varianza.

hold@N es un instrumento que funciona, pero no un ordenador de modelos. Se disparó sobre una diferencia real de checkpoint, se disparó sobre la playlist juzgada (0,62 frente a 0,25) donde *holisticness@10* veía una brecha de 0,003, y devolvió EMPATE correctamente tres veces. La recomendación es por tanto conservarla como *lectura de laboratorio* por recorrido y **no** cablearla como columna de tabla: su verdad de referencia es la preferencia del oyente, que está en $n = 1$ voto ciego. Promover un compuesto no validado a métrica principal es cómo la corona acabó necesitando un umbral de recall externo, y sustituir un compuesto no validado por otro repite el error.

Cuatro trampas metodológicas, cada una al precio de un positivo retirado. Valen más que el nulo. **(1) Una comparación entre particiones disfrazada de resultado de arquitectura.** Las dos preselecciones por defecto del laboratorio se entrenan sobre particiones *distintas* con vocabulario e ítems-latentes idénticos, así que compararlas atribuye a la arquitectura diferencias de checkpoint y de partición; empareje del mismo lote cuando la afirmación sea arquitectónica. **(2) La selección de semillas de ánimo extremo infla los efectos $\sim 2,5\times$** (el +0,314 de S2 se volvió +0,122 de S3 sobre una muestra aleatoria). **(3) Un término anti-gaming puede ser demasiado débil para su trabajo:** *stasis* normalizaba al principio el déficit por el *ancho* de la banda y, como la banda de saltos de este oyente es amplia, un despliegue aplanado puntuó 0,740 — *por encima* del 0,477 de un generador real. Normalice por el *umbral*; un guardián al que puede vencer la degeneración que persigue blanquea esa degeneración como buena puntuación. **(4) Una métrica que no devuelve nada debe descartar el *par*** y reportar el n menor, o el emparejamiento se rompe en silencio. El jackknife se ganó el sueldo con $n < 40$ en todo momento: mató dos de tres positivos por eje con $n = 8$ y marcó S4 y S5 como no respaldados con 0/39 y 0/11.

Qué añade la lectura por eje, incluido un control negativo fallido. Con $n = 39$ solo el desvanecimiento de *energía* separa las ramas (-0,039 [-0,069, -0,009], a favor de la torre doble); valencia, acoustiness y tempo abarcan cero. Pero un control *negativo* pre-registrado se movió: la desviación de *nivel* de energía respecto de la semilla favorece a la GRU única (+0,018 [+0,005, +0,032]). Son propiedades distintas, así que la afirmación tuvo que re-alcanzarse de «sostiene mejor la semilla» a «es más estacionaria» — y muestra que la exclusión deliberada de un término de nivel en *hold@N* es una decisión que *cambia el orden*, no una simplificación neutra. Dos límites más viajan con el lote: el 74 % del corpus lleva los campos acústicos que la métrica necesita, así que las semillas se pre-filtraron por cobertura de prefijo $\geq 60\%$ (un leve efecto de selección), y nada de esto se ha escuchado.

Nada se promocionó, registró ni cableó; el campeón, la tabla de corona y los anclajes del grupo de mejores modelos quedan sin cambios. Para el registro, la posición en la corona viva relevante para la cuestión de la torre doble es un *empate* más que una derrota — la mejor rama doble legítima 0,02378 frente al 0,02454 de la GRU única, una brecha de 0,0008 contra un semiancho de $\sim 0,0018$.

La familia fue refutada en recall@10, empata en la métrica principal viva y no muestra nada en el eje de despliegue. El siguiente eje indicado no es por tanto la topología sino el *régimen de entrenamiento*: los cinco nulos de arquitectura mantuvieron el teacher forcing de un paso idéntico byte a byte mientras el producto rueda veinte pasos sobre su propia salida, y ese desajuste de exposición es lo único que esos nulos no podían haber detectado. *Fuente: 2026-07-27-rollout-hold-metric.md.*

20. Pista siguiente: un memorándum de investigación, y qué permite su procedencia

Estatus, primero. Esta sección consolida un documento que **no es un informe de campaña**. Nada se ejecutó en el servidor, nada se promocionó, nada se registró; el campeón, la tabla de mejores, la tabla de corona y los anclajes del grupo de mejores modelos quedan todos sin cambios por él. Lo produjo un flujo de investigación (cuatro exploradores, cinco lentes de propuesta, cinco cribadores adversariales y luego síntesis) más puntuación *offline* contra checkpoints congelados. Donde reporta un número, ese número vino de un cribado offline sobre artefactos almacenados, no de un run nativo. Se incluye aquí porque es el padre directo de la campaña de la Sección 21 y porque sus resultados negativos — el cementerio de más abajo — son más baratos de reutilizar que de redescubrir. Se reporta en un registro más bajo que las campañas medidas, y sus cifras se mantienen deliberadamente fuera de toda tabla de este documento.

La partición de procedencia, mantenida visible. El propio memorándum distingue dos clases de número, y esa distinción sobrevive a esta síntesis.

Re-derivado de forma independiente por el orquestador. La proporción de consultas de prueba cuyo último ítem de prefijo tiene *cero* soporte de bigramas de entrenamiento: 795 de 1431 = 0,5556, reproducida por un script independiente. El control sin compuerta, que es auto-validante porque debe igualar al campeón: 0,21174, exacto. La rama con compuerta: 0,23201, un Δ pareado de +0,02027 [+0,01048, +0,03075] con el IC sobre cero. Y su descomposición por bucket: el bucket de soporte cero se mueve 0,1660→0,2025 sobre 795 consultas mientras los dos buckets cálidos quedan **idénticos bit a bit** (0,3116 y 0,2326, sin cambio).

No verificado por el orquestador. Solo reportado por agentes y tratado como provisional: la cifra +0,01957 de la segunda partición, el +0,02865 del canal de repetición, los números de `latent_gamma` y la discordancia recalculada de 0,0706 con su suelo de ruido de $\sim 0,0145$. Ninguno aparece en la Tabla 16 ni en ninguna tabla de corona, y el primero de ellos es precisamente lo que se encargó establecer nativamente a la campaña siguiente.

Una cautela que el memorándum enuncia sobre su propio titular. Las diez variantes de compuerta se cribaron **sobre el conjunto de prueba**, así que citar el IC de la mejor rama es optimista por construcción y el cribado no puede ser evidencia por sí mismo. Tres cosas lo mitigan — cuatro variantes mecánicamente relacionadas caen todas en 0,019 a 0,020, la descomposición por bucket es una explicación mecánica y no un ajuste, y los buckets cálidos no se mueven ni un acierto — pero la mitigación es un argumento, no una medición. La confirmación nativa en dos particiones es la compuerta real, y es la Sección 21.

El titular honesto: «una topología mejor» es la pregunta equivocada. El registro ya la había respondido seis veces: celda y función de pérdida en el espacio AE-64; profundidad, anchura

y dirección; anchura en PCA-192; fusión de torre doble (Sección 15); la cabeza MLP de fusión, una regresión *activa* recuperada al borrarla; el pre-codificador por paso, una pérdida medida con el mecanismo identificado hasta `frac_exact_zero = frac_negative_coords` (Sección 16); y el desvanecimiento en despliegue (Sección 19). Cinco lentes se apuntaron a la cuestión de topología y *toda* propuesta con forma de arquitectura volvió debilitada, bajo el ruido o pre-eliminada. Dos volvieron con resultados negativos medidos: una rama de Markov dividida perdió en cada punto de su propia rejilla pre-registrada, y una cabeza softmax factorizada por artista quedó muerta por su propio run de pre-eliminación, que encontró que compuertar por los 5 artistas principales sobre el checkpoint real cambia el recall en **exactamente** 0,0, porque el top-10 de la GRU entrenada ya vive dentro de sus propios 5 artistas principales.

Hacia dónde apunta la evidencia en cambio: el modelo no es la restricción. Lo son aquello contra lo que se le pide ordenar y qué ramas tienen permitido hablar en una consulta dada. Toda propuesta que sobrevivió al cribado adversarial es un cambio de conjunto de candidatos o de condicionamiento por evidencia — una rama de Markov con compuerta de evidencia, un canal causal de repetición entre sesiones, escalares de fiabilidad por rama, una máscara de negativos solo del prefijo, la temperatura del softmax nunca barrida. Ninguna es una topología. Es la misma conclusión a la que el registro había llegado por el lado de la representación, alcanzada desde cinco direcciones independientes, y viene con una justificación de medición: las palancas en tiempo de evaluación y de puntuación son 3 a 33× más baratas de resolver que las de entrenamiento (Sección 18), así que una lista corta de propuestas en tiempo de puntuación es la respuesta racional al instrumento que este laboratorio tiene.

Los dos supervivientes que merecen nombre. (1) `markov_gate` — hacer que la rama de Markov se abstenga donde no tiene evidencia de bigramas, restaurando el término `trust` que la normalización del blend borra. Doce líneas, cero parámetros aprendidos, y confirmado nativamente en la sección siguiente. (2) **Un canal causal de repetición entre sesiones** — el 76,17 % de los objetivos retenidos se reprodujo en una sesión *estrictamente anterior* y no está en el prefijo actual, y nada en la familia puede verlo, porque la rama de Markov es un bigrama congelado en entrenamiento y el puntuador de recencia solo puntuaba ítems del prefijo, que el evaluador enmascara a $-\infty$ (su 0,001 registrado es código muerto, no una medición). Su Jaccard de aciertos con la GRU es 0,060 frente al 0,201 del par GRU/Markov que produjo un blend funcional, es decir, es señal genuinamente distinta. Su problema es de *gobernanza*, no de código: es una enmienda del conjunto de información que mueve el techo ordenable de 0,4493 a 0,7617, lo que exige su propia columna de tabla y una decisión explícita antes de que cualquier número suyo sea comparable con algo de este documento. Una tercera propuesta, `latent_gamma` (un re-escalado espectral de un escalar sobre los ítems-latentes), merece registro por su *reencuadre* más que por su delta: en el cribado offline la contribución de recall completa del campeón es reproducible por un re-escalado diagonal de 192 números, lo que recategoriza «la mayor victoria del registro» como un arreglo de condicionamiento que la supervisión encontró por casualidad, y predice que seguir aprendiendo métricas lineales está casi agotado. Todas estas cifras son de la clase provisional.

El cementerio, que es la parte reutilizable. Cada entrada es un carril que no debería reabrirse sin información nueva. La entropía cruzada de catálogo completo o restringida al soporte queda pre-vaciada por una rama existente con ~53 % de cobertura de soporte (0,1223 frente a 0,1230) — el candidato número uno de la literatura no se traslada porque el lado de ítem está congelado. Una cabeza softmax factorizada por artista queda refutada por su propia pre-eliminación (exactamente 0,0). Dividir la rama de Markov en componentes de pista y de retroceso se midió en cada

punto de la rejilla y perdió en los cinco ($-0,0217$ a $-0,0384$, todos con IC bajo cero), porque una z-normalización separada destruye estructuralmente el término **trust** dentro del régimen cálido. Un re-ordenador de segunda etapa con pool igualado es inalcanzable: la densidad de positivos del pool de entrenamiento es 0,5975 frente al 0,3368 de prueba, así que su propia compuerta de avance pasa *a causa* de la confusión. Una cabeza de mezcla de vMF pierde frente a su propia descomposición oráculo. Difusión, DreamRec y flow-matching están falsificados externamente para este escenario, y la recuperación generativa con IDs semánticos queda estrictamente dominada cuando el coseno exacto sobre 15 MB ya es asequible y el corpus es 55 % a 64 % frío. El des-sesgado de popularidad no tiene nada que des-sesgar (la línea base de popularidad es 0,0007). La minería de negativos duros es perjudicial a temperatura baja aquí, porque los negativos más duros son pistas del mismo álbum y del mismo artista, es decir, se minan falsos positivos. Y la norma de salida pre-normalización de la GRU no es una señal de confianza (correlación con la corrección +0,0073, y la pérdida es exactamente invariante a la norma); el margen entre la puntuación top-1 y las diez siguientes sí lo es, con +0,294.

El único resultado teórico duradero. La observación transversal del memorándum de que **la anomalía del combinador aprendido queda explicada mecánicamente** es la parte que cambia cómo debe leerse el registro. Una búsqueda oráculo previa sobre pesos de rama *escalares, globales y estáticos* devolvió +0,004 abarcando cero, y ahora se ve por qué eso es compatible con un +0,020 real de una compuerta: quitar la rama de Markov *globalmente* gana en el bucket de soporte cero y pierde en el bucket cálido, y las dos se cancelan casi exactamente. Ninguna constante puede expresar una intervención cuyo signo se invierte con un estadístico de datos por consulta, y la z-normalización es invariante a escala, así que demostrablemente no puede verla. La trampa registrada de «cuatro nulos independientes de combinador aprendido» debería por tanto prohibir la *fusión aprendida a nivel de puntuación* — pesos ajustados, stackers, fusión de rangos, fusión de representaciones de extremo a extremo — y **no** el compuertado por evidencia por consulta, que es una tercera cosa: nada se aprende, nada co-adapta y la condición es un conteo del lado de entrenamiento. *Fuente: 2026-07-27b-nexttrack-model-topology-research-memo.md* (memorándum de investigación; véase la partición de procedencia arriba).

21. Pista siguiente: markov_gate: una rama que se abstiene donde no tiene evidencia

Motivación. Esta es la confirmación nativa en dos particiones de la propuesta titular del memorándum (Sección 20), y produce la mayor ganancia individual de recall de todo el arco de pista siguiente a partir de un cambio de nueve líneas sin parámetros nuevos.

El mecanismo, y por qué no es el carril refutado del combinador. La rama de Markov mezcla su fila de bigramas con un retroceso por artista/género a través de un peso de confianza $\text{trust} = n_u / (n_u + 8)$, donde n_u es el soporte de bigramas de entrenamiento del último ítem del prefijo de la consulta. Con $n_u = 0$ la confianza es cero y la rama es **puro retroceso**: no lleva ninguna evidencia a nivel de pista. Pero el normalizador de candidatos del blend es *invariante a escala* por construcción — lleva el vector de puntuaciones de cada rama a varianza unitaria para que tres ramas en escalas muy distintas sean comparables — así que el retroceso sin evidencia se re-infla y habla con un voto completo de un tercio de todos modos. En la partición canónica eso ocurre en 795 de 1431 **consultas de prueba**, el 55,6 %. La intervención consiste en hacer que

la rama se *abstenga* con $n_u = 0$ y renormalizar el divisor de tres ramas a dos. Nada se aprende; la condición es un conteo del lado de entrenamiento. Esa es exactamente la tercera categoría que la trampa registrada del combinador aprendido no cubría, y la descomposición por bucket de más abajo es una prueba mecánica de que ningún peso global estático podía encontrar el efecto: quitar la rama globalmente es un empate de $-0,0070$, porque la ganancia de soporte cero y la pérdida del bucket caliente se cancelan.

Diseño y la compuerta previa. Seis runs en el hub, todos **seq-blend** desde la definición del campeón, con los controles **re-entrenados en este lote** en lugar de sustituidos del archivo, de modo que toda comparación pareada esté igualada en código a una sola generación. Dos particiones: la canónica **seq-20260715-131139** y la disjunta de retención anterior **seq-20260718-211238** (64 % frío, n_{test} 1431). El alto duro pre-registrado era que el control sin compuerta tenía que reproducir **recall@10** 0,21174, exactamente 303 de 1431, probando que el nuevo indicador dejaba al campeón idéntico bit a bit. **Lo hizo, hasta el último dígito** (0,21174004192872117).

Resultados. La Tabla 39 es el lote, la Tabla 40 la estadística pareada y la Tabla 41 la descomposición que sostiene el argumento. La Figura 31 dibuja ambas.




Figura 31: **Izquierda:** la descomposición por bucket sobre los tres pares control/rama (**ds1** canónica, **ds2** la segunda partición con 64% de fríos, **ds1 $\lambda 0.7$** el mismo par canónico bajo un re-ordenamiento MMR). El efecto entero se sitúa en el bucket de soporte cero; en ambos buckets cálidos las listas top- k de las ramas son idénticas byte a byte, y por eso un peso global de rama no puede expresar demostrablemente esta intervención. **Derecha:** el mismo resultado en el plano recall $\times$ corona. MMR por sí solo (azul) es una palanca *con precio* en el campeón: compra corona y pierde recall con el IC bajo cero. La compuerta (verde) compra *ambos*. Compuestas, compuerta+MMR aterriza en el recall del campeón ($\Delta +0,00140$, abarcando) con 3,6× su holistiness, así que la compuerta cambia el nivel de MMR en el campeón de CON PRECIO a GRATIS.

Interpretación. El defecto es real, pertenece al normalizador y vale 29 aciertos. La invariancia a escala es exactamente lo que hace robusto al z-blend frente a ramas en escalas inconmensurables, y exactamente lo que destruye su *confianza*. Una rama de Markov que nunca ha visto la pista actual emite un puro retroceso por artista/género; el normalizador lo re-infla a la misma huella que una GRU que sí ha modelado el prefijo, y el blend promedia las dos como

iguales. Apagar ese tercio del voto donde está desinformado convierte 43 fallos en aciertos y 14 aciertos en fallos — neto +29, +9,6 % relativo, sobre el mejor modelo del registro. `recall@10` 0,23201 (332 de 1431) es **la mejor cifra de recall de este documento**, con el IC pareado sobre cero en dos particiones disjuntas y MRR al alza en ambas. Para escala: el margen de coronación del propio campeón sobre la corona previa fue +0,0259 en la canónica y +0,0426 en la segunda; esta compuerta añade +0,0203 / +0,0196 *sobre eso*, sin costo de entrenamiento adicional.

La compuerta es además una palanca de corona, lo que no se predijo. ΔH está sobre cero en las tres comparaciones pareadas, y las facetas dicen por qué: abstenerse mata la componente de *eco de bigrama* de la recomendación. La concentración de artista cae 0,69165→0,59821 y la adyacencia 0,60971→0,57477 — la lista deja de repetir un artista — mientras `mood_coh sube` 0,39822→0,46226 y `music@10` sube 0,45379→0,49319. Los cuatro factores de corona se mueven en la dirección correcta a la vez. Es la primera palanca del registro que des-eageriza al campeón *sin* pagar en coherencia de ánimo, y resuelve el doble pago exacto que la Sección 18 identificó como estructural: allí el des-eagering era un re-ordenamiento peleando contra las puntuaciones del propio modelo, así que alejarse del artista semilla también sacaba al blend del vecindario de ánimo del prefijo. Aquí el des-eagering es la retirada de un voto que no tenía derecho a emitirse.

Compuerta y MMR son aditivos, no sustitutivos, y su composición es el titular para la tabla de corona. El Δ de la compuerta sola (+0,02027) y el de la compuerta bajo $\lambda 0,7$ (+0,01957) son indistinguibles, y los buckets dicen por qué: MMR re-ordena la cabeza de una lista puntuada, la compuerta cambia qué lista se puntúa, y actúan sobre partes disjuntas de la tubería. Por sí solo, MMR $\lambda 0,7$ en el campeón es NIVEL-2 CON PRECIO (−0,01817 de recall, IC bajo cero). Añádase la compuerta y el costo de recall se paga exactamente: A3 es +0,00140 [−0,01188, +0,01468], un empate estadístico con el campeón, con H 0,030980 — 3,6× el 0,008603 del campeón, cómodamente sobre el umbral obligatorio de recall 0,108. En la tabla de corona eso se sitúa en el **puesto 2**, solo detrás de la GRU única a $\lambda 0,7$, que anota su 0,034171 con un recall de 0,11461: A3 entrega el 96 % de la corona del líder incumbente con 1,86× su recall.

La cautela honesta, y por qué la estructura fuera de muestra la redime. El memorándum cribó diez variantes de compuerta sobre el conjunto de prueba, así que su +0,02027 archivado era optimista por selección y no podía ser evidencia. Cuatro cosas lo redimen aquí: el efecto se reproduce en una *segunda partición disjunta con 64 % de fríos sobre la que no se cribó*, dentro de 0,0007 de la cifra canónica; se reproduce bajo una tercera condición ($\lambda 0,7$) que tampoco se cribó; cuatro variantes mecánicamente relacionadas del memorándum caen todas en 0,019 a 0,020, así que el cribado medía una meseta y no seleccionaba un rincón afortunado; y los buckets cálidos no se mueven ni un acierto, que es una predicción *estructural* del mecanismo y no un resultado ajustado. Queda un riesgo residual: la *frontera* de $n_u = 0$ misma se eligió con conocimiento del conjunto de prueba. La versión sin frontera — escalar la rama por `trust` *antes* de normalizar en lugar de abstenerse en duro — es el seguimiento principal, y es estrictamente más general. Nada de esto es tampoco una casualidad de la tasa de fríos de una partición: la segunda es 64 % fría, su bucket de soporte cero crece al 62,3 % de las consultas mientras la ganancia por consulta se encoge ligeramente, y el Δ neto sale casi idéntico. El valor de la palanca escala con cuánta de la distribución de consultas carece de evidencia de bigramas, que es la mayoría en cualquier partición de este corpus.

Gobernanza, y un hallazgo de infraestructura que casi se comió el resultado. Nada se promocionó, registró ni etiquetó; por frontera de diseño esta campaña lleva solo una *recomendación* de promoción, y la fila de tabla en la Tabla 16 está etiquetada en consecuencia. El recálculo determinista de los doce mejores por *holisticness* del servidor auto-promocionó no obstante cuatro

runs del lote, lo cual es comportamiento del servidor y no una acción de campaña, y dejó el grupo necesitando re-curación. Por separado: el worker remoto de entrenamiento estaba vivo con un **checkout obsoleto que contenía cero apariciones del nuevo indicador**. Si alguna rama con compuerta se hubiera despachado allí habría ejecutado la ruta *sin compuerta* y habría devuelto silenciosamente un nulo — la trampa registrada de que «el checkout remoto puede divergir en silencio», en su peor forma, porque el fallo es un número equivocado y no un error. No pudo ocurrir aquí solo porque el despacho remoto es opt-in y todos los runs del lote se publicaron sin él (confirmado por un marcador de no-reclamado en los seis). Hasta que el checkout se refresque, cualquier run `seq-blend` en cola ignora la compuerta en silencio.

Enmiendas al registro. Dos, ambas de estrechamiento y no de anulación. **(1)** La trampa del combinador aprendido debería prohibir la *fusión aprendida a nivel de puntuación* y no el *compuertado por evidencia por consulta*; el nulo oráculo previo y esta victoria de +0,020 son ambos verdaderos y se reconcilian con la descomposición por bucket, ya que un escalar global estático no puede expresar una compuerta cuyo signo se invierte con n_u . **(2)** El borrado de la *confianza* por rama que hace el normalizador es un defecto **general**, del cual el retroceso de soporte cero de la rama de Markov es una instancia. Cualquier rama con una noción dependiente de la consulta de «aquí no tengo evidencia» queda mal ponderada igual, y las ramas de contenido y de GRU no se han auditado para ello. *Fuente: 2026-07-27c-nexttrack-markov-gate-confirm.md.*

22. Pista siguiente: el regularizador de eagerness a un margen calibrado: refutado, con mecanismo

Motivación. La Sección 14 dejó `eager_beta` — la única palanca de des-eagering *en tiempo de entrenamiento* del repositorio — registrada como «un mando débil, no recomendado». Ese veredicto merecía una re-prueba, porque la sonda que lo respaldaba usó un margen de cero a una dosis que valía entre el 1 % y el 3 % de la función de pérdida. Esta campaña preguntó si la palanca funciona cuando el margen se coloca en la *cola derecha* medida de la distribución de cosenos de transición a 15 a 60× esa dosis. Lo que estaba en juego era la despleabilidad: en ese momento `mmr_lambda` entraba solo por la ruta de evaluación y nunca llegaba al servicio, así que el regularizador de entrenamiento era el único candidato anti-eager que podía llegar a producción.

El diseño se escribió para que un nulo siguiera siendo informativo. La métrica primaria pre-registrada fue el Δ pareado de `artist_conc@10` contra un control del mismo lote, con `holistic-ness@10 degradada` explícitamente a secundaria porque en el punto de operación $\partial H / \partial \text{music@10} = +0,2062$ frente a $\partial H / \partial \text{eager} = -0,0378$ — una razón de 5,46× que habría puntuado un des-eagering *exitoso* como aproximadamente cero. Se pre-registró un umbral de relevancia en dos partes: `music@10 absoluto` $\geq 0,4300$ y un límite inferior del $\Delta \text{music@10}$ pareado por encima de $-0,030$. Ocho runs de `seq-dualgru` sobre la partición canónica `seq-20260715-131139`, todos remotos, 60 min de cómputo, ninguno fallido. La compuerta de identidad bit a bit pasó con exactamente 170 aciertos y la concentración reconstruida coincidiendo con la rama registrada a 15 decimales, y se pre-registró una compuerta de penalización-activa como detector de fallo silencioso: **pasó en tres ramas y FALLÓ — reportando la penalización inerte — en cuatro**, que es el resultado de la campaña.

Resultados. La Tabla 42 es el lote y la Tabla 43 la estadística pareada. La Figura 32 muestra el mecanismo.




Figura 32: **Izquierda:** el resultado central de la campaña. La penalización realizada del hinge en la inicialización, reconstruida a partir de la inflación de la pérdida en la época 1 con inicialización compartida (semilla idéntica, así que inicialización y orden de lotes idénticos). Los márgenes se calibraron desde el coseno de transición *ítem*→*ítem* (mediana 0,262, p75 0,584, p90 0,830), pero la penalización actúa sobre *predicción*→*actual*, cuyo techo a lo largo del entrenamiento se sitúa entre 0,5843 y 0,70: con $m \geq 0,5843$ la cantidad penalizada nunca entra en el soporte del hinge y la traza de pérdida es idéntica bit a bit a la del control en las 14 épocas, con β hasta el tope del esquema. **Derecha:** donde el mando *sí* dispara, eagerness y relevancia son el mismo mecanismo. Empujar la predicción lejos del latente de la pista actual la empuja también fuera de la región donde vive la verdadera pista siguiente, así que no hay ventana entre un des-eagerness real y romper el umbral de relevancia. La línea de trazo y punto marca el comparador gratuito ya registrado que ninguna rama de aquí igualó dentro del umbral.

Interpretación. La refutación es expresiva, no de dosis, y ese es el hallazgo completo: **la calibración midió la distribución equivocada.** Los márgenes se extrajeron de $\cos(x_t, x_{t+1})$ — cuán separadas están dos pistas reproducidas consecutivamente — pero el hinge actúa sobre $\cos(\text{pred}_t, x_t)$, cuán cerca queda la *predicción* del modelo de la pista actual. Esas distribuciones no son comparables. Reconstruir el hinge desde la inflación de la pérdida en la época 1 sitúa el techo de la cantidad penalizada entre 0,5843 y 0,70, así que p75 y p90 de la distribución de transiciones reales quedan *fuera del soporte de la cantidad que se penaliza*, y las ramas B3 y B4 reprodujeron la pérdida del control a 16 cifras significativas en cada una de 14 épocas. La cobertura del diseño — que la penalización realizada *excedería* su valor nominal — queda empíricamente invertida por órdenes de magnitud. La razón es estructural: una predicción entrenada con InfoNCE es un *promedio cercano cubierto* sobre muchas continuaciones plausibles, así que su coseno absoluto a cualquier ítem individual está acotado bajo. **La eagerness es una propiedad de ordenamiento** — si los vecinos de la pista actual ocupan los primeros puestos — y un hinge sobre un coseno absoluto no puede expresarla.

Donde el mando *sí* dispara, eagerness y relevancia resultan ser el mismo mecanismo. Con $m = 0$ la palanca funciona espectacularmente sobre la faceta — A2 recorta la concentración 0,371→0,134 y lleva *ild* a 0,676 — mientras *music@10* se derrumba a 0,358 y el *recall* a 20 de 1431. No hay ventana de separación: el 27 % de las transiciones reales tiene coseno negativo,

así que empujar la predicción lejos del latente de la pista actual la empuja también fuera de la región donde vive la verdadera pista siguiente, y `mood_coh` también se derrumba (0,480→0,222). Ya con $\beta = 3$ se rompe el umbral absoluto de relevancia. El modo de fallo pre-registrado se disparó exactamente como estaba escrito.

El resultado previo queda afinado en lugar de retirado, y la banda usable queda identificada. La sonda del 2026-07-22 con $\beta \leq 0,2$, $m = 0$ reportó «débil» — correcto en banda, equivocado en interpretación. Ese ajuste queda justo *por debajo* del umbral de destrucción, y con $\beta = 3$ el mismo ajuste es un destructor de relevancia. Todo el rango dinámico usable con $m = 0$ está por tanto entre $\beta = 0,2$ y $\beta = 3$, un factor de 15, sin explorar, acotado arriba por la degeneración y abajo por la nulidad de efecto. La escalera de dosis ejecutada aquí **no tenía poca potencia; apuntaba más allá del blanco.**

Dos resultados de segundo orden que conviene conservar. Primero, degradar H a secundaria fue portante: A2 tiene con mucho las mejores facetas y el H *peor* (0,003569), porque el factor de anclaje la aniquila exactamente como predecía la razón de derivadas de $5,46\times$. Si H hubiera sido primaria, esta campaña se habría leído como un nulo plano en lugar de una frontera cartografiada. Segundo, el des-eagering real más barato del registro sigue siendo un ajuste de *arquitectura* y no este mando: el comparador gratuito ya registrado con `fusion_layers = 1` da Δ concentración $-0,051$ a un costo de recall de $-0,016$, y ninguna rama de aquí igualó eso dentro del umbral de relevancia — las ramas que respetan el umbral entregaron entre $-0,003$ y $+0,0002$, y las que superaron $-0,051$ pagaron 4 a $8\times$ el recall.

Por qué no se ejecutaron las fases posteriores aprobadas. Las tres estaban condicionadas a una victoria en la fase A, y no la hay. Las ramas de la fase C estaban además definidas *por referencia* al margen y β de la ganadora, así que sin ganadora quedan indefinidas; aplicada literalmente a las ramas que pasaron los umbrales, la regla de selección habría gastado tres runs transfiriendo un ajuste *demostrablemente inerte* a otra familia. El ejecutor se detuvo en lugar de improvisar, que es el resultado correcto: el siguiente paso es un diseño re-apuntado, no la fase C aprobada. Concretamente, re-especificar la penalización en lugar de re-ajustarla — un hinge sobre una cantidad *de ordenamiento* como $\cos(\text{pred}, x_t) - \cos(\text{pred}, x_{t+1})$, o un término explícito de masa del mismo artista sobre el top- k — y, por eliminación, hacer que el re-ordenamiento en tiempo de evaluación llegue a la ruta de servicio, ya que con la palanca de entrenamiento refutada la única palanca que funcionaba era en ese momento una que la ruta de servicio no podía reproducir. Esa última observación es sobre lo que actúa la sección siguiente. *Fuente: 2026-07-30-eager-margin-calibrated-refutation.md.*

23. Pista siguiente: el tope duro por artista y la segunda superficie de evaluación

Motivación. Dos palancas anti-eager *blandas* habían sido refutadas el día anterior. El regularizador en tiempo de entrenamiento está mal especificado (Sección 22): se apoya en un coseno absoluto que una predicción InfoNCE cubierta nunca lleva por encima de $\sim 0,6$, mientras la eagerness es una propiedad *de ordenamiento*. El re-ordenamiento MMR en tiempo de evaluación es real (Sección 18) pero se mide **inerte en el caso patológico**: en una playlist real del usuario el modelo ordena 59 de sus 60 candidatos principales como un solo artista y el siguiente artista aparece por primera vez en el **puesto 75**, mientras todo el presupuesto de diversidad de MMR allí vale $0,3 \times 0,26 \approx 0,078$ de puntuación normalizada — ni de lejos suficiente para pagar una caída de relevancia de 70 puestos. Los dos fallos comparten un mecanismo: **una penalización**

blanda en el espacio de puntuación pierde ante un gradiente de relevancia empinado. La palanca probada aquí no compite en puntuación en absoluto. Un tope *duro* por artista sobre el top- k **no puede ser superado en puntuación** — la misma propiedad en la que ya se apoyaba el enfriamiento de artista del recorrido — y es la primera palanca de des-eagering de este proyecto que funciona.

La segunda superficie de evaluación, en breve. Cada número de pista siguiente de las secciones anteriores es un top-10 de *un solo disparo*: puntuar el catálogo una vez desde un prefijo de sesión retenido y buscar la siguiente pista distinta. El escaparate desplegado, en cambio, sirve una *caminata autorregresiva* — añade su propia predicción al prefijo y vuelve a dar un paso, veinte veces — y una serie de pasos individualmente legales puede terminar en una región completamente distinta del espacio latente mientras cada paso por separado parece correcto. De hecho la deriva es invisible *por construcción* en la superficie de un solo disparo, porque la faceta `mood_coh` de `holisticness@10` mide el coseno de cada candidato al centroide del *prefijo*, que en una caminata viaja con el modelo. Una línea de medición separada — consolidada por completo en el documento compañero de pista siguiente y anclada en las propias 73 632 transiciones consecutivas reales del usuario, con un coseno de paso mediano de 0,261 y el 27,0 % de los pasos *negativos* — añadió por tanto cuatro métricas de nivel de caminata: **vibe** (coseno medio de cada pista generada al centroide *fijo* de la semilla: ¿el recorrido sostiene su ánimo?), **stride_err** ($|\text{coseno de paso mediano} - 0,261|$, mejor cuanto más bajo: ¿se mueve como el oyente al que imita?), **drift** (desplazamiento al final del recorrido, mejor cuanto más cerca de cero), **genres** (géneros distintos visitados, contados como *crédito*) y **ground** (un umbral de degeneración: concordancia graduada con la continuación real). Dos controles deterministas en tiempo de recuperación ajustan la caminata sin tocar el modelo — un *ancla* de semilla a y un término de *zancada* s , uno tirando hacia un punto fijo y otro empujando desde el último punto — así que una configuración de caminata se escribe como una celda a/s . El motor desplegado es una GRU de torre doble que lee las vistas `latent` y `cummean` con una fusión puramente lineal, en la celda $a0,8/s0,5$; es la única *victoria* de arquitectura medida en este corpus, y ganó en la superficie de caminata después de que tres campañas refutaran a su familia en recall.

Implementación, y por qué se traslada donde MMR no puede. El tope se aplica al *ordenamiento*, después de MMR, tanto en la evaluación en tiempo de entrenamiento como en el ordenador de servicio, de modo que evaluación y servicio coinciden por construcción — lo que evita la clase de divergencia corregida ese mismo día. Está enhebrado en las cinco familias de predictor que lo declaran con un valor por defecto de «apagado», así que todo run y modelo preexistente es idéntico byte a byte. Es **de mejor esfuerzo y no absoluto** (verificado con pruebas unitarias): el barrido recorre todo el ordenamiento buscando artistas admisibles, pero donde el espacio de candidatos de un prefijo se agota las ranuras restantes se rellenan con ítems diferidos en lugar de devolver menos de k ; la identidad se mantiene cuando el tope está apagado o es $\geq k$, y los ítems de artista desconocido nunca se topan. Crucialmente no necesita vectores sónicos, así que a diferencia de MMR se traslada sin cambios a un cliente delgado — MMR exigiría enviar un dial de similitud de 48 MB frente al de ~ 6 MB ya horneado.

Resultados. La Tabla 44 es el tope en la superficie de un solo disparo, medido fuera de run: las puntuaciones se calculan una vez por modelo y se memoizan, así que cada rama de tope ve vectores de puntuación *idénticos bit a bit* y el emparejamiento es exacto y no meramente apareado. La Figura 33 dibuja el compromiso.

Interpretación. **music@10 sube, con el IC sobre cero, en todos los topes y en ambos modelos** (+0,0105 a +0,0230). Es el resultado más importante de la campaña y no se predijo: el




Figura 33: **Izquierda:** la concentración de artista se derrumba, 0,692→0,113 con tope 3 en el campeón con compuerta. **Centro:** el resultado que *no* se predijo — la relevancia graduada *sube*, con el IC pareado sobre cero en todos los topes y en ambos modelos, y se replica en la partición disjunta con 64% de fríos con +0,026. La preocupación pre-registrada era que un tope des-eagerizara degenerando en relleno genérico; ocurre lo contrario, porque los ítems promovidos desde el puesto 75 en adelante son *más* aptos musicalmente para la continuación real que las pistas del mismo artista que desplazan. **Derecha:** el precio, en el plano recall × corona. El tope tiene *precio*, no es gratis: compuerta + tope 3 cuesta 52 de 1431 aciertos exactos frente al statu quo desplegado, mientras aterrizas una holisticness@10 de generación 3 en torno al 40% por encima de la corona incumbente con 1,5× su recall. Todas las ramas superan el umbral de 155 aciertos, así que ninguna es una instancia de la patología de «maximizar holisticness prediciendo peor».

tope cambia relevancia literal por relevancia graduada. Solo el recall@10 exacto regresa. Con compuerta + tope 5 frente al statu quo desplegado, el recall cae 0,2117→0,1985 (−19 aciertos) mientras el MRR *sube* 0,1220→0,1311, la concentración cae 0,692→0,231, *il*d sube 0,406→0,580, mood_coh sube 0,398→0,414, music@10 sube 0,454→0,506 y holisticness@10 sube 0,0086→0,0401.

El tope no se paga con la ganancia de la compuerta, y hay que decirlo con claridad. La compuerta son +29 aciertos; el tope más suave cuesta −48 en el modelo con compuerta. Así que compuerta + tope es un neto de −52 aciertos frente al statu quo desplegado con tope 3. Quien le importe el recall exacto debe leer esto como un compromiso, no como una victoria gratuita; el objetivo declarado del proyecto es la holisticness de sesión, donde es una ganancia de 5,6×. Todas las ramas de tope superan el umbral de recall 0,108 (0,151 a 0,198), así que no son instancias de la patología que el umbral existe para rechazar.

El tope solo aprieta donde hay un problema. Sobre un top-10 ya variado es literalmente inocuo en todos los valores de tope. La comprobación puntual sobre tres playlists reales del usuario lo hace concreto, contando artistas distintos en el top-10: en una playlist que el campeón ya sirve con 8 artistas distintos, el tope no cambia *nada* en ningún valor. En la playlist patológica — el caso que derrotó a ambas palancas blandas de plano — pasa de 1 artista distinto a 5 con tope 3, es decir, de diez pistas consecutivas de un artista a un reparto genuino entre cinco. **Y repara exactamente la única regresión de la compuerta:** la compuerta sola lleva una playlist de 8 artistas distintos a 4 (concentración 0,044→0,467), y con tope 3 vuelve a 7 (0,089) y con tope 2 a 8 (0,044) — idéntico al campeón desplegado. La ganancia de precisión de la compuerta queda por

tanto disponible *sin* su costo de diversidad.

Confirmado por runs registrados y luego endurecido en una segunda partición. Tres runs registrados en la partición canónica, lanzados desde los hiperparámetros declarados en el registro del campeón con compuerta y variando solo el tope, reprodujeron **cada cifra reportada hasta el último dígito** (run-20260730-235524-0ec1d-seq-blend con el tope apagado, run-20260730-235524-93d38-seq-blend con tope 3, run-20260730-234635-a6252-seq-blend con tope 5), así que la medición fuera de run se traslada exactamente y la fontanería queda verificada de extremo a extremo. Cuatro runs más en la partición disjunta con 64 % de fríos seq-20260718-211238 probaron entonces dos piernas pre-registradas, *ambas* requeridas: Δ concentración $\leq -0,05$ con el IC bajo cero, *y* un límite inferior del Δ music@10 *sobre* cero — la relevancia graduada tenía que seguir *mejorando*, no meramente evitar el colapso. **Ambas se sostienen** con tope 3 (concentración $-0,52699$ $[-0,54546, -0,50825]$; music@10 $+0,02644$ $[+0,01919, +0,03368]$), con el costo de recall *menor* y la ganancia de relevancia *mayor* en la ventana más fría, y con la concentración absoluta con tope 3 a 0,008 de la cifra canónica. El mismo lote entregó una tercera reproducción independiente del efecto pareado de la compuerta de evidencia, coincidiendo exactamente con el $+0,01957$ registrado.

Tres cautelas, una de ellas una lección sobre umbrales. Primero, el umbral *absoluto* de music@10 $\geq 0,43$ de la partición canónica **no** se traslada: el control propio de esa partición se sitúa en 0,4295 sobre una ventana legítimamente más fría, así que pre-registrar la regla sobre el Δ pareado en lugar de sobre un umbral absoluto es la única razón por la que esto no se leyó como un falso fallo. **Derive los umbrales por línea base.** Segundo, la medición es solo con $k = 10$, y k interactúa con el tope: un tope *fijo* de 3 con $k = 50$ lleva la concentración a 0,021 — cinco veces más allá del punto de operación endurecido — y alcanza el puesto base p95 278, mientras escalar el tope para preservar la *proporción* alcanza solo p95 156 y mantiene la concentración en 0,118. Escalado es a la vez más suave con la relevancia y fiel a lo validado, y ambos son idénticos con $k = 10$; está implementado como el 30 % de las ranuras con un mínimo de 3, tanto en el cliente como en el ordenador del servidor, de modo que las dos rutas coinciden por construcción. Tercero, nada de esto se promocionó, se registró como campeón ni se desplegó, y la recomendación registrada es markov_gate con tope 3 como siguiente candidato de despliegue (el tope 5 como alternativa conservadora, cuyo MRR sigue por encima del actual). Una divergencia abierta entre evaluación y servicio a nivel de fila, documentada por separado, implica que la salida en producción será cercana a estos números pero no idéntica.

Dos hallazgos de ingeniería que generalizan. Primero, una compuerta de identidad bit a bit atrapó un *lanzamiento inválido*: el control inicial corrió contra un checkout remoto obsoleto que contenía cero apariciones de ninguno de los dos indicadores nuevos, así que ambos hiperparámetros se ignoraron en silencio y el run reportó las métricas del campeón *sin compuerta y sin tope* bajo hiperparámetros con compuerta — un número equivocado, no un error. La lección es más afilada que «resincronice el worker»: **calcule la suma de verificación de los archivos de predictor de la familia que se va a lanzar inmediatamente antes de publicar**, no en tiempo de diseño, porque la campaña anterior había verificado los archivos de *otras dos* familias. Segundo, el mismo incidente dejó una fila de run huérfana atascada en **running**, que ni el endpoint de parada ni el de borrado pueden limpiar (el primero solo rastrea runs locales, el segundo rechaza runs reclamados por un worker) — una brecha que conviene cerrar antes de que vuelva a ocurrir. Ambas palancas se portaron después a los dos clientes del escarapate como puro

post-procesado, sin reconstrucción de modelo, sin vectores nuevos y sin reentrenamiento, y con pruebas de paridad que fijan el ordenamiento portado contra la referencia de Python; en uno de los clientes el motor campeón resulta **degenerado sin tope** — treinta pistas de un solo artista sobre una semilla de rock argentino — así que allí el tope es portante y no cosmético. *Fuente: 2026-07-30c-artist-cap-measurement.md.*

24. Pista siguiente: topología de pila de etapas: la profundidad refutada en ambas superficies

Motivación. La pregunta del usuario fue directa: ¿una *pila* explícita de etapas de MLP por paso y etapas recurrentes supera a una GRU única, en un corpus donde cinco campañas de arquitectura consecutivas han devuelto nulos? Se especificaron cuatro disposiciones — **ann+gru+ann+gru**, **ann+gru+gru+ann**, **ann+gru+gru+gru**, **gru+gru+gru+gru** — más una quinta, **gru+ann+gru+gru**, elegida por el usuario para probar *por qué* un MLP líder perjudicaba con $N = 1$: la Sección 16 atribuía esa pérdida a que la rectificación de media onda destruye información de signo del prefijo que la transformación lineal de entrada compuertada de una GRU preserva, así que poner el MLP sobre un *estado oculto compuertado* en lugar de sobre PCA con signo crudo debería hacer desaparecer el daño. Es además la primera campaña de este arco juzgada en *dos* superficies por diseño y no a posteriori, y fija el estándar que hereda la campaña siguiente.

Diseño, y la prueba de equivalencia que hizo posible un control. Siete runs de un nuevo predictor, **seq-stack**, sobre la partición canónica **seq-20260715-131139** (1431 sesiones de prueba), 90 min de cómputo, cero fallos, cero runs de contingencia gastados. La capacidad se igualó en $\sim 1\,282\,000$ parámetros entre las cinco ramas de 4 etapas (dispersión mutua 0,445 %), y los siete conteos se re-verificaron instanciando el modelo en lugar de confiar en el diseño. Todo excepto la cadena de etapas y las anchuras se mantiene fijo: dropout 0,1, InfoNCE, τ 0,07, 40 épocas, paciencia 6, lr 0,001, lote 128, semilla 1337, MMR apagado, tope de artista apagado.

La identidad bit a bit con los 176 aciertos históricos de la familia *no está disponible* aquí y su ausencia no es un fallo: el entrenador re-siembra al entrar, así que entregarle un modelo pre-construido desfasa el flujo de dropout incluso cuando los pesos iniciales coinciden. La campaña se apoyó por tanto en una **prueba de equivalencia funcional** más un **control del mismo lote**, y todo veredicto se enuncia contra ese control. La prueba se ejecutó *antes* de la edición del registro y del reinicio del servidor, así que un fallo no habría costado nada: con **stages=["gru"]** el nuevo modelo calcula la misma función que la GRU única incumbente, con $\max |\Delta|$ **0.00e+00** en **forward** y en **predict_next** a longitudes de prefijo $T = 1, 2, 5, 17, 40$ y 394 944 parámetros en ambos lados. El control del mismo lote devolvió entonces 178 **de** 1431, dentro de la banda pre-registrada [155, 198] y a solo 2 aciertos de los 176 históricos — exactamente el pequeño desfase que predice el argumento de la re-siembra. Dos compuertas más importaron: la completitud de métricas fue verde en los siete runs (sin descarte de claves por imagen del worker del tipo que documenta la Sección 18), y el instrumento de caminata se verificó contra el motor desplegado, cuyos Δ **vibe** (−0,0033) y Δ **stride_err** (+0,0137) abarcan ambos cero contra el control recién entrenado. El arnés de caminata reprodujo además *las diez* medias registradas previamente de forma exacta y se mantuvo estable bit a bit al añadir ramas, que es lo que autoriza el emparejamiento entre invocaciones separadas.

Resultados, la superficie de un solo disparo. Tabla 45.

Ninguna rama cumple ninguna cláusula de victoria. Cada rama de 4 etapas pierde recall y holistichness por IC pareado, y las cinco quedan **por debajo del umbral absoluto obligatorio**

de recall 0,108 (0,0706 a 0,0860). Derivado por línea base a partir del propio music@10 del control, 0,45519, cada rama de 4 etapas queda 5,0 % a 8,4 % por debajo del umbral de relevancia también, así que ninguna es siquiera neutra en relevancia. Las pérdidas son 2,5 a 3,7× el semiancho medido: no es una cuestión de banda de ruido.

Resultados, la superficie de caminata. Tabla 46, en la celda primaria igualada a0,4/s0,3, pareada contra el control del mismo lote sobre las métricas de caminata de la Sección 23. *vibe* se reporta siempre con *stride_err* al lado, a zancada igualada, según la cautela permanente de que una ganancia de *vibe* comprada dando pasos más cortos no es una ganancia.

Cada rama de 4 etapas dispara la cláusula de refutación. D la dispara *dos veces*, fallando también el umbral de anclaje ($\Delta\text{ground} -0,0250 [-0,0474, -0,0048]$), y A pierde además variedad de género ($-1,200 [-2,125, -0,300]$). Ninguna rama se acerca a una cláusula de victoria. Dos comprobaciones de robustez cierran las vías de escape. Se corrió una **sonda de zancada** pre-registrada sobre $s \in \{0,2,0,3,0,4\}$ para las dos únicas ramas con algún movimiento direccional hacia una victoria de caminata, y *ambas alcanzan su máximo en s0,3 — la celda en la que ya se habían medido* (C: *vibe*/stride_err 0,586/0,183, 0,548/0,113, 0,517/0,153; E: 0,576/0,155, 0,540/0,109, 0,516/0,174); con s0,4 ambas pierden *vibe* con el IC bajo cero mientras *stride_err* empeora. Y la mejor rama se re-midió en la celda **desplegada** a0,8/s0,5, donde queda refutada otra vez ($\Delta\text{vibe} -0,0158 [-0,0267, -0,0059]$, $\Delta\text{stride_err}$ abarcando).




Figura 34: **Izquierda:** las cinco ramas de 4 etapas caen *por debajo* del umbral absoluto obligatorio de recall, mientras el control de capacidad 3,24× empata con el ancla — así que el daño es la profundidad, no la capacidad. Las barras de error son el IC bootstrap pareado contra el control del mismo lote, proyectado sobre la escala de aciertos. **Centro:** el número más interesante de la campaña. La rama B alcanza la *mejor* pérdida InfoNCE de validación del lote y recupera 55 aciertos menos que el control: el objetivo que entrena toda la familia y la calidad de recuperación del top-10 se desacoplan en profundidad, así que cualquier búsqueda de arquitectura que seleccione por pérdida de validación elegiría la rama equivocada. **Derecha:** el cierre en dos superficies. La lectura de caminata en la celda primaria igualada refuta las mismas cinco ramas que refuta la superficie de un solo disparo; el control de capacidad empata en ambas. El eje no falla meramente en cerrarse en una superficie: se cierra en dos.

Interpretación. El eje queda cerrado, y es el primer nulo de este arco que cierra en ambas superficies. Las cinco ramas de 4 etapas quedan refutadas por IC pareado en recall

de un solo disparo *y* en la caminata con la compuerta del instrumento en verde, y el control de capacidad es indistinguible en ambas. Es el sexto nulo consecutivo de arquitectura en este corpus *y*, a diferencia de los cinco anteriores, satisface la regla permanente de que un veredicto de un solo disparo no dice nada sobre la superficie que sirve el producto.

La hipótesis de mecanismo del usuario queda refutada, y ese es el hecho más reutilizable de aquí. La rama E puso el MLP sobre un *estado oculto compuertado* en lugar de sobre PCA con signo crudo, lo que según la historia del rectificador debería eliminar el daño. No lo hace: E alcanza 118 de 1431, empata con otras dos disposiciones, solo supera a la peor y no se acerca a los 178 del control. Así que la rectificación de media onda de la *entrada cruda* no es el mecanismo — lo que está mal sobrevive a mover el rectificador aguas abajo de una compuerta. Un run compró la refutación limpia de una historia plausible y fácil de creer.

El daño es la profundidad misma, y tres controles cierran las alternativas simultáneamente. No es la capacidad: el control de $3,24\times$ empata en ambas superficies. No es la regularización ni la parada temprana: *cada* rama de 4 etapas entrena *más* que el control (21 a 40 épocas contra 14) y dos de cinco alcanzan una pérdida de validación *menor*, así que la contingencia pre-autorizada por conteo de dropout falló en sus dos cláusulas de disparo y no se gastó — la aplicación cuádruple de dropout queda exculpada. Y no es el MLP: un MLP líder por paso en profundidad 4 es neutro en recall y *positivo* en *holisticness* contra la disposición puramente recurrente ($\Delta H +0,00291$, IC sobre cero). Lo que queda es la profundidad de la cadena recurrente, y su costo es grande: 55 a 77 aciertos de 1431.

Enmarcar supera a intercalar a capacidad idéntica bit a bit. *ann+gru+gru+ann* supera a *ann+gru+ann+gru* por $+0,01537$ de recall con el IC sobre cero *con el mismo conteo de parámetros por fórmula* — la comparación de topología con el control más estrecho que la campaña podía hacer. Interponer un MLP por paso *entre* dos recurrencias es peor que ponerlos por fuera, lo que es coherente con la lectura de profundidad: romper la cadena recurrente por el medio cuesta más que añadir profundidad en los extremos. Dos contrastes más son planos: el número de etapas recurrentes (2 frente a 3) abarca en recall, y la posición del rectificador no compra nada más allá de superar a la peor disposición.

Un MLP líder por paso no es perjudicial en profundidad 4, lo que estrecha en lugar de confirmar el resultado con $N = 1$. El «un ann líder es perjudicial» de la Sección 16 se midió con $N = 1$ contra una GRU única; en profundidad 4 la misma adición es gratuita o ligeramente buena. La trampa del pre-codificador debería acotarse al caso superficial.

El objetivo y la recuperación se desacoplan en profundidad, y esta es la instancia más nítida hasta ahora. La rama B logra la pérdida InfoNCE de validación *más baja* de todo el lote (6,5378 contra el 6,5832 del control) mientras recupera 55 **aciertos menos** (123 contra 178). Todo nulo previo de arquitectura en este corpus era coherente con «la maquinaria extra no hace nada»; este muestra que la maquinaria extra hace algo medible a la pérdida y que es lo *equivocado*. La consecuencia operativa es contundente: seleccione por recall@10 y por la caminata, nunca por el objetivo de entrenamiento. Una cautela viaja con ello: B llegó al tope de 40 épocas sin que la paciencia se disparara, así que su recall es un *límite inferior*, y una re-ejecución más larga es la prueba limpia del desacoplamiento (la predicción es una mejor pérdida de validación y no un mejor recall).

Las facetas de eagerness mejoran monótonamente a medida que las ramas empeoran, y los umbrales lo atraparon. Cada rama de 4 etapas des-eageriza sustancialmente (concentración $0,359 \rightarrow 0,263$ a $0,318$) y eleva *ild*; bajo una lectura ingenua con *holisticness* como primaria algunas parecerían interesantes. Todas mueren por el umbral absoluto de recall y por el umbral de relevancia por línea base — el mismo mecanismo que ya ha salvado cuatro campañas.

Nótese que la cifra *absoluta* canónica de relevancia 0,43 habría dejado pasar a varias de estas ramas, así que el umbral debe derivarse por línea base.

Dos subproductos, y la línea de gobernanza. Un pariente con $N = 2$ cerrado previamente — una torre doble con un pre-MLP en un lado, cerrada por un empate de recall de un solo disparo — se evaluó en la caminata por primera vez aquí y queda **refutado en la caminata** ($\Delta\text{vibe} -0,0255 [-0,0432, -0,0096]$), siendo su única ganancia real menos deriva. Es la misma firma que mostró antes una variante de celda recurrente — mejor zancada y deriva, peor vibe — lo que ahora parece una propiedad general de añadir maquinaria pre-recurrencia y no algo específico de ninguna de las dos ramas. Segundo, la métrica de anclaje volvió a discriminar casi nada, separando una rama de nueve, coherentemente con su aritmética registrada (rango entre ramas 0,0060 frente a una desviación típica por sesión de 0,1417, que necesitaría ~ 2140 sesiones): es un umbral que atrapa degeneración, no una métrica de ordenamiento, y solo se usó así. Nada se promocionó como campeón, nada se registró como reclamo de corona y nada se desplegó; las siete ramas se promocionaron *solo para medición*, cada una con la nota literal «promovida para habilitar la evaluación de caminata; no es un reclamo de corona», lo que inundó el grupo de mejores modelos y se entregó al agente de curación.

Dos hallazgos de proceso que conviene conservar. Primero, la compuerta de suma de verificación de predictores se disparó *sobre un archivo que el diseño no nombró para copiar* — listaba un módulo a copiar y un módulo compartido solo a *verificar*, y la verificación falló. La divergencia resultó inerte para este lote, pero eso es un juicio *a posteriori* que requirió leer el diff; la regla que lo atrapó es la que conviene conservar. **Verifique la suma de cada archivo del cierre de importación de la familia, no solo de los que copió.** Segundo, el cuerpo de lanzamiento aprobado fue rechazado por el bloque de registro aprobado: el JSON del diseño enviaba seis hiperparámetros que el bloque no declara, así que las primeras publicaciones fallaron sin más. Se resolvió eliminando las seis claves *tras probar que eliminarlas es inocuo* — los valores por defecto del predictor suministran exactamente esos valores y el diccionario resuelto de hiperparámetros es idéntico en ambos casos, verificado por comparación directa — y el bloque de registro se dejó exactamente como se aprobó. *Fuente: 2026-08-01-stage-stack-topology.md.*

25. Pista siguiente: bancos de torres paralelas cerrados en ambas superficies

Esta es la séptima campaña de arquitectura sobre el corpus de pista siguiente y la que cierra la rama *paralela* del eje. Es la segunda campaña consolidada aquí juzgada en **ambas** superficies de evaluación, según el estándar que fijó la Sección 24, así que necesita un párrafo de orientación antes de los resultados.

La segunda superficie, en breve. Todos los números de pista siguiente de las secciones anteriores son un top-10 *de un disparo*: se puntúa el catálogo una vez desde un prefijo de sesión y se busca la pista siguiente held-out. El showcase despachado, en cambio, sirve una *caminata* autorregresiva — añade su propia predicción al prefijo y vuelve a dar un paso, veinte veces — y una serie de pasos individualmente legales puede acabar en una región del espacio latente completamente distinta aunque cada paso por separado parezca correcto. Una línea de medición aparte (introducida en la Sección 23 y consolidada por completo en el documento complementario de

pista siguiente, y anclada en las 73 632 transiciones consecutivas reales del propio usuario, cuyo coseno de paso mediano es 0,261) añadió por eso cuatro métricas a nivel de caminata: **vibe** (coseno medio de cada pista generada al centroide de la *semilla*: ¿sostiene el viaje su mood?), **stride_err** ($|\text{coseno de paso mediano} - 0,261|$, mejor cuanto más bajo: ¿se mueve como la persona a la que imita?), **drift** (desplazamiento al final del viaje, mejor cuanto más cerca de cero), **genres** (géneros distintos visitados) y **ground** (un suelo de degeneración: coincidencia con la continuación real). Dos controles deterministas en tiempo de recuperación ajustan la caminata sin tocar el modelo — un *ancla* de semilla a y un término de *zancada* s —, así que una configuración de caminata se escribe como una celda a/s . El motor desplegado es una GRU de torre doble que lee las vistas **latent** y **cummean** con fusión puramente lineal (**fusion_layers** = 0) en la celda $a0,8/s0,5$; es la única *victoria* de arquitectura medida de este corpus, y ganó en la superficie de la caminata después de que tres campañas refutasen su familia en recall.

Motivación. Esa victoria vino con un mecanismo declarado: la torre lleva una **referencia fija que la recurrencia nunca sobrescribe**, que es lo que sostiene un mood. Un mecanismo de esa forma hace una predicción comprobable: debería ser *sensible a la dosis*. Si una torre de referencia fija compra un vibe sostenido más +1,5 géneros, entonces N torres — las suficientes sobre la vista **latent** cruda para sostener el suelo de recall y el resto sobre **cummean** — deberían comprar *más* de lo mismo. Esta campaña recorre esa curva de dosis, y es el seguimiento que esa propia victoria pedía.

El vehículo es un predictor nuevo, **seq-bank**: N torres GRU desnudas *paralelas* de una sola capa sobre vistas causales configurables, con sus estados ocultos por paso concatenados y leídos por **una única cabeza lineal**. Su decisión de diseño es colapsar el número de torres y el multiconjunto de vistas en un *único* hiperparámetro **views**, de modo que N no puede desincronizarse de las vistas. Lo que el predictor *no* puede expresar importa tanto como lo que puede: declara exactamente 15 hiperparámetros y ninguno de **fusion_layers**, **fusion_hidden**, **pre_hidden**, **pre_layers**, **layers**, **num_layers**, **arch**, **bidirectional**, **residual** o **eager_beta** está entre ellos. Todo mecanismo que las secciones anteriores ya han refutado — la cabeza de fusión MLP (Sección 15), el pre-codificador por paso (Sección 16), el regularizador anti-eager blando (Sección 14) — queda por tanto *estructuralmente inalcanzable* y no solo sin usar, y una guarda **parse_views** rechaza cualquier especificación sin una torre **latent**, lo que también pone fuera de alcance las patologías registradas de **delta/cummean** en 0,058 a 0,087.

Se pre-registraron dos hipótesis. La primaria es la hipótesis de *dosis* anterior. La sub-hipótesis independiente es el mecanismo que el barrido de torre doble ya había establecido: si la vista **latent** cruda *subsume* a sus hermanas, entonces N torres **latent** idénticas no compran nada, sea cual sea N .

Diseño. Diez ejecuciones sobre la partición canónica **seq-20260715-131139** (1431 sesiones de prueba, tasa de ítems fríos 0,5507), 84,2 min de cómputo, cero fallos. Todo salvo **views** / **hidden** / **dropout** queda fijo: **loss** InfoNCE, $\tau = 0,07$, 40 épocas, paciencia 6, lr 0,001, batch 128, semilla 1337, MMR apagado, tope por artista apagado. **La capacidad está igualada a $3,00\times$ la línea base h256** en todas las ramas de banco y en el control de GRU única C1 (h512), con los conteos re-verificados desde los artefactos en vez de confiados al diseño — **seq_bank** emite **n_params** en **metrics.json**, y la dispersión mutua entre las siete ramas a $3,00\times$ incluyendo C1 es del 0,405 %. La regla de decisión se escribió sobre ambas superficies antes del lanzamiento. En **S1** (recall@10 de un disparo) una victoria exige un Δ pareado por encima de cero contra *ambos*: el ancla h256 C0 *y* la C1 con parámetros igualados, sujeto a un suelo absoluto de recall ($\geq 0,108$, es decir 155 de 1431) y a un suelo de relevancia por línea base (el Δ music@10 pareado frente a C0 no puede

caer por debajo de cero). En **S2** (la caminata: 40 sesiones held-out $\times$ 20 pasos con tope por artista 1, pareadas contra la C0 *del mismo lote*) la celda primaria es $a0,4/s0,3$, y guardar una definición exige además **el mismo signo en la celda desplegada** $a0,8/s0,5$.

El instrumento se fijó antes de medir nada. Las diez puertas pre-registradas salieron en verde, y tres merecen constar porque hacen la comparación inusualmente estrecha. Una puerta de *equivalencia funcional* mostró que **seq-bank** es una generalización estricta de ambos incumbentes y no una familia nueva: con **views="latent"** reproduce **SeqNextLatent** y con **views="latent+latent"** reproduce el **DualTowerNextLatent** a **fusion_layers = 0**, con $\max|\Delta|$ **0.00e+00** tanto en **forward** como en **predict_next** para longitudes de prefijo $T = 1, 2, 5, 17, 40$ y conteos de parámetros idénticos en ambos lados; una comprobación adicional del flujo de entrenamiento igualó la pérdida de train y de validación por época hasta el último dígito a lo largo de tres épocas, con los diez tensores del state-dict a $\max|\Delta|$ **0.00e+00**. Las dos puertas de identidad bit a bit dieron entonces exacto: C0 reprodujo su **recall@10** registrado $0,12299091544374564 = 176$ de 1431 (una **décima** reproducción, con **music@10**, **H@10** y **MRR** coincidiendo hasta el último dígito) y R2 reprodujo la rama **latent/latent** $f0$ de torre doble en $0,1187980433263452 = 170$ de 1431, así que la banda de reserva del diseño nunca fue necesaria. Y el instrumento de caminata se contrastó contra el **gru.onnx** despachado: $\Delta\text{vibe} +0,0028$ y $\Delta\text{stride_err} +0,0005$ cruzan ambos el cero, así que los veredictos de S2 contra la C0 del lote no son un artefacto de la base.

Resultados, S1. La Tabla 47 es el lote. **Ninguna rama va en negrita como ganadora porque no hay ninguna:** ninguna rama logra siquiera la primera pata de la regla de victoria, las nueve ramas no-ancla empatan contra C0, y *cinco de las ocho ramas de banco pierden contra la GRU única con parámetros igualados C1 con el IC por debajo de cero*. Los dos suelos pasan en todas las ramas: la peor es V1 con 162 aciertos, lejos del suelo de 155, y el Δ de relevancia más negativo es el de V2, $-0,006109$, que cruza el cero.

El número más nítido del lote es un cero. B4 — cuatro torres h211 **latent** independientes, 1 187 700 parámetros — y C1 — una GRU h512, 1 182 912 parámetros — devuelven los **mismos** 186 **aciertos de** 1431, con un Δ pareado de exactamente $0,000000$ $[-0,00839, +0,00839]$. Con un presupuesto igualado de $\sim 3,00\times$, *la topología y la anchura son intercambiables en este corpus*: lo que descubren cuatro torres con inicializaciones aleatorias distintas, una única recurrencia más ancha ya lo tenía. La Figura 35 (izquierda) dibuja el eje N a capacidad igualada, y la línea que pasa por $186/170/172/186$ es plana dentro de la propia resolución medida de la partición (Sección 17.1).

Es además la demostración más limpia del registro de *por qué la pata de control con parámetros igualados es obligatoria*. Leídos solo contra el ancla h256, los +10 aciertos de B4 habrían parecido una victoria de topología y las cinco ramas que pierden contra C1 habrían pasado todas por empates: el ancla no puede distinguir «el banco ayudó» de «los parámetros extra ayudaron, y el banco los gastó peor de lo que lo habría hecho la anchura». La pata C1 hace exactamente eso, y es lo que convierte un lote de nueve empates en un cierre. Nótese también lo que la planitud cuesta en la dirección *contraria*: los +10 aciertos de C1 sobre C0 tampoco son significativos ($+0,006988$ $[-0,00210, +0,01607]$), el **séptimo** empate de anchura con parámetros igualados del registro, de modo que la campaña tampoco puede reclamar h512 como una mejora pese a ser el mayor conteo de aciertos de GRU única medido (186 frente a los 179 de h454). Los puntos de anchura de GRU única sobre PCA-192 se leen ahora $h256 \rightarrow 176$, $h297 \rightarrow 162$, $h425 \rightarrow 173$, $h454 \rightarrow 179$, $h512 \rightarrow 186$, $h537 \rightarrow 174$: no monótonos, con un rango de $0,0168$ y sin tendencia.

Resultados, S2. La Tabla 48 es la caminata. Dos ramas — B2 (**latent+latent** h334) y V3 (**latent+cummean+cummean**) — alcanzaron un **TRADE** genuino en la celda primaria, comprando

cada una una mejora de deriva con el IC por encima de cero y sosteniendo el vibe. Ambas **voltean** en la celda desplegada: la ganancia de deriva se evapora en un cruce del cero y el **vibe** — la línea no negociable — se va por debajo de cero en las dos. Bajo la regla pre-acordada, **no se guardó ninguna definición**.




Figura 35: El eje de bancos de torres paralelas, cerrado en ambas superficies. **Izquierda:** el eje N a capacidad igualada ($\sim 3,00\times$ la línea base h256). Las barras de error son el IC bootstrap pareado contra C0 proyectado a la escala de aciertos; la banda gris es la resolución medida de la partición ($\pm 0,0124$ recall@10 = $\pm 17,7$ aciertos, Figura 29), y todas las ramas caen dentro. Cuatro torres h211 (B4) y una GRU h512 (C1) devuelven los mismos 186 aciertos, con Δ pareado 0,000000. **Centro:** las dos ramas que lograron un TRADE de caminata en la celda primaria voltean en la celda desplegada: la ganancia de deriva que compró el TRADE decae hasta cruzar el cero mientras el **vibe** se va por debajo. Los marcadores grises son estimaciones puntuales cuyo IC cruza el cero (el informe fuente solo cita límites para los intervalos que no lo cruzan). **Derecha:** el único resultado positivo de la campaña, y no es sobre topología — con parámetros idénticos byte a byte (789 696 en ambos, `model.pt` de 3 162 277 bytes en ambos) el dropout 0,1 supera al dropout 0,0, con el IC por encima de cero.

Interpretación. La hipótesis de dosis queda refutada, y falla en la dirección opuesta a la predicción. Añadir torres **cummean** de referencia fija no compró más de lo que compró $N = 2$: destruyó la caminata de forma monótona. Ordenadas por Δ vibe en la celda primaria, la secuencia es B4/B2 (todo-latent, ≈ 0) > B3 > V3 (una **cummean**, $-0,0094$) > V2 ($-0,0144$, IC por debajo de cero) > V1 ($-0,0174$, IC por debajo de cero), y el mismo orden se mantiene en S1, donde las tres ramas con **cummean** ocupan los *tres últimos* puestos (162, 166, 170 aciertos) y son las únicas cuyas estimaciones puntuales de Δ music@10 pasan de $-0,005$. La ironía merece decirse sin rodeos: **la torre añadida para sostener un mood es la torre que empeoró la medida de mood de la caminata**; las dos únicas ramas cuyo **vibe** queda refutado sin paliativos son las dos que cargan más **cummean**. Haga lo que haga el motor desplegado **latent/cummean** con $N = 2$, no es «más **cummean** es más sostén del mood», y la lectura estructural que motivó el diseño no sobrevive a ser dosificada.

La sub-hipótesis queda confirmada y se extiende limpiamente de $N = 2$ a $N = 4$. B2 (170), B3 (172) y B4 (186) cruzan todas el cero frente a C0 y no muestran tendencia distinguible del ruido de anchura. Es el mismo mecanismo que encontró el barrido de torre doble (Sección 15)

— la vista `latent` cruda subsume a sus hermanas — ahora medido en tres recuentos de torres en lugar de dos, que es lo que exige cerrar un eje por dosis y no por un único punto.

El único hallazgo positivo es un subproducto del nulo, y aterriza sobre el motor desplegado. D2 y R2 difieren en *un* hiperparámetro: los parámetros son idénticos byte a byte (789 696 en ambos, `model.pt` de 3 162 277 bytes en ambos), solo se mueve `dropout`, y el $\Delta\text{recall}@10$ es $+0,004892$ [$+0,000699$, $+0,009783$], **IC por encima de cero:** el dropout 0,1 *supera* al dropout 0,0 (177 frente a 170 aciertos). Leído con cuidado, esto no revierte el resultado «`fusion_layers = 0` supera a `fusion_layers = 1`» confirmado tres veces en el registro; hace algo más incómodo. El dropout entra en `seq_dualgru` solo por un pre-MLP, un hueco entre capas o el MLP de fusión, y con `fusion_layers = 0`, una capa y sin pre-codificador *los tres están ausentes*: la ruta f0 construye **cero** módulos de dropout. Así que toda rama f0 del registro, **incluido el motor desplegado del showcase**, entrenó sub-regularizada y dejaba $\approx +0,005$ de recall sobre la mesa; y los tres huecos f0-vs-f1 registrados ($+0,016$ / $+0,020$ / $+0,0266$, Tabla 34) se midieron contra un f1 que *sí* tenía la regularización que le faltaba a su comparador f0, de modo que no son comparables en igualdad de condiciones y la ventaja topológica real de f0 es, si acaso, *mayor* que la registrada. Donde esas tres cifras se citen como mediciones limpias de topología deben re-enunciarse como no igualmente-regularizadas. De aquí sale el seguimiento más barato de todo el tablero: reentrenar el motor desplegado con `dropout = 0,1` y releer ambas superficies — una mejora gratuita, no una apuesta de arquitectura.

La disociación con la pérdida de validación recibe una cuarta confirmación, ahora como correlación de rangos (Figura 36). En las diez ramas, Spearman(mejor InfoNCE de validación, aciertos) = $-0,2954$, $p = 0,407$: ningún poder predictivo utilizable y, si acaso, con el signo equivocado. Los casos nítidos son brutales: B4 y B2 difieren en 0,0003 de pérdida de validación y en 16 aciertos; V1 tiene la cuarta mejor pérdida de validación del lote y el *peor* conteo de aciertos; C0 tiene la *peor* pérdida de validación y supera a seis de las ocho ramas de banco; y R2 alcanza mejor pérdida de validación que D2 recuperando siete aciertos menos, lo que hace de la disociación y del hallazgo del dropout dos caras de la misma moneda. La regla de decisión nunca leyó la pérdida de validación, y esto es por qué.

Los dos TRADE de caminata eran locales a la celda, lo cual es un resultado metodológico por derecho propio. B2 y V3 lograron cada una un Δdrift real por encima de cero en $a0,4/s0,3$ con el vibe sostenido, y las dos voltearon a vibe por debajo de cero en $a0,8/s0,5$ con la ganancia de deriva desaparecida. Si el diseño no hubiera pre-registrado el requisito de la celda secundaria, esta campaña habría reportado dos resultados positivos de caminata y habría guardado dos definiciones. **La cláusula de la celda secundaria es la cláusula que hizo el trabajo aquí**, y debería seguir siendo obligatoria en todo diseño futuro de caminata. La sonda de zancada pre-registrada apunta en la misma dirección: en $a0,4$ sobre $s \in \{0,2, 0,3, 0,4\}$ las tres ramas con `cummean` hacen pico en $s0,3$, la celda en la que ya estaban medidas — la tercera campaña consecutiva en la que re-ajustar la zancada no rescata nada — y en $s0,2$ su Δvibe pasa a positivo que cruza el cero solo a costa de dar pasos visiblemente más cortos ($\Delta\text{stride_err}$ por encima de cero en las tres) y de perder variedad de géneros ($-1,90$ / $-1,78$ / $-1,00$, todos por debajo de cero). Ese es exactamente el intercambio que la cláusula de victoria de caminata existe para rechazar.

La firma del fallo es la opuesta a la de la campaña de arquitectura anterior, y eso es diagnóstico. Ninguna rama fue refutada aquí por un suelo: el suelo de recall y el de relevancia pasan en las diez ejecuciones, y ocho de las nueve ramas no-áncla se sitúan en una concentración por artista *más alta* que el áncla (0,3547 a 0,3799 frente a 0,3559), es decir, las ramas no se de-eagerizaron. Los suelos no fueron entonces el mecanismo operativo: estas ramas no son degeneradas,




Figura 36: El objetivo de entrenamiento no ordena la recuperación: cuarta confirmación, y su instancia más nítida hasta ahora. Diez ramas del lote de bancos de torres: mejor InfoNCE de validación frente a aciertos de 1431. Spearman = $-0,2954$, $p = 0,407$. B4 y B2 distan 0,0003 en pérdida de validación y 16 aciertos; C0, el peor ajuste del lote, supera a seis de los ocho bancos. Todas las ramas pararon temprano (época 14 siete veces, luego 21 y 24 dos veces), así que el recall de ninguna rama es una cota inferior impuesta por el techo de épocas.

son simplemente **planas**. Es un modo de fallo distinto al de la campaña inmediatamente anterior de profundidad en serie (Sección 24), en la que las cinco ramas cayeron *por debajo* del suelo de recall, y es por lo que este eje cierra como un nulo y no como un daño.

El alcance del cierre, con precisión. Lo que cierra es «bancos de $N \geq 3$ torres GRU desnudas paralelas a `fusion_layers = 0`», y solo eso, al estándar que la Sección 24 fijó para un cierre en este corpus: ambas superficies, con el instrumento de caminata verificado. **No** vuelve a cerrar la familia de torre doble, que sigue reabierta en la superficie de la caminata (Sección 23) y sigue siendo el motor desplegado. Nada se promovió como campeón, no se guardó ninguna definición y no se construyó ningún dataset; las ocho ramas de medición se promovieron solo para medir, cada una con la nota literal «promoted to enable walk evaluation; not a crown claim», y la inundación resultante del grupo de mejores modelos (hasta 15 entradas) se declaró por adelantado y se derivó al agente de curación. Cero de las tres ejecuciones de contingencia pre-autorizadas se gastaron, y la traza de épocas explica por qué: la extensión del confundido de dropout requería que R2 parase más tarde que D2 y las dos pararon en la época 14; la contingencia del techo de épocas requería que alguna rama llegase al tope de 40 y todas pararon temprano; la contingencia del bracket de anchura requería que C1 perdiese, y no perdió.

Una limitación es heredada, no introducida. La premisa de esta campaña — el mecanismo de dosis — se leyó de un hallazgo que *no tiene informe de campaña propio*: la reapertura de la familia de torre doble en la superficie de la caminata solo existe como acumulado en `PROJECT-FACTS.md`, un commit de git y la transcripción del documento complementario de pista siguiente. La puerta

de reproducción del arnés re-derivó exactamente las diez medias registradas de esa reapertura y sus deltas, así que la *medición* es reproducible y el instrumento no se ha movido; lo que falta es la redacción primaria, y debería reponerse desde el commit y las entradas del fichero de hechos.
Fuente: 2026-08-02-tower-bank-parallel-towers.md.

26. Conclusiones

Trece campañas (jun–jul 2026) sobre el objetivo de rotación girado convergen en una única historia, con una salvedad de última hora (punto 12). (1) A través de dos campañas de rasgos y tres barridos de familia de modelos (dos corpus), toda modalidad densa y toda familia densa de distancia/margen/red-densa pierde ante los one-hots de identidad categórica leídos por árboles de gradient boosting — el latente song-AE diluye (Sección 5.1), el SVM de kernel es peor-que-la-media (Sección 5.2), y sobre el nuevo corpus completo de 64-d las dos familias de árboles lideran mientras el pyramid-MLP denso es último (Sección 5.4). (2) La elección de métrica es de peso sobre un objetivo binario: el MAE es degenerado (un predictor de tubo- ϵ de dos niveles publica un MAE engañosamente bajo siendo peor que la media), y un blend por-grilla-por-MAE incluso selecciona mal tal predictor; las métricas de clasificación honestas (AUC, log-loss, Brier) restauran una comparación justa (Sección 5.3). (3) Las campañas entregaron dos bandas de ruido medidas — $2\sigma = 0,0086$ MAE y $2\sigma = 0,0126$ AUC — y el primer campeón de rotación registrado y promovible del proyecto, **xgboost-classifier-rotation** con AUC 0.7429 sobre DS-META, más una definición xgboost guardada del nuevo corpus con AUC 0.7204. (4) La red neuronal densa se diagnosticó por completo (Sección 6): un barrido de arquitectura refutó la hipótesis de presupuesto (cada geometría se auto-detiene en 73–100 iteraciones y la red convergida reproduce el AUC sub-entrenado hasta todos los dígitos), así que la restricción vinculante es la *representación* de one-hots crudos, no la optimización — y el log-loss peor-que-el-azar de la red junto a un AUC genuino la marca como confiadamente mal calibrada, no meramente débil. (5) Ese diagnóstico se probó luego directamente: el **burn-deep-classifier** en Rust/burn, que alimenta los one-hots de identidad en *crudo*, reparó la calibración por completo (log-loss $2,0 \rightarrow \sim 0,62$, al régimen de los árboles) y elevó el AUC ~ 2 bandas a 0,7038 (Sección 6.7) — confirmando que la patología fue un artefacto de representación, no una propiedad intrínseca de las redes. Pero la brecha con los árboles solo se *estrechó* (de ~ 3.3 bandas a ~ 1), no se cerró: la red aún queda bajo **catboost** y **xgboost**, el **mlp** plano superó tanto a las topologías de embedding como wide-deep (los embeddings de entidad están famélicos a la baja cardinalidad de identidad del corpus), y nada superó la barra de guardado ~ 0.71 . (6) Esa palanca vigente se accionó luego. Una re-ejecución pareada sobre una matriz *high-vocab* — idéntica al dataset 60/40 pero con el tope de artista elevado $60 \rightarrow 300$ y género $40 \rightarrow 120$ — *volteó* el ranking de topología (Sección 6.8): **embeddings**, famélica y última sobre la matriz 60/40, ahora *supera* a **mlp** (un vuelco de $+0,0130$ que revierte el resultado previo y confirma la hipótesis de inanición direccionalmente), y la red guardada alcanza el nivel de los árboles dentro del dataset con AUC 0,7192 (dentro de ~ 1 banda de **catboost**) — la primera ANN en superar la barra de guardado de rotación, guardada como **burn-deep-embeddings-highvocab**. El hallazgo convergente aún se mantiene arriba (**xgboost** lidera toda matriz, y mayor resolución eleva a *toda* familia, no solo al embedding), pero el hilo de trampas-ANN queda ahora cerrado: una red consciente de la representación que consume one-hots crudos está calibrada en el régimen de los árboles, y dada suficiente resolución de identidad su topología de embedding alcanza el nivel de los árboles — la resolución de identidad era la palanca todo el tiempo. (7) Una sonda final probó luego el inverso de la palanca — si una representación aprendida *derivada del árbol*, en vez de alimentada junto a él, podía superar al árbol puro — y la refutó: el truco de Facebook GBDT→LR

generalizado a GBDT→MLP, con una cabeza fresca entrenada sobre los índices de hoja one-hot del campeón congelado, tope 1,8–2,4 bandas bajo el campeón xgboost puro (mejor AUC de cabeza 0,6978) y está mal calibrada en cada cabeza, porque los one-hots de hoja son una vista estrictamente más lossy de un árbol cuyo scoring aditivo de valores de hoja ya pondera las hojas óptimamente (Sección 6.10). La cabeza densa ni siquiera puede recuperar el árbol que generó sus rasgos — la séptima confirmación convergente de que la resolución de identidad, no nuevas cabezas o representaciones apiladas sobre los árboles, es la palanca durable. (8) Finalmente, la palanca de resolución de identidad vigente se mapeó hasta su borde: un barrido de tope de vocabulario sobre el GBDT puro — config campeona congelada, solo `vocab_top_n` movido — muestra que la palanca está *en gran medida agotada* (Sección 6.11). El primer salto de cardinalidad (60/40 → 300/120) lleva la ganancia; pasado 300/120 cada paso es sub-banda, la curva se estanca dentro del sobre de ruido, xgboost alcanza solo 0,7349 en 1000/300 (+0,005, ~0.4 banda sobre el ancla, así que ningún save disparó), y `catboost` lo sigue — dos familias de árboles coincidiendo en que las columnas marginales de alta cardinalidad llevan poca señal independiente. No saturada y no revertida, pero disminuyendo: la altura cruda del tope ya no es la palanca durable, y el trabajo futuro de identidad debería apuntar a la *calidad* de resolución (interacciones de seguidores/popularidad, jerarquía de género) en vez de topes más grandes — con el punto de vocabulario completo (6633 cols) aún no medido contra un techo de memoria del host.

(9) Una décima campaña caracterizó una *segunda* red consciente de la representación y alcanzó el mismo techo: el `burn-ae-classifier` de dos fases, que pre-entrena un autoencoder sobre el vector de rasgos ensamblado y trasplanta el encoder a un clasificador, es plano a través de 13 configs de capacidad/cabeza (una franja de 0,0054 de ancho dentro de la banda), empatando con el `mlp burn-deep` plano, y se mantiene ~1.8 bandas bajo el campeón de árboles; congelar el encoder pre-entrenado por MSE bajo una cabeza profunda es un modo de colapso documentado (Sección 6.9). El latente de reconstrucción no supervisado es agnóstico a la tarea — una tercera confirmación de que una representación aprendida aguas abajo de los one-hots de identidad no compra poder de ranking que los árboles no tengan. (10) Dos campañas de interpretabilidad abrieron las redes con un autoencoder disperso por modelo (Secciones 6.12, 6.13): con AUC igual, una pirámide que se estrecha *consolida* sus conceptos interpretables en un cuello de botella comprimido mientras una red uniforme mantiene un conjunto más amplio, y en vocabulario alto un par embeddings/mlp empatado en AUC captura la *misma* señal decodable ~0.14 con distinta asignación de conceptos — “misma señal, distinta disposición”, invisible a la tabla. (11) Un barrido de capacidad sobre la matriz high-vocab confirmó que la red densa está en su techo allí: ni ensanchar ni profundizar supera al control [128, 64] por una banda, una tercera capa de embedding *perjudica* (−0,0152, dilución no inanición), y el mejor `mlp` empatando con el mejor `embeddings` — la capacidad, no el mecanismo de embeddings, fue la palanca, y está agotada (Sección 6.13). (12) Finalmente, se planteó la pregunta honesta hacia adelante — y reencuadra toda la tabla. Una partición cronológica de primera clase (entrenar-antes / probar-después) baja el campeón de AUC 0,735 a 0,619, un colapso de ~0.11 que es *universal* a través de xgboost, catboost y logistic y es no-estacionariedad de gusto genuina, no censura-a-la-derecha; una lectura walk-forward aterriza en 0,59–0,67 cada año, nunca cerca de la línea base aleatoria (Sección 7). Todo AUC registrado es por tanto una cota superior del ranking de misma era; la habilidad real hacia adelante de “¿reproduciré una canción que descubra a continuación?” es ~0.62–0.63. El mecanismo es la rotación de identidad — artistas futuros no vistos caen en `__other__` y el modelo debe recaer en el piso intrínseco más débil ~0.60 — que es precisamente por qué topes de vocabulario más altos y redes más grandes, ambas palancas de memorización de misma era, no transfieren hacia adelante. Esto no revierte ningún número de partición aleatoria; clarifica qué miden y hace de la señal intrínseca generalizable más rica la única

palanca restante para el rendimiento hacia adelante.

(13) Una línea de trabajo paralela — recomendación de *pista siguiente* (next-track), cuya tarea y métricas no tienen relación con las tablas de rotación de arriba (Secciones 8–10) — se consolidó a través de veintiuna campañas y un memorándum de investigación. Una GRU de sesión por sí sola solo *empata* con la barra de co-escucha de Markov de primer orden y pierde en MRR, y ni el ajuste de pérdida ni ninguna topología (profundidad/anchura/residual/dirección) la supera. Pero un z-blend R+M de *fusión de rankings* (GRU $\times$ Markov) supera la barra de forma decisiva (+61 % de R@10, confirmado con 3 semillas) porque las dos ramas ordenan pistas correctas *distintas*; un stacker XGB aprendido rinde por debajo del z-blend fijo, y añadir ramas neuronales redundantes no ayuda — la victoria es diversidad de señal, no número de modelos. La única señal nueva genuinamente aditiva es el *contenido*: un barrido de representación de ítems halló que la *dimensión* latente (no el compresor) es la palanca y hace pico en PCA-192, y sobre ese espacio rico un z-blend R+M+C de tres ramas es la fila «mejor registrada» actual con R@10 0,1859, MRR 0,1025 (Δ pareado sobre el campeón previo +0,0133, IC>0). Dos salvedades acotan la coronación: la confirmación por reproducción tuvo dispersión cero porque **seq-nexttrack** es determinista en esta CPU (así que verificó determinismo, no robustez a la semilla), y el límite inferior del paired- Δ supera cero por solo +0,0007 en una única partición. Todo predictor de ranking de pista siguiente *fue* solo de entrenamiento y fuera del servidor hasta el arco de la proyección: una *proyección de contenido aprendida* supervisada ($R'+M+C'$) — un mapa métrico InfoNCE del espacio de ítems PCA-192 en el que recuperan la GRU y la rama de contenido — superó luego la coronación R+M+C con R@10 0,2117 (paired Δ +0,0259 IC>0), resolviendo ambas salvedades de R+M+C (es robusta a la semilla $\times 3$ y alcanza fríos) y endureciéndose en una segunda partición disjunta con 0.64 de fríos (paired Δ +0,0426 IC>0, más ancho en la partición más fría); ahora está *registrada, promovida y servible* (blend-gru-markov-content-proj, rango 1 del grupo de mejores modelos, Secciones 11–11.2), cerrando la brecha de productización, mientras que todo método prestado de ajuste-a-la-literatura (session-kNN, fusión de rankings, combinadores aprendidos, suavizado de Markov, trucos de pérdida de GRU) se cerró. Una exploración de representación del vector de ítem confirmó luego que la geometría PCA-192 de peso igual lastra un modelo *crudo* pero el arreglo es *absorbido* por la proyección (Sección 12), y una métrica continua de tipo “suena parecido”, *music@10* — correlacionada con recall@10 ($r = 0,609$) pero coronando al **seq-nexttrack** que regresa contenido como el más cercano musicalmente — se añadió como columna solo de visualización (Sección 13). Finalmente, una campaña de medición añadió una suite *solo de visualización* de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10): el síntoma de eagerness *sigue* a Recall@10 dentro de la familia de blends (el campeón es el modelo más artist-eager, artist_adj@10 0,610) pero proviene de la pata de bigrama de *Markov*, no de la RNN (GRU / LSTM individuales con artist_adj@10 $\approx 0,345$), y la GRU y la LSTM están estadísticamente empatadas (la hipótesis “la GRU gana por ser más eager” queda refutada); de dos palancas anti-eager el re-ranqueo MMR en evaluación es la palanca fuerte ($\lambda=0,9$ casi gratis) y el regularizador β de entrenamiento es débil, no se promovió nada, y $\lambda \approx 0,9$ queda señalado para una futura decisión de holisticidad del usuario (Sección 14).

(14) Dos campañas finales de arquitectura de pista siguiente cerraron después los últimos ejes de arquitectura abiertos, y ambas son nulos con mecanismo. Una GRU de *torre doble* entrenada conjuntamente, cruzando la matriz completa de vistas {latent,delta,cummean}² contra una torre única emparejada en parámetros al 0,098 %, falla en las ocho ramas (Sección 15) — el *cuarto* nulo independiente de combinador aprendido y el decisivo, porque responde a la objeción permanente a los tres anteriores («por supuesto que falla un combinador atornillado encima: entrenad la fusión de extremo a extremo»): entrenada de extremo a extremo a nivel de representación, sigue fallando. El mecanismo es que la vista **latent** cruda ya *subsume* a las otras (una GRU sobre latentes crudos

integra internamente el movimiento y la media acumulada; el único par genuinamente complementario, `delta+cummean`, supera a sus dos padres pero es desesperado en términos absolutos). Dos subproductos son duraderos: la cabeza MLP de fusión es activamente *perjudicial* (quitarla gana en todos los regímenes medidos, tres veces), y la anchura de GRU única queda ahora cerrada en PCA-192 como ya lo estaba en AE-64. Un *pre-codificador* por paso aprendido falla luego con más contundencia (Sección 16): la ablación decisiva de torre única *pierde* sin paliativos ($-0,0140$, IC por debajo de cero, 156 aciertos contra 176), la curva de dosis es plana hasta el doble de la dimensión de entrada y la colocación es irrelevante. Como un pre-codificador *lineal* es aquí demostrablemente neutro en expresividad, el rectificador es la única causa candidata — y una lectura contrafactual de interpretabilidad lo confirmó, midiendo el mapa afín como neutro en $\sim 0,8\sigma$ y la ReLU costando $\sim 5,9\sigma$, con `frac_exact_zero` 0,5327 coincidiendo con `frac_negative_coords` 0,5327 hasta cuatro dígitos: la rectificación de media onda de un latente centrado en cero borra exactamente su mitad negativa. A lo largo de cinco nulos de arquitectura el patrón es difícil de descartar: añadir maquinaria de representación *alrededor* de una GRU única sobre un buen espacio latente no ayuda en este corpus, mientras que toda ganancia real vino de mejorar el propio espacio latente o del z-blend fijo. Es la misma forma de hallazgo que el arco de la línea de rotación (puntos 1, 7, 9): la maquinaria aprendida apilada sobre una representación ya buena no compra nada, y la *resolución de la representación* es la palanca duradera. (15) Por último, dos hechos sobre el *instrumento* y no sobre ningún modelo reencuadran el arco de arquitectura (Sección 17). Los nulos están **limitados por potencia**: con $n = 1431$ el semiancho del IC de bootstrap pareado es 0,0124 en Recall@10 y $\sim 0,0018$ en *holisticness*@10, mientras que una familia de arquitectura completa abarca solo 0,028 y 0,0031 — así que de ocho ramas adyacentes son separables unos dos niveles en recall y uno en *holisticidad*, y resolver una diferencia de 0,005 exigiría ~ 8800 sesiones. La lectura honesta es que *los daños grandes se detectaron con fiabilidad mientras las victorias moderadas nunca fueron detectables*, lo cual es una afirmación distinta de «estas arquitecturas no funcionan» y produce una regla de priorización: más ramas de arquitectura son un mal uso de las ejecuciones en esta partición, den lo que den, porque todo el rango dinámico del eje apenas duplica el error de medición. Y *holisticness*@10 existe en tres generaciones de código mutuamente no comparables (3 factores; 4 factores anclada; anclada más concentración de artista), cuyas diferencias empujenn a toda diferencia entre modelos y bajo todas las cuales el campeón servible de pista siguiente queda *último* — así que el tablero de pista siguiente sigue denominado en Recall@10 y cada columna de *holisticidad* va etiquetada con su generación (Tabla 36). Nótese el paralelo con el punto (12): ambas líneas de trabajo terminan en una salvedad de medición y no de modelado — el AUC de partición aleatoria de rotación es una cota superior de la habilidad hacia adelante, y los nulos de arquitectura de pista siguiente están acotados por el tamaño del conjunto de prueba. (16) Una séptima campaña de arquitectura de pista siguiente cerró después la rama *paralela* del eje, y es el segundo veredicto de este documento que se apoya en **dos** superficies de evaluación (el punto (19) es el primero): el ya conocido top-10 de un disparo, y la *caminata* autorregresiva que el showcase sirve realmente (Sección 25). Un banco de N torres GRU desnudas paralelas bajo una única cabeza lineal, igualado a $3,00\times$ la línea base h256 y dosificado de $N = 2$ a $N = 4$, no gana en ninguna de las dos superficies: todas las ramas *empatan* con la línea base en recall de un disparo mientras **cinco de ocho pierden contra una GRU única con parámetros igualados** con el IC por debajo de cero, y las dos ramas que logran un trade de caminata en la celda primaria voltean a *vibe* por debajo de cero en la celda desplegada, así que no se guardó ninguna definición. El dato decisivo es un cero: cuatro torres h211 (1 187 700 params) y una GRU h512 (1 182 912 params) devuelven los *mismos* 186 aciertos de 1431, con Δ pareado 0,000000 — *topología y anchura son intercambiables con este presupuesto*, que es además la demostración más

limpia del registro de por qué la pata de control con parámetros igualados es obligatoria: contra el ancla sola, cinco ramas perdedoras habrían pasado por empates. La campaña se construyó para dosificar el mecanismo declarado de la propia victoria de caminata (una referencia fija que la recurrencia nunca sobreescribe) y la dosis queda refutada *irónicamente*: las torres **cummean** añadidas para sostener un mood son las peores ramas del lote en ambas superficies y las dos únicas cuyo **vibe** de caminata queda refutado sin paliativos. El único resultado del lote con IC lejos del cero es un subproducto sobre *regularización*, no sobre topología: con parámetros idénticos byte a byte el dropout 0,1 supera al dropout 0,0 en +0,0049 de recall@10. Eso es consecuente porque la ruta **fusion_layers** = 0 construye *cero* módulos de dropout, de modo que toda rama f0 del registro — incluido el motor desplegado del showcase — entrenó sub-regularizada, los tres huecos f0-vs-f1 registrados no son igualmente-regularizados, y la mejora más barata del tablero es un único reentrenamiento. Es la misma forma que los puntos (7), (9) y (14): la maquinaria apilada sobre una representación ya buena no compra nada, y las palancas durables son la representación y el régimen de entrenamiento.

(17) Seis campañas más de pista siguiente completan entonces esa línea, y los dos resultados *positivos* en ellas son cambios en tiempo de puntuación y no modelos. La frontera de MMR λ en tiempo de evaluación (Sección 18) es la primera palanca de *holisticness* confirmada del registro — ocho de ocho ramas la elevan con el IC sobre cero, tres ramas de la GRU única superan la barra histórica con un empate de recall, y tres de los cuatro factores de corona mejoran juntos — y resuelve unánimemente su pregunta de mecanismo pre-registrada: la diversificación sónica des-concentra *artistas* 1,59 a $3,06\times$ más rápido de lo que reduce el eco de la semilla en 8 de 8 ramas, así que la secuela de penalización explícita de artista queda cancelada. Su subproducto es una regla de medición: el emparejamiento de pesos compartidos es 3 a $33\times$ más afilado que el suelo de ruido de la familia de arquitecturas del punto (15), así que las palancas en tiempo de evaluación deben presupuestar su efecto mínimo detectable a partir del emparejamiento. Después, **markov_gate** (Sección 21) entrega la mayor ganancia individual de recall de todo el arco desde nueve líneas y cero parámetros nuevos: hacer que la rama de Markov se *abstenga* donde el último ítem del prefijo no tiene soporte de bigramas de entrenamiento (el 55,6 % de las consultas) eleva el recall@10 a 0,23201 (332 de 1431), pareado +0,02027 en la canónica y +0,01957 en una partición disjunta con 64 % de fríos. El defecto es el normalizador *invariante a escala* del blend re-inflando un retroceso sin evidencia a un voto completo de un tercio, y la descomposición por bucket — efecto entero en el bucket de soporte cero, los dos buckets cálidos **idénticos byte a byte** — prueba mecánicamente que ningún peso de rama global y estático podía encontrarlo, lo que *estrecha* la trampa del combinador aprendido, confirmada cuatro veces, a la *fusión aprendida a nivel de puntuación* y no al compuertado por evidencia por consulta. Es una recomendación, no una promoción. (18) Los resultados negativos de la misma ventana son igualmente portantes. El regularizador anti-eager en tiempo de entrenamiento queda refutado *expresivamente* y no por dosis (Sección 22): sus márgenes se calibraron desde la cola de transición ítem→ítem mientras el hinge actúa sobre predicción→actual, cuyo techo queda por debajo de los cuantiles usados, así que cuatro ramas reproducen la pérdida del control a 16 cifras significativas y las que sí disparan destruyen la relevancia en el mismo movimiento que des-eageriza. Lo que *sí* funciona es la primera palanca de este proyecto que no puede ser superada en puntuación: un **tope duro por artista** sobre el top-*k* (Sección 23), que lleva **artist_conc@10** de 0,692 a 0,113 y la **holisticness@10** de generación 3 de 0,0086 a 0,0481 mientras **music@10** *sube* con el IC sobre cero en todos los ajustes y en ambos modelos — cambia relevancia *literal* por relevancia *graduada* — endurecido en una partición disjunta con 64 % de fríos sobre dos piernas pre-registradas, a un precio declarado de 52 de 1431 aciertos exactos. Una métrica de despliegue construida a propósito (Sección 19) devuelve

un sexto nulo de arquitectura en el régimen de despliegue y encuentra que la varianza por semilla domina la identidad del modelo; y un memorándum de investigación (Sección 20), reportado en un registro más bajo porque nada en él se ejecutó en el servidor, converge desde cinco direcciones independientes en la tesis de que toda propuesta superviviente es un cambio de *condicionamiento por evidencia* y no de capacidad — la misma forma que los puntos (1), (7), (9) y (14) del lado de rotación. (19) Una campaña de profundidad de pila de etapas (Sección 24) cierra finalmente la rama *serie* del eje de arquitectura en *ambas* superficies de evaluación, el estándar que hereda después la campaña de bancos de torres del punto (16). Cinco disposiciones de etapas de MLP por paso y recurrentes igualadas en capacidad caen todas *por debajo* del umbral obligatorio de recall y quedan refutadas otra vez en la caminata, mientras un control de capacidad de $3,24\times$ empata en ambas — así que el daño es la profundidad misma, y no la capacidad, la regularización ni el MLP (un MLP líder por paso es neutro en recall y positivo en holistiness en profundidad 4, lo que estrecha el resultado del pre-codificador con $N = 1$ del punto (14) al caso superficial). Dos hechos sobreviven al nulo: enmarcar supera a intercalar a capacidad idéntica bit a bit (+0,01537, IC sobre cero), y el objetivo de entrenamiento se **desacopla** de la recuperación — la rama con la mejor pérdida InfoNCE de validación del lote recupera 55 aciertos menos que el control, así que cualquier búsqueda de arquitectura sobre esta familia que seleccione por pérdida de validación elige la rama equivocada.

27. Informes fuente

Esta síntesis consolida treinta y cinco documentos fuente de `experiments/` — treinta y cuatro informes de campaña y un memorándum de investigación, este último señalado como tal porque nada en él se ejecutó en el servidor:

- `2026-06-09-ae-xgboost-blend.md` — blend de latente-autoencoder + XGBoost sobre rotación (Sección 5.1).
- `2026-06-09-svm-kernel-rotation.md` — barrido de SVM de kernel y blend condicional; primera banda de ruido de MAE medida (Sección 5.2).
- `2026-06-09-rotation-classification.md` — bake-off de AUC, primera banda de ruido de AUC medida, primer campeón de rotación registrado (Sección 5.3).
- `2026-06-12-classifier-bakeoff-p64.md` — bake-off de cuatro familias de clasificadores y barrido xgboost de depth/lr sobre el nuevo corpus completo de 64-d (Secciones 5.4 y 6).
- `2026-06-12-pyramid-mlp-arch-scan.md` — barrido de arquitectura de seis geometrías del pyramid-MLP, refutando la hipótesis de presupuesto (Secciones 5.5 y 6).
- `2026-06-12-burn-deep-topology.md` — el bake-off de topología del `burn-deep-classifier` en Rust/burn; resuelve la cuestión de la red consciente de la representación, arreglando la calibración pero no la brecha de AUC (Sección 6.7).
- `2026-06-12-high-vocab-topology.md` — la re-ejecución pareada de topología sobre una matriz de mayor cardinalidad de identidad; voltea `embeddings>mlp` y eleva la red guardada al nivel de los árboles dentro del dataset, la primera ANN en superar la barra de guardado de rotación (Sección 6.8).

- `2026-06-15-gbdt-leaf-head-ceiling-probe.md` — el truco de Facebook GBDT→LR generalizado a GBDT→MLP; cada cabeza de embedding de hojas tope bajo el campeón xgboost puro con calibración rota, la séptima refutación convergente (Sección 6.10).
- `2026-06-15-vocab-cap-scan-gbdt.md` — el barrido de tope de vocabulario de resolución de identidad sobre el GBDT puro; mapea la curva tope→AUC y halla la palanca en gran medida agotada pasado 300/120 (ganancias sub-banda, ningún save disparó), con el punto de todo-vocabulario no medido en el techo de memoria del host (Sección 6.11).
- `2026-06-15-burn-ae-classifier-capacity-scan.md` — primera caracterización del `burn-ae-classifier` de dos fases; 13 configs en una franja sub-banda, empata con el `mlp burn-deep` plano, y un modo de colapso de cabeza-profunda-congelada (Sección 6.9).
- `2026-07-12-pyramid-vs-rect-sae.md` — lectura de representación por SAE por modelo; con AUC igual la pirámide consolida conceptos en su cuello de botella mientras la red uniforme mantiene un conjunto más amplio (Sección 6.12).
- `2026-07-12-high-vocab-capacity-scan.md` — el barrido de capacidad del `burn-deep-classifier` sobre la matriz high-vocab (TECHO) más una lectura de asignación por SAE cross-familia (Sección 6.13).
- `2026-07-12-taste-drift-temporal-split.md` — la partición cronológica frente a aleatoria; una caída universal de ~ 0.11 de AUC que reencuadra la tabla como una cota superior del ranking de misma era (Sección 7).
- `2026-07-15-nexttrack-compression-representation-bakeoff.md` — la primera campaña de recomendación de *pista siguiente* incorporada: un bake-off de compresión de la representación de ítems (PCA frente a autoencoder $\times$ dimensión latente 32/64/128) bajo un readout GRU congelado. PCA-128 es el ganador GRU-individual (paired- Δ +0,0189, IC>0) pero la victoria no se traslada al blend R+M, así que nada se promovió (Sección 9).
- `2026-07-13-nexttrack-sequence-sweep.md` — la campaña fundacional de pista siguiente: un barrido de secuencias GRU/LSTM contra la barra de Markov de primer orden; la mejor GRU-infonce empata en R@10 pero pierde en MRR (Sección 8.1).
- `2026-07-13-nexttrack-topology-scan.md` — barrido de topología profundidad / anchura / residual / bidireccional; la arquitectura es una palanca agotada, todas las ramas quedan bajo la barra de Markov (Sección 8.2).
- `2026-07-14-nexttrack-blend-and-ensemble.md` — el z-blend R+M GRU $\times$ Markov supera la barra en +61 % de R@10 (el primer campeón de pista siguiente); ningún ensamble más rico lo mejora y el stacker XGB aprendido rinde por debajo (Sección 8.3).
- `2026-07-14-nexttrack-graded-relevance-and-new-legs.md` — métricas de relevancia graduada de primera clase (artist@k / genre@k / artist_mrr) y nuevos aprendices base leak-free; content-kNN es la única señal aditiva, empatando al campeón sobre AE-64 (Sección 8.4).
- `2026-07-15b-nexttrack-compression-dim-extension.md` — el barrido de dimensión PCA/AE extendido a 192/256; la curva hace pico en PCA-192 y se revierte, así que PCA-128 se mantiene como la base de la Fase 2 (Sección 10.1).

- `2026-07-15c-nexttrack-phase2-model-sweep.md` — el barrido de familia de modelos sobre los espacios PCA ricos; el z-blend fijo supera al stacker aprendido, LSTM es el mejor modelo individual, y R+M+C sobre PCA-192 se corona como la nueva fila «mejor registrada» (Sección 10.2).
- `2026-07-18-nexttrack-literature-fit-campaign.md` — una exploración guiada por bibliografía; una proyección de contenido aprendida supervisada ($R'+M+C'$) es una nueva fila «mejor registrada» ($R@10$ 0,2117, paired Δ sobre R+M+C +0,0259 IC>0, robusta a la semilla, alcanza fríos), y cada método prestado (session-kNN, fusión de rankings, combinador aprendido, suavizado de Markov, negativos por importancia de GRU) se cierra (Sección 11.1).
- `2026-07-18b-nexttrack-projection-registration-and-scan.md` — la proyección reproducida on-server, registrada + promovida + servible como `blend-gru-markov-content-proj` (rango 1 del grupo de mejores modelos); un barrido de objetivo / rango / τ (InfoNCE $\gg$ BPR; default mantenido) y endurecimiento en segunda partición sobre una partición disjunta con 0.64 de fríos (paired Δ +0,0426 IC>0) (Sección 11.2).
- `2026-07-18c-nexttrack-representation-exploration.md` — una auditoría de representación del vector de ítem; la geometría PCA-192 de peso igual lastra la GRU cruda (seis de ocho espacios alternativos la elevan IC>0) pero la ganancia es absorbida por la proyección (Sección 12).
- `2026-07-20-musical-distance-metric.md` — la métrica continua de tipo “suena parecido” `music@10` y su backfill offline de 53 runs; correlaciona con `recall@10` ($r = 0,609$) pero corona a un ganador distinto, el `seq-nexttrack` que regresa contenido (Sección 13).
- `2026-07-22-session-holisticness-and-antieager-levers.md` — una suite solo de visualización de holisticidad de sesión (`artist_adj@10` / `mood_coh@10` / `ild@10`) y dos palancas anti-eager (MMR en evaluación `mmr_lambda`, y `eager_beta` de entrenamiento); el campeón es el modelo más artist-eager, la eagerness proviene de la pata de Markov, $GRU \approx LSTM$, y MMR λ es la palanca fuerte (Sección 14).
- `2026-07-25-nexttrack-dual-tower-fusion-scan.md` — el escaneo de emparejamiento de vistas $\times$ profundidad de fusión en torre doble contra una torre única emparejada en parámetros al 0,098%; **REFUTADO** (el cuarto nulo de combinador aprendido, que cierra la objeción de «entrenad la fusión de extremo a extremo»), mostrando que la vista de latentes crudos subsume a `delta/cummean`, que la cabeza MLP de fusión es activamente perjudicial, que la anchura de GRU única queda cerrada en PCA-192, y que holisticidad y recall están anticorrelacionados en todo el lote (Sección 15).
- `2026-07-26-nexttrack-pre-encoder-scan.md` — el escaneo del pre-codificador por paso aprendido (presencia $\times$ colocación $\times$ dosis) con la ablación decisiva de torre única; **REFUTADO y activamente perjudicial** ($-0,0140$ de Recall@10, IC por debajo de cero), con el rectificador identificado analíticamente y luego medido (mapa afín neutro en $\sim 0,8\sigma$, ReLU en $\sim 5,9\sigma$, `frac_exact_zero` = `frac_negative_coords` = 0,5327), más el análisis de potencia medido y las tres generaciones de holisticidad (Secciones 16 y 17).
- `2026-07-26-nexttrack-mmr-lambda-frontier.md` — la frontera nativa de MMR λ en tiempo de evaluación sobre ambas anclas; **CONFIRMADA** como la primera palanca de holisticness genuina del registro (tres ramas NIVEL-1 «gratis» de la GRU única por encima de la

barra histórica con un empate de recall, mejor H 0,030355), con la pregunta de mecanismo pre-registrada resuelta unánimemente a favor de la hipótesis responsiva (8 de 8 ramas, razón 1,59 a 3,06), con la faceta que liga mostrando su cambio al bajar λ , con el eje del conjunto de candidatos cerrado como mando de ajuste fino, y con el emparejamiento de pesos compartidos medido 3 a 33× más afilado que el suelo de ruido de la familia de arquitecturas (Sección 18).

- 2026-07-27-rollout-hold-metric.md — `hold@N`, una métrica de generación para el régimen de despliegue autorregresivo (desvanecimiento por eje calibrado sobre 2135 sesiones reales de entrenamiento, con el término anti-gaming dentro de la métrica), más cinco barridos y 240 recorridos; **REFUTADA** como discriminador de modelos — un sexto nulo de arquitectura, obtenido en el régimen de despliegue — con la varianza por semilla mostrando su dominio sobre la identidad del modelo y tres positivos retirados documentados como catálogo de trampas de las métricas de generación (Sección 19).
- 2026-07-27b-nexttrack-model-topology-research-memo.md — **un memorándum de investigación, no un informe de campaña**: nada se ejecutó en el servidor, nada se promovió, nada se registró, y sus números provienen de cribados offline sobre checkpoints congelados. Consolidado en un registro más bajo, con su propia partición verificado/provisional preservada y su cautela de cribado sobre el conjunto de prueba enunciada; su contenido reutilizable es la tesis convergente de que toda propuesta superviviente es un cambio de *condicionamiento por evidencia* y no de capacidad, la explicación mecánica de la anomalía del combinador aprendido, y el cementerio (Sección 20).
- 2026-07-27c-nexttrack-markov-gate-confirm.md — la confirmación nativa en dos particiones de `markov_gate`; **CONFIRMADA** y la mayor ganancia individual de recall del arco ($R@10$ 0,23201 = 332 de 1431, pareado +0,02027 en la canónica y +0,01957 en una partición disjunta con 64% de fríos, MRR al alza en ambas), con los buckets cálidos de evidencia *idénticos byte a byte*, una ganancia de corona no prevista en la que los cuatro factores se mueven en la dirección correcta a la vez, una primera rama de corona neutra en recall al componerse con MMR, y la trampa del combinador aprendido estrechada en consecuencia (Sección 21).
- 2026-07-30-eager-margin-calibrated-refutation.md — el regularizador de eagerness en tiempo de entrenamiento con márgenes calibrados desde la cola de transición medida; **REFUTADO en todo el eje, con mecanismo**: los márgenes se extrajeron del coseno ítem→ítem mientras el hinge actúa sobre predicción→actual, cuyo techo queda entre 0,5843 y 0,70, así que cuatro ramas son demostrablemente inertes (trazas de pérdida idénticas bit a bit con β hasta el tope del esquema) y las que sí disparan destruyen la relevancia antes de ayudar (Sección 22).
- 2026-07-30c-artist-cap-measurement.md — *el tope duro por artista*, la primera palanca de des-eagring que funciona, y funciona porque no puede ser superada en puntuación: `artist_conc@10` 0,692→0,113 con `music@10` *al alza* (IC sobre cero) en todos los ajustes y en ambos modelos, endurecido en una partición disjunta con 64% de fríos sobre dos piernas pre-registradas, a un precio declarado de 52 de 1431 aciertos exactos; es además donde este documento introduce la segunda superficie de evaluación, la caminata autorregresiva (Sección 23).

- `2026-08-01-stage-stack-topology.md` — la campaña de topología de pila de etapas (disposiciones de MLP por paso $\times$ recurrencia a capacidad igualada, vía el nuevo predictor `seq-stack`); **REFUTADA en ambas superficies** y el primer cierre de este corpus a ese estándar: las cinco ramas de 4 etapas caen *por debajo* del umbral de recall y quedan refutadas otra vez en la caminata, el control de capacidad de $3,24\times$ empata en ambas, la hipótesis del usuario sobre la posición del rectificador queda refutada, enmarcar supera a intercalar a capacidad idéntica bit a bit, y la rama de mejor ajuste del lote recupera 55 aciertos menos que el control (Sección 24).
- `2026-08-02-tower-bank-parallel-towers.md` — la campaña de dosis de bancos de torres paralelas (N torres GRU desnudas bajo una única cabeza lineal, vía el nuevo predictor `seq-bank`) y la primera campaña aquí juzgada en *dos* superficies; **CERRADA en ambas**: ninguna rama gana, cinco de ocho pierden contra una GRU única con parámetros igualados, cuatro torres h211 y una GRU h512 devuelven los mismos 186 aciertos (Δ pareado 0,000000), la dosis de `cummean` empeora estrictamente la caminata, los dos trades de caminata son locales a la celda, y el único resultado del lote con IC lejos del cero es que el dropout 0,1 supera al dropout 0,0 con parámetros idénticos byte a byte — lo que implica que toda rama `fusion_layers = 0` del registro, el motor desplegado incluido, entrenó sub-regularizada (Sección 25).

Cuadro 11: El barrido de capacidad + arquitectura-de-cabeza del `burn-ae-classifier` (ds-20260609-204419-p64-s42, semilla 42; fijos: `ae_epochs` 80, `ae_lr` 1×10^{-3} , épocas 200, `lr` 1×10^{-3} , dropout 0.1, patience 25). Las 13 ejecuciones tuvieron éxito. AUC y exactitud mejor cuanto más alto; log-loss mejor cuanto más bajo. Ganador (cfg3) y mejor celda por métrica en negrita; el colapso de cabeza-profunda-congelada (cfg10) es la única fila fuera de banda. Ordenado por AUC.

Run id	enc / clf / freeze / act	AUC	log-loss	exact.
run-20260615-1523 59-21f11-burn-ae- classifier	[128,64] / [128,64] / ft / relu	0.69719	0.6216	0.6496
run-20260615-1523 59-05bce-burn-ae- classifier	[256,128] / [128] / ft / relu	0.69712	0.6254	0.6485
run-20260615-1523 59-e5a75-burn-ae- classifier	[128,32] / [64] / ft / relu	0.69657	0.6246	0.6451
run-20260615-1523 59-94f8f-burn-ae- classifier	[128,64] / [64] / ft / relu (re-ejec. línea base)	0.69645	0.6264	0.6496
run-20260615-1523 59-7a459-burn-ae- classifier	[128,64] / [256,128] / ft / relu	0.69561	0.6235	0.6434
run-20260615-1523 59-cb93b-burn-ae- classifier	[384,192] / [192,96] / ft / relu	0.69541	0.6224	0.6426
run-20260615-1601 12-aaldb-burn-ae- classifier	[256,128] / [128] / <i>congelado</i> / re- lu	0.69530	0.6242	0.6409
run-20260615-1601 12-4a764-burn-ae- classifier	[128,64] / [128,64] / ft / gelu	0.69340	0.6256	0.6411
run-20260615-1523 59-3b006-burn-ae- classifier	[256,128,64] / [64] / ft / relu	0.69302	0.6279	0.6481
run-20260615-1601 13-7567b-burn-ae- classifier	[128,64] / [128,64] / ft / silu	0.69242	0.6230	0.6436
run-20260615-1523 59-86fd5-burn-ae- classifier	[256,128] / [256,128] / ft / relu	0.69240	0.6275	0.6392
run-20260615-1523 59-dbb6a-burn-ae- classifier	[128,64] / [] (sonda lineal) / ft / relu	0.69175	0.6282	0.6405
run-20260615-1601 12-17da7-burn-ae- classifier	[128,64] / [128,64] / <i>congelado</i> / relu (colapso)	0.68210	0.6378	0.6373

Cuadro 12: La sonda de techo de cabeza-de-hojas GBDT (ds-20260609-204419-p64-s42, semilla 42; el GBDT emisor de hojas es la config campeona congelada en cada tratamiento, solo varía la cabeza). Las cuatro ejecuciones tuvieron éxito. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Control (ganador) en negrita; mejor celda por métrica en negrita; filas de tratamiento ordenadas por AUC. Umbral de refutación (campeón -2σ) = 0,7078: cada cabeza está por debajo de él.

Rama / run id	Cabeza	AUC	log
C0 (run-20260615-151551-f2911-xgboost-classifier)	árbol puro (campeón)	0.7204	0.6
T1 (run-20260615-151551-b4db5-gbdt-leaf-head-classifier)	lineal (ℓ_2 logística, l2 1.0)	0.6978	1.3
T3 (run-20260615-151551-44b1d-gbdt-leaf-head-classifier)	mlp [256, 128], head_lr 1×10^{-3}	0.6921	1.1
T2 (run-20260615-151551-9d655-gbdt-leaf-head-classifier)	mlp [128], head_lr 1×10^{-3}	0.6897	0.8

Cuadro 13: El barrido de tope de vocabulario sobre el GBDT puro (config xgboost campeona congelada; catboost defaults; el único eje es vocab_top_n, todo lo demás idéntico byte a byte al ancla 300/120: mismas 23 529 filas, semilla de partición 42, PCA64, bloque de campos). Ordenado por tope de artista/género. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. La nueva mejor ejecución de linaje single-split en negrita; mejor celda por métrica en negrita. La fila de vocabulario completo es el build fallido (techo de memoria del host, dos intentos), registrada como un fallo de infraestructura, no un resultado. Banda de AUC $2\sigma \approx 0,0126$.

Run id	tope	cols	modelo	AUC	log-loss	B
run-20260615-163751-de9a4-xgboost-classifier	60/40	177	xgb	0.72044	0.60754	0.2
run-20260615-163803-3391f-catboost-classifier	60/40	177	cat	0.71105	0.61324	0.2
run-20260615-163803-536d5-xgboost-classifier	300/120	497	xgb	0.72988	0.60223	0.2
run-20260615-163803-6f170-catboost-classifier	300/120	497	cat	0.72516	0.60681	0.2
run-20260615-163803-1a0ba-xgboost-classifier	500/200	777	xgb	0.72966	0.60392	0.2
run-20260615-163803-1fae3-catboost-classifier	500/200	777	cat	0.72372	0.60894	0.2
run-20260615-163803-e75be-xgboost-classifier	1000/300	1377	xgb	0.73490	0.60070	0.2
run-20260615-163803-9ed65-catboost-classifier	1000/300	1377	cat	0.72633	0.60931	0.2
(build fallido)	todo 5594/962	6633	—	—	—	—

Cuadro 14: El barrido de capacidad del `burn-deep-classifier` sobre la matriz `high-vocab` (`ds-20260612-143014-p64-s42`, 497 cols; `activation=relu`, dropout 0.1, épocas 250, patience 20; solo varía la geometría oculta dentro de una topología). Las seis tuvieron éxito. AUC y exactitud mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador (B1) y mejor celda por métrica en negrita; ordenado por AUC. La rama `embeddings` profunda (B3) es el único movimiento fuera de banda.

Run id	topología / hidden	AUC	log-loss	exact.	Brier
run-20260712-1710 08-065bd-burn-dee p-classifier	embeddings / [128,64]	0.72274	0.61043	0.66426	0.21140
run-20260712-1710 08-7c302-burn-dee p-classifier	mlp / [256,128,64]	0.71800	0.61266	0.66065	0.21276
run-20260712-1710 08-cf746-burn-dee p-classifier	embeddings / [256,128]	0.71798	0.61323	0.66511	0.21246
run-20260712-1710 08-fc3e0-burn-dee p-classifier	mlp / [256,128]	0.71576	0.61220	0.66638	0.21249
run-20260712-1710 08-c093f-burn-dee p-classifier	mlp / [128,64]	0.71229	0.61694	0.65852	0.21447
run-20260712-1710 08-786b4-burn-dee p-classifier	embeddings / [256,128,64]	0.70750	0.61671	0.66001	0.21444

Cuadro 15: La brecha de AUC aleatorio-frente-a-cronológico, builds definitivos del framework (todos `spotify_tracks_song_ae`, 23 529 filas, semilla 42; cada modelo sobre la partición nativa de su dataset). “completo” lleva los one-hots de identidad, “intrínseco” los descarta (64 PCA + 7 numéricos solo). La fila del campeón en negrita; la columna de deriva es la caída aleatorio–cronológico sobre la matriz completa. Completo-aleatorio reproduce el campeón registrado (0,73490), validando los builds. Datasets: completo-aleatorio `ds-20260712-183615`, completo-crono `ds-20260712-183629`, intrínseco-aleatorio `ds-20260712-183630`, intrínseco-crono `ds-20260712-183631`. Banda de AUC $2\sigma \approx 0,0126$.

Modelo	compl. · aleat.	compl. · crono	deriva	intr. · aleat.	intr. · crono
xgboost (campeón)	0.73490	0.61894	+0,116	0.71020	0.59858
catboost	0.72889	0.61294	+0,116	0.70172	0.59556
logistic	0.72141	0.61234	+0,109	0.64836	0.59016

Cuadro 16: Tabla de «mejor registrada» de pista siguiente (régimen de RANKING), sobre la partición next-distinct sin fugas (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos). R@10, MRR, artist@10, genre@10, music@10 mejor cuanto más alto; la barra de Markov es la referencia incumbente. Los valores de music@10 son el backfill offline (Sección 13); las filas sin un run mapeado se dejan en blanco. Fila campeona y campeones previos en negrita; mejor celda por métrica en negrita. Las tres filas de arquitectura refutada añadidas el 2026-07-25/26 se muestran para *acotar* sus ejes y quedan excluidas del resaltado de mejor celda; no llevan IC marginal, solo un Δ pareado contra la línea base de GRU única (Tablas 30 y 32). La fila superior, añadida el 2026-07-27c, es el campeón con compuerta de evidencia de la Sección 21: una *recomendación* de promoción y no un modelo registrado, así que su R@10 va en negrita como la mejor registrada pero por lo demás queda excluida del resaltado de mejor celda, y lleva un Δ pareado (Tabla 40) en lugar de un IC marginal. **No comparable con ninguna tabla de rotación de arriba.** Espacios de ítems: AE-64 (spotify_tracks_song_ae); PCA-*k* (spotify_tracks_song_pcak), todos ajustados desde la fuente leak-safe spotify_tracks_content.

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	mus@10	Nota
$R'+M+C' + \text{comp.}$	0.2320	0.1335	0.367	0.463	0.493	mejor R@10
$R'+M+C'$, PCA-192 (campeón, servible)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	0.454	nuevo campeón
R+M+C, PCA-192 (campeón de fusión previo)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	0.449	contenido aditiv
R+M+C, PCA-128	0.1824 [0.162, 0.203]	0.0993	0.332	0.396	—	contenido aditiv
R+M, AE-64 (campeón previo)	0.1726 [0.154, 0.192]	0.0963	0.322	0.397	0.441	ancla prod.; 3 s
R+M+C, AE-64 (graded-preferred)	0.1740 [0.154, 0.194]	0.1014	0.330	0.400	—	contenido solo e
R+M, PCA-192	0.1712 [0.151, 0.192]	0.0952	0.329	0.398	0.443	$\approx$ campeón prev
R+M, PCA-128	0.1670 [0.148, 0.187]	0.0920	0.329	0.398	0.444	ganancia GRU r
R+A+M, AE-64	0.1684	0.0943	—	—	—	rama ANN redu
GRU single h512, PCA-192	0.1300	—	—	—	0.458	empate anchura
banco torres lat×4, PCA-192	0.1300	—	—	—	0.459	banco = anchur
LSTM single, PCA-128	0.1272 [0.110, 0.145]	0.0495	0.335	0.458	0.451	mejor único; $\ll$
GRU única h454, PCA-192	0.1251	0.0539	0.338	0.454	0.457	anchura cerrada
GRU single, PCA-192	0.1230 [0.106, 0.140]	0.0534	0.338	0.450	0.456	óptimo puntual
torre doble GRU f0, PCA-192	0.1188	0.0563	0.337	0.456	0.455	torre doble: refu
GRU single, PCA-128 (base)	0.1146 [0.099, 0.132]	0.0489	0.333	0.452	0.457	espacio base cor
pre-MLP→GRU, PCA-192	0.1090	0.0446	0.324	0.469	0.450	pre-codif. perju
B2 Markov de primer orden (barra)	0.1069 [0.092, 0.124]	0.0694	0.298	0.389	0.407	incumbente de l
ANN pooled-MLP single, PCA-128	0.0901 [0.076, 0.105]	0.0394	0.299	0.435	0.426	pierde ante la G
XGB stacker (M+G / M+G+A)	0.080–0.087	0.042–0.049	0.31	0.38	0.41	el combinador r
content-kNN (song-AE cosine)	0.0636 [0.050, 0.077]	0.0321	0.272	0.405	—	la rama C aditiv
item2vec (SGNS solo entren.)	0.0517	0.0214	0.166	0.312	—	arrastra el blen

Cuadro 17: La campaña de fusión: el z-blend R+M supera la barra de Markov de forma decisiva, y ningún ensamble más rico lo mejora. R@10 y MRR mejor cuanto más alto; campeón en negrita. *No comparable con ninguna tabla de rotación.*

Modelo	R@10 [IC 95 %]	MRR	Nota
z-blend R+M $\alpha=0,5$ (campeón)	0.1726 [0.154, 0.192]	0.0963	Δ vs Markov +0,066 [+0,05, +0,08]
z-blend R+A+M	0.1684	0.0943	rama ANN redundante con GRU
B2 barra de Markov (M)	0.1069 [0.092, 0.123]	0.0694	la referencia
XGB stacker M+R	0.1020	0.0561	combinador aprendido $\ll$ z-blend
GRU sola (R)	0.0957	0.0411	empata la barra solo en R@10
z-blend R+A	0.0894	0.0377	$\approx$ GRU sola
XGB stacker M+R+A	0.0887	0.0572	apenas supera a Markov

Cuadro 18: El bake-off de compresión de la representación de ítems: seis espacios de ítems (PCA lineal frente al AE no lineal $\times$ dimensión latente 32 / 64 / 128), cada uno evaluado bajo el *mismo* readout congelado **gru-infonce-h256** sobre la partición next-distinct (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos; paired- Δ vs el control AE-64 del mismo lote). Las seis tuvieron éxito. R@10, MRR, artist@10 y genre@10 mejor cuanto más alto. Ganador (PCA-128) en negrita; mejor celda por métrica en negrita. *No comparable con ninguna tabla de rotación.*

Espacio	Run id	R@10 [IC 95 %]	paired- Δ vs AE-64	M
PCA-128 (ganador)	run-20260715-042100-a1d9d	0.1146 [0.099, 0.132]	+0,0189 [+0,004, +0,034]	0.1146
PCA-64 (segundo)	run-20260715-042100-8851d	0.1041 [0.088, 0.121]	+0,0084 [−0,005, +0,022] (empate)	0.1041
AE-64 (control)	run-20260715-042059-dd261	0.0957 [0.081, 0.111]	— (control)	0.0957
AE-128	run-20260715-042059-e96ae	0.0929 [0.078, 0.108]	−0,0028 [−0,015, +0,009] (empate)	0.0929
AE-32	run-20260715-042059-d3f9e	0.0545 [0.043, 0.066]	−0,0412 [−0,055, −0,027]	0.0545
PCA-32	run-20260715-042059-b1242	0.0412 [0.031, 0.052]	−0,0545 [−0,069, −0,041]	0.0412

Cuadro 19: Barrido de familia de modelos de la Fase 2 sobre los espacios PCA ricos, ordenado por R@10 (mejor cuanto más alto). El z-blend fijo es el combinador de referencia; el stacker XGB aprendido rinde muy por debajo. Fila campeona y campeón previo en negrita; mejor celda por métrica en negrita. El Δ pareado es por sesión contra la referencia nombrada. *No comparable con ninguna tabla de rotación.*

Modelo	Run id / fuente	R@10 [IC 95 %]	MRR	Δ pareado
R+M+C, PCA-192 (fila camp.)	analyze_rmc (A4)	0.1859 [0.166, 0.207]	0.1025	vs camp. +0,0133 [+0,001, +0,026]
R+M+C, PCA-128	analyze_rmc (A2)	0.1824 [0.162, 0.203]	0.0993	vs camp. +0,0098 (empate)
R+M, AE-64 (campeón previo)	run-20260714-170928-645ae	0.1726 [0.154, 0.192]	0.0963	— (referencia)
R+M, PCA-192	run-20260715-142440-96f53	0.1712 [0.151, 0.192]	0.0952	vs camp. −0,0014 (empate)
R+M, PCA-128	run-20260715-044920-36dce	0.1670 [0.148, 0.187]	0.0920	vs camp. −0,0056 (empate)
LSTM single, PCA-128	run-20260715-142440-546d0	0.1272 [0.110, 0.145]	0.0495	vs GRU-128 +0,0126 (> 0)
GRU single, PCA-192	run-20260715-142440-89d6a	0.1230 [0.106, 0.140]	0.0534	vs GRU-128 +0,0084 (empate)
ANN pooled-MLP, PCA-128	run-20260715-142440-7e528	0.0901 [0.076, 0.105]	0.0394	vs GRU-128 −0,0245
XGB stacker M+G, PCA-128	run-20260715-142440-371b1	0.0867 [0.073, 0.101]	0.0493	vs GRU-128 −0,0280
XGB stacker M+G+A, PCA-192	run-20260715-142440-f111d	0.0853 [0.071, 0.099]	0.0490	vs GRU-192 −0,0377

Cuadro 20: Nivel A1 de la campaña de ajuste-a-la-literatura: la proyección de contenido aprendida sobre PCA-192, frente al campeón R+M+C (1431 sesiones de prueba; IC bootstrap al 95 %; Δ pareado por sesión vs el campeón). Ganador ($R'+M+C'$) en negrita; mejor celda por métrica en negrita. *No comparable con ninguna tabla de rotación.*

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	Δ pareado vs campeón
R+M+C campeón (tercios)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	— (referencia)
$R'+M+C'$ (ambas proyectadas)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	+0,0259 [+0,012, +0,041] > 0
R+M+C+C' (4 ramas)	0.2061 [0.185, 0.227]	0.1148	0.345	0.410	+0,0203 [+0,013, +0,029] > 0
R+M+C' (cambia C→C')	0.1971 [0.177, 0.218]	0.1107	0.334	0.400	+0,0112 [−0,000, +0,023] cand.
C' proj-contenido (sim, r192)	0.1516	0.0708	0.305	0.401	vs C no-sup. 0.0685: +0,083
C' two-tower dir. (r192)	0.1349	0.0552	0.291	0.393	gana simétrica

Cuadro 21: Las vías de ajuste-a-la-literatura que se cerraron: cada método prestado no logra superar al z-blend fijo campeón (1431 sesiones de prueba; Δ pareado del blend por sesión vs el campeón).

Vía	R@10 en solitario	Δ del blend vs campeón	Veredicto
Suavizado KN de Markov (Nivel A2)	0.1069→0.1104	−0,0021 (cruza 0)	nulo en el blend
Combinador de ranking, <i>oráculo</i> (B1)	0.1901 (blend)	+0,0042 (cruza 0)	sin margen honesto
Fusión de ranking RRF (B1)	0.1572 (blend)	−0,029 (IC<0)	perjudica recall
V-SKNN kNN de sesión (B2)	0.0671	−0,038 (IC<0)	arrastra (solo cálidos)
Negativos por importancia GRU (C)	0.1230→0.1279	−0,0014 (empate)	se diluye

Cuadro 22: El barrido de ablación on-server de objetivo / rango / τ (6 celdas, ordenadas por recall@10). Todas superponen la definición promovida; hit@10 = recall@10 por construcción. Campeón promovido (default, mantenido) en negrita; mejor celda por métrica en negrita (todas de la celda sub-ruido τ -0,10).

Config	recall@10	MRR	art@10	gen@10	run id
S2 infonce / full / τ 0,10	0.2229	0.1273	0.3424	0.4032	run-20260718-193111-a781c
infonce / full / τ 0,07 (promovido, mantenido)	0.2117	0.1220	0.3326	0.4011	run-20260718-191539-1b89c
S3 infonce / rank 64 / τ 0,07	0.2055	0.1169	0.3326	0.3990	run-20260718-193650-66c96
S1 infonce / full / τ 0,05	0.1929	0.1111	0.3354	0.3997	run-20260718-192443-57432
S4 bpr / full / τ 0,07	0.1579	0.0939	0.3187	0.3913	run-20260718-194228-4cc06
S5 bpr / rank 64 / τ 0,07	0.1523	0.0909	0.3194	0.3906	run-20260718-194832-d070f

Cuadro 23: Endurecimiento en segunda partición sobre la partición disjunta de holdout-temprano con 0.64 de fríos seq-20260718-211238 (1431 sesiones de prueba; solo-validación). Métricas puntuales (arriba) y el Δ pareado por sesión (abajo, bootstrap de 2000 remuestreos, semilla 1337). Campeón de proyección en negrita.

Config	recall@10	MRR	art@10	gen@10	run id
$R'+M+C'$ campeón de proyección	0.1705	0.1050	0.2991	0.3417	run-20260718-212639-50e1d
Coronación R+M+C (referencia primaria)	0.1279	0.0816	0.2956	0.3410	run-20260718-213156-cf1dd
R+M 2 ramas (referencia de contexto)	0.1174	0.0791	0.2844	0.3368	run-20260718-214114-93bad
Δ pareado recall@10 (proyección – referencia):					
PROY vs R+M+C (primaria)	+0,0426	[+0,0280, +0,0573] — enteramente > 0; MRR +0,0234 (sin regresión)			
PROY vs R+M (contexto)	+0,0531	[+0,0391, +0,0678] — enteramente > 0			

Cuadro 24: Exploración de representación del vector de ítem: ocho espacios de ítems de 192-d alternativos vs el campeón PCA-192, bajo readout A (proyección campeona) y readout C (GRU congelada). Δ pareado sobre hit@10 exacto (bootstrap de 2000 remuestreos, rng 1337) vs la línea base del mismo readout; una mejora necesita el IC enteramente > 0. Filas de línea base y la mejor mejora de readout C (V5) en negrita. *No comparable con ninguna tabla de rotación.*

Variante (espacio)	dataset id	Readout A (proyección)		Readout C (GRU congelada)	
		R@10	Δ hit@10 [IC]	R@10	Δ hit@10 [IC]
full — PCA-192 (línea base)	seq-20260715-131139	0.2117	(línea base)	0.1230	(línea base)
V1 noaco	seq-20260718-222742	0.2089	−0,0028 [−0,013, +0,008]	0.1481	+0,0252 [+0,009, +0,041]
V2 std (whiten todo)	seq-20260718-222754	0.2082	−0,0035 [−0,015, +0,008]	0.1530	+0,0300 [+0,011, +0,049]
V3 std-noaco	seq-20260718-222807	0.2166	+0,0049 [−0,008, +0,017]	0.1572	+0,0342 [+0,015, +0,055]
V4 textcat	seq-20260718-222820	0.1950	−0,0168 [−0,029, −0,006]	0.1565	+0,0335 [+0,015, +0,051]
V5 balanced-pca192	seq-20260718-222834	0.2159	+0,0042 [−0,006, +0,015]	0.1586	+0,0356 [+0,019, +0,052]
V7 std-txtcatup	seq-20260718-222848	0.2055	−0,0063 [−0,019, +0,006]	0.1488	+0,0259 [+0,006, +0,046]
V10 text-only	seq-20260718-222901	0.1999	−0,0119 [−0,025, +0,001]	0.1377	+0,0147 [−0,005, +0,034]
V6 sonic-64 (64-d)	seq-20260718-222905	0.1936	−0,0182 [−0,031, −0,005]	0.1216	−0,0014 [−0,017, +0,013]

Cuadro 25: music@10 por familia de predictor, del backfill offline sobre los 53 runs de pista siguiente (una partición compartida de 1431 casos). El campeón de recall@10 (**seq-blend**) *no* es el campeón de music@10 (**seq-nexttrack**). Mejor celda por columna en negrita.

Familia de predictor	runs	mejor recall@10	mejor music@10	music@10 medio
seq-blend	23	0.223	0.461	0.441
seq-nexttrack	24	0.159	0.482	0.448
seq-markov	1	0.107	0.407	0.407
seq-ann	1	0.090	0.426	0.426
seq-stacker	3	0.087	0.418	0.411
seq-popularity	1	0.001	0.185	0.185

Cuadro 26: Huella de holisticidad de la Fase A a través de la familia de modelos, ordenada por Recall@10 (1431 sesiones de test). Todos los runs comparten el prefijo run-20260722-165345-; la columna id lista el sufijo distintivo. Recall@10 (aciertos crudos de 1431), MRR, artist@10, genre@10, music@10, mood_coh@10, ild@10 mejor-mayor; **artist_adj@10 mejor-menor**. Fila del campeón y mejor celda por métrica en negrita. [†] Los valores extremos de artist_adj@10 / ild@10 del suelo de popularidad son *degenerados* (ignora la semilla): aterrizas ≈ 0 recall y mood_coh@10 negativo, probando que las métricas no se juegan bajo/alto por un buen modelo.

Config	id	R@10 (crudo)	MRR	art@10	gen@10	mus@10	artadj@10↓	mood@10↑	ild@10↑
A1 campeón $R'+M+C'$	82a8f	0.2117 (303)	0.122	0.333	0.401	0.454	0.610	0.398	0.406
A2 R+M (blend)	28dbb	0.1712 (245)	0.095	0.329	0.398	0.443	0.579	0.399	0.403
A3 GRU sola ($\beta=0$)	e39c9	0.1230 (176)	0.053	0.338	0.450	0.456	0.347	0.479	0.454
B LSTM (resto igual a A3)	bb387	0.1188 (170)	0.049	0.328	0.455	0.449	0.344	0.458	0.463
A4 markov (primer orden)	047cc	0.1069 (153)	0.069	0.298	0.389	0.407	0.543	0.310	0.462
A5 popularidad	34614	0.0007 (1)	0.001	0.014	0.085	0.185	0.003[†]	-0,041	0.898[†]

Cuadro 27: Barrido MMR λ de la Fase C sobre el campeón, computado offline desde su checkpoint (mmr_pool 200; 1431 sesiones de test). Recall@10 (aciertos crudos), MRR, artist@10, music@10, mood_coh@10, ild@10 mejor-mayor; **artist_adj@10 mejor-menor**. Mejor celda por métrica en negrita; recall / MRR del default del campeón ($\lambda=\text{off}$) en negrita.

λ	R@10 (crudo)	Δ vs off	MRR	art@10	mus@10	artadj↓	mood↑	ild↑
off (1.0)	0.2117 (303)	—	0.122	0.333	0.454	0.610	0.398	0.406
0.9	0.2103 (301)	-0,0014 (EMPATE)	0.121	0.341	0.462	0.603	0.391	0.436
0.7	0.1936 (277)	-0,0181	0.116	0.347	0.476	0.571	0.364	0.520
0.5	0.1642 (235)	-0,0475	0.108	0.359	0.487	0.486	0.315	0.653
0.3	0.1097 (157)	-0,1020	0.100	0.358	0.492	0.293	0.238	0.815

Cuadro 28: Barrido del regularizador anti-eager β de la Fase D sobre la GRU individual (eager_margin 0,0; 1431 sesiones de test). Recall@10, artist@10, mood_coh@10, ild@10 mejor-mayor; **artist_adj@10 mejor-menor**. Mejor celda por métrica en negrita.

run id	β	R@10 (crudo)	MRR	art@10	artadj↓	mood↑	ild↑
run-20260722-165345-e39c9	0.0	0.1230 (176)	0.053	0.338	0.347	0.479	0.454
run-20260722-165345-353b5	0.05	0.1237 (177)	0.053	0.337	0.346	0.478	0.455
run-20260723-002044-af11a	0.1	0.1202 (172)	0.053	0.335	0.344	0.477	0.456
run-20260723-002044-17cf8	0.2	0.1202 (172)	0.051	0.336	0.340	0.475	0.458

Cuadro 29: Continuación multi-paso de la Fase E (arnés -m 3 -k 10, 1172 casos) sobre seq-20260715-131139: la GRU (checkpoint A3) supera al bigrama de Markov de primer orden en ambas métricas (mejor-mayor). Ganador en negrita.

Modelo	suffix_recall@10	cont_prec@10
markov (bigrama de primer orden)	0.0869	0.0236
GRU (gru-infonce-h256, A3)	0.0963	0.0273

Cuadro 30: Escaneo de emparejamiento de vistas $\times$ profundidad de fusión en torre doble, diez ejecuciones sobre `seq-20260715-131139` (1431 sesiones de prueba), ordenadas por Recall@10. Todas las ramas comparten el prefijo de run-id `run-20260725-143502-`; C0 es `run-20260725-143143-97c1e`. El Δ pareado es un bootstrap pareado por sesión contra C0 (2000 remuestreos, rng 1337). Recall@10 en crudo = aciertos de 1431; los límites del IC se dan con tres decimales, y un IC que cruza cero es un *empate*. Los códigos de rama llevan el par de vistas (lat=`latent`, del=`delta`, cum=`cummean`) y la profundidad de fusión (`-f0` = lectura lineal; en otro caso, una cabeza MLP de 256). R@10, MRR, mus@10, ild@10 mejor cuanto más alto; **artadj@10 mejor cuanto más bajo**; H es la generación *de 3 factores* de holisticidad (Sección 17). Mejor celda por métrica en negrita. [†] El artadj@10 / H extremos de D-CC *no* son una corona real: se compran con 95 de 1431 aciertos, 0,0566 por debajo de la línea base, incumpliendo el piso de recall de $\pm 0,015$ por $3,8\times$.

Rama	id	params	R@10 (crudo)	Δ vs C0 [IC 95 %]	MRR	mus@10	artadj↓	ild↑	H↑
C0 h256 <i>base</i>	97c1e	394944	0.12299 (176)	—	0.05341	0.4558	0.3474	0.4536	0.14172
C1 h425 <i>ctrl</i>	be11b	871017	0.12089 (173)	−0,0021 [−,011, +,006]	0.05215	0.4597	0.3640	0.4506	0.13850
D-LL-f0 <i>lat/lat</i>	18b4a	789696	0.11880 (170)	−0,0042 [−,013, +,004]	0.05631	0.4553	0.3630	0.4506	0.13774
D-LC-f0 <i>lat/cum</i>	3e5d4	789696	0.11740 (168)	−0,0056 [−,017, +,005]	0.05087	0.4458	0.3557	0.4630	0.13648
D-LL <i>lat/lat</i>	12fe6	871872	0.10273 (147)	−0,0203 [−,035, −,007]	0.04235	0.4446	0.3092	0.4873	0.14635
D-LC <i>lat/cum</i>	a95c5	871872	0.09713 (139)	−0,0259 [−,039, −,013]	0.03901	0.4380	0.2997	0.4913	0.15000
D-LD <i>lat/del</i>	8d214	871872	0.09154 (131)	−0,0315 [−,045, −,018]	0.04029	0.4385	0.2999	0.4988	0.14673
D-DC <i>del/cum</i>	e9cfb	871872	0.08665 (124)	−0,0363 [−,050, −,022]	0.03379	0.4125	0.2319	0.5413	0.16340
D-CC <i>cum/cum</i>	88a4c	871872	0.06639 (95)	−0,0566 [−,072, −,041]	0.02664	0.3935	0.1899[†]	0.5235	0.19715[†]
D-DD <i>del/del</i>	4324f	871872	0.05800 (83)	−0,0650 [−,082, −,049]	0.02819	0.4016	0.2363	0.5457	0.13335

Cuadro 31: Atribución de vistas: cada celda mixta contra *ambos* de sus padres de vista única (Δ pareado de Recall@10, 1431 sesiones). Solo uno de los tres pares mixtos es genuinamente complementario — y es precisamente el que no tiene torre de latentes crudos.

Celda mixta	vs padre 1	vs padre 2	Veredicto
D-LC <i>lat/cum</i>	D-LL: −0,0056 [−,018, +,007]	D-CC: +0,0308 [+0,018, +,045]	<i>no</i> complementario
D-LD <i>lat/del</i>	D-LL: −0,0112 [−,023, +,001]	D-DD: +0,0335 [+0,020, +,047]	<i>no</i> complementario
D-DC <i>del/cum</i>	D-DD: +0,0287 [+0,015, +,043]	D-CC: +0,0203 [+0,008, +,034]	complementario: ambos IC>0

Cuadro 32: Presencia $\times$ colocación $\times$ dosis del pre-codificador, diez ejecuciones sobre seq-20260715-131139 (1431 sesiones de prueba), ordenadas por Recall@10. Todas las ramas comparten el prefijo run-20260726-161801-; C0 es run-20260726-161429-bdcbc. El Δ pareado es un bootstrap pareado por sesión contra C0 (2000 remuestreos, rng 1337); los límites del IC se dan con tres decimales, y un IC que cruza cero es un *empate*. Los códigos de rama dual dan las anchuras de pre-codificador de las dos torres (A0/B256 = torre A desnuda, torre B rectificada con anchura 256) y la profundidad de fusión. Aquí H es la generación *de 4 factores* (anclada) de holisticidad y **no** es comparable con la columna de 3 factores de la Tabla 30 (Sección 17). Mejor celda por métrica en negrita; **artadj@10 mejor cuanto más bajo**. [†] El artadj mínimo de T4 y el ild máximo de T1 son el familiar intercambio de des-eagerizar-prediciendo-peor: ambos quedan $\sim 0,025$ por debajo de C0 en recall.

Rama	id	params	R@10 (crudo)	Δ vs C0 [IC 95 %]	MRR	mus@10	artadj↓	ild↑	H↑
C2 h454 <i>ctrl</i>	7646d	969 936	0.12509 (179)	+0,0021 [−,007, +,011]	0.05389	0.4572	0.3668	0.4466	0.045765
T1-f0 A0/B256, f0	a6423	888 256	0.12369 (177)	+0,0007 [−,012, +,013]	0.05470	0.4575	0.3627	0.4616	0.044541
C0 h256 <i>base</i>	bdcbc	394 944	0.12299 (176)	—	0.05341	0.4558	0.3474	0.4536	0.047086
C1 h297 <i>ctrl</i>	7bab3	494 697	0.11321 (162)	−0,0098 [−,017, −,003]	0.05199	0.4513	0.3602	0.4474	0.045285
S1 preMLP256	ad53f	493 504	0.10901 (156)	−0,0140 [−,027, −,001]	0.04463	0.4499	0.3240	0.4815	0.047132
C3 <i>dual desn.</i>	0df6f	871 872	0.10273 (147)	−0,0203 [−,035, −,007]	0.04235	0.4446	0.3092	0.4873	0.046612
T2 A0/B128, f1	dc7d2	847 424	0.09993 (143)	−0,0231 [−,037, −,009]	0.04490	0.4415	0.3039	0.4939	0.046431
T3 A0/B384, f1	ca0b8	1 093 440	0.09993 (143)	−0,0231 [−,037, −,009]	0.04333	0.4441	0.3068	0.4961	0.045895
T4 A256/B256, f1	bd5b5	1 068 992	0.09783 (140)	−0,0252 [−,039, −,011]	0.03829	0.4343	0.2845[†]	0.4986	0.043985
T1 A0/B256, f1	9450b	970 432	0.09713 (139)	−0,0259 [−,040, −,013]	0.04176	0.4369	0.2962	0.5016[†]	0.045769

Cuadro 33: La curva de dosis, tal como se midió: Δ Recall@10 pareado contra la rama de torre doble desnuda C3 con `fusion_layers = 1`. Plana según la prueba pre-registrada — pero nominalmente descendente, nunca ascendente.

pre_hidden_b	Rama	R@10 (crudo)	Δ vs C3 (desnuda)
0	C3	0.10273 (147)	—
128	T2	0.09993 (143)	−0,0028 [−,015, +,009] cruza cero
256	T1	0.09713 (139)	−0,0056 [−,019, +,008] cruza cero
384	T3	0.09993 (143)	−0,0028 [−,015, +,011] cruza cero

Cuadro 34: La regresión de `fusion_layers`, tres mediciones independientes. Δ Recall@10 pareado de la rama de lectura lineal menos su gemela con cabeza MLP; positivo significa que quitar el MLP de fusión *ayuda*. La columna ΔH solo está disponible para los dos pares de 3 factores del mismo lote. *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md (filas 1–2), 2026-07-26-nexttrack-pre-encoder-scan.md (fila 3).*

Par (f0 – f1)	Régimen	Δ R@10 [IC 95 %]	ΔH [IC 95 %]
D-LL-f0 – D-LL	vistas redundantes, sin pre-codificador	+0,0161 [+0,0021, +0,0301]	−0,0086 [−0,0116, −0,0055]
D-LC-f0 – D-LC	vistas complementarias, sin pre-codificador	+0,0203 [+0,0063, +0,0335]	−0,0135 [−0,0171, −0,0100]
T1-f0 – T1	con pre-codificador por paso	+0,0266 [+0,0140, +0,0391]	—

Cuadro 35: Resolución medida de la partición de prueba. Los semianchos son medias sobre las nueve comparaciones de bootstrap pareado del lote del pre-codificador (2000 remuestreos, $n = 1431$); el rango de familia es el recorrido completo de ese lote en cada métrica. «Niveles» es rango/semiancho, es decir, cuántos escalones genuinamente distinguibles pueden ocupar ocho ramas adyacentes. *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md, 2026-07-26-nexttrack-pre-encoder-scan.md.*

Métrica	semiancho del IC con $n = 1431$	rango de familia	niveles	n para $\Delta = 0,005$
Recall@10	0.0124	0.0280	~ 2 de 8	~ 8800
holisticness@10	0.0018	0.0031	~ 1 de 8	—

Cuadro 36: Los mismos modelos bajo las tres generaciones de holisticidad, ordenados por Recall@10. El efecto de generación empequeñece al efecto de modelo, y el orden es aproximadamente *inverso* al de Recall@10 en todo el rango — razón por la cual la tabla de clasificación de pista siguiente sigue denominada en Recall@10. Los guiones son ejecuciones cuyas facetas no pudieron re-derivarse bajo esa generación (ejecuciones solo remotas sin fichero de predicciones materializado). *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md, 2026-07-26-nexttrack-pre-encoder-scan.md.*

Modelo (run)	R@10 (crudo)	gen-1 (3-f)	gen-2 (4-f)	gen-3 (actual)
blend $R' + M + C'$ (1c1a3)	0.21174 (303)	0.0632	0.020830	0.00860
GRU única h454 (7646d)	0.12509 (179)	—	0.045765	0.02399
GRU única h256 (97c1e, bdcabc)	0.12299 (176)	0.14172	0.047086	0.02454
GRU única h425 (be11b)	0.12089 (173)	0.13850	0.046677	0.02487
S1 pre-MLP→GRU (ad53f)	0.10901 (156)	0.14499	0.047132	0.02410
D-CC <i>cum/cum</i> (88a4c)	0.06639 (95)	0.19715	0.050436	—
mood-session (degen.)	0.02380 (34)	0.23319	0.043881	0.00000

Cuadro 37: La frontera de MMR λ sobre ambas anclas, partición canónica seq-20260715-131139 ($n = 1431$), ordenada por `holisticness@10`. Todo run id es run-20260726- más una hora de lanzamiento y un sufijo hexadecimal, en orden de rama: 184115-bf395 (B3), 184115-1dc77 (A4), 184116-20d9b (B4), 184115-147a6 (B2), 184115-e1539 (B1), 183333-9a0b2 (B0), 184115-7a2f7 (A3), 184115-36edb (A2), 184115-6cb38 (A1), 183333-1c361 (A0); las ramas A son seq-blend y las B seq-nexttrack. Cada Δ es un bootstrap pareado (2000 remuestreos, rng 1337) contra el control $\lambda = 1,0$ de la propia rama, con las cinco facetas re-agregadas sobre el mismo conjunto de índices remuestreado antes del producto; los límites del IC se dan a tres decimales por ancho. Códigos de nivel: *t1* NIVEL-1 GRATIS, *t2* NIVEL-2 CON PRECIO, *t3* NIVEL-3 RECHAZADA, *ctrl* el control $\lambda = 1,0$ de la propia rama. La faceta que liga — la que entra en el factor de eagerness por el `max()` — es `conc` en A0/A1/A2 y B0, y `adj` en todas las demás. H@10, R@10, `mus` (= `music@10`) e `ild` mejor cuanto más alto; `adj`, `conc` mejor cuanto más bajo. Mejor celda por métrica en negrita; la rama promocionable B4 en negrita completa. `mood_coh` se omite por ancho y se lee en la interpretación: B0→B3 0,4788→0,4585 (−4 %) frente a A0→A4 0,3982→0,2378 (−40 %), el colapso del campeón bajo diversificación. *Fuente: 2026-07-26-nexttrack-mmr-lambda-frontier.md.*

Rama	λ /pool	H@10	ΔH [IC 95 %]	R@10 (aciertos)	$\Delta R@10$ [IC 95 %]	mus	ild	adj / conc
B3 <i>t2</i>	0.7 / 200	0.034171	+0,0096 [+0,008, +0,011]	0.11461 (164)	−0,0085 [−0,016, −0,001]	0.4747	0.5314	0.313 / 0.271
A4 <i>t3</i>	0.3 / 200	0.031626	+0,0230 [+0,021, +0,026]	0.10971 (157)	−0,1019 [−0,120, −0,084]	0.4925	0.8146	0.293 / 0.190
B4 <i>t1</i>	0.7 / 50	0.030355	+0,0058 [+0,005, +0,007]	0.12020 (172)	−0,0029 [−0,008, +0,003]	0.4670	0.5017	0.327 / 0.302
B2 <i>t1</i>	0.8 / 200	0.029458	+0,0049 [+0,004, +0,006]	0.11950 (171)	−0,0036 [−0,009, +0,001]	0.4648	0.4961	0.330 / 0.307
B1 <i>t1</i>	0.9 / 200	0.026761	+0,0022 [+0,002, +0,003]	0.12089 (173)	−0,0021 [−0,006, +0,002]	0.4597	0.4716	0.341 / 0.337
B0 <i>ctrl</i>	1.0 / 200	0.024539	—	0.12299 (176)	—	0.4558	0.4536	0.347 / 0.356
A3 <i>t3</i>	0.5 / 200	0.023576	+0,0150 [+0,013, +0,017]	0.16422 (235)	−0,0473 [−0,061, −0,033]	0.4871	0.6527	0.486 / 0.461
A2 <i>t2</i>	0.7 / 200	0.015289	+0,0067 [+0,006, +0,008]	0.19357 (277)	−0,0181 [−0,029, −0,008]	0.4759	0.5201	0.571 / 0.608
A1 <i>t1</i>	0.9 / 200	0.010435	+0,0018 [+0,001, +0,002]	0.21034 (301)	−0,0013 [−0,008, +0,005]	0.4625	0.4362	0.603 / 0.671
A0 <i>ctrl</i>	1.0 / 200	0.008603	—	0.21174 (303)	—	0.4538	0.4064	0.610 / 0.692

Cuadro 38: Cinco barridos de `hold@20`, bootstrap pareado sobre semillas (2000 remuestreos, rng 1337) con un jackknife de dejar-una-semilla-fuera (“LOO” es el número de reajustes que preservan el veredicto). Un Δ positivo favorece a la rama de torre doble. La regla pre-registrada era CONFIRMADO si y solo si el IC queda enteramente sobre cero y el veredicto sobrevive $\geq 90\%$ de los reajustes LOO; EMPATE si el IC abarca. S2 y S3 cumplieron esa regla y aun así fueron *retirados* — véase la interpretación. *Fuente: 2026-07-27-rollout-hold-metric.md.*

#	Barrido	n	$\Delta \text{hold@20}$ [IC 95 %]	LOO	Veredicto
S1	piloto, semillas de ánimo extremo, prefijo de 10	8	−0,034 [−0,138, +0,079]	0/8	EMPATE
S2	piloto, semillas de ánimo extremo, prefijo de 30	8	+0,314 [+0,107, +0,529]	8/8	<i>retirado</i>
S3	réplica, semillas aleatorias	39	+0,122 [+0,044, +0,201]	39/39	<i>confundido</i>
S4	control de misma partición	39	+0,033 [−0,030, +0,093]	0/39	EMPATE
S4b	misma partición, otro checkpoint doble	39	+0,051 [−0,012, +0,118]	0/39	EMPATE
S4c	intra-arquitectura	39	−0,072 [−0,141, −0,002]	—	significativo
S5	las 11 playlists del propio usuario	11	+0,004 [−0,088, +0,104]	0/11	EMPATE
—	la única playlist juzgada	1	+0,379 (0,623 / 0,245)	—	atípico

Cuadro 39: El lote de `markov_gate`, seis runs desde la definición campeona `blend-gru-markov-content-proj`. `ds1` = seq-20260715-131139 (canónica, 55 % frío), `ds2` = seq-20260718-211238 (disjunta, 64 % frío); el recall absoluto de `ds2` es menor *por construcción*, así que léase solo a través del Δ pareado. Todo run id es run-20260728- más el valor de la columna *run*. Las métricas graduadas también siguen a la compuerta: artist@10 0,333→0,367 y genre@10 0,401→0,463 de C1 a A1, y 0,382 / 0,497 en A3. Filas ordenadas por recall@10. H@10 es de generación 3 (Sección 17.2). R@10, MRR, H@10, mus@10, ild, mood mejor cuanto más alto; adj, conc mejor cuanto más bajo. Mejor celda por métrica en negrita entre las ramas de la partición canónica; la nueva fila de mejor recall A1 en negrita completa. *Fuente: 2026-07-27c-nexttrack-markov-gate-confirm.md.*

id	run	ds	cambios	R@10 (aciertos)	MRR	H@10	mus@10	ild	adj	conc	mood
A1	005349-507bb	ds1	comp.	0.23201 (332)	0.13352	0.018699	0.49319	0.43377	0.57477	0.59821	0.46226
A3	012030-6d1b7	ds1	comp. + $\lambda 0.7$	0.21314 (305)	0.12852	0.030980	0.51649	0.56770	0.51279	0.47325	0.41885
C1	004444-b32ea	ds1	— (camp.)	0.21174 (303)	0.12199	0.008603	0.45379	0.40637	0.60971	0.69165	0.39822
C3	011245-bfc67	ds1	solo $\lambda 0.7$	0.19357 (277)	0.11560	0.015289	0.47592	0.52010	0.57135	0.60823	0.36433
A2	010658-39e20	ds2	comp.	0.19008 (272)	0.11801	0.008414	0.42953	0.41401	0.58672	0.64847	0.42618
C2	010113-e2599	ds2	— (camp.)	0.17051 (244)	0.10498	0.003392	0.39616	0.40177	0.61013	0.71945	0.35364

Cuadro 40: Bootstrap pareado sobre las 1431 sesiones de prueba (2000 remuestreos, rng 1337, apareado por id de fila). ΔH se calcula *producto-de-medias por remuestreo* — las cinco facetas re-agregadas sobre el mismo conjunto de índices remuestreado para ambas ramas, y luego multiplicadas — no como media de productos por fila. n_{disc} cuenta las sesiones cuyo hit@10 cambió siquiera, con el desglose por signo. Un veredicto WIN significa que el IC de recall queda enteramente sobre cero, EMPATE que abarca; los límites se abrevian a cuatro decimales por ancho. *Fuente: 2026-07-27c-nexttrack-markov-gate-confirm.md.*

Comparación	$\Delta R@10$ [IC 95 %]	Veredicto	ΔH [IC 95 %]	n_{disc} (+/-)
A1 – C1 (compuerta, ds1)	+0,02027 [+0,0105, +0,0308]	WIN	+0,010096 [+0,0085, +0,0117]	57 (43/14)
A2 – C2 (compuerta, ds2)	+0,01957 [+0,0105, +0,0301]	WIN	+0,005022 [+0,0039, +0,0062]	56 (42/14)
A3 – C3 (compuerta, $\lambda 0.7$)	+0,01957 [+0,0091, +0,0301]	WIN	+0,015691 [+0,0136, +0,0179]	64 (46/18)
A3 – C1 (comp.+MMR / campeón)	+0,00140 [-0,0119, +0,0147]	EMPATE	+0,022377 [+0,0199, +0,0249]	96 (49/47)
C3 – C1 (solo MMR $\lambda 0.7$)	-,01817 [-0,0294, -,0077]	cuesta recall	+0,006686 [+0,0057, +0,0077]	60 (17/43)

Cuadro 41: La descomposición por bucket, reproducida *nativamente* a través del constructor real de transiciones y agrupada por el soporte de bigramas de entrenamiento n_u del último ítem del prefijo de cada consulta — la cantidad exacta que calcula el puntuador de Markov. recall@10 dentro del bucket, aciertos entre paréntesis. En ambos buckets cálidos las listas top- k de las dos ramas son **idénticas byte a byte**, así que la compuerta es una intervención quirúrgicamente pura de $n_u = 0$ con literalmente cero costo del lado cálido, sobre tres pares control/rama independientes. *Fuente: 2026-07-27c-nexttrack-markov-gate-confirm.md.*

Par	Bucket	n	control	con compuerta	Δ	$\zeta_{\text{top-}k}$ idéntico?
<i>Partición canónica, A1 vs C1</i>						
	$n_u = 0$	795	0.1660 (132)	0.2025 (161)	+0,0365	no
	n_u 1–10	292	0.3116 (91)	0.3116 (91)	+0,0000	SÍ
	$n_u > 10$	344	0.2326 (80)	0.2326 (80)	+0,0000	SÍ
<i>Segunda partición, A2 vs C2</i>						
	$n_u = 0$	892	0.1244 (111)	0.1558 (139)	+0,0314	no
	n_u 1–10	322	0.2578 (83)	0.2578 (83)	+0,0000	SÍ
	$n_u > 10$	217	0.2304 (50)	0.2304 (50)	+0,0000	SÍ
<i>Partición canónica bajo MMR $\lambda 0.7$, A3 vs C3</i>						
	$n_u = 0$	795	0.1472 (117)	0.1824 (145)	+0,0352	no
	n_u 1–10	292	0.2945 (86)	0.2945 (86)	+0,0000	SÍ
	$n_u > 10$	344	0.2151 (74)	0.2151 (74)	+0,0000	SÍ

Cuadro 42: El lote de **eager_beta** $\times$ margen, ocho runs de **seq-dualgru** sobre **seq-20260715-131139** ($n = 1431$). Todo run id es **run-20260730-** más el valor de la columna *run*. m es el margen del hinge y β el peso de la penalización. H@10 es de generación 3 (Sección 17.2). «ep» es la mejor época sobre las épocas realmente ejecutadas; recall@10 es **aciertos**/1431 en todos los casos (C0 0,118798, A1 0,053809, A2 0,013976, B1 0,114605, y 0,118798 en cada rama inerte). **ild** se omite por ancho y se mueve solo en las ramas que disparan (0,4506 en C0, 0,5572 en A1, 0,6762 en A2, 0,4530 en B1, 0,4504 a 0,4506 en las inertes). **mood**, **mus@10**, H@10 mejor cuanto más alto; **conc**, **adj** mejor cuanto más bajo. Las celdas de menor eagerness están en negrita y pertenecen a ramas *degeneradas*, que es para lo que existe el umbral de relevancia. *Fuente: 2026-07-30-eager-margin-calibrated-refutation.md.*

Rama	run	m	β	aciertos	conc	adj	mood	mus@10	H@10	ep	veredicto
C0	175402-cd006	0	0	170	0.370588	0.362963	0.479846	0.455347	0.023785	8/14	CONTROL
A1	181405-53088	0	3	77	0.240717	0.206010	0.346867	0.399997	0.013339	18/24	DEGENERADA
A2	181405-0bc1a	0	12	20	0.133535	0.107687	0.221756	0.358132	0.003569	37/40	DEGENERADA
B1	181405-84da4	0.40	9	164	0.367606	0.364151	0.463440	0.447386	0.021601	15/21	sin efecto
B2	175402-7c304	0.5843	19	170	0.370634	0.363103	0.479955	0.455210	0.023751	8/14	INERTE
B3	184556-b08c1	0.70	35	170	0.370588	0.362963	0.479846	0.455347	0.023785	8/14	INERTE (bit)
B4	175402-0d310	0.8304	92	170	0.370588	0.362963	0.479846	0.455347	0.023785	8/14	INERTE (bit)
B5	184556-47d7b	0.5843	57	170	0.370743	0.363103	0.479955	0.455379	0.023771	8/14	INERTE

Cuadro 43: Estadística pareada contra el control C0 del mismo lote (2000 remuestreos, rng 1337, $n = 1431$). n_{disc} cuenta las sesiones cuyo hit@10 cambió. Los semianchos medidos en las ramas *activas* (0,0080 a 0,0173) coinciden con el 0,0102 previsto por el diseño, así que el instrumento estaba correctamente dimensionado — el eje falló igualmente. *Fuente: 2026-07-30-eager-margin-calibrated-refutation.md.*

Rama	$\Delta_{\text{artist_conc}}$ [IC 95 %]	$\Delta_{\text{music@10}}$ [IC 95 %]	ΔH	n_{disc}	media $ \Delta_{\text{conc}} $
A1	-0,12987 [-0,14354, -0,11605]	-0,05535 [-0,06606, -0,04465]	-0,010445	125	0.191304
A2	-0,23705 [-0,25493, -0,22026]	-0,09721 [-0,11107, -0,08333]	-0,020215	166	0.282895
B1	-0,00298 [-0,01085, +0,00519]	-0,00796 [-0,01411, -0,00194]	-0,002183	62	0.093734
B2	+0,00005 [-0,00028, +0,00039]	-0,00014 [-0,00037, +0,00000]	-0,000034	0	0.000419
B3	+0,00000 [+0,00000, +0,00000]	+0,00000 [+0,00000, +0,00000]	+0,000000	0	0.000000
B4	+0,00000 [+0,00000, +0,00000]	+0,00000 [+0,00000, +0,00000]	+0,000000	0	0.000000
B5	+0,00016 [-0,00031, +0,00068]	+0,00003 [-0,00036, +0,00045]	-0,000014	0	0.000901

Cuadro 44: El tope duro por artista en la superficie de un solo disparo, partición canónica seq-20260715-131139 ($n = 1431$), sobre el campeón desplegado y sobre el campeón más la compuerta de evidencia de la Sección 21. Pareado sobre puntuaciones en caché idénticas bit a bit (2000 remuestreos, rng 1337). H@10 es de generación 3 (Sección 17.2). R@10, MRR, mus@10, ild, H@10 mejor cuanto más alto; conc, adj mejor cuanto más bajo. Mejor celda por métrica en negrita dentro de cada bloque; el candidato de despliegue recomendado (compuerta + tope 3) en negrita completa. *Fuente: 2026-07-30c-artist-cap-measurement.md.*

tope	R@10	aciertos	MRR	conc	adj	ild	mood	mus@10	H@10
<i>Campeón $R' + M + C'$ (desplegado, sin compuerta)</i>									
off	0.211740	303	0.121985	0.691653	0.609713	0.406374	0.398222	0.453790	0.008603
5	0.178896	256	0.119693	0.252613	0.337247	0.563417	0.358768	0.474291	0.027258
3	0.160727	230	0.116915	0.122975	0.215304	0.613641	0.339311	0.476787	0.033862
2	0.138365	198	0.112313	0.061946	0.150384	0.639717	0.328459	0.474317	0.036331
<i>Campeón + markov_gate (el candidato desplegable)</i>									
off	0.232006	332	0.133521	0.598214	0.574773	0.433765	0.462264	0.493189	0.018699
5	0.198463	284	0.131137	0.231338	0.335849	0.580367	0.413910	0.505703	0.040056
3	0.175402	251	0.127788	0.113440	0.217191	0.631939	0.386846	0.505762	0.048063
2	0.150943	216	0.122627	0.057365	0.152690	0.660122	0.368732	0.503767	0.051175

Cuadro 45: El lote de pila de etapas en la superficie de un solo disparo, siete runs sobre seq-20260715-131139 ($n_{\text{test}} = 1431$), ordenados por recall@10. Los run ids son run-20260801- más la hora de bloque y el sufijo hexadecimal, en completo: 003536-eaf81 (C0), 003536-bcedf (C1), 003646-07994 (B), 003646-8cc2d (E), 003646-dbe68 (C), 003536-d612e (D), 003646-6e3bf (A). Códigos de etapa: a = MLP por paso, g = GRU. Cada H@10 se recalculó desde predictions.json bajo la definición viva y coincide exactamente con el valor almacenado. El Δ pareado es contra el control C0 del mismo lote (2000 remuestreos, rng 1337). El MRR@10 truncado y mood_coh se omiten por ancho y siguen de cerca al recall: MRR@10 0,04555 (C0), 0,04579 (C1), y luego 0,02080 a 0,02894 en las cinco ramas de 4 etapas; mood_coh 0,4788 (C0), 0,4856 (C1), y luego 0,3821 a 0,3964. R@10, H@10, mus@10 mejor cuanto más alto; conc, adj mejor cuanto más bajo — y las celdas de menor eagerness pertenecen a ramas *refutadas*, que es para lo que existe el umbral de recall. *ild* sube monótonamente a medida que las ramas empeoran (0,4549 en C0, 0,4424 en C1, y luego 0,5112 a 0,5373 en las cinco ramas de 4 etapas) y se omite aquí por ancho. *Fuente: 2026-08-01-stage-stack-topology.md.*

Rama	id	etapas / anchura	params	R@10 (aciertos)	$\Delta R@10$ [IC 95 %]	H@10	conc	adj	mus@10
C0 <i>ctrl</i>	eaf81	gru h256	394 944	0.12439 (178)	—	0.024378	0.3589	0.3482	0.4552
C1 <i>cap.</i>	bcedf	gru h537	1 280 937	0.12159 (174)	−0,00280 [−,0119, +,0056]	0.023418	0.3773	0.3653	0.4556
B	07994	agga h299	1 281 407	0.08595 (123)	−0,03843 [−,0538, −,0231]	0.017558	0.3176	0.2639	0.4264
E	8cc2d	gagg h259	1 277 321	0.08246 (118)	−0,04193 [−,0566, −,0280]	0.021053	0.2704	0.2376	0.4310
C	dbe68	aggg h256	1 283 008	0.07966 (114)	−0,04472 [−,0601, −,0301]	0.021442	0.2626	0.2375	0.4324
D	d612e	gggg h229	1 282 821	0.07687 (110)	−0,04752 [−,0622, −,0328]	0.018529	0.2644	0.2326	0.4222
A	6e3bf	agag h299	1 281 407	0.07058 (101)	−0,05381 [−,0685, −,0391]	0.017374	0.2730	0.2335	0.4168

Cuadro 46: El lote de pila de etapas sobre la caminata generada: 40 sesiones retenidas $\times$ 20 pasos con tope de artista 1, pareado contra el control C0 *del mismo lote* (2000 remuestreos). La cláusula de refutación es « Δ vibe con IC bajo cero y Δ stride_err sin IC bajo cero». *vibe*, *genres*, *ground* mejor cuanto más alto; *stride_err* mejor cuanto más bajo; *drift* mejor cuanto más cerca de cero. Los límites del IC se citan donde el intervalo se separa de cero. *Fuente: 2026-08-01-stage-stack-topology.md.*

Rama	vibe	stride_err	drift	genres	ground	Δ vibe [IC 95 %]	V2
GRU displ. a0.4 s0.0	0.609	0.399	−0,089	9.925	0.345	+0,0376 IC>0	referencia
motor displ. a0.4 s0.3	0.568	0.129	−0,080	10.450	0.357	−0,0033 abarca	puerta
C0 a0.4 s0.3	0.571	0.116	−0,080	10.325	0.344	base	base
C1 gru h537	0.561	0.122	−0,082	10.625	0.359	−0,0100 abarca	indist.
D gggg	0.557	0.122	−0,071	10.225	0.319	−0,0140 [−,0255, −,0022]	REFUTADA $\times 2$
C aggg	0.548	0.113	−0,064	10.250	0.340	−0,0231 [−,0381, −,0084]	REFUTADA
B agga	0.545	0.126	−0,061	9.675	0.335	−0,0258 [−,0421, −,0108]	REFUTADA
E gagg	0.540	0.109	−0,084	9.225	0.335	−0,0316 [−,0494, −,0144]	REFUTADA
A agag	0.534	0.117	−0,085	9.125	0.336	−0,0375 [−,0559, −,0214]	REFUTADA

Cuadro 47: El lote de bancos de torres en S1, diez ejecuciones sobre `seq-20260715-131139` (1431 sesiones de prueba), ordenadas por aciertos. El lote se lanzó en cuatro tandas; cada id de ejecución es `run-20260802-` más la hora de la tanda y el sufijo hexadecimal de la columna id, en detalle: 182050-91b54, 182050-2e6f2, 183404-91e31, 183404-62604, 183404-67185, 190415-1d662, 190415-90866, 190415-b5928, 192627-17502, 192627-836b1. El Δ pareado es un bootstrap pareado por sesión (2000 remuestreos, rng 1337) calculado desde los artefactos `predictions.json` fila a fila; un IC que cruza el cero es un *empate*, y * marca un Δ frente a C1 cuyo IC queda enteramente *por debajo* de cero. d0,1 / d0,0 es el dropout del par D2 / R2 de parámetros idénticos byte a byte. Capacidad: las siete ramas C1, B2, B3, B4, V1, V2 y V3 abarcan 2,996 a 3,007× la línea base h256 (dispersión mutua 0,405 %), D2 y R2 están exactamente en 2,000× y C0 en 1,000×. Códigos de vista: lat=**latent**, cum=**cummean**, del=**delta**. H@10 es la holisticidad de *generación 3* (Sección 17.2), en unidades crudas de pista siguiente. R@10, H@10 y mus@10 mejor cuanto más alto; a_conc es mejor cuanto más bajo, pero es solo de visualización y deliberadamente *no* va en negrita: el eagerness de ninguna rama es una afirmación de esta campaña. Mejor celda por métrica en negrita; C1 y B4 empatan exactamente en R@10 y ambas van en negrita. *Fuente: 2026-08-02-tower-bank-parallel-towers.md.*

Rama	id	views / anchura	params	R@10 (crudo)	Δ vs C0 [IC 95 %]	Δ vs C1	H@10	mus@10	a_conc
C1 <i>ctrl</i>	91e31	1×GRU h512	1 182 912	0.12998 (186)	+0,0070 [−,002, +,016]	—	0.02380	0.4581	0.3825
B4	1d662	lat×4 h211	1 187 700	0.12998 (186)	+0,0070 [−,002, +,017]	+0,0000	0.02446	0.4594	0.3716
D2	62604	lat×2 h256 d0,1	789 696	0.12369 (177)	+0,0007 [−,008, +,008]	−0,0063	0.02426	0.4567	0.3698
C0 <i>base</i>	91b54	1×GRU h256	394 944	0.12299 (176)	—	−0,0070	0.02454	0.4558	0.3559
B3	90866	lat×3 h256	1 184 448	0.12020 (172)	−0,0028 [−,010, +,006]	−0,0098*	0.02358	0.4554	0.3764
R2	2e6f2	lat×2 h256 d0,0	789 696	0.11880 (170)	−0,0042 [−,013, +,004]	−0,0112*	0.02378	0.4554	0.3706
B2	67185	lat×2 h334	1 186 560	0.11880 (170)	−0,0042 [−,013, +,003]	−0,0112*	0.02336	0.4554	0.3799
V3	17502	lat+cum+cum h256	1 184 448	0.11880 (170)	−0,0042 [−,016, +,006]	−0,0112	0.02320	0.4497	0.3581
V2	836b1	lat+cum+del h256	1 184 448	0.11600 (166)	−0,0070 [−,020, +,005]	−0,0140*	0.02245	0.4497	0.3547
V1	b5928	lat×2+cum h256	1 184 448	0.11321 (162)	−0,0098 [−,022, +,001]	−0,0168*	0.02299	0.4500	0.3572

Cuadro 48: El lote de bancos de torres en S2, la caminata generada: 40 sesiones held-out × 20 pasos con tope por artista 1, pareadas contra la C0 *del mismo lote* (2000 remuestreos). El bloque superior es la celda primaria a0,4 / s0,3; el inferior re-mide las dos ramas TRADE en la celda *desplegada* a0,8 / s0,5, donde la cláusula de guardado exige el mismo signo. **vibe**, Δ drift, Δ genres y Δ ground mejor cuanto más alto; **stride_err** mejor cuanto más bajo. Los límites del IC se citan solo donde el intervalo no cruza el cero, como en el informe fuente, y * marca todos esos intervalos — una *ganancia* en Δ drift, una *refutación* en Δ vibe y Δ genres. *Fuente: 2026-08-02-tower-bank-parallel-towers.md.*

Rama	vibe	stride_err	Δ vibe	Δ stride_err	Δ drift	Δ genres	Δ ground
<i>Celda primaria a0,4 / s0,3</i>							
C0 (base)	0.566	0.130	—	—	—	—	—
B2 TRADE	0.567	0.139	+0,0017	+0,0099	+0,0339 [+0,007, +,063]*	−0,225	+0,0044
V3 TRADE	0.556	0.124	−0,0094	−0,0045	+0,0286 [+0,001, +,059]*	−0,450	−0,0024
C1	0.563	0.130	−0,0020	+0,0015	+0,0194	−0,375	+0,0008
D2	0.559	0.129	−0,0065	+0,0005	+0,0104	−0,750	+0,0003
B4	0.566	0.139	+0,0006	+0,0103	+0,0164	−0,775	+0,0004
B3	0.557	0.135	−0,0078	+0,0060	+0,0146	−1,025*	+0,0154
V2 <i>refutada</i>	0.551	0.127	−0,0144 [−,029, −,001]*	−0,0019	+0,0259	−0,025	−0,0148
V1 <i>refutada</i>	0.548	0.119	−0,0174 [−,035, −,001]*	−0,0099	+0,0227	−1,725*	+0,0017
<i>Celda desplegada a0,8 / s0,5 — los dos TRADE se derrumban</i>							
B2 <i>refutada</i>	—	—	−0,0064 [−,012, −,001]*	−0,0107	−0,0052	−0,175	+0,0006
V3 <i>refutada</i>	—	—	−0,0112 [−,017, −,006]*	−0,0074	+0,0043	−0,400	−0,0039