

Engagement de Spotify a partir de Metadatos: Síntesis de Experimentos

22 de julio de 2026

Resumen

Este documento es la síntesis viva de las campañas de predicción de ajuste de gusto (taste-fit); los informes markdown de `experiments/` son el registro primario. El objetivo activo es una señal binaria de *rotación* — ¿ganó una pista una escucha repetida, $\text{play_count} \geq 2$? — predicha a partir de los *metadatos intrínsecos* de una pista solamente (género, artista, popularidad de artista/pista, número de seguidores, año de lanzamiento, tipo de lanzamiento) sobre el corpus de escucha del usuario. La métrica principal es el área bajo la curva ROC (AUC); el objetivo de regresión de magnitud de engagement con el que abrió el laboratorio ($\text{play_count} \times \text{completion_ratio}$, transformado con $\log 1p$) se conserva como un campo científico documentado pero ya no se entrega. El embedding conductual de co-escucha y todos los campos de reproducción/curación quedan deliberadamente excluidos del conjunto de rasgos. Se incorporan abajo cinco campañas de jun-2026; convergen en un único hallazgo — la identidad categórica de artista/género/álbum leída por árboles de gradient boosting supera a toda modalidad densa y a toda familia densa de distancia/margen — y coronaron al primer campeón registrado y promovible del proyecto, `xgboost-classifier-rotation`, con AUC 0,7429 sobre el corpus original DS-META. Tres campañas de jun-12 luego re-plantearon la pregunta de familia sobre un corpus 2026 mayor (un dataset completo de 64-d, 23 529 filas): un bake-off de cuatro familias de clasificadores en el que `xgboost-classifier` vuelve a ganar (AUC 0,7204), `catboost` le sigue dentro de banda, y un `pyramid-mlp` denso queda último; un barrido de seis geometrías de arquitectura que cierra la familia de redes densas para AUC *refutando* la hipótesis de presupuesto; y un bake-off de topología de un nuevo `burn-deep-classifier` en Rust/`burn` que, al alimentar los one-hots de identidad en *crudo*, repara la calibración de la red densa por completo ($\log\text{-loss } 2,0 \rightarrow 0,62$) y eleva su AUC ~ 2 bandas hasta 0,7038 — pero aún queda $\sim 1\text{--}2$ bandas por debajo del nivel de los árboles, con los embeddings de entidad aprendidos famélicos por la baja cardinalidad de identidad. Una séptima campaña luego cierra ese hilo: una re-ejecución pareada del bake-off de topología sobre una matriz de *mayor* cardinalidad de identidad (tope de artista $60 \rightarrow 300$, género $40 \rightarrow 120$) invierte el ranking — `embeddings` ahora *supera* a `mlp` (un vuelco de $+0,0130$ que revierte el resultado previo, confirmando la hipótesis de inanición) — y eleva la red al nivel de los árboles dentro del dataset (AUC 0,7192, dentro de ~ 1 banda de `catboost`), la primera ANN en superar la barra de guardado de rotación, guardada como `burn-deep-embeddings-highvocab`. Una octava campaña luego sondea la palanca inversa y la refuta: el clásico truco de Facebook GBDT $\rightarrow$ LR generalizado a GBDT $\rightarrow$ MLP — entrenar una cabeza fresca sobre los índices de hoja one-hot del árbol campeón congelado — queda $1,8\text{--}2,4$ bandas de ruido *por debajo* del campeón xgboost puro (mejor AUC de cabeza 0,6978) con calibración muy rota, una séptima confirmación convergente de que las representaciones aprendidas apiladas sobre los árboles no ayudan. Una novena campaña luego sondea hasta dónde puede llegar la palanca vigente de resolución de identidad: un barrido de tope de vocabulario sobre el GBDT puro, manteniendo la config campeona congelada y moviendo *solo* la cardinalidad de one-hots de artista/género, halla la palanca *en gran medida agotada* — el primer salto ($60/40 \rightarrow 300/120$) lleva la ganancia, y pasado 300/120 cada paso paga

solo retornos sub-banda; xgboost alcanza un nuevo mejor AUC de linaje single-split 0,7349 en 1000/300 (solo +0,005, ~ 0.4 banda, sobre el ancla — ningún guardado disparó), **catboost** lo sigue, y el punto de vocabulario completo no pudo construirse (techo de memoria del host). La Sección 6 consolida por qué las redes neuronales artificiales rinden estructuralmente peor sobre esta matriz de rasgos densa en one-hot, cómo la red consciente de la representación resuelve el diagnóstico, y cómo suficiente resolución de identidad finalmente hace que la topología de embeddings rinda. Se consolida además una línea de trabajo paralela — recomendación de *pista siguiente* (next-track), evaluada sobre una partición de sesiones sin fugas por recall@10 (Secciones 8–10): un blend de fusión de rankings GRU×Markov supera la barra de co-escucha de primer orden en $\sim +61\%$ de recall@10, y añadir una tercera rama content-kNN sobre un espacio de ítems rico PCA-192 (R+M+C) es la fila «mejor registrada» actual con recall@10 0,1859; una campaña posterior de ajuste-a-la-literatura la supera luego con una *proyección de contenido aprendida* supervisada ($R'+M+C'$) con recall@10 0,2117, robusta a la semilla y endurecida en dos particiones — el primer modelo de ranking de pista siguiente registrado, promovido y servible (Secciones 11–13). Su tarea, métricas y campeón no tienen relación con las tablas de rotación y nunca deben leerse contra ellas.

1. Introducción

Este documento es la síntesis viva de las campañas de experimentos; los informes markdown de **experiments/** son el registro primario. Cada sección transcribe (nunca recalcula) los resultados cuantitativos de una campaña, preserva sus identificadores de ejecución y de dataset de forma literal para trazabilidad, y añade la motivación y la interpretación que los informes escuetos omiten.

Tarea y objetivo. El laboratorio predice el *ajuste de gusto* a partir de los metadatos intrínsecos de una pista sobre el corpus de escucha del usuario. Abrió con un objetivo de regresión de magnitud de engagement — $\text{play_count} \times \text{completion_ratio}$, entrenado contra una transformación $\log 1p$ y remapeado con `expm1` — pero el 2026-06-08 el objetivo activo giró a una señal binaria de *rotación*: $\text{play_count} \geq 2$, es decir, ¿ganó la pista una escucha repetida (Sección 3)? La rotación es la entrada accionable al término de deseabilidad por pista del Playlist Pathfinder, es mucho más aprendible que la magnitud de engagement (los árboles alcanzan $\text{AUC} \approx 0,73$ en rotación frente a $R^2 \approx 0,3$ en engagement), y con una tasa base cercana al 44,5 % está naturalmente repartida para la búsqueda de caminos. El engagement se conserva como campo científico documentado, pero la rotación es el objetivo entregado y toda tabla de abajo es sobre él.

Métricas. Como el objetivo es binario, la métrica principal es el área bajo la curva ROC (AUC, mejor cuanto más alto), la cantidad por la que la tabla de clasificación (Tabla 1) ordena y por la que el grupo de mejores modelos auto-promueve; se reporta junto a log-loss, exactitud y el puntaje de Brier. No obstante, coexisten dos regímenes de métrica distintos en las campañas de rotación. Las campañas abrieron con una lectura de *regresión* — error absoluto medio (MAE), RMSE y R^2 sobre la escala $[0, 1]$ de $P(\text{rotación})$ — y solo después adoptaron la lectura honesta de *clasificación* una vez que el framework ganó un modo binario. El MAE se conserva en la tabla histórica de regresión (Tabla 4) para significancia de banda dentro de familia, pero se documenta allí como *degenerado* sobre un objetivo binario: un SVR de tubo- ϵ puede publicar un MAE engañosamente bajo siendo peor que predecir la media (Sección 5.2), una ilusión que las métricas de clasificación disuelven. Las métricas de porcentaje absoluto (MAPE/medAPE) son indefinidas sobre rotación, ya que la mitad de las etiquetas son exactamente cero. La tabla histórica de engagement, donde el MAE *sí* es la métrica principal natural, se preserva en **PROJECT-FACTS.md**; sus números viven en la escala de engagement $\log 1p$ y no son comparables con nada de abajo.

Rasgos. El espacio de rasgos son los *metadatos intrínsecos* de una pista solamente: género, artista, popularidad de artista/pista, número de seguidores, año de lanzamiento, número de artistas acreditados y tipo de lanzamiento. Las modalidades de embedding denso (word2vec de co-escucha, texto-contenido, acústica y el latente del song-autoencoder de la Sección 5.1) son señales *conductuales o descriptivas*, no identidad categórica, y los predictores basados en payload sobre los one-hots de metadatos son los modelos canónicos aquí. Críticamente, la receta es *libre de fugas*: los campos de reproducción que mecánicamente constituyen o aproximan el objetivo — `play_count`, `completion_ratio`, `skip_rate`, `shuffle_rate`, `distinct_sessions`, y el campo `engagement` degradado mismo — y los campos de curación conductualmente enredados quedan todos excluidos por defecto.

Tres matrices de rasgos. Las tres primeras campañas corrieron sobre el corpus original *DS-META* (12 256 filas, solo metadatos). Las campañas de jun-12 corrieron sobre un corpus 2026 mayor, el dataset *completo de 64-d* (`ds-20260609-204419-p64-s42`, 23 529 filas, 177 columnas: 64 latentes PCA song-AE + 7 numéricos + 106 one-hots de identidad con topes de vocabulario artista 60 / género 40 — la matriz *vocab-60/40*). Una campaña final de jun-12 (Sección 6.8) re-ejecutó sobre una variante *high-vocab* (`ds-20260612-143014-p64-s42`, *mismas* 23 529 filas / semilla de partición 42 / PCA64, difiriendo *solo* en la cardinalidad de identidad: tope de artista 60 → 300, género 40 → 120; 497 columnas incluyendo 426 one-hots — artista 301, género 121, tipo-álbum 4). **Estas son tres matrices no comparables:** DS-META difiere del corpus completo de 64-d tanto en tamaño (12 256 frente a 23 529 filas) como en conjunto de rasgos (solo metadatos frente a +64 latentes AE), y las matrices 60/40 y high-vocab difieren en cardinalidad de identidad (177 frente a 497 columnas). Por tanto los números de AUC nunca deben leerse entre ellas — ni contra el campeón DS-META de 0,7429, ni entre las tablas 60/40 y high-vocab. Cada matriz lleva su propia tabla (Tablas 1, 2 y 3); nada regresó cuando el xgboost 60/40 aterriza en 0,7204, y toda familia puntúa *más alto* sobre la matriz high-vocab más ancha porque la granularidad de identidad extra es señal genuina.

2. Trasfondo: familias de modelos y métricas

Esta sección da la teoría mínima para un lector que conoce ML pero no este repositorio. Está anclada a `PROJECT-FACTS.md` y crece solo cuando una nueva familia de predictores o métrica entra en los informes.

Las familias en juego.

Árboles de gradient boosting (`xgboost`, `xgboost-classifier`, `catboost-classifier`, `ngboost-classifier`)

Un ensamble aditivo de árboles poco profundos, cada uno ajustado al gradiente residual de la etapa previa. Como *regresor* su salida es un promedio de hoja, acotado por el rango de los objetivos de entrenamiento; como *clasificador* emite una probabilidad calibrada a través de un enlace logístico, la forma que gana en rotación. Los árboles parten sobre columnas individuales, así que leen los one-hots dispersos de identidad de artista/género/álbum de una pista *sin pérdida* y capturan interacciones no lineales sin cruces de rasgos manuales — la razón por la que dominan este corpus. `catboost` es una variante GBDT de ordered boosting con árboles simétricos (oblivious) y manejo categórico nativo; sobre este corpus es la segunda familia de árboles legítima, co-líder *en banda* con `xgboost`. `ngboost` es una variante de boosting de gradiente natural que ajusta una *distribución* predictiva

completa; su maquinaria probabilística, pagada con aprendices base poco profundos, le cuesta poder de ranking crudo aquí. El costo de la familia GBDT en general es un ajuste no determinista (el submuestreo y el muestreo de columnas cargan una semilla RNG interna), así que dos ejecuciones con distintas semillas difieren levemente. El campeón registrado `xgboost-classifier-rotation` es de esta familia.

Regresión logística. Log-odds lineal pasado por una sigmoide: un clasificador lineal determinista, regularizado con ℓ_2 . Es el *piso lineal* natural para un objetivo binario — el análogo de ridge en el mundo de la regresión — y sirve como control barato y reproducible sobre el arnés. Al ser una única frontera lineal en un espacio de rasgos denso, difumina la identidad categórica dispersa que los árboles explotan, y aterriza muy por debajo de ellos en rotación.

SVM de kernel / SVC (svc con kernels rbf / lineal / poly / sigmoide). Un clasificador de máximo margen que opera sobre distancias inducidas por kernel entre puntos. Como *regresor* (SVR) sobre un objetivo binario el tubo ϵ -insensible degenera — el origen de la trampa del MAE binario de la Sección 5.2; como *clasificador* de probabilidad propio (SVC) la divergencia se desvanece pero todo kernel aún pierde ante los árboles, porque un modelo de distancia densa / margen grande no puede leer one-hots de identidad dispersos como lo hace una partición de árbol alineada a ejes. El kernel sigmoide es el más débil y es el eco de refutación documentado.

Pyramid-MLP (pyramid-mlp-classifier). Una red neuronal artificial feed-forward con una pila de capas ocultas que se estrecha en “pirámide”, activaciones ReLU y un optimizador Adam, ajustada sobre la matriz de rasgos escalada con StandardScaler. Es el único aprendiz *denso* (cada-entrada-a-cada-unidad-oculta) del proyecto sobre rotación. Como desarrolla en extenso la Sección 6, una red densa es exactamente el régimen que los datos de gusto densos en one-hot combaten: debe aprender pesos densos sobre una entrada mayormente-cero, y aterriza última en el bake-off con una calibración reventada que un barrido de arquitectura prueba que es estructural, no un artefacto de presupuesto.

Red consciente de la representación (burn-deep-classifier). Un clasificador feed-forward en Rust/burn construido para reparar las patologías del pyramid-MLP. Parte la matriz de rasgos en un bloque continuo *estandarizado* (64 PCA + 7 numéricos) y un conjunto de grupos de one-hots de identidad en *crudo* (sin estandarizar; artista, género, tipo-álbum), de modo que el escalador nunca convierte categorías raras en picos atípicos (Sección 6.2). Un enum `topology` selecciona entre un `mlp` denso plano sobre las entradas concatenadas, `embeddings` aprendidos por grupo, y una partición `wide_deep` (una ruta lineal ancha sobre los one-hots junto a una ruta profunda sobre el bloque continuo). Como reporta la Sección 6.7, la representación de one-hots en crudo arregla la calibración por completo y eleva el AUC ~ 2 bandas sobre la pirámide, pero la red aún queda ~ 1 – 2 bandas por debajo del nivel de los árboles, y las variantes de embeddings no ganan nada porque las cardinalidades de identidad aquí son demasiado bajas para alimentarlas.

Red de trasplante AE (burn-ae-classifier). Una red en Rust/burn de dos fases. La Fase 1 pre-entrena un autoencoder para reconstruir el vector de rasgos *completo* ensamblado — el bloque continuo estandarizado junto a los one-hots de identidad en *crudo*, $D=177$ — por error cuadrático medio; la Fase 2 trasplanta el encoder entrenado a un clasificador softmax profundo (encoder $\rightarrow$ latente $\rightarrow$ cabeza $\rightarrow$ logits) y lo afina de extremo a extremo con entropía cruzada. Una bandera `freeze_encoder` elige un extractor de rasgos fijo frente a afinar.

Prueba si un pre-entrenamiento de reconstrucción *no supervisado* entrega al clasificador un latente que los one-hots crudos no le den ya a una red desde cero; como reporta la Sección 6.9, no lo hace — el latente reconstructivo es agnóstico a la tarea, y la familia empata con el `mlp burn-deep` plano sin alcanzar el nivel de los árboles.

Blend Autoencoder-XGBoost (`autoencoder-xgboost`). Un ensamble ponderado $\hat{y} = w \cdot \hat{y}_{ae} + (1 - w) \cdot \hat{y}_{xgb}$ que combina un regresor sobre un latente de song-autoencoder precomputado de 64 dimensiones con un modelo XGBoost de metadatos, con el peso w ajustado en un holdout de entrenamiento. Su propósito era probar si el latente AE denso lleva señal de rotación que los one-hots de metadatos pierden; no lo hace, y el ajustador correctamente lleva $w \rightarrow 0$, colapsando el ensamble a XGBoost solo-metadatos (Sección 5.1).

Por qué un objetivo binario hace degenerado al MAE. Para un objetivo continuo, el error absoluto medio es un resumen fiel de cuán lejos quedan las predicciones de la verdad. Sobre un objetivo $\{0, 1\}$ no lo es: un modelo puede minimizar el MAE abrazando las etiquetas sin importar cómo las *ordena* o *calibra*. Un SVR con un tubo $\epsilon=0,1$ ajusta sus salidas a un escalón de dos niveles cerca de $\{0, 1, 0, 9\}$, quedando solo $\sim 0,1$ de cada etiqueta — un MAE bajo — mientras su ranking es inútil (R^2 negativo). Las métricas que importan para una señal binaria de ajuste de gusto son por tanto las de clasificación:

AUC (área bajo la curva ROC). La probabilidad de que un positivo aleatorio se ordene por encima de un negativo aleatorio; 0,5 es azar, 1,0 es perfecto. Es libre de umbral y de escala, depende solo del *orden* de las probabilidades predichas, y es exactamente la propiedad que el Pathfinder necesita de su término de deseabilidad. Es la métrica principal y la clave de ordenamiento de la tabla.

Log-loss. La log-verosimilitud negativa de las etiquetas bajo las probabilidades predichas; castiga los errores *confiados* severamente y así premia la calibración, no solo el ranking.

Puntaje de Brier. El error cuadrático medio entre la probabilidad predicha y la etiqueta $\{0, 1\}$ — una medida de calibración-y-refinamiento sobre la escala natural $[0, 1]$, mejor cuanto más bajo.

Un modelo que gana en AUC y log-loss y Brier, como lo hace el campeón, gana en ranking y calibración a la vez; el artefacto del MAE binario que adula a un SVR degenerado no aparece en ninguno de ellos. La misma tríada luego expone la patología opuesta en una red densa (Sección 6): un modelo puede publicar un AUC respetable — ranking genuino — mientras su log-loss y Brier son catastróficos, es decir, ordena aceptablemente pero está *confiadamente equivocado*.

Una nota sobre el objetivo logarítmico histórico. El objetivo de regresión inaugural del laboratorio, engagement, es de cola pesada y no negativo, así que se entrenó contra una transformación $\log 1p$ y se remapeó con `expm1`. Ese par de transformación carga un peligro — un modelo no acotado en espacio logarítmico puede producir una gran predicción logarítmica positiva que `expm1` amplifica a un valor enorme, la “explosión de `expm1`” — razón por la cual las familias acotadas por construcción (árboles, kernels rbf) se prefieren sobre las no acotadas (modelos lineales, MLPs) sobre ese objetivo. El engagement sigue siendo un campo documentado y su tabla vive en `PROJECT-FACTS.md`, pero ya no es el objetivo entregado, así que el peligro de explosión es ahora una nota histórica al pie más que una restricción de diseño viva.

3. El giro a rotación: de la magnitud de engagement a una señal binaria de ajuste de gusto

El 2026-06-08 el objetivo activo giró de la magnitud de engagement a una señal binaria de *rotación*, definida como $\text{play_count} \geq 2$ — ¿ganó la pista una escucha repetida? La rotación es la entrada accionable al término `W_FIT` del Playlist Pathfinder, donde una deseabilidad por pista en $[0, 1]$ sesga el camino A^* ; una probabilidad de rotación calibrada es un `fit_norm` más limpio que una estimación de engagement $\log 1p$ -entonces-expm1. La rotación también resulta ser mucho más aprendible que la magnitud de engagement (los árboles de gradient boosting alcanzan $\text{AUC} \approx 0,73$ en rotación frente a $R^2 \approx 0,3$ en engagement) y está naturalmente repartida para la búsqueda de caminos, con una tasa base cercana al 44,5 %. El engagement se conserva como campo científico documentado pero ya no es el objetivo entregado.

El giro es decisivo para cómo debe leerse cada número de abajo. La rotación vive sobre la escala $[0, 1]$, así que su MAE/R^2 *no* son comparables con la tabla de engagement preservada en `PROJECT-FACTS.md`; y como la mitad de las etiquetas de rotación son exactamente cero, las métricas de porcentaje absoluto (MAPE/medAPE) son indefinidas para esas filas. Por tanto coexisten dos regímenes de métrica distintos en las campañas de rotación: una lectura temprana de *regresión* (MAE, RMSE, R^2 , unidades $P(\text{rotación})$) y la lectura honesta posterior de *clasificación* (AUC, log-loss, exactitud, Brier). Como muestran las campañas de abajo, la elección de métrica no es cosmética — bajo MAE un SVR de kernel puede *parecer* competitivo siendo peor que predecir la media, una ilusión que las métricas de clasificación disuelven.

4. Tablas de clasificación de rotación

Cuatro tablas. Las dos primeras son sobre el corpus original DS-META, una por régimen de métrica; la tercera y la cuarta son sobre el corpus completo de 64-d de 2026 mayor. **Ninguna de las tres tablas de AUC es comparable con las otras** — se sitúan sobre tres matrices de rasgos no comparables (DS-META solo metadatos; la matriz *vocab-60/40* completa de 64-d; y la matriz *high-vocab* completa de 64-d, que comparte el corpus, las filas y la partición 60/40 pero eleva los topos de cardinalidad de identidad). Cada tabla lleva sus propias referencias dentro del dataset y nunca debe leerse entre ellas (véase la nota “Tres matrices de rasgos” de la Introducción). La tabla de AUC DS-META lleva el primer campeón de rotación registrado y promovible del proyecto; la tabla 60/40 lleva la definición xgboost registrada del nuevo corpus; la tabla high-vocab lleva la primera ANN en superar la barra de guardado de rotación (Sección 6.8). Finalmente, **todo AUC en las cuatro tablas se mide sobre una partición train/test aleatoria**; una partición cronológica (entrenar-en-anterior, probar-en-posterior) cuenta una historia marcadamente distinta — los números de abajo son cotas superiores del ranking de la misma era, y la habilidad honesta de predicción hacia adelante sobre este corpus es ~ 0.11 de AUC más baja (Sección 7).

5. Campañas

5.1. Blend de latente-autoencoder + XGBoost: una modalidad muerta, aislada

Motivación. Esta fue la primera campaña sobre el objetivo de rotación girado. La hipótesis era que un latente de song-autoencoder precomputado de 64 dimensiones (de la colección Qdrant `spotify_tracks_song_ae`) lleva la *identidad* de una pista de una forma que los one-hots de metadatos no, y que mezclar un regresor sobre el latente AE con un modelo XGBoost de metadatos

Cuadro 1: Rotación, régimen de *clasificación*, **corpus DS-META** — ordenado por AUC (mejor cuanto más alto). El campeón es la única definición registrada y auto-promovida. Datasets: DS-META `ds-20260609-141622-p1-s42` (115 cols, solo metadatos, pca floor); la fila de 178 cols añade las 64 columnas de latente song-AE (`ds-20260608-204402-p64-s42`). Banda de ruido de AUC $2\sigma = 0,0126$.

Modelo	Dataset	AUC	log-loss	exactitud	¿Registrado?
xgboost-classifier (campeón)	DS-META	0.7429	0.5883	0.6846	sí (rango 1)
xgboost-classifier (178, +latente AE)	p64-s42	0.7350	0.6045	0.6818	no
svc (poly $d=3$, mejor no-árbol)	DS-META	0.6855	0.6452	0.6450	no
logistic ($C=1$, piso lineal)	DS-META	0.6762	0.6329	0.6491	no
svc (rbf)	DS-META	0.6722	0.6469	0.6426	no
svc (lineal)	DS-META	0.6363	0.6535	0.6373	no
svc (sigmoide, peor)	DS-META	0.6255	0.6673	0.6267	no

— $\hat{y} = w \cdot \hat{y}_{ae} + (1 - w) \cdot \hat{y}_{xgb}$, con el peso w ajustado en un holdout de entrenamiento — podría superar a XGBoost-metadatos solo. Las seis ramas corrieron sobre `ds-20260608-204402-p64-s42` (64 latente AE + 114 metadatos = 178 cols, 12,256 filas, 9,805/2,451 en semilla 42), variando solo la rama AE (kNN en $k \in \{10, 25, 50, 100, 200\}$, más una rama ridge-sobre-latente).

Resultados. Las seis ejecuciones (`run-20260609-131545-e34e4` y hermanas) tuvieron éxito, y todas devolvieron métricas de blend idénticas byte a byte — MAE 0.38789, R^2 0.191, RMSE 0.4475 — porque el ajustador de peso llevó $w \rightarrow 0$ en cada rama. El único eje que se movió fue el error autónomo de la rama AE mae_{ae} , que creció monótonamente con el tamaño de la vecindad, de 0.4259 en $k = 10$ a 0.4702 en $k = 200$ (la rama ridge aterrizó en 0.4623, entre $k = 100$ y $k = 200$). La Figura 1 muestra la curva contra las tres referencias horizontales que importan: incluso la mejor lectura AE ($k = 10$, 0.4259) nunca alcanza el árbol solo-metadatos (0.3879), ni siquiera el *xgboost* de solo-latente-AE registrado (0.4098).

Interpretación. El colapso a $w = 0$ es la respuesta correcta, no un bug a arreglar: dada una rama AE estrictamente peor que la rama XGB en el holdout, el peso convexo óptimo *es* cero. El único valor real de la arquitectura fue que *aisló* el latente en una rama que el ajustador podía descartar, recuperando un resultado más limpio que alimentar el latente a un XGBoost unificado — lo que de hecho *diluye* el árbol (MAE 0.3965 con las 64 columnas de latente presentes frente a 0.3879 con ellas descartadas). El latente song-AE se une así a la co-escucha, el texto-contenido y los rasgos acústicos como una modalidad densa que pierde ante los one-hots de identidad categórica. La única salvedad en su momento era honestidad sobre la significancia: la ventaja de 0,3879 frente a 0,3965 es de solo 0,0086 de MAE sobre un objetivo $[0, 1]$, y la banda de ruido de rotación estaba entonces sin medir — así que la campaña reportó el número pero no afirmó victoria significativa y no promovió nada. *Fuente: 2026-06-09-ae-xgboost-blend.md.*

5.2. SVM de kernel sobre rotación: una refutación, y la trampa del MAE binario

Motivación. Descartado el latente, esta campaña probó si algún kernel SVM (rbf / lineal / poly / sigmoide) produce un predictor de rotación competitivo con el líder XGBoost solo-metadatos y — solo si alguno pasaba — si añadía señal ortogonal en un blend ponderado por grilla. La matriz de metadatos se redujo al pca floor en un dataset nuevo (`ds-20260609-141622-p1-s42`, 115 cols), con dos hermanas de semilla de partición (semillas 17 y 101) construidas para medir la banda de

Cuadro 2: Rotación, régimen de *clasificación*, **nuevo corpus completo de 64-d** — ordenado por AUC (mejor cuanto más alto). Dataset `ds-20260609-204419-p64-s42` (23 529 filas, 177 cols: 64 PCA song-AE + 7 numéricos + 106 one-hots de identidad). **No comparable con la Tabla 1:** distinto tamaño de corpus y conjunto de rasgos; la única referencia intra-corpus válida es el punto `xgboost 0,7204`, que el `bake-off` reprodujo byte a byte. La config por defecto del ganador se guarda como la definición del nuevo corpus. El mejor del barrido de semilla única (profundidad 8, lr 0.03, 0,7261) está +0,0057 sobre el defecto — dentro de banda — así que se marca para confirmar con 3 semillas, no se promueve. El log-loss del `pyramid-mlp` es su techo de calibración documentado (Sección 6); las filas `burn-deep-classifier` son la red consciente de la representación en Rust/`burn` que lo repara (log-loss $\rightarrow \sim 0.62$) pero aún queda por debajo del nivel de los árboles, así que ninguna se registra (Sección 6.7). Banda de AUC $2\sigma \approx 0,0126$ (estimación del corpus antiguo, aproximada aquí).

Modelo	max_depth/lr	AUC	log-loss	exactitud	Nota
xgboost-classifier (ganador, guardado)	6 / 0.05	0.7204	0.6075	0.6585	registrado
xgboost-classifier (mejor barrido, 1 semilla)	8 / 0.03	0.7261	0.6044	0.6651	marcado,
catboost-classifier (2º árbol, en banda)	6 / 0.05	0.7111	0.6132	0.6560	−0,0093,
burn-deep-classifier (mlp, mejor ajuste)	lr 0.0005 / [128,64]	0.7038	0.6221	0.6521	mejor AN
burn-deep-classifier (mlp, ganador Fase 1)	lr 0.001 / [128,64]	0.7001	0.6211	0.6470	red densa
burn-ae-classifier (trasplante AE, mejor)	enc[128,64]/clf[128,64]	0.6972	0.6216	0.6496	−0,0066 v
ngboost-classifier	—	0.6917	0.6293	0.6392	~ 2.3 band
pyramid-mlp-classifier (mejor arch-scan)	[512,256]	0.6792	2.0584	0.6326	red densa
pyramid-mlp-classifier (bake-off, 300 iter)	[256,128,64]	0.6781	2.4085	0.6326	red densa

ruido, y el campeón reproducido como control (`run-20260609-141717-9a8ba-autoencoder-xgboost`, peso de blend 0). Un resultado secundario fue el entregable central de la campaña: la **primera banda de ruido de rotación medida**.

Resultados. A través de las tres semillas de partición del control XGBoost solo-metadatos (s42 0.387891, s17 0.393072, s101 0.396417) la desviación estándar muestral es $\sigma_{\text{split}} = 0,00430$, dando una banda de significancia 2σ de **0.0086 de MAE** sobre la escala $[0, 1]$. Esto zanja retroactivamente la pregunta abierta de la campaña previa: la ventaja de 0,3879 frente a 0,3965 es $\Delta 0,0086 \approx 1\cdot\text{banda}$ (probablemente mejor, no confiada), mientras que la brecha de 0,3879 frente a 0,4098 (solo-latente-AE) es $\sim 2,5\cdot\text{banda}$ y por tanto real. En cuanto a las ramas SVM, rbf, lineal y poly publicaron todas MAE dentro de la banda del control (0.381–0.390), *más bajo* que el campeón en el caso poly (0.3814) — pero cada una de ellas es peor-que-la-media en R^2 (−0,13 a −0,20), con RMSE 0.53–0.54 contra el 0.4475 del árbol. El SVR sigmoide divergió de plano: MAE 0.624, RMSE 1.531, R^2 −8,48, con predicciones alcanzando 24.7 sobre un objetivo $[0, 1]$ — la clásica explosión del SVR-sigmoide no acotado. La Figura 2 contrasta las dos vistas de métrica directamente.

Interpretación. El MAE de SVR bajo es una degeneración de la métrica sobre un objetivo binario. Con un tubo- ϵ de ancho 0,1 sobre etiquetas $\{0, 1\}$, el SVR colapsa a una función escalón de dos niveles anclada cerca de las clases correctas — cada fila queda a unos 0,1 de su etiqueta, así que el MAE es pequeño, mientras que la calibración y el ranking quedan destruidos (R^2 negativo). La métrica que importa para el `fit_norm` del Pathfinder (ranking y calibración, es decir R^2 /RMSE/AUC) dice que el SVM pierde decisivamente. Peor aún, los dos blends de la etapa 2 (`run-20260609-143114-528ef-blend` y su gemelo `lgbm`) ajustaron pesos de exactamente $[0, 0, 1, 0]$ — la

Cuadro 3: Rotación, régimen de *clasificación*, **matriz high-vocab completa de 64-d** — ordenado por AUC (mejor cuanto más alto). Dataset `ds-20260612-143014-p64-s42` (23 529 filas, 497 cols: 64 PCA song-AE + 9 numéricos + 426 one-hots de identidad — artista 301, género 121, tipo-álbum 4). **No comparable con las Tablas 1 o 2:** comparte el corpus, las filas y la partición 60/40 pero eleva la cardinalidad de identidad (tope de artista 60 → 300, género 40 → 120), así que toda familia se re-ejecutó aquí para un ranking fresco dentro del dataset. Los árboles subieron sobre la matriz más ancha (xgboost 0,7204 → 0,7299, catboost 0,7111 → 0,7252). El **burn-deep-classifier** guardado (**embeddings**) es la primera ANN en alcanzar el nivel de los árboles dentro del dataset y superar la barra de guardado de rotación (Sección 6.8); xgboost es el líder dentro del dataset pero ninguna regla de guardado de árbol disparó esta campaña. Banda de AUC $2\sigma \approx 0,0126$ (estimación del corpus antiguo, aproximada aquí).

Modelo	config	AUC	log-loss	exactitud	Nota
xgboost-classifier (líder intra-dataset)	d6 / lr0.05	0.7299	0.6022	0.6719	no registrado
catboost-classifier (2º árbol)	defaults	0.7252	0.6068	0.6649	−0,0047, en b
burn-deep-classifier (embeddings, mejor Fase 2)	ed8 / lr0.0005	0.7228	0.6105	0.6645	nivel árboles;
burn-deep-classifier (embeddings, <i>guardado</i>)	ed16 / lr0.001	0.7192	0.6087	0.6694	registrado (hi
burn-deep-classifier (mlp)	lr0.001	0.7129	0.6166	0.6617	−0,0063 vs er
burn-deep-classifier (wide_deep)	lr0.001	0.7061	0.6256	0.6526	rezagado, am

Cuadro 4: Rotación, régimen de *regresión*, **corpus DS-META** — ordenado por MAE sobre la escala $[0, 1]$ de $P(\text{rotación})$ (mejor cuanto más bajo). El líder XGBoost solo-metadatos es la rama **mae_xgb** reproducida dentro de cada ejecución de blend; nunca se guardó como definición autónoma. La fila SVM-poly se lista por completitud y está *refutada*: su MAE más bajo es el artefacto del tubo- ϵ de la Sección 5.2, su R^2 es negativo. Banda de ruido de MAE $2\sigma = 0,0086$.

Modelo	MAE	RMSE	R^2	Fuente
XGBoost solo-metadatos (latente AE descartado)	0.3879	0.4475	0.191	ae-blend / svm
xgboost sobre latente+metadatos combinados	0.3965	—	0.166	giro rotación
xgboost sobre solo-latente AE (64 cols)	0.4098	—	0.132	giro rotación
svm (poly, artefacto tubo- ϵ — REFUTADO)	0.3814	0.5303	−0,137	svm

grilla, optimizando el mismo MAE de validación degenerado, *seleccionó mal SVM puro* y descartó el árbol, lo opuesto al auto-deshabilitado visto en la campaña de blend. La lección es contundente: un objetivo de blend por-grilla-por-MAE es en sí inseguro sobre un objetivo binario. Nada se registró ni promovió; el SVM de kernel se volvió la quinta familia de régimen denso en perder ante la identidad one-hot sobre este corpus. *Fuente: 2026-06-09-sum-kernel-rotation.md.*

5.3. El bake-off honesto de AUC y el primer campeón de AUC

Motivación. La campaña SVM expuso que el MAE es la lente equivocada para un objetivo binario. Mientras tanto el framework había ganado un modo de clasificación (`domain.toml task = binary`, métrica principal AUC, mejor cuanto más alto; el grupo de mejores modelos ordena por AUC y auto-promueve la ejecución superior). Esta campaña re-ejecutó la comparación sobre ese pie honesto: xgboost-classifier contra logistic y un barrido de cuatro kernels SVC, todos sobre DS-META, más una rama de 178 columnas con el latente AE re-añadido para zanjar la cuestión




Figura 1: El latente song-AE no lleva ninguna señal de rotación que los one-hots de metadatos no lleven ya mejor. El error autónomo kNN mae_{ae} sube monótonamente conforme se ensancha la vecindad (la señal del latente es más fuerte en vecindades locales estrechas y se diluye hacia la tasa base), e incluso su mejor punto queda por encima tanto del árbol de solo-latente-AE como del árbol solo-metadatos. El ajustador de peso correctamente lleva el peso del blend a cero, así que el ensamble colapsa a XGBoost solo-metadatos.

de dilución del latente sobre el eje AUC, y tres semillas de control para medir la banda de ruido de AUC. La hipótesis — un sexto test del hallazgo convergente — era que xgboost-classifier gana y toda familia densa pierde.

Resultados. Las nueve ejecuciones tuvieron éxito. La config campeona (run-20260609-172920-6 27d6-xgboost-classifier, hiperparámetros de control, semilla 42) alcanzó **AUC 0.7429** (log-loss 0.5883, exactitud 0.6846, Brier 0.2017) y se registró como **xgboost-classifier-rotation** y se auto-promovió a mejores-modelos rango 1 — el primer campeón de rotación del proyecto guardado, puntuado por AUC y promovible. La primera banda de ruido de *AUC* medida viene de las tres semillas de control (s42 0.742934, s17 0.730659, s101 0.734469, media 0.736020): $\sigma_{AUC} = 0.00628$, $2\sigma = \mathbf{0.0126}$ (Figura 4). Esta banda es una métrica distinta de la banda de 0.0086 de MAE y no la reemplaza. Toda familia densa perdió por muchas bandas — svc-poly 0.6855, logistic 0.6762, svc-rbf 0.6722, svc-linear 0.6363, svc-sigmoid 0.6255 — un rango de 4.6 a 9.3 bandas de ruido por debajo del campeón (Figura 3). La rama de 178 columnas (latente AE re-añadido) puntuó 0.7350, -0.0079 por debajo del campeón solo-metadatos — la misma dirección dilutiva que el resultado de regresión, pero dentro de la banda de AUC, así que neutral-tirando-a-dilutivo en una semilla única.

Interpretación. Reencuadrar la rotación como clasificación hizo dos cosas a la vez. Disolvió la ilusión del SVR de la Sección 5.2 — bajo AUC, log-loss y Brier, cada kernel SVC es ahora visiblemente peor que los árboles, todos en la misma dirección, así que el artefacto del tubo- ϵ que hacía parecer competitivo el MAE del SVR simplemente se desvanece. Y confirmó que la métrica solo fue siempre un problema para la *justicia de la comparación*; la familia densa siempre fue la perdedora. Notablemente svc-sigmoid no colapsa al azar bajo clasificación (mantiene AUC 0.6255 en vez de explotar): un objetivo de probabilidad propio quita la divergencia no acotada que arruinó




Figura 2: Sobre un objetivo binario, un MAE de SVR bajo es un artefacto, no habilidad. Con $\epsilon = 0,1$ sobre un objetivo $\{0, 1\}$ el SVR ajusta sus salidas a los bordes del tubo- ϵ (un escalón duro de dos niveles, $p_{50} \approx 0,10$, $p_{90} \approx 0,90$), así que cada fila queda solo $\sim 0,1$ de su etiqueta y el MAE (izquierda) lee competitivo. El R^2 honesto (derecha) lo expone: cada kernel es peor que predecir la media. El sigmoide está fuera de escala en $R^2 = -8,48$.

la ejecución SVR-sigmoide. El hallazgo convergente ahora se sostiene sobre una métrica honesta: la señal de ajuste de gusto vive en la *identidad* de artista/género/álbum, capturada por one-hots dispersos y explotada por árboles, no en modelos densos de distancia o margen. La palanca restante es la *resolución* de identidad — elevar los toques de vocabulario para que la cola `artist=__other__` obtenga columnas reales — no nuevas modalidades ni familias. La próxima campaña planificada es un barrido de hiperparámetros del campeón ahora que la familia y la métrica están zanjadas. *Fuente: 2026-06-09-rotation-classification.md.*

5.4. Bake-off de cuatro familias sobre el nuevo corpus completo de 64-d, y un barrido xgboost de depth/lr

Motivación. Las tres primeras campañas corrieron sobre el corpus original DS-META. Esta campaña re-planteó la pregunta de familia sobre el corpus 2026 mayor — “todo el embedding de 64-d”, la matriz completa de 177 columnas (ds-20260609-204419-p64-s42, 23 529 filas, 64 PCA song-AE + 7 numéricos + 106 one-hots de identidad) — poniendo cuatro familias de clasificadores cara a cara con defectos de registro, semilla 42: `xgboost-classifier`, `catboost-classifier`, `ngboost-classifier` y un `pyramid-mlp-classifier` denso. Las tres últimas son *familias nuevas en este proyecto*. El ganador luego se ganó un barrido de `max_depth`×`learning_rate`. La única referencia intra-corpus válida es una ejecución preexistente sobre este dataset (run-20260609-2047 26-439d8-xgboost-classifier, AUC 0,7204); nada aquí puede leerse contra el campeón DS-META de 0,7429 (distinto corpus y conjunto de rasgos).

Resultados. Las cuatro ramas del bake-off tuvieron éxito (Tabla 5; Figura 5). `xgboost-classifier` (run-20260612-115909-840c0-xgboost-classifier) ganó con AUC 0,7204, reproduciendo la referencia intra-corpus byte a byte (0,720 438 340 3) — la puerta de determinismo pasó.




Figura 3: La métrica de clasificación honesta confirma el hallazgo convergente por sexta vez. xgboost-classifier lee la identidad dispersa de artista/género/álbum de los one-hots sin pérdida; las familias densas de distancia/margen (logistic y los cuatro kernels SVC) difuminan esa identidad en un espacio de rasgos denso y aterrizan de 4.6 a 9.3 bandas de ruido más abajo. La franja sombreada es la banda $2\sigma = 0,0126$ bajo el campeón; ningún retador llega a una banda de él.

catboost-classifier (run-20260612-115909-c7ef6-catboost-classifier) siguió en 0,7111, $-0,0093$ detrás — *dentro* de la banda ~ 0.0126 , así que co-líder y la segunda familia de árboles legítima, no una pérdida. ngboost-classifier (run-20260612-115909-d725b-ngboost-classifier) aterrizó en 0,6917 (~ 2.3 bandas atrás), y el pyramid-mlp-classifier denso (run-20260612-115909-ea698-pyramid-mlp-classifier) fue último en 0,6781 — con un log-loss de 2,4085 y Brier 0,3251 muy por encima de los ~ 0.60 – 0.63 / ~ 0.21 de los árboles, el diagnóstico diseccionado en la Sección 6.

Cuadro 5: Fase 1 — el bake-off de cuatro familias sobre el nuevo corpus completo de 64-d (ds-20260609-204419-p64-s42, semilla 42, defectos de registro). Las cuatro tuvieron éxito. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador en negrita; mejor celda por métrica en negrita.

Rama / run id	Predictor	AUC	log-loss	exactit
C0 (run-20260612-115909-840c0-xgboost-classifier)	xgboost-classifier	0.7204	0.6075	0.658
A1 (run-20260612-115909-c7ef6-catboost-classifier)	catboost-classifier	0.7111	0.6132	0.656
A2 (run-20260612-115909-d725b-ngboost-classifier)	ngboost-classifier	0.6917	0.6293	0.639
A3 (run-20260612-115909-ea698-pyramid-mlp-classifier)	pyramid-mlp-classifier	0.6781	2.4085	0.632

El ganador se ganó un barrido de Fase 2 sobre $\text{max_depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0, 03, 0, 05, 0, 1\}$ (datos en forma de tabla en el informe fuente; Figura 6). La profundidad es el eje dominante: cada celda de profundidad-4 está en el fondo (0.7074–0.7119), y la esquina profundidad-8 / lr-0.03 encabeza la grilla en 0,7261 (run-20260612-120207-2dd3d-xgboost-classifier, log-loss 0,6044). Un learning rate alto (0.1) perjudica consistentemente tanto el AUC como la calibración. Pero la brecha mejor-vs-defecto ($+0.0057$) está *dentro* de la banda, así que la




Figura 4: La primera banda de ruido de AUC de rotación medida. Tres semillas de partición de datos de la config campeona registrada dan $\sigma_{\text{AUC}} = 0,0063$ y una banda de significancia 2σ de 0,0126. En términos relativos es de hecho más estrecha que la banda de MAE (0.85 % frente a 1.10 % de coeficiente de variación), como se espera de una métrica de rango sobre 2,451 filas de prueba. La banda solo importa para la decisión sub-banda de dilución del latente; campeón y retadores están separados por muchas bandas.

config por defecto profundidad-6/lr-0.05 se guardó como la definición del nuevo corpus y la celda profundidad-8/lr-0.03 se marcó para una confirmación de 3 semillas en vez de promoverse.

Interpretación. El hallazgo convergente sobrevive intacto al cambio de corpus: sobre un corpus distinto y mayor con el latente AE presente, las dos familias de árboles vuelven a liderar y la red densa vuelve a ser última. **catboost** se gana su lugar como segunda familia de árboles legítima (co-líder en banda) — un miembro de diversidad-de-árboles / segunda-opinión, no una ganancia de AUC sobre **xgboost**. **ngboost** paga por su maquinaria distribucional: los aprendices base poco profundos (**base_max_depth** 3) sub-ajustan la matriz de 177 columnas densa en one-hot. El AUC de último lugar del pyramid-MLP *más* su log-loss reventado son la firma de red densa; el bake-off leyó el log-loss como un artefacto de sub-entrenamiento de 300 iteraciones y prescribió más presupuesto — una hipótesis que la campaña siguiente prueba y refuta. *Fuente: 2026-06-12-classifier-bakeoff-p64.md.*

5.5. Barrido de arquitectura del Pyramid-MLP: refutando la hipótesis de presupuesto

Motivación. El bake-off marcó el último lugar del pyramid-MLP (AUC 0,6781, log-loss 2,4085) como un artefacto de sub-entrenamiento por el tope de 300 iteraciones, prescribiendo “subir **max_iter** para que la red converja”. Este seguimiento prueba ese mecanismo directamente: seis geometrías de pirámide, todas con **max_iter** subido a **800**, $\alpha 1 \times 10^{-4}$, learning rate 1×10^{-3} , semilla 42, sobre el mismo dataset — de modo que la comparación refleja *arquitectura*, no presupuesto. ¿Alguna geometría, dado el presupuesto para converger, eleva la familia densa a un AUC competitivo?

Resultados. Refutado en todo aspecto (Tabla 6; Figuras 7 y 8). **Ninguna rama alcanzó el tope de 800**: cada geometría se auto-detuvo en **73–100 iteraciones** vía la tolerancia de meseta de pérdida **n_iter_no_change** de sklearn — muy por debajo incluso del viejo tope de 300, así que




Figura 5: El orden de familias sobrevive al cambio de corpus. Sobre la matriz completa de 64-d de 2026 mayor las dos familias de árboles de gradient boosting lideran (**xgboost** ganando, **catboost** co-líder dentro de la banda 2σ sombreada bajo el ganador); **ngboost** queda ~ 2.3 bandas atrás; el **pyramid-mlp** denso es último, el mismo hallazgo convergente visto sobre DS-META en la Figura 3.

el presupuesto nunca fue la restricción vinculante. El indicio decisivo: la rama de re-línea-base M0 ([256,128,64], la geometría del bake-off ahora en `max_iter` 800) reprodujo el AUC de la ejecución sub-entrenada hasta todos los dígitos — 0,678 092 6 frente a 0,678 092 6 — porque corrió las mismas 73 iteraciones. Subir el tope de 300 a 800 no cambió nada. La mejor geometría convergida fue M1 [512,256] con AUC 0,6792 (`run-20260612-123155-0ace5`), un empate estadístico con el defecto sub-entrenado ($+0,0011 \approx$ cero) y ~ 3.3 bandas por debajo de xgboost. Toda la familia aterrizó en una franja de AUC de 0.0080 de ancho (0.6712–0.6792), enteramente dentro de una banda de ruido — el ranking de geometría no es resoluble en una semilla única — con el log-loss (2.06–2.78) y Brier (0.32–0.34) reventados al mismo nivel que el defecto sub-entrenado en cada rama. Ninguna definición se guardó (por debajo de la barra de guardado 0.683).

Cuadro 6: El barrido de arquitectura de seis geometrías del pyramid-MLP (`ds-20260609-204419-p64-s42`, `max_iter` 800, α 1×10^{-4} , lr 1×10^{-3} , semilla 42), ordenado por AUC. Las seis tuvieron éxito; *ninguna* alcanzó el tope de 800 iteraciones — cada una se auto-detuvo en el conteo de iteraciones listado. Mejor celda por métrica en negrita.

Rama	Capas ocultas	AUC	log-loss	Brier	Iters (de 800)
M1 ancha-poco profunda	[512, 256]	0.6792	2.0584	0.3216	75
M0 re-línea-base	[256, 128, 64]	0.6781	2.4085	0.3251	73
M4 estrechamiento suave	[384, 307, 246]	0.6777	2.7764	0.3292	87
M2 pirámide profunda	[256, 128, 64, 32]	0.6737	2.7631	0.3303	100
M3 estrechamiento fuerte	[512, 169, 56]	0.6736	2.7031	0.3365	89
M5 ancha-profunda	[512, 307, 184, 111]	0.6712	2.6457	0.3348	84

Interpretación. La refutación es limpia y doble: ni el presupuesto de entrenamiento (cada rama se auto-detiene muy por debajo del tope; M0 reproduce el AUC sub-entrenado hasta todos los




Figura 6: El barrido xgboost `max_depth`×`learning_rate` sobre el nuevo corpus. La profundidad es la palanca (el AUC sube monótonamente por el eje de profundidad a los learning rates lentos), y un learning rate rápido perjudica. La mejor celda (profundidad 8, lr 0.03, recuadrada) alcanza 0,7261 pero solo +0,0057 sobre el defecto — dentro de la banda 2σ — así que la config por defecto permanece guardada y la mejor celda espera un confirm de 3 semillas.

dígitos) ni la arquitectura (las seis geometrías dentro de una banda) mueven la familia densa. El log-loss alto no es por tanto una trayectoria de entrenamiento truncada sino un genuino *techo de calibración* a estos hiperparámetros — la meseta elegida por el optimizador. Con las propias perillas de la familia densa agotadas, la restricción vinculante debe estar en otra parte: en la *representación* de entrada, el tema de la Sección 6. La tendencia direccional dentro de familia — más ancho-y-poco-profundo levemente favorecido (M1 arriba), profundidad/capacidad levemente dañina (M5 ancha-profunda última) — es consistente con una red densa luchando por encaminar señal a través de 106 one-hots dispersos: capas extra añaden capacidad para memorizar y difuminar, no para separar. La familia está cerrada para AUC sobre este conjunto de rasgos; no re-escanear geometría ni presupuesto. *Fuente: 2026-06-12-pyramid-mlp-arch-scan.md.*

6. Por qué las redes neuronales artificiales rinden peor sobre datos de gusto densos en one-hot

El `pyramid-mlp` denso es la única red neuronal artificial en las campañas de rotación, y a lo largo de dos campañas de jun-12 aterriza última con un patrón de fallo distintivo. Esta sección consolida, rigurosamente, *por qué* — anclando cada afirmación en la evidencia de las campañas. La versión corta es el *hallazgo convergente* documentado del proyecto: sobre esta matriz de rasgos la restricción vinculante es la *representación* de entrada, y una red densa es la única clase de modelo estructuralmente desajustada a ella. Construimos el argumento en cinco partes y cerramos con el siguiente paso motivado.




Figura 7: Ambas perillas de la familia densa están agotadas. *Izquierda*: las seis geometrías aterrizan dentro de una única banda 2σ alrededor del defecto sub-entrenado — la arquitectura no es la restricción vinculante. *Derecha*: cada geometría se auto-detiene en 73–100 iteraciones, muy por debajo incluso del viejo tope de 300 (por no hablar del subido a 800), así que el *presupuesto* de entrenamiento tampoco fue nunca la restricción vinculante. El optimizador alcanza una meseta de pérdida de la que no puede escapar a este learning rate y se detiene. La restricción vinculante es la *representación* de entrada.

6.1. La matriz de rasgos es mayormente identidad dispersa

La matriz completa de 64-d tiene 177 columnas, y su *composición* es toda la historia. **106 de las 177 columnas son one-hots dispersos de identidad**: artista ($\times 61$), *genre_primary* ($\times 41$) y *album_type* ($\times 4$). Solo 71 columnas son continuas — los 64 latentes PCA song-AE y 7 campos numéricos de metadatos (popularidades, número de seguidores, año de lanzamiento, número de artistas acreditados). Para una pista dada exactamente una columna de artista, una de género y una de tipo-álbum está activa; el resto de las 106 son cero. La matriz está, por construcción, dominada por un bloque mayormente-cero de indicadores mutuamente excluyentes.

Un árbol de gradient boosting lee este bloque *sin pérdida y barato*: una única partición alineada a ejes sobre la columna *artist=X* divide los datos exactamente sobre esa identidad, sin forzar ninguna interacción entre los one-hots y sin costo pagado por las columnas que son cero. Capturar “las pistas del artista *X* en el género *Y* rotan” le cuesta al árbol dos particiones anidadas. Una red densa no puede hacer esto. Debe aprender un peso *denso* desde cada una de las 106 entradas mayormente-cero hacia cada unidad oculta, y luego extraer una combinación no lineal — gastando capacidad y señal de gradiente modelando la estructura de un bloque que el árbol maneja con una comparación. Este es precisamente el régimen en el que los árboles dominan estructuralmente a las redes densas, y es el *hallazgo convergente* del proyecto, ahora observado a través de cuatro modalidades de rasgos y cinco familias de modelos: la señal de ajuste de gusto la lleva la identidad de artista/género, capturada por one-hots y explotada por árboles, no por atributos descriptivos ni modelos de distancia/margen/densos. El pyramid-MLP es simplemente el turno de la familia densa de perder ante ella.

6.2. La estandarización convierte categorías raras en picos atípicos

La red densa se alimenta con una matriz escalada con StandardScaler, y la estandarización interactúa patológicamente con los one-hots dispersos. Una columna one-hot para una categoría presente en una fracción p de filas tiene media p y desviación estándar $\sqrt{p(1-p)}$. Estandarizarla mapea las filas “encendidas” a

$$z_{\text{on}} = \frac{1-p}{\sqrt{p(1-p)}} = +\sqrt{\frac{1-p}{p}}, \quad z_{\text{off}} = \frac{0-p}{\sqrt{p(1-p)}} = -\sqrt{\frac{p}{1-p}}.$$

Para una categoría *rara* — la cola larga de artistas y géneros, donde p es pequeño — el valor “encendido” $+\sqrt{(1-p)/p}$ se vuelve un gran pico positivo (para $p = 0,01$ es $\approx +9,9$), mientras el valor “apagado” queda en un diminuto negativo $-\sqrt{p/(1-p)} \approx -0,1$. Cada identidad rara llega por tanto a la red como un atípico ocasional y enorme sobre su propio eje. Las unidades ReLU con Adam a learning rate 1×10^{-3} oscilan fuerte sobre estos picos — una única activación de categoría rara produce una gran pre-activación que el optimizador persigue — y la cabeza softmax/sigmoide se satura, emitiendo probabilidades cerca de 0 o cerca de 1 sobre evidencia delgada. Los árboles son inmunes: un umbral de partición sobre un one-hot es invariante a cualquier reescalado monótono, así que el pico del escalador no les hace nada. Este es un contribuyente mecánico directo a la calibración reventada documentada a continuación.

6.3. La firma diagnóstica: ranking genuino, calibración rota

El fallo de la red densa tiene una firma precisa y reproducible en las métricas — y *no* es el fallo de un modelo débil. El pyramid-MLP publica AUC $\approx 0,68$ (0.6781 en el bake-off, 0.6792 el mejor en el barrido de arquitectura): señal de ranking genuina, bien por encima de la línea de azar de 0.5, solo ~ 3 bandas por debajo de los árboles. Pero *al mismo tiempo* su log-loss es $\approx 2,0$ – $2,8$ y su Brier $\approx 0,32$ – $0,34$, contra el log-loss $\approx 0,60$ – $0,63$ y el Brier $\approx 0,21$ de los árboles (Figura 8). **El log-loss de la red de 2.0–2.8 es así mucho peor que la línea base aleatoria, mientras que el 0.61 de xgboost está muy por debajo de ella.**

Esta combinación — ranking aceptable, log-loss peor-que-el-azar — significa que la red está *confiadamente equivocada*: empuja muchas predicciones a los extremos saturados (cerca de 0 o cerca de 1) del lado equivocado de la etiqueta, y el log-loss castiga cada error confiado así severamente. Está mal calibrada, no débil: el ordenamiento está ahí, pero las probabilidades adjuntas a ese ordenamiento son inutilizables como un `fit_norm`. El mecanismo es exactamente la saturación por pico del escalador de la Sección 6.2. Contrasta con los árboles, cuyas salidas de frecuencia de hoja están calibradas por construcción: una hoja que reporta probabilidad q es la frecuencia empírica de rotación de las filas de entrenamiento que caen en ella, así que las probabilidades del árbol son honestas por diseño — la razón por la que gana en log-loss y Brier además de AUC.

6.4. Optimización frente a representación: la restricción vinculante

Una objeción natural es que la red está meramente sub-optimizada — muy pocas iteraciones, la geometría equivocada. El barrido de arquitectura (Sección 5.5) descarta ambas. Sobre el eje de *presupuesto*, cada una de las seis geometrías se auto-detiene en 73–100 iteraciones, muy por debajo incluso del viejo tope de 300 (por no hablar del subido a 800): el optimizador alcanza una meseta de pérdida de la que no puede escapar, así que más presupuesto no compra nada — la rama de re-línea-base M0 reprodujo el AUC sub-entrenado hasta todos los dígitos porque corrió las




Figura 8: El diagnóstico de red densa: la red está confiadamente equivocada, no meramente débil. *Izquierda:* en AUC el pyramid-MLP genuinamente ordena (≈ 0.68 , bien por encima del azar, ~ 3 bandas bajo los árboles) — hay señal real en su ordenamiento. *Derecha:* pero su log-loss (≈ 2.0 – 2.8) es mucho *peor* que la línea base de tasa base aleatoria (≈ 0.69 , punteada), mientras los árboles quedan muy por debajo de ella (≈ 0.61). Un modelo que ordena aceptablemente pero puntúa un log-loss peor-que-el-azar está emitiendo probabilidades confiadas y mal calibradas.

mismas 73 iteraciones. Sobre el eje de *arquitectura*, las seis geometrías aterrizan dentro de una única banda de ruido, y la mejor geometría convergida reproduce el AUC sub-entrenado a cuatro dígitos (0.6792 frente a 0.6781). Ambas perillas internas a la familia densa están por tanto agotadas. Por eliminación, la restricción vinculante no es ni presupuesto ni arquitectura sino la *representación* de entrada — los one-hots crudos de la Sección 6.1, que la red no puede consumir como lo hace un árbol. Este es el diagnóstico que apunta a topologías conscientes de la representación (embeddings de entidad, wide-and-deep) como la única palanca sin probar, ya que están diseñadas precisamente para reemplazar one-hots crudos con una representación densa aprendida.

6.5. PCA ya se ha anticipado al trabajo no lineal de la red

Hay una segunda razón por la que la red densa tiene poco que hacer. Los 64 latentes PCA song-AE ya son una compresión *lineal*, *decorrelacionada* de un embedding de 1536 dimensiones: PCA ha extraído la estructura lineal dominante y entregado a la red componentes ortogonales con la mayor parte de la varianza lineal fácil ya separada. Cualquier interacción no lineal que una capa oculta pudiera descubrir en ese bloque ha sido en gran medida anticipada; poca estructura no lineal queda para que la profundidad de la red explote. La evidencia es directa: una regresión logística simple alcanza AUC 0.676 sobre este corpus y el MLP convergido alcanza 0.679 — un empate técnico. Una red ReLU multicapa no compra esencialmente nada sobre una única frontera lineal, que es exactamente lo que uno espera cuando el bloque continuo ya está linealmente pre-condicionado y el bloque categórico es la parte que lleva señal que la red no puede leer.

6.6. La pregunta abierta y el siguiente paso motivado

El diagnóstico es ahora agudo: el techo de la red densa lo fija su incapacidad de consumir identidad one-hot cruda, no el presupuesto, la arquitectura ni el bloque continuo. Eso aísla una única pregunta abierta y comprobable — *¿puede una topología consciente de la representación cerrar la brecha con los árboles?* Los dos ingredientes que apuntan al diagnóstico directamente son (i) **embeddings de entidad** para los grupos de identidad (artista, género, tipo-álbum), que reemplazan cada bloque one-hot disperso con un vector denso de baja dimensión aprendido — el arreglo estándar para categóricos de alta cardinalidad en redes, eliminando tanto el problema de pesos-densos-sobre-ceros de la Sección 6.1 como el problema del pico del escalador de la Sección 6.2; y (ii) una partición **wide-and-deep** — una ruta lineal ancha sobre los one-hots (para que la identidad se lea directamente, como la lee el árbol) junto a una ruta profunda sobre el bloque continuo. Una implementación en Rust/`burn` de tal red consciente de la representación — el **burn-deep-classifier** — se construyó precisamente para responder esta pregunta. La Sección 6.7 reporta sus resultados, y resuelven el diagnóstico limpiamente: la patología de calibración fue de hecho un artefacto de representación y está arreglada, pero la brecha de AUC con los árboles solo se *estrecha*, no se cierra.

Fuentes: 2026-06-12-classifier-bakeoff-p64.md, 2026-06-12-pyramid-mlp-arch-scan.md.

6.7. Resuelto: el burn-deep-classifier arregla la calibración pero no la brecha de AUC

Motivación. Las subsecciones precedentes dejaron una única pregunta abierta aguda: el techo de la red densa lo fija su incapacidad de consumir identidad one-hot cruda, así que *¿puede una topología consciente de la representación cerrar la brecha con los árboles?* El **burn-deep-classifier** — una red enteramente en Rust/`burn` — se construyó para responderla. Su diseño apunta directamente a las dos patologías diagnosticadas: mantiene los one-hots de identidad en *crudo* (estandarizando solo el bloque continuo de 64 PCA + 7 numéricos), de modo que el mecanismo de pico del escalador de la Sección 6.2 nunca dispare, y expone un enum `topology` sobre un `mlp` denso plano, **embeddings** de entidad aprendidos, y una partición **wide_deep**. La Fase 1 comparó las tres topologías (épocas 250, patience 20, early-stop sobre log-loss de validación, hidden [128, 64], embed_dim 8, lr 1×10^{-3} , batch 256); la Fase 2 ajustó al ganador. Las nueve ejecuciones corrieron sobre el mismo dataset completo de 64-d (`ds-20260609-204419-p64-s42`) y tuvieron éxito limpiamente.

Resultados. El titular es la recuperación de calibración (Figura 9). Cada topología aterriza en log-loss 0,621–0,628 y Brier 0,217–0,220 — de lleno en el régimen ~ 0.60 – 0.63 / ~ 0.21 de los árboles — contra el log-loss 2,0–2,4 y Brier 0,33 de la pirámide `sklearn`. **La patología de calibración está arreglada por completo.** Sobre el eje de topología (Tabla 7), el `mlp` plano gana con AUC 0,7001, con **embeddings** (0,6934) y **wide_deep** (0,6918) ambos dentro de la banda $2\sigma = 0,0126$ de él y entre sí — **embeddings** roza a **wide_deep** por un sub-banda +0,0016. El ajuste `mlp` de la Fase 2 (Tabla 8) tope en AUC 0,7038 (lr 5×10^{-4} , [128, 64]): la grilla de 6 celdas completa es una franja de 0,0081 de ancho (0,6957–0,7038), cada celda [128, 64] supera a cada celda [256, 128], y la mejor config es solo +0,0037 (dentro de banda) sobre el ganador de la Fase 1, así que la config `mlp` de la Fase 1 se mantiene. En 0,7038 la red queda $-0,0073$ bajo `catboost` (~ 0.6 banda) y $-0,0166$ bajo `xgboost` (~ 1.3 bandas); por debajo de la barra de guardado ~ 0.71 , así que ninguna definición se persistió.

Interpretación. El resultado resuelve la pregunta abierta de la Sección 6.6 en dos partes, y las dos respuestas apuntan en direcciones opuestas. Primero, el veredicto de *calibración* se revierte: el log-loss peor-que-el-azar del pyramid-MLP de la Sección 6.3 fue un artefacto de *representación*

Cuadro 7: Fase 1 — el bake-off de topología del `burn-deep-classifier` (`ds-20260609-204419-p64-s42`, params fijos: épocas 250, patience 20, hidden [128,64], embed_dim 8, dropout 0.1, lr 1×10^{-3} , batch 256, relu; el único eje es `topology`). Las tres tuvieron éxito. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador en negrita; mejor celda por métrica en negrita.

Rama / run id	Topología	AUC	log-loss	exactitud	Brier
T-mlp (<code>run-20260612-140116-41fc9-burn-deep-classifier</code>)	mlp	0.7001	0.6211	0.6470	0.2179
T-emb (<code>run-20260612-140116-0eda4-burn-deep-classifier</code>)	embeddings	0.6934	0.6251	0.6436	0.2179
T-wd (<code>run-20260612-140116-e85be-burn-deep-classifier</code>)	wide_deep	0.6918	0.6281	0.6407	0.2179

Cuadro 8: Fase 2 — ajuste de la topología `mlp` ganadora, una grilla `lr×hidden` (otros params fijos). Las seis tuvieron éxito, ordenadas por AUC; ganador en negrita, mejor celda por métrica en negrita. Toda la grilla está dentro de una banda de ruido, cada celda [128,64] supera a cada celda [256,128], y la mejor ganancia sobre el ganador de la Fase 1 (+0,0037) es sub-banda — así que la config de la Fase 1 es la config de registro.

Run id	lr	hidden	AUC	log-loss	exactitud	Brier
run-20260612-140211-6575a-burn-deep-classifier	0.0005	[128,64]	0.7038	0.6221	0.6521	0.2179
run-20260612-140211-21ad5-burn-deep-classifier	0.002	[128,64]	0.6997	0.6227	0.6532	0.2179
run-20260612-140211-18c9e-burn-deep-classifier	0.001	[128,64]	0.6996	0.6213	0.6447	0.2179
run-20260612-140211-fecb0-burn-deep-classifier	0.0005	[256,128]	0.6966	0.6232	0.6424	0.2179
run-20260612-140211-4c359-burn-deep-classifier	0.002	[256,128]	0.6963	0.6245	0.6460	0.2188
run-20260612-140211-0f4e1-burn-deep-classifier	0.001	[256,128]	0.6957	0.6252	0.6424	0.2188

— one-hots crudos aplastados en el estandarizador — no una propiedad intrínseca de las redes densas sobre datos de gusto, y una red que mantiene los one-hots crudos está calibrada en el régimen de los árboles. La lectura anterior de “calibración rota es un techo fijo” se sostiene solo para la representación pirámide-sklearn. El AUC también se recuperó: el 0,7038 de la red burn es +0,025 sobre la mejor pirámide convergida (0,6792), ~ 2 bandas de ganancia genuina de poder de ranking, así que la conclusión previa de que “la familia MLP está cerrada para AUC en $\approx 0,68$ ” se revisa — una red Rust de one-hots crudos alcanza ~ 0.70 . Segundo, y en contra de la lectura optimista, el arreglo de representación *no* alcanza el nivel de los árboles: en 0,7038 la red aún queda ~ 1 banda bajo `catboost` y ~ 1.3 bajo `xgboost`. La brecha se estrechó dramáticamente (de las ~ 3.3 bandas de la pirámide a ~ 1) pero no se cerró, así que el hallazgo convergente sobrevive intacto — los árboles aún leen los one-hots dispersos de identidad un pelo más efectivamente que incluso una red de one-hots crudos. La comparación de topología lo afila: que el `mlp` plano supere tanto a la variante de embedding como a la `wide-deep` es la *misma* lección de “la identidad ya está en los one-hots” que enseñaron las campañas de árboles, ahora reproducida dentro de la familia ANN — los embeddings aprendidos por grupo tienen poco que añadir sobre 61 one-hots de artista y 41 de género, y la palanca vigente para la red (como para los árboles) es la *resolución* de identidad: elevar los toques de vocabulario y la topología de embeddings debería por fin empezar a rendir — una predicción que la re-ejecución high-vocab de la Sección 6.8 luego confirma, volcando `embeddings` por encima de `mlp` y elevando la red al nivel de los árboles. Ninguna definición se guardó aquí (por debajo de la barra ~ 0.71); la red es una línea base densa fuerte, ahora honesta, y un miembro de ensamble natural por su sesgo inductivo decorrelacionado, no un campeón. *Fuente:*




Figura 9: La red consciente de la representación resuelve la pregunta abierta de la Sección 6.6. *Izquierda:* las tres topologías están dentro de una banda 2σ entre sí; el **mlp** plano gana y los **embeddings** de entidad apenas rozan a **wide_deep**, porque a estas cardinalidades de identidad (artista 61, género 41, tipo-álbum 4) los embeddings aprendidos están famélicos — rinden a cientos-o-miles de categorías, no docenas (una hipótesis que la Sección 6.8 confirma elevando los topes). *Derecha:* el titular. Mantener los one-hots en *crudo* baja el log-loss del $\approx 2,0$ de la pirámide sklearn (confiadamente mal calibrada, peor que la línea base aleatoria) a $\approx 0,62$, al régimen de los árboles — una confirmación limpia de que la patología de calibración fue un artefacto de representación, no una propiedad intrínseca de las redes sobre estos datos.

2026-06-12-burn-deep-topology.md.

6.8. Confirmado: elevar la cardinalidad de identidad eleva la red de embeddings al nivel de los árboles

Motivación. La Sección 6.7 cerró con una predicción aguda y comprobable: la topología de **embeddings** de entidad perdió ante el **mlp** plano *solo* porque las cardinalidades de identidad (artista 61, género 41) eran demasiado bajas para alimentar un embedding aprendido, así que elevar los topes de vocabulario debería voltear el ranking. Esta campaña es la re-ejecución pareada que lo prueba directamente. Se construyó una matriz nueva (ds-20260612-143014-p64-s42) *idéntica* al dataset 60/40 completo de 64-d de la Sección 6.7 — mismas 23 529 filas, misma semilla de partición 42, PCA64 idéntico byte a byte — difiriendo en *un* eje solo: la cardinalidad de identidad, con el tope de artista elevado 60 $\rightarrow$ 300 (50,4% de cobertura) y **genre_primary** 40 $\rightarrow$ 120 (78,8%). Es una *tercera* matriz no comparable (497 columnas: 64 PCA + 9 numéricos + 426 one-hots — artista 301, género 121, tipo-álbum 4 — frente a las 177 de la matriz 60/40), así que todas las métricas aquí son referencias frescas dentro del dataset y nunca deben leerse contra las tablas 60/40 o DS-META. La pregunta titular: con la cardinalidad $5\times$ (artista) y $3\times$ (género) mayor, ¿ahora **embeddings** supera a **mlp**? La Fase 0 re-ejecutó los dos árboles para un nivel de árboles dentro del dataset; la Fase 1 re-ejecutó el bake-off de topología (la rama embeddings ahora en embed_dim 16, ya que la mayor cardinalidad justifica una tabla más ancha); la Fase 2 ajustó la

topología ganadora sobre `embed_dim × lr`.

Resultados. El ranking **se volteó** (Tabla 9; Figura 10). `embeddings` (`run-20260612-143411-e8db6-burn-deep-classifier`) gana con AUC 0,7192, con `mlp` en 0,7129 (+0,0063) y `wide_deep` último en 0,7061 (+0,0131). Sobre la matriz 60/40 `mlp` había superado a `embeddings` por +0,0067; aquí `embeddings` supera a `mlp` por +0,0063 — un **vuelco de** +0,0130 a favor del embedding, cruzando la banda, la reversión cualitativa que la hipótesis de inanición predijo. La Fase 0 muestra que ambos árboles también subieron sobre la matriz más ancha: `xgboost` 0,7204 → 0,7299 (+0,0095, `run-20260612-143411-02fda-xgboost-classifier`, log-loss 0,6022) y `catboost` 0,7111 → 0,7252 (+0,0141, `run-20260612-143411-8f15e-catboost-classifier`), así que el vocabulario alto es señal genuina para toda familia — no le entrega al embedding una ventaja única, *desbloquea* una topología que antes estaba famélica. El ajuste de la Fase 2 sobre `embed_dim × lr` (mejor `embed_dim` 8 / `lr` 5×10^{-4} , AUC 0,7228, `run-20260612-143508-3310f-burn-deep-classifier`) muestra que la victoria vino de *habilitar* `embeddings` más un learning rate más lento, no de una tabla más ancha: el AUC es monótono-decreciente en `embed_dim` al `lr` lento (`ed8` 0,7228 > `ed16` 0,7210 > `ed32` 0,7200, un rango sub-banda de $\sim 0,0028$), así que `embed_dim` ya está saturado en 8. La mejor celda ajustada supera al ganador de la Fase 1 por solo +0,0036 (sub-banda), así que la regla de decisión guardó la config de la *Fase 1* (`embeddings`, `embed_dim` 16, `lr` 1×10^{-3}) como **`burn-deep-embeddings-highvocab`**. Un gemelo de determinismo reprodujo la ejecución de la Fase 1 a cuatro dígitos (0,71923 frente a 0,71923). En 0,7192 la red guardada queda −0,0060 bajo `catboost` (< 1 banda) y −0,0107 bajo `xgboost`, dentro de la banda de la segunda familia de árboles — la primera ANN en alcanzar el nivel de los árboles dentro del dataset y superar la barra de guardado de rotación.

Cuadro 9: Fase 1 — el bake-off de topología del **`burn-deep-classifier`** sobre la matriz **high-vocab** (`ds-20260612-143014-p64-s42`, params fijos: épocas 250, patience 20, hidden [128, 64], `embed_dim` 16, dropout 0.1, `lr` 1×10^{-3} , batch 256, relu; el único eje es **topology**). Las tres tuvieron éxito. El ranking *revierte* el resultado 60/40 de la Tabla 7: `embeddings` ahora gana. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador en negrita; mejor celda por métrica en negrita.

Topología / run id	Topología	AUC	log-loss	exactitud
T-emb (<code>run-20260612-143411-e8db6-burn-deep-classifier</code>)	embeddings	0.7192	0.6087	0.6694
T-mlp (<code>run-20260612-143411-01d7b-burn-deep-classifier</code>)	mlp	0.7129	0.6166	0.6617
T-wd (<code>run-20260612-143411-7d117-burn-deep-classifier</code>)	wide_deep	0.7061	0.6256	0.6526

Interpretación. Esto resuelve la pregunta abierta de la Sección 6.7 *confirmada*: la pérdida anterior de la topología de embedding fue un artefacto de inanición por baja cardinalidad, no un límite intrínseco, y elevar los toques voltea el ranking exactamente como se predijo. Dos salvedades honestas mantienen la afirmación calibrada. Primera, el margen single-split emb-vs-mlp (+0,0063) es en sí sub-banda, así que la *magnitud* de la reversión necesita un confirm de 3 particiones; lo decisivo es la *dirección* — todo el ranking se reordenó, con la rama de embedding pasando del fondo del ranking 60/40 a la cima de este. Segunda, el vocabulario alto ayuda a *todos*: los árboles ganaron tanto como (`catboost`) o más que la rama de embedding, así que la lectura correcta es “mayor resolución es mejor señal para toda familia, y específicamente desbloquea la topología de embedding”, no “`embeddings` ahora ganan de plano” — `xgboost` en 0,7299 sigue siendo el líder dentro del dataset, $\sim 0,0107$ (~ 1 banda) sobre la red guardada. Pero el arco cualitativo que recorrió la Sección 6 ahora cierra limpiamente: una red densa que consume one-hots crudos está calibrada en el régimen de los árboles (Sección 6.7), y dada *suficiente* resolución de identidad su topología de

Cuadro 10: Fase 2 — ajuste de la topología `embeddings` ganadora, una grilla `embed_dim`×`lr` (hidden [128, 64], otros params fijos), ordenada por AUC; ganador en negrita, mejor celda por métrica en negrita. El AUC es monótono-decreciente en `embed_dim` a $lr \ 5 \times 10^{-4}$ (la tabla ya está saturada en ancho 8), y $lr \ 5 \times 10^{-4}$ supera a $lr \ 1 \times 10^{-3}$ en todo ancho. La mejor ganancia sobre el ganador de la Fase 1 (+0,0036) es sub-banda, así que la config de la Fase 1 es la config de registro.

	<code>embed_dim</code>	<code>lr</code>	AUC	log-loss	exactitud	Brier
	8	0.0005	0.7228	0.6105	0.6645	0.2114
	16	0.0005	0.7210	0.6088	0.6711	0.2108
	32	0.0005	0.7200	0.6100	0.6657	0.2114
	8	0.001	0.7193	0.6092	0.6643	0.2112
	16	0.001	0.7192	0.6087	0.6666	0.2110
	32	0.001	0.7183	0.6097	0.6668	0.2114

embedding alcanza el nivel de los árboles — la palanca vigente de “la resolución de identidad es la palanca”, demostrada. El log-loss (~ 0.61) y el Brier (~ 0.21) se mantienen en el régimen calibrado de los árboles todo el tiempo, así que no hay penalización de calibración por la victoria. Una nota de higiene de datos: el reporte de redundancia del manifiesto high-vocab marca 21 colinealidades one-hot casi perfectas género↔artista (p.ej. `genre_primary=australian psych` $\equiv$ `artist=Tame Impala`, correlación 1,000; 19 más $\geq 0,957$), un artefacto de admitir géneros raros llevados por un único artista recién admitido; los árboles y los regularizadores de la red lo absorben sin patología de ejecución observada, pero conviene saberlo antes de leer importancias de one-hots individuales sobre esta matriz. El `burn-deep-embeddings-highvocab` guardado se marca para el best-model-selector como la primera ANN de nivel de árboles y un candidato natural de diversidad de familia. *Fuente: 2026-06-12-high-vocab-topology.md.*

6.9. Una segunda red consciente de la representación: el trasplante AE confirma el techo

Motivación. La Sección 6.7 estableció que una red que mantiene los one-hots de identidad en *crudo* está calibrada en el régimen de los árboles pero aún tope ~ 1 banda bajo los árboles. Una pregunta natural siguiente es si una *representación no supervisada aprendida* de las mismas entradas — en vez de las entradas crudas mismas — eleva la red más. El `burn-ae-classifier` lo prueba: la Fase 1 pre-entrena un autoencoder para reconstruir el vector de rasgos ensamblado completo (bloque continuo estandarizado junto a los one-hots crudos, $D=177$) por MSE, la Fase 2 trasplanta el encoder a un clasificador softmax y afina. Esta campaña es la primera caracterización de la familia — un barrido de 13 configs sobre la matriz 60/40 completa de 64-d (`ds-20260609-204419-p64-s42`, semilla 42) sobre tamaño de latente, profundidad/ancho de cabeza, activación y la bandera `freeze_encoder`, leído contra el campeón xgboost intra-corpus (0,7204) y el `mlp burn-deep` comparable (0,7038).

Resultados. La capacidad no importa para esta familia sobre rotación (Tabla 11; Figura 11). Las 12 configs afinadas abarcan una única franja de 0,0054 de ancho (0,69175–0,69719), enteramente dentro de la banda $2\sigma = 0,0126$ — un empate plano a través de un rango de latente de $4\times$ (32 a 128), a través de profundidad y ancho de cabeza, y a través de activación. La mejor nominal (`cfg3`, `enc[128, 64]/clf[128, 64]`, AUC 0,69719) supera la línea base 0,69225 por solo +0,00494 (sub-banda), e incluso la sonda lineal pura (`cfg2`, `clf[]`, 0,69175) está solo −0,00544 por debajo de ella: una única capa lineal sobre el latente afinado ya captura esencialmente toda la habilidad de la




Figura 10: La resolución de identidad cierra el hilo de trampas-ANN. *Izquierda:* la comparación pareada **embeddings**-frente-a-**mlp** a través de las dos cardinalidades. Sobre la matriz 60/40 **mlp** gana por +0,0067; sobre la matriz high-vocab **embeddings** gana por +0,0063 — un vuelco de +0,0130 que revierte el ranking y confirma el diagnóstico de inanición: con la cardinalidad de artista 5× y la de género 3× mayor la tabla de embeddings por fin tiene suficientes identidades distintas para aprender una geometría de bajo rango útil en vez de colapsar casi constante. *Derecha:* el ranking de AUC de cinco familias dentro del dataset sobre la matriz high-vocab. La red **embeddings** guardada (0,7192) alcanza el fondo del nivel de los árboles (sombreado: desde una banda bajo **catboost** hasta **xgboost**) — la primera ANN en hacerlo — mientras **xgboost** (0,7299) sigue siendo el líder dentro del dataset.

familia. El único efecto fuera de banda es una *trampa*: congelar el encoder pre-entrenado por MSE es seguro bajo una cabeza poco profunda (cfg11, 0,695 30, en banda) pero *colapsa* bajo una cabeza profunda (cfg10, 0,682 10, −0,0151 ≈ 1.2 bandas, la peor fila). relu roza a gelu y silu por un margen sub-banda. La calibración es sana en todo momento (log-loss ~0.62, Brier ~0.22 — el régimen de los árboles), así que es un miembro denso calibrado legítimo, solo que no un contendiente de AUC: la mejor config queda ~1.8 bandas bajo **xgboost** y es *estadísticamente igual* al **mlp burn-deep** plano (−0,0066, sub-banda). Ninguna definición se guardó.

Interpretación. El pre-entrenamiento AE compra un init rápido y estable pero *ningún AUC* sobre una red de one-hots crudos desde cero: como el objetivo de reconstrucción es puramente descriptivo (MSE sobre el vector ensamblado), el latente que entrega al clasificador es agnóstico a la tarea, y ninguna cantidad de capacidad de encoder/latente/cabeza lo convierte en poder de ranking de nivel de árboles. Esta es la misma lección de “una representación aprendida aguas abajo de los one-hots de identidad no añade nada que los árboles no tengan ya” — la dilución del latente AE de la Sección 5.1 y la inanición de embeddings de entidad de la Sección 6.7 — ahora reproducida en una tercera familia densa. El colapso-por-congelar es una trampa citable: un extractor de rasgos óptimo para MSE no es óptimo para la etiqueta, así que una cabeza profunda sobre un encoder congelado apila capacidad inútil y sub-ajusta. Si la familia se revisita alguna vez, la palanca es el *objetivo* de pre-entrenamiento (supervisado o contrastivo), no su tamaño. La familia está cerrada para AUC sobre rotación tal como está configurada. *Fuente:*




Figura 11: La red de trasplante AE confirma el techo de la red densa sobre dos ejes. *Izquierda:* las 12 configs afinadas colapsan sobre una única franja de 0,0054 de ancho dentro de la banda de ruido, muy por debajo del `mlp burn-deep` comparable (discontinua, 0,7038) y el campeón `xgboost` (verde, 0,7204) — tamaño de latente, profundidad/ancho de cabeza y activación son todas palancas agotadas; la capacidad está saturada en la config más pequeña probada. *Derecha:* el único efecto real. Congelar el encoder pre-entrenado por MSE es seguro bajo una cabeza (casi-)lineal (`cfg11`, en banda) pero *colapsa* el modelo bajo una cabeza profunda (`cfg10`, $-0,0151 \approx 1,2$ bandas): una cabeza profunda apilada sobre una representación congelada y agnóstica a la tarea simplemente sub-ajusta la etiqueta, porque los gradientes que habrían re-formado el encoder hacia el objetivo están bloqueados. El afinado de extremo a extremo (el defecto de registro) evita la trampa.

2026-06-15-burn-ae-classifier-capacity-scan.md.

6.10. Refutado: una cabeza de embedding de hojas GBDT no puede recuperar el árbol que generó sus rasgos

Motivación. El hilo ANN de arriba cerró con una lección limpia — una representación aprendida alimentada aguas abajo de los one-hots de identidad no compra poder de ranking que los árboles no tengan ya (la dilución del latente AE de la Sección 5.1; los embeddings de entidad famélicos salvo alta cardinalidad, Sección 6.7). Esta campaña somete esa lección a estrés en su punto más duro con el clásico truco de Facebook GBDT→LR, generalizado a GBDT→MLP. El árbol campeón congelado — la config registrada `xgboost-classifier-rotation-p64`, *duramente congelada*, no un ajustable — emite, para cada fila, el índice de la hoja en la que cae en cada uno de sus 500 árboles boosteados; esos índices se codifican one-hot en la propia partición axial aprendida del árbol ($\sim 10k$ columnas de pertenencia a hoja), y una cabeza fresca (una cabeza lineal logística ℓ_2 , o un MLP poco profundo) se entrena encima. La entrada a la cabeza es así la *propia* partición del árbol; la hipótesis — un séptimo test del hallazgo convergente — era que ni siquiera esto *superaría* al árbol puro, siendo la refutación esperada el hallazgo citable. Todas las ramas corrieron sobre la matriz 60/40 completa de 64-d (`ds-20260609-204419-p64-s42`, semilla 42); la única referencia válida es el campeón intra-dataset 0,7204, nunca los números DS-META 0,7429 o high-vocab 0,7299 (matrices distintas).

Resultados. Refutado exactamente como se predijo (Tabla 12; Figura 12). El control C0 (`run-20260615-151551-f2911-xgboost-classifier`) reprodujo el campeón hasta los 16 dígitos

(0,720 438 340 310 031 4), así que la puerta de determinismo pasó y los tratamientos son interpretables. Cada cabeza luego tope *por debajo* del árbol puro por más de una banda de ruido: GBDT→lineal con AUC 0,6978 ($-0,0227$, ~ 1.8 bandas), GBDT→MLP[256,128] con 0,6921 (~ 2.2 bandas), GBDT→MLP[128] con 0,6897 (~ 2.4 bandas) — la mejor de ellas está ella misma 0,0100 por debajo del umbral de refutación (campeón – banda = 0,7078). La rama de empate-en-banda (que habría disparado un spot-check de 3 semillas) y la rama de victoria ($> 0,7330$) nunca se dispararon; ninguna definición se guardó. La cabeza lineal — la receta literal de Facebook — es la mejor de las tres, y añadir capacidad MLP sobre los one-hots de hoja no recupera el árbol, consistente con el encuadre original de la receta como un truco *lineal* barato. Peor que el déficit de AUC, *cada cabeza está muy mal calibrada*: log-loss 0,8162–1,3119 y Brier 0,2603–0,2951 contra el 0,6075 / 0,2109 del árbol. La cabeza logística ℓ_2 al inverso- $C=1$ por defecto está sub-regularizada sobre $\sim 10k$ indicadores de hoja dispersos — lleva un puñado de pesos de hoja a magnitudes grandes y emite probabilidades sobre-confiadas, la misma firma de sobre-confianza pirámide-sklearn (log-loss muy por encima del de los árboles mientras el AUC solo queda modestamente detrás) vista en la Sección 6.3, y una bandera roja de calibración para el best-model-selector en caso de que alguna de estas ejecuciones se considere alguna vez para el grupo.




Figura 12: La pila de embedding de hojas queda refutada sobre ambos ejes. *Izquierda*: cada rama GBDT→cabeza tope por debajo del árbol campeón puro en AUC — la mejor (GBDT→lineal, 0,6978) está ella misma una banda completa por debajo del umbral de refutación (la línea discontinua en campeón $-2\sigma = 0,7078$; la franja sombreada es la banda). *Derecha*: y cada cabeza está mal calibrada, con log-loss 0,82–1,31 muy por encima del régimen de los árboles (0,61, punteada) y pasado la línea base de tasa base aleatoria (0,69, discontinua) para las dos peores. Aprender una cabeza sobre los propios índices de hoja one-hot del árbol es estrictamente más lossy que leer directamente las sumas de valores de hoja del árbol.

Interpretación. La refutación es decisiva y mecánica. El scoring aditivo de valores de hoja del árbol ya pondera cada hoja *conjuntamente* a través de 500 rondas de boosting con shrinkage; re-codificar esas hojas como indicadores de pertenencia one-hot y ajustar una cabeza *post-hoc* descarta la estructura de boosting y la re-estima peor. Los one-hots de hoja son una vista estrictamente más lossy de un árbol que ya puntúa mejor directamente — la cabeza densa ni siquiera puede recuperar el árbol que generó sus propios rasgos. Esta es la misma familia que la dilución del latente AE (Sección 5.1) y el techo de cabeza-densa (Sección 6), llevada a su límite: aquí la *entrada* de la cabeza

es la partición óptima del árbol, y aún tope ~ 2 bandas por debajo. Re-ajustar la regularización de la cabeza podría domar la sobre-confianza pero no puede cerrar un déficit de AUC de ~ 1.8 bandas, así que la familia de cabeza-de-hojas está cerrada para rotación. Esta es la séptima confirmación convergente de que la palanca durable es la *resolución* de identidad (elevar topes de vocabulario, que ya elevó xgboost a 0,7299 sobre la matriz high-vocab), no nuevas cabezas ni representaciones apiladas sobre el árbol. *Fuente: 2026-06-15-gbdt-leaf-head-ceiling-probe.md.*

6.11. El barrido de tope de vocabulario de resolución de identidad: una palanca en gran medida agotada

Motivación. Cada campaña de arriba cierra sobre la misma palanca vigente — la *resolución* de identidad: elevar los topes de vocabulario de artista/género para que la cola `__other__` obtenga columnas one-hot reales, lo que ya elevó xgboost de 0,7204 (60/40) a 0,7299 (300/120, Sección 6.8) y volteó la red de embedding al nivel de los árboles. Pero solo existían *dos* puntos sobre esa curva tope→AUC, y el extremo alto era el récord de linaje. Esta campaña mapea dónde deja de rendir la palanca. Mantiene la config registrada `xgboost-classifier-rotation-p64 congelada` (`catboost` defaults como rama secundaria), mantiene *todo lo demás* fijo — mismo corpus de 23 529 filas, misma semilla de partición 42 (18 823 entrenamiento / 4706 prueba), mismo PCA64, mismo bloque de campos — y mueve el *único* eje `vocab_top_n`, añadiendo tres puntos de tope más alto: 500/200 (777 cols), 1000/300 (1377 cols) y el vocabulario completo, 5594/962 (6633 cols). La hipótesis a discriminar: *saturación* (ganancia por paso < una banda) frente a *reversión* (el AUC baja conforme las columnas de artista singleton inyectan varianza memorizable).

Resultados. Las ocho ejecuciones lanzadas tuvieron éxito; los controles reprodujeron ambas anclas a cuatro dígitos (xgboost 60/40 0,720 44 frente a la referencia 0,7204, $\Delta + 0,00004$; xgboost 300/120 0,729 88 frente a 0,7299, $\Delta - 0,00002$), así que toda la curva se sitúa bajo una medición consistente (Tabla 13; Figura 13). xgboost subió a un nuevo mejor de linaje single-split de 0,734 90 en 1000/300 (`run-20260615-163803-e75be-xgboost-classifier`), pero la estructura de pasos cuenta la historia real: el salto 60 $\rightarrow$ 300 fue +0,00944 (+0,75 banda), luego 300 $\rightarrow$ 500 fue *plano* ($-0,00022$, dentro del ruido) y 500 $\rightarrow$ 1000 fue +0,00524 (+0,42 banda). El mejor punto está solo +0,00502 (~ 0.40 banda) sobre el ancla 0.7299 — una mejora *sub-banda*, muy corta de los +0,0126 que requeriría una superación confiada. `catboost` sigue a xgboost cualitativamente en cada tope (0,711 05 $\rightarrow$ 0,725 16 $\rightarrow$ 0,723 72 $\rightarrow$ 0,726 33), quedando ~ 0.005 – 0.009 por debajo de él en todo momento y subiendo igual de suave después de 300/120 — su manejo categórico nativo *no* escala mejor en alta cardinalidad. El punto de vocabulario completo (6633 cols) en el tope de la curva **no pudo construirse**: dos intentos POST cada uno devolvió un id de build pero murió a mitad de materialización contra el techo de memoria del host (~ 2.3 GB libres de 15 GB bajo carga concurrente), dejando ningún dataset y ningún artefacto. Ese es un techo de infraestructura, *no* un resultado de modelado, y el extremo superior de la curva se registra como no medido.

Interpretación. El veredicto es un limpio “no saturada, no revertida, pero disminuyendo”. Ningún punto interior cayó una banda completa bajo el ancla (el más bajo, 500/200, es $-0,00022$), así que la hipótesis de reversión no dispara — las columnas de artista singleton en alta cardinalidad *no* dañan el árbol, consistente con el prior de no-exploración del proyecto de que las particiones alineadas a ejes toleran one-hots colineales y mayormente-cero simplemente no partiendo sobre los inútiles. Pero las ganancias pasado el primer salto son todas sub-banda y oscilan arriba y abajo dentro del sobre $2\sigma = 0,0126$: la curva pasado 300/120 se lee mejor como una meseta plana con jitter single-split que como una subida monótona, que es exactamente por qué la regla de decisión guarda un save detrás de una superación de ≥ 1 banda más un confirm de 3 semillas. El +0,00502 del mejor punto está en la ventana de “probablemente mejor, necesita confirmación”, así que el




Figura 13: La palanca de resolución de identidad está en gran medida agotada. Manteniendo la config campeona congelada y moviendo solo el tope de one-hots de artista/género, la curva tope→AUC sube abruptamente en el primer salto (60/40 → 300/120, +0,75 banda) y luego *se estanca*: 300 → 500 es plano (−0,00022, dentro del ruido) y 500 → 1000 recupera solo +0,42 banda, así que la nueva mejor de linaje single-split (0,73490 en 1000/300) supera el ancla 300/120 por solo +0,00502 (~0.40 banda, dentro del sobre sombreado +2σ y por tanto una mejora *sub-banda*). *catboost* (discontinua) sigue a *xgboost* en cada tope, ~0.005–0.009 por debajo — el manejo categórico nativo no compra ventaja de alta cardinalidad. El punto de vocabulario completo (6633 cols, × rojo) está *no medido*: su build chocó con un techo de memoria del host en ambos intentos, un fallo de infraestructura más que un resultado de modelado.

confirm de 3 semillas no disparó y ninguna definición se guardó; el campeón DS-META cross-matrix (0,7429) mantiene el rango 1 sin cambios, y el punto 1000/300 se auto-promovió a mejores-modelos rango 3 sin desplazar a ningún modelo registrado. La lectura honesta para trabajo futuro: la *altura* cruda del tope de vocabulario es una palanca en gran medida agotada sobre este corpus — el gran pago fue el primer salto, ya registrado. El acuerdo de *catboost* lo sella: dos familias de árboles independientes dicen que las columnas marginales pasado 300/120 llevan poca señal independiente. La señal de rotación residual es la parte conductual/contextual que ninguna cardinalidad de metadatos de canción puede capturar, así que el trabajo de identidad debería girar de topes más grandes a resolución *de calidad* — interacciones de seguidores-de-artista / popularidad, jerarquía de género — y la guía vigente de “la resolución de identidad es la palanca” debería leerse ahora “débil y estancándose pasado 300/120, con el extremo superior aún no medido pendiente de un build ancho sobre un host quiescente”. *Fuente: 2026-06-15-vocab-cap-scan-gbdt.md*.

6.12. Leyendo las redes: autoencoders dispersos por modelo

Motivación. Todo resultado hasta ahora se ha leído de la tabla de clasificación — AUC, log-loss, Brier. Pero dos redes pueden publicar AUC idéntico mientras tallan la entrada en representaciones internas muy distintas, una distinción que la tabla no puede ver. Esta campaña abre esa caja. Primero porta un *autoencoder disperso por modelo* (POST /api/interp/model-sae) a la familia *burn-deep-classifier* (la cabeza SAE existía antes solo para un regresor), de modo

que la promoción ahora auto-encola una lectura de interpretabilidad: un SAE 2×-sobrecapado (11 0,0015, 40 épocas) se ajusta sobre las activaciones de cada capa oculta, sus átomos se sondean por *conceptos* interpretables, y la *decodabilidad* lineal de la rotación se mide capa por capa. El primer uso compara dos geometrías con AUC fijo sobre la matriz canónica completa de 64-d (ds-20260609-204419-p64-s42, semilla 42): una *pyramid* que se estrecha [256, 128, 64] contra una *rect* uniforme [128, 128, 128], difiriendo *solo* en la forma oculta.

Resultados. Las dos redes están **estadísticamente empatadas** en AUC (pyramid 0,698 57, rect 0,699 37; $\Delta 0,0008 \ll$ banda) — ambas en el nivel del *mlp burn-deep* registrado y ~ 1.7 bandas bajo el campeón xgboost. También capturan la *misma cantidad* de señal decodable: la decodabilidad lineal de la rotación apenas se eleva sobre la entrada cruda ($\sim 0.111 \rightarrow \sim 0.12$) para ambas. La diferencia es puramente en *disposición* (Figura 14). Los conceptos interpretables de la pirámide hacen pico en su capa media de 128-d (72) y luego comprimen $\sim 40\%$ en el cuello de botella de 64-d (42); la red uniforme los reparte más uniformemente y *retiene* más hasta el final ($17 \rightarrow 66 \rightarrow 54$), porque tiene el ancho para hacerlo. Ninguna red está famélica — ambas utilizan plenamente cada átomo SAE (0 muertos / 0 raros), dan esencialmente a cada segmento de identidad ($\sim 103\text{--}105/105$) un átomo separador dedicado, y reconstruyen $> 96\%$ de la varianza de activación — así que la brecha de conteo-de-conceptos es asignación genuina, no capacidad. Un control sin early-stop confirmó una trampa registrada: corridas a las 100 épocas completas con patience 0, ambas redes de 3 capas sobreajustan (AUC $-0,015$, log-loss revienta a 0,96–1,22); el régimen calibrado $\sim 0.699 / 0.625$ se recupera solo *porque* las ejecuciones de producción hacen early-stop. **Las redes burn-deep más profundas necesitan patience.**




Figura 14: Con AUC igual, dos geometrías disponen la misma señal de forma distinta — una diferencia representacional invisible a la tabla. La *pyramid* que se estrecha [256, 128, 64] (azul) hace pico de sus conceptos interpretables-por-SAE en la capa media de 128-d (72) y exprime $\sim 40\%$ de ellos en el cuello de 64-d (42); la *rect* uniforme [128, 128, 128] (gris) reparte sus conceptos y retiene más hasta la capa de salida ($17 \rightarrow 66 \rightarrow 54$). Ambas redes utilizan plenamente cada átomo y decodan la rotación al mismo techo ~ 0.12 , así que la pirámide *consolida* su estructura interpretable en un cuello de botella comprimido mientras la red uniforme mantiene un conjunto de conceptos más amplio — mismo AUC, distinta asignación.

Interpretación. Con igual poder de ranking la pirámide consolida su estructura interpretable en un cuello de botella que se estrecha mientras la red uniforme la distribuye, y ambas mera-

mente re-expresan la decodabilidad ~ 0.11 de la entrada cruda en vez de fabricar nueva señal de gusto. El SAE confirma así, mecanísticamente, lo que la tabla solo implica: las redes densas no están encontrando estructura que los árboles pierdan; están re-empaquetando la misma señal de identidad en una representación que el AUC no puede distinguir. Este patrón de “misma señal, distinta asignación” recurre a través de familias en vocabulario más alto (Sección 6.13). *Fuente: 2026-07-12-pyramid-vs-rect-sae.md.*

6.13. La capacidad es una palanca agotada en vocabulario alto, y qué ve el SAE

Motivación. La matriz high-vocab (Sección 6.8) fue donde la red de embedding alcanzó primero el nivel de los árboles, pero nunca se ajustó en profundidad/ancho. Esta campaña plantea la pregunta directa: ¿la *capacidad* — ancho o profundidad — eleva la familia ANN a través de la brecha restante de ~ 0.2 – 0.6 banda con los árboles sobre esa matriz (ds-20260612-143014-p64-s42, 497 cols)? Dos escaleras de geometría de un eje, lr fijo en el mejor registrado de cada topología: una escalera **embeddings** (ed8, lr 5×10^{-4}) y una escalera **mlp** (lr 1×10^{-3}), cada una escalonando [128, 64] (control) $\rightarrow$ [256, 128] (más ancha) $\rightarrow$ [256, 128, 64] (más profunda). Cada rama promovida también obtiene el SAE por modelo de la Sección 6.12, para una lectura de representación cross-familia en vocabulario alto.

Resultados. **TECHO — la capacidad está saturada para ambas topologías** (Tabla 14; Figura 15). Ni ensanchar ni profundizar supera su propio control [128, 64] por más de una banda; la mejor config sigue siendo la **embeddings** registrada ed8/lr 5×10^{-4} /[128, 64] (reproducida aquí en 0,72274, $\Delta -0,0001$). Profundizar **embeddings** a tres capas activamente *perjudica* ($-0,0152 \approx 1.2$ bandas, el único movimiento fuera de banda); profundizar **mlp** ayuda un toque sub-banda ($+0,0057$). Crucialmente, el mejor **mlp** (B6, 0,71800) cierra a menos de $+0,0047$ del mejor **embeddings** (B1, 0,72274): en sus mejores geometrías las dos topologías empatan dentro de una banda, así que **la capacidad, no el mecanismo de embeddings, fue la palanca** — la lectura anterior de “embeddings gana en vocabulario alto” es un empate en banda, y la familia ANN sigue ~ 0.2 – 0.6 banda bajo el nivel de los árboles (catboost 0,7252, xgboost 0,7299). La definición guardada **burn-deep-embeddings-highvocab** y el campeón están ambos sin cambios; la mejor rama se promovió para el registro como **emb-128-64-ed8-highvocab**.

Interpretación. El SAE por modelo explica *por qué* ambos movimientos fallan. El par cross-familia empatado en AUC — **embeddings** [128, 64] (0,72274) y **mlp** [256, 128, 64] (0,71800) — se estanca en el *mismo* techo de decodabilidad (capa de pico test R^2_{target} 0,149 frente a 0,141) y ambos dan a los 245 segmentos de identidad un átomo separador dedicado; la diferencia es solo de disposición. El ganador alcanza el techo con pocos conceptos contruidos monótonamente ($33 \rightarrow 75$, $\Sigma 108$), mientras que el **mlp** más profundo/ancho forma casi $2\times$ los conceptos ($55 \rightarrow 113 \rightarrow 32$, $\Sigma 200$) que hacen pico en su capa media y *colapsan* a través de su cuello — el mismo patrón de consolidación-frente-a-proliferación de la Sección 6.12, ahora reproducido a través de familias e invisible al AUC. Y la penalización de $-0,0152$ de embeddings-profundos es dilución, no inanición: esa rama tiene 0 átomos muertos y utilización plena pero una *entrada* de embedding de entidad aprendida más débil (R^2_{target} 0,123 frente al 0,133 del ganador), y su profundidad extra nunca la recupera (la decodabilidad baja a mitad de tronco). Esta es la cara mecanística del techo de capacidad: una tercera capa sobre una tabla de embedding aprendida diluye el ranking en vez de afilarlo. Tanto este barrido como el barrido de tope de vocabulario GBDT (Sección 6.11) apuntan igual — la *calidad* de resolución de identidad, no la capacidad cruda del modelo o del vocabulario, es la palanca restante. *Fuente: 2026-07-12-high-vocab-capacity-scan.md.*




Figura 15: La capacidad es una palanca agotada para la red densa en vocabulario alto. Manteniendo lr en el mejor de cada topología y escalonando la geometría oculta $[128, 64] \rightarrow [256, 128] \rightarrow [256, 128, 64]$, ni la escalera **embeddings** (azul) ni la **mlp** (gris) supera su propio control por una banda; una tercera capa **embeddings** *perjudica* por 0,0152 (~ 1.2 bandas, el único movimiento fuera de banda), porque la profundidad extra diluye una entrada de embedding de entidad aprendida ya peor condicionada. El mejor **mlp** cierra a menos de +0,0047 del mejor **embeddings**, así que las dos familias empatan dentro de una banda — la capacidad, no el mecanismo de embeddings, fue la palanca — y todo el nivel ANN se mantiene ~ 0.2 – 0.6 banda bajo el nivel de los árboles dentro del dataset (sombreado, catboost 0,7252 hasta xgboost 0,7299).

7. Deriva de gusto: la tabla de clasificación es una cota superior de la predicción hacia adelante

Motivación. Todo AUC en este documento se mide sobre una partición train/test *aleatoria*, que deja que una pista descubierta en un período dado aterrice a ambos lados de la partición. Eso responde “¿puede el modelo ordenar pistas de la misma era que sus datos de entrenamiento?” — pero la pregunta desplegada mira hacia adelante: ¿*reproduciré una canción que descubra a continuación?* Esta campaña la plantea honestamente añadiendo una capacidad de partición cronológica de primera clase al constructor (`split_order_field` en la petición de build): las filas se ordenan por un campo de payload (aquí `first_played`), las más tempranas van a entrenamiento y las más tardías a prueba, y PCA, vocabulario e imputación se ajustan todos solo sobre las filas de entrenamiento tempranas, así que la partición es libre de fugas. Se construyeron cuatro datasets desde la colección activa `spotify_tracks_song_ae` — completo e intrínseco, cada uno aleatorio y cronológico — y el campeón más un barrido de modelos se evaluaron sobre la partición nativa de cada dataset. Si el AUC colapsa bajo la partición cronológica, el gusto deriva y la tabla sobreestima la habilidad real hacia adelante.

Resultados. El **gusto no es estacionario** (Tabla 15; Figura 16). El build completo-aleatorio reproduce el campeón registrado a cinco dígitos (0,73490), validando los builds frescos; el build cronológico de los *mismos* rasgos lo baja a 0,61894 — un colapso de +0,116 (≈ 9 bandas de ruido). La caída es de 0,109–0,116 para *cada* familia de modelos (catboost 0,72889 $\rightarrow$ 0,61294,

logistic 0,721 41→0,612 34), así que es el dato/gusto, no una peculiaridad de modelo. Los one-hots de identidad apenas ayudan hacia adelante: *descartarlos* (el build intrínseco) cuesta solo ~ 0.02 cronológico (0,618 94→0,598 58) frente a ~ 0.025 aleatorio — mayormente memorizan artistas de la misma era. Un *xgboost* ponderado por recencia (sobre-ponderando descubrimientos recientes) recupera solo +0,003 (sub-banda), así que la deriva no es un simple efecto de recencia. Y la lectura walk-forward — entrenar sobre `first_played < Y`, probar sobre el año *Y* — aterriza en 0,59–0,67 para cada año individual de 2019 a 2026, *nunca* cerca de la línea base aleatoria 0,735, y más historia de entrenamiento no cierra la brecha. Un re-particionado fuera-del-framework de los rasgos preexistentes construidos aleatoriamente concuerda a ~ 0.007 de AUC (0,626), y controlar por censura-a-la-derecha (restringiendo la prueba cronológica a pistas con ≥ 180 días de oportunidad de reproducción) apenas lo mueve (0,625 79→0,623 19) — así que la penalización es no-estacionariedad genuina, no el corrimiento de tasa base de pistas recientes mecánicamente-menos-rotadas.




Figura 16: El AUC de la tabla de clasificación es una cota superior de la predicción hacia adelante. *Izquierda*: pasar de una partición aleatoria a una cronológica (entrenar-antes / probar-después) baja el AUC en ~ 0.11 para *cada* familia de modelos — la penalización es el dato, no un modelo. *Derecha*: la lectura walk-forward (entrenar sobre `first_played < Y`, probar sobre el año *Y*) aterriza en 0,59–0,67 cada año y nunca se acerca a la línea base aleatoria 0,735 (verde), siguiendo el nivel cronológico $\sim 0,619$ (rojo discontinuo) en su lugar; más historia acumulada no cierra la brecha. La habilidad hacia adelante de “¿reproduciré una canción que descubra a continuación?” sobre este corpus es ~ 0.62 – 0.63 , ~ 0.11 por debajo de la tabla de partición aleatoria.

Interpretación. El mecanismo es la rotación de identidad, y ata todo el documento. La rotación la conduce la *identidad* de artista/género en one-hots (el hallazgo convergente de cada campaña de arriba); en una partición cronológica el período de prueba está lleno de artistas recién descubiertos que eran no vistos en entrenamiento y caen en `__other__`, así que el modelo debe recaer en la señal acústica/metadatos intrínseca más débil — que tope cerca de 0,60. Eso es exactamente por qué elevar topes de vocabulario (Sección 6.11) y añadir capacidad de red (Sección 6.13) son palancas agotadas para la habilidad hacia adelante: solo afilan la *memorización* de la misma era, que no transfiere. Es también la historia de misma-señal que cuentan los SAEs por modelo — decodabilidad lineal ~ 0.14 sin átomo de gusto monosemántico limpio (Secciones 6.12, 6.13): quita la memorización de identidad y queda poca señal de gusto generalizable. La lectura práctica: todo

AUC registrado es una cota superior del ranking de misma era, no de la habilidad hacia adelante; un modelo desplegado necesita re-entrenamiento periódico porque el gusto deriva; y la única palanca que movería el AUC *hacia adelante* es señal intrínseca generalizable más rica (mejor acústica, estructura cross-artista), ya que la resolución de identidad y la capacidad de modelo están ambas agotadas y son solo-de-la-misma-era. Esto no revierte ningún número de la tabla — los AUC de partición aleatoria son mediciones válidas del ranking de misma era — pero reencuadra lo que significan. *Fuente: 2026-07-12-taste-drift-temporal-split.md.*

8. Recomendación de pista siguiente: la tarea, la barra de Markov y el campeón de fusión

Toda campaña de arriba apunta a la señal binaria de *rotación*. Las secciones restantes incorporan una línea de trabajo *separada* — recomendación de *pista siguiente* (next-track) — cuya tarea, métricas y campeón no tienen relación con las tablas de rotación y nunca deben leerse contra ellas. Esta sección consolida las cuatro campañas que establecieron la tarea, su barra base y su campeón de fusión; las dos secciones que siguen (Secciones 9 y 10) desarrollan los ejes de representación de ítems y familia de modelos y coronan la fila «mejor registrada» actual.

Tarea y partición. La tarea es *recuperación* (retrieval) del siguiente ítem: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente. Se evalúa sobre una única partición cronológica sin fugas *next-distinct* del artefacto de secuencias `seq-20260713-014226` (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba en el corte 2024-08-24). La **tasa de ítems fríos es 0.55** — más de la mitad de las pistas objetivo de las sesiones de prueba nunca aparecen en ninguna sesión de entrenamiento — así que el recall absoluto es modesto *por construcción* y cada resultado se lee contra la barra base incumbente, no una barra absoluta.

Métricas. La métrica principal es **recall@10** (R@10, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al rango recíproco medio (MRR) y, desde 2026-07-14, los diagnósticos de *relevancia graduada* de primera clase: *artist@10* / *genre@10* (un candidato del top-diez comparte el artista / género primario de la verdad) y *artist_mrr*. Todos los intervalos de confianza aquí son IC bootstrap al 95 % sobre 2000 remuestros de las 1431 sesiones de prueba, y el estadístico decisivo es el Δ *pareado* por sesión contra una referencia nombrada (la barra de Markov, un ancla GRU del mismo espacio, o el campeón). Las métricas graduadas son el marcador honesto: el campeón acierta el *artista* correcto en el top diez $\sim 32\%$ de las veces y el *género* correcto $\sim 40\%$, mucho más útil que el número de recall exacto de $\sim 17\%$ que impone la tasa de ítems fríos. Desde 2026-07-20 la tabla también incluye **music@10**, una métrica graduada continua de tipo “suena parecido” (Sección 13): el coseno máximo medio, en un espacio intrínseco balanceado de distancia musical, entre la siguiente pista verdadera y los diez candidatos — un superconjunto suave de recall@10, solo de visualización (la métrica principal sigue siendo recall@10). Desde 2026-07-22 el tablero también lleva una suite *solo de visualización* de holisticidad de sesión (*artist_adj@10* / *mood_coh@10* / *ild@10*; Sección 14), que no reordena el tablero pero toma la huella del campeón como la fila más artist-eager.

La barra de Markov. La referencia contra la que se mide cada rama es el modelo de co-ocurrencia de *Markov* de primer orden (B2: un `track_bigram` solo de entrenamiento con back-off

por artista/género, el término de transición que la app hermana ya despacha) con R@10 0,1069, MRR 0,0694. Los pisos de popularidad (B0) y recencia (B1) quedan cerca de cero (R@10 0,0007). Una *victoria* de tabla requiere superar la referencia en *ambos* R@10 y MRR más allá de los tests de paired- Δ / IC marginal, seguido de un confirm por reproducción.

La Tabla 16 es la tabla vigente de «mejor registrada» de pista siguiente. El campeón *row* actual — y, desde 2026-07-18, un modelo *registrado, promovido y servible* — es una *proyección de contenido aprendida* supervisada, $R'+M+C'$, sobre el espacio de ítems PCA-192 (Secciones 11–11.2): las ramas GRU y content-kNN recuperan en un mapa métrico InfoNCE del espacio de ítems ajustado hacia la adyacencia de pista siguiente. Supera al z-blend de tres ramas $R+M+C$ sobre el mismo espacio (Sección 10.2), que había destronado al z-blend de dos ramas $R+M$ sobre el espacio AE-64 (Sección 8.3). Desde 2026-07-18 la familia de secuencias lleva un contrato de servicio de ranking, así que el campeón es servible vía POST `/api/models/blend-gru-markov-content-proj/predict` (rango 1 del grupo de mejores modelos); los blends anteriores debajo de él, y las ramas en solitario, siguen siendo referencias fuera del servidor.

8.1. El barrido de secuencias: una GRU-infonce empata con la barra de Markov

Motivación. La campaña inaugural de la instancia planteó la pregunta fundacional: ¿un modelo de secuencias con contexto de sesión — una GRU/LSTM sobre el prefijo ordenado, prediciendo el latente song-AE de 64 dimensiones de la siguiente pista y recuperando por coseno — supera al modelo de transición de Markov de primer orden que la app hermana ya despacha, *hacia adelante*, sobre la partición de sesiones sin fugas? Cuatro ramas cruzaron la celda recurrente (GRU, LSTM), la capacidad (`hidden` 128, 256) y, decisivamente, la función de pérdida (regresión coseno frente a InfoNCE contrastiva), todas sobre `seq-20260713-014226` a 60 épocas.

Resultados. Ninguna rama superó la barra. La regla de decisión requería superar a B2 en *ambos* R@10 y MRR más allá de IC no solapados; la mejor rama (M3, GRU `hidden128` InfoNCE) alcanzó un *empate* estadístico con la barra de Markov en R@10 (0,0894, el IC del paired- Δ incluye cero) pero *perdió* en MRR (0,0388 frente a 0,0694) y `recall@20`. La palanca dominante fue la función de pérdida: InfoNCE fue $\approx 2,3\times$ el coseno en R@10 (0,0894 frente a 0,0391), mientras que la capacidad (`h256`) y la celda LSTM apenas movieron las ramas coseno (todas ~ 0.038 – 0.041).

Interpretación. Un latente-más-un-solo-salto-coseno es una ruta más difícil a la *pista* siguiente *exacta* que un bigrama de co-escucha: el bigrama memoriza directamente “qué sigue a qué”, mientras que la GRU debe aterrizar cerca del punto correcto en un espacio de contenido de 64-d y luego recuperar, perdiendo en el ranking preciso (MRR). El hallazgo es consistente con el resultado de deriva de gusto del laboratorio padre — 0,55 de ítems fríos, comportamiento guiado por identidad/adyacencia — y fijó la agenda: InfoNCE es la pérdida base, y la rama natural siguiente es un *blend* de las puntuaciones de candidatos de la GRU con el bigrama de Markov. *Fuente:* `2026-07-13-nexttrack-sequence-sweep.md`.

8.2. Barrido de topología: profundidad, anchura y dirección son una palanca agotada

Motivación. Con la pérdida fijada en InfoNCE, este barrido aisló la *topología* de red: ¿la profundidad (capas apiladas), la anchura (`hidden` 256), una pila residual entre capas o la bidireccionalidad elevan el modelo de secuencias por encima de la barra de Markov? Como una RNN bidireccional bajo teacher forcing por paso filtraría ítems futuros, la rama bidireccional usó un objetivo leak-free de último ítem (codificar el prefijo completo, predecir solo el siguiente ítem retenido).

Resultados. Refutado. Ninguna rama superó la barra en ambas métricas. La mejor rama (anchura h256, R@10 0,0957) es un *empate* en R@10 y pierde en MRR (0,0411 frente a 0,0694). La profundidad es plana de 1→2 capas (0,0894→0,0922, dentro de banda) y *perjudica* con 3 capas (0,0825, fuera de banda por debajo de la barra); la pila residual sobre profundidad-2/h256 no añadió nada. La rama bidireccional colapsó (0,0482), pero esto es un artefacto del *objetivo*, no un veredicto sobre la direccionalidad: el objetivo leak-free de último ítem aporta ~1 objetivo de entrenamiento por sesión frente a los ~13 pares de siguiente-paso del teacher forcing, así que entrenó con ~13× menos señal.

Interpretación. La arquitectura no es la palanca para pista siguiente en este corpus. La señal transferible de recuperación por latente se estanca en R@10 ~0.09–0.10 a través de profundidad, anchura, residual y dirección, por debajo del bigrama de co-escucha — consistente con todo el arco: la función de pérdida movió la aguja y la capacidad/topología no. La única palanca inexplorada restante era el encuadre de candidatos / la fusión, que la campaña siguiente accionó decisivamente. *Fuente: 2026-07-13-nexttrack-topology-scan.md.*

8.3. El campeón de fusión GRU×Markov, y por qué más ensamblado falla

Motivación. El barrido y el escaneo de topología coincidieron en que la mejor GRU individual solo *empata* con la barra de Markov en R@10 mientras pierde en MRR. Esta campaña preguntó si *combinar* modelos supera la barra, y hasta dónde llega el ensamblado. Se definieron tres ramas, cada una emitiendo puntuaciones de candidatos sobre todo el vocabulario: **M** = el bigrama de Markov solo de entrenamiento (la barra), **R** = la recurrencia GRU-infonce-h256, y **A** = un MLP ANN de bolsa-de-prefijo (un gemelo feed-forward de R). Se combinaron con un z-blend ponderado y, como alternativa aprendida, un stacker XGB (un meta-aprendiz GBDT sobre rasgos por candidato).

Resultados. El **z-blend R+M** ($\alpha=0,5$) *supera la barra de forma decisiva*: R@10 0,1726 [0,154,0,192], MRR 0,0963, un Δ pareado sobre Markov de +0,0657 [+0,049,+0,083] (IC enteramente por encima de cero) — ~+61 % de R@10, +39 % de MRR — en una meseta robusta a lo largo de $\alpha \in [0,25,0,75]$ y reproducido a través de tres semillas (0,1705 / 0,1726 / 0,1726). Se registró como el predictor **seq-blend** y la definición **blend-gru-markov**, el primer campeón de pista siguiente. Más ensamblado luego *no logró* mejorarlo (Tabla 17): R+A+M (0,1684) es levemente peor, R+A ($\approx$ GRU sola, 0,0894) es mucho peor, y ambas variantes del stacker XGB (M+R 0,1020; M+R+A 0,0887) apenas superan a Markov sola.

Interpretación. La victoria es sobre *diversidad* de señal, no número de modelos. La GRU (similitud de latente) y Markov (conteos de co-ocurrencia) ordenan pistas correctas *distintas*, así que fusionarlas aproximadamente duplica la tasa de acierto; amontonar más del *mismo* tipo de señal — otro predictor neuronal de latente (A), redundante con R — no añade nada. El stacker XGB aprendido *rinde por debajo* del z-blend simple, en contra de la intuición habitual de que “apilar supera a mezclar”: su entrenamiento puntual binario-con-negativos no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas. El margen restante está acotado por la tasa de ítems fríos de 0,55 y requiere *señal genuinamente nueva*, no más fusión de modelos — la hipótesis que la campaña de relevancia graduada prueba a continuación. *Fuente: 2026-07-14-nexttrack-blend-and-ensemble.md.*

8.4. Métricas de relevancia graduada y nuevos aprendices base: el contenido es la única señal aditiva

Motivación. Dos hilos en una campaña. (A) Hacer que la evaluación acredite aterrizar la *banda/ambiente* correcto aunque la pista exacta esté mal — la observación de que “la primera elec-

ción normalmente no es la pista exacta, pero el artista normalmente es correcto” — promoviendo *artist@k*, *genre@k* y *artist_mrr* a métricas de primera clase cableadas de extremo a extremo (`seq_common.eval_from_scores` $\rightarrow$ `Metrics` / `MetricsSpec` de Rust $\rightarrow$ `domain.toml` $\rightarrow$ UI). (B) Probar aprendices base leak-free genuinamente nuevos — **C** = content-kNN (coseno del latente song-AE de cada candidato al prefijo, sin entrenamiento), **M2** = un trigram de Markov de segundo orden con back-off, e **I** = un item2vec SGNS solo de entrenamiento — evaluados tanto en las métricas exactas como en las nuevas graduadas.

Resultados. La ruta de la métrica exacta fue idéntica byte a byte (claves puramente aditivas); el campeón reprodujo R@10 0,1726 / MRR 0,0963 exactamente. Ningún aprendiz base nuevo superó la barra en solitario (M2 0,1076 $\approx$ M 0,1069; el trigram cae al bigrama — las sesiones son demasiado cortas para disparar; item2vec 0,0517 es la rama más débil). Mezclado en el campeón, **el contenido es la única señal aditiva: R+M+C** (añadiendo la rama de contenido) es el mejor blend en MRR (0,0963 $\rightarrow$ 0,1014), *artist@10* (0,3215 $\rightarrow$ 0,3298) y *artist_mrr*, y empata al campeón en R@10 exacto (Δ pareado +0,0014, IC cruza cero). item2vec *arrastra* el blend (R+M+I 0,1349); el trigram es neutral.

Interpretación. content-kNN ordena pistas cuasi-correctas *distintas* (similitud de ambiente por latente) frente a la GRU (recurrencia de sesión) y Markov (co-ocurrencia), justo la diversidad que la campaña de fusión predijo que necesitaría la señal nueva. Sobre el espacio AE-64 la rama de contenido solo *empató* al campeón en recall exacto mientras elevaba las métricas graduadas — así que se llevó adelante como la tercera rama *graded-preferred*, no como un nuevo campeón exacto. Ese “empate” se vuelve una *victoria* cuando el espacio de ítems es más rico (Sección 10): sobre PCA-192 la misma construcción R+M+C es la más fuerte registrada. El item2vec de co-escucha y el trigram de Markov no añadieron nada en estos datos. *Fuente: 2026-07-14-nexttrack-graded-relevance-and-new-legs.md.*

9. Recomendación de pista siguiente: el bake-off de compresión de la representación de ítems

Toda campaña de arriba apunta a la señal binaria de *rotación*. Esta sección incorpora el primer informe de una línea de trabajo *separada* — recomendación de *pista siguiente* (next-track) — cuya tarea, métricas y campeón no tienen relación con las tablas de rotación y nunca deben leerse contra ellas. La tarea es recuperación: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente. Se evalúa sobre una partición cronológica *next-distinct* sin fugas (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba en el corte 2024-08-24; tasa de ítems fríos 0.55), y su métrica principal es **recall@10** (R@10, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al rango recíproco medio (MRR) y los diagnósticos de acierto de categoría *artist@10* / *genre@10* / *artist_mrr*. Todos los intervalos de confianza aquí son IC bootstrap al 95 % sobre 2000 remuestreos de las 1431 sesiones de prueba. El campeón vigente de esta línea — la referencia contra la que se lee esta campaña — es un *z-blend R+M* de fusión de rankings (**blend-gru-markov**, $\alpha=0,5$) de una GRU de secuencias con un modelo de co-ocurrencia de Markov de primer orden sobre el espacio multimodal song-autoencoder de 64-dim (`spotify_tracks_song_ae`, “AE-64”), con R@10 0,173 [0,154, 0,192], MRR 0,096, confirmado con tres semillas. *Motivación.* El espacio de ítems del campeón — un latente AE de 64-dim — fue una elección temprana arbitraria, y la GRU de secuencias predice *hacia* y recupera *sobre* cualquier geometría que ese espacio imponga. Esta campaña pregunta qué *compresión* es el mejor espacio para la GRU: PCA lineal frente al autoencoder no lineal, cada uno a dimensión latente 32 / 64

/ 128. Se hornearon cinco espacios alternativos desde la *misma* fuente de contenido leak-safe de 384-dim (`spotify_tracks_content`), cada uno ajustado sin supervisión sobre los 23 529 ítems usando solo campos intrínsecos de contenido/acústica/catálogo (texto-384 + numéricos z-scored + acústicas `af_*` + multi-hot de género/tipo-álbum), nunca un campo conductual o de objetivo. Cada espacio se evaluó luego bajo un readout GRU *congelado* (`gru-infonce-h256: arch=gru, loss=infonce, hidden=256`, una capa, dropout 0.1, 40 épocas, lr 1×10^{-3} , batch 128, $k=10$), de modo que el espacio latente de ítems es el único eje que se mueve. La apuesta del diseño era que la pérdida de reconstrucción de peso igual por bloque del AE *preservaría* los pequeños bloques de acústica/catálogo que la varianza global dominada por texto de PCA muriera de hambre; la hipótesis nula era que la dimensión, no el compresor, fija el techo. Cada artefacto pasó una puerta de paridad idéntica (mismas 7154 sesiones / 19 402 ítems / partición / corte), así que la comparación es de igual a igual, y el $\text{paired-}\Delta$ es la diferencia de R@10 por sesión contra el control AE-64 del mismo lote.

Resultados. La puerta de paridad pasó: el control AE-64 reprodujo su R@10 registrado 0,0957 $\in [0,081, 0,112]$, así que el ranking es válido. Los seis espacios entrenaron limpiamente (Tabla 18; Figura 17). **PCA-128** (`spotify_tracks_song_pca128`, artefacto `seq-20260715-030509`; ejecución `run-20260715-042100-a1d9d`) es el ganador GRU-individual con R@10 0,1146, un $\text{paired-}\Delta$ de +0,0189 [+0,0042, +0,0335] sobre el control AE-64 — un IC *enteramente por encima de cero*, la única rama que supera el control significativamente — y también encabeza MRR (0,0489), `artist@10` (0,3326) y `artist_mrr` (0,2644). PCA-64 es el segundo (0,1041, $\text{paired-}\Delta$ cruzando cero: un empate). Los dos espacios de 32-dim (AE-32 0,0545, PCA-32 0,0412) quedan muy por debajo del control de 64-dim, ambos con IC de $\text{paired-}\Delta$ *enteramente por debajo de cero*. La sonda content-kNN sin entrenamiento (una recuperación coseno pura en cada espacio, última columna del informe) es plana en ~ 0.06 a través de los seis espacios y *no* sigue el ranking de la GRU: el R@10 de sonda de PCA-128 (0,0636) empata exactamente el control AE-64 (0,0636), y AE-32 encabeza la sonda (0,0720) pese a quedar casi-último bajo la GRU.

La victoria GRU-individual, sin embargo, **no** sobrevive al blend de producción. Re-fusionar la rama GRU PCA-128 ganadora con la rama de Markov (`seq-blend`, $\alpha=0,5$, semilla 1337; ejecución `run-20260715-044920-36dce`) puntúa R@10 0,1670 [0,148, 0,187], MRR 0,0923 — *por debajo* del blend campeón AE-64 (0,173, MRR 0,096) en ambas métricas, con IC solapados. Por la regla de decisión esto no es un evento de tabla: nada se promovió, el blend campeón AE-64 se mantiene, y PCA-128 se lleva adelante solo como el espacio base sancionado de la Fase 2.

Interpretación. Cuatro cosas se siguen. Primera, **la dimensionalidad latente es la palanca dominante y el compresor es secundario**: para PCA la tendencia es monótona ($0,041 \rightarrow 0,104 \rightarrow 0,115$ a través de dim 32/64/128), y 32 dims mueren de hambre el espacio sin importar el método. Segunda, **la hipótesis de preservación acústica del diseño queda refutada**: en dim generosa el PCA lineal supera al AE no lineal (PCA-128 > AE-128, PCA-64 $\geq$ AE-64), y aunque AE-32 preserva los bloques numérico/acústico casi a la perfección queda cerca del fondo — así que la preservación acústica es irrelevante para la recuperación de pista siguiente. Lo que ayuda es una geometría objetivo *ordenada por varianza y decorrelacionada* (PCA-128 captura EVR acumulado 0,982) que la GRU encuentra más fácil de regresar que los latentes de peso igual enredados del AE; el ordenamiento por varianza global de PCA es una ventaja aquí, no la desventaja que la hipótesis asumía. Tercera, la ventaja del AE es un fenómeno puramente de *baja capacidad* (AE-32 > PCA-32): el cuello de botella no lineal empaca más estructura utilizable en 32 dims, pero la ventaja se evapora y se revierte una vez que la dim es generosa. Cuarta, la sonda content-kNN plana que no sigue el ranking de la GRU es una *divergencia señalada*: la riqueza de recuperación intrínseca de estos espacios es similar, así que la ganancia de PCA-128 viene de la *aprendibilidad* de su geometría




Figura 17: La dimensión latente, no el compresor, es la palanca. Ambas series suben abruptamente de dim 32 a 64; PCA (azul) luego sigue subiendo hasta 128 y *sobrepasa* al AE, mientras que el AE (gris) se estanca — su punto de 128-dim (0,0929) de hecho cae por debajo de su propio control de 64-dim (0,0957). En dim 32 el AE roza a PCA, un cruce de baja capacidad que se revierte una vez que la dim es generosa. El control AE-64 (anillo rojo) es el espacio de ítems del campeón; el ganador PCA-128 (estrella verde) es la única rama cuyo IC del paired- Δ supera cero. Las barras de error son IC bootstrap al 95 %; los IC vecinos se solapan, así que la victoria descansa en el test *pareado*, no en los intervalos marginales.

objetivo para la GRU entrenada, no de un espacio demostrablemente más rico en lo absoluto — que es exactamente por qué la regla de decisión lo señaló en vez de auto-promoverlo. La salvedad de peso para el trabajo aguas abajo es el resultado del blend: una rama GRU claramente más fuerte (0,1146 vs 0,096) no compró *nada* en el blend, porque la rama de Markov es independiente de la representación y las pistas extra que la mejor GRU recupera evidentemente se solapan con lo que Markov ya aporta. **Las ganancias de representación medidas sobre la GRU individual no se trasladan automáticamente al blend de producción**, así que el eje de compresión es progreso genuino para el modelo individual pero esencialmente agotado para el blend. *Fuente: 2026-07-15-nexttrack-compression-representation-bakeoff.md.*

10. Pista siguiente Fase 1b/2: el techo de dimensión, el barrido de familia de modelos y el campeón R+M+C

El bake-off de compresión (Sección 9) halló que la *dimensión* latente es la palanca dominante y dejó a PCA aún subiendo en 128. Dos campañas de seguimiento localizaron el techo de dimensión, luego barrieron la familia de modelos sobre los espacios elegidos — y, en el proceso, coronaron una nueva fila «mejor registrada».

10.1. El techo de dimensión de compresión: PCA hace pico en 192

Motivación. Con la dimensión establecida como la palanca, este tramo extendió el barrido de PCA hacia arriba (PCA-192, PCA-256) para localizar el óptimo real antes de que la Fase 2 comprometiera un espacio base, y añadió AE-192 para probar si $\text{PCA} \geq \text{AE}$ se sostiene a mayor dimensión. El protocolo fue idéntico: todas las reps ajustadas desde la fuente leak-safe `spotify_tracks_content`, evaluadas bajo el *mismo* readout congelado `gru-infonce-h256`, cada nuevo artefacto de secuencias pasando la puerta de paridad exacta; la referencia es PCA-128 (run -20260715-042100-a1d9d), el ganador de la Fase 1, y el Δ pareado por sesión se mide contra ella.

Resultados. La curva de R@10 frente a dimensión de PCA **hace pico en ~ 192** (R@10 0,1230) y *se revierte* hacia 256 (0,1167); no seguía subiendo. La tendencia completa es $32 \rightarrow 0,041$, $64 \rightarrow 0,104$, $128 \rightarrow 0,115$, **192 $\rightarrow 0,123$** , $256 \rightarrow 0,117$ (Figura 18). PCA-192 es el óptimo puntual, pero su Δ pareado frente a PCA-128 es $+0,0084$ $[-0,0007, +0,0189]$ — falla la barra de “IC enteramente por encima de cero” por 0,0007, un pelo — así que por la regla mecánica **PCA-128 se mantiene como la base de la Fase 2**, con PCA-192 marcado como el candidato a confirmar-y-promover. $\text{PCA} \geq \text{AE}$ se sostiene con fuerza y la brecha es máxima en 192 (PCA-192 0,123 frente a AE-192 0,098); el AE se estanca plano en ~ 0.09 – 0.10 desde dim 64 hacia arriba.




Figura 18: Se encuentra el techo de dimensión. Extendiendo el barrido de compresión de la Figura 17 a PCA-192/256 y AE-192, la curva PCA (azul) hace pico en ~ 192 (R@10 0,123) y se revierte hacia 256, mientras que el AE (gris) se estanca plano en ~ 0.09 – 0.10 y nunca lo alcanza — la brecha $\text{PCA} \geq \text{AE}$ es máxima en 192. PCA-192 es el óptimo puntual (estrella verde) pero su Δ pareado sobre PCA-128 roza cero, así que PCA-128 (la base marcada) se mantiene como la base individual de la Fase 2. Las barras de error son IC bootstrap al 95 % sobre las 1431 sesiones de prueba.

Interpretación. La varianza extra más allá de ~ 192 (PCA-256 captura EVR acumulado 0,997) son dimensiones de baja señal / ruido que la GRU no puede explotar y que diluyen levemente la geometría objetivo. La meseta plana del AE reconfirma la hipótesis de preservación acústica refutada del bake-off a mayor dimensión: su objetivo de reconstrucción de peso igual sigue gastando capacidad en los pequeños bloques numérico/acústico (reconstrucción $R^2 \approx 0,999$ en 192) en lugar

de la estructura de texto/catálogo de alta varianza que la GRU necesita. Como antes, la sonda content-kNN sin entrenamiento sigue plana ($\sim 0.064-0.070$) y no reproduce el pico de la GRU, así que el óptimo de dimensión es sobre la *aprendibilidad* del objetivo, no la riqueza intrínseca de recuperación. *Fuente: 2026-07-15b-nexttrack-compression-dim-extension.md.*

10.2. El barrido de familia de modelos y el nuevo campeón, R+M+C sobre PCA-192

Motivación. Con el eje de compresión zanjado (base PCA-128, candidato PCA-192), esta campaña barrió la *familia* de modelos sobre los espacios elegidos: ¿una celda recurrente distinta (LSTM), un MLP agregado no recurrente (ANN) o un stacker XGB *aprendido* superan al z-blend fijo GRU $\times$ Markov — y añadir la tercera rama content-kNN (R+M+C) sobre el espacio PCA *rico* finalmente supera al campeón? Una configuración fija corrió a través de todas las ramas; solo variaron la familia de modelos y la representación, y el servidor se serializó (`--max-runs 1`) para evitar la trampa de sobresuscripción de hilos.

Resultados. Una **nueva fila «mejor registrada»**: el **z-blend R+M+C sobre PCA-192** (GRU $\times$ Markov solo de entrenamiento $\times$ content-kNN, tercios iguales) alcanza R@10 0,1859 [0,166, 0,207], MRR 0,1025, un Δ pareado sobre el campeón previo de +0,0133 [+0,0007, +0,0259] — enteramente por encima de cero, sin regresión de MRR (Tabla 19; Figura 19). La rama de contenido es genuinamente aditiva sobre el espacio rico, superando al R+M del mismo espacio en +0,0154 (PCA-128) / +0,0147 (PCA-192), ambos IC por encima de cero — *más fuerte* que el R+M+C de AE-64 que solo empató (Sección 8.4), porque el espacio más rico y de mayor EVR hace que la rama de contenido rinda. El **stacker XGB aprendido rinde muy por debajo** del z-blend fijo (0,080–0,087, perdiendo incluso ante su propia rama base GRU individual), reconfirmando la campaña de fusión; la **LSTM es el mejor modelo individual** (PCA-128 0,1272, Δ pareado sobre la GRU +0,0126, IC por encima de cero) pero muy por debajo de los blends; y la base individual de la Fase 2 **se mantiene en PCA-128** (la ventaja de la GRU-192 aún roza cero).

La coronación, y sus dos salvedades honestas. El candidato a evento de tabla se confirmó produciendo la rama GRU-192 cinco veces (la original más cuatro re-ejecuciones) y recalculando R+M+C cada vez; el Δ pareado sobre el campeón previo fue +0,0133 [+0,0007, +0,0259] en *cada* re-ejecución, con la ventaja de MRR intacta, así que R+M+C sobre PCA-192 se registró como la nueva fila campeona. Dos salvedades viajan con la coronación y no deben omitirse. Primera, **la dispersión de reproducción fue exactamente cero** porque el entrenamiento de **seq-nexttrack** es determinista en esta CPU — los cinco checkpoints GRU-192 fueron idénticos byte a byte — así que la confirmación verificó *determinismo, no robustez a la semilla*; la única incertidumbre cuantificada es el bootstrap de partición única. Segunda, **el límite inferior del Δ pareado es +0,0007**: la coronación supera cero por un pelo en una única partición. La coronación es real según el criterio pre-acordado, pero el margen sobre el campeón previo es delgado, y endurecerla requiere una segunda partición de prueba sin fugas (o ramas con semillas variadas una vez que el blend se generalice a tres ramas).

Interpretación. El hilo de compresión-más-familia-de-modelos queda por lo demás cerrado: PCA-128 es la base individual, la LSTM es el mejor modelo individual, el stacker aprendido está muerto como combinador, y el z-blend fijo es el combinador de referencia. El resultado de peso es que *el contenido es la única rama que añade señal de ranking genuinamente nueva, y rinde más sobre el espacio PCA de mayor EVR* — la excepción a la regla vigente de que las ganancias de modelo individual / representación no se trasladan al blend (el par R+M sobre los espacios PCA ricos solo empata al campeón AE-64). La brecha de productización persiste: el campeón es solo de entrenamiento y fuera del servidor, así que el campeón previo R+M sobre AE-64 sigue siendo




Figura 19: El barrido de familia de modelos de la Fase 2. El z-blend fijo es el combinador de referencia: R+M+C sobre PCA-192 (verde) es la nueva fila campeona, la rama de contenido es genuinamente aditiva sobre el espacio rico, y el stacker XGB aprendido (rojo) rinde muy por debajo — pierde incluso ante su propia rama base GRU individual. LSTM roza a GRU como el mejor modelo individual (gris) pero queda muy por debajo de los blends. La barra de Markov de primer orden (0,107) es la referencia incumbente; la fila campeona está en 0,186.

el ancla desplegable hasta que el blend de tres ramas se registre con un subcomando `predict`.
Fuente: 2026-07-15c-nexttrack-phase2-model-sweep.md.

11. Pista siguiente: la proyección de contenido aprendida, su registro y endurecimiento en dos particiones

El campeón R+M+C (Sección 10.2) llevaba dos salvedades delgadas — una confirmación por reproducción solo-determinista y un límite inferior del paired- Δ de solo +0,0007 — y su margen estaba acotado por la tasa de ítems fríos de 0,55, que solo la señal *nueva* puede atacar. Tres campañas de finales de julio coronaron, registraron y endurecieron un campeón genuinamente nuevo. Esta sección incorpora las dos primeras (la victoria y su productización); los hilos de vector de ítem y music@10 siguen en las Secciones 12 y 13.

11.1. La campaña de ajuste-a-la-literatura: una proyección de contenido supervisada gana

Motivación. Guiada por un estudio de la literatura establecida de recomendación en sesión (la línea de session-kNN de Jannach–Ludewig, reglas secuenciales / Markov factorizado, trucos de entrenamiento de GRU4Rec, fusión de rankings y learning-to-rank, recomendación en sesión consciente de contenido / arranque en frío), esta campaña pre-registró tres niveles de métodos

clásicos y preguntó cuáles mejoran realmente el ajuste a *este* problema — una tarea de *recuperación* de pista siguiente distinta, de un solo usuario, basada en sesión, con 55 % de objetivos fríos. Todas las ramas se midieron fuera del servidor sobre el artefacto campeón PCA-192 seq-20260715-131139, reutilizando el driver sancionado que reproduce al campeón (R+M+C 0,1859) exactamente; el estadístico de decisión es el Δ pareado por sesión contra ese campeón.

Resultados — la única victoria. Una **proyección de contenido aprendida** supervisada es una nueva fila «mejor registrada». Ajustar un mapa métrico lineal W del espacio de contenido PCA-192 hacia la adyacencia de pista siguiente (InfoNCE sobre pares consecutivos de entrenamiento, auto-bucles descartados) y luego recuperar *ambas* la rama de contenido (C') y la GRU (R') en ese espacio proyectado da **z-blend** $R'+M+C'R@10$ 0,2117 [0,191, 0,233], **MRR** 0,1220 — un Δ pareado sobre el campeón de +0,0259 [+0,012, +0,041], enteramente por encima de cero (Tabla 20). A diferencia de la coronación R+M+C es **robusta a la semilla** (tres semillas; Δ pareado +0,026 / +0,025 / +0,029, todos IC > 0) y **alcanza ítems fríos**: la rama de contenido proyectada C' puntúa objetivos fríos 0,152 $\approx$ cálidos 0,151, frente a los cálidos 0,226 / fríos 0,010 de Markov, así que alcanza la mayoría fría del 55 %. El mapa simétrico único supera al two-tower direccional, y rango-192 = rango-64 (la ganancia es la supervisión, no la capacidad). Como efecto secundario, la GRU individual proyectada R' ($\sim$ 0,176) casi iguala al blend campeón *antiguo* y aplasta al mejor individual previo (LSTM 0,127).

Las vías que se cerraron. Toda otra dirección no logró superar al z-blend fijo, como el estudio predijo para un corpus de un solo usuario y con muchos fríos (Tabla 21). El suavizado principiado de Markov (descuento absoluto + un piso de continuación de Kneser–Ney) es una ganancia en solitario real pero minúscula (0,1069 $\rightarrow$ 0,1104) que se diluye en el blend (−0,0021, IC cruza 0). Un combinador consciente de ranking no tiene margen honesto: incluso los pesos *oráculo*, ajustados sobre las etiquetas de prueba, alcanzan solo 0,1901 (+0,0042, cruza 0), y la fusión RRF *perjudica* el recall (−0,029, IC<0). Un kNN de sesión V-SKNN con puerta es solo-cálido frente al 55 % de fríos y *arrastra* el blend (−0,038, IC<0). Y los negativos por importancia de GRU4Rec dan un tick en solitario dentro del ruido (+0,005) que también se diluye (−0,0014, empate). **La única ganancia aditiva viene de señal nueva, no de fusión más astuta.**

Interpretación. La proyección de contenido supervisada es la primera señal nueva genuinamente aditiva desde la propia rama de contenido, y funciona por la razón que el estudio señaló: el contenido es el único canal con alcance a fríos, y reemplazar la geometría PCA no supervisada y ordenada por varianza por una ajustada al objetivo eleva *ambas* ramas que la comparten. Los métodos prestados vistosos son callejones sin salida aquí porque o rebarajan las mismas tres ramas (sin margen sobre el z-blend, incluso para el oráculo) o importan una suposición colaborativa que el corpus de un solo usuario viola. *Fuente: 2026-07-18-nexttrack-literature-fit-campaign.md.*

11.2. Registro, el barrido de objetivo / rango / τ , y endurecimiento en segunda partición

Motivación. La victoria de la proyección aterrizó como driver fuera del servidor. Este seguimiento la implementó como capacidad de primera clase del predictor **seq-blend** (hiperparámetros `projection`, `projection_rank`, `projection_objective`, `projection_tau`, ...), luego reprodujo la victoria on-server, la registró + promovió, y corrió un barrido de ablación pre-aprobado.

Registro. El run de verificación (run-20260718-191539-1b89c-seq-blend, default de la definición = InfoNCE / rango completo / τ 0,07) reprodujo el driver fuera del servidor a cuatro decimales — R@10 0,21174, MRR 0,12199 — y se promovió vía la API como **blend-gru-markov-content-proj**, con la matriz de proyección horneada en el directorio del modelo para servicio. GET /api/best-models lo confirma en **rango 1** (0,21174), por encima del

campeón servible previo `blend-gru-markov-content` (rango 2, 0,18588); es servible vía `POST /api/models/blend-gru-markov-content-proj/predict`.

El barrido. La regla de decisión — re-promover solo una config que supere al default en *ambos* $R@10$ y MRR por más que la banda de ruido de $\sim \pm 0,015$ — confirma el default (Tabla 22). **InfoNCE** $\gg$ **BPR** es el eje más agudo: ambas celdas BPR (0,1579, 0,1523) caen $\sim 0,055$ bajo el default y aterrizan *por debajo incluso del viejo campeón $R+M+C$* (0,1859). **Rango completo $\geq$ rango-64** ($-0,006$, un empate). Y τ es **levemente sensible y monótona hacia arriba** ($0,05 \rightarrow 0,1929$, $0,07 \rightarrow 0,2117$, $0,10 \rightarrow 0,2229$) — pero la celda superior nominal $\tau-0,10$ supera al default por solo $+0,0112$ en recall, *dentro* de la banda, así que es un empate y el default se **MANTUVO**. A diferencia del eje de reponderación de la Sección 11.1, aquí las métricas graduadas *siguen* al recall, porque el barrido mueve la *calidad de señal* en vez de refusionar ramas fijas.

Endurecimiento en segunda partición. La coronación se midió sobre una única partición sin fugas; un pase solo-de-validación la re-corrió (más los dos blends de referencia) sobre una **segunda partición disjunta y sin fugas** `seq-20260718-211238` — una banda cronológica de holdout-temprano 60–80 % sobre el mismo espacio PCA-192, con espacio de ítems idéntico byte a byte, ventana de prueba disjunta en índice y tiempo respecto al test 80–100 % de la partición campeona, con una **tasa de ítems fríos** de 0,64 (vs 0,55). Por construcción el $R@10$ absoluto aterriza por debajo del 0,212 de la primera partición; el veredicto es el Δ pareado (Tabla 23; Figura 20). La regla de decisión (Δ pareado vs $R+M+C$ con IC enteramente > 0 y MRR sin regresión) se cumple: Δ pareado $+0,0426$ [$+0,0280$, $+0,0573$], $MRR +0,0234$. El margen es *más ancho* aquí que en la primera partición ($+0,0259$) — en una partición más fría las ramas Markov / content-kNN de la coronación alcanzan menos objetivos y la rama C' de la proyección, que alcanza fríos, carga proporcionalmente más de la victoria. La coronación está ahora endurecida en dos particiones disjuntas sin fugas, resolviendo ambas salvedades de $R+M+C$.

Fuente: 2026-07-18b-nexttrack-projection-registration-and-scan.md.

12. Pista siguiente: exploración de representación del vector de ítem

Motivación. El eje de compresión (Secciones 9 y 10.1) halló que la *dimensión* latente domina pero nunca preguntó si la *composición* del vector de ítem de 192-d — el PCA de 4 bloques de peso igual (texto / numérico / acústico / categórico) — es en sí misma un lastre. Un preflight de ratio de varianza explicada (EVR) dijo que podría serlo: el presupuesto de varianza de entrada crudo es 44 % acústico + 43 % numérico frente a solo 2.5 % texto (el texto está L2-normalizado, así que su escala por dimensión es minúscula), así que el PCA-192 de matriz completa gasta **87 % de su presupuesto de varianza** reconstruyendo los bloques numérico + acústico a $R^2 = 1,000$ mientras que el bloque de texto portador de señal alcanza solo $R^2 = 0,717$; la estandarización por columna (whitening) voltea el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905) (Figura 21). Se construyeron ocho espacios de latentes de ítems alternativos con puerta de paridad respecto a la partición campeona (solo difiere `item_latents.f32`) y cada uno se evaluó bajo *dos* readouts: **(A)** la proyección campeona `blend-gru-markov-content-proj` (el techo del espacio bajo la receta ganadora) y **(C)** la GRU individual congelada `gru-infonce-h256` (calidad de representación cruda). Solo-validación; nada promovido.

Veredicto. **Readout A: ninguna variante supera al campeón PCA-192 con IC del Δ pareado enteramente > 0** (V3 std-noaco $+0,0049$ y V5 balanced $+0,0042$ cruzan 0; V4 textcat $-0,0168$ y V6 sonic-64 $-0,0182$ regresan). **Readout C: seis de ocho variantes superan a la GRU congelada con IC del Δ pareado enteramente > 0** ($+0,025$ a $+0,036$). Así que la




Figura 20: La ventaja de la proyección *se ensancha* en la partición más fría. Sobre la partición canónica con 0.55 de fríos el campeón de proyección supera a la coronación R+M+C por Δ pareado +0,0259; sobre una partición disjunta y más fría de holdout-temprano con 0.64 de fríos el margen *crece* a +0,0426 (ambos IC enteramente > 0). El R@10 absoluto es menor en la partición más fría por construcción; el veredicto es el Δ pareado. La rama C' que alcanza fríos carga proporcionalmente más de la victoria donde hay más objetivos fríos.

geometría cruda *es* un lastre — suprimir las direcciones ruidosas eleva la GRU cruda en $\sim 20\text{--}29\%$ relativo — **pero la ganancia es absorbida por completo por la proyección**, que ya reponderó esas direcciones de los datos. El whitening y la proyección aprendida son el mismo arreglo, y el campeón ya lo accionó. El eje graduado se mueve más limpiamente que el recall exacto (el whitening eleva el genre@10 de la GRU congelada a $\sim 0,47$; un espacio solo-texto publica los máximos de artist@10 / genre@10 de readout A), y la métrica continua music@10 (Sección 13) corrobora: el campeón de proyección la lidera (0,4538) sobre R+M+C (0,4491), y es plana a través de las ocho representaciones ($\sim 0,447\text{--}0,460$). Una precaución: dejar caer numérico+acústico *por completo* (V4) perjudica al campeón aunque ayude a la GRU cruda, así que conservar numérico y hacer whitening / dejar caer solo acústico. *Fuente: 2026-07-18c-nexttrack-representation-exploration.md.*

13. Pista siguiente: la métrica de distancia musical music@10

Motivación. El recall@10 exacto es implacable sobre un corpus de un solo usuario con 55 % de fríos. Esta campaña introduce una métrica graduada *continua* de tipo “suena parecido”, **music@10**, y la back-fillea a través de cada run de pista siguiente. Es la media sobre casos de prueba del mejor coseno (máximo), en un espacio intrínseco *balanceado* de distancia musical (`spotify_tracks_content_metric`: una fusión con pesos por bloque, parcialmente whitened, del latente song-AE de 64-d whitened, el embedding de texto de nombre/tag de 384-d, cinco numéricos de metadatos, y un prototipo AE por género), entre la siguiente pista verdadera y los diez candidatos recuperados. Un top-diez que contiene la verdad exacta puntúa 1,0, así que music@10 es un *superconjunto suave* de recall@10 ; es solo de visualización (la métrica principal sigue siendo




Figura 21: Por qué el vector de ítem es un lastre para un modelo crudo — y por qué la proyección es el arreglo. El PCA-192 de peso igual ordena las dimensiones por varianza cruda, así que 87 % de su presupuesto capturado reconstruye los bloques numérico + acústico conductualmente inertes (popularidad / era / volumen) mientras que el bloque de texto portador de señal (2.5 % de la varianza de entrada cruda, L2-normalizado) queda infra-preserved (R^2 0,717). La estandarización por columna voltea el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905). La proyección InfoNCE aprendida aprende esta misma reponderación de los datos.

recall@10).

Resultados. music@10 se recalculó offline y de forma no destructiva a través de los 53 runs de pista siguiente (desde el `predictions.json` almacenado de cada run y su `items.json` de dataset, sobre la partición compartida de 1431 casos). **Correlaciona** con recall@10 ($r = 0,609$) pero está lejos de ser redundante, y corona a un ganador *distinto* (Tabla 25; Figura 23). El campeón de recall@10 es un run **seq-blend** (0,223), pero las predicciones *más cercanas musicalmente* vienen de **seq-nexttrack** — que regresa directamente el latente de contenido de la siguiente pista y recupera por coseno — con mejor music@10 0,482 y la media de familia más alta (0,448). El piso **seq-popularity** es correctamente el peor (0,185), confirmando que la métrica no está trivialmente saturada.

Interpretación. music@10 es una vista genuinamente distinta y no saturada de la calidad de pista siguiente: premia la proximidad *sónica*, que la métrica de acierto exacto ignora. El desacople recall-versus-music tiene un mecanismo limpio — un modelo que regresa el latente de contenido (**seq-nexttrack**) aterriza *cerca* de la verdad en el espacio de contenido incluso cuando falla la pista exacta, así que sus fallos “suenan bien” más a menudo que los del blend. Por eso la métrica es solo de visualización y no debe volverse silenciosamente un objetivo de selección; la promoción aún ordena por recall@10. Hereda una circularidad leve del dial *balanced* (el bloque de texto embebe el nombre del artista; el bloque de género es un prototipo de género), así que premia parcialmente la proximidad de mismo-artista / género. *Fuente: 2026-07-20-musical-distance-metric.md.*




Figura 22: El lastre de representación es real para la GRU *cruda* pero *absorbido* por la proyección campeona. Seis de ocho espacios de whitening / drop-acústico / métricos elevan la GRU congelada (readout C, verde; los seis con IC del paired-Δ enteramente > 0), pero ninguno eleva la proyección campeona (readout A, azul; los dos espacios nominalmente positivos cruzan 0, y V4/V6 regresan significativamente). El mapa InfoNCE aprendido ya reponderó fuera las direcciones acústicas / numéricas ruidosas: el whitening y la proyección son el mismo arreglo.

14. Next-track: métricas de holisticidad de sesión y las palancas anti-eager (MMR λ / eager β)

Motivación. Una queja cualitativa recurrente sobre los mejores blends es que sus predicciones se sienten “demasiado album-eager / de tipo bigrama” — repiten como loro el artista actual en lugar de curar una continuación holística. Esta campaña cuantifica ese síntoma con una nueva suite *solo de visualización* de métricas de *holisticidad de sesión*, pone a prueba la hipótesis del usuario de que *la GRU supera a la LSTM porque es más eager* (más ansiosa por repetir el artista actual), y mide si dos nuevas palancas de la Fase 2 reducen esa eagerness a un costo de recall aceptable: un re-ranqueo MMR en evaluación (`mmr_lambda`) y un regularizador anti-eager de entrenamiento (`eager_beta`). Es un pase de medición / exploratorio: no se promueve nada, la métrica principal sigue siendo Recall@10 y la decisión sobre el objetivo de holisticidad se difiere explícitamente al usuario. Cada rama corre sobre la partición *canónica* PCA-192 del campeón `seq-20260715-131139` (1431 sesiones de test; tasa de ítems fríos 0,55), y el campeón reprodujo exactamente su Recall@10 de registro 0,2117 (0,211 74).

Las nuevas métricas de holisticidad solo de visualización. Cableadas de extremo a extremo junto a `music@10` (`seq_common.eval_from_scores` → Rust → `domain.toml` → UI); la métrica principal no cambia.

artist_adj@10 (↓). Fracción del top-10 que comparte el artista de la pista *semilla* — la tasa de “repite como loro el artista actual”. **Menor es mejor.**




Figura 23: music@10 frente a recall@10 a través de los 53 runs de pista siguiente, un punto por run, coloreado por familia de predictor. Los dos ejes correlacionan ($r = 0,609$) pero coronan ganadores distintos — el campeón de recall@10 (un run **seq-blend** en 0,223) no es el más cercano musicalmente, que es un run **seq-nexttrack** (music@10 0,482) que regresa el latente de contenido y recupera por coseno. music@10 es solo de visualización; recall@10 sigue siendo la métrica principal.

album_adj@10. Lo mismo sobre (artista, álbum); **omitida en este dataset** porque su `items.json` no lleva el campo de álbum (esperado, no un error — cubierto por un dataset separado que sí lleva álbum).

mood_coh@10 (↑). Coseno medio del top-10 al centroide de mood del prefijo en el espacio content-metric; mayor es más coherente en mood.

ild@10 (↑). Diversidad intra-lista (distancia sónica media por pares) del top-10; mayor es menos duplicativo.

suffix_recall@10 / cont_prec@10. Cobertura de continuación multi-paso, producida solo por el arnés bajo demanda `seq_continuation_eval.py` (Fase E, abajo), no por los runs normales.

La puerta de sanidad pasó: music@10 / mood_coh@10 / ild@10 se pueblan en todos los runs de blend y GRU, de modo que los vectores content-metric cargaron y las palancas MMR / mood / ild están vivas, no son no-ops. Ambas palancas nuevas están APAGADAS por defecto y verificadas byte-idénticas al estar apagadas.

Resultados — la huella de holisticidad (Fase A). La Tabla 26 toma la huella de la familia de modelos. **La eagerness sigue a Recall@10 dentro de la familia de blends** — el campeón (Recall@10 0,2117) es el modelo *más* artist-eager medido (artist_adj@10 0,610), con R+M a continuación (0,579) — pero la eagerness vive en la pata de *Markov*, no en la RNN: la barra de Markov de primer orden por sí sola ya está en 0,543, mientras que la GRU / LSTM individuales quedan mucho más abajo, en artist_adj@10 $\approx 0,345$. Así que los blends compran su ventaja en

Recall@10 siendo artist-adyacentes (de tipo bigrama), que es exactamente lo que la suite de holística señala. Las RNN individuales son, en cambio, los modelos *coherentes en mood y de baja eagerness* (el mayor mood_coh@10, el menor artist_adj@10 entre modelos reales). Crucialmente, las métricas *no se juegan trivialmente*: el suelo de popularidad maximiza ild@10 (0,898) y minimiza artist_adj@10 (0,003) pero puntúa ≈ 0 recall y mood_coh@10 *negativo* — se maximizan siendo aleatorio, así que los modelos de baja eagerness / alta diversidad con sentido son las RNN individuales reales.

GRU frente a LSTM (Fase B) — la hipótesis no se sostiene. Con los hiperparámetros igualados (h256, InfoNCE, 40 épocas, lr 1×10^{-3}), la GRU y la LSTM quedan estadísticamente *empatadas*: Recall@10 0,1230 frente a 0,1188 ($\Delta +0,0042$, dentro de la banda $\pm 0,015$), y artist_adj@10 0,347 frente a 0,344 (un $+0,003$ despreciable). La GRU no es mediblemente más eager que la LSTM en esta partición, así que la hipótesis “la GRU gana porque repite el artista actual con más fuerza” queda **refutada aquí**.

La palanca MMR λ (Fase C) — la palanca fuerte. MMR es un re-ranqueo puramente en evaluación, así que los cuatro runs de entrenamiento por- λ lanzados originalmente fueron *cancelados* (no experimentos fallidos); el barrido se computó offline desde el único checkpoint del campeón (la celda $\lambda=\text{off}$ reprodujo exactamente el Recall@10 0,2117 del campeón). A medida que λ cae de off hacia 0,3 (Tabla 27; Figura 24), Recall@10 baja — lo *único* que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (des-eagering). $\lambda=0,9$ es **esencialmente gratis**: el Δ de recall es $-0,0014$, bien dentro de la banda $\pm 0,015$ (un empate), pero ya eleva ild@10 $0,406 \rightarrow 0,436$ y recorta la eagerness $0,610 \rightarrow 0,603$. $\lambda \approx 0,7$ sacrifica ~ 2 puntos de recall ($\Delta -0,0181$, justo fuera de la banda) por una gran ganancia de ild@10 ($0,406 \rightarrow 0,520$) y una caída real de eagerness ($0,610 \rightarrow 0,571$). Un efecto colateral notable: **music@10 sube monótonamente** a medida que se diversifica ($0,454 \rightarrow 0,492$) — cercanía sónica y diversidad de lista no están en tensión; solo se sacrifica el recall exacto.

El regularizador anti-eager β (Fase D) — la palanca débil. Una penalización de entrenamiento sobre la predicción casi-copia del latente de la pista actual (eager_margin 0,0) apenas mueve la aguja (Tabla 28): a lo largo de β 0 a 0,2, artist_adj@10 solo se desplaza $0,347 \rightarrow 0,340$ ($\Delta -0,0074$) e ild@10 solo $0,454 \rightarrow 0,458$, con Recall@10 plano (las cuatro dentro de $\pm 0,015$). La GRU individual ya es de baja eagerness (0,347), así que queda poco comportamiento de copia para penalizar — β no es una palanca de holística útil en estos ajustes.

Continuación multi-paso (Fase E). El arnés bajo demanda (seq_continuation_eval.py -m 3 -k 10, 1172 casos de continuación) muestra que la GRU *supera* al bigrama de Markov en ambas métricas multi-paso (Tabla 29): la ventaja de la RNN *se ensancha* más allá de la pista siguiente inmediata, porque la co-ocurrencia de un solo paso del bigrama no se compone en buenas continuaciones de 3 pasos, mientras que el estado de secuencia aprendido de la GRU sí — la imagen especular del tablero de un solo paso, donde el blend con bigrama gana el Recall@10 crudo.

Interpretación y la decisión diferida. La campaña entrega un relato mecanístico limpio del síntoma de eagerness: proviene de la pata de bigrama de Markov (que repite como loro el artista actual vía co-ocurrencia cruda), no de la pata neural, así que cualquier des-eagering futuro debería apuntar al bigrama / la fusión, no a la RNN. De las dos nuevas palancas, el re-ranqueo MMR en evaluación es la palanca *fuerte* y el regularizador β de entrenamiento es *débil*. No se promueve nada — la métrica principal sigue siendo Recall@10 y el campeón no cambia — pero $\lambda \approx 0,9$ **queda señalado como una mejora de holística casi gratis para una futura decisión de promoción del usuario** (Recall@10 empate dentro del ruido, ild@10 $0,406 \rightarrow 0,436$, eagerness $0,610 \rightarrow 0,603$), con $\lambda \approx 0,7$ como el punto de operación de “des-eagering significativo por ~ 2 puntos de recall”; adoptar cualquiera de los dos requiere una decisión del usuario más una confirmación




Figura 24: El trade-off de MMR λ sobre el campeón de pista siguiente. A medida que λ cae de off hacia 0,3, Recall@10 (rojo, eje izquierdo) baja — lo único que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (eje derecho; más diverso, menos artist-eager) y music@10 incluso *sube*. $\lambda=0,9$ queda dentro de la banda de empate de recall $\pm 0,015$ pero ya eleva ild@10 en 0,030; $\lambda \approx 0,7$ compra una gran ganancia de ild@10 y des-eagering real por ~ 2 puntos de recall. MMR es la palanca de holisticidad fuerte; β (Tabla 28) es débil.

de 3 semillas / run nativo. El regularizador β no se recomienda como palanca en estos ajustes.
Fuente: *2026-07-22-session-holisticness-and-antieager-levers.md*.

15. Conclusiones

Trece campañas (jun–jul 2026) sobre el objetivo de rotación girado convergen en una única historia, con una salvedad de última hora (punto 12). (1) A través de dos campañas de rasgos y tres barridos de familia de modelos (dos corpus), toda modalidad densa y toda familia densa de distancia/margen/red-densa pierde ante los one-hots de identidad categórica leídos por árboles de gradient boosting — el latente song-AE diluye (Sección 5.1), el SVM de kernel es peor-que-la-media (Sección 5.2), y sobre el nuevo corpus completo de 64-d las dos familias de árboles lideran mientras el pyramid-MLP denso es último (Sección 5.4). (2) La elección de métrica es de peso sobre un objetivo binario: el MAE es degenerado (un predictor de tubo- ϵ de dos niveles publica un MAE engañosamente bajo siendo peor que la media), y un blend por-grilla-por-MAE incluso selecciona mal tal predictor; las métricas de clasificación honestas (AUC, log-loss, Brier) restauran una comparación justa (Sección 5.3). (3) Las campañas entregaron dos bandas de ruido medidas — $2\sigma = 0,0086$ MAE y $2\sigma = 0,0126$ AUC — y el primer campeón de rotación registrado y promovible del proyecto, *xgboost-classifier-rotation* con AUC 0.7429 sobre DS-META, más una definición xgboost guardada del nuevo corpus con AUC 0.7204. (4) La red neuronal densa se diagnosticó por completo (Sección 6): un barrido de arquitectura refutó la hipótesis de presupuesto (cada geometría se auto-detiene en 73–100 iteraciones y la red convergida reproduce el AUC subentrenado hasta todos los dígitos), así que la restricción vinculante es la *representación* de one-hots

crudos, no la optimización — y el log-loss peor-que-el-azar de la red junto a un AUC genuino la marca como confiadamente mal calibrada, no meramente débil. (5) Ese diagnóstico se probó luego directamente: el **burn-deep-classifier** en Rust/**burn**, que alimenta los one-hots de identidad en *crudo*, reparó la calibración por completo (log-loss $2,0 \rightarrow \sim 0,62$, al régimen de los árboles) y elevó el AUC ~ 2 bandas a 0,7038 (Sección 6.7) — confirmando que la patología fue un artefacto de representación, no una propiedad intrínseca de las redes. Pero la brecha con los árboles solo se *estrechó* (de ~ 3.3 bandas a ~ 1), no se cerró: la red aún queda bajo **catboost** y **xgboost**, el **mlp** plano superó tanto a las topologías de embedding como wide-deep (los embeddings de entidad están famélicos a la baja cardinalidad de identidad del corpus), y nada superó la barra de guardado ~ 0.71 . (6) Esa palanca vigente se accionó luego. Una re-ejecución pareada sobre una matriz *high-vocab* — idéntica al dataset 60/40 pero con el tope de artista elevado $60 \rightarrow 300$ y género $40 \rightarrow 120$ — *volteó* el ranking de topología (Sección 6.8): **embeddings**, famélica y última sobre la matriz 60/40, ahora *supera* a **mlp** (un vuelco de $+0,0130$ que revierte el resultado previo y confirma la hipótesis de inanición direccionalmente), y la red guardada alcanza el nivel de los árboles dentro del dataset con AUC 0,7192 (dentro de ~ 1 banda de **catboost**) — la primera ANN en superar la barra de guardado de rotación, guardada como **burn-deep-embeddings-highvocab**. El hallazgo convergente aún se mantiene arriba (**xgboost** lidera toda matriz, y mayor resolución eleva a *toda* familia, no solo al embedding), pero el hilo de trampas-ANN queda ahora cerrado: una red consciente de la representación que consume one-hots crudos está calibrada en el régimen de los árboles, y dada suficiente resolución de identidad su topología de embedding alcanza el nivel de los árboles — la resolución de identidad era la palanca todo el tiempo. (7) Una sonda final probó luego el inverso de la palanca — si una representación aprendida *derivada del árbol*, en vez de alimentada junto a él, podía superar al árbol puro — y la refutó: el truco de Facebook GBDT $\rightarrow$ LR generalizado a GBDT $\rightarrow$ MLP, con una cabeza fresca entrenada sobre los índices de hoja one-hot del campeón congelado, tope 1,8–2,4 bandas bajo el campeón **xgboost** puro (mejor AUC de cabeza 0,6978) y está mal calibrada en cada cabeza, porque los one-hots de hoja son una vista estrictamente más lossy de un árbol cuyo scoring aditivo de valores de hoja ya pondera las hojas óptimamente (Sección 6.10). La cabeza densa ni siquiera puede recuperar el árbol que generó sus rasgos — la séptima confirmación convergente de que la resolución de identidad, no nuevas cabezas o representaciones apiladas sobre los árboles, es la palanca durable. (8) Finalmente, la palanca de resolución de identidad vigente se mapeó hasta su borde: un barrido de tope de vocabulario sobre el GBDT puro — config campeona congelada, solo **vocab_top_n** movido — muestra que la palanca está *en gran medida agotada* (Sección 6.11). El primer salto de cardinalidad (60/40 $\rightarrow$ 300/120) lleva la ganancia; pasado 300/120 cada paso es sub-banda, la curva se estanca dentro del sobre de ruido, **xgboost** alcanza solo 0,7349 en 1000/300 ($+0,005$, ~ 0.4 banda sobre el ancla, así que ningún save disparó), y **catboost** lo sigue — dos familias de árboles coincidiendo en que las columnas marginales de alta cardinalidad llevan poca señal independiente. No saturada y no revertida, pero disminuyendo: la altura cruda del tope ya no es la palanca durable, y el trabajo futuro de identidad debería apuntar a la *calidad* de resolución (interacciones de seguidores/popularidad, jerarquía de género) en vez de topes más grandes — con el punto de vocabulario completo (6633 cols) aún no medido contra un techo de memoria del host.

(9) Una décima campaña caracterizó una *segunda* red consciente de la representación y alcanzó el mismo techo: el **burn-ae-classifier** de dos fases, que pre-entrena un autoencoder sobre el vector de rasgos ensamblado y trasplanta el encoder a un clasificador, es plano a través de 13 configs de capacidad/cabeza (una franja de 0,0054 de ancho dentro de la banda), empata con el **mlp burn-deep** plano, y se mantiene ~ 1.8 bandas bajo el campeón de árboles; congelar el encoder pre-entrenado por MSE bajo una cabeza profunda es un modo de colapso documentado (Sección 6.9).

El latente de reconstrucción no supervisado es agnóstico a la tarea — una tercera confirmación de que una representación aprendida aguas abajo de los one-hots de identidad no compra poder de ranking que los árboles no tengan. (10) Dos campañas de interpretabilidad abrieron las redes con un autoencoder disperso por modelo (Secciones 6.12, 6.13): con AUC igual, una pirámide que se estrecha *consolida* sus conceptos interpretables en un cuello de botella comprimido mientras una red uniforme mantiene un conjunto más amplio, y en vocabulario alto un par embeddings/mlp empatado en AUC captura la *misma* señal decodable ~ 0.14 con distinta asignación de conceptos — “misma señal, distinta disposición”, invisible a la tabla. (11) Un barrido de capacidad sobre la matriz high-vocab confirmó que la red densa está en su techo allí: ni ensanchar ni profundizar supera al control [128, 64] por una banda, una tercera capa de embedding *perjudica* (-0.0152 , dilución no inanición), y el mejor mlp empatado con el mejor embeddings — la capacidad, no el mecanismo de embeddings, fue la palanca, y está agotada (Sección 6.13). (12) Finalmente, se planteó la pregunta honesta hacia adelante — y reencuadra toda la tabla. Una partición cronológica de primera clase (entrenar-antes / probar-después) baja el campeón de AUC 0,735 a 0,619, un colapso de ~ 0.11 que es *universal* a través de xgboost, catboost y logistic y es no-estacionariedad de gusto genuina, no censura-a-la-derecha; una lectura walk-forward aterriza en 0,59–0,67 cada año, nunca cerca de la línea base aleatoria (Sección 7). Todo AUC registrado es por tanto una cota superior del ranking de misma era; la habilidad real hacia adelante de “¿reproduciré una canción que descubra a continuación?” es ~ 0.62 – 0.63 . El mecanismo es la rotación de identidad — artistas futuros no vistos caen en `__other__` y el modelo debe recaer en el piso intrínseco más débil ~ 0.60 — que es precisamente por qué topes de vocabulario más altos y redes más grandes, ambas palancas de memorización de misma era, no transfieren hacia adelante. Esto no revierte ningún número de partición aleatoria; clarifica qué miden y hace de la señal intrínseca generalizable más rica la única palanca restante para el rendimiento hacia adelante.

(13) Una línea de trabajo paralela — recomendación de *pista siguiente* (next-track), cuya tarea y métricas no tienen relación con las tablas de rotación de arriba (Secciones 8–10) — se consolidó a través de doce campañas. Una GRU de sesión por sí sola solo *empata* con la barra de co-escucha de Markov de primer orden y pierde en MRR, y ni el ajuste de pérdida ni ninguna topología (profundidad/anchura/residual/dirección) la supera. Pero un z-blend R+M de *fusión de rankings* (GRU $\times$ Markov) supera la barra de forma decisiva (+61 % de R@10, confirmado con 3 semillas) porque las dos ramas ordenan pistas correctas *distintas*; un stacker XGB aprendido rinde por debajo del z-blend fijo, y añadir ramas neuronales redundantes no ayuda — la victoria es diversidad de señal, no número de modelos. La única señal nueva genuinamente aditiva es el *contenido*: un barrido de representación de ítems halló que la *dimensión* latente (no el compresor) es la palanca y hace pico en PCA-192, y sobre ese espacio rico un z-blend R+M+C de tres ramas es la fila «mejor registrada» actual con R@10 0,1859, MRR 0,1025 (Δ pareado sobre el campeón previo +0,0133, IC>0). Dos salvedades acotan la coronación: la confirmación por reproducción tuvo dispersión cero porque `seq-nexttrack` es determinista en esta CPU (así que verificó determinismo, no robustez a la semilla), y el límite inferior del paired- Δ supera cero por solo +0,0007 en una única partición. Todo predictor de ranking de pista siguiente *fue* solo de entrenamiento y fuera del servidor hasta el arco de la proyección: una *proyección de contenido aprendida* supervisada ($R'+M+C'$) — un mapa métrico InfoNCE del espacio de ítems PCA-192 en el que recuperan la GRU y la rama de contenido — superó luego la coronación R+M+C con R@10 0,2117 (paired Δ +0,0259 IC>0), resolviendo ambas salvedades de R+M+C (es robusta a la semilla $\times 3$ y alcanza fríos) y endureciéndose en una segunda partición disjunta con 0.64 de fríos (paired Δ +0,0426 IC>0, más ancho en la partición más fría); ahora está *registrada, promovida y servible* (`blend-gru-markov-content-proj`, rango 1 del grupo de mejores modelos, Secciones 11–11.2), cerrando la brecha de productización, mientras

que todo método prestado de ajuste-a-la-literatura (session-kNN, fusión de rankings, combinadores aprendidos, suavizado de Markov, trucos de pérdida de GRU) se cerró. Una exploración de representación del vector de ítem confirmó luego que la geometría PCA-192 de peso igual lastra un modelo *crudo* pero el arreglo es *absorbido* por la proyección (Sección 12), y una métrica continua de tipo “suena parecido”, *music@10* — correlacionada con *recall@10* ($r = 0,609$) pero coronando al **seq-nexttrack** que regresa contenido como el más cercano musicalmente — se añadió como columna solo de visualización (Sección 13). Finalmente, una campaña de medición añadió una suite *solo de visualización* de holisticidad de sesión (*artist_adj@10* / *mood_coh@10* / *ild@10*): el síntoma de eagerness *sigue* a Recall@10 dentro de la familia de blends (el campeón es el modelo más artist-eager, *artist_adj@10* 0,610) pero proviene de la pata de bigrama de *Markov*, no de la RNN (GRU / LSTM individuales con *artist_adj@10* $\approx 0,345$), y la GRU y la LSTM están estadísticamente empatadas (la hipótesis “la GRU gana por ser más eager” queda refutada); de dos palancas anti-eager el re-ranqueo MMR en evaluación es la palanca fuerte ($\lambda=0,9$ casi gratis) y el regularizador β de entrenamiento es débil, no se promovió nada, y $\lambda \approx 0,9$ queda señalado para una futura decisión de holisticidad del usuario (Sección 14).

16. Informes fuente

Esta síntesis consolida veinticinco informes de campaña de **experiments/**:

- 2026-06-09-ae-xgboost-blend.md — blend de latente-autoencoder + XGBoost sobre rotación (Sección 5.1).
- 2026-06-09-svm-kernel-rotation.md — barrido de SVM de kernel y blend condicional; primera banda de ruido de MAE medida (Sección 5.2).
- 2026-06-09-rotation-classification.md — bake-off de AUC, primera banda de ruido de AUC medida, primer campeón de rotación registrado (Sección 5.3).
- 2026-06-12-classifier-bakeoff-p64.md — bake-off de cuatro familias de clasificadores y barrido xgboost de depth/lr sobre el nuevo corpus completo de 64-d (Secciones 5.4 y 6).
- 2026-06-12-pyramid-mlp-arch-scan.md — barrido de arquitectura de seis geometrías del pyramid-MLP, refutando la hipótesis de presupuesto (Secciones 5.5 y 6).
- 2026-06-12-burn-deep-topology.md — el bake-off de topología del **burn-deep-classifier** en Rust/**burn**; resuelve la cuestión de la red consciente de la representación, arreglando la calibración pero no la brecha de AUC (Sección 6.7).
- 2026-06-12-high-vocab-topology.md — la re-ejecución pareada de topología sobre una matriz de mayor cardinalidad de identidad; voltea **embeddings>mlp** y eleva la red guardada al nivel de los árboles dentro del dataset, la primera ANN en superar la barra de guardado de rotación (Sección 6.8).
- 2026-06-15-gbdt-leaf-head-ceiling-probe.md — el truco de Facebook GBDT→LR generalizado a GBDT→MLP; cada cabeza de embedding de hojas tope bajo el campeón xgboost puro con calibración rota, la séptima refutación convergente (Sección 6.10).
- 2026-06-15-vocab-cap-scan-gbdt.md — el barrido de tope de vocabulario de resolución de identidad sobre el GBDT puro; mapea la curva tope→AUC y halla la palanca en gran

medida agotada pasado 300/120 (ganancias sub-banda, ningún save disparó), con el punto de todo-vocabulario no medido en el techo de memoria del host (Sección 6.11).

- **2026-06-15-burn-ae-classifier-capacity-scan.md** — primera caracterización del **burn-ae-classifier** de dos fases; 13 configs en una franja sub-banda, empata con el **mlp burn-deep** plano, y un modo de colapso de cabeza-profunda-congelada (Sección 6.9).
- **2026-07-12-pyramid-vs-rect-sae.md** — lectura de representación por SAE por modelo; con AUC igual la pirámide consolida conceptos en su cuello de botella mientras la red uniforme mantiene un conjunto más amplio (Sección 6.12).
- **2026-07-12-high-vocab-capacity-scan.md** — el barrido de capacidad del **burn-deep-classifier** sobre la matriz high-vocab (TECHO) más una lectura de asignación por SAE cross-familia (Sección 6.13).
- **2026-07-12-taste-drift-temporal-split.md** — la partición cronológica frente a aleatoria; una caída universal de ~ 0.11 de AUC que reencuadra la tabla como una cota superior del ranking de misma era (Sección 7).
- **2026-07-15-nexttrack-compression-representation-bakeoff.md** — la primera campaña de recomendación de *pista siguiente* incorporada: un bake-off de compresión de la representación de ítems (PCA frente a autoencoder $\times$ dimensión latente 32/64/128) bajo un readout GRU congelado. PCA-128 es el ganador GRU-individual (paired- Δ +0,0189, IC>0) pero la victoria no se traslada al blend R+M, así que nada se promovió (Sección 9).
- **2026-07-13-nexttrack-sequence-sweep.md** — la campaña fundacional de pista siguiente: un barrido de secuencias GRU/LSTM contra la barra de Markov de primer orden; la mejor GRU-infonce empata en R@10 pero pierde en MRR (Sección 8.1).
- **2026-07-13-nexttrack-topology-scan.md** — barrido de topología profundidad / anchura / residual / bidireccional; la arquitectura es una palanca agotada, todas las ramas quedan bajo la barra de Markov (Sección 8.2).
- **2026-07-14-nexttrack-blend-and-ensemble.md** — el z-blend R+M GRU $\times$ Markov supera la barra en +61 % de R@10 (el primer campeón de pista siguiente); ningún ensamble más rico lo mejora y el stacker XGB aprendido rinde por debajo (Sección 8.3).
- **2026-07-14-nexttrack-graded-relevance-and-new-legs.md** — métricas de relevancia graduada de primera clase (artist@k / genre@k / artist_mrr) y nuevos aprendices base leak-free; content-kNN es la única señal aditiva, empatando al campeón sobre AE-64 (Sección 8.4).
- **2026-07-15b-nexttrack-compression-dim-extension.md** — el barrido de dimensión PCA/AE extendido a 192/256; la curva hace pico en PCA-192 y se revierte, así que PCA-128 se mantiene como la base de la Fase 2 (Sección 10.1).
- **2026-07-15c-nexttrack-phase2-model-sweep.md** — el barrido de familia de modelos sobre los espacios PCA ricos; el z-blend fijo supera al stacker aprendido, LSTM es el mejor modelo individual, y R+M+C sobre PCA-192 se corona como la nueva fila «mejor registrada» (Sección 10.2).

- `2026-07-18-nexttrack-literature-fit-campaign.md` — una exploración guiada por bibliografía; una proyección de contenido aprendida supervisada ($R'+M+C'$) es una nueva fila «mejor registrada» ($R@10$ 0,2117, paired Δ sobre $R+M+C$ +0,0259 $IC>0$, robusta a la semilla, alcanza fríos), y cada método prestado (session-kNN, fusión de rankings, combinador aprendido, suavizado de Markov, negativos por importancia de GRU) se cierra (Sección 11.1).
- `2026-07-18b-nexttrack-projection-registration-and-scan.md` — la proyección reproducida on-server, registrada + promovida + servible como `blend-gru-markov-content-proj` (rango 1 del grupo de mejores modelos); un barrido de objetivo / rango / τ (InfoNCE $\gg$ BPR; default mantenido) y endurecimiento en segunda partición sobre una partición disjunta con 0.64 de fríos (paired Δ +0,0426 $IC>0$) (Sección 11.2).
- `2026-07-18c-nexttrack-representation-exploration.md` — una auditoría de representación del vector de ítem; la geometría PCA-192 de peso igual lastra la GRU cruda (seis de ocho espacios alternativos la elevan $IC>0$) pero la ganancia es absorbida por la proyección (Sección 12).
- `2026-07-20-musical-distance-metric.md` — la métrica continua de tipo “suena parecido” `music@10` y su backfill offline de 53 runs; correlaciona con `recall@10` ($r = 0,609$) pero corona a un ganador distinto, el `seq-nexttrack` que regresa contenido (Sección 13).
- `2026-07-22-session-holisticness-and-antieager-levers.md` — una suite solo de visualización de holisticidad de sesión (`artist_adj@10` / `mood_coh@10` / `ild@10`) y dos palancas anti-eager (MMR en evaluación `mmr_lambda`, y `eager_beta` de entrenamiento); el campeón es el modelo más artist-eager, la eagerness proviene de la pata de Markov, $GRU \approx LSTM$, y MMR λ es la palanca fuerte (Sección 14).

Cuadro 11: El barrido de capacidad + arquitectura-de-cabeza del `burn-ae-classifier` (ds-20260609-204419-p64-s42, semilla 42; fijos: `ae_epochs` 80, `ae_lr` 1×10^{-3} , épocas 200, `lr` 1×10^{-3} , dropout 0.1, patience 25). Las 13 ejecuciones tuvieron éxito. AUC y exactitud mejor cuanto más alto; log-loss mejor cuanto más bajo. Ganador (cfg3) y mejor celda por métrica en negrita; el colapso de cabeza-profunda-congelada (cfg10) es la única fila fuera de banda. Ordenado por AUC.

Run id	enc / clf / freeze / act	AUC	log-loss	exact.
run-20260615-1523 59-21f11-burn-ae- classifier	[128,64] / [128,64] / ft / relu	0.69719	0.6216	0.6496
run-20260615-1523 59-05bce-burn-ae- classifier	[256,128] / [128] / ft / relu	0.69712	0.6254	0.6485
run-20260615-1523 59-e5a75-burn-ae- classifier	[128,32] / [64] / ft / relu	0.69657	0.6246	0.6451
run-20260615-1523 59-94f8f-burn-ae- classifier	[128,64] / [64] / ft / relu (re-ejec. línea base)	0.69645	0.6264	0.6496
run-20260615-1523 59-7a459-burn-ae- classifier	[128,64] / [256,128] / ft / relu	0.69561	0.6235	0.6434
run-20260615-1523 59-cb93b-burn-ae- classifier	[384,192] / [192,96] / ft / relu	0.69541	0.6224	0.6426
run-20260615-1601 12-aaldb-burn-ae- classifier	[256,128] / [128] / <i>congelado</i> / re- lu	0.69530	0.6242	0.6409
run-20260615-1601 12-4a764-burn-ae- classifier	[128,64] / [128,64] / ft / gelu	0.69340	0.6256	0.6411
run-20260615-1523 59-3b006-burn-ae- classifier	[256,128,64] / [64] / ft / relu	0.69302	0.6279	0.6481
run-20260615-1601 13-7567b-burn-ae- classifier	[128,64] / [128,64] / ft / silu	0.69242	0.6230	0.6436
run-20260615-1523 59-86fd5-burn-ae- classifier	[256,128] / [256,128] / ft / relu	0.69240	0.6275	0.6392
run-20260615-1523 59-dbb6a-burn-ae- classifier	[128,64] / [] (sonda lineal) / ft / relu	0.69175	0.6282	0.6405
run-20260615-1601 12-17da7-burn-ae- classifier	[128,64] / [128,64] / <i>congelado</i> / relu (colapso)	0.68210	0.6378	0.6373

Cuadro 12: La sonda de techo de cabeza-de-hojas GBDT (ds-20260609-204419-p64-s42, semilla 42; el GBDT emisor de hojas es la config campeona congelada en cada tratamiento, solo varía la cabeza). Las cuatro ejecuciones tuvieron éxito. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Control (ganador) en negrita; mejor celda por métrica en negrita; filas de tratamiento ordenadas por AUC. Umbral de refutación (campeón -2σ) = 0,7078: cada cabeza está por debajo de él.

Rama / run id	Cabeza	AUC	log
C0 (run-20260615-151551-f2911-xgboost-classifier)	árbol puro (campeón)	0.7204	0.6
T1 (run-20260615-151551-b4db5-gbdt-leaf-head-classifier)	lineal (ℓ_2 logística, l2 1.0)	0.6978	1.3
T3 (run-20260615-151551-44b1d-gbdt-leaf-head-classifier)	mlp [256, 128], head_lr 1×10^{-3}	0.6921	1.1
T2 (run-20260615-151551-9d655-gbdt-leaf-head-classifier)	mlp [128], head_lr 1×10^{-3}	0.6897	0.8

Cuadro 13: El barrido de tope de vocabulario sobre el GBDT puro (config xgboost campeona congelada; catboost defaults; el único eje es vocab_top_n, todo lo demás idéntico byte a byte al ancla 300/120: mismas 23 529 filas, semilla de partición 42, PCA64, bloque de campos). Ordenado por tope de artista/género. AUC mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. La nueva mejor ejecución de linaje single-split en negrita; mejor celda por métrica en negrita. La fila de vocabulario completo es el build fallido (techo de memoria del host, dos intentos), registrada como un fallo de infraestructura, no un resultado. Banda de AUC $2\sigma \approx 0,0126$.

Run id	tope	cols	modelo	AUC	log-loss	B
run-20260615-163751-de9a4-xgboost-classifier	60/40	177	xgb	0.72044	0.60754	0.2
run-20260615-163803-3391f-catboost-classifier	60/40	177	cat	0.71105	0.61324	0.2
run-20260615-163803-536d5-xgboost-classifier	300/120	497	xgb	0.72988	0.60223	0.2
run-20260615-163803-6f170-catboost-classifier	300/120	497	cat	0.72516	0.60681	0.2
run-20260615-163803-1a0ba-xgboost-classifier	500/200	777	xgb	0.72966	0.60392	0.2
run-20260615-163803-1fae3-catboost-classifier	500/200	777	cat	0.72372	0.60894	0.2
run-20260615-163803-e75be-xgboost-classifier	1000/300	1377	xgb	0.73490	0.60070	0.2
run-20260615-163803-9ed65-catboost-classifier	1000/300	1377	cat	0.72633	0.60931	0.2
(build fallido)	todo 5594/962	6633	—	—	—	—

Cuadro 14: El barrido de capacidad del `burn-deep-classifier` sobre la matriz `high-vocab` (`ds-20260612-143014-p64-s42`, 497 cols; `activation=relu`, dropout 0.1, épocas 250, patience 20; solo varía la geometría oculta dentro de una topología). Las seis tuvieron éxito. AUC y exactitud mejor cuanto más alto; log-loss y Brier mejor cuanto más bajo. Ganador (B1) y mejor celda por métrica en negrita; ordenado por AUC. La rama `embeddings` profunda (B3) es el único movimiento fuera de banda.

Run id	topología / hidden	AUC	log-loss	exact.	Brier
run-20260712-1710 08-065bd-burn-dee p-classifier	embeddings / [128,64]	0.72274	0.61043	0.66426	0.21140
run-20260712-1710 08-7c302-burn-dee p-classifier	mlp / [256,128,64]	0.71800	0.61266	0.66065	0.21276
run-20260712-1710 08-cf746-burn-dee p-classifier	embeddings / [256,128]	0.71798	0.61323	0.66511	0.21246
run-20260712-1710 08-fc3e0-burn-dee p-classifier	mlp / [256,128]	0.71576	0.61220	0.66638	0.21249
run-20260712-1710 08-c093f-burn-dee p-classifier	mlp / [128,64]	0.71229	0.61694	0.65852	0.21447
run-20260712-1710 08-786b4-burn-dee p-classifier	embeddings / [256,128,64]	0.70750	0.61671	0.66001	0.21444

Cuadro 15: La brecha de AUC aleatorio-frente-a-cronológico, builds definitivos del framework (todos `spotify_tracks_song_ae`, 23 529 filas, semilla 42; cada modelo sobre la partición nativa de su dataset). “completo” lleva los one-hots de identidad, “intrínseco” los descarta (64 PCA + 7 numéricos solo). La fila del campeón en negrita; la columna de deriva es la caída aleatorio–cronológico sobre la matriz completa. Completo-aleatorio reproduce el campeón registrado (0,734 90), validando los builds. Datasets: completo-aleatorio `ds-20260712-183615`, completo-crono `ds-20260712-183629`, intrínseco-aleatorio `ds-20260712-183630`, intrínseco-crono `ds-20260712-183631`. Banda de AUC $2\sigma \approx 0,0126$.

Modelo	compl. · aleat.	compl. · crono	deriva	intr. · aleat.	intr. · crono
xgboost (campeón)	0.73490	0.61894	+0,116	0.71020	0.59858
catboost	0.72889	0.61294	+0,116	0.70172	0.59556
logistic	0.72141	0.61234	+0,109	0.64836	0.59016

Cuadro 16: Tabla de «mejor registrada» de pista siguiente (régimen de RANKING), sobre la partición next-distinct sin fugas (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos). R@10, MRR, artist@10, genre@10, music@10 mejor cuanto más alto; la barra de Markov es la referencia incumbente. Los valores de music@10 son el backfill offline (Sección 13); las filas sin un run mapeado se dejan en blanco. Fila campeona y campeones previos en negrita; mejor celda por métrica en negrita. **No comparable con ninguna tabla de rotación de arriba.** Espacios de ítems: AE-64 (spotify_tracks_song_ae); PCA- k (spotify_tracks_song_pca k), todos ajustados desde la fuente leak-safe spotify_tracks_content.

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	mus@10	Nota
$R'+M+C'$, PCA-192 (campeón, servible)	0.2117 [0.191 , 0.233]	0.1220	0.333	0.401	0.454	nuevo campeón
R+M+C, PCA-192 (campeón de fusión previo)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	0.449	contenido aditiv
R+M+C, PCA-128	0.1824 [0.162, 0.203]	0.0993	0.332	0.396	—	contenido aditiv
R+M , AE-64 (campeón previo)	0.1726 [0.154, 0.192]	0.0963	0.322	0.397	0.441	ancla prod.; 3 s
R+M+C, AE-64 (graded-preferred)	0.1740 [0.154, 0.194]	0.1014	0.330	0.400	—	contenido solo e
R+M, PCA-192	0.1712 [0.151, 0.192]	0.0952	0.329	0.398	0.443	$\approx$ campeón prev
R+M, PCA-128	0.1670 [0.148, 0.187]	0.0920	0.329	0.398	0.444	ganancia GRU r
R+A+M, AE-64	0.1684	0.0943	—	—	—	rama ANN redu
LSTM single, PCA-128	0.1272 [0.110, 0.145]	0.0495	0.335	0.458	0.451	mejor único; $\ll$
GRU single, PCA-192	0.1230 [0.106, 0.140]	0.0534	0.338	0.450	0.456	óptimo puntual
GRU single, PCA-128 (base)	0.1146 [0.099, 0.132]	0.0489	0.333	0.452	0.457	espacio base cor
B2 Markov de primer orden (barra)	0.1069 [0.092, 0.124]	0.0694	0.298	0.389	0.407	incumbente de l
ANN pooled-MLP single, PCA-128	0.0901 [0.076, 0.105]	0.0394	0.299	0.435	0.426	pierde ante la G
XGB stacker (M+G / M+G+A)	0.080–0.087	0.042–0.049	0.31	0.38	0.41	el combinador r
content-kNN (song-AE cosine)	0.0636 [0.050, 0.077]	0.0321	0.272	0.405	—	la rama C aditiv
item2vec (SGNS solo entren.)	0.0517	0.0214	0.166	0.312	—	arrastra el blen

Cuadro 17: La campaña de fusión: el z-blend R+M supera la barra de Markov de forma decisiva, y ningún ensamble más rico lo mejora. R@10 y MRR mejor cuanto más alto; campeón en negrita. *No comparable con ninguna tabla de rotación.*

Modelo	R@10 [IC 95 %]	MRR	Nota
z-blend R+M $\alpha=0,5$ (campeón)	0.1726 [0.154 , 0.192]	0.0963	Δ vs Markov +0,066 [+0,05, +0,08]
z-blend R+A+M	0.1684	0.0943	rama ANN redundante con GRU
B2 barra de Markov (M)	0.1069 [0.092, 0.123]	0.0694	la referencia
XGB stacker M+R	0.1020	0.0561	combinador aprendido $\ll$ z-blend
GRU sola (R)	0.0957	0.0411	empata la barra solo en R@10
z-blend R+A	0.0894	0.0377	$\approx$ GRU sola
XGB stacker M+R+A	0.0887	0.0572	apenas supera a Markov

Cuadro 18: El bake-off de compresión de la representación de ítems: seis espacios de ítems (PCA lineal frente al AE no lineal $\times$ dimensión latente 32 / 64 / 128), cada uno evaluado bajo el *mismo* readout congelado **gru-infonce-h256** sobre la partición next-distinct (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos; paired- Δ vs el control AE-64 del mismo lote). Las seis tuvieron éxito. R@10, MRR, artist@10 y genre@10 mejor cuanto más alto. Ganador (PCA-128) en negrita; mejor celda por métrica en negrita. *No comparable con ninguna tabla de rotación.*

Espacio	Run id	R@10 [IC 95 %]	paired- Δ vs AE-64	M
PCA-128 (ganador)	run-20260715-042100-a1d9d	0.1146 [0.099, 0.132]	+0,0189 [+0,004, +0,034]	0.1146
PCA-64 (segundo)	run-20260715-042100-8851d	0.1041 [0.088, 0.121]	+0,0084 [−0,005, +0,022] (empate)	0.1041
AE-64 (control)	run-20260715-042059-dd261	0.0957 [0.081, 0.111]	— (control)	0.0957
AE-128	run-20260715-042059-e96ae	0.0929 [0.078, 0.108]	−0,0028 [−0,015, +0,009] (empate)	0.0929
AE-32	run-20260715-042059-d3f9e	0.0545 [0.043, 0.066]	−0,0412 [−0,055, −0,027]	0.0545
PCA-32	run-20260715-042059-b1242	0.0412 [0.031, 0.052]	−0,0545 [−0,069, −0,041]	0.0412

Cuadro 19: Barrido de familia de modelos de la Fase 2 sobre los espacios PCA ricos, ordenado por R@10 (mejor cuanto más alto). El z-blend fijo es el combinador de referencia; el stacker XGB aprendido rinde muy por debajo. Fila campeona y campeón previo en negrita; mejor celda por métrica en negrita. El Δ pareado es por sesión contra la referencia nombrada. *No comparable con ninguna tabla de rotación.*

Modelo	Run id / fuente	R@10 [IC 95 %]	MRR	Δ pareado
R+M+C, PCA-192 (fila camp.)	analyze_rmc (A4)	0.1859 [0.166, 0.207]	0.1025	vs camp. +0,0133 [+0,001, +0,026]
R+M+C, PCA-128	analyze_rmc (A2)	0.1824 [0.162, 0.203]	0.0993	vs camp. +0,0098 (empate)
R+M, AE-64 (campeón previo)	run-20260714-170928-645ae	0.1726 [0.154, 0.192]	0.0963	— (referencia)
R+M, PCA-192	run-20260715-142440-96f53	0.1712 [0.151, 0.192]	0.0952	vs camp. −0,0014 (empate)
R+M, PCA-128	run-20260715-044920-36dce	0.1670 [0.148, 0.187]	0.0920	vs camp. −0,0056 (empate)
LSTM single, PCA-128	run-20260715-142440-546d0	0.1272 [0.110, 0.145]	0.0495	vs GRU-128 +0,0126 (> 0)
GRU single, PCA-192	run-20260715-142440-89d6a	0.1230 [0.106, 0.140]	0.0534	vs GRU-128 +0,0084 (empate)
ANN pooled-MLP, PCA-128	run-20260715-142440-7e528	0.0901 [0.076, 0.105]	0.0394	vs GRU-128 −0,0245
XGB stacker M+G, PCA-128	run-20260715-142440-371b1	0.0867 [0.073, 0.101]	0.0493	vs GRU-128 −0,0280
XGB stacker M+G+A, PCA-192	run-20260715-142440-f111d	0.0853 [0.071, 0.099]	0.0490	vs GRU-192 −0,0377

Cuadro 20: Nivel A1 de la campaña de ajuste-a-la-literatura: la proyección de contenido aprendida sobre PCA-192, frente al campeón R+M+C (1431 sesiones de prueba; IC bootstrap al 95 %; Δ pareado por sesión vs el campeón). Ganador ($R'+M+C'$) en negrita; mejor celda por métrica en negrita. *No comparable con ninguna tabla de rotación.*

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	Δ pareado vs campeón
R+M+C campeón (tercios)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	— (referencia)
$R'+M+C'$ (ambas proyectadas)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	+0,0259 [+0,012, +0,041] > 0
R+M+C+C' (4 ramas)	0.2061 [0.185, 0.227]	0.1148	0.345	0.410	+0,0203 [+0,013, +0,029] > 0
R+M+C' (cambia C→C')	0.1971 [0.177, 0.218]	0.1107	0.334	0.400	+0,0112 [−0,000, +0,023] cand.
C' proj-contenido (sim, r192)	0.1516	0.0708	0.305	0.401	vs C no-sup. 0.0685: +0,083
C' two-tower dir. (r192)	0.1349	0.0552	0.291	0.393	gana simétrica

Cuadro 21: Las vías de ajuste-a-la-literatura que se cerraron: cada método prestado no logra superar al z-blend fijo campeón (1431 sesiones de prueba; Δ pareado del blend por sesión vs el campeón).

Vía	R@10 en solitario	Δ del blend vs campeón	Veredicto
Suavizado KN de Markov (Nivel A2)	0.1069→0.1104	−0,0021 (cruza 0)	nulo en el blend
Combinador de ranking, <i>oráculo</i> (B1)	0.1901 (blend)	+0,0042 (cruza 0)	sin margen honesto
Fusión de ranking RRF (B1)	0.1572 (blend)	−0,029 (IC<0)	perjudica recall
V-SKNN kNN de sesión (B2)	0.0671	−0,038 (IC<0)	arrastra (solo cálidos)
Negativos por importancia GRU (C)	0.1230→0.1279	−0,0014 (empate)	se diluye

Cuadro 22: El barrido de ablación on-server de objetivo / rango / τ (6 celdas, ordenadas por recall@10). Todas superponen la definición promovida; hit@10 = recall@10 por construcción. Campeón promovido (default, mantenido) en negrita; mejor celda por métrica en negrita (todas de la celda sub-ruido τ -0,10).

Config	recall@10	MRR	art@10	gen@10	run id
S2 infonce / full / τ 0,10	0.2229	0.1273	0.3424	0.4032	run-20260718-193111-a781c
infonce / full / τ 0,07 (promovido, mantenido)	0.2117	0.1220	0.3326	0.4011	run-20260718-191539-1b89c
S3 infonce / rank 64 / τ 0,07	0.2055	0.1169	0.3326	0.3990	run-20260718-193650-66c96
S1 infonce / full / τ 0,05	0.1929	0.1111	0.3354	0.3997	run-20260718-192443-57432
S4 bpr / full / τ 0,07	0.1579	0.0939	0.3187	0.3913	run-20260718-194228-4cc06
S5 bpr / rank 64 / τ 0,07	0.1523	0.0909	0.3194	0.3906	run-20260718-194832-d070f

Cuadro 23: Endurecimiento en segunda partición sobre la partición disjunta de holdout-temprano con 0.64 de fríos seq-20260718-211238 (1431 sesiones de prueba; solo-validación). Métricas puntuales (arriba) y el Δ pareado por sesión (abajo, bootstrap de 2000 remuestreos, semilla 1337). Campeón de proyección en negrita.

Config	recall@10	MRR	art@10	gen@10	run id
$R'+M+C'$ campeón de proyección	0.1705	0.1050	0.2991	0.3417	run-20260718-212639-50e1d
Coronación R+M+C (referencia primaria)	0.1279	0.0816	0.2956	0.3410	run-20260718-213156-cf1dd
R+M 2 ramas (referencia de contexto)	0.1174	0.0791	0.2844	0.3368	run-20260718-214114-93bad
Δ pareado recall@10 (proyección – referencia):					
PROY vs R+M+C (primaria)	+0,0426 [+0,0280, +0,0573] — enteramente > 0; MRR +0,0234 (sin regresión)				
PROY vs R+M (contexto)	+0,0531 [+0,0391, +0,0678] — enteramente > 0				

Cuadro 24: Exploración de representación del vector de ítem: ocho espacios de ítems de 192-d alternativos vs el campeón PCA-192, bajo readout A (proyección campeona) y readout C (GRU congelada). Δ pareado sobre hit@10 exacto (bootstrap de 2000 remuestreos, rng 1337) vs la línea base del mismo readout; una mejora necesita el IC enteramente > 0. Filas de línea base y la mejor mejora de readout C (V5) en negrita. *No comparable con ninguna tabla de rotación.*

Variante (espacio)	dataset id	Readout A (proyección)		Readout C (GRU congelada)	
		R@10	Δ hit@10 [IC]	R@10	Δ hit@10 [IC]
full — PCA-192 (línea base)	seq-20260715-131139	0.2117	(línea base)	0.1230	(línea base)
V1 noaco	seq-20260718-222742	0.2089	−0,0028 [−0,013, +0,008]	0.1481	+0,0252 [+0,009, +0,041]
V2 std (whiten todo)	seq-20260718-222754	0.2082	−0,0035 [−0,015, +0,008]	0.1530	+0,0300 [+0,011, +0,049]
V3 std-noaco	seq-20260718-222807	0.2166	+0,0049 [−0,008, +0,017]	0.1572	+0,0342 [+0,015, +0,055]
V4 textcat	seq-20260718-222820	0.1950	−0,0168 [−0,029, −0,006]	0.1565	+0,0335 [+0,015, +0,051]
V5 balanced-pca192	seq-20260718-222834	0.2159	+0,0042 [−0,006, +0,015]	0.1586	+0,0356 [+0,019, +0,052]
V7 std-txtcatup	seq-20260718-222848	0.2055	−0,0063 [−0,019, +0,006]	0.1488	+0,0259 [+0,006, +0,046]
V10 text-only	seq-20260718-222901	0.1999	−0,0119 [−0,025, +0,001]	0.1377	+0,0147 [−0,005, +0,034]
V6 sonic-64 (64-d)	seq-20260718-222905	0.1936	−0,0182 [−0,031, −0,005]	0.1216	−0,0014 [−0,017, +0,013]

Cuadro 25: music@10 por familia de predictor, del backfill offline sobre los 53 runs de pista siguiente (una partición compartida de 1431 casos). El campeón de recall@10 (**seq-blend**) *no* es el campeón de music@10 (**seq-nexttrack**). Mejor celda por columna en negrita.

Familia de predictor	runs	mejor recall@10	mejor music@10	music@10 medio
seq-blend	23	0.223	0.461	0.441
seq-nexttrack	24	0.159	0.482	0.448
seq-markov	1	0.107	0.407	0.407
seq-ann	1	0.090	0.426	0.426
seq-stacker	3	0.087	0.418	0.411
seq-popularity	1	0.001	0.185	0.185

Cuadro 26: Huella de holisticidad de la Fase A a través de la familia de modelos, ordenada por Recall@10 (1431 sesiones de test). Todos los runs comparten el prefijo `run-20260722-165345-`; la columna `id` lista el sufijo distintivo. Recall@10 (aciertos crudos de 1431), MRR, `artist@10`, `genre@10`, `music@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Fila del campeón y mejor celda por métrica en negrita. [†] Los valores extremos de `artist_adj@10` / `ild@10` del suelo de popularidad son *degenerados* (ignora la semilla): aterrizas ≈ 0 recall y `mood_coh@10` negativo, probando que las métricas no se juegan bajo/alto por un buen modelo.

Config	id	R@10 (crudo)	MRR	art@10	gen@10	mus@10	artadj@10↓	mood@10↑	ild@10↑
A1 campeón $R'+M+C'$	82a8f	0.2117 (303)	0.122	0.333	0.401	0.454	0.610	0.398	0.406
A2 R+M (blend)	28dbb	0.1712 (245)	0.095	0.329	0.398	0.443	0.579	0.399	0.403
A3 GRU sola ($\beta=0$)	e39c9	0.1230 (176)	0.053	0.338	0.450	0.456	0.347	0.479	0.454
B LSTM (resto igual a A3)	bb387	0.1188 (170)	0.049	0.328	0.455	0.449	0.344	0.458	0.463
A4 markov (primer orden)	047cc	0.1069 (153)	0.069	0.298	0.389	0.407	0.543	0.310	0.462
A5 popularidad	34614	0.0007 (1)	0.001	0.014	0.085	0.185	0.003[†]	-0,041	0.898[†]

Cuadro 27: Barrido MMR λ de la Fase C sobre el campeón, computado offline desde su checkpoint (`mmr_pool` 200; 1431 sesiones de test). Recall@10 (aciertos crudos), MRR, `artist@10`, `music@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Mejor celda por métrica en negrita; recall / MRR del default del campeón ($\lambda=\text{off}$) en negrita.

λ	R@10 (crudo)	Δ vs off	MRR	art@10	mus@10	artadj↓	mood↑	ild↑
off (1.0)	0.2117 (303)	—	0.122	0.333	0.454	0.610	0.398	0.406
0.9	0.2103 (301)	-0,0014 (EMPATE)	0.121	0.341	0.462	0.603	0.391	0.436
0.7	0.1936 (277)	-0,0181	0.116	0.347	0.476	0.571	0.364	0.520
0.5	0.1642 (235)	-0,0475	0.108	0.359	0.487	0.486	0.315	0.653
0.3	0.1097 (157)	-0,1020	0.100	0.358	0.492	0.293	0.238	0.815

Cuadro 28: Barrido del regularizador anti-eager β de la Fase D sobre la GRU individual (`eager_margin` 0,0; 1431 sesiones de test). Recall@10, `artist@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Mejor celda por métrica en negrita.

run id	β	R@10 (crudo)	MRR	art@10	artadj↓	mood↑	ild↑
run-20260722-165345-e39c9	0.0	0.1230 (176)	0.053	0.338	0.347	0.479	0.454
run-20260722-165345-353b5	0.05	0.1237 (177)	0.053	0.337	0.346	0.478	0.455
run-20260723-002044-af11a	0.1	0.1202 (172)	0.053	0.335	0.344	0.477	0.456
run-20260723-002044-17cf8	0.2	0.1202 (172)	0.051	0.336	0.340	0.475	0.458

Cuadro 29: Continuación multi-paso de la Fase E (arnés `-m 3 -k 10`, 1172 casos) sobre `seq-20260715-131139`: la GRU (checkpoint A3) supera al bigrama de Markov de primer orden en ambas métricas (mejor-mayor). Ganador en negrita.

Modelo	suffix_recall@10	cont_prec@10
markov (bigrama de primer orden)	0.0869	0.0236
GRU (gru-infonce-h256, A3)	0.0963	0.0273