
A Portrait of a Predictor

What your next-track model hears coming

Un retrato de quien predice — lo que tu modelo del próximo tema oye venir

A data portrait derived from 91,827 listening steps, the concepts a next-track GRU learned inside its own hidden state, and GPT-labeled sparse-autoencoder atoms.

Spotify Next-Track Lab · sequence dataset `seq-20260718-222807`
2026-07-23

How to read this document


This report is bilingual. **Part I is in English; Part II es la versión en español** (identical content). It reads one thing: not *what* you listen to, but what a machine trained to guess your *next* track has learned about you. It is built from (1) 91,827 listening steps (each: the session so far $\rightarrow$ the track that actually came next); (2) the champion blend’s recurrent base learner, a GRU (**best-seq-nexttrack-20260718-230948-d3d4a**) that predicts the next track’s latent and ranks the library by it; and (3) a sparse-autoencoder (SAE) probe of that GRU’s hidden state, whose learned “atoms” were named by GPT (**gpt-4o-mini**). Method and caveats are in the Provenance appendix — read it: the model has *genuinely* learned next-track structure, but it stores it in a *dense, entangled* way, and that honesty is part of the picture.

1 The one-paragraph portrait

Ask this model what you will play next and it thinks, above all, in **artists and their sonic neighbourhoods**. Its strongest internal features are dedicated detectors for the artists you loop hardest — *DIIV*, *Rammstein*, *Thievery Corporation*, *Aphex Twin*, *Four Tet* — and for a handful of genre textures: *alternative metal*, *Brooklyn / indie rock*, *album rock*, *Düsseldorf electronic*, *ambient*, and a clear seam of *argentine rock*. From the session so far it can linearly guess the *genre* of your very next track far above chance. It has learned the same listener the aggregate portrait found — electronic core, rock heart, Argentine thread — but arrived at it sideways, by learning what tends to *follow* what in a session.

2 What it predicts


The model ranks your whole library for the next slot. On held-out sessions the true next track lands in its top 10 **15.7%** of the time (**recall@10**), and when it misses the exact track it usually lands something that *sounds* right: its top 10 scores **0.48** on **music@10** (sonic similarity to the truth). Most tellingly, the next track’s **genre is linearly decodable from the GRU’s hidden state at AUC 0.79** (41.7% top-1 across 25 genres, against a 0.7% chance rate) — the recurrent state genuinely carries where the session is heading.



3 The concepts it formed

The GRU doesn’t store “predict DIIV.” It learns abstract feature detectors in its 256-dimensional hidden state; the SAE pulls those apart into individual “atoms,” and GPT named each from the next-tracks that most excite it. The strongest atoms are crisp and namable:

sep (σ)	Concept (GPT label)	Type
3.8	DIIV — Brooklyn indie vibe	artist
3.5	Rammstein — live performances	artist
3.4	Rammstein — alternative-metal pattern	artist
3.0	Pink Floyd — album-rock pattern	genre
2.8	Thievery Corporation — downtempo	artist
2.8	Indie-rock favourites	genre
2.8	DIIV — indie soundscape	artist
2.7	Aphex Twin — ambient detection	artist
2.7	Four Tet — electronica repetition	artist




Each “sep” is how many standard deviations an atom’s activation rises right before a next track of that artist/genre, versus every other step — a clean 3.8σ for the DIIV detector is a strong, specific feature.

4 Who it thinks about most

The model spends its sharpest features on the artists that dominate your sessions. **Rammstein alone accounts for several of the top atoms**; DIIV gets two. This is the recurrent echo of heavy rotation: the more an artist anchors your sessions, the more dedicated hidden capacity the GRU devotes to seeing them coming. Some of these atoms also track *sonic continuity* — the Rammstein detectors carry a mood correlation of $\approx +0.2$, firing when the next track is not just same-artist but same-*sound*, while the DIIV detector is almost purely identity (≈ 0.0).

5 What it captures — and what it drops

Reassuringly, the model leaves almost nothing on the table: **all 25 of the frequent next-track genres are represented** by at least one dedicated atom, and **zero** frequent next-item concepts are dropped. The genres it separates most sharply are exactly your pillars:



5.1 The honest caveat: dense, not clean

The catch is *how* it stores all this. The hidden state is **dense, not sparse**: the SAE reconstructs it near-perfectly (99% of variance), but ≈ 418 of 512 atoms fire on a typical step. So while the strongest atoms are namable, next-track information is *smeared across nearly the whole layer* rather than isolated into a few tidy features. Read the concepts above as “the dominant artists and genres each have a strong dedicated direction,” not “the model is a clean dictionary of your taste.” This matches the standing lab finding that SAEs on this corpus don’t yield crisp monosemantic atoms at this data scale — the labels are suggestive readings, and the decodability numbers (§2) are the solid ground.

6 The portrait in one line


A next-track model that thinks in artists and their sonic neighbourhoods — sharpest on the ones you loop (DIIV, Rammstein, Thievery Corporation, Aphex Twin, Four Tet), fluent in every genre from alternative metal to Düsseldorf electronic to argentine rock, able to call the next track’s genre far above chance — but holding it all in a dense, distributed hidden state rather than a tidy shelf of concepts.

7 El retrato en un párrafo

Si le preguntas a este modelo qué vas a reproducir a continuación, piensa, ante todo, en **artistas y sus vecindarios sonoros**. Sus rasgos internos más fuertes son detectores dedicados a los artistas que más repites — *DIIV*, *Rammstein*, *Thievery Corporation*, *Aphex Twin*, *Four Tet*— y a unas pocas texturas de género: *alternative metal*, *indie* de Brooklyn, *album rock*, electrónica de Düsseldorf, *ambient* y una veta clara de *rock argentino*. A partir de la sesión hasta ese punto puede adivinar linealmente el *género* del próximo tema muy por encima del azar. Ha aprendido al mismo oyente que encontró el retrato agregado — núcleo electrónico, corazón de rock, hebra argentina— pero llegó de costado, aprendiendo qué suele *seguir* a qué dentro de una sesión.

8 Lo que predice

El modelo ordena toda tu biblioteca para el próximo lugar. En sesiones reservadas, el próximo tema real cae en su top 10 el **15,7 %** de las veces (**recall@10**), y cuando falla el tema exacto suele acertar algo que *suen*a bien: su top 10 marca **0,48** en **music@10** (similitud sonora con lo verdadero). Y lo más revelador: el **género del próximo tema es linealmente decodificable desde el estado oculto del GRU con AUC 0,79** (41,7 % de acierto top-1 entre 25 géneros, frente a un azar del 0,7 %) — el estado recurrente sí lleva hacia dónde va la sesión.




(Etiquetas de la figura en inglés: “accuracy” = acierto; “chance” = azar.)

9 Los conceptos que formó

El GRU no guarda “predecir DIIV”. Aprende detectores de rasgos abstractos en su estado oculto de 256 dimensiones; el SAE los separa en “átomos” individuales, y GPT nombró cada uno a partir de los próximos temas que más lo activan. Los átomos más fuertes son nítidos y nombrables:

sep (σ)	Concepto (etiqueta GPT)	Tipo
3,8	DIIV — <i>indie</i> de Brooklyn	artista
3,5	Rammstein — en vivo	artista
3,4	Rammstein — patrón <i>alt-metal</i>	artista
3,0	Pink Floyd — patrón <i>album rock</i>	género
2,8	Thievery Corporation — <i>downtempo</i>	artista
2,8	Favoritos del <i>indie rock</i>	género
2,8	DIIV — paisaje <i>indie</i>	artista
2,7	Aphex Twin — <i>ambient</i>	artista
2,7	Four Tet — repetición <i>electronica</i>	artista




Cada “sep” es cuántas desviaciones estándar sube la activación de un átomo justo antes de un próximo tema de ese artista/género, frente al resto de los pasos — un $3,8\sigma$ limpio para el detector de DIIV es un rasgo fuerte y específico.

10 En quién piensa más

El modelo gasta sus rasgos más afilados en los artistas que dominan tus sesiones. **Rammstein solo se lleva varios de los átomos principales**; DIIV, dos. Es el eco recurrente de la reescucha intensa: cuanto más ancla un artista tus sesiones, más capacidad oculta le dedica el GRU a verlo venir. Algunos de esos átomos también siguen la *continuidad sonora* — los detectores de Rammstein llevan una correlación de humor de $\approx +0,2$, activándose cuando el próximo tema no solo es del mismo artista sino del mismo *sonido*, mientras que el de DIIV es casi pura identidad ($\approx 0,0$).

11 Lo que captura — y lo que deja pasar

Tranquiliza que el modelo casi no deja nada sobre la mesa: **los 25 géneros frecuentes del próximo tema están representados** por al menos un átomo dedicado, y se descartan **cero** conceptos frecuentes. Los géneros que separa con más nitidez son justamente tus pilares:



11.1 La advertencia honesta: denso, no limpio

El detalle es *cómo* guarda todo esto. El estado oculto es **denso, no disperso**: el SAE lo reconstruye casi a la perfección (99% de la varianza), pero ≈ 418 de 512 átomos se activan en un paso típico. Así que, aunque los átomos más fuertes sean nombrables, la información del próximo tema está *repartida por casi toda la capa* en vez de aislada en unos pocos rasgos limpios. Lee los conceptos de arriba como “los artistas y géneros dominantes tienen cada uno una dirección dedicada fuerte”, no como “el modelo es un diccionario limpio de tu gusto”. Esto coincide con el hallazgo estable del laboratorio de que los SAE en este corpus no dan átomos monosemánticos nítidos a esta escala de datos — las etiquetas son lecturas sugerentes, y los números de decodificación (§2) son el terreno firme.

12 El retrato en una línea

Un modelo del próximo tema que piensa en artistas y sus vecindarios sonoros — más afilado en los que repites (DIIV, Rammstein, Thievery Corporation, Aphex Twin, Four Tet), fluido en cada género del alternative metal a la electrónica de Düsseldorf y el rock argentino, capaz de anticipar el género del próximo tema muy por encima del azar — pero guardándolo todo en un estado oculto denso y distribuido en vez de un estante ordenado de conceptos.

Provenance & honest caveats · Procedencia y advertencias

Data. A single user’s Spotify listening history, sessionized into the sequence dataset `seq-20260718-222807`. The per-model SAE ran over **91,827** (*session, step*) rows (73,632 train / 18,195 test); each row is the hidden state at one step paired with the track that actually came next. Aggregate concept statistics are computed directly over these rows.

Model. `best-seq-nextttrack-20260718-230948-d3d4a`, a single-layer GRU (256-d hidden) — the recurrent base learner of the promoted GRU×Markov blend champion. It encodes the session prefix and ranks the library by cosine to its predicted next-track latent (`recall@10` = 0.157, `music@10` = 0.48).

Interpretability. A sparse autoencoder (512 atoms, $2\times$ overcomplete, ℓ_1 = 0.0015, 40 epochs) trained on the GRU’s per-step hidden activations; analysis `interp-run-20260723-204848-4e89f-msae` (reopen it under the UI’s *Saved analyses* tool). “Concepts” are read against the *next item*: an atom’s association is its mean-activation separation (in σ) for a next-track artist / genre / album class. Next-item genre decodability is a logistic probe on the raw activations (top-1 accuracy + macro-AUC vs. a majority baseline). The 12 surfaced atoms per layer had their top-activating next-tracks sent to **GPT** (`gpt-4o-mini`) for a concept label.

The honest caveat. The GRU has genuinely learned next-track structure — genre is decodable at AUC 0.79 and every frequent concept is represented — but the representation is *dense*: ≈ 418 of 512 atoms fire per step and the code reconstructs 99% of the layer’s variance, so “concepts” are strong *directions* in an entangled space, not clean monosemantic units. The SAE is a discovery lens, not a decision rule; the GPT labels are automated readings of 10 tracks each and occasionally blur. The decodability and coverage numbers are solid; the atom labels are illustrative.