

Recomendación de Pista Siguiente en Sesión: Síntesis de Experimentos

15 de julio de 2026

Resumen

Este documento es la síntesis viva de las campañas de recomendación de *pista siguiente* (next-track); los informes markdown de `experiments/` (con `nexttrack` en el nombre) son el registro primario. La tarea es *recuperación* (retrieval) del siguiente ítem: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente, evaluada sobre una única partición cronológica sin fugas (leak-free) *next-distinct* (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba; tasa de ítems fríos (cold-item) 0,55). La métrica principal es recall@10 , reportada junto al rango recíproco medio (MRR) y los diagnósticos de relevancia graduada artist@10 / genre@10 / artist_mrr . Se consolidan siete campañas. Una GRU de sesión por sí sola solo *empata* con la barra de Markov de co-escucha de primer orden (R@10 0,1069) en recall@10 y pierde en MRR, y ni el ajuste de la función de pérdida ni ninguna topología de red (profundidad, anchura, residual, dirección) la superan. El avance es la *fusión de rankings*: un z-blend R+M (GRU $\times$ Markov) supera la barra en $\sim +61\%$ de recall@10 (0,1726, confirmado con 3 semillas), porque las dos ramas ordenan pistas correctas *distintas*; un stacker XGB aprendido rinde por debajo del z-blend fijo y añadir ramas neuronales redundantes no ayuda. La única señal genuinamente aditiva es el *contenido*: un barrido de representación de ítems halló que la *dimensión* latente (no el compresor) es la palanca, con un pico en PCA-192, y sobre ese espacio rico un z-blend R+M+C de tres ramas (GRU $\times$ Markov $\times$ content-kNN) es la fila «mejor registrada» actual con recall@10 0,1859, MRR 0,1025 (paired Δ sobre el campeón previo +0,0133, IC por encima de cero). Dos salvedades acotan la coronación — la confirmación por reproducción tuvo dispersión cero porque el entrenador es determinista (verificó determinismo, no robustez a la semilla), y el límite inferior del paired- Δ supera cero por solo +0,0007 en una única partición. Todos los predictores de ranking aquí son solo de entrenamiento y fuera del servidor, así que una victoria confirmada es una fila «mejor registrada», no un modelo promovido, y el campeón previo R+M sobre AE-64 sigue siendo el ancla de productización.

1. Introducción

Este documento es la síntesis viva de las campañas de recomendación de pista siguiente; los informes markdown de `experiments/` son el registro primario. Cada sección transcribe (nunca recalcula) los resultados cuantitativos de una campaña, preserva sus identificadores de ejecución y de dataset de forma literal para trazabilidad, y añade la motivación y la interpretación que los informes escuetos omiten. Esta instancia se clonó de un laboratorio hermano de ajuste de gusto / rotación y se reorientó a un objetivo de ranking de secuencias; las campañas de rotación son una línea de trabajo separada y *no* se cubren aquí.

Tarea y partición. El laboratorio predice, dentro de una *sesión* de escucha, qué pista reproduce el usuario a *continuación* — una tarea de recuperación del siguiente ítem. El modelo consume el prefijo ordenado de la sesión y puntúa cada ítem del catálogo; los candidatos se ordenan y la siguiente pista *distinta* retenida es el objetivo (una evaluación leave-last-out que excluye los ítems del prefijo, siguiendo la convención de paridad con Markov). Todo el trabajo corre sobre un único artefacto de secuencias, `seq-20260713-014226` (7154 sesiones / 19 402 ítems), particionado *cronológicamente por inicio de sesión* en 5723 entrenamiento / 1431 prueba en el corte 2024-08-24. La propiedad definitoria de esta partición es su **tasa de ítems fríos de 0,55**: más de la mitad de las pistas objetivo de las sesiones de prueba nunca aparecen en ninguna sesión de entrenamiento. Esta es la realidad de predicción hacia adelante sin fugas, y acota el recall absoluto por construcción — cada resultado se lee contra la barra base incumbente, nunca un número absoluto.

Métricas. La métrica principal es **recall@10** ($R@10$, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al **rango recíproco medio** (MRR, el inverso medio del rango de la siguiente pista verdadera) y **recall@20**. Desde 2026-07-14 la evaluación también emite métricas de *relevancia graduada* de primera clase sobre el mismo ranking con prefijo excluido (Sección 7): **artist@k** (algún candidato del top- k comparte el artista de la siguiente pista verdadera), **genre@k** (análogamente sobre el género primario) y **artist_mrr** (MRR del primer candidato del mismo artista). Todos los intervalos de confianza son IC bootstrap al 95 % sobre 2000 remuestreos de las 1431 sesiones de prueba, y el estadístico decisivo es el Δ *pareado* por sesión contra una referencia nombrada. Una *victoria* de tabla requiere superar la referencia en *ambos* $R@10$ y MRR más allá de IC marginales no solapados (la barra estricta), seguido de una confirmación por reproducción; el test de paired- Δ con IC-enteramente-mayor-que-cero es el estadístico alternativo más potente (coronó a ambos campeones) y puede discrepar de la barra estricta. Las métricas graduadas son el marcador honesto: el recall exacto es modesto por construcción, pero el campeón acierta el *artista* correcto en el top diez $\sim 32\%$ de las veces y el *género* correcto $\sim 40\%$ — mucho más útil que el número exacto de $\sim 17\%$ que impone la tasa de ítems fríos.

El campeón vigente y el ancla de productización. La fila «mejor registrada» actual es un blend de fusión de rankings de tres ramas, $R+M+C$ (una GRU de sesión $\times$ un modelo de co-ocurrencia de Markov de primer orden $\times$ una rama content-kNN) sobre un espacio de ítems PCA-192, con $R@10$ 0,1859, MRR 0,1025 (Sección 10). El campeón previo, el z-blend de dos ramas $R+M$ sobre el espacio del song-autoencoder de 64 dimensiones (AE-64), con $R@10$ 0,1726 / MRR 0,0963 (Sección 6), sigue siendo el *ancla de productización*: es el blend de dos ramas que mapea directamente sobre la ramura de transición de la app hermana, y sigue siendo el modelo desplegable hasta que el blend de tres ramas se registre como predictor. **Ningún predictor de ranking aquí es promovible al grupo de mejores modelos**: son solo de entrenamiento (sin subcomando `predict`), y $R+M+C$ es un driver de fusión fuera del servidor, así que una victoria confirmada es una fila «mejor registrada», no un modelo promovido.

2. Trasfondo: la tarea de secuencias, las líneas base y las métricas

Esta sección da la teoría mínima para un lector que conoce machine learning pero no este repositorio. Está anclada al archivo vivo de hechos del proyecto y crece solo cuando una nueva familia de predictores o métrica entra en los informes.

Los modelos y líneas base en juego.

GRU / LSTM de sesión (seq-nexttrack). Una red neuronal recurrente que lee el prefijo ordenado de la sesión un ítem a la vez (cada ítem representado por su vector latente) y emite un latente predicho del siguiente ítem; los candidatos se ordenan por similitud coseno a esa predicción. La GRU (gated recurrent unit) y la LSTM (long short-term memory) son las dos celdas recurrentes probadas. La recurrencia captura el *contexto de sesión* — la trayectoria de la sesión de escucha — en lugar de un único ítem previo.

Función de pérdida: InfoNCE frente a coseno. El modelo de secuencias puede entrenarse para regresar el latente del siguiente ítem por pérdida *coseno* (acercar la predicción al latente verdadero) o por **InfoNCE**, un objetivo contrastivo que acerca la predicción al ítem verdadero y la aleja de un lote de negativos. InfoNCE es la palanca individual más importante de todo el arco: es $\approx 2,3\times$ el coseno en recall@10, porque la recuperación por ranking premia una representación que *separa* el siguiente ítem verdadero de los distractores, lo que una pérdida contrastiva optimiza directamente y una regresión puntual no.

Co-ocurrencia de Markov de primer orden (la barra, B2). Un modelo de transición solo de entrenamiento: un **track_bigram** que cuenta “qué pista sigue a qué” con back-off por artista/género para pares no vistos (el término de transición que la app hermana ya despacha). Memoriza la adyacencia directamente, que es exactamente lo que premia el ranking exacto de la siguiente pista, y es la barra de referencia contra la que se mide cada rama. También se probó un Markov de segundo orden (trigrama) con back-off y es esencialmente neutral — las sesiones son demasiado cortas/dispersas para que un trigrama dispare, así que cae al bigrama.

item2vec. Un embedding skip-gram (SGNS) de co-escucha entrenado solo sobre las sesiones de *entrenamiento* (un análogo leak-safe de word2vec, donde las “palabras” son pistas y las “frases” son sesiones); los candidatos se ordenan por coseno al prefijo agregado por media. Sobre 5723 sesiones de entrenamiento es demasiado disperso para localizar y es la rama más débil registrada; los vectores de co-escucha de historia completa *no* se usan deliberadamente porque filtran a través de la partición.

content-kNN. Una rama de recuperación sin entrenamiento: coseno del latente de cada candidato a los latentes del prefijo (agregado por máximo). Es débil por sí sola en recall exacto pero captura similitud de *ambiente* (vibe) que los conteos pierden (su genre@10 ya roza la barra de Markov), y es la única tercera rama genuinamente aditiva para el blend de fusión.

z-blend de fusión de rankings frente a stacker aprendido. Dos formas de combinar ramas. El **z-blend** normaliza (z-score) las puntuaciones de candidatos de cada rama y toma una suma ponderada ($\alpha \cdot z(\text{rama}) + \dots$) — un fusor fijo, ligero en parámetros. El **stacker XGB** (apilador) es un meta-aprendiz de gradient boosting sobre rasgos por candidato (puntuaciones de ramas + popularidad + recencia + coincidencia de artista/género), entrenado de forma puntual con negativos muestreados. A lo largo de dos campañas el z-blend fijo *supera* al stacker aprendido de forma decisiva, porque el entrenamiento puntual binario del stacker no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas.

Espacios de latentes de ítems: song-AE frente a PCA, y la trampa de la colección equivocada. El modelo de secuencias predice *hacia*, y recupera *sobre*, un espacio latente por ítem, así que la elección de ese espacio es un eje de primera clase. Aparecen tres familias:

AE-64 (`spotify_tracks_song_ae`). Un latente *song-autoencoder* no lineal de 64 dimensiones, el espacio de ítems campeón original. Un autoencoder comprime cada ítem reconstruyéndolo a través de un cuello de botella; su pérdida de reconstrucción de peso igual por bloque reparte la capacidad de forma uniforme entre los bloques de contenido, acústica y catálogo.

PCA- k (`spotify_tracks_song_pca`). Una compresión *lineal* por componentes principales a dimensión $k \in \{32, 64, 128, 192, 256\}$, que ordena las dimensiones por varianza explicada y las decorrelaciona. Como muestran las Secciones 8–9, esta geometría ordenada por varianza y decorrelacionada es *más fácil* de regresar para la GRU que los latentes de peso igual enredados del AE, así que PCA supera al AE en toda dimensión ≥ 64 .

La trampa de la colección equivocada. Ambos anteriores se ajustan *solo* desde la fuente leak-safe `spotify_tracks_content` (campos intrínsecos de contenido/acústica/catálogo; sin campo conductual ni objetivo). La colección por defecto `spotify_tracks` de 200 dimensiones es un embedding *conductual* de co-escucha que filtra suavemente el comportamiento de repetición y **nunca** debe usarse como espacio de ítems.

3. Tabla de clasificación de pista siguiente

La Tabla 1 es la tabla vigente de «mejor registrada». Está sobre la única partición next-distinct sin fugas y ordenada por `recall@10`. **Todo predictor de ranking aquí es solo de entrenamiento y fuera del servidor**, así que el “campeón” es una fila «mejor registrada», no un modelo promovido y exportable a la app; el campeón previo R+M sobre AE-64 sigue siendo el ancla de productización (Sección 1). Los espacios de ítems se ajustan todos desde la fuente de contenido leak-safe (Sección 2).

4. El barrido de secuencias: una GRU-infonce empata con la barra de Markov

Motivación. La campaña inaugural de la instancia planteó la pregunta fundacional: ¿un modelo de secuencias con contexto de sesión — una GRU/LSTM sobre el prefijo ordenado, prediciendo el latente song-AE de 64 dimensiones de la siguiente pista y recuperando por coseno — supera al modelo de transición de Markov de primer orden que la app hermana ya despacha, *hacia adelante*, sobre la partición de sesiones sin fugas? Cuatro ramas cruzaron la celda recurrente (GRU, LSTM), la capacidad (`hidden` 128, 256) y, decisivamente, la función de pérdida (coseno frente a InfoNCE), a 60 épocas.

Resultados. Ninguna rama superó la barra. La mejor rama (M3, GRU `hidden`128 InfoNCE) alcanzó un *empate* estadístico con la barra de Markov en `R@10` (0,0894, el IC del paired- Δ incluye cero) pero *perdió* en MRR (0,0388 frente a 0,0694) y `recall@20`. La palanca dominante fue la función de pérdida: InfoNCE fue $\approx 2,3\times$ el coseno en `R@10` (0,0894 frente a 0,0391), mientras que la capacidad (`h`256) y la celda LSTM apenas movieron las ramas coseno (todas en $\sim 0.038\text{--}0.041$). Los pisos de popularidad y recencia quedaron cerca de cero (`R@10` 0,0007).

Interpretación. Un latente-más-un-solo-salto-coseno es una ruta más difícil a la *pista* siguiente *exacta* que un bigrama de co-escucha: el bigrama memoriza directamente “qué sigue a qué”,

Cuadro 1: Tabla de «mejor registrada» de pista siguiente, sobre la partición next-distinct sin fugas (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos). R@10, MRR, artist@10, genre@10 mejor cuanto más alto; el modelo de Markov de primer orden es la barra de referencia incumbente. Fila campeona y campeón previo en negrita; mejor celda por métrica en negrita.

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	Nota
R+M+C, PCA-192 (fila campeona)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	mejor registrada
R+M+C, PCA-128	0.1824 [0.162, 0.203]	0.0993	0.332	0.396	contenido aditivo
R+M, AE-64 (campeón previo)	0.1726 [0.154, 0.192]	0.0963	0.322	0.397	ancla prod.; 3 semillas
R+M+C, AE-64 (graded-preferred)	0.1740 [0.154, 0.194]	0.1014	0.330	0.400	contenido solo empata
R+M, PCA-192	0.1712 [0.151, 0.192]	0.0952	0.329	0.398	≈ campeón previo
R+M, PCA-128	0.1670 [0.148, 0.187]	0.0920	0.329	0.398	ganancia GRU no traslada
R+A+M, AE-64	0.1684	0.0943	—	—	rama ANN redundante
LSTM single, PCA-128	0.1272 [0.110, 0.145]	0.0495	0.335	0.458	mejor único; << blend
GRU single, PCA-192	0.1230 [0.106, 0.140]	0.0534	0.338	0.450	óptimo puntual de dim
GRU single, PCA-128 (base)	0.1146 [0.099, 0.132]	0.0489	0.333	0.452	espacio base confirmado
GRU single, PCA-256	0.1167 [0.101, 0.134]	0.0502	0.338	0.458	pasado el pico de dim
B2 Markov de primer orden (barra)	0.1069 [0.092, 0.124]	0.0694	0.298	0.389	incumbente de la app
GRU single, AE-64 (control)	0.0957 [0.081, 0.111]	0.0411	0.294	0.450	control del bake-off
ANN pooled-MLP, PCA-128	0.0901 [0.076, 0.105]	0.0394	0.299	0.435	pierde ante la GRU
XGB stacker (M+G / M+G+A)	0.080–0.087	0.042–0.049	0.31	0.38	el combinador rinde peor
content-kNN (song-AE)	0.0636 [0.050, 0.077]	0.0321	0.272	0.405	la rama C aditiva
item2vec (SGNS solo entren.)	0.0517	0.0214	0.166	0.312	arrastra el blend
B0 popularidad / B1 recencia	0.0007	—	—	—	pisos

mientras que la GRU debe aterrizar cerca del punto correcto en un espacio de contenido de 64-d y luego recuperar, perdiendo en el ranking preciso (MRR). El hallazgo es consistente con una realidad de deriva de gusto — 0,55 de ítems fríos, comportamiento guiado por identidad/adyacencia — y fijó la agenda: InfoNCE es la pérdida base, y la rama natural siguiente es un *blend* de las puntuaciones de candidatos de la GRU con el bigrama de Markov. *Fuente: 2026-07-13-nexttrack-sequence-sweep.md.*

5. Barrido de topología: profundidad, anchura y dirección son una palanca agotada

Motivación. Con la pérdida fijada en InfoNCE, este barrido aisló la *topología* de red: ¿la profundidad (capas apiladas), la anchura (`hidden 256`), una pila residual entre capas o la bidireccionalidad elevan el modelo de secuencias por encima de la barra de Markov? Como una RNN bidireccional bajo teacher forcing por paso filtraría ítems futuros, la rama bidireccional usó un objetivo leak-free de último ítem (codificar el prefijo completo, predecir solo el siguiente ítem retenido).

Resultados. Refutado. Ninguna rama superó la barra en ambas métricas. La mejor rama (anchura `h256`, R@10 0,0957) es un *empate* en R@10 y pierde en MRR (0,0411 frente a 0,0694). La profundidad es plana de 1→2 capas (0,0894→0,0922, dentro de banda) y *perjudica* con 3 capas (0,0825, fuera de banda por debajo de la barra); la pila residual sobre profundidad-2/h256 no añadió nada. La rama bidireccional colapsó (0,0482), pero esto es un artefacto del *objetivo*, no un veredicto sobre la direccionalidad: el objetivo leak-free de último ítem aporta ~1 objetivo de entrenamiento por sesión frente a los ~13 pares de siguiente-paso del teacher forcing, así que entrenó con ~13× menos señal.

Interpretación. La arquitectura no es la palanca para pista siguiente en este corpus. La señal

transferible de recuperación por latente se estanca en $R@10 \sim 0.09\text{--}0.10$ a través de profundidad, anchura, residual y dirección, por debajo del bigrama de co-escucha — consistente con todo el arco: la función de pérdida movió la aguja y la capacidad/topología no. La única palanca inexplorada restante era el encuadre de candidatos / la fusión, que la campaña siguiente accionó decisivamente. *Fuente: 2026-07-13-nexttrack-topology-scan.md.*

6. El campeón de fusión GRU×Markov, y por qué más ensamblado falla

Motivación. El barrido y el escaneo de topología coincidieron en que la mejor GRU individual solo *empata* con la barra de Markov en $R@10$ mientras pierde en MRR. Esta campaña preguntó si *combinar* modelos supera la barra, y hasta dónde llega el ensamblado. Se definieron tres ramas, cada una emitiendo puntuaciones de candidatos sobre todo el vocabulario: **M** = el bigrama de Markov solo de entrenamiento (la barra), **R** = la recurrencia GRU-infonce-h256, y **A** = un MLP ANN de bolsa-de-prefijo (un gemelo feed-forward de R). Se combinaron con un z-blend ponderado y, como alternativa aprendida, un stacker XGB.

Resultados. El **z-blend R+M** ($\alpha=0,5$) *supera la barra de forma decisiva*: $R@10$ 0,1726 [0,154,0,192], MRR 0,0963, un Δ pareado sobre Markov de +0,0657 [+0,049,+0,083] (IC enteramente por encima de cero) — $\sim +61\%$ de $R@10$, +39% de MRR — en una meseta robusta a lo largo de $\alpha \in [0,25,0,75]$ y reproducido a través de tres semillas (0,1705 / 0,1726 / 0,1726). Se registró como el predictor **seq-blend** y la definición **blend-gru-markov**, el primer campeón de pista siguiente. Más ensamblado luego *no logró* mejorarlo (Tabla 2): R+A+M (0,1684) es levemente peor, R+A ($\approx$ GRU sola, 0,0894) es mucho peor, y ambas variantes del stacker XGB (M+R 0,1020; M+R+A 0,0887) apenas superan a Markov sola.

Cuadro 2: La campaña de fusión: el z-blend R+M supera la barra de Markov de forma decisiva, y ningún ensamble más rico lo mejora. $R@10$ y MRR mejor cuanto más alto; campeón en negrita.

Modelo	$R@10$ [IC 95 %]	MRR	Nota
z-blend R+M $\alpha=0,5$ (campeón)	0.1726 [0.154, 0.192]	0.0963	Δ vs Markov +0,066 [+0,05, +0,08]
z-blend R+A+M	0.1684	0.0943	rama ANN redundante con GRU
B2 barra de Markov (M)	0.1069 [0.092, 0.123]	0.0694	la referencia
XGB stacker M+R	0.1020	0.0561	combinador aprendido $\ll$ z-blend
GRU sola (R)	0.0957	0.0411	empata la barra solo en $R@10$
z-blend R+A	0.0894	0.0377	$\approx$ GRU sola
XGB stacker M+R+A	0.0887	0.0572	apenas supera a Markov

Interpretación. La victoria es sobre *diversidad* de señal, no número de modelos. La GRU (similitud de latente) y Markov (conteos de co-ocurrencia) ordenan pistas correctas *distintas*, así que fusionarlas aproximadamente duplica la tasa de acierto; amontonar más del *mismo* tipo de señal — otro predictor neuronal de latente (A), redundante con R — no añade nada. El stacker XGB aprendido *rinde por debajo* del z-blend simple, en contra de la intuición habitual de que “apilar supera a mezclar”: su entrenamiento puntual binario-con-negativos no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas. El margen restante está acotado por la tasa de ítems fríos de 0,55 y requiere *señal genuinamente nueva*, no más fusión de modelos — la hipótesis que la campaña siguiente pone a prueba. *Fuente: 2026-07-14-nexttrack-blend-and-ensemble.md.*

7. Métricas de relevancia graduada y nuevos aprendices base: el contenido es la única señal aditiva

Motivación. Dos hilos en una campaña. (A) Hacer que la evaluación acredite aterrizar la *banda/ambiente* correcto aunque la pista exacta esté mal — la observación de que “la primera elección normalmente no es la pista exacta, pero el artista normalmente es correcto” — promoviendo *artist@k*, *genre@k* y *artist_mrr* a métricas de primera clase cableadas de extremo a extremo (`seq_common.eval_from_scores` → `Metrics / MetricsSpec` de Rust → `domain.toml` → UI). (B) Probar aprendices base leak-free genuinamente nuevos — **C** = content-kNN, **M2** = un trigram de Markov de segundo orden con back-off, e **I** = un item2vec SGNS solo de entrenamiento — evaluados tanto en las métricas exactas como en las nuevas graduadas.

Resultados. La ruta de la métrica exacta fue idéntica byte a byte (claves puramente aditivas); el campeón reprodujo R@10 0,1726 / MRR 0,0963 exactamente. Ningún aprendiz base nuevo superó la barra en solitario (M2 0,1076 $\approx$ M 0,1069 — el trigram cae al bigram; item2vec 0,0517 es la rama más débil). Mezclado en el campeón, **el contenido es la única señal aditiva: R+M+C** (añadiendo la rama de contenido) es el mejor blend en MRR (0,0963→0,1014), *artist@10* (0,3215→0,3298) y *artist_mrr*, y empata al campeón en R@10 exacto (Δ pareado +0,0014, IC cruza cero). item2vec *arrastra* el blend (R+M+I 0,1349); el trigram es neutral.

Interpretación. content-kNN ordena pistas cuasi-correctas *distintas* (similitud de ambiente por latente) frente a la GRU (recurrencia de sesión) y Markov (co-ocurrencia), justo la diversidad que la campaña de fusión predijo que necesitaría la señal nueva. Sobre el espacio AE-64 la rama de contenido solo *empató* al campeón en recall exacto mientras elevaba las métricas graduadas, así que se llevó adelante como la tercera rama *graded-preferred*, no como un nuevo campeón exacto. Ese “empate” se vuelve una *victoria* cuando el espacio de ítems es más rico (Sección 10): sobre PCA-192 la misma construcción R+M+C es la más fuerte registrada. El item2vec de co-escucha y el trigram de Markov no añadieron nada en estos datos. *Fuente: 2026-07-14-nexttrack-graded-relevance-and-new-legs.md.*

8. El bake-off de compresión de la representación de ítems

Motivación. El espacio de ítems del campeón — un latente AE de 64 dimensiones — fue una elección temprana arbitraria, y la GRU de secuencias predice *hacia* y recupera *sobre* cualquier geometría que ese espacio imponga. Esta campaña pregunta qué *compresión* es el mejor espacio para la GRU: PCA lineal frente al autoencoder no lineal, cada uno a dimensión latente 32 / 64 / 128. Se hornearon seis espacios alternativos desde la *misma* fuente de contenido leak-safe de 384 dimensiones (`spotify_tracks_content`), cada uno ajustado sin supervisión sobre los 23 529 ítems usando solo campos intrínsecos de contenido/acústica/catálogo, y luego evaluados bajo un readout GRU *congelado* (`gru-infonce-h256`), de modo que el espacio latente de ítems es el único eje que se mueve. La apuesta del diseño era que la pérdida de reconstrucción de peso igual por bloque del AE *preservaría* los pequeños bloques de acústica/catálogo que la varianza global dominada por texto de PCA muriera de hambre; la hipótesis nula era que la dimensión, no el compresor, fija el techo.

Resultados. La puerta de paridad pasó: el control AE-64 reprodujo su R@10 registrado de 0,0957. Los seis espacios entrenaron limpiamente (Tabla 3; Figura 1). **PCA-128** es el ganador GRU-individual con R@10 0,1146, un Δ pareado de +0,0189 [+0,0042, +0,0335] sobre el control AE-64 — un IC *enteramente por encima de cero*, la única rama que supera el control significativamente — y también encabeza MRR, *artist@10* y *artist_mrr*. PCA-64 es el segundo (0,1041,

empate). Los dos espacios de 32 dimensiones quedan muy por debajo del control de 64 dimensiones (ambos IC por debajo de cero). La sonda content-kNN sin entrenamiento es plana en ~ 0.06 a través de los seis espacios y *no* sigue el ranking de la GRU.

Cuadro 3: El bake-off de compresión de la representación de ítems: seis espacios de ítems (PCA lineal frente al AE no lineal $\times$ dimensión latente 32 / 64 / 128), cada uno evaluado bajo el *mismo* readout congelado **gru-infonce-h256** (1431 sesiones de prueba; paired- Δ vs el control AE-64 del mismo lote). R@10, MRR, artist@10, genre@10 mejor cuanto más alto. Ganador (PCA-128) en negrita; mejor celda por métrica en negrita.

Espacio	Run id	R@10 [IC 95 %]	Δ vs AE-64	MRR	art@10	gen@10
PCA-128 (ganador)	run-2026071 5-042100-a1 d9d	0.1146 [0.099, 0.132]	+0,019 [+0,004, +0,034]	0.0489	0.3326	0.4521
PCA-64 (segundo)	run-2026071 5-042100-88 51d	0.1041 [0.088, 0.121]	+0,008 (empate)	0.0416	0.3117	0.4598
AE-64 (control)	run-2026071 5-042059-dd 261	0.0957 [0.081, 0.111]	— (control)	0.0411	0.2942	0.4500
AE-128	run-2026071 5-042059-e9 6ae	0.0929 [0.078, 0.108]	−0,003 (empate)	0.0398	0.3026	0.4640
AE-32	run-2026071 5-042059-d3 f9e	0.0545 [0.043, 0.066]	−0,041	0.0274	0.2376	0.3955
PCA-32	run-2026071 5-042059-b1 242	0.0412 [0.031, 0.052]	−0,055	0.0224	0.2187	0.3816

La victoria GRU-individual **no** sobrevive al blend de producción: re-fusionar la rama GRU PCA-128 ganadora con la rama de Markov da R@10 0,1670, *por debajo* del blend campeón AE-64 (0,1726) con IC solapados. No se promovió nada; PCA-128 se llevó adelante solo como el espacio base sancionado para la Fase 2.

Interpretación. La dimensionalidad latente es la palanca dominante y el compresor es secundario. La hipótesis de preservación acústica del diseño queda *refutada*: en dimensión generosa el PCA lineal supera al AE no lineal, y aunque AE-32 preserva los bloques numérico/acústico casi a la perfección queda cerca del fondo. Lo que ayuda es una geometría objetivo *ordenada por varianza y decorrelacionada* que la GRU encuentra más fácil de regresar que los latentes de peso igual enredados del AE. La ventaja del AE en dim 32 es un fenómeno puramente de baja capacidad que se revierte una vez que la dimensión es generosa. La sonda content-kNN plana que no sigue el ranking de la GRU es una divergencia señalada: la victoria viene de la *aprendibilidad* de la geometría objetivo de PCA, no de un espacio demostrablemente más rico. Y la salvedad de peso es el resultado del blend: una rama GRU claramente más fuerte no compró *nada* en el blend, porque la rama de Markov es independiente de la representación y las pistas extra que la mejor GRU recupera se solapan con lo que Markov ya aporta. *Fuente: 2026-07-15-nexttrack-compression-representation-bakeoff.md.*

9. El techo de dimensión: PCA hace pico en 192

Motivación. Con la dimensión establecida como la palanca y PCA aún subiendo en 128, este tramo extendió el barrido de PCA hacia arriba (PCA-192, PCA-256) para localizar el óptimo




Figura 1: La dimensión latente, no el compresor, es la palanca. Ambas series suben abruptamente de dim 32 a 64; PCA (azul) luego sigue subiendo hasta 128 y *sobrepasa* al AE, mientras que el AE (gris) se estanca — su punto de 128 dim de hecho cae por debajo de su propio control de 64 dim. En dim 32 el AE roza a PCA, un cruce de baja capacidad que se revierte una vez que la dimensión es generosa. El control AE-64 (anillo rojo) es el espacio de ítems del campeón; el ganador PCA-128 (estrella verde) es la única rama cuyo IC del paired- Δ supera cero. Las barras de error son IC bootstrap al 95 %; los IC vecinos se solapan, así que la victoria descansa en el test *pareado*.

real antes de que la Fase 2 comprometiera un espacio base, y añadió AE-192 para probar si $\text{PCA} \geq \text{AE}$ se sostiene a mayor dimensión. El protocolo fue idéntico (el mismo readout congelado `gru-infonce-h256`, la misma puerta de paridad); la referencia es PCA-128 (`run-20260715-042100-a1d9d`).

Resultados. La curva de R@10 frente a dimensión de PCA **hace pico en ~192** (R@10 0,1230) y *se revierte* hacia 256 (0,1167); no seguía subiendo. La tendencia completa es 32 $\rightarrow$ 0,041, 64 $\rightarrow$ 0,104, 128 $\rightarrow$ 0,115, **192** $\rightarrow$ 0,123, 256 $\rightarrow$ 0,117 (Figura 2). PCA-192 es el óptimo puntual, pero su Δ pareado frente a PCA-128 es +0,0084 [−0,0007, +0,0189] — falla la barra de “IC enteramente por encima de cero” por 0,0007, un pelo — así que **PCA-128 se mantiene como la base de la Fase 2**, con PCA-192 marcado como el candidato a confirmar-y-promover. $\text{PCA} \geq \text{AE}$ se sostiene con fuerza y la brecha es máxima en 192 (PCA-192 0,123 frente a AE-192 0,098); el AE se estanca plano en ~0.09–0.10 desde dim 64 hacia arriba.

Interpretación. La varianza extra más allá de ~192 (PCA-256 captura un ratio de varianza explicada acumulado de 0,997) son dimensiones de baja señal / ruido que la GRU no puede explotar y que diluyen levemente la geometría objetivo. La meseta plana del AE reconfirma la hipótesis refutada de preservación acústica a mayor dimensión: su objetivo de reconstrucción de peso igual sigue gastando capacidad en los pequeños bloques numérico/acústico (reconstrucción $R^2 \approx 0,999$ en 192) en lugar de la estructura de texto/catálogo de alta varianza que la GRU necesita. Como antes, la sonda content-kNN sin entrenamiento sigue plana y no reproduce el pico de la GRU, así que el óptimo de dimensión es sobre la *aprendibilidad* del objetivo, no la riqueza intrínseca de recuperación. *Fuente: 2026-07-15b-nexttrack-compression-dim-extension.md.*




Figura 2: Se encuentra el techo de dimensión. Extendiendo el barrido de compresión de la Figura 1 a PCA-192/256 y AE-192, la curva PCA (azul) hace pico en ~ 192 ($R@10$ 0,123) y se revierte hacia 256, mientras que el AE (gris) se estanca plano en ~ 0.09 – 0.10 y nunca lo alcanza — la brecha $PCA \geq AE$ es máxima en 192. PCA-192 es el óptimo puntual (estrella verde) pero su Δ pareado sobre PCA-128 roza cero, así que PCA-128 se mantiene como la base individual de la Fase 2. Las barras de error son IC bootstrap al 95 % sobre las 1431 sesiones de prueba.

10. El barrido de familia de modelos y el nuevo campeón, R+M+C sobre PCA-192

Motivación. Con el eje de compresión zanjado (base PCA-128, candidato PCA-192), esta campaña barrió la *familia* de modelos sobre los espacios elegidos: ¿una celda recurrente distinta (LSTM), un MLP agregado no recurrente (ANN) o un stacker XGB *aprendido* superan al z-blend fijo GRU×Markov — y añadir la tercera rama content-kNN (R+M+C) sobre el espacio PCA *rico* finalmente supera al campeón? Una configuración fija corrió a través de todas las ramas; solo variaron la familia de modelos y la representación, y el servidor se serializó (`--max-runs 1`) para evitar una trampa de rendimiento por sobresuscripción de hilos.

Resultados. Una **nueva fila «mejor registrada»**: el **z-blend R+M+C sobre PCA-192** (GRU × Markov solo de entrenamiento × content-kNN, tercios iguales) alcanza $R@10$ 0,1859 [0,166, 0,207], MRR 0,1025, un Δ pareado sobre el campeón previo de +0,0133 [+0,0007, +0,0259] — enteramente por encima de cero, sin regresión de MRR (Tabla 4; Figura 3). La rama de contenido es genuinamente aditiva sobre el espacio rico, superando al R+M del mismo espacio en +0,0154 (PCA-128) / +0,0147 (PCA-192), ambos IC por encima de cero — *más fuerte* que el R+M+C de AE-64 que solo empató (Sección 7), porque el espacio más rico y de mayor EVR hace que la rama de contenido rinda. El **stacker XGB aprendido rinde muy por debajo** del z-blend fijo (0,080–0,087, perdiendo incluso ante su propia rama base GRU individual); la **LSTM es el mejor modelo individual** (PCA-128 0,1272, Δ pareado sobre la GRU +0,0126, IC por encima de cero) pero muy por debajo de los blends; y la base individual de la Fase 2 **se mantiene en PCA-128**.

La coronación, y sus dos salvedades honestas. El candidato a evento de tabla se confirmó re-

Cuadro 4: Barrido de familia de modelos de la Fase 2 sobre los espacios PCA ricos, ordenado por R@10 (mejor cuanto más alto). El z-blend fijo es el combinador de referencia; el stacker XGB aprendido rinde muy por debajo. Fila campeona y campeón previo en negrita; mejor celda por métrica en negrita. El Δ pareado es por sesión contra la referencia nombrada.

Modelo	Run id / fuente	R@10 [IC 95 %]	MRR	Δ pareado
R+M+C, PCA-192 (fila camp.)	analyze_rmc (A4)	0.1859 [0.166, 0.207]	0.1025	vs camp. +0,0133 [+0,001, +0,026]
R+M+C, PCA-128	analyze_rmc (A2)	0.1824 [0.162, 0.203]	0.0993	vs camp. +0,0098 (empate)
R+M, AE-64 (campeón previo)	run-20260714- 170928-645ae	0.1726 [0.154, 0.192]	0.0963	— (referencia)
R+M, PCA-192	run-20260715- 142440-96f53	0.1712 [0.151, 0.192]	0.0952	vs camp. -0,0014 (empate)
R+M, PCA-128	run-20260715- 044920-36dce	0.1670 [0.148, 0.187]	0.0920	vs camp. -0,0056 (empate)
LSTM single, PCA-128	run-20260715- 142440-546d0	0.1272 [0.110, 0.145]	0.0495	vs GRU-128 +0,0126 (> 0)
GRU single, PCA-192	run-20260715- 142440-89d6a	0.1230 [0.106, 0.140]	0.0534	vs GRU-128 +0,0084 (empa- te)
ANN pooled-MLP, PCA-128	run-20260715- 142440-7e528	0.0901 [0.076, 0.105]	0.0394	vs GRU-128 -0,0245
XGB stacker M+G, PCA-128	run-20260715- 142440-371b1	0.0867 [0.073, 0.101]	0.0493	vs GRU-128 -0,0280
XGB stacker M+G+A, PCA-192	run-20260715- 142440-f111d	0.0853 [0.071, 0.099]	0.0490	vs GRU-192 -0,0377

produciendo la rama GRU-192 cinco veces (la original más cuatro re-ejecuciones) y recalculando R+M+C cada vez; el Δ pareado sobre el campeón previo fue +0,0133 [+0,0007, +0,0259] en *cada* re-ejecución, con la ventaja de MRR intacta, así que R+M+C sobre PCA-192 se registró como la nueva fila campeona. Dos salvedades viajan con la coronación y no deben omitirse. Primera, **la dispersión de reproducción fue exactamente cero** porque el entrenamiento de `seq-nexttrack` es determinista en esta CPU — los cinco checkpoints GRU-192 fueron idénticos byte a byte — así que la confirmación verificó *determinismo, no robustez a la semilla*; la única incertidumbre cuantificada es el bootstrap de partición única. Segunda, **el límite inferior del Δ pareado es +0,0007**: la coronación supera cero por un pelo en una única partición. La coronación es real según el criterio pre-acordado, pero el margen sobre el campeón previo es delgado, y endurecerla requiere una segunda partición de prueba sin fugas (o ramas con semillas variadas una vez que el blend se generalice a tres ramas).

Interpretación. El hilo de compresión-más-familia-de-modelos queda por lo demás cerrado: PCA-128 es la base individual, la LSTM es el mejor modelo individual, el stacker aprendido está muerto como combinador, y el z-blend fijo es el combinador de referencia. El resultado de peso es que *el contenido es la única rama que añade señal de ranking genuinamente nueva, y rinde más sobre el espacio PCA de mayor EVR* — la excepción a la regla vigente de que las ganancias de modelo individual / representación no se trasladan al blend (el par R+M sobre los espacios PCA ricos solo empata al campeón AE-64). La brecha de productización persiste: el campeón es solo de entrenamiento y fuera del servidor, así que el campeón previo R+M sobre AE-64 sigue siendo el ancla desplegable hasta que el blend de tres ramas se registre con un subcomando `predict`.
Fuente: *2026-07-15c-nexttrack-phase2-model-sweep.md*.




Figura 3: El barrido de familia de modelos de la Fase 2. El z-blend fijo es el combinador de referencia: R+M+C sobre PCA-192 (verde) es la nueva fila campeona, la rama de contenido es genuinamente aditiva sobre el espacio rico, y el stacker XGB aprendido (rojo) rinde muy por debajo — pierde incluso ante su propia rama base GRU individual. LSTM roza a GRU como el mejor modelo individual (gris) pero queda muy por debajo de los blends. La barra de Markov de primer orden (0,107) es la referencia incumbente; la fila campeona está en 0,186.

11. Conclusiones

Siete campañas (jul 2026) sobre la tarea de recuperación de pista siguiente convergen en una historia clara. (1) Un modelo de secuencias de sesión, incluso en su mejor forma (GRU-infonce), solo *empata* con la barra de Markov de co-escucha de primer orden en recall@10 y pierde en MRR: predecir un latente del siguiente ítem y recuperar por un salto coseno es una ruta más difícil a la pista siguiente exacta que un bigrama que memoriza la adyacencia directamente. (2) La *pérdida* de entrenamiento es la palanca individual dominante (InfoNCE $\approx 2,3\times$ el coseno); la *topología* de red — profundidad, anchura, residual, dirección — es una palanca agotada, y ninguna arquitectura supera la barra. (3) El avance es la *fusión de rankings*: un z-blend R+M de las ramas GRU y Markov supera la barra en $\sim +61\%$ de recall@10 (confirmado con 3 semillas), porque las dos ramas ordenan pistas correctas *distintas*. La victoria es sobre *diversidad* de señal, no número de modelos — añadir una rama neuronal redundante no ayuda, y un stacker XGB aprendido *rinde por debajo* del z-blend fijo, porque su entrenamiento puntual no captura el objetivo de ranking. (4) Un barrido de representación de ítems halló que la *dimensión* latente, no el compresor, es la palanca: el PCA lineal supera al autoencoder no lineal en toda dimensión ≥ 64 (la hipótesis de preservación acústica queda refutada), la curva hace pico en PCA-192 y se revierte hacia 256, y PCA-128 es la base individual confirmada. (5) Sobre el espacio PCA rico la única señal nueva genuinamente aditiva — *content-kNN*, que solo *empató* al campeón sobre el espacio AE-64 — se vuelve una victoria: un z-blend R+M+C de tres ramas sobre PCA-192 es la fila «mejor registrada» actual con recall@10 0,1859, MRR 0,1025 (Δ pareado sobre el campeón previo +0,0133, IC por encima de cero, confirmado a

través de cinco reproducciones). (6) Dos salvedades honestas acotan la coronación: la confirmación por reproducción tuvo dispersión cero porque `seq-nexttrack` es determinista en esta CPU (así que verificó determinismo, no robustez a la semilla), y el límite inferior del `paired- $\Delta$` supera cero por solo +0,0007 en una única partición — endurecerla requiere una segunda partición de prueba sin fugas. (7) Todo predictor de ranking aquí es solo de entrenamiento y fuera del servidor, así que la coronación es una fila «mejor registrada», no un modelo promovido y exportable a la app; el campeón previo R+M sobre AE-64 sigue siendo el ancla de productización, y registrar un blend de tres ramas con un subcomando `predict` es el trabajo futuro principal vigente.

12. Informes fuente

Esta síntesis consolida siete informes de campaña de pista siguiente de `experiments/`:

- `2026-07-13-nexttrack-sequence-sweep.md` — la campaña fundacional de pista siguiente: un barrido de secuencias GRU/LSTM contra la barra de Markov de primer orden; la mejor GRU-infonce empata en R@10 pero pierde en MRR (Sección 4).
- `2026-07-13-nexttrack-topology-scan.md` — el barrido de topología profundidad / anchura / residual / bidireccional; la arquitectura es una palanca agotada, todas las ramas quedan bajo la barra de Markov (Sección 5).
- `2026-07-14-nexttrack-blend-and-ensemble.md` — el z-blend R+M GRU×Markov supera la barra en +61 % de R@10 (el primer campeón de pista siguiente); ningún ensamble más rico lo mejora y el stacker XGB aprendido rinde por debajo (Sección 6).
- `2026-07-14-nexttrack-graded-relevance-and-new-legs.md` — métricas de relevancia graduada de primera clase (`artist@k` / `genre@k` / `artist_mrr`) y nuevos aprendices base leak-free; content-kNN es la única señal aditiva, empatando al campeón sobre AE-64 (Sección 7).
- `2026-07-15-nexttrack-compression-representation-bakeoff.md` — el bake-off de compresión de la representación de ítems (PCA frente a autoencoder × dimensión latente 32/64/128) bajo un readout GRU congelado; PCA-128 es el ganador GRU-individual pero la victoria no se traslada al blend (Sección 8).
- `2026-07-15b-nexttrack-compression-dim-extension.md` — el barrido de dimensión PCA/AE extendido a 192/256; la curva hace pico en PCA-192 y se revierte, así que PCA-128 se mantiene como la base de la Fase 2 (Sección 9).
- `2026-07-15c-nexttrack-phase2-model-sweep.md` — el barrido de familia de modelos sobre los espacios PCA ricos; el z-blend fijo supera al stacker aprendido, la LSTM es el mejor modelo individual, y R+M+C sobre PCA-192 se corona como la nueva fila «mejor registrada» (Sección 10).