

Recomendación de Pista Siguiente en Sesión: Síntesis de Experimentos

31 de julio de 2026

Resumen

Este documento es la síntesis viva de las campañas de recomendación de *pista siguiente* (next-track); los informes markdown de `experiments/` (con `nexttrack` en el nombre) son el registro primario. La tarea es *recuperación* (retrieval) del siguiente ítem: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente, evaluada sobre una única partición cronológica sin fugas (leak-free) *next-distinct* (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba; tasa de ítems fríos (cold-item) 0,55). La métrica principal es recall@10, reportada junto al rango recíproco medio (MRR) y los diagnósticos de relevancia graduada artist@10 / genre@10 / artist_mrr. Se consolidan doce campañas. Una GRU de sesión por sí sola solo *empata* con la barra de Markov de co-escucha de primer orden (R@10 0,1069) en recall@10 y pierde en MRR, y ni el ajuste de la función de pérdida ni ninguna topología de red (profundidad, anchura, residual, dirección) la superan. El avance es la *fusión de rankings*: un z-blend R+M (GRU $\times$ Markov) supera la barra en $\sim +61\%$ de recall@10 (0,1726, confirmado con 3 semillas), porque las dos ramas ordenan pistas correctas *distintas*; un stacker XGB aprendido rinde por debajo del z-blend fijo y añadir ramas neuronales redundantes no ayuda. La única señal genuinamente aditiva es el *contenido*: un barrido de representación de ítems halló que la *dimensión* latente (no el compresor) es la palanca, con un pico en PCA-192, y sobre ese espacio rico un z-blend R+M+C de tres ramas (GRU $\times$ Markov $\times$ content-kNN) es la fila «mejor registrada» actual con recall@10 0,1859, MRR 0,1025. Una campaña posterior de ajuste-a-la-literatura superó luego esa coronación: una *proyección de contenido aprendida* supervisada ($R'+M+C'$), que ajusta un mapa métrico lineal del espacio de ítems PCA-192 hacia la adyacencia de pista siguiente por InfoNCE y recupera las ramas GRU y de contenido en él, alcanza recall@10 0,2117, MRR 0,1220 (paired Δ sobre R+M+C +0,0259, IC por encima de cero), es *robusta a la semilla* a través de tres semillas y *alcanza ítems fríos*, y se endurece en una segunda partición disjunta con 0.64 de fríos (paired Δ +0,0426, IC por encima de cero) — resolviendo las dos salvedades delgadas (confirmación solo-determinista, margen +0,0007) que acotaban la coronación R+M+C. A diferencia de todo predictor de ranking previo, está registrada, promovida y es *servible* (`blend-gru-markov-content-proj`, rango 1 del grupo de mejores modelos), cerrando la brecha de productización; una exploración de representación del vector de ítem y una métrica continua *music@10* de tipo “suena parecido” corroboran al campeón sin destronarlo. Una campaña final de medición añade una suite *solo de visualización* de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10) que toma la huella del campeón como el modelo *más* artist-eager medido (artist_adj@10 0,610) — con la eagerness proveniente de su pata de bigrama de Markov, no de la RNN, y la GRU y la LSTM estadísticamente empatadas — y encuentra que un re-ranqueo MMR en evaluación ($\lambda \approx 0,9$) es una palanca de holisticidad casi gratis, mientras que un regularizador anti-eager de entrenamiento es débil; no se promueve nada y la métrica principal sigue siendo Recall@10. Dos campañas finales de arquitectura cierran después los ejes de arquitectura que quedaban, y ambas son nulos: una GRU de *torre doble* entrenada conjuntamente sobre pares de vistas causales del prefijo no logra superar a

una torre única emparejada en parámetros — el cuarto nulo independiente de combinador aprendido, y el que responde a la objeción de «entrenad la fusión de extremo a extremo» — y un *pre-codificador* por paso aprendido delante de la recurrencia no solo es inútil sino activamente *perjudicial* en una torre única (−0,0140 de Recall@10, con el IC por debajo de cero), pérdida que una lectura contrafactual de interpretabilidad rastrea hasta la rectificación de media onda de un latente centrado en cero, que borra exactamente su mitad negativa (`frac_exact_zero` 0,5327 = `frac_negative_coords` 0,5327). Por último, un análisis de potencia medido reencuadra los cinco nulos de arquitectura: con $n = 1431$ el semiancho del IC de bootstrap pareado es 0,0124 en Recall@10 mientras una familia de arquitectura completa abarca solo 0,028, así que los daños grandes se detectaron con fiabilidad mientras las victorias moderadas nunca fueron detectables — y *holisticness@10* existe en tres generaciones de código mutuamente no comparables, razón por la cual esta síntesis mantiene su tablero denominado en Recall@10. Una última campaña de medición cambia luego la *superficie* y no el modelo: el producto despachado sirve una *caminata autorregresiva* (walk), mientras *holisticness@10* puntúa un top-10 de un solo disparo cuya *mood_coh* se ancla a un centroide de prefijo que *crece*, de modo que la deriva del viaje era invisible por construcción (y la composición es 5,5× más sensible a su factor de relevancia que al de eagerness). Cuatro métricas a nivel de caminata calibradas contra la escucha real del propio usuario (73 632 transiciones consecutivas reales, coseno de paso mediano 0,261, 27,0% de ellas negativas) muestran que el motor despachado camina 2,5× más ceñido que la persona a la que imita (paso mediano 0,661), y tres controles deterministas en tiempo de recuperación — un ancla de semilla, un término de zancada (stride) y un tope duro por artista que *no puede ser superado por puntuación* (dos particiones disjuntas: $\Delta_{\text{artist_conc}}$ −0,527 con $\Delta_{\text{music@10}}$ +0,026, ambos con IC lejos de cero) — hacen simultáneamente alcanzables una zancada de escucha real y un vibe sostenido. Sobre 40 sesiones held-out idénticas y con bootstrap pareado, la familia de *torre doble* que tres campañas habían refutado en recall es la ganadora sobre el objetivo enunciado (*latent/cummean*: error de zancada −0,2545, géneros +1,50, deriva +0,0351, todos con IC lejos de cero y el vibe *sostenido*), mientras empujar la GRU única o el campeón a la misma zancada *cuesta* vibe — pero **ground** cruza el cero en todas las ramas, así que solo queda establecida la *forma* del viaje, y la métrica principal sigue sin cambios.

1. Introducción

Este documento es la síntesis viva de las campañas de recomendación de pista siguiente; los informes markdown de **experiments/** son el registro primario. Cada sección transcribe (nunca recalcula) los resultados cuantitativos de una campaña, preserva sus identificadores de ejecución y de dataset de forma literal para trazabilidad, y añade la motivación y la interpretación que los informes escuetos omiten. Esta instancia se clonó de un laboratorio hermano de ajuste de gusto / rotación y se reorientó a un objetivo de ranking de secuencias; las campañas de rotación son una línea de trabajo separada y *no* se cubren aquí.

Tarea y partición. El laboratorio predice, dentro de una *sesión* de escucha, qué pista reproduce el usuario a *continuación* — una tarea de recuperación del siguiente ítem. El modelo consume el prefijo ordenado de la sesión y puntúa cada ítem del catálogo; los candidatos se ordenan y la siguiente pista *distinta* retenida es el objetivo (una evaluación leave-last-out que excluye los ítems del prefijo, siguiendo la convención de paridad con Markov). Todo el trabajo corre sobre un único artefacto de secuencias, seq-20260713-014226 (7154 sesiones / 19 402 ítems), particionado *cronológicamente por inicio de sesión* en 5723 entrenamiento / 1431 prueba en el corte 2024-08-24. La propiedad definitoria de esta partición es su **tasa de ítems fríos** de 0,55: más de la mitad de las pistas objetivo de las sesiones de prueba nunca aparecen en ninguna sesión de entrenamiento.

Esta es la realidad de predicción hacia adelante sin fugas, y acota el recall absoluto por construcción — cada resultado se lee contra la barra base incumbente, nunca un número absoluto.

Métricas. La métrica principal es **recall@10** ($R@10$, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al **rango recíproco medio** (MRR, el inverso medio del rango de la siguiente pista verdadera) y **recall@20**. Desde 2026-07-14 la evaluación también emite métricas de *relevancia graduada* de primera clase sobre el mismo ranking con prefijo excluido (Sección 7): **artist@k** (algún candidato del top- k comparte el artista de la siguiente pista verdadera), **genre@k** (análogamente sobre el género primario) y **artist_mrr** (MRR del primer candidato del mismo artista). Todos los intervalos de confianza son IC bootstrap al 95 % sobre 2000 remuestreos de las 1431 sesiones de prueba, y el estadístico decisivo es el Δ *pareado* por sesión contra una referencia nombrada. Una *victoria* de tabla requiere superar la referencia en *ambos* $R@10$ y MRR más allá de IC marginales no solapados (la barra estricta), seguido de una confirmación por reproducción; el test de paired- Δ con IC-enteramente-mayor-que-cero es el estadístico alternativo más potente (coronó a ambos campeones) y puede discrepar de la barra estricta. Las métricas graduadas son el marcador honesto: el recall exacto es modesto por construcción, pero el campeón acierta el *artista* correcto en el top diez $\sim 32\%$ de las veces y el *género* correcto $\sim 40\%$ — mucho más útil que el número exacto de $\sim 17\%$ que impone la tasa de ítems fríos. Desde 2026-07-20 la tabla también incluye **music@10**, una métrica graduada continua de tipo “suena parecido” (Sección 14): el coseno máximo medio, en un espacio intrínseco balanceado de distancia musical, entre la siguiente pista verdadera y los diez candidatos recuperados — un superconjunto suave de recall@10 que acredita aterrizar algo que *suena como* la verdad en un fallo exacto. Es solo de visualización; la métrica principal sigue siendo recall@10.

El campeón vigente. La fila «mejor registrada» actual — y, desde 2026-07-18, un modelo *registrado, promovido y servible* — es una *proyección de contenido aprendida* supervisada, $R' + M + C'$: una GRU de sesión $\times$ un modelo de co-ocurrencia de Markov de primer orden $\times$ una rama content-kNN, donde la GRU (R') y la rama de contenido (C') recuperan en un mapa métrico InfoNCE del espacio de ítems PCA-192 ajustado hacia la adyacencia de pista siguiente, con $R@10$ 0,2117, MRR 0,1220 (Secciones 11–12). Supera al z-blend de tres ramas $R + M + C$ sobre el mismo espacio PCA-192 ($R@10$ 0,1859; Sección 10), que a su vez había destronado al z-blend de dos ramas $R + M$ sobre el espacio del song-autoencoder de 64 dimensiones (AE-64, $R@10$ 0,1726; Sección 6). La proyección es *robusta a la semilla y endurecida en dos particiones*, y es desplegable vía `POST /api/models/blend-gru-markov-content-proj/predict` — cerrando la brecha de productización que dejaban los drivers de fusión fuera del servidor previos. Los campeones previos siguen siendo referencias útiles ($R + M$ sigue siendo el blend de dos ramas más ligero), pero ya no son el ancla desplegable.

2. Trasfondo: la tarea de secuencias, las líneas base y las métricas

Esta sección da la teoría mínima para un lector que conoce machine learning pero no este repositorio. Está anclada al archivo vivo de hechos del proyecto y crece solo cuando una nueva familia de predictores o métrica entra en los informes.

Los modelos y líneas base en juego.

GRU / LSTM de sesión (seq-nexttrack). Una red neuronal recurrente que lee el prefijo ordenado de la sesión un ítem a la vez (cada ítem representado por su vector latente) y emite

un latente predicho del siguiente ítem; los candidatos se ordenan por similitud coseno a esa predicción. La GRU (gated recurrent unit) y la LSTM (long short-term memory) son las dos celdas recurrentes probadas. La recurrencia captura el *contexto de sesión* — la trayectoria de la sesión de escucha — en lugar de un único ítem previo.

Función de pérdida: InfoNCE frente a coseno. El modelo de secuencias puede entrenarse para regresar el latente del siguiente ítem por pérdida *coseno* (acercar la predicción al latente verdadero) o por **InfoNCE**, un objetivo contrastivo que acerca la predicción al ítem verdadero y la aleja de un lote de negativos. InfoNCE es la palanca individual más importante de todo el arco: es $\approx 2,3\times$ el coseno en recall@10, porque la recuperación por ranking premia una representación que *separa* el siguiente ítem verdadero de los distractores, lo que una pérdida contrastiva optimiza directamente y una regresión puntual no.

Co-ocurrencia de Markov de primer orden (la barra, B2). Un modelo de transición solo de entrenamiento: un `track_bigram` que cuenta “qué pista sigue a qué” con back-off por artista/género para pares no vistos (el término de transición que la app hermana ya despacha). Memoriza la adyacencia directamente, que es exactamente lo que premia el ranking exacto de la siguiente pista, y es la barra de referencia contra la que se mide cada rama. También se probó un Markov de segundo orden (trigrama) con back-off y es esencialmente neutral — las sesiones son demasiado cortas/dispersas para que un trigrama dispare, así que cae al bigrama.

item2vec. Un embedding skip-gram (SGNS) de co-escucha entrenado solo sobre las sesiones de *entrenamiento* (un análogo leak-safe de word2vec, donde las “palabras” son pistas y las “frases” son sesiones); los candidatos se ordenan por coseno al prefijo agregado por media. Sobre 5723 sesiones de entrenamiento es demasiado disperso para localizar y es la rama más débil registrada; los vectores de co-escucha de historia completa *no* se usan deliberadamente porque filtran a través de la partición.

content-kNN. Una rama de recuperación sin entrenamiento: coseno del latente de cada candidato a los latentes del prefijo (agregado por máximo). Es débil por sí sola en recall exacto pero captura similitud de *ambiente* (vibe) que los conteos pierden (su genre@10 ya roza la barra de Markov), y es la única tercera rama genuinamente aditiva para el blend de fusión.

z-blend de fusión de rankings frente a stacker aprendido. Dos formas de combinar ramas. El **z-blend** normaliza (z-score) las puntuaciones de candidatos de cada rama y toma una suma ponderada ($\alpha \cdot z(\text{rama}) + \dots$) — un fusor fijo, ligero en parámetros. El **stacker XGB** (apilador) es un meta-aprendiz de gradient boosting sobre rasgos por candidato (puntuaciones de ramas + popularidad + recencia + coincidencia de artista/género), entrenado de forma puntual con negativos muestreados. A lo largo de dos campañas el z-blend fijo *supera* al stacker aprendido de forma decisiva, porque el entrenamiento puntual binario del stacker no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas.

Proyección de contenido aprendida (mapa métrico supervisado). Un mapa lineal W del espacio de latentes de ítems ajustado por **InfoNCE** sobre los pares consecutivos de entrenamiento ($u \rightarrow v$) (auto-bucles descartados, convención de Markov), de modo que el coseno en el espacio- W refleja “probable de seguir”. Es leak-free (solo pares de entrenamiento + latentes de contenido intrínsecos, nunca la partición). Tanto la rama content-kNN (C') como

la GRU (R') recuperan luego en el espacio proyectado; Markov no cambia. Es la única alternativa *supervisada* a la geometría PCA no supervisada y ordenada por varianza y — como el contenido es el único canal con alcance a ítems fríos — eleva *ambas* ramas que comparten el espacio, siendo el campeón actual (Sección 11).

Fusión recurrente de torre doble (seq-dualgru). Dos torres recurrentes *independientes* (pesos separados) leen el prefijo en paralelo sobre *vistas* estrictamente causales configurables de él — **latent** (el vector de ítem crudo), **delta** (la diferencia entre pasos) o **cummean** (el centroide acumulado de la sesión) — y sus estados ocultos por paso, concatenados, los lee una cabeza de fusión (**fusion_layers** = 0 para una lectura puramente lineal, = 1 para un MLP de anchura 256). Reutiliza literalmente el objetivo, el batching, la parada temprana y la evaluación de **seq-nexttrack**, de modo que aísla la arquitectura como única variable. La idea motivadora es que dos torres solo deberían ayudar si ven información genuinamente distinta; la Sección 16 lo pone a prueba y lo refuta.

Pre-codificador por paso. Una re-incrustación no lineal colocada *delante de* la recurrencia — [Linear, ReLU, Dropout] aplicada en cada paso temporal, expuesta como **pre_hidden/pre_layers**. Es un objeto de prueba inusualmente nítido: la propia transformación de entrada de una GRU *ya* es lineal, así que un pre-codificador lineal con anchura $\geq$ la dimensión de entrada es exactamente igual de expresivo que no tener pre-codificador, y el *rectificador* es el único cambio — lo que hace que el nulo de la Sección 17 sea atribuible mecánicamente y no solo negativo.

Espacios de latentes de ítems: song-AE frente a PCA, y la trampa de la colección equivocada. El modelo de secuencias predice *hacia*, y recupera *sobre*, un espacio latente por ítem, así que la elección de ese espacio es un eje de primera clase. Aparecen tres familias:

AE-64 (spotify_tracks_song_ae). Un latente *song-autoencoder* no lineal de 64 dimensiones, el espacio de ítems campeón original. Un autoencoder comprime cada ítem reconstruyéndolo a través de un cuello de botella; su pérdida de reconstrucción de peso igual por bloque reparte la capacidad de forma uniforme entre los bloques de contenido, acústica y catálogo.

PCA- k (spotify_tracks_song_pca k). Una compresión *lineal* por componentes principales a dimensión $k \in \{32, 64, 128, 192, 256\}$, que ordena las dimensiones por varianza explicada y las decorrelaciona. Como muestran las Secciones 8–9, esta geometría ordenada por varianza y decorrelacionada es *más fácil* de regresar para la GRU que los latentes de peso igual enredados del AE, así que PCA supera al AE en toda dimensión ≥ 64 .

La trampa de la colección equivocada. Ambos anteriores se ajustan *solo* desde la fuente leak-safe **spotify_tracks_content** (campos intrínsecos de contenido/acústica/catálogo; sin campo conductual ni objetivo). La colección por defecto **spotify_tracks** de 200 dimensiones es un embedding *conductual* de co-escucha que filtra suavemente el comportamiento de repetición y **nunca** debe usarse como espacio de ítems.

3. Tabla de clasificación de pista siguiente

La Tabla 1 es la tabla vigente de «mejor registrada». Está sobre la única partición next-distinct sin fugas y ordenada por recall@10. Desde 2026-07-18 la familia de secuencias lleva un contrato de servicio de ranking, así que el blend campeón de proyección aprendida es un modelo *promovido y*

servible (**blend-gru-markov-content-proj**, rango 1 del grupo de mejores modelos), no una mera fila de tabla (Sección 12); los blends anteriores debajo de él, y las ramas en solitario, siguen siendo referencias fuera del servidor. Los espacios de ítems se ajustan todos desde la fuente de contenido leak-safe (Sección 2). Desde 2026-07-22 la evaluación también lleva una suite *solo de visualización* de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10; Sección 15); no reordena este tablero (la métrica principal sigue siendo Recall@10), pero toma la huella del campeón como la fila más artist-eager. Desde 2026-07-25 el tablero lleva además tres puntos de dato de arquitectura *refutados*: el control de capacidad de GRU única más ancho, la mejor rama de torre doble y la mejor rama de pre-codificador en torre única (Secciones 16–17). Se listan porque *acotan* sus ejes, no porque sean candidatos: ninguno supera la línea base de GRU única según el estadístico pareado y ninguno se registró. Sobre la métrica principal efectiva en el servidor, y sobre por qué este tablero sigue denominado en Recall@10 a lo largo de tres generaciones de holisticidad, véase la Sección 18.2.

Cuadro 1: Tabla de «mejor registrada» de pista siguiente, sobre la partición next-distinct sin fugas (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos). R@10, MRR, artist@10, genre@10, music@10 mejor cuanto más alto; el modelo de Markov de primer orden es la barra de referencia incumbente. Los valores de music@10 son el backfill offline (Sección 14); las filas sin un run mapeado se dejan en blanco. Fila campeona y campeones previos en negrita; mejor celda por métrica en negrita. Las tres filas de arquitectura refutada añadidas el 2026-07-25/26 se muestran para *acotar* sus ejes y quedan excluidas del resaltado de mejor celda; no llevan IC marginal, solo un Δ pareado contra la línea base de GRU única (Tablas 15 y 17).

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	mus@10	Nota
$R'+M+C'$, PCA-192 (campeón, servible)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	0.454	nuevo campeón
R+M+C, PCA-192 (campeón de fusión previo)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	0.449	contenido aditivo
R+M+C, PCA-128	0.1824 [0.162, 0.203]	0.0993	0.332	0.396	—	contenido aditivo
R+M, AE-64 (campeón previo)	0.1726 [0.154, 0.192]	0.0963	0.322	0.397	0.441	ancla prod.; 3 sem
R+M+C, AE-64 (graded-preferred)	0.1740 [0.154, 0.194]	0.1014	0.330	0.400	—	contenido solo emp
R+M, PCA-192	0.1712 [0.151, 0.192]	0.0952	0.329	0.398	0.443	$\approx$ campeón previo
R+M, PCA-128	0.1670 [0.148, 0.187]	0.0920	0.329	0.398	0.444	ganancia GRU no
R+A+M, AE-64	0.1684	0.0943	—	—	—	rama ANN redund
LSTM single, PCA-128	0.1272 [0.110, 0.145]	0.0495	0.335	0.458	0.451	mejor único; $\ll$ bl
GRU única h454, PCA-192	0.1251	0.0539	0.338	0.454	0.457	anchura cerrada
GRU single, PCA-192	0.1230 [0.106, 0.140]	0.0534	0.338	0.450	0.456	óptimo puntual de
torre doble GRU f0, PCA-192	0.1188	0.0563	0.337	0.456	0.455	torre doble: refuta
GRU single, PCA-128 (base)	0.1146 [0.099, 0.132]	0.0489	0.333	0.452	0.457	espacio base confir
GRU single, PCA-256	0.1167 [0.101, 0.134]	0.0502	0.338	0.458	0.456	pasado el pico de c
pre-MLP→GRU, PCA-192	0.1090	0.0446	0.324	0.469	0.450	pre-codif. perjudic
B2 Markov de primer orden (barra)	0.1069 [0.092, 0.124]	0.0694	0.298	0.389	0.407	incumbente de la a
GRU single, AE-64 (control)	0.0957 [0.081, 0.111]	0.0411	0.294	0.450	0.432	control del bake-of
ANN pooled-MLP, PCA-128	0.0901 [0.076, 0.105]	0.0394	0.299	0.435	0.426	pierde ante la GRU
XGB stacker (M+G / M+G+A)	0.080–0.087	0.042–0.049	0.31	0.38	0.41	el combinador rind
content-kNN (song-AE)	0.0636 [0.050, 0.077]	0.0321	0.272	0.405	—	la rama C aditiva
item2vec (SGNS solo entren.)	0.0517	0.0214	0.166	0.312	—	arrastra el blend
B0 popularidad / B1 recencia	0.0007	—	—	—	0.185	pisos

4. El barrido de secuencias: una GRU-infonce empata con la barra de Markov

Motivación. La campaña inaugural de la instancia planteó la pregunta fundacional: ¿un modelo de secuencias con contexto de sesión — una GRU/LSTM sobre el prefijo ordenado, prediciendo el latente song-AE de 64 dimensiones de la siguiente pista y recuperando por coseno — supera al modelo de transición de Markov de primer orden que la app hermana ya despacha, *hacia adelante*, sobre la partición de sesiones sin fugas? Cuatro ramas cruzaron la celda recurrente (GRU, LSTM), la capacidad (`hidden` 128, 256) y, decisivamente, la función de pérdida (coseno frente a InfoNCE), a 60 épocas.

Resultados. Ninguna rama superó la barra. La mejor rama (M3, GRU `hidden`128 InfoNCE) alcanzó un *empate* estadístico con la barra de Markov en R@10 (0,0894, el IC del paired- Δ incluye cero) pero *perdió* en MRR (0,0388 frente a 0,0694) y recall@20. La palanca dominante fue la función de pérdida: InfoNCE fue $\approx 2,3\times$ el coseno en R@10 (0,0894 frente a 0,0391), mientras que la capacidad (`h`256) y la celda LSTM apenas movieron las ramas coseno (todas en ~ 0.038 – 0.041). Los pisos de popularidad y recencia quedaron cerca de cero (R@10 0,0007).

Interpretación. Un latente-más-un-solo-salto-coseno es una ruta más difícil a la *pista* siguiente *exacta* que un bigrama de co-escucha: el bigrama memoriza directamente “qué sigue a qué”, mientras que la GRU debe aterrizar cerca del punto correcto en un espacio de contenido de 64-d y luego recuperar, perdiendo en el ranking preciso (MRR). El hallazgo es consistente con una realidad de deriva de gusto — 0,55 de ítems fríos, comportamiento guiado por identidad/adyacencia — y fijó la agenda: InfoNCE es la pérdida base, y la rama natural siguiente es un *blend* de las puntuaciones de candidatos de la GRU con el bigrama de Markov. *Fuente:* 2026-07-13-nexttrack-sequence-sweep.md.

5. Barrido de topología: profundidad, anchura y dirección son una palanca agotada

Motivación. Con la pérdida fijada en InfoNCE, este barrido aisló la *topología* de red: ¿la profundidad (capas apiladas), la anchura (`hidden` 256), una pila residual entre capas o la bidireccionalidad elevan el modelo de secuencias por encima de la barra de Markov? Como una RNN bidireccional bajo teacher forcing por paso filtraría ítems futuros, la rama bidireccional usó un objetivo leak-free de último ítem (codificar el prefijo completo, predecir solo el siguiente ítem retenido).

Resultados. Refutado. Ninguna rama superó la barra en ambas métricas. La mejor rama (anchura `h`256, R@10 0,0957) es un *empate* en R@10 y pierde en MRR (0,0411 frente a 0,0694). La profundidad es plana de 1→2 capas (0,0894→0,0922, dentro de banda) y *perjudica* con 3 capas (0,0825, fuera de banda por debajo de la barra); la pila residual sobre profundidad-2/`h`256 no añadió nada. La rama bidireccional colapsó (0,0482), pero esto es un artefacto del *objetivo*, no un veredicto sobre la direccionalidad: el objetivo leak-free de último ítem aporta ~ 1 objetivo de entrenamiento por sesión frente a los ~ 13 pares de siguiente-paso del teacher forcing, así que entrenó con $\sim 13\times$ menos señal.

Interpretación. La arquitectura no es la palanca para pista siguiente en este corpus. La señal transferible de recuperación por latente se estanca en R@10 ~ 0.09 – 0.10 a través de profundidad, anchura, residual y dirección, por debajo del bigrama de co-escucha — consistente con todo el arco: la función de pérdida movió la aguja y la capacidad/topología no. La única palanca inexplorada restante era el encuadre de candidatos / la fusión, que la campaña siguiente accionó decisivamente. *Fuente:* 2026-07-13-nexttrack-topology-scan.md.

6. El campeón de fusión GRU×Markov, y por qué más ensamblado falla

Motivación. El barrido y el escaneo de topología coincidieron en que la mejor GRU individual solo *empata* con la barra de Markov en R@10 mientras pierde en MRR. Esta campaña preguntó si *combinar* modelos supera la barra, y hasta dónde llega el ensamblado. Se definieron tres ramas, cada una emitiendo puntuaciones de candidatos sobre todo el vocabulario: **M** = el bigrama de Markov solo de entrenamiento (la barra), **R** = la recurrencia GRU-infonce-h256, y **A** = un MLP ANN de bolsa-de-prefijo (un gemelo feed-forward de R). Se combinaron con un z-blend ponderado y, como alternativa aprendida, un stacker XGB.

Resultados. El **z-blend R+M** ($\alpha=0,5$) *supera la barra de forma decisiva*: R@10 0,1726 [0,154,0,192], MRR 0,0963, un Δ pareado sobre Markov de +0,0657 [+0,049,+0,083] (IC enteramente por encima de cero) — $\sim +61\%$ de R@10, $+39\%$ de MRR — en una meseta robusta a lo largo de $\alpha \in [0,25,0,75]$ y reproducido a través de tres semillas (0,1705 / 0,1726 / 0,1726). Se registró como el predictor **seq-blend** y la definición **blend-gru-markov**, el primer campeón de pista siguiente. Más ensamblado luego *no logró* mejorarlo (Tabla 2): R+A+M (0,1684) es levemente peor, R+A ($\approx$ GRU sola, 0,0894) es mucho peor, y ambas variantes del stacker XGB (M+R 0,1020; M+R+A 0,0887) apenas superan a Markov sola.

Cuadro 2: La campaña de fusión: el z-blend R+M supera la barra de Markov de forma decisiva, y ningún ensamble más rico lo mejora. R@10 y MRR mejor cuanto más alto; campeón en negrita.

Modelo	R@10 [IC 95 %]	MRR	Nota
z-blend R+M $\alpha=0,5$ (campeón)	0.1726 [0.154, 0.192]	0.0963	Δ vs Markov +0,066 [+0,05,+0,08]
z-blend R+A+M	0.1684	0.0943	rama ANN redundante con GRU
B2 barra de Markov (M)	0.1069 [0.092, 0.123]	0.0694	la referencia
XGB stacker M+R	0.1020	0.0561	combinador aprendido $\ll$ z-blend
GRU sola (R)	0.0957	0.0411	empata la barra solo en R@10
z-blend R+A	0.0894	0.0377	$\approx$ GRU sola
XGB stacker M+R+A	0.0887	0.0572	apenas supera a Markov

Interpretación. La victoria es sobre *diversidad* de señal, no número de modelos. La GRU (similitud de latente) y Markov (conteos de co-ocurrencia) ordenan pistas correctas *distintas*, así que fusionarlas aproximadamente duplica la tasa de acierto; amontonar más del *mismo* tipo de señal — otro predictor neuronal de latente (A), redundante con R — no añade nada. El stacker XGB aprendido *rinde por debajo* del z-blend simple, en contra de la intuición habitual de que “apilar supera a mezclar”: su entrenamiento puntual binario-con-negativos no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas. El margen restante está acotado por la tasa de ítems fríos de 0,55 y requiere *señal genuinamente nueva*, no más fusión de modelos — la hipótesis que la campaña siguiente pone a prueba. *Fuente: 2026-07-14-nexttrack-blend-and-ensemble.md.*

7. Métricas de relevancia graduada y nuevos aprendices base: el contenido es la única señal aditiva

Motivación. Dos hilos en una campaña. (A) Hacer que la evaluación acredite aterrizar la *banda/ambiente* correcto aunque la pista exacta esté mal — la observación de que “la primera elec-

ción normalmente no es la pista exacta, pero el artista normalmente es correcto” — promoviendo *artist@k*, *genre@k* y *artist_mrr* a métricas de primera clase cableadas de extremo a extremo (*seq_common.eval_from_scores* → *Metrics* / *MetricsSpec* de Rust → *domain.toml* → UI). (B) Probar aprendices base leak-free genuinamente nuevos — **C** = content-kNN, **M2** = un trigram de Markov de segundo orden con back-off, e **I** = un item2vec SGNS solo de entrenamiento — evaluados tanto en las métricas exactas como en las nuevas graduadas.

Resultados. La ruta de la métrica exacta fue idéntica byte a byte (claves puramente aditivas); el campeón reprodujo R@10 0,1726 / MRR 0,0963 exactamente. Ningún aprendiz base nuevo superó la barra en solitario (M2 0,1076 $\approx$ M 0,1069 — el trigram cae al bigrama; item2vec 0,0517 es la rama más débil). Mezclado en el campeón, **el contenido es la única señal aditiva: R+M+C** (añadiendo la rama de contenido) es el mejor blend en MRR (0,0963→0,1014), artist@10 (0,3215→0,3298) y artist_mrr, y empata al campeón en R@10 exacto (Δ pareado +0,0014, IC cruza cero). item2vec *arrastra* el blend (R+M+I 0,1349); el trigram es neutral.

Interpretación. content-kNN ordena pistas cuasi-correctas *distintas* (similitud de ambiente por latente) frente a la GRU (recurrencia de sesión) y Markov (co-ocurrencia), justo la diversidad que la campaña de fusión predijo que necesitaría la señal nueva. Sobre el espacio AE-64 la rama de contenido solo *empató* al campeón en recall exacto mientras elevaba las métricas graduadas, así que se llevó adelante como la tercera rama graded-preferred, no como un nuevo campeón exacto. Ese “empate” se vuelve una *victoria* cuando el espacio de ítems es más rico (Sección 10): sobre PCA-192 la misma construcción R+M+C es la más fuerte registrada. El item2vec de co-escucha y el trigram de Markov no añadieron nada en estos datos. *Fuente: 2026-07-14-nexttrack-graded-relevance-and-new-legs.md.*

8. El bake-off de compresión de la representación de ítems

Motivación. El espacio de ítems del campeón — un latente AE de 64 dimensiones — fue una elección temprana arbitraria, y la GRU de secuencias predice *hacia* y recupera *sobre* cualquier geometría que ese espacio imponga. Esta campaña pregunta qué *compresión* es el mejor espacio para la GRU: PCA lineal frente al autoencoder no lineal, cada uno a dimensión latente 32 / 64 / 128. Se hornearon seis espacios alternativos desde la *misma* fuente de contenido leak-safe de 384 dimensiones (*spotify_tracks_content*), cada uno ajustado sin supervisión sobre los 23 529 ítems usando solo campos intrínsecos de contenido/acústica/catálogo, y luego evaluados bajo un readout GRU *congelado* (*gru-infonce-h256*), de modo que el espacio latente de ítems es el único eje que se mueve. La apuesta del diseño era que la pérdida de reconstrucción de peso igual por bloque del AE *preservaría* los pequeños bloques de acústica/catálogo que la varianza global dominada por texto de PCA muriera de hambre; la hipótesis nula era que la dimensión, no el compresor, fija el techo.

Resultados. La puerta de paridad pasó: el control AE-64 reprodujo su R@10 registrado de 0,0957. Los seis espacios entrenaron limpiamente (Tabla 3; Figura 1). **PCA-128** es el ganador GRU-individual con R@10 0,1146, un Δ pareado de +0,0189 [+0,0042, +0,0335] sobre el control AE-64 — un IC *enteramente por encima de cero*, la única rama que supera el control significativamente — y también encabeza MRR, artist@10 y artist_mrr. PCA-64 es el segundo (0,1041, empate). Los dos espacios de 32 dimensiones quedan muy por debajo del control de 64 dimensiones (ambos IC por debajo de cero). La sonda content-kNN sin entrenamiento es plana en ~ 0.06 a través de los seis espacios y *no* sigue el ranking de la GRU.

La victoria GRU-individual **no** sobrevive al blend de producción: re-fusionar la rama GRU PCA-128 ganadora con la rama de Markov da R@10 0,1670, *por debajo* del blend campeón AE-64

Cuadro 3: El bake-off de compresión de la representación de ítems: seis espacios de ítems (PCA lineal frente al AE no lineal $\times$ dimensión latente 32 / 64 / 128), cada uno evaluado bajo el *mismo* readout congelado **gru-infonce-h256** (1431 sesiones de prueba; paired- Δ vs el control AE-64 del mismo lote). R@10, MRR, artist@10, genre@10 mejor cuanto más alto. Ganador (PCA-128) en negrita; mejor celda por métrica en negrita.

Espacio	Run id	R@10 [IC 95 %]	Δ vs AE-64	MRR	art@10	gen@10
PCA-128 (ganador)	run-2026071 5-042100-a1 d9d	0.1146 [0.099, 0.132]	+0,019 [+0,004, +0,034]	0.0489	0.3326	0.4521
PCA-64 (segundo)	run-2026071 5-042100-88 51d	0.1041 [0.088, 0.121]	+0,008 (empate)	0.0416	0.3117	0.4598
AE-64 (control)	run-2026071 5-042059-dd 261	0.0957 [0.081, 0.111]	— (control)	0.0411	0.2942	0.4500
AE-128	run-2026071 5-042059-e9 6ae	0.0929 [0.078, 0.108]	−0,003 (empate)	0.0398	0.3026	0.4640
AE-32	run-2026071 5-042059-d3 f9e	0.0545 [0.043, 0.066]	−0,041	0.0274	0.2376	0.3955
PCA-32	run-2026071 5-042059-b1 242	0.0412 [0.031, 0.052]	−0,055	0.0224	0.2187	0.3816

(0,1726) con IC solapados. No se promovió nada; PCA-128 se llevó adelante solo como el espacio base sancionado para la Fase 2.

Interpretación. La dimensionalidad latente es la palanca dominante y el compresor es secundario. La hipótesis de preservación acústica del diseño queda *refutada*: en dimensión generosa el PCA lineal supera al AE no lineal, y aunque AE-32 preserva los bloques numérico/acústico casi a la perfección queda cerca del fondo. Lo que ayuda es una geometría objetivo *ordenada por varianza y decorrelacionada* que la GRU encuentra más fácil de regresar que los latentes de peso igual enredados del AE. La ventaja del AE en dim 32 es un fenómeno puramente de baja capacidad que se revierte una vez que la dimensión es generosa. La sonda content-kNN plana que no sigue el ranking de la GRU es una divergencia señalada: la victoria viene de la *aprendibilidad* de la geometría objetivo de PCA, no de un espacio demostrablemente más rico. Y la salvedad de peso es el resultado del blend: una rama GRU claramente más fuerte no compró *nada* en el blend, porque la rama de Markov es independiente de la representación y las pistas extra que la mejor GRU recupera se solapan con lo que Markov ya aporta. *Fuente: 2026-07-15-nexttrack-compression-representation-bakeoff.md.*

9. El techo de dimensión: PCA hace pico en 192

Motivación. Con la dimensión establecida como la palanca y PCA aún subiendo en 128, este tramo extendió el barrido de PCA hacia arriba (PCA-192, PCA-256) para localizar el óptimo real antes de que la Fase 2 comprometiera un espacio base, y añadió AE-192 para probar si $\text{PCA} \geq \text{AE}$ se sostiene a mayor dimensión. El protocolo fue idéntico (el mismo readout congelado **gru-infonce-h256**, la misma puerta de paridad); la referencia es PCA-128 (run-20260715-042100-a1d9d).

Resultados. La curva de R@10 frente a dimensión de PCA **hace pico en ~ 192** (R@10 0,1230) y




Figura 1: La dimensión latente, no el compresor, es la palanca. Ambas series suben abruptamente de dim 32 a 64; PCA (azul) luego sigue subiendo hasta 128 y *sobrepasa* al AE, mientras que el AE (gris) se estanca — su punto de 128 dim de hecho cae por debajo de su propio control de 64 dim. En dim 32 el AE roza a PCA, un cruce de baja capacidad que se revierte una vez que la dimensión es generosa. El control AE-64 (anillo rojo) es el espacio de ítems del campeón; el ganador PCA-128 (estrella verde) es la única rama cuyo IC del paired- Δ supera cero. Las barras de error son IC bootstrap al 95%; los IC vecinos se solapan, así que la victoria descansa en el test *pareado*.

se revierte hacia 256 (0,1167); no seguía subiendo. La tendencia completa es $32 \rightarrow 0,041$, $64 \rightarrow 0,104$, $128 \rightarrow 0,115$, **192** $\rightarrow 0,123$, $256 \rightarrow 0,117$ (Figura 2). PCA-192 es el óptimo puntual, pero su Δ pareado frente a PCA-128 es $+0,0084$ $[-0,0007, +0,0189]$ — falla la barra de “IC enteramente por encima de cero” por 0,0007, un pelo — así que **PCA-128 se mantiene como la base de la Fase 2**, con PCA-192 marcado como el candidato a confirmar-y-promover. $\text{PCA} \geq \text{AE}$ se sostiene con fuerza y la brecha es máxima en 192 (PCA-192 0,123 frente a AE-192 0,098); el AE se estanca plano en $\sim 0,09$ – $0,10$ desde dim 64 hacia arriba.

Interpretación. La varianza extra más allá de ~ 192 (PCA-256 captura un ratio de varianza explicada acumulado de 0,997) son dimensiones de baja señal / ruido que la GRU no puede explotar y que diluyen levemente la geometría objetivo. La meseta plana del AE reconfirma la hipótesis refutada de preservación acústica a mayor dimensión: su objetivo de reconstrucción de peso igual sigue gastando capacidad en los pequeños bloques numérico/acústico (reconstrucción $R^2 \approx 0,999$ en 192) en lugar de la estructura de texto/catálogo de alta varianza que la GRU necesita. Como antes, la sonda content-kNN sin entrenamiento sigue plana y no reproduce el pico de la GRU, así que el óptimo de dimensión es sobre la *aprendibilidad* del objetivo, no la riqueza intrínseca de recuperación. *Fuente: 2026-07-15b-nexttrack-compression-dim-extension.md.*




Figura 2: Se encuentra el techo de dimensión. Extendiendo el barrido de compresión de la Figura 1 a PCA-192/256 y AE-192, la curva PCA (azul) hace pico en ~ 192 ($R@10$ 0,123) y se revierte hacia 256, mientras que el AE (gris) se estanca plano en ~ 0.09 – 0.10 y nunca lo alcanza — la brecha $PCA \geq AE$ es máxima en 192. PCA-192 es el óptimo puntual (estrella verde) pero su Δ pareado sobre PCA-128 roza cero, así que PCA-128 se mantiene como la base individual de la Fase 2. Las barras de error son IC bootstrap al 95 % sobre las 1431 sesiones de prueba.

10. El barrido de familia de modelos y el nuevo campeón, R+M+C sobre PCA-192

Motivación. Con el eje de compresión zanjado (base PCA-128, candidato PCA-192), esta campaña barrió la *familia* de modelos sobre los espacios elegidos: ¿una celda recurrente distinta (LSTM), un MLP agregado no recurrente (ANN) o un stacker XGB *aprendido* superan al z-blend fijo GRU $\times$ Markov — y añadir la tercera rama content-kNN (R+M+C) sobre el espacio PCA *rico* finalmente supera al campeón? Una configuración fija corrió a través de todas las ramas; solo variaron la familia de modelos y la representación, y el servidor se serializó (`--max-runs 1`) para evitar una trampa de rendimiento por sobresuscripción de hilos.

Resultados. Una **nueva fila «mejor registrada»**: el **z-blend R+M+C sobre PCA-192** (GRU $\times$ Markov solo de entrenamiento $\times$ content-kNN, tercios iguales) alcanza $R@10$ 0,1859 [0,166, 0,207], MRR 0,1025, un Δ pareado sobre el campeón previo de +0,0133 [+0,0007, +0,0259] — enteramente por encima de cero, sin regresión de MRR (Tabla 4; Figura 3). La rama de contenido es genuinamente aditiva sobre el espacio rico, superando al R+M del mismo espacio en +0,0154 (PCA-128) / +0,0147 (PCA-192), ambos IC por encima de cero — *más fuerte* que el R+M+C de AE-64 que solo empató (Sección 7), porque el espacio más rico y de mayor EVR hace que la rama de contenido rinda. El **stacker XGB aprendido rinde muy por debajo** del z-blend fijo (0,080–0,087, perdiendo incluso ante su propia rama base GRU individual); la **LSTM es el mejor modelo individual** (PCA-128 0,1272, Δ pareado sobre la GRU +0,0126, IC por encima de cero) pero muy por debajo de los blends; y la base individual de la Fase 2 **se mantiene en PCA-128**.

La coronación, y sus dos salvedades honestas. El candidato a evento de tabla se confirmó re-

Cuadro 4: Barrido de familia de modelos de la Fase 2 sobre los espacios PCA ricos, ordenado por R@10 (mejor cuanto más alto). El z-blend fijo es el combinador de referencia; el stacker XGB aprendido rinde muy por debajo. Fila campeona y campeón previo en negrita; mejor celda por métrica en negrita. El Δ pareado es por sesión contra la referencia nombrada.

Modelo	Run id / fuente	R@10 [IC 95 %]	MRR	Δ pareado
R+M+C, PCA-192 (fila camp.)	analyze_rmc (A4)	0.1859 [0.166, 0.207]	0.1025	vs camp. +0,0133 [+0,001, +0,026]
R+M+C, PCA-128	analyze_rmc (A2)	0.1824 [0.162, 0.203]	0.0993	vs camp. +0,0098 (empate)
R+M, AE-64 (campeón previo)	run-20260714- 170928-645ae	0.1726 [0.154, 0.192]	0.0963	— (referencia)
R+M, PCA-192	run-20260715- 142440-96f53	0.1712 [0.151, 0.192]	0.0952	vs camp. -0,0014 (empate)
R+M, PCA-128	run-20260715- 044920-36dce	0.1670 [0.148, 0.187]	0.0920	vs camp. -0,0056 (empate)
LSTM single, PCA-128	run-20260715- 142440-546d0	0.1272 [0.110, 0.145]	0.0495	vs GRU-128 +0,0126 (> 0)
GRU single, PCA-192	run-20260715- 142440-89d6a	0.1230 [0.106, 0.140]	0.0534	vs GRU-128 +0,0084 (empa- te)
ANN pooled-MLP, PCA-128	run-20260715- 142440-7e528	0.0901 [0.076, 0.105]	0.0394	vs GRU-128 -0,0245
XGB stacker M+G, PCA-128	run-20260715- 142440-371b1	0.0867 [0.073, 0.101]	0.0493	vs GRU-128 -0,0280
XGB stacker M+G+A, PCA-192	run-20260715- 142440-f111d	0.0853 [0.071, 0.099]	0.0490	vs GRU-192 -0,0377

produciendo la rama GRU-192 cinco veces (la original más cuatro re-ejecuciones) y recalculando R+M+C cada vez; el Δ pareado sobre el campeón previo fue +0,0133 [+0,0007, +0,0259] en *cada* re-ejecución, con la ventaja de MRR intacta, así que R+M+C sobre PCA-192 se registró como la nueva fila campeona. Dos salvedades viajan con la coronación y no deben omitirse. Primera, **la dispersión de reproducción fue exactamente cero** porque el entrenamiento de `seq-nexttrack` es determinista en esta CPU — los cinco checkpoints GRU-192 fueron idénticos byte a byte — así que la confirmación verificó *determinismo, no robustez a la semilla*; la única incertidumbre cuantificada es el bootstrap de partición única. Segunda, **el límite inferior del Δ pareado es +0,0007**: la coronación supera cero por un pelo en una única partición. La coronación es real según el criterio pre-acordado, pero el margen sobre el campeón previo es delgado, y endurecerla requiere una segunda partición de prueba sin fugas (o ramas con semillas variadas una vez que el blend se generalice a tres ramas).

Interpretación. El hilo de compresión-más-familia-de-modelos queda por lo demás cerrado: PCA-128 es la base individual, la LSTM es el mejor modelo individual, el stacker aprendido está muerto como combinador, y el z-blend fijo es el combinador de referencia. El resultado de peso es que *el contenido es la única rama que añade señal de ranking genuinamente nueva, y rinde más sobre el espacio PCA de mayor EVR* — la excepción a la regla vigente de que las ganancias de modelo individual / representación no se trasladan al blend (el par R+M sobre los espacios PCA ricos solo empata al campeón AE-64). La brecha de productización persiste: el campeón es solo de entrenamiento y fuera del servidor, así que el campeón previo R+M sobre AE-64 sigue siendo el ancla desplegable hasta que el blend de tres ramas se registre con un subcomando `predict`.
Fuente: *2026-07-15c-nexttrack-phase2-model-sweep.md*.




Figura 3: El barrido de familia de modelos de la Fase 2. El z-blend fijo es el combinador de referencia: R+M+C sobre PCA-192 (verde) es la nueva fila campeona, la rama de contenido es genuinamente aditiva sobre el espacio rico, y el stacker XGB aprendido (rojo) rinde muy por debajo — pierde incluso ante su propia rama base GRU individual. LSTM roza a GRU como el mejor modelo individual (gris) pero queda muy por debajo de los blends. La barra de Markov de primer orden (0,107) es la referencia incumbente; la fila campeona está en 0,186.

11. La proyección de contenido aprendida: un nuevo campeón de la campaña de ajuste-a-la-literatura

Motivación. El campeón R+M+C (Sección 10) llevaba dos salvedades delgadas — una confirmación por reproducción solo-determinista y un límite inferior del paired- Δ de solo +0,0007 — y su margen estaba acotado por la tasa de ítems fríos de 0,55, que solo la señal *nueva* puede atacar. Guiada por un estudio de la literatura establecida de recomendación en sesión (la línea de session-kNN de Jannach–Ludewig, reglas secuenciales / Markov factorizado, trucos de entrenamiento de GRU4Rec, fusión de rankings y learning-to-rank, recomendación en sesión consciente de contenido / arranque en frío), esta campaña pre-registró tres niveles de métodos clásicos y preguntó cuáles mejoran realmente el ajuste a *este* problema — una tarea de *recuperación* de pista siguiente distinta, de un solo usuario, basada en sesión, con 55 % de objetivos fríos. Todas las ramas se midieron fuera del servidor sobre el artefacto campeón PCA-192 seq-20260715-131139, reutilizando el driver sancionado que reproduce al campeón (R+M+C 0,1859) exactamente; el estadístico de decisión es el Δ pareado por sesión contra ese campeón.

Resultados — la única victoria. Una **proyección de contenido aprendida** supervisada es una nueva fila «mejor registrada». Ajustar un mapa métrico lineal W del espacio de contenido PCA-192 hacia la adyacencia de pista siguiente (InfoNCE sobre pares consecutivos de entrenamiento, auto-bucles descartados) y luego recuperar *ambas* la rama de contenido (C') y la GRU (R') en ese espacio proyectado da **z-blend** $R'+M+C'R@10$ 0,2117 [0,191, 0,233], **MRR** 0,1220 — un Δ

pareado sobre el campeón de +0,0259 [+0,012, +0,041], enteramente por encima de cero (Tabla 5). A diferencia de la coronación R+M+C, es **robusta a la semilla** (tres semillas; Δ pareado +0,026 / +0,025 / +0,029, todos IC > 0 — una confirmación genuina con semillas variadas, ya que la proyección tiene init aleatorio y lotes barajados) y **alcanza ítems fríos**: la rama de contenido proyectada C' puntúa objetivos fríos 0,152 $\approx$ cálidos 0,151, frente a los cálidos 0,226 / fríos 0,010 de Markov, así que alcanza ítems nunca vistos tan bien como los vistos — generalización de contenido genuina, el único canal que alcanza la mayoría fría del 55 %. El mapa simétrico único supera al two-tower direccional, y rango-192 = rango-64 (la ganancia es la supervisión, no la capacidad). Como efecto secundario, la GRU individual proyectada R' ($\sim$ 0,176) casi iguala al blend campeón *antiguo* y aplasta al mejor individual previo (LSTM 0,127).

Cuadro 5: Nivel A1 de la campaña de ajuste-a-la-literatura: la proyección de contenido aprendida sobre PCA-192, frente al campeón R+M+C (1431 sesiones de prueba; IC bootstrap al 95 %; Δ pareado por sesión vs el campeón). Ganador ($R'+M+C'$) en negrita; mejor celda por métrica en negrita.

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	Δ pareado vs campeón
R+M+C campeón (tercios)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	— (referencia)
$R'+M+C'$ (ambas proyectadas)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	+0,0259 [+0,012, +0,041] > 0
R+M+C+ C' (4 ramas)	0.2061 [0.185, 0.227]	0.1148	0.345	0.410	+0,0203 [+0,013, +0,029] > 0
R+M+ C' (cambia $C \rightarrow C'$)	0.1971 [0.177, 0.218]	0.1107	0.334	0.400	+0,0112 [−0,000, +0,023] cand.
C' proj-contenido (sim, r192)	0.1516	0.0708	0.305	0.401	vs C no-sup. 0.0685: +0,083
C' two-tower dir. (r192)	0.1349	0.0552	0.291	0.393	gana simétrica

Las vías que se cerraron. Toda otra dirección de ajuste-a-la-literatura no logró superar al z-blend fijo, exactamente como el estudio predijo para un corpus de un solo usuario y con muchos fríos (Tabla 6). El suavizado principiado de Markov (descuento absoluto + un piso de continuación de Kneser–Ney) es una ganancia de estimador en solitario real pero minúscula (0,1069 $\rightarrow$ 0,1104) que se diluye en el blend (−0,0021, IC cruza 0 — la rama de contenido ya cubre la masa fría marginal que recupera). Un combinador consciente de ranking no tiene margen honesto: incluso los pesos *oráculo*, ajustados directamente sobre las etiquetas de prueba, alcanzan solo 0,1901 (+0,0042, cruza 0), y la fusión de ranking RRF *perjudica* el recall (−0,029, IC<0, descartando la magnitud de puntuación que el z-blend conserva). Un kNN de sesión V-SKNN con puerta es solo-cálido frente al 55 % de objetivos fríos y *arrastra* el blend (−0,038, IC<0) — el escenario de un solo usuario elimina el vecindario colaborativo entre usuarios que impulsa sus victorias de benchmark multiusuario. Y los negativos por importancia de GRU4Rec (un banco de negativos ponderado por soporte más grande) dan un tick en solitario dentro del ruido (+0,005) que también se diluye (−0,0014, empate). **La única ganancia aditiva viene de señal nueva, no de fusión más astuta.**

Cuadro 6: Las vías de ajuste-a-la-literatura que se cerraron: cada método prestado no logra superar al z-blend fijo campeón (1431 sesiones de prueba; Δ pareado del blend por sesión vs el campeón).

Vía	R@10 en solitario	Δ del blend vs campeón	Veredicto
Suavizado KN de Markov (Nivel A2)	0.1069 $\rightarrow$ 0.1104	−0,0021 (cruza 0)	nulo en el blend
Combinador de ranking, <i>oráculo</i> (B1)	0.1901 (blend)	+0,0042 (cruza 0)	sin margen honesto
Fusión de ranking RRF (B1)	0.1572 (blend)	−0,029 (IC<0)	perjudica recall
V-SKNN kNN de sesión (B2)	0.0671	−0,038 (IC<0)	arrastra (solo cálidos)
Negativos por importancia GRU (C)	0.1230 $\rightarrow$ 0.1279	−0,0014 (empate)	se diluye

Interpretación. La proyección de contenido supervisada es la primera señal nueva genuinamente aditiva desde la propia rama de contenido, y funciona por la razón que el estudio señaló: el contenido es el único canal con alcance a ítems fríos, y reemplazar la geometría PCA no supervisada y ordenada por varianza por una ajustada al objetivo eleva *ambas* ramas que la comparten. Los métodos prestados vistosos — session-kNN, combinadores aprendidos, trucos de pérdida del lado GRU — son callejones sin salida aquí porque o rebarajan las mismas tres ramas (sin margen sobre el z-blend, incluso para el oráculo) o importan una suposición colaborativa que el corpus de un solo usuario viola. El único eje secundario movable es la relevancia graduada: los reponderados oráculo / RRF y la proyección empujan artist@10 / genre@10, una palanca que el eje de recall exacto no comparte. *Fuente: 2026-07-18-nexttrack-literature-fit-campaign.md.*

12. Registro, el barrido de objetivo / rango / τ , y endurecimiento en segunda partición

Motivación. La victoria de la proyección aterrizó como driver fuera del servidor — la misma brecha de productización que tenía la coronación R+M+C. Este seguimiento implementó la proyección como capacidad de primera clase del predictor seq-blend (hiperparámetros `projection`, `projection_rank`, `projection_objective`, `projection_tau`, ...: ajusta el mapa métrico desde los pares consecutivos de entrenamiento, lo guarda como `projection.npz` en el directorio del run, y lo hornea en el modelo promovido para servicio), luego (1) reprodujo la victoria on-server y la registró + promovió, y (2) corrió un barrido de ablación pre-aprobado de objetivo / rango / τ para confirmar que el default es la config robusta a promover.

Registro. El run de verificación (run-20260718-191539-1b89c-seq-blend, default de la definición = InfoNCE / rango completo / τ 0,07) reprodujo el driver fuera del servidor a cuatro decimales — R@10 0,21174, MRR 0,12199 — y se promovió vía la API como `blend-gru-markov-content-proj`, con la matriz de proyección horneada en el directorio del modelo para servicio. GET /api/best-models lo confirma en **rango 1** (0,21174), por encima del campeón servible previo `blend-gru-markov-content` (rango 2, 0,18588). Con el contrato de servicio de ranking de la familia de secuencias este es un modelo genuinamente desplegable, servible vía POST /api/models/blend-gru-markov-content-proj/predict.

El barrido. La regla de decisión — re-promover solo una config que supere al default en *ambos* R@10 y MRR por más que la banda de ruido de $\sim \pm 0,015$ — confirma el default (Tabla 7). **InfoNCE** $\gg$ **BPR** es el eje más agudo: ambas celdas BPR (0,1579, 0,1523) caen $\sim 0,055$ bajo el default InfoNCE y aterrizan *por debajo incluso del viejo campeón R+M+C* (0,1859), así que el mapa BPR por pares produce una geometría materialmente peor para ambas ramas de latente compartido. **Rango completo** $\geq$ **rango-64** ($-0,006$, un empate — reconfirmando “la ganancia es la supervisión, no la capacidad”). Y τ es **levemente sensible y monótona hacia arriba** en el rango probado (0,05 $\rightarrow$ 0,1929, 0,07 $\rightarrow$ 0,2117, 0,10 $\rightarrow$ 0,2229) — pero la celda superior nominal τ -0,10 supera al default por solo +0,0112 en recall, *dentro* de la banda de ruido, así que es un empate y el default se **MANTUVO**. A diferencia del eje de reponderación de la Sección 11, aquí las métricas graduadas *siguen* al recall (mejor y peor juntas), porque el barrido mueve la *calidad de señal* en vez de refusionar ramas fijas.

12.1. Endurecimiento en segunda partición

Motivación. La coronación de la proyección se midió sobre una única partición sin fugas. Este pase solo-de-validación la re-corrió — más los dos blends de referencia — sobre una **segunda**

Cuadro 7: El barrido de ablación on-server de objetivo / rango / τ (6 celdas, ordenadas por recall@10). Todas superponen la definición promovida; hit@10 = recall@10 por construcción. Campeón promovido (default, mantenido) en negrita; mejor celda por métrica en negrita (todas de la celda sub-ruido τ -0,10).

Config	recall@10	MRR	art@10	gen@10	run id
S2 infonce / full / τ 0,10	0.2229	0.1273	0.3424	0.4032	run-20260718-193111-a781c
infonce / full / τ 0,07 (promovido, mantenido)	0.2117	0.1220	0.3326	0.4011	run-20260718-191539-1b89c
S3 infonce / rank 64 / τ 0,07	0.2055	0.1169	0.3326	0.3990	run-20260718-193650-66c96
S1 infonce / full / τ 0,05	0.1929	0.1111	0.3354	0.3997	run-20260718-192443-57432
S4 bpr / full / τ 0,07	0.1579	0.0939	0.3187	0.3913	run-20260718-194228-4cc06
S5 bpr / rank 64 / τ 0,07	0.1523	0.0909	0.3194	0.3906	run-20260718-194832-d070f

partición disjunta y sin fugas para zanjar si la victoria es específica de la partición. Nada se promueve ni re-promueve. La partición seq-20260718-211238 es una banda cronológica de *holdout-temprano* 60–80 % sobre el mismo espacio PCA-192 (train 4.292 [60 % más temprano] / test 1.431 [banda 60–80 %]); el espacio de ítems es idéntico byte a byte al de la partición campeona, y la ventana de prueba es **disjunta en índice y tiempo** respecto al test 80–100 % de la partición campeona. Su **tasa de ítems fríos** es 0,64 (frente a 0,55), un test de estrés de alcance a fríos más fuerte e independiente — así que el R@10 absoluto aterriza *por debajo* del 0,212 de la primera partición por construcción, y el veredicto es el Δ pareado por sesión sobre *esta* partición, no la reproducción absoluta.

Cuadro 8: Endurecimiento en segunda partición sobre la partición disjunta de holdout-temprano con 0.64 de fríos seq-20260718-211238 (1431 sesiones de prueba; solo-validación, nada promovido). Métricas puntuales (arriba) y el Δ pareado por sesión (abajo, bootstrap de 2000 remuestreos, semilla 1337). Campeón de proyección en negrita.

Config	recall@10	MRR	art@10	gen@10	run id
R'+M+C'campeón de proyección	0.1705	0.1050	0.2991	0.3417	run-20260718-212639-50e1d
Coronación R+M+C (referencia primaria)	0.1279	0.0816	0.2956	0.3410	run-20260718-213156-cf1dd
R+M 2 ramas (referencia de contexto)	0.1174	0.0791	0.2844	0.3368	run-20260718-214114-93bad
Δ pareado recall@10 (proyección – referencia):					
PROY vs R+M+C (primaria)	+0,0426	[+0,0280, +0,0573]	— enteramente > 0; MRR +0,0234 (sin regresión)		
PROY vs R+M (contexto)	+0,0531	[+0,0391, +0,0678]	— enteramente > 0		

Veredicto — coronación endurecida. La regla de decisión (Δ pareado vs R+M+C con IC 95 % enteramente > 0 y MRR sin regresión) se cumple: Δ pareado +0,0426 [+0,0280, +0,0573], MRR +0,0234 (sin regresión). La ventaja de la proyección no es específica de la partición — de hecho el margen es *más ancho* aquí (+0,0426) que en la primera partición (+0,0259), consistente con el mecanismo de alcance a fríos (Figura 4). Combinado con la robustez a la semilla de tres semillas y la




Figura 4: La ventaja de la proyección *se ensancha* en la partición más fría. Sobre la partición canónica con 0.55 de fríos el campeón de proyección supera a la coronación R+M+C por Δ pareado +0,0259; sobre una partición disjunta y más fría de holdout-temprano con 0.64 de fríos el margen *crece* a +0,0426 (ambos IC enteramente > 0). El R@10 absoluto es menor en la partición más fría por construcción (más objetivos son fríos); el veredicto es el Δ pareado, inequívoco en ambas. El mecanismo: en una partición más fría las ramas Markov / content-kNN de la coronación alcanzan menos objetivos, y la rama de contenido C' de la proyección, que alcanza fríos, carga proporcionalmente más de la victoria.

descomposición de alcance a fríos previas, la coronación está ahora endurecida en dos particiones disjuntas sin fugas — resolviendo ambas salvedades que viajaban con la coronación R+M+C. *Fuente: 2026-07-18b-nexttrack-projection-registration-and-scan.md.*

13. Representación del vector de ítem: ¿es la geometría el cuello de botella?

Motivación. El eje de compresión (Secciones 8–9) halló que la *dimensión* latente domina pero nunca preguntó si la *composición* del vector de ítem de 192-d — el PCA de 4 bloques de peso igual (texto / numérico / acústico / categórico) — es en sí misma un lastre. Un preflight de ratio de varianza explicada (EVR) dijo que podría serlo: el presupuesto de varianza de entrada crudo es 44 % acústico + 43 % numérico frente a solo 2.5 % texto (el texto está L2-normalizado, así que su escala por dimensión es minúscula), así que el PCA-192 de matriz completa gasta **87 % de su presupuesto de varianza** reconstruyendo los bloques numérico + acústico a $R^2 = 1,000$ mientras que el bloque de texto portador de señal alcanza solo $R^2 = 0,717$; la estandarización por columna (whitening) voltea el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905) (Figura 5). Se construyeron ocho espacios de latentes de ítems alternativos (whitening $\times$ drop-acústico, solo-texto, texto+categórico, y la geometría métrica de distancia musical) con puerta de paridad respecto a la partición campeona (vocab / partición idénticos byte a byte; solo difiere `item_latents.f32`) y cada uno se evaluó bajo *dos* readouts: (**A**) la proyección campeona

`blend-gru-markov-content-proj` (el mapa InfoNCE se reajusta sobre ese espacio — el techo del espacio bajo la receta ganadora) y (C) la GRU individual congelada `gru-infonce-h256` (calidad de representación cruda). Solo-validación; nada promovido.




Figura 5: Por qué el vector de ítem es un lastre para un modelo crudo — y por qué la proyección es el arreglo. El PCA-192 de peso igual ordena las dimensiones por varianza cruda, así que 87 % de su presupuesto capturado reconstruye los bloques numérico + acústico conductualmente inertes (popularidad / era / volumen) mientras que el bloque de texto portador de señal (2.5 % de la varianza de entrada cruda, L2-normalizado) queda infra-preservado (R^2 0,717). La estandarización por columna volteja el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905). La proyección InfoNCE aprendida aprende esta misma reponderación de los datos.

Veredicto — recall exacto. **Readout A: ninguna variante supera al campeón PCA-192 con IC del Δ pareado enteramente > 0 .** Los dos espacios nominalmente positivos (V3 std-noaco +0,0049, V5 balanced-pca192 +0,0042) cruzan cero; dos espacios son significativamente *peores* (V4 textcat -0,0168, dejar caer numérico+acústico le cuesta señal real a la proyección; V6 sonic-64 -0,0182, el lastre esperado de 64-d). **Readout C: seis de ocho variantes superan a la GRU congelada con IC del Δ pareado enteramente > 0** (+0,025 a +0,036; mejor V5 balanced +0,0356, V3 std-noaco +0,0342). Así que la geometría PCA-192 de matriz completa cruda *es* un lastre — suprimir las direcciones acústicas / numéricas ruidosas eleva la GRU cruda en ~ 20 – 29 % relativo — **pero la ganancia es absorbida por completo por la proyección**: el whitening eleva el readout C, no el readout A, porque el mapa InfoNCE aprendido ya reponderó fuera esas direcciones de los datos. El whitening y la proyección aprendida son el *mismo arreglo*, y el campeón ya lo accionó (Figura 6).

Graduadas y music@10. Las palancas de representación mueven el eje *graduado* más limpiamente que el recall exacto: el whitening eleva el genre@10 de la GRU congelada a $\sim 0,47$ (V7 std-txtcatup 0,4717, V3 std-noaco 0,4710 vs línea base 0,4500), y bajo la proyección un espacio solo-texto (V10) publica los máximos de readout A en artist@10 (0,3466) y genre@10 (0,4144) mientras cede -0,0119 de recall exacto. La métrica continua **music@10** (Sección 14) *corrobor*a el veredicto de recall exacto en vez de revertirlo: el campeón de proyección la lidera (0,4538) sobre la coronación R+M+C (0,4491), y bajo la proyección campeona es plana a través de las ocho

Cuadro 9: Exploración de representación del vector de ítem: ocho espacios de ítems de 192-d alternativos vs el campeón PCA-192, bajo readout A (proyección campeona) y readout C (GRU congelada). Δ pareado sobre hit@10 exacto (bootstrap de 2000 remuestreos, rng 1337) vs la línea base del mismo readout; una mejora necesita el IC enteramente > 0 . Filas de línea base y la mejor mejora de readout C (V5) en negrita.

Variante (espacio)	dataset id	Readout A (proyección)		Readout C (GRU congelada)	
		R@10	Δ hit@10 [IC]	R@10	Δ hit@10 [IC]
full — PCA-192 (línea base)	seq-20260715-131139	0.2117	(línea base)	0.1230	(línea base)
V1 noaco	seq-20260718-222742	0.2089	-0,0028 [-0,013, +0,008]	0.1481	+0,0252 [+0,009, +0,041]
V2 std (whiten todo)	seq-20260718-222754	0.2082	-0,0035 [-0,015, +0,008]	0.1530	+0,0300 [+0,011, +0,049]
V3 std-noaco	seq-20260718-222807	0.2166	+0,0049 [-0,008, +0,017]	0.1572	+0,0342 [+0,015, +0,055]
V4 textcat	seq-20260718-222820	0.1950	-0,0168 [-0,029, -0,006]	0.1565	+0,0335 [+0,015, +0,051]
V5 balanced-pca192	seq-20260718-222834	0.2159	+0,0042 [-0,006, +0,015]	0.1586	+0,0356 [+0,019, +0,052]
V7 std-txtcatup	seq-20260718-222848	0.2055	-0,0063 [-0,019, +0,006]	0.1488	+0,0259 [+0,006, +0,046]
V10 text-only	seq-20260718-222901	0.1999	-0,0119 [-0,025, +0,001]	0.1377	+0,0147 [-0,005, +0,034]
V6 sonic-64 (64-d)	seq-20260718-222905	0.1936	-0,0182 [-0,031, -0,005]	0.1216	-0,0014 [-0,017, +0,013]

representaciones ($\sim 0,447$ – $0,460$). Re-basar la geometría mueve el emparejamiento de banda / ambiente, pero la adyacencia exacta de pista siguiente en el techo del campeón es inamovible — que es precisamente el eje que la proyección supervisada posee.

Interpretación. El vector de ítem PCA-192 de peso igual es un lastre genuino para un modelo *crudo*, y la proyección aprendida es exactamente la respuesta correcta a él — esta campaña valida de forma independiente *por qué* la proyección es el campeón (es el arreglo de representación, aprendido) y confirma que no queda almuerzo gratis en re-basar la geometría de entrada. La única precaución: dejar caer numérico+acústico *por completo* (V4 textcat) perjudica al campeón aunque ayude a la GRU cruda, así que el bloque numérico porta algo que la proyección usa — conservar numérico, hacer whitening / dejar caer solo acústico. La dirección abierta más prometedora es componer los dos arreglos: ajustar la proyección *sobre* un espacio whitened / std-noaco / métrico para ver si alcanza más lejos o es redundante. *Fuente: 2026-07-18c-nexttrack-representation-exploration.md.*

14. La métrica music@10: el campeón de recall no es el más cercano musicalmente

Motivación. El recall@10 exacto es implacable sobre un corpus de un solo usuario con 55 % de fríos, y los diagnósticos artist@10 / genre@10 son aciertos de categoría toscos. Esta campaña introduce una métrica graduada *continua* de tipo “suena parecido”, **music@10**, y la back-fillea a través de cada run de pista siguiente. Se define como la media sobre casos de prueba del mejor coseno (máximo), en un espacio intrínseco *balanceado* de distancia musical (spotify_tracks_content_metric: una fusión con pesos por bloque, parcialmente whitened, del latente song-AE de 64-d whitened, el embedding de texto de nombre/tag de 384-d, cinco numéricos de metadatos, y un prototipo AE por género), entre la siguiente pista verdadera y los diez candidatos recuperados. Un top-diez que contiene la verdad exacta puntúa 1,0, así que music@10 es un *superconjunto suave* de recall@10 — acredita aterrizar algo que *suena como* la verdad incluso en un fallo exacto / de artista / de género. Es solo de visualización; la métrica principal sigue siendo recall@10.

Resultados. music@10 se recalculó offline y de forma no destructiva a través de los 53 runs de pista siguiente (desde el predictions.json almacenado de cada run y su items.json de dataset, sobre la partición compartida de 1431 casos). **Correlaciona** con recall@10 ($r = 0,609$) — un mejor




Figura 6: El lastre de representación es real para la GRU *cruda* pero *absorbido* por la proyección campeona. Seis de ocho espacios de whitening / drop-acústico / métricos elevan la GRU congelada (readout C, verde; los seis con IC del paired- Δ enteramente > 0 , +0,025 a +0,036), pero ninguno eleva la proyección campeona (readout A, azul; los dos espacios nominalmente positivos cruzan 0, y V4/V6 regresan significativamente). El mapa InfoNCE aprendido ya reponderó fuera las direcciones acústicas / numéricas ruidosas, así que hacer whitening a la entrada primero es redundante en el techo del campeón: el whitening y la proyección son el mismo arreglo.

ranker también aterriza fallos más cercanos — pero está lejos de ser redundante, y corona a un ganador *distinto* (Tabla 10; Figura 7). El campeón de recall@10 es un run **seq-blend** (0,223), pero las predicciones *más cercanas musicalmente* vienen de **seq-nexttrack** — que regresa directamente el latente de contenido de la siguiente pista y recupera por coseno — con mejor music@10 0,482 y la media de familia más alta (0,448). Cuando un modelo de pista siguiente falla la pista exacta, aún tiende a hacer aflorar algo que *suen*a bien; el piso **seq-popularity** es correctamente el peor (music@10 0,185), confirmando que la métrica no está trivialmente saturada.

Cuadro 10: music@10 por familia de predictor, del backfill offline sobre los 53 runs de pista siguiente (una partición compartida de 1431 casos). El campeón de recall@10 (**seq-blend**) *no* es el campeón de music@10 (**seq-nexttrack**). Mejor celda por columna en negrita.

Familia de predictor	runs	mejor recall@10	mejor music@10	music@10 medio
seq-blend	23	0.223	0.461	0.441
seq-nexttrack	24	0.159	0.482	0.448
seq-markov	1	0.107	0.407	0.407
seq-ann	1	0.090	0.426	0.426
seq-stacker	3	0.087	0.418	0.411
seq-popularity	1	0.001	0.185	0.185

Interpretación. music@10 es una vista genuinamente distinta y no saturada de la calidad de pista siguiente: premia la proximidad *sónica*, que la métrica de acierto exacto ignora. El desacople




Figura 7: music@10 frente a recall@10 a través de los 53 runs de pista siguiente, un punto por run, coloreado por familia de predictor. Los dos ejes correlacionan ($r = 0,609$: un mejor ranker también aterriza fallos más cercanos) pero coronan ganadores distintos — el campeón de recall@10 (un run **seq-blend** en 0,223) no es el más cercano musicalmente, que es un run **seq-nexttrack** (music@10 0,482) que regresa el latente de contenido y recupera por coseno. El piso **seq-popularity** es correctamente el peor en ambos. music@10 es solo de visualización; recall@10 sigue siendo la métrica principal.

recall-versus-music tiene un mecanismo limpio — un modelo que regresa el latente de contenido (**seq-nexttrack**) aterriza *cerca* de la verdad en el espacio de contenido incluso cuando falla la pista exacta, así que sus fallos “suenan bien” más a menudo que los del blend, que optimiza el rango exacto. Por eso la métrica es solo de visualización y no debe volverse silenciosamente un objetivo de selección: la promoción aún ordena por recall@10. La métrica hereda una circularidad leve del dial *balanced* (el bloque de texto embebe el nombre del artista; el bloque de género es un prototipo de género), así que premia parcialmente la proximidad de mismo-artista / género — pensada para “suena / se siente parecido”, no una verdad perceptual de referencia. Un endpoint compañero GET `/api/pathfinder/similar` sirve “canciones como esta” sobre el mismo índice. Fuente: 2026-07-20-musical-distance-metric.md.

15. Métricas de holisticidad de sesión y las palancas anti-eager (MMR λ / eager β)

Motivación. Una queja cualitativa recurrente sobre los mejores blends es que sus predicciones se sienten “demasiado album-eager / de tipo bigrama” — repiten como loro el artista actual en lugar de curar una continuación holística. Esta campaña cuantifica ese síntoma con una nueva suite *solo de visualización* de métricas de *holisticidad de sesión*, pone a prueba la hipótesis del usuario de que *la GRU supera a la LSTM porque es más eager* (más ansiosa por repetir el artista actual), y mide si dos nuevas palancas de la Fase 2 reducen esa eagerness a un costo de recall aceptable:

un re-ranqueo MMR en evaluación (`mmr_lambda`) y un regularizador anti-eager de entrenamiento (`eager_beta`). Es un pase de medición / exploratorio: no se promueve nada, la métrica principal sigue siendo Recall@10 y la decisión sobre el objetivo de holisticidad se difiere explícitamente al usuario. Cada rama corre sobre la partición *canónica* PCA-192 del campeón `seq-20260715-131139` (1431 sesiones de test; tasa de ítems fríos 0,55), y el campeón reprodujo exactamente su Recall@10 de registro 0,2117 (0,21174).

Las nuevas métricas de holisticidad solo de visualización. Cableadas de extremo a extremo junto a `music@10` (`seq_common.eval_from_scores` $\rightarrow$ Rust $\rightarrow$ `domain.toml` $\rightarrow$ UI); la métrica principal no cambia.

artist_adj@10 ($\downarrow$). Fracción del top-10 que comparte el artista de la pista *semilla* — la tasa de “repite como loro el artista actual”. **Menor es mejor.**

album_adj@10. Lo mismo sobre (artista, álbum); **omitida en este dataset** porque su `items.json` no lleva el campo de álbum (esperado, no un error — cubierto por un dataset separado que sí lleva álbum).

mood_coh@10 ($\uparrow$). Coseno medio del top-10 al centroide de mood del prefijo en el espacio content-metric; mayor es más coherente en mood.

ild@10 ($\uparrow$). Diversidad intra-lista (distancia sónica media por pares) del top-10; mayor es menos duplicativo.

suffix_recall@10 / cont_prec@10. Cobertura de continuación multi-paso, producida solo por el arnés bajo demanda `seq_continuation_eval.py` (Fase E, abajo), no por los runs normales.

La puerta de sanidad pasó: `music@10` / `mood_coh@10` / `ild@10` se pueblan en todos los runs de blend y GRU, de modo que los vectores content-metric cargaron y las palancas MMR / mood / ild están vivas, no son no-ops. Ambas palancas nuevas están APAGADAS por defecto y verificadas byte-idénticas al estar apagadas.

Resultados — la huella de holisticidad (Fase A). La Tabla 11 toma la huella de la familia de modelos. **La eagerness sigue a Recall@10 dentro de la familia de blends** — el campeón (Recall@10 0,2117) es el modelo *más* artist-eager medido (`artist_adj@10` 0,610), con R+M a continuación (0,579) — pero la eagerness vive en la pata de *Markov*, no en la RNN: la barra de Markov de primer orden por sí sola ya está en 0,543, mientras que la GRU / LSTM individuales quedan mucho más abajo, en `artist_adj@10` $\approx$ 0,345. Así que los blends compran su ventaja en Recall@10 siendo artist-adyacentes (de tipo bigrama), que es exactamente lo que la suite de holisticidad señala. Las RNN individuales son, en cambio, los modelos *coherentes en mood y de baja eagerness* (el mayor `mood_coh@10`, el menor `artist_adj@10` entre modelos reales). Crucialmente, las métricas *no se juegan trivialmente*: el suelo de popularidad maximiza `ild@10` (0,898) y minimiza `artist_adj@10` (0,003) pero puntúa $\approx$ 0 recall y `mood_coh@10` *negativo* — se maximizan siendo aleatorio, así que los modelos de baja eagerness / alta diversidad con sentido son las RNN individuales reales.

GRU frente a LSTM (Fase B) — la hipótesis no se sostiene. Con los hiperparámetros igualados (h256, InfoNCE, 40 épocas, lr 1×10^{-3}), la GRU y la LSTM quedan estadísticamente *empatadas*: Recall@10 0,1230 frente a 0,1188 ($\Delta +0,0042$, dentro de la banda $\pm 0,015$), y `artist_adj@10` 0,347 frente a 0,344 (un +0,003 despreciable). La GRU no es mediblemente más eager que la LSTM en

Cuadro 11: Huella de holisticidad de la Fase A a través de la familia de modelos, ordenada por Recall@10 (1431 sesiones de test). Todos los runs comparten el prefijo `run-20260722-165345-`; la columna `id` lista el sufijo distintivo. Recall@10 (aciertos crudos de 1431), MRR, `artist@10`, `genre@10`, `music@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Fila del campeón y mejor celda por métrica en negrita. [†] Los valores extremos de `artist_adj@10` / `ild@10` del suelo de popularidad son *degenerados* (ignora la semilla): aterrizas ≈ 0 recall y `mood_coh@10` negativo, probando que las métricas no se juegan bajo/alto por un buen modelo.

Config	id	R@10 (crudo)	MRR	art@10	gen@10	mus@10	artadj@10↓	mood@10↑	ild@10↑
A1 campeón $R'+M+C'$	82a8f	0.2117 (303)	0.122	0.333	0.401	0.454	0.610	0.398	0.406
A2 R+M (blend)	28dbb	0.1712 (245)	0.095	0.329	0.398	0.443	0.579	0.399	0.403
A3 GRU sola ($\beta=0$)	e39c9	0.1230 (176)	0.053	0.338	0.450	0.456	0.347	0.479	0.454
B LSTM (resto igual a A3)	bb387	0.1188 (170)	0.049	0.328	0.455	0.449	0.344	0.458	0.463
A4 markov (primer orden)	047cc	0.1069 (153)	0.069	0.298	0.389	0.407	0.543	0.310	0.462
A5 popularidad	34614	0.0007 (1)	0.001	0.014	0.085	0.185	0.003[†]	−0,041	0.898[†]

esta partición, así que la hipótesis “la GRU gana porque repite el artista actual con más fuerza” queda **refutada aquí**.

La palanca MMR λ (Fase C) — la palanca fuerte. MMR es un re-ranqueo puramente en evaluación, así que los cuatro runs de entrenamiento por- λ lanzados originalmente fueron *cancelados* (no experimentos fallidos); el barrido se computó offline desde el único checkpoint del campeón (la celda $\lambda=\text{off}$ reprodujo exactamente el Recall@10 0,2117 del campeón). A medida que λ cae de off hacia 0,3 (Tabla 12; Figura 8), Recall@10 baja — lo *único* que se sacrifica — mientras `ild@10` sube y `artist_adj@10` baja (des-eagering). $\lambda=0,9$ es **esencialmente gratis**: el Δ de recall es $-0,0014$, bien dentro de la banda $\pm 0,015$ (un empate), pero ya eleva `ild@10` $0,406 \rightarrow 0,436$ y recorta la eagerness $0,610 \rightarrow 0,603$. $\lambda \approx 0,7$ sacrifica ~ 2 puntos de recall ($\Delta -0,0181$, justo fuera de la banda) por una gran ganancia de `ild@10` ($0,406 \rightarrow 0,520$) y una caída real de eagerness ($0,610 \rightarrow 0,571$). Un efecto colateral notable: **`music@10` sube monótonamente** a medida que se diversifica ($0,454 \rightarrow 0,492$) — cercanía sónica y diversidad de lista no están en tensión; solo se sacrifica el recall exacto.

Cuadro 12: Barrido MMR λ de la Fase C sobre el campeón, computado offline desde su checkpoint (`mmr_pool` 200; 1431 sesiones de test). Recall@10 (aciertos crudos), MRR, `artist@10`, `music@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Mejor celda por métrica en negrita; recall / MRR del default del campeón ($\lambda=\text{off}$) en negrita.

λ	R@10 (crudo)	Δ vs off	MRR	art@10	mus@10	artadj↓	mood↑	ild↑
off (1.0)	0.2117 (303)	—	0.122	0.333	0.454	0.610	0.398	0.406
0.9	0.2103 (301)	−0,0014 (EMPATE)	0.121	0.341	0.462	0.603	0.391	0.436
0.7	0.1936 (277)	−0,0181	0.116	0.347	0.476	0.571	0.364	0.520
0.5	0.1642 (235)	−0,0475	0.108	0.359	0.487	0.486	0.315	0.653
0.3	0.1097 (157)	−0,1020	0.100	0.358	0.492	0.293	0.238	0.815

El regularizador anti-eager β (Fase D) — la palanca débil. Una penalización de entrenamiento sobre la predicción casi-copia del latente de la pista actual (`eager_margin` 0,0) apenas mueve la aguja (Tabla 13): a lo largo de β 0 a 0,2, `artist_adj@10` solo se desplaza $0,347 \rightarrow 0,340$ ($\Delta -0,0074$) e `ild@10` solo $0,454 \rightarrow 0,458$, con Recall@10 plano (las cuatro dentro de $\pm 0,015$). La GRU individual ya es de baja eagerness (0,347), así que queda poco comportamiento de copia para penalizar — β no es una palanca de holisticidad útil en estos ajustes.

Continuación multi-paso (Fase E). El arnés bajo demanda (`seq_continuation_eval.py -m 3 -k 10`, 1172 casos de continuación) muestra que la GRU *supera* al bigrama de Markov en ambas




Figura 8: El trade-off de MMR λ sobre el campeón de pista siguiente. A medida que λ cae de off hacia 0,3, Recall@10 (rojo, eje izquierdo) baja — lo único que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (eje derecho; más diverso, menos artist-eager) y music@10 incluso *sube*. $\lambda=0,9$ queda dentro de la banda de empate de recall $\pm 0,015$ pero ya eleva ild@10 en 0,030; $\lambda \approx 0,7$ compra una gran ganancia de ild@10 y des-eagring real por ~ 2 puntos de recall. MMR es la palanca de holisticidad fuerte; β (Tabla 13) es débil.

métricas multi-paso (Tabla 14): la ventaja de la RNN *se ensancha* más allá de la pista siguiente inmediata, porque la co-ocurrencia de un solo paso del bigrama no se compone en buenas continuaciones de 3 pasos, mientras que el estado de secuencia aprendido de la GRU sí — la imagen especular del tablero de un solo paso, donde el blend con bigrama gana el Recall@10 crudo.

Interpretación y la decisión diferida. La campaña entrega un relato mecanístico limpio del síntoma de eagerness: proviene de la pata de bigrama de Markov (que repite como loro el artista actual vía co-ocurrencia cruda), no de la pata neural, así que cualquier des-eagring futuro debería apuntar al bigrama / la fusión, no a la RNN. De las dos nuevas palancas, el re-ranqueo MMR en evaluación es la palanca *fuerte* y el regularizador β de entrenamiento es *débil*. No se promueve nada — la métrica principal sigue siendo Recall@10 y el campeón no cambia — pero $\lambda \approx 0,9$ **queda señalado como una mejora de holisticidad casi gratis para una futura decisión de promoción del usuario** (Recall@10 empate dentro del ruido, ild@10 0,406 $\rightarrow$ 0,436, eagerness 0,610 $\rightarrow$ 0,603), con $\lambda \approx 0,7$ como el punto de operación de “des-eagring significativo por ~ 2 puntos de recall”; adoptar cualquiera de los dos requiere una decisión del usuario más una confirmación de 3 semillas / run nativo. El regularizador β no se recomienda como palanca en estos ajustes. *Fuente: 2026-07-22-session-holistichness-and-antieager-levers.md.*

16. Fusión de torre doble refutada: el cuarto nulo de combinador

Motivación. Para el 2026-07-25 el registro ya tenía tres nulos independientes de *combinador aprendido*: el stacker XGB (0,080 a 0,087, *por debajo* de su propia rama GRU base; Sección 10), la fusión de rangos recíprocos ($-0,029$) e incluso pesos de blend ajustados en test de forma *oracular*

Cuadro 13: Barrido del regularizador anti-eager β de la Fase D sobre la GRU individual (eager_margin 0,0; 1431 sesiones de test). Recall@10, artist@10, mood_coh@10, ild@10 mejor-mayor; **artist_adj@10 mejor-menor**. Mejor celda por métrica en negrita.

run id	β	R@10 (crudo)	MRR	art@10	artadj↓	mood↑	ild↑
run-20260722-165345-e39c9	0.0	0.1230 (176)	0.053	0.338	0.347	0.479	0.454
run-20260722-165345-353b5	0.05	0.1237 (177)	0.053	0.337	0.346	0.478	0.455
run-20260723-002044-af11a	0.1	0.1202 (172)	0.053	0.335	0.344	0.477	0.456
run-20260723-002044-17cf8	0.2	0.1202 (172)	0.051	0.336	0.340	0.475	0.458

Cuadro 14: Continuación multi-paso de la Fase E (arnés -m 3 -k 10, 1172 casos) sobre seq-20260715-131139: la GRU (checkpoint A3) supera al bigrama de Markov de primer orden en ambas métricas (mejor-mayor). Ganador en negrita.

Modelo	suffix_recall@10	cont_prec@10
markov (bigrama de primer orden)	0.0869	0.0236
GRU (gru-infonce-h256, A3)	0.0963	0.0273

(+0,004, con el IC cruzando cero; Sección 11). Los tres eran combinadores **post-hoc, a nivel de puntuación**, lo que dejaba en pie una objeción obvia: *por supuesto* que falla un combinador atornillado encima — hay que entrenar la fusión de extremo a extremo para que las partes se co-adapten. Esta campaña ejecuta exactamente esa objeción, a nivel de *representación*, de forma conjunta y desde cero.

El vehículo es un predictor nuevo, **seq-dualgru**: dos torres recurrentes *independientes* (pesos separados) leen el prefijo en paralelo sobre *vistas causales* configurables, sus estados ocultos por paso se concatenan y una cabeza MLP los fusiona en el latente predicho de la siguiente pista. Se exponen tres vistas, todas estrictamente causales en el paso t : **latent** (el vector de ítem crudo), **delta** (la diferencia entre pasos, con $x_{-1} = 0$) y **cummean** (el centroide acumulado de la sesión — la cantidad a partir de la cual se construyó la rama MLP agrupada **seq-ann**). Es crucial que reutiliza **seq_nexttrack.make_batches** y **step_loss** literalmente, de modo que objetivo, batching, parada temprana y evaluación son byte a byte los de la familia, y no incorpora modo bidireccional (una pasada hacia atrás filtraría el objetivo de *teacher forcing*).

La hipótesis era nítida: dos torres deberían superar a una *solo si ven información genuinamente distinta*; dos torres sobre la misma vista **latent** deberían reducirse a un efecto de capacidad o de ensamblado implícito que una GRU única más ancha compra más barato. El diseño cruza por tanto el *triángulo superior completo* de la matriz de vistas $\{\text{latent}, \text{delta}, \text{cummean}\}^2$ (seis celdas con **fusion_layers** = 1) con un eje de *profundidad de fusión* (dos celdas con **fusion_layers** = 0, una lectura puramente lineal de los estados concatenados) y — el eje que le faltaba al escaneo de topología previo (Sección 5) — un **control de capacidad de GRU única emparejado en parámetros**. Los recuentos de parámetros se re-midieron instanciando las clases reales con **latent_dim** = 192: el control C1 (h425, 871 017 parámetros) coincide con las seis ramas duales de **fusion_layers** = 1 (871 872) al 0,098 %, y es un 10 % *mayor* que las ramas de **fusion_layers** = 0 (789 696) — deliberadamente generoso con la torre única.

La barra honesta. Se pre-registraron dos tableros por *separado*, para que el veredicto científico y el evento de tablero no pudieran intercambiarse a posteriori. En **Recall@10** la barra para un modelo único autónomo es el tablero de modelo único 0,123, *no* el blend campeón de tres ramas

0,212 — comparar un modelo entrenado contra una fusión de tres ramas sería un error de categoría, y usar la torre doble como rama R' exige un cambio de código en `seq-blend`, explícitamente fuera de alcance. En **holisticness@10** la regla de corona lleva un piso de recall anti-degenerado (véase más abajo). Las diez ejecuciones corren sobre la partición canónica `seq-20260715-131139` con semilla 1337, ejecutadas de una en una en un único worker remoto, y la línea base C0 reprodujo su Recall@10 de registro 0,12299 (176 de 1431) *exactamente*.

Resultados. La Tabla 15 es el lote. **Ninguna rama va en negrita como ganadora porque no hay ganadora:** la línea base de GRU única mantiene el mejor Recall@10 del lote, y ni una de las ocho ramas duales la supera con el IC del Δ pareado enteramente por encima de cero — seis pierden sin ambigüedad y dos (el par con `fusion_layers = 0`) empatan. La regla de refutación pre-registrada se activó.

Cuadro 15: Escaneo de emparejamiento de vistas $\times$ profundidad de fusión en torre doble, diez ejecuciones sobre `seq-20260715-131139` (1431 sesiones de prueba), ordenadas por Recall@10. Todas las ramas comparten el prefijo de run-id `run-20260725-143502-`; C0 es `run-20260725-143143-97c1e`. El Δ pareado es un bootstrap pareado por sesión contra C0 (2000 remuestreos, rng 1337). Recall@10 en crudo = aciertos de 1431; los límites del IC se dan con tres decimales, y un IC que cruza cero es un *empate*. Los códigos de rama llevan el par de vistas (`lat`=`latent`, `del`=`delta`, `cum`=`cummean`) y la profundidad de fusión (`-f0` = lectura lineal; en otro caso, una cabeza MLP de 256). `R@10`, `MRR`, `mus@10`, `ild@10` mejor cuanto más alto; **artadj@10 mejor cuanto más bajo**; H es la generación *de 3 factores* de holisticidad (Sección 18). Mejor celda por métrica en negrita. [†] El `artadj@10` / H extremos de D-CC *no* son una corona real: se compran con 95 de 1431 aciertos, 0,0566 por debajo de la línea base, incumpliendo el piso de recall de $\pm 0,015$ por $3,8\times$.

Rama	id	params	R@10 (crudo)	Δ vs C0 [IC 95 %]	MRR	mus@10	artadj↓	ild↑	H↑
C0 h256 <i>base</i>	97c1e	394 944	0.12299 (176)	—	0.05341	0.4558	0.3474	0.4536	0.14172
C1 h425 <i>ctrl</i>	be11b	871 017	0.12089 (173)	−0,0021 [−,011, +,006]	0.05215	0.4597	0.3640	0.4506	0.13850
D-LL-f0 <i>lat/lat</i>	18b4a	789 696	0.11880 (170)	−0,0042 [−,013, +,004]	0.05631	0.4553	0.3630	0.4506	0.13774
D-LC-f0 <i>lat/cum</i>	3e5d4	789 696	0.11740 (168)	−0,0056 [−,017, +,005]	0.05087	0.4458	0.3557	0.4630	0.13648
D-LL <i>lat/lat</i>	12fe6	871 872	0.10273 (147)	−0,0203 [−,035, −,007]	0.04235	0.4446	0.3092	0.4873	0.14635
D-LC <i>lat/cum</i>	a95c5	871 872	0.09713 (139)	−0,0259 [−,039, −,013]	0.03901	0.4380	0.2997	0.4913	0.15000
D-LD <i>lat/del</i>	8d214	871 872	0.09154 (131)	−0,0315 [−,045, −,018]	0.04029	0.4385	0.2999	0.4988	0.14673
D-DC <i>del/cum</i>	e9cfb	871 872	0.08665 (124)	−0,0363 [−,050, −,022]	0.03379	0.4125	0.2319	0.5413	0.16340
D-CC <i>cum/cum</i>	88a4c	871 872	0.06639 (95)	−0,0566 [−,072, −,041]	0.02664	0.3935	0.1899[†]	0.5235	0.19715[†]
D-DD <i>del/del</i>	4324f	871 872	0.05800 (83)	−0,0650 [−,082, −,049]	0.02819	0.4016	0.2363	0.5457	0.13335

La capacidad tampoco era la palanca omitida. El control emparejado en parámetros C1 (h425, 871 017 parámetros — $2,2\times$ C0) obtiene 0,12089 frente al 0,12299 de C0, con un Δ pareado de −0,0021 que cruza cero. Esto cubre un hueco real: la *anchura* de GRU única solo se había escaneado sobre el espacio AE de 64 dimensiones (Sección 5), y el espacio rico PCA-192 estaba sin probar. Se comporta igual, así que **la anchura de GRU única queda ahora cerrada también en PCA-192, como ya lo estaba en AE-64**. Como C1 es una coincidencia genuina al 0,098 % en parámetros con las ramas de `fusion_layers = 1`, el nulo no puede reatribuirse a «la capacidad habría ayudado»: demostrablemente no lo habría hecho.

Atribución de vistas: la complementariedad es real, pero cae en el par equivocado. El triángulo completo de vistas es lo que vuelve esto decible mecánicamente en lugar de un juicio de valor, y la respuesta es genuinamente sorprendente (Tabla 16, Figura 9). El par que el diseño nominó como su mejor esperanza — `latent + cummean` — *no* es complementario: empatiza con su padre `latent/latent` y solo supera al padre de solo centroide, es decir, la torre de latentes crudos carga con la celda entera y la torre de centroide es peso muerto. Lo mismo ocurre con `latent + delta`. Pero `delta + cummean` *sí* es complementario: supera a *ambos* padres con IC por encima de cero.

Leído en conjunto: el mecanismo de co-adaptación que proponía la hipótesis **funciona** de verdad; simplemente ocurre que **la vista latent cruda ya subsume todo lo que llevan las otras dos**. Una GRU sobre latentes crudos integra internamente el movimiento entre pasos y la media acumulada, de modo que emparejarla con un cálculo explícito de cualquiera de los dos es redundante — mientras que dos vistas *empobrecidas* sí tienen información no solapada que agrupar, a un nivel absoluto desesperado (0,08665). Esa es una explicación mecanicista limpia del nulo, no una mera ausencia de efecto.

Cuadro 16: Atribución de vistas: cada celda mixta contra *ambos* de sus padres de vista única (Δ pareado de Recall@10, 1431 sesiones). Solo uno de los tres pares mixtos es genuinamente complementario — y es precisamente el que no tiene torre de latentes crudos.

Celda mixta	vs padre 1	vs padre 2	Veredicto
D-LC <i>lat/cum</i>	D-LL: $-0,0056$ [$-0,018$, $+0,007$]	D-CC: $+0,0308$ [$+0,018$, $+0,045$]	<i>no complementario</i>
D-LD <i>lat/del</i>	D-LL: $-0,0112$ [$-0,023$, $+0,001$]	D-DD: $+0,0335$ [$+0,020$, $+0,047$]	<i>no complementario</i>
D-DC <i>del/cum</i>	D-DD: $+0,0287$ [$+0,015$, $+0,043$]	D-CC: $+0,0203$ [$+0,008$, $+0,034$]	complementario: ambos IC>0




Figura 9: La matriz completa de emparejamiento de vistas con `fusion_layers = 1`, una ejecución por celda. Toda celda dual queda *por debajo* de la línea base de GRU única (0,12299), y el orden es monótono en cuánta vista **latent** cruda contiene el par: ambas-latent es la mejor, ambas-delta la peor. El triángulo inferior nunca se ejecutó (el emparejamiento es simétrico por construcción) y se enmascara en gris en lugar de reflejarse, de modo que la escala de color refleja solo celdas medidas. El gradiente es el hallazgo: una torre recurrente sobre latentes crudos ya calcula lo que **delta** y **cummean** hacen explícito.

La cabeza MLP de fusión es activamente perjudicial, no solo inútil. Ambas ramas con `fusion_layers = 0` superan a sus gemelas de `fusion_layers = 1` con el IC del Δ pareado por encima de cero ($+0,0161$ en latent/latent, $+0,0203$ en latent/cummean) con un 10% *menos* de

parámetros — así que quitar la cabeza vuelve el modelo mediblemente mejor en *ambos* regímenes de vista. Mecanísticamente esto encaja con todo el arco de la familia: el objetivo es recuperación coseno/InfoNCE *en* el espacio latente de ítems, así que el trabajo de la cabeza es aterrizar *en* esa geometría, y una capa no lineal extra de anchura 256 entre el estado recurrente y una lectura métrica solo añade una deformación que la pérdida debe después deshacer. El intercambio corre al revés en holística (ambas ramas f0 tienen H *menor*, con el IC de ΔH por debajo de cero): la deformación extra de las ramas f1 difunde el top-diez (más ild, menos artist_adj) a costa de los aciertos exactos. La regla adoptada es **fusion_layers = 0 por defecto**, confirmada luego una tercera vez (Tabla 19).

Holisticidad y recall están anticorrelacionados, y el piso de recall se ganó su lugar. Cinco ramas elevan *holisticness@10* con el IC del ΔH por encima de cero, culminando en el 0,19715 de D-CC (+0,055) — que en la métrica de corona desnuda habría quedado segundo en todo el tablero. Pero D-CC aterriza 95 de 1431 aciertos exactos frente a los 176 de la línea base. El orden del lote por H es casi el *inverso* de su orden por recall (Figura 10), de modo que **las cinco ganadoras en ΔH incumplen el piso de recall pre-registrado de $\pm 0,015$** y la regla de corona nunca se activó. Sin ese piso la campaña habría «ganado la corona» con un modelo un 46 % peor en su trabajo real — precisamente el modo de fallo degenerado de *mood-session* (H 0,2332 con Recall@10 0,0238) que el piso se escribió para bloquear. Con la evidencia actual, **la holística sin restricciones se maximiza prediciendo peor**, así que cualquier objetivo futuro de holística en este corpus debe ser uno *restringido*.




Figura 10: Por qué la regla de corona necesita un piso de recall duro. A lo largo de las diez ramas, *holisticness@10* corre casi exactamente *al revés* que Recall@10: las cinco ramas que superan el tramo de ΔH con IC por encima de cero (verde) son las cinco más *alejadas por debajo* de la línea base en recall exacto, y las cinco caen fuera del piso de $\pm 0,015$ (sombreado). El cuadrado hueco es el modelo incumbente *mood-session* que motivó el piso: la mayor holística del registro con 34 de 1431 pistas siguientes correctas. Los valores de H son de la generación de 3 factores (Sección 18).

Interpretación. No se registró nada ni se promovió nada; el campeón, la tabla de clasificación

y los pines quedan intactos. Lo que compra la campaña es un *cierre*: el nulo de combinador es ahora robusto en todo el espacio de diseño de combinadores en este corpus — post-hoc a nivel de puntuación (de tres formas) *y* a nivel de representación entrenado conjuntamente con un control emparejado en parámetros — lo que consolida materialmente que «el z-blend fijo de tercios iguales es el combinador de referencia». Dos sub-hallazgos genuinos sobreviven al nulo (la cabeza MLP de fusión perjudicial, y la complementariedad **delta+cummean**), y la maquinaria en sí es sólida: 10 de 10 ejecuciones exitosas, el nuevo predictor entrena, converge y evalúa con paridad exacta respecto a la familia, y D-LL-f0 incluso obtiene el mejor MRR del lote (0,05631 frente al 0,05341 de C0) — la única métrica en la que lidera una rama dual. Según la disciplina de la banda de ruido eso es «al menos igual, probablemente ni mejor ni peor», no una victoria.

Un hallazgo de procedencia que revisa dos números previos. Antes del lote se descubrió que el directorio del worker remoto en vivo estaba *obsoleto*: su `seq_common.py` no tenía `holisticness_at_k` en absoluto, `seq_nexttrack.py` difería del hub por md5 y faltaban por completo tres módulos `seq_*.py`. Tras refrescar y verificar que toda la familia era md5-idéntica al hub, C0 devolvió 0,12299, idéntico bit a bit al valor de registro del hub — y *no* el 0,1201957 que habían devuelto dos ejecuciones remotas anteriores (`run-20260723-002044-af11a`, `-17cf8`). El «desplazamiento de $-0,0028$ por orden de reducción entre hosts» que aquellas ejecuciones sugerían queda por tanto **retirado: era una diferencia de código, no un efecto de host**. Sus números de recall pertenecen a un estado de código superado y no son comparables en código con lotes posteriores; siguen siendo válidos como las mediciones de eagerness β para las que se tomaron (Tabla 13), ya que esas conclusiones descansan en comparaciones intra-lote. La lección general — un checkout remoto divergente produce un *número equivocado*, no una caída — es ahora una comprobación previa permanente. *Fuente: 2026-07-25-nexttrack-dual-tower-fusion-scan.md*.

17. El pre-codificador por paso refutado, y el mecanismo del rectificador

Motivación. El nulo de torre doble cerró la asimetría de vistas *deterministas*: **delta** y **cummean** son funciones con pérdida de lo que una torre de latentes crudos ya posee, así que emparejarlas no compra nada. Esta campaña plantea la versión estrictamente más fuerte: ¿una re-incrustación **aprendida** por paso, que *no* es función de información que la torre ya tenga, amplía útilmente el espacio de hipótesis? El eje es una re-incrustación no lineal delante de la recurrencia, $[\text{Linear}(d_{\text{in}}, w), \text{ReLU}, \text{Dropout}] \times \text{pre_layers}$, aplicada por paso temporal (estrictamente causal), con el `input_size` de la GRU pasando a ser *w*.

La hipótesis tiene un filo analítico inusualmente nítido. La propia transformación de entrada de una GRU *ya es lineal* ($W_i x$ por compuerta), y un pre-codificador *lineal* con $w \geq d_{\text{in}}$ es exactamente igual de expresivo que una GRU desnuda, puesto que $W_i(Vx) = (W_i V)x$ sin restricción de rango. **La ReLU es por tanto el único cambio de expresividad**, lo que significa que no hace falta una ejecución de control con pre-codificador lineal y que un nulo no puede despacharse como «el pre-codificador era redundante por construcción». El movimiento decisivo del diseño es la **ablación de torre única** S1 — un $\text{MLP}_{256} \rightarrow \text{GRU}_{256}$ contra una GRU simple emparejada en parámetros — porque sin ella cualquier resultado de torre doble es ininterpretable: ¿pre-codificador, o segunda torre?

Diez ejecuciones, la misma partición canónica, el mismo worker remoto único, cero fallos. Dos puertas de reproducción pasaron *bit a bit*: C0 devolvió Recall@10 0,12299091544374564 (176 de 1431, idéntico hasta el último dígito, una séptima reproducción), confirmando que la edición de

`pre_hidden` no perturbó la ruta de código por defecto de la familia; y C3, la rama de torre doble desnuda, devolvió 0,10272536687631029, exactamente su valor de registro, validando todos los veredictos duales.

Resultados. La Tabla 17 es el lote y la Figura 11 el veredicto de un vistazo. Ni una de las seis ramas con pre-MLP supera la línea base con el IC del Δ pareado por encima de cero: cinco pierden sin ambigüedad, una empata. **Y la ablación decisiva no solo empata: pierde:** S1 en 0,10901 frente al 0,12299 de C0, con $\Delta -0,0140$ y el IC enteramente por debajo de cero, 156 aciertos contra 176. Puesto que aquí un pre-codificador lineal es demostrablemente neutro en expresividad, **la re-incrustación con ReLU está destruyendo información del prefijo que la propia transformación de entrada lineal con compuertas de la GRU preservaba.**

Cuadro 17: Presencia $\times$ colocación $\times$ dosis del pre-codificador, diez ejecuciones sobre seq-20260715-131139 (1431 sesiones de prueba), ordenadas por Recall@10. Todas las ramas comparten el prefijo run-20260726-161801-; C0 es run-20260726-161429-bdcbc. El Δ pareado es un bootstrap pareado por sesión contra C0 (2000 remuestreos, rng 1337); los límites del IC se dan con tres decimales, y un IC que cruza cero es un *empate*. Los códigos de rama dual dan las anchuras de pre-codificador de las dos torres (A0/B256 = torre A desnuda, torre B rectificada con anchura 256) y la profundidad de fusión. Aquí H es la generación *de 4 factores* (anclada) de holisticidad y **no** es comparable con la columna de 3 factores de la Tabla 15 (Sección 18). Mejor celda por métrica en negrita; **artadj@10 mejor cuanto más bajo.** [†] El artadj mínimo de T4 y el ild máximo de T1 son el familiar intercambio de des-eagerizar-prediciendo-peor: ambos quedan $\sim 0,025$ por debajo de C0 en recall.

Rama	id	params	R@10 (crudo)	Δ vs C0	IC 95 %	MRR	mus@10	artadj↓	ild↑	H↑
C2 h454 <i>ctrl</i>	7646d	969 936	0.12509 (179)	+0,0021	[−,007, +,011]	0.05389	0.4572	0.3668	0.4466	0.045765
T1-f0 A0/B256, f0	a6423	888 256	0.12369 (177)	+0,0007	[−,012, +,013]	0.05470	0.4575	0.3627	0.4616	0.044541
C0 h256 <i>base</i>	bdcbc	394 944	0.12299 (176)	—		0.05341	0.4558	0.3474	0.4536	0.047086
C1 h297 <i>ctrl</i>	7bab3	494 697	0.11321 (162)	−0,0098	[−,017, −,003]	0.05199	0.4513	0.3602	0.4474	0.045285
S1 preMLP256	ad53f	493 504	0.10901 (156)	− 0,0140	[−,027, −,001]	0.04463	0.4499	0.3240	0.4815	0.047132
C3 <i>dual desn.</i>	0df6f	871 872	0.10273 (147)	−0,0203	[−,035, −,007]	0.04235	0.4446	0.3092	0.4873	0.046612
T2 A0/B128, f1	dc7d2	847 424	0.09993 (143)	−0,0231	[−,037, −,009]	0.04490	0.4415	0.3039	0.4939	0.046431
T3 A0/B384, f1	ca0b8	1 093 440	0.09993 (143)	−0,0231	[−,037, −,009]	0.04333	0.4441	0.3068	0.4961	0.045895
T4 A256/B256, f1	bd5b5	1 068 992	0.09783 (140)	−0,0252	[−,039, −,011]	0.03829	0.4343	0.2845 [†]	0.4986	0.043985
T1 A0/B256, f1	9450b	970 432	0.09713 (139)	−0,0259	[−,040, −,013]	0.04176	0.4369	0.2962	0.5016 [†]	0.045769

La curva de dosis es plana, y la colocación es irrelevante. Barriendo `pre_hidden_b` por $\{0, 128, 256, 384\}$ con `fusion_layers` = 1 (Tabla 18), todo par adyacente cruza cero y también lo hacen los extremos — un eje **plano**, lo que por la cláusula pre-registrada habría bloqueado el registro incluso si alguna regla de victoria se hubiera activado. Nótese, sin embargo, que el orden *nominal* es descendente-y-luego-plano, nunca ascendente: toda rama dosada queda por debajo de la dual desnuda. Junto con la pérdida significativa de S1, el signo de este eje es consistentemente negativo en ambas torres y en las cuatro anchuras, así que no hay pico interior que perseguir. La simetría es igualmente un no-factor: T1 (asimétrica, una torre desnuda) contra T4 (ambas torres rectificadas) cruza cero en recall, así que mantener desnuda la torre A no es determinante a esta dosis.

El único positivo sólido: la regresión de profundidad de fusión, medida por tercera vez y mayor. T1-f0 supera a T1 por +0,0266 con el IC por encima de cero, frente al +0,016 y +0,020 medidos en los dos regímenes de vista de torre doble (Tabla 19). El mecanismo se sostiene y se afila: cada capa no lineal extra entre el estado recurrente y la lectura métrica añade una deformación que la pérdida InfoNCE debe deshacer, y *cuanta más no linealidad se haya añadido ya en el lado de entrada, más cuesta la deformación del lado de salida.* Nótese además que T1-f0 — la única rama




Figura 11: El veredicto del pre-codificador. Δ Recall@10 de bootstrap pareado por sesión contra la línea base reproducida, una fila por rama; la franja sombreada es la banda práctica de empate de $\pm 0,015$. Ni una rama con pre-codificador alcanza un IC enteramente por encima de cero. La fila decisiva es S1 — la torre única, la única rama cuyo resultado es atribuible sin ambigüedad al pre-codificador — que pierde sin paliativos. Como un pre-codificador *lineal* a esta anchura es demostrablemente neutro en expresividad, el rectificador es la única causa candidata.

con pre-codificador que empata con la línea base — es exactamente la rama que tiene *a la vez* una torre A desnuda y `fusion_layers = 0`: la ruta más corta y sin deformar desde los latentes crudos hasta la lectura. `fusion_layers = 0` es el valor por defecto de la familia, punto.

El mecanismo, medido en lugar de inferido. El argumento analítico señalaba al rectificador como única causa candidata; una lectura de interpretabilidad posterior lo *midio* (Figura 12). El control decisivo fue un tap contrafactual que el motor de autoencoder disperso no puede expresar: el *propio* mapa afín del modelo con la ReLU eliminada. Leyendo la decodificabilidad de género de la siguiente pista en el mismo paso (11 184 filas de prueba de sonda, 25 clases, error estándar pareado $\leq 0,0065$): el latente crudo puntúa 0,4033, el mapa afín 0,4084 (**neutro**, $\sim 0,8\sigma$, exactamente como predice $W_i(Vx) = (W_iV)x$) y el tap rectificado 0,3700 ($\sim 5,9\sigma$: **la ReLU es toda la pérdida**). La prueba definitiva es aritmética: `frac_exact_zero` en el tap rectificado es 0,5327, que coincide con el `frac_negative_coords` del tap afín, 0,5327, hasta cuatro dígitos. El rectificador borra *precisamente* la mitad negativa, dejando ~ 120 unidades vivas para 192 direcciones con signo — *menos coordenadas vivas que dimensiones tiene la entrada*. Los latentes PCA-192 están centrados en cero y son casi simétricos por construcción, y con $w = 256$ (solo $1,33\times$ la dimensión de entrada) no hay ni de lejos suficiente sobrecompletitud para re-codificar el semiespacio descartado, a diferencia de los embeddings anchos donde viven normalmente los MLP con ReLU. El daño sobrevive a la recurrencia: dentro de un mismo modelo, `tower_b` (alimentada rectificada) puntúa 0,3929 frente a su *gemela idéntica* `tower_a` (alimentada cruda) con 0,4183, $\sim 3,9\sigma$ — y `tower_a` reproduce la GRU simple autónoma (0,4235), que es exactamente lo que exige «la torre desnuda rescata».

Interpretación, y una salvedad honesta sobre los controles. Este es el quinto nulo consecutivo

Cuadro 18: La curva de dosis, tal como se midió: Δ Recall@10 pareado contra la rama de torre doble desnuda C3 con `fusion_layers = 1`. Plana según la prueba pre-registrada — pero nominalmente descendente, nunca ascendente.

pre_hidden_b	Rama	R@10 (crudo)	Δ vs C3 (desnuda)
0	C3	0.10273 (147)	—
128	T2	0.09993 (143)	-0,0028 [-,015, +,009] cruza cero
256	T1	0.09713 (139)	-0,0056 [-,019, +,008] cruza cero
384	T3	0.09993 (143)	-0,0028 [-,015, +,011] cruza cero

Cuadro 19: La regresión de `fusion_layers`, tres mediciones independientes. Δ Recall@10 pareado de la rama de lectura lineal menos su gemela con cabeza MLP; positivo significa que quitar el MLP de fusión *ayuda*. La columna ΔH solo está disponible para los dos pares de 3 factores del mismo lote. *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md (filas 1–2), 2026-07-26-nexttrack-pre-encoder-scan.md (fila 3).*

Par (f0 – f1)	Régimen	Δ R@10 [IC 95 %]	ΔH [IC 95 %]
D-LL-f0 – D-LL	vistas redundantes, sin pre-codificador	+0,0161 [+0,0021, +0,0301]	-0,0086 [-0,0116, -0,0055]
D-LC-f0 – D-LC	vistas complementarias, sin pre-codificador	+0,0203 [+0,0063, +0,0335]	-0,0135 [-0,0171, -0,0100]
T1-f0 – T1	con pre-codificador por paso	+0,0266 [+0,0140, +0,0391]	—

de arquitectura, y cierra el *lado de entrada* como el nulo de vistas cerró la dirección de vistas de entrada: junto con los cuatro nulos de combinador aprendido, añadir maquinaria de representación *alrededor* de una GRU única sobre un buen espacio latente no ayuda en este corpus, mientras que toda ganancia real del registro vino de mejorar el *propio espacio latente* (la proyección de contenido InfoNCE, PCA-192) o del z-blend fijo. El eje queda ahora acotado cuantitativamente: mejor rama con pre-codificador 0,12369, un empate; dosis plana hasta el doble de la dimensión de entrada; colocación irrelevante; interacción con la profundidad de fusión resuelta. La salvedad es que el *control de anchura emparejado en parámetros resultó un instrumento más débil de lo supuesto*: C1 (h297) llegó a 0,11321, perdiendo él mismo contra C0, y los puntos de anchura del lote corren $176 \rightarrow 162 \rightarrow 173 \rightarrow 179$ aciertos en h256 / h297 / h425 / h454 — no monótonos, abarcando 0,0119 de recall sin tendencia. «La anchura de GRU única es plana en PCA-192» sobrevive como afirmación de *tendencia* (h454 empata con h256), pero el ruido entre anchuras es de $\sim \pm 0,01$ en una sola partición, aproximadamente dos tercios de la banda de ruido. **Un control emparejado en anchura que es él mismo una única ejecución sin replicar no es un anclaje de capacidad fiable a esta magnitud de efecto** — razón por la cual importa que el veredicto de S1 descansa en la comparación con C0, reproducida hasta el último dígito. Una segunda salvedad queda sin desenredar: el pre-MLP termina en **Dropout**, de modo que las ramas con pre-codificador reciben dropout a la *entrada* de la GRU que las ramas desnudas no tienen, y la pérdida de S1 podría deberse en parte a sobre-regularización más que al rectificador — separarlos exige un parámetro `pre_dropout` que todavía no existe. *Fuente: 2026-07-26-nexttrack-pre-encoder-scan.md.*

18. Leyendo el registro: potencia estadística y las generaciones de holisticidad

De los lotes del 2026-07-25/26 emergieron dos hechos transversales que cambian cómo debe leerse cada número anterior. Ninguno es un resultado sobre un modelo; ambos son resultados sobre el *instrumento de medida*, y su lugar es aquí y no enterrados en una sola campaña.




Figura 12: El mecanismo del rectificador, medido. Decodificabilidad de género de la siguiente pista en cada tap de representación, incluido uno contrafactual que el motor de interpretabilidad no puede expresar: el propio mapa afín del modelo con la ReLU eliminada. En el lado de entrada el mapa afín es *gratis* ($\sim 0,8\sigma$) y la ReLU es el coste *entero* ($\sim 5,9\sigma$); tras la recurrencia el daño persiste ($\sim 3,9\sigma$ entre dos torres idénticas que solo difieren en si su entrada fue rectificada), mientras que la torre alimentada en crudo reproduce la GRU simple autónoma. `frac_exact_zero` en el tap rectificado (0,5327) coincide con el `frac_negative_coords` del tap afín (0,5327) hasta cuatro dígitos: la rectificación de media onda de un latente centrado en cero borra exactamente la mitad negativa, dejando ~ 120 unidades vivas para 192 direcciones con signo.

18.1. Los nulos están limitados por potencia, y esa es una afirmación distinta

Todo veredicto de este documento descansa en un bootstrap pareado por sesión sobre las mismas 1431 sesiones de prueba. Ese n tiene una resolución medible. Promediado sobre las nueve comparaciones pareadas del lote del pre-codificador, el semiancho del IC al 95 % es 0,0124 en Recall@10 (0,0128 sobre las nueve del lote de torre doble, así que la cifra es estable), y $\sim 0,0018$ en holistiness@10. Compárense ahora con el *rango completo* de una familia de arquitectura: 0,028 en Recall@10 y 0,0031 en holistiness@10 (Tabla 20). El cociente es toda la historia: el rango completo de una familia mide solo $\sim 2,3$ anchos de resolución en recall y $\sim 1,9$ en holisticidad, de modo que de ocho ramas adyacentes son separables aproximadamente **dos niveles** en Recall@10 y **uno** en holistiness@10. Resolver una diferencia de 0,005 en Recall@10 a esta precisión exigiría $n \approx 1431 \cdot (0,0124/0,005)^2 \approx 8800$ sesiones de prueba, seis veces lo que aporta la partición (Figura 13).

La lectura honesta de los cinco nulos de arquitectura se sigue directamente, y no es la que da una mirada superficial. Lo que estas campañas establecieron con firmeza es que las arquitecturas probadas no entregan ganancias *grandes*, y que varias de ellas hacen *daño* real — los daños son los resultados bien potenciados, porque son grandes (S1 $-0,0140$; la regresión de `fusion_layers` $+0,0266$; seis de ocho ramas duales por debajo de la línea base). Lo que las campañas *no* pueden establecer es la ausencia de una ganancia moderada: una mejora genuina de $+0,005$ — que sobre una línea base de 0,123 sería un respetable 4 % relativo — habría

Cuadro 20: Resolución medida de la partición de prueba. Los semianchos son medias sobre las nueve comparaciones de bootstrap pareado del lote del pre-codificador (2000 remuestreos, $n = 1431$); el rango de familia es el recorrido completo de ese lote en cada métrica. «Niveles» es rango/semiancho, es decir, cuántos escalones genuinamente distinguibles pueden ocupar ocho ramas adyacentes. *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md, 2026-07-26-nexttrack-pre-encoder-scan.md.*

Métrica	semiancho del IC con $n = 1431$	rango de familia	niveles	n para $\Delta = 0,005$
Recall@10	0.0124	0.0280	~ 2 de 8	~ 8800
holisticness@10	0.0018	0.0031	~ 1 de 8	—

sido invisible por construcción. Así que «la fusión de torre doble queda refutada» y «el pre-codificador queda refutado» deben leerse como *ningún efecto grande, y ningún efecto de la magnitud hipotetizada*, no como «estas arquitecturas no funcionan». La consecuencia práctica es una regla de priorización más que una salvedad: en esta partición, más ramas de arquitectura son un mal uso de las ejecuciones sea cual sea su resultado, porque todo el rango dinámico del espacio de diseño apenas duplica el error de medición. O se amplía n , o se pasa a ejes cuyos efectos sean grandes — que es, empíricamente, exactamente lo que han entregado los ejes de representación y supervisión (el +0,0259 de la proyección de contenido es el doble del semiancho, y el +0,0426 del endurecimiento en segunda partición, el triple).

18.2. Tres generaciones de holisticness@10, y por qué el tablero se denomina en recall

El compuesto *holisticness@10* se revisó dos veces en cuatro días, y los valores almacenados **no son comparables entre los cortes**:

Gen. 1 — 3 factores (hasta 2026-07-24). El producto desnudo

$$\text{clamp}(\text{mood_coh}, 0) \times \text{ild} \times (1 - \text{artist_adj}),$$

que no lleva *ningún término de corrección en absoluto*. Los valores caen en 0,063 a 0,233 — la columna de la Tabla 15.

Gen. 2 — 4 factores, anclada (2026-07-25). Multiplica por un factor de anclaje (*grounding*) de *music@10*,

$$\text{clamp}((\text{music@10} - 0,185)/0,815, 0, 1).$$

Como *music@10* cae al mismo compás que el recall, esto cancela las «victorias» por des-eagerización que premiaba la forma de 3 factores; los valores caen en 0,044 a 0,050 — la columna de la Tabla 17.

Gen. 3 — consciente de la concentración (2026-07-26). La *eagerness* pasa a ser $\max(\text{artist_adj}, \text{artist_conc})$ y el piso de anclaje sube 0,185→0,34. Los valores caen cerca de 0,009 a 0,025.

Cada faceta se almacena por fila, así que cualquier generación es recalculable a posteriori (el ayudante `rescore_holisticness.py` lo hace para las ejecuciones a las que puede llegar), y la Tabla 21 re-deriva las tres para un corte representativo. Dos consecuencias importan al leer este documento. Primera, **una columna de holisticidad debe llevar siempre la etiqueta de su**




Figura 13: Los nulos de arquitectura están limitados por potencia. El semiancho del IC de bootstrap pareado cae como $1/\sqrt{n}$; con el $n = 1431$ de la partición vale 0,0124 en Recall@10, mientras que una familia de arquitectura completa abarca solo 0,028. Resolver una diferencia de 0,005 exigiría ~ 8800 sesiones de prueba. La lectura honesta de los cinco nulos de arquitectura se sigue de inmediato: *los daños grandes se detectaron con fiabilidad; las victorias moderadas nunca fueron detectables*.

generación, porque el efecto de generación empuja al efecto de modelo: todo valor de 3 factores supera mecánicamente a todo valor de 4 factores, ya que el factor de anclaje multiplica por $\sim 0,3$. Segunda, y más importante, **los tableros de recall y de holisticidad apuntan en direcciones opuestas en todas las generaciones**. El blend campeón — 0,21174 de Recall@10, 303 de 1431 — queda *último* en la Tabla 21 bajo las tres fórmulas, porque es el modelo más artist-eager del registro; lideran la rama degenerada *cummean/cummean* y *mood-session*. La generación 3 degradó *mood-session* de primero a un cero genuino, pero *no* arregló la rama degenerada de torre doble, así que el piso de recall de $\pm 0,015$ sigue siendo obligatorio en cualquier afirmación de holisticidad.

Qué es la métrica principal, y por qué ordena este documento. Para completar el cuadro: la clave `[metrics].primary` de `domain.toml`, y el `primary_metric` del grupo de mejores modelos, han marcado ambos `holisticness@10` desde 2026-07-23, así que la métrica principal *efectiva en el servidor* ya no es Recall@10. Las afirmaciones de las secciones anteriores de que «la métrica principal sigue siendo Recall@10» eran ciertas cuando se escribieron y quedan superadas *para el servidor*. Aun así, este documento sigue denominando su tabla de clasificación (Tabla 1) y cada veredicto de campaña en **Recall@10**, y lo hace deliberadamente: es la moneda de comparabilidad del registro, es estable en las tres generaciones de la métrica y — como muestra la Tabla 21 — un orden por holisticidad situaría último al campeón servible. La holisticidad se reporta en todo el documento como columna diagnóstica etiquetada y marcada con su generación. Fuentes: 2026-07-25-*nexttrack-dual-tower-fusion-scan.md*, 2026-07-26-*nexttrack-pre-encoder-scan.md*.

Cuadro 21: Los mismos modelos bajo las tres generaciones de holisticidad, ordenados por Recall@10. El efecto de generación empequeñece al efecto de modelo, y el orden es aproximadamente *inverso* al de Recall@10 en todo el rango — razón por la cual la tabla de clasificación de este documento sigue denominada en Recall@10. Los guiones son ejecuciones cuyas facetas no pudieron re-derivarse bajo esa generación (ejecuciones solo remotas sin fichero de predicciones materializado). *Fuentes: 2026-07-25-nexttrack-dual-tower-fusion-scan.md, 2026-07-26-nexttrack-pre-encoder-scan.md.*

Modelo (run)	R@10 (crudo)	gen-1 (3-f)	gen-2 (4-f)	gen-3 (actual)
blend $R'+M+C'$ (1c1a3)	0.21174 (303)	0.0632	0.020830	0.00860
GRU única h454 (7646d)	0.12509 (179)	—	0.045765	0.02399
GRU única h256 (97c1e, bdcabc)	0.12299 (176)	0.14172	0.047086	0.02454
GRU única h425 (be11b)	0.12089 (173)	0.13850	0.046677	0.02487
S1 pre-MLP→GRU (ad53f)	0.10901 (156)	0.14499	0.047132	0.02410
D-CC <i>cum/cum</i> (88a4c)	0.06639 (95)	0.19715	0.050436	—
mood-session (degen.)	0.02380 (34)	0.23319	0.043881	0.00000

19. La superficie de la caminata: medir lo que el producto realmente sirve

Motivación. Todo veredicto hasta este punto — incluidos el tablero de la corona de la Tabla 1 y las tres generaciones de holisticidad de la Sección 18.2 — se calcula sobre un **top-10 de un solo disparo** (one-shot): el modelo ve un prefijo held-out, ordena el catálogo una vez y se puntúa contra un único objetivo. Pero el artefacto que este laboratorio despacha, `clients/infinite-playlist`, sirve una **caminata autorregresiva** (walk): elige una pista, la añade a la sesión, vuelve a puntuar y repite tantos pasos como pida quien escucha. Son superficies distintas, y `domain.toml` lo ha dicho en prosa desde el principio — su bloque `[metrics]` enuncia el objetivo como «*sesiones mood-coherentes y no-eager, no acertar la pista siguiente literal*». La intención declarada y la métrica implementada habían divergido. Esta sección cierra esa brecha: define cuatro métricas a nivel de caminata calibradas contra la escucha real del propio usuario, añade tres controles de *tiempo de recuperación* (retrieval) y ejecuta un cara a cara de muestra emparejada. Es también el único lugar de este documento donde una refutación documentada queda *revertida* sobre un objetivo nuevo, y por eso se reporta con extensión en vez de plegarse dentro de las secciones de campaña anteriores.

19.1. El desajuste de superficie, y por qué la deriva era invisible

Dos hechos mecánicos explican por qué nada de lo anterior podría haber detectado una caminata a la deriva.

Primero, el ancla crece. La faceta `mood_coh` de `holisticness@10` mide el coseno de cada candidato al centroide del *prefijo* (`seq_common.py:558`). En una evaluación de un solo disparo el prefijo es fijo y eso es una lectura razonable de «¿se mantiene esta lista en el mismo mood?». En una caminata el prefijo *es* el viaje recorrido, así que el punto de referencia viaja con el modelo: un viaje que abandona su región de partida mediante mil pasos individualmente legales puntúa bien *en cada paso*, porque cada paso se compara con un centroide que ya se ha desplazado casi todo el camino hasta allí. **La deriva es invisible por construcción** — no está subponderada: es inmedible en esta formulación.

Segundo, la composición está dominada por la relevancia. Derivar la composición de generación 3 en el punto de operación del campeón da $\partial H / \partial \text{music@10} = +0,206$ frente a

$\partial H/\partial \text{eager} = -0,038$: `holisticness@10` es $5,5\times$ más sensible a su factor de relevancia que a su factor de eagerness. Así que incluso el término *pensado* para poner precio a la calidad de la sesión termina reportando sobre todo relevancia graduada. Es la misma asimetría que la Sección 18.2 observó desde fuera, donde el multiplicador $\sim 0,3$ del factor de anclaje hacía que todo valor de generación 2 quedara por debajo de todo valor de generación 1; aquí queda cuantificada en la derivada.

19.2. Cuatro métricas de caminata, calibradas contra las sesiones del propio usuario

El nuevo instrumento (`tools/walk_eval.py`) genera viajes a partir de sesiones *reales* held-out — una semilla de 5 pistas tomada de la sesión, luego 20 pasos autorregresivos, con los ítems del prefijo excluidos y como máximo una pista por artista salvo indicación en contra — y los puntúa en cuatro ejes:

1. **Ajuste de transiciones (principal).** ¿Se parecen las distancias paso a paso de la caminata a la escucha *real* de este usuario? Esto sigue directamente el hallazgo de playlist-lab: medir *transiciones*, no promedios, y calibrar contra las sesiones propias del usuario. Promediar una distancia a un centroide tiene la forma equivocada — penaliza un cambio de género legítimo y premia quedarse quieto. Se reporta como la distancia 1-Wasserstein (W_1 , menor es mejor) entre la distribución de cosenos de pares consecutivos del viaje y la real, más dos lecturas legibles: el coseno de paso mediano y la fracción de pasos dentro de la banda p10–p90 real.
2. **Vibe y deriva.** El coseno *anclado a la semilla*: coseno medio de las pistas generadas al centroide del núcleo de la semilla (*vibe*, mayor es mejor) y la diferencia entre el último cuarto y el primero (*drift*, mejor cuanto más cerca de cero). El ancla queda fija en la semilla y *no* crece, que es precisamente el defecto de `mood_coh` que identifica la Sección 19.1.
3. **La variedad como crédito.** Artistas distintos y géneros distintos en el viaje, contados como *crédito* y no como el coste al que `artist_adj/artist_conc` les ponen precio. Cohesión no es un solo género: los géneros distintos son bienvenidos si preservan el *vibe*, así que un viaje que cubre más géneros con el mismo *vibe* es mejor, no peor.
4. **Anclaje a la verdad (grounding).** Relevancia graduada (mejor coseno sónico, en el espacio balanceado de distancia musical de la Sección 14) entre cada pista generada y lo que el usuario *realmente* reprodujo después en esa sesión. Es la barandilla: sin ella gana una deriva agradable pero inconexa, que es exactamente la lección que la corona aprendió cuando se añadió `music_rel`.

La calibración, y el número que reencuadró el proyecto. La distribución de referencia son los cosenos de pares consecutivos del propio usuario sobre las 5723 sesiones de *entrenamiento* de seq-20260715–131139: 73 632 pares, mediana 0,261, p10–p90 $[-0,192, 0,830]$ y 27,0 % de los pasos reales *negativos*. La escucha real se mueve — cambia de dirección más de una cuarta parte de las veces. Frente a eso, el motor que el showcase realmente despachó (una GRU única como `gru.onnx` con un ancla de semilla de 0,4) camina con un paso mediano de 0,661, aproximadamente $2,5\times$ más ceñido de lo que camina el usuario (Figura 14). La queja de que el showcase se sentía «plano a pesar de tener muchos artistas» ya tiene una medición detrás: muchos movimientos pequeños y seguros. El campeón de blend tiene el fallo opuesto — su paso mediano, 0,317, se sitúa esencialmente sobre la mediana real, pero su *vibe* es de solo 0,187, porque su proyección InfoNCE

(Sección 11) codifica «qué sigue a esto» y no «qué suena como esto», de modo que un ancla de mood aplicada *dentro* de ese espacio proyectado se topa con un techo de 0,44 mientras la misma ancla en el espacio PCA-192 crudo alcanza 0,58. La Tabla 22 es la primera lectura completa.




Figura 14: El argumento central de esta sección, en una figura. Los 73 632 cosenos de transición consecutiva del propio usuario (espacio de ítems PCA-192, solo sesiones de entrenamiento) forman una distribución *ancha*: mediana 0,261, p10–p90 [–0,192, 0,830], 27,0 % de pasos negativos. El motor que el showcase despachó camina con un paso mediano de 0,661 — unas 2,5× más ceñido que la persona a la que imita — y ninguna métrica de un solo disparo podía verlo, porque *holisticness@10* puntúa un top-10 y su *mood_coh* se ancla a un centroide de prefijo que crece con la caminata. El campeón de blend (0,317) iguala el paso real pero no logra sostener un *vibe*. Recuentos por bin transcritos del bloque de calibración de `tools/walk_eval.py`.

W_1 **no es emparejable, y eso importó.** El W_1 distribucional se calcula sobre una muestra *agrupada* (pooled) de pasos, así que no tiene valor por sesión y no puede entrar en un bootstrap pareado — el estadístico sobre el que descansa todo otro veredicto de este documento. Por eso los dos primeros barridos compararon ramas medidas en muestras *distintas* (20 sesiones × 20 pasos para la frontera, 12 × 15 para la sonda de torre doble), y una diferencia de *vibe* de 0,588 frente a 0,624 cae holgadamente dentro de lo que ese desajuste por sí solo puede producir: no se había establecido nada. El cara a cara (Sección 19.4) sustituye por tanto W_1 por $\text{stride_err} = |\text{paso mediano} - 0,261|$, una cantidad por sesión que sí empareja, al coste de describir solo el centro de la distribución.

19.3. Tres controles en tiempo de recuperación, y dos refutados

Ninguno de los tres controles siguientes toca el entrenamiento. Todos se aplican en tiempo de *recuperación*, sobre las puntuaciones que el modelo ya produce, y eso es lo que los hace baratos de desplegar y baratos de re-ajustar.

ANCLA (a). Sumar $a \cdot \cos(\text{candidato}, \text{centroide de la semilla})$ a la puntuación de cada candidato. Sostiene el *geist* tirando de la caminata hacia la región desde la que quien escucha la

Cuadro 22: Primera lectura a nivel de caminata de los dos motores despachados. 40 sesiones held-out, semilla de 5 pistas, 20 pasos autorregresivos cada una; **cap** es el límite por artista dentro del viaje. W_1 y $|\text{paso mediano} - 0,261|$ menor es mejor; **vibe**, fracción en banda, artistas, géneros y **ground** mayor es mejor; **drift** mejor cuanto más cerca de cero. La última fila es la referencia contra la que se calibran las métricas (su fracción en banda es 80 % por construcción). Mejor celda por columna en negrita entre las ramas de modelo. *Fuente: `tools/walk_eval.py`.*

Rama	W_1	paso med.	en banda	vibe	drift	artistas	géneros	ground
GRU +ancla 0,4, cap 1 (despachada)	0.320	0.661	80,6 %	0.609	-0.089	20.0	9.93	0.345
GRU +ancla 0,4, cap 3	0.341	0.681	76,7 %	0.610	-0.075	13.2	6.53	0.393
GRU sin ancla, cap 1	0.263	0.574	85,2 %	0.302	-0.277	20.0	8.78	0.276
Campeón ($R'+M+C'$), cap 1	0.078	0.317	90,3 %	0.187	-0.186	20.0	10.33	0.289
Campeón ($R'+M+C'$), cap 3	0.147	0.452	84,8 %	0.193	-0.224	11.1	5.33	0.306
<i>las sesiones reales del usuario</i>	0.000	0.261	80,0 %	—	—	—	—	—

sembró. En el campeón el término se z-normaliza sobre los candidatos admisibles, porque su puntuación base es a su vez un z-blend de tres ramas y sumar un coseno crudo a un z-blend descuadra las escalas.

ZANCADA (STRIDE, s). Restar $s \cdot \cos(\text{candidato}, \text{pista anterior})$. *Agranda* cada paso sin permitir que la caminata abandone el vecindario de la semilla, porque el ancla sigue aplicándose — los dos términos son ortogonales por diseño, uno tirando hacia un punto fijo y otro empujando lejos del último punto. Es deliberadamente *determinista*: el muestreo también aflojaría la zancada, pero el showcase sirve permalinks y «misma receta $\Rightarrow$ mismo viaje» es ya una promesa, así que un decodificador estocástico quedó descartado, no sin probar.

TOPE (CAP). Un límite *duro* por artista aplicado al orden (`seq_common.artist_cap_order`), después de MMR, tanto en `eval_from_scores` como en `rank_topk/predict_ranking`, de modo que evaluación y serving coinciden por construcción. Es de mejor esfuerzo y no absoluto: donde el espacio de candidatos admisibles de un prefijo se agota, los huecos restantes se rellenan con ítems diferidos en vez de devolver menos de k . Por defecto `None`, así que todo run y modelo preexistente es idéntico bit a bit; y como no necesita vectores sónicos es la única palanca de diversidad aquí que se porta sin cambios a un cliente ligero.

Por qué un tope y no una penalización — los dos controles refutados. Ambas palancas anti-eager blandas de la Sección 15 fallan por una razón compartida: una penalización blanda en el espacio de puntuación pierde contra un gradiente de relevancia pronunciado. `eager_beta`, el regularizador de tiempo de entrenamiento, está *mal especificado*: pivota sobre el valor absoluto de $\cos(\text{predicción}, \text{pista actual})$, que una predicción InfoNCE cubierta (hedged) nunca lleva por encima de $\sim 0,6$, mientras que la eagerness es una propiedad de *ordenamiento* — si los ítems del mismo artista ocupan los primeros puestos — y no una propiedad de una similitud absoluta. `mmr_lambda`, el re-ranking en evaluación, era además *solo de evaluación* hasta que se corrigió la ruta de serving, así que la frontera de λ nunca había sido una palanca desplegable; e incluso corregida se mide inerte en el caso patológico. En la playlist real **rock chabon ahre** el modelo ordena 59 de sus 60 primeros candidatos como un mismo artista y el siguiente artista no aparece hasta el **puesto 75**, mientras todo el presupuesto de diversidad de MMR ahí vale $0,3 \times 0,26 \approx 0,078$ de puntuación normalizada — ni de lejos suficiente para pagar una caída de 70 puestos de relevancia. Un tope no compite en puntuación en absoluto: *no puede ser superado por puntuación*, la misma propiedad en

la que ya se apoyaba el `artist_cooldown` de `seq_extend`. La penalización blanda de artista del propio showcase resultó ser efectivamente **binaria** de la misma manera — en 0 producía bloques de artista con rachas de hasta 13, y con *cualquier* valor $\geq 0,25$ cada caminata de 30 pasos devolvía 30 artistas distintos, racha máxima 1, concentración 0,000 — así que el deslizador no alcanzaba el término medio en absoluto, y un tope duro expuesto como forma del viaje (Explore / Balanced / Continue / Blocks) es lo que sí lo alcanza.

El tope en la superficie de un solo disparo, para el registro. La Tabla 23 es el tope medido donde mide el resto de este documento: el top-10 de un solo disparo de la partición canónica, emparejado sobre puntuaciones cacheadas idénticas bit a bit. Recorta `artist_conc@10` de 0,692 a 0,123 con cap 3 y eleva la `holisticness@10` de generación 3 de 0,008603 a 0,033862, a un coste de 73 de 1431 aciertos exactos. El resultado que *no* se predijo es que **music@10 sube, con IC por encima de cero, en todos los topes y en los dos modelos probados** (+0,011 a +0,023): el modo de fallo pre-registrado — des-eagerizar degradándose hacia relleno genérico — no ocurre, porque los ítems promovidos desde el puesto 75 y más allá son *más* aptos musicalmente para la continuación verdadera que las pistas del mismo artista que desplazan. El tope cambia relevancia *literal* por relevancia *graduada*. Sobre el campeón más `markov_gate` (una compuerta en tiempo de serving que suprime la rama de Markov donde el ítem actual no tiene soporte de bigrama; su propia campaña, fechada 2026-07-27c, aún no está consolidada en esta síntesis) el mismo cap 3 da `artist_conc` 0,598→0,113 y `holisticness@10` 0,018699→0,048063, reproducido dígito a dígito por tres runs registrados de confirmación (run-20260730-235524-0ec1d-seq-blend con el tope apagado, run-20260730-235524-93d38-seq-blend con cap 3, run-20260730-234635-a6252-seq-blend con cap 5), y **endurece en la partición disjunta con 0.64 de fríos** seq-20260718-211238 sobre dos piernas pre-registradas: $\Delta\text{artist_conc}$ -0,52699 [-0,54546, -0,50825] con IC bajo cero y $\Delta\text{music@10}$ +0,02644 [+0,01919, +0,03368] con IC sobre cero, y con la ganancia de relevancia *mayor* en la ventana más fría. Dos cautelas viajan con esto: el recall exacto es la única métrica que regresa en todos los topes, y el umbral absoluto de `music@10` $\geq 0,43$ de la partición canónica **no** se traslada — el control propio de la segunda partición se sitúa en 0,4295 sobre una ventana legítimamente más fría, así que los umbrales deben derivarse por línea base y el pre-registro debe hacerse sobre el Δ pareado.

Cuadro 23: El tope duro por artista en la superficie de un solo disparo, sobre el campeón desplegado ($R'+M+C'$, sin compuerta), partición canónica seq-20260715-131139, $n = 1431$. Medición fuera de run: las puntuaciones se calculan una vez por modelo y se memoizan, así que cada rama de tope ve vectores de puntuación idénticos bit a bit y el emparejamiento es exacto, no meramente apareado (2000 remuestreos, rng 1337). `holisticness@10` es de generación 3 (Sección 18.2). `artist_conc` y `artist_adj` menor es mejor; el resto mayor es mejor. *Fuente: 2026-07-30c-artist-cap-measurement.md.*

cap	R@10	aciertos	MRR	artist_conc	artist_adj	ild	music@10	H@10 (gen-3)
off	0.211740	303	0.121985	0.691653	0.609713	0.406374	0.453790	0.008603
5	0.178896	256	0.119693	0.252613	0.337247	0.563417	0.474291	0.027258
3	0.160727	230	0.116915	0.122975	0.215304	0.613641	0.476787	0.033862
2	0.138365	198	0.112313	0.061946	0.150384	0.639717	0.474317	0.036331

La frontera ancla $\times$ zancada. Con los dos controles de espacio de puntuación en la mano, la pregunta pasa a ser si la *conjunción* es alcanzable en absoluto: una zancada de escucha real

y un vibe sostenido. La Tabla 24 barre 24 celdas — 16 en la GRU, 8 en el campeón, todas con cap 1 — contra una ventana objetivo pre-registrada antes del barrido: paso mediano dentro del centro de la banda real (0,20 a 0,38) y $\text{vibe} \geq 0,50$. Exactamente dos celdas caen dentro, una por motor (Figura 15). La estructura de la rejilla es el hallazgo: los dos controles son genuinamente ortogonales — a ancla fija, subir la zancada baja el paso mediano de forma monótona mientras el vibe decae mucho más despacio — de modo que la ventana solo es alcanzable con ambos activos, y ninguna de las configuraciones despachadas estaba dentro. El ancla del campeón además debe aplicarse en el espacio PCA-192 *crudo* y no en su propia geometría proyectada, y por eso la frontera llega a 0,503 donde la primera sonda se topaba con 0,44.

Cuadro 24: La frontera ancla (a) $\times$ zancada (s), 20 sesiones held-out $\times$ 20 pasos, cap 1, en ambos motores. W_1 menor es mejor; «paso med.» se compara contra el 0,261 real del usuario; **vibe**, géneros y **ground** mayor es mejor; **drift** mejor cuanto más cerca de cero. La ventana es paso mediano $\in [0,20, 0,38]$ y $\text{vibe} \geq 0,50$, pre-registrada antes del barrido; las dos filas que la satisfacen van en negrita. La configuración GRU despachada es $a = 0,4$, $s = 0$; el campeón tal como se despliega es $a = 0$, $s = 0$. Fuente: *tools/walk_frontier.py*.

Motor	a / s	W_1	paso med.	vibe	drift	géneros	ground
GRU	0.0 / 0.0	0.287	0.607	0.286	-0.328	9.70	0.270
GRU	0.0 / 0.3	0.273	-0.018	0.200	-0.157	8.95	0.291
GRU	0.0 / 0.6	0.564	-0.374	0.123	-0.102	12.00	0.244
GRU	0.0 / 1.0	0.702	-0.557	0.084	-0.036	15.80	0.224
GRU	0.2 / 0.0	0.323	0.663	0.563	-0.124	9.40	0.345
GRU	0.2 / 0.3	0.186	0.094	0.426	-0.098	11.05	0.335
GRU	0.2 / 0.6	0.473	-0.251	0.330	-0.067	13.25	0.303
GRU	0.2 / 1.0	0.675	-0.522	0.185	-0.077	15.05	0.253
GRU	0.4 / 0.0 (<i>despachada</i>)	0.361	0.709	0.639	-0.090	9.95	0.349
GRU	0.4 / 0.3	0.104	0.297	0.588	-0.076	11.05	0.358
GRU	0.4 / 0.6	0.356	-0.127	0.437	-0.044	12.55	0.303
GRU	0.4 / 1.0	0.588	-0.405	0.302	-0.027	15.20	0.287
GRU	0.8 / 0.0	0.364	0.713	0.678	-0.067	11.00	0.352
GRU	0.8 / 0.3	0.190	0.506	0.672	-0.070	12.15	0.351
GRU	0.8 / 0.6	0.122	0.176	0.605	-0.038	12.60	0.358
GRU	0.8 / 1.0	0.420	-0.188	0.460	-0.016	14.65	0.335
Campeón	0.0 / 0.0 (<i>desplegado</i>)	0.062	0.318	0.185	-0.203	11.00	0.275
Campeón	0.0 / 0.5	0.240	-0.032	0.104	+0.002	12.15	0.266
Campeón	1.0 / 0.0	0.239	0.577	0.551	-0.138	8.95	0.327
Campeón	1.0 / 0.5	0.072	0.282	0.503	-0.130	9.55	0.324
Campeón	2.0 / 0.0	0.276	0.596	0.625	-0.060	8.90	0.359
Campeón	2.0 / 0.5	0.170	0.472	0.615	-0.105	9.45	0.338
Campeón	4.0 / 0.0	0.300	0.645	0.669	-0.051	9.85	0.338
Campeón	4.0 / 0.5	0.236	0.544	0.664	-0.085	9.70	0.340

19.4. El cara a cara de muestra emparejada

Motivación. Cada uno de los dos barridos anteriores encontró una celda dentro de la ventana, pero en muestras distintas, y W_1 no puede emparejarse — así que las finalistas tenían que volver a correr una contra otra sobre material *idéntico* antes de poder afirmar nada. *tools/walk_headtohead.py* camina cinco ramas sobre las mismas 40 sesiones held-out desde las mismas semillas de 5 pistas, con cap 1, y reporta diferencias de bootstrap pareado (2000 remuestreos, rng 1337) contra la configuración **despachada** — la GRU única con ancla 0,4,




Figura 15: Los dos controles en tiempo de recuperación son ortogonales, y solo su *conjunción* alcanza la ventana objetivo (sombreada: paso mediano $\in [0,20,0,38]$ y *vibe* $\geq 0,50$). Cada línea une un ancla fija a medida que crece la zancada, lo que mueve el viaje hacia la izquierda (pasos más grandes) mientras el *vibe* decae despacio — así que el compromiso es real pero suave. Ninguna configuración despachada está dentro de la ventana: la GRU con $a = 0,4$, $s = 0$ sostiene un *vibe* de 0,639 pero camina a 0,709, y el campeón tal como se despliega camina a 0,318 con un *vibe* de 0,185. 20 sesiones held-out $\times$ 20 pasos, cap 1 (`tools/walk_frontier.py`).

zancada 0 — sobre cinco métricas por sesión: *vibe* (mayor mejor), *stride_err* (menor mejor), *drift* (más cerca de cero), *genres* (mayor) y *ground* (mayor).

Resultados. La Tabla 25 da las medias y la Tabla 26 las diferencias pareadas; la Figura 16 grafica estas últimas con un panel por métrica, cada uno en su propia escala.

Cuadro 25: Medias de las métricas de caminata sobre las 40 sesiones held-out idénticas (20 pasos, cap 1). *stride_err* = |paso mediano − 0,261| (menor mejor); *vibe*, *genres* y *ground* mayor es mejor; *drift* mejor cuanto más cerca de cero. Mejor celda por columna en negrita. *Fuente:* `tools/walk_headtohead.py`.

Rama	vibe	stride_err	drift	genres	ground
GRU despachada, $a0,4$ $s0,0$	0.609	0.399	−0.089	9.925	0.345
GRU ajustada, $a0,4$ $s0,3$	0.568	0.129	−0.080	10.450	0.357
dual latent/latent f0, $a0,8$ $s0,4$	0.638	0.157	−0.063	10.975	0.351
dual latent/cummean f0 , $a0,8$ $s0,5$	0.610	0.144	−0.053	11.425	0.351
Campeón ($R'+M+C'$), $a1,0$ $s0,5$	0.476	0.135	−0.131	9.600	0.334

Interpretación. Lea primero la columna *stride_err*: las cuatro ramas ajustadas la recortan en $\sim 0,25$ con el IC bajo cero, que es simplemente el control de zancada funcionando — el error de 0,399 del motor despachado era $\sim 2,6\times$ el de la siguiente peor rama. La variación interesante es lo que cada rama *paga* por ello. Empujar la GRU única a una zancada real **cuesta** *vibe* (−0,0409, IC bajo cero) y el campeón paga mucho más (−0,1327, IC bajo cero): para estos dos motores zancada

Cuadro 26: Diferencias pareadas por sesión contra la GRU **despachada** ($a0,4$ $s0,0$) sobre las mismas 40 sesiones, 2000 remuestreos de bootstrap, rng 1337. El «veredicto» lee el IC respecto de la dirección buena de cada métrica: **stride_err** es menor-mejor, así que un IC bajo cero es una *victoria*; **drift** arranca negativo en todas las ramas, así que un Δ positivo lo acerca a cero. Victorias en negrita. *Fuente: tools/walk_headtohead.py.*

Rama	Métrica	Δ [IC 95 %]	Veredicto
GRU ajustada $a0,4$ $s0,3$	vibe	-0.0409 [-0.0602, -0.0221]	IC<0: <i>cuesta vibe</i>
	stride_err	-0.2695 [-0.3058 , -0.2358]	IC<0: victoria
	drift	+0.0089 [-0.0255, +0.0420]	cruza el cero
	genres	+0.525 [-0.475, +1.500]	cruza el cero
	ground	+0.0116 [-0.0143, +0.0408]	cruza el cero
dual latent/latent f0 $a0,8$ $s0,4$	vibe	+0.0297 [+0.0146 , +0.0468]	IC>0: victoria
	stride_err	-0.2423 [-0.2790 , -0.2053]	IC<0: victoria
	drift	+0.0259 [-0.0011, +0.0521]	cruza el cero
	genres	+1.050 [+0.250 , +1.876]	IC>0: victoria
	ground	+0.0060 [-0.0172, +0.0314]	cruza el cero
dual latent/cummean f0 $a0,8$ $s0,5$	vibe	+0.0013 [-0.0151, +0.0180]	cruza el cero: <i>sostenido</i>
	stride_err	-0.2545 [-0.2962 , -0.2127]	IC<0: victoria
	drift	+0.0351 [+0.0071 , +0.0627]	IC>0: victoria
	genres	+1.500 [+0.500 , +2.500]	IC>0: victoria
	ground	+0.0059 [-0.0163, +0.0285]	cruza el cero
Campeón ($R'+M+C'$) $a1,0$ $s0,5$	vibe	-0.1327 [-0.1629, -0.1041]	IC<0: <i>cuesta vibe</i>
	stride_err	-0.2638 [-0.3120 , -0.2155]	IC<0: victoria
	drift	-0.0422 [-0.0983, +0.0093]	cruza el cero
	genres	-0.325 [-1.500, +0.876]	cruza el cero
	ground	-0.0115 [-0.0467, +0.0236]	cruza el cero

y vibe están en tensión, exactamente como predecía la pendiente suave pero real de la frontera. Ambas ramas de torre doble escapan del compromiso. **latent/latent** con $a0,8$ $s0,4$ *gana* vibe (+0,0297, IC sobre cero) y géneros (+1,05, IC sobre cero) igualando la zancada; **latent/cummean** con $a0,8$ $s0,5$ sostiene el vibe (+0,0013, cruzando el cero — sostenido, no canjeado) y es la única rama con *tres* victorias, añadiendo 1,5 géneros (IC sobre cero) y la única mejora significativa de deriva (+0,0351, IC sobre cero, es decir: el viaje termina más cerca de donde empezó). Sobre el objetivo tal como está enunciado — secuencias que sostienen un mood y exploran géneros — **latent/cummean** es la ganadora, y la GRU única que de hecho se despachó no está siquiera en la frontera.

19.5. La reversión de la torre doble, y lo que el registro ya sabía

Vale la pena decirlo sin rodeos, porque es el resultado metodológico más consecuente de este documento: **la familia de torre doble fue cerrada por tres campañas por motivos de recall y es la ganadora sobre el objetivo enunciado.** La Sección 16 la refutó en toda la matriz de vistas {latent,delta,cummean}²; la rama **cummean/cummean** llegó incluso a marcarse como *degenerada* por encabezar la holisticidad de generación 1 con Recall@10 0,066. Todos esos juicios se emitieron sobre exactitud de pista siguiente de un solo disparo, y ninguno es erróneo en esa superficie — la reversión no corrige los veredictos de recall, sino que demuestra que respondían a otra pregunta. El análisis de potencia de la Sección 18.1 hace compatibles ambas lecturas en lugar de contradictorias: lo que la campaña de torre doble estableció fue la ausencia de una ganancia




Figura 16: El cara a cara de muestra emparejada, un panel por métrica en su propia escala — deliberadamente sin eje doble, que insinuaría una comparabilidad que estas cinco cantidades no tienen. El verde es un IC enteramente en el lado bueno de la métrica, el rojo enteramente en el lado malo, el gris cruza el cero. Todas las ramas compran la zancada real; solo las ramas de torre doble la compran sin pagar vibe, y **ground** cruza el cero en *todas* las ramas.

grande de recall, lo cual es plenamente consistente con que la familia sea mejor en algo que la métrica de recall no mide.

La corroboración ya estaba en el registro, archivada como negativa. La nota de interpretabilidad en `predictors/seq_dualgru.py:113` recoge que la torre **cummean** «añadió direcciones lineales reales (CKA 0,458) pero **cero** conceptos de siguiente ítem que la torre A no tuviera». Leído como resultado de pista siguiente eso es peso muerto, y así quedó anotado. Leído en la superficie de la caminata es la parte útil: una torre cuyo contenido es ortogonal a la predicción del siguiente ítem es exactamente una torre que transporta *estado de sesión* en vez de adyacencia. Dos hechos estructurales completan la explicación. La familia recupera en el espacio de latentes de ítem *crudo*, sin proyección aprendida, así que un ancla de mood en espacio crudo es nativa a su geometría — a diferencia del campeón, cuya proyección InfoNCE despoja precisamente la estructura de similitud sonora que un ancla necesita. Y una de las ramas promovidas lee la *media causal* del prefijo, que estructuralmente es una señal de promedio móvil.

Una sub-hipótesis queda refutada. La predicción natural a partir de lo anterior — que la torre **cummean** sostiene un vibe de forma *nativa* — es falsa: con los dos controles apagados su vibe es 0,236, estadísticamente indistinguible del 0,234 de **latent/latent**. La arquitectura no aporta el sostén del mood por sí sola; solo se convierte en el mejor anfitrión para uno una vez aplicados el ancla y la zancada. Es una afirmación más débil y más interesante que la que sugería el argumento estructural, y es la que la medición respalda.

19.6. Despliegue, y lo que no queda establecido

La rama de torre doble ajustada es ahora el **motor por defecto** del showcase, exportada como **dualgru.onnx** (3,16 MB) con una paridad ONNX frente a torch de 1×10^{-7} en toda longitud de prefijo $T = 1 \dots 40$ — la suma acumulada de **cummean** era el riesgo del trazado, y es la razón por la que la comprobación de paridad barrió T en vez de muestrearlo. La GRU única se conserva al lado para comparación, y el ancla/zancada ajustados viven en el manifiesto de despliegue y no en

el código, así que re-ajustar es un re-horneado y no una edición de código. El campeón de blend fue retirado del showcase de extremo a extremo: servido desde un Worker su caminata costaba $\sim 0,94$ s de CPU por lote de 8, unas $100\times$ el tope de CPU de 10ms del plan gratuito en el que el showcase está desplegado, y el loteo no puede rescatar un paso único que ya cuesta ~ 117 ms.

Lo que esta sección *no* establece. Cuatro límites, dichos sin rodeos. **(1)** `ground` cruza el cero en *todas* las ramas (Tabla 26), así que ninguna rama queda establecida como mejor prediciendo la continuación real — las victorias son sobre la *forma* del viaje, y la barandilla de anclaje solo confirma que ninguna rama se degradó hacia una irrelevancia agradable. **(2)** Una partición, una semilla, 40 sesiones de 20 pasos; las métricas de caminata no han tenido endurecimiento en segunda partición del tipo que la Sección 12.1 aplica a la corona de recall, y la ventana objetivo misma se eligió a partir de la dispersión del primer barrido. **(3)** Nada de esto se ha *escuchado*. Toda afirmación es una afirmación geométrica sobre cosenos en un espacio PCA-192, y «sostiene un mood» está operacionalizado como «se mantiene cerca de un centroide de semilla», que es una hipótesis sobre la percepción y no una medición de ella. **(4)** La métrica principal del proyecto está **sin cambios**: `holisticness@10` sigue siendo `[metrics].primary` y el tablero de este documento sigue denominado en Recall@10 (Sección 18.2). Si las métricas de caminata deben pasar a ser principales es una decisión abierta, no zanjada — y hasta que se zanje, el resumen honesto es que la superficie de la caminata ya es *medible*, y que sobre ella gana una familia refutada. *Fuentes*: `2026-07-30c-artist-cap-measurement.md`, `PROJECT-FACTS.md` (roll-up 2026-07-31b), `tools/walk_eval.py`, `tools/walk_frontier.py`, `tools/walk_dualgru.py`, `tools/walk_headtohead.py`.

20. Conclusiones

Quince campañas (jul 2026) sobre la tarea de recuperación de pista siguiente convergen en una historia clara. (1) Un modelo de secuencias de sesión, incluso en su mejor forma (GRU-infonce), solo *empata* con la barra de Markov de co-escucha de primer orden en recall@10 y pierde en MRR: predecir un latente del siguiente ítem y recuperar por un salto coseno es una ruta más difícil a la pista siguiente exacta que un bigrama que memoriza la adyacencia directamente. (2) La *pérdida* de entrenamiento es la palanca individual dominante (InfoNCE $\approx 2,3\times$ el coseno); la *topología* de red — profundidad, anchura, residual, dirección — es una palanca agotada, y ninguna arquitectura supera la barra. (3) El avance es la *fusión de rankings*: un z-blend R+M de las ramas GRU y Markov supera la barra en $\sim +61\%$ de recall@10 (confirmado con 3 semillas), porque las dos ramas ordenan pistas correctas *distintas*. La victoria es sobre *diversidad* de señal, no número de modelos — añadir una rama neuronal redundante no ayuda, y un stacker XGB aprendido *rinde por debajo* del z-blend fijo, porque su entrenamiento puntual no captura el objetivo de ranking. (4) Un barrido de representación de ítems halló que la *dimensión* latente, no el compresor, es la palanca: el PCA lineal supera al autoencoder no lineal en toda dimensión ≥ 64 (la hipótesis de preservación acústica queda refutada), la curva hace pico en PCA-192 y se revierte hacia 256, y PCA-128 es la base individual confirmada. (5) Sobre el espacio PCA rico la única señal nueva genuinamente aditiva — *content-kNN*, que solo *empató* al campeón sobre el espacio AE-64 — se vuelve una victoria: un z-blend R+M+C de tres ramas sobre PCA-192 es la fila «mejor registrada» actual con recall@10 0,1859, MRR 0,1025 (Δ pareado sobre el campeón previo +0,0133, IC por encima de cero, confirmado a través de cinco reproducciones). (6) Dos salvedades honestas acotan la coronación: la confirmación por reproducción tuvo dispersión cero porque `seq-nexttrack` es determinista en esta CPU (así que verifiqué determinismo, no robustez a la semilla), y el límite inferior del paired- Δ

supera cero por solo +0,0007 en una única partición — endurecerla requiere una segunda partición de prueba sin fugas. (7) Todo predictor de ranking aquí es solo de entrenamiento y fuera del servidor, así que la coronación es una fila «mejor registrada», no un modelo promovido y exportable a la app; el campeón previo R+M sobre AE-64 sigue siendo el ancla de productización, y registrar un blend de tres ramas con un subcomando `predict` es el trabajo futuro principal vigente. (8) Una campaña posterior de ajuste-a-la-literatura *superó* luego la coronación con la primera señal nueva genuinamente aditiva desde el contenido: una *proyección de contenido aprendida* supervisada ($R'+M+C'$), un mapa métrico InfoNCE del espacio de ítems PCA-192 ajustado hacia la adyacencia de pista siguiente en el que recuperan tanto la GRU como la rama de contenido, con `recall@10` 0,2117, `MRR` 0,1220 (paired Δ sobre R+M+C +0,0259, $IC>0$). Resuelve ambas salvedades de R+M+C — es robusta a la semilla a través de tres semillas y alcanza ítems fríos (su rama de contenido puntúa objetivos fríos tan bien como cálidos) — y fue *registrada, promovida y servible* (`blend-gru-markov-content-proj`, rango 1 del grupo de mejores modelos), cerrando la brecha de productización; un barrido de objetivo / rango / τ confirma InfoNCE $\gg$ BPR y mantiene el default, y la coronación luego se endureció en una segunda partición disjunta con 0.64 de fríos (paired Δ +0,0426, $IC>0$, el margen *más ancho* en la partición más fría). Todo método prestado de ajuste-a-la-literatura (session-kNN, fusión de rankings / combinadores aprendidos, trucos de pérdida del lado GRU, suavizado de Markov) se cerró — la única ganancia aditiva vino de señal nueva, no de fusión más astuta. (9) Una exploración de representación del vector de ítem confirmó luego *por qué* la proyección es el campeón: la geometría PCA-192 de peso igual es un lastre real para un modelo crudo (seis de ocho espacios whitened / drop-acústico / métricos elevan la GRU congelada, IC del Δ pareado > 0), pero la ganancia es *absorbida* por completo por la proyección aprendida (ningún espacio supera al campeón en readout A) — el whitening y la proyección son el mismo arreglo, y el campeón ya lo accionó. (10) Finalmente, se introdujo una métrica continua de tipo “suena parecido”, *music@10*, y se back-filleó a través de los 53 runs: correlaciona con `recall@10` ($r = 0,609$) pero corona a un ganador distinto (el `seq-nexttrack` que regresa contenido aterriza los fallos más cercanos musicalmente, mejor 0,482), corroborando los hallazgos de `recall` exacto sin revertirlos; es solo de visualización y la métrica principal sigue siendo `recall@10`. (11) Finalmente, una campaña de medición añadió una suite *solo de visualización* de holisticidad de sesión (`artist_adj@10` / `mood_coh@10` / `ild@10`) y dos palancas anti-eager. Encontró que el síntoma de eagerness *sigue* a `Recall@10` dentro de la familia de blends — el campeón es el modelo más artist-eager (`artist_adj@10` 0,610) — pero la eagerness proviene de la pata de bigrama de *Markov*, no de la RNN (GRU / LSTM individuales con `artist_adj@10` $\approx 0,345$), y la GRU y la LSTM están estadísticamente empatadas tanto en `recall` como en eagerness (la hipótesis “la GRU gana por ser más eager” queda refutada). De las dos palancas, el re-ranqueo MMR en evaluación es la palanca fuerte ($\lambda=0,9$ casi gratis: `recall` empate, `ild@10` 0,406 $\rightarrow$ 0,436; $\lambda \approx 0,7$ des-eagers por ~ 2 puntos de `recall`; *music@10* incluso sube al diversificar la lista) mientras que el regularizador β de entrenamiento es débil (β 0 a 0,2 mueve `artist_adj@10` solo $-0,0074$); no se promovió nada, y $\lambda \approx 0,9$ queda señalado para una futura decisión de holisticidad del usuario (Sección 15). (12) Dos campañas finales de arquitectura cerraron después los últimos ejes de arquitectura abiertos, y ambas son nulos — pero nulos con mecanismo. Una GRU de *torre doble* entrenada conjuntamente, cruzando la matriz completa de vistas $\{\text{latent}, \text{delta}, \text{cummean}\}^2$ contra una torre única emparejada en parámetros al 0,098 %, no logra superar a esa torre en ninguna de ocho ramas (Sección 16). Este es el *cuarto* nulo independiente de combinador aprendido y el que más importa, porque responde a la objeción permanente a los tres anteriores («por supuesto que falla un combinador atornillado encima: entrenad la fusión de extremo a extremo»): entrenada de extremo a extremo a nivel de representación, sigue fallando. El mecanismo es que la vista `latent`

cruda ya *subsume* a las otras — una GRU sobre latentes crudos integra internamente el movimiento y la media acumulada, y el único par genuinamente complementario es `delta+cummean`, que supera a sus dos padres pero es desesperado en términos absolutos. Dos subproductos son duraderos: la cabeza MLP de fusión es activamente *perjudicial* (quitarla gana en todos los regímenes medidos, tres veces, Tabla 19), y la anchura de GRU única queda ahora cerrada en PCA-192 como ya lo estaba en AE-64. Un *pre-codificador* por paso aprendido falla luego con más contundencia (Sección 17): la ablación decisiva de torre única *pierde* sin paliativos ($-0,0140$, IC por debajo de cero, 156 aciertos contra 176), la curva de dosis es plana hasta el doble de la dimensión de entrada y la colocación es irrelevante. Como un pre-codificador *lineal* es aquí demostrablemente neutro en expresividad, el rectificador es la única causa candidata — y una lectura contrafactual de interpretabilidad lo confirmó, midiendo el mapa afín como neutro en $\sim 0,8\sigma$ y la ReLU costando $\sim 5,9\sigma$, con `frac_exact_zero` 0,5327 coincidiendo con `frac_negative_coords` 0,5327 hasta cuatro dígitos: la rectificación de media onda de un latente centrado en cero borra exactamente su mitad negativa. A lo largo de cinco nulos de arquitectura el patrón es ya difícil de descartar: en este corpus de un solo usuario con 55 % de ítems fríos, añadir maquinaria de representación *alrededor* de una GRU única sobre un buen espacio latente no ayuda, mientras que toda ganancia real vino de mejorar el propio espacio latente o del z-blend fijo. (13) Por último, dos hechos sobre el *instrumento* y no sobre ningún modelo reencuadran todo el arco de arquitectura (Sección 18). Los nulos están **limitados por potencia**: con $n = 1431$ el semiancho del IC de bootstrap pareado es 0,0124 en Recall@10 y $\sim 0,0018$ en *holisticness*@10, mientras que una familia de arquitectura completa abarca solo 0,028 y 0,0031 — así que de ocho ramas adyacentes son separables unos dos niveles en recall y uno en *holisticidad*, y resolver una diferencia de 0,005 exigiría ~ 8800 sesiones. La lectura honesta es por tanto que *los daños grandes se detectaron con fiabilidad mientras las victorias moderadas nunca fueron detectables*, lo cual es una afirmación distinta de «estas arquitecturas no funcionan» y produce una regla de priorización: más ramas de arquitectura son un mal uso de las ejecuciones en esta partición, den lo que den, porque todo el rango dinámico del eje apenas duplica el error de medición. Y *holisticness*@10 existe en tres generaciones de código mutuamente no comparables (3 factores; 4 factores anclada; anclada más concentración de artista), cuyas diferencias empequeñecen a toda diferencia entre modelos y bajo todas las cuales el campeón servible queda *último* — así que esta síntesis mantiene su tablero denominado en Recall@10 y etiqueta cada columna de *holisticidad* con su generación (Tabla 21). (14) Por último, una campaña sobre la *superficie* y no sobre el modelo descubre que el tablero anterior había estado puntuando la superficie equivocada (Sección 19). Todo lo demás en este documento es un top-10 de un solo disparo, mientras el producto despachado sirve una *caminata* autorregresiva — y la `mood_coh` de *holisticness*@10 se ancla al centroide del *prefijo*, que en una caminata crece con el viaje, así que una serie de pasos individualmente legales que acaba en la región opuesta del espacio puntúa bien en cada paso: la deriva era invisible por construcción, y la composición es además $5,5\times$ más sensible a la relevancia que a la *eagerness*. Calibrado contra las 73 632 transiciones consecutivas del propio usuario (coseno de paso mediano 0,261, 27,0 % negativas), el motor que el showcase despachó camina $2,5\times$ demasiado ceñido (paso mediano 0,661) — «plano a pesar de tener muchos artistas» eran muchos movimientos pequeños y seguros — mientras el campeón de blend iguala la zancada real pero no logra sostener un mood, porque su proyección InfoNCE codifica qué *sigue* y no qué *suen*a parecido. Tres controles deterministas en tiempo de recuperación arreglan la alcanzabilidad: un ancla de semilla, un término de zancada (determinista a propósito — el muestreo rompería la garantía del permalink) y un tope *duro* por artista, que triunfa exactamente donde fallaron las dos palancas anti-eager blandas porque no puede ser superado por puntuación (en la playlist patológica 59 de los 60 primeros candidatos son un mismo artista y el siguiente artista está en el puesto 75, contra un presupuesto de diversidad

de MMR que vale $\approx 0,078$ de puntuación normalizada; `eager_beta` está mal especificado sobre un coseno absoluto cuando la eagerness es una propiedad de *ordenamiento*). El tope endurece en dos particiones disjuntas y, de forma inesperada, *eleva music010* en todos sus ajustes: cambia relevancia literal por relevancia graduada. Y sobre 40 sesiones held-out idénticas con bootstrap pareado, **la familia de torre doble, cerrada por tres campañas por motivos de recall, es la ganadora sobre el objetivo enunciado** — `latent/cummean` con ancla 0,8 y zancada 0,5 logra error de zancada $-0,2545$, géneros $+1,50$ y deriva $+0,0351$ con todos los IC lejos de cero mientras *sostiene* el vibe, donde la GRU única ($-0,0409$) y el campeón ($-0,1327$) pagan vibe por la misma zancada. La corroboración ya estaba en el registro como *negativa* (`seq_dualgru.py:113`: la torre `cummean` «añadió direcciones lineales reales (CKA 0,458) pero cero conceptos de siguiente ítem que la torre A no tuviera») — peso muerto para predecir la pista siguiente es exactamente estado de sesión para sostener un mood, aunque la lectura fuerte queda refutada: `cummean` *no* sostiene un vibe de forma nativa (0,236 frente a 0,234), solo aloja uno una vez aplicados los controles. Está desplegada como motor por defecto del showcase; y `ground` cruza el cero en todas las ramas, así que lo establecido es la *forma* del viaje, no la verdad de la pista siguiente, sobre una partición, una semilla y 40 sesiones, sin que nada se haya escuchado todavía y con la métrica principal sin cambios.

21. Informes fuente

Esta síntesis consolida quince informes de campaña de pista siguiente de `experiments/`:

- `2026-07-13-nexttrack-sequence-sweep.md` — la campaña fundacional de pista siguiente: un barrido de secuencias GRU/LSTM contra la barra de Markov de primer orden; la mejor GRU-infonce empata en R@10 pero pierde en MRR (Sección 4).
- `2026-07-13-nexttrack-topology-scan.md` — el barrido de topología profundidad / anchura / residual / bidireccional; la arquitectura es una palanca agotada, todas las ramas quedan bajo la barra de Markov (Sección 5).
- `2026-07-14-nexttrack-blend-and-ensemble.md` — el z-blend R+M GRU×Markov supera la barra en +61 % de R@10 (el primer campeón de pista siguiente); ningún ensamble más rico lo mejora y el stacker XGB aprendido rinde por debajo (Sección 6).
- `2026-07-14-nexttrack-graded-relevance-and-new-legs.md` — métricas de relevancia graduada de primera clase (`artist@k` / `genre@k` / `artist_mrr`) y nuevos aprendices base leak-free; content-kNN es la única señal aditiva, empatando al campeón sobre AE-64 (Sección 7).
- `2026-07-15-nexttrack-compression-representation-bakeoff.md` — el bake-off de compresión de la representación de ítems (PCA frente a autoencoder × dimensión latente 32/64/128) bajo un readout GRU congelado; PCA-128 es el ganador GRU-individual pero la victoria no se traslada al blend (Sección 8).
- `2026-07-15b-nexttrack-compression-dim-extension.md` — el barrido de dimensión PCA/AE extendido a 192/256; la curva hace pico en PCA-192 y se revierte, así que PCA-128 se mantiene como la base de la Fase 2 (Sección 9).
- `2026-07-15c-nexttrack-phase2-model-sweep.md` — el barrido de familia de modelos sobre los espacios PCA ricos; el z-blend fijo supera al stacker aprendido, la LSTM es el mejor

modelo individual, y R+M+C sobre PCA-192 se corona como la nueva fila «mejor registrada» (Sección 10).

- `2026-07-18-nexttrack-literature-fit-campaign.md` — una exploración guiada por bibliografía; una proyección de contenido aprendida supervisada ($R'+M+C'$) es la nueva fila «mejor registrada» (R@10 0,2117, paired Δ sobre R+M+C +0,0259 IC>0, robusta a la semilla, alcanza fríos), y cada método prestado (session-kNN, fusión de rankings, combinador aprendido, suavizado de Markov, negativos por importancia de GRU) se cierra (Sección 11).
- `2026-07-18b-nexttrack-projection-registration-and-scan.md` — la proyección reproducida on-server, registrada + promovida + servible como `blend-gru-markov-content-proj` (rango 1 del grupo de mejores modelos); un barrido de objetivo / rango / τ (InfoNCE $\gg$ BPR; default mantenido) y endurecimiento en segunda partición sobre una partición disjunta con 0.64 de fríos (paired Δ +0,0426 IC>0) (Sección 12).
- `2026-07-18c-nexttrack-representation-exploration.md` — una auditoría de representación del vector de ítem; la geometría PCA-192 de peso igual lastra la GRU cruda (seis de ocho espacios alternativos la elevan IC>0) pero la ganancia es absorbida por la proyección (ningún espacio supera al campeón en readout A) (Sección 13).
- `2026-07-20-musical-distance-metric.md` — la métrica continua de tipo “suena parecido” music@10 y su backfill offline de 53 runs; correlaciona con recall@10 ($r = 0,609$) pero corona a un ganador distinto, el `seq-nexttrack` que regresa contenido (Sección 14).
- `2026-07-22-session-holisticness-and-antieager-levers.md` — una suite solo de visualización de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10) y dos palancas anti-eager (MMR en evaluación `mmr_lambda`, y `eager_beta` de entrenamiento); el campeón es el modelo más artist-eager, la eagerness proviene de la pata de Markov, $GRU \approx LSTM$, y MMR λ es la palanca fuerte (Sección 15).
- `2026-07-25-nexttrack-dual-tower-fusion-scan.md` — el escaneo de emparejamiento de vistas $\times$ profundidad de fusión en torre doble contra una torre única emparejada en parámetros al 0,098%; **REFUTADO** (el cuarto nulo de combinador aprendido, y el que cierra la objeción de «entrenad la fusión de extremo a extremo»), mostrando que la vista de latentes crudos subsume a `delta/cummean`, que la cabeza MLP de fusión es activamente perjudicial, que la anchura de GRU única queda cerrada en PCA-192, y que holisticidad y recall están anticorrelacionados en todo el lote (Sección 16).
- `2026-07-26-nexttrack-pre-encoder-scan.md` — el escaneo del pre-codificador por paso aprendido (presencia $\times$ colocación $\times$ dosis) con la ablación decisiva de torre única; **REFUTADO y activamente perjudicial** (−0,0140 de Recall@10, IC por debajo de cero), con el rectificador identificado analíticamente y luego medido (mapa afín neutro en $\sim 0,8\sigma$, ReLU en $\sim 5,9\sigma$, `frac_exact_zero` = `frac_negative_coords` = 0,5327), más el análisis de potencia medido y las tres generaciones de holisticidad (Secciones 17 y 18).
- `2026-07-30c-artist-cap-measurement.md` — el *tope duro por artista*, la primera palanca de des-eagerización que funciona, y funciona porque no puede ser superada por puntuación: `artist_conc@10` 0,692→0,123 con `music@10` *subiendo* (IC sobre cero) en todos sus ajustes, endurecida en una segunda partición disjunta con 0.64 de fríos, junto con las refutaciones de las dos palancas blandas a las que sustituye (Sección 19.3). El material a nivel de caminata de

la Sección 19 — el desajuste de superficie, las cuatro métricas de caminata, la frontera ancla $\times$ zancada, el cara a cara de muestra emparejada y la reversión de la torre doble — está transcrito del roll-up de `PROJECT-FACTS.md` de 2026-07-31b y de las cuatro herramientas de medición que este cita (`tools/walk_eval.py`, `walk_frontier.py`, `walk_dualgru.py`, `walk_headtohead.py`), cuyos docstrings de módulo son la autoridad sobre cómo se calcula cada métrica; ese material aún no tiene informe de campaña propio.