

Recomendación de Pista Siguiente en Sesión: Síntesis de Experimentos

22 de julio de 2026

Resumen

Este documento es la síntesis viva de las campañas de recomendación de *pista siguiente* (next-track); los informes markdown de `experiments/` (con `nexttrack` en el nombre) son el registro primario. La tarea es *recuperación* (retrieval) del siguiente ítem: dada una *sesión* de escucha (una secuencia ordenada de pistas), ordenar el catálogo y recuperar la siguiente pista distinta que el usuario reprodujo realmente, evaluada sobre una única partición cronológica sin fugas (leak-free) *next-distinct* (7154 sesiones / 19 402 ítems; 5723 entrenamiento / 1431 prueba; tasa de ítems fríos (cold-item) 0,55). La métrica principal es recall@10, reportada junto al rango recíproco medio (MRR) y los diagnósticos de relevancia graduada artist@10 / genre@10 / artist_mrr. Se consolidan doce campañas. Una GRU de sesión por sí sola solo *empata* con la barra de Markov de co-escucha de primer orden (R@10 0,1069) en recall@10 y pierde en MRR, y ni el ajuste de la función de pérdida ni ninguna topología de red (profundidad, anchura, residual, dirección) la superan. El avance es la *fusión de rankings*: un z-blend R+M (GRU $\times$ Markov) supera la barra en $\sim +61\%$ de recall@10 (0,1726, confirmado con 3 semillas), porque las dos ramas ordenan pistas correctas *distintas*; un stacker XGB aprendido rinde por debajo del z-blend fijo y añadir ramas neuronales redundantes no ayuda. La única señal genuinamente aditiva es el *contenido*: un barrido de representación de ítems halló que la *dimensión* latente (no el compresor) es la palanca, con un pico en PCA-192, y sobre ese espacio rico un z-blend R+M+C de tres ramas (GRU $\times$ Markov $\times$ content-kNN) es la fila «mejor registrada» actual con recall@10 0,1859, MRR 0,1025. Una campaña posterior de ajuste-a-la-literatura superó luego esa coronación: una *proyección de contenido aprendida* supervisada ($R'+M+C'$), que ajusta un mapa métrico lineal del espacio de ítems PCA-192 hacia la adyacencia de pista siguiente por InfoNCE y recupera las ramas GRU y de contenido en él, alcanza recall@10 0,2117, MRR 0,1220 (paired Δ sobre R+M+C +0,0259, IC por encima de cero), es *robusta a la semilla* a través de tres semillas y *alcanza ítems fríos*, y se endurece en una segunda partición disjunta con 0.64 de fríos (paired Δ +0,0426, IC por encima de cero) — resolviendo las dos salvedades delgadas (confirmación solo-determinista, margen +0,0007) que acotaban la coronación R+M+C. A diferencia de todo predictor de ranking previo, está registrada, promovida y es *servible* (`blend-gru-markov-content-proj`, rango 1 del grupo de mejores modelos), cerrando la brecha de productización; una exploración de representación del vector de ítem y una métrica continua *music@10* de tipo “suena parecido” corroboran al campeón sin destronarlo. Una campaña final de medición añade una suite *solo de visualización* de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10) que toma la huella del campeón como el modelo *más* artist-eager medido (artist_adj@10 0,610) — con la eagerness proveniente de su pata de bigrama de Markov, no de la RNN, y la GRU y la LSTM estadísticamente empatadas — y encuentra que un re-ranqueo MMR en evaluación ($\lambda \approx 0,9$) es una palanca de holisticidad casi gratis, mientras que un regularizador anti-eager de entrenamiento es débil; no se promueve nada y la métrica principal sigue siendo Recall@10.

1. Introducción

Este documento es la síntesis viva de las campañas de recomendación de pista siguiente; los informes markdown de **experiments/** son el registro primario. Cada sección transcribe (nunca recalcula) los resultados cuantitativos de una campaña, preserva sus identificadores de ejecución y de dataset de forma literal para trazabilidad, y añade la motivación y la interpretación que los informes escuetos omiten. Esta instancia se clonó de un laboratorio hermano de ajuste de gusto / rotación y se reorientó a un objetivo de ranking de secuencias; las campañas de rotación son una línea de trabajo separada y *no* se cubren aquí.

Tarea y partición. El laboratorio predice, dentro de una *sesión* de escucha, qué pista reproduce el usuario a *continuación* — una tarea de recuperación del siguiente ítem. El modelo consume el prefijo ordenado de la sesión y puntúa cada ítem del catálogo; los candidatos se ordenan y la siguiente pista *distinta* retenida es el objetivo (una evaluación leave-last-out que excluye los ítems del prefijo, siguiendo la convención de paridad con Markov). Todo el trabajo corre sobre un único artefacto de secuencias, **seq-20260713-014226** (7154 sesiones / 19 402 ítems), particionado *cronológicamente por inicio de sesión* en 5723 entrenamiento / 1431 prueba en el corte 2024-08-24. La propiedad definitoria de esta partición es su **tasa de ítems fríos de 0,55**: más de la mitad de las pistas objetivo de las sesiones de prueba nunca aparecen en ninguna sesión de entrenamiento. Esta es la realidad de predicción hacia adelante sin fugas, y acota el recall absoluto por construcción — cada resultado se lee contra la barra base incumbente, nunca un número absoluto.

Métricas. La métrica principal es **recall@10** (R@10, la fracción de sesiones de prueba cuya siguiente pista retenida aparece entre las diez recuperadas), reportada junto al **rango recíproco medio** (MRR, el inverso medio del rango de la siguiente pista verdadera) y recall@20. Desde 2026-07-14 la evaluación también emite métricas de *relevancia graduada* de primera clase sobre el mismo ranking con prefijo excluido (Sección 7): **artist@k** (algún candidato del top- k comparte el artista de la siguiente pista verdadera), **genre@k** (análogamente sobre el género primario) y **artist_mrr** (MRR del primer candidato del mismo artista). Todos los intervalos de confianza son IC bootstrap al 95 % sobre 2000 remuestreos de las 1431 sesiones de prueba, y el estadístico decisivo es el Δ *pareado* por sesión contra una referencia nombrada. Una *victoria* de tabla requiere superar la referencia en *ambos* R@10 y MRR más allá de IC marginales no solapados (la barra estricta), seguido de una confirmación por reproducción; el test de paired- Δ con IC-enteramente-mayor-que-cero es el estadístico alternativo más potente (coronó a ambos campeones) y puede discrepar de la barra estricta. Las métricas graduadas son el marcador honesto: el recall exacto es modesto por construcción, pero el campeón acierta el *artista* correcto en el top diez $\sim 32\%$ de las veces y el *género* correcto $\sim 40\%$ — mucho más útil que el número exacto de $\sim 17\%$ que impone la tasa de ítems fríos. Desde 2026-07-20 la tabla también incluye **music@10**, una métrica graduada continua de tipo “suena parecido” (Sección 14): el coseno máximo medio, en un espacio intrínseco balanceado de distancia musical, entre la siguiente pista verdadera y los diez candidatos recuperados — un superconjunto suave de recall@10 que acredita aterrizar algo que *suena como* la verdad en un fallo exacto. Es solo de visualización; la métrica principal sigue siendo recall@10.

El campeón vigente. La fila «mejor registrada» actual — y, desde 2026-07-18, un modelo *registrado, promovido y servible* — es una *proyección de contenido aprendida* supervisada, $R' + M + C'$: una GRU de sesión $\times$ un modelo de co-ocurrencia de Markov de primer orden $\times$ una rama content-kNN, donde la GRU (R') y la rama de contenido (C') recuperan en un mapa métrico InfoNCE

del espacio de ítems PCA-192 ajustado hacia la adyacencia de pista siguiente, con R@10 0,2117, MRR 0,1220 (Secciones 11–12). Supera al z-blend de tres ramas $R+M+C$ sobre el mismo espacio PCA-192 (R@10 0,1859; Sección 10), que a su vez había destronado al z-blend de dos ramas $R+M$ sobre el espacio del song-autoencoder de 64 dimensiones (AE-64, R@10 0,1726; Sección 6). La proyección es *robusta a la semilla* y *endurecida en dos particiones*, y es desplegable vía `POST /api/models/blend-gru-markov-content-proj/predict` — cerrando la brecha de productización que dejaban los drivers de fusión fuera del servidor previos. Los campeones previos siguen siendo referencias útiles (R+M sigue siendo el blend de dos ramas más ligero), pero ya no son el ancla desplegable.

2. Trasfondo: la tarea de secuencias, las líneas base y las métricas

Esta sección da la teoría mínima para un lector que conoce machine learning pero no este repositorio. Está anclada al archivo vivo de hechos del proyecto y crece solo cuando una nueva familia de predictores o métrica entra en los informes.

Los modelos y líneas base en juego.

GRU / LSTM de sesión (seq-nexttrack). Una red neuronal recurrente que lee el prefijo ordenado de la sesión un ítem a la vez (cada ítem representado por su vector latente) y emite un latente predicho del siguiente ítem; los candidatos se ordenan por similitud coseno a esa predicción. La GRU (gated recurrent unit) y la LSTM (long short-term memory) son las dos celdas recurrentes probadas. La recurrencia captura el *contexto de sesión* — la trayectoria de la sesión de escucha — en lugar de un único ítem previo.

Función de pérdida: InfoNCE frente a coseno. El modelo de secuencias puede entrenarse para regresar el latente del siguiente ítem por pérdida *coseno* (acercar la predicción al latente verdadero) o por **InfoNCE**, un objetivo contrastivo que acerca la predicción al ítem verdadero y la aleja de un lote de negativos. InfoNCE es la palanca individual más importante de todo el arco: es $\approx 2,3\times$ el coseno en recall@10, porque la recuperación por ranking premia una representación que *separa* el siguiente ítem verdadero de los distractores, lo que una pérdida contrastiva optimiza directamente y una regresión puntual no.

Co-ocurrencia de Markov de primer orden (la barra, B2). Un modelo de transición solo de entrenamiento: un `track_bigram` que cuenta “qué pista sigue a qué” con back-off por artista/género para pares no vistos (el término de transición que la app hermana ya despacha). Memoriza la adyacencia directamente, que es exactamente lo que premia el ranking exacto de la siguiente pista, y es la barra de referencia contra la que se mide cada rama. También se probó un Markov de segundo orden (trigrama) con back-off y es esencialmente neutral — las sesiones son demasiado cortas/dispersas para que un trigrama dispare, así que cae al bigrama.

item2vec. Un embedding skip-gram (SGNS) de co-escucha entrenado solo sobre las sesiones de *entrenamiento* (un análogo leak-safe de word2vec, donde las “palabras” son pistas y las “frases” son sesiones); los candidatos se ordenan por coseno al prefijo agregado por media. Sobre 5723 sesiones de entrenamiento es demasiado disperso para localizar y es la rama más débil registrada; los vectores de co-escucha de historia completa *no* se usan deliberadamente porque filtran a través de la partición.

content-kNN. Una rama de recuperación sin entrenamiento: coseno del latente de cada candidato a los latentes del prefijo (agregado por máximo). Es débil por sí sola en recall exacto pero captura similitud de *ambiente* (vibe) que los conteos pierden (su genre@10 ya roza la barra de Markov), y es la única tercera rama genuinamente aditiva para el blend de fusión.

z-blend de fusión de rankings frente a stacker aprendido. Dos formas de combinar ramas. El **z-blend** normaliza (z-score) las puntuaciones de candidatos de cada rama y toma una suma ponderada ($\alpha \cdot z(\text{rama}) + \dots$) — un fusor fijo, ligero en parámetros. El **stacker XGB** (apilador) es un meta-aprendiz de gradient boosting sobre rasgos por candidato (puntuaciones de ramas + popularidad + recencia + coincidencia de artista/género), entrenado de forma puntual con negativos muestreados. A lo largo de dos campañas el z-blend fijo *supera* al stacker aprendido de forma decisiva, porque el entrenamiento puntual binario del stacker no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas.

Proyección de contenido aprendida (mapa métrico supervisado). Un mapa lineal W del espacio de latentes de ítems ajustado por **InfoNCE** sobre los pares consecutivos de entrenamiento ($u \rightarrow v$) (auto-bucles descartados, convención de Markov), de modo que el coseno en el espacio- W refleja “probable de seguir”. Es leak-free (solo pares de entrenamiento + latentes de contenido intrínsecos, nunca la partición). Tanto la rama content-kNN (C') como la GRU (R') recuperan luego en el espacio proyectado; Markov no cambia. Es la única alternativa *supervisada* a la geometría PCA no supervisada y ordenada por varianza y — como el contenido es el único canal con alcance a ítems fríos — eleva *ambas* ramas que comparten el espacio, siendo el campeón actual (Sección 11).

Espacios de latentes de ítems: song-AE frente a PCA, y la trampa de la colección equivocada. El modelo de secuencias predice *hacia*, y recupera *sobre*, un espacio latente por ítem, así que la elección de ese espacio es un eje de primera clase. Aparecen tres familias:

AE-64 (spotify_tracks_song_ae). Un latente *song-autoencoder* no lineal de 64 dimensiones, el espacio de ítems campeón original. Un autoencoder comprime cada ítem reconstruyéndolo a través de un cuello de botella; su pérdida de reconstrucción de peso igual por bloque reparte la capacidad de forma uniforme entre los bloques de contenido, acústica y catálogo.

PCA- k (spotify_tracks_song_pca k). Una compresión *lineal* por componentes principales a dimensión $k \in \{32, 64, 128, 192, 256\}$, que ordena las dimensiones por varianza explicada y las decorrelaciona. Como muestran las Secciones 8–9, esta geometría ordenada por varianza y decorrelacionada es *más fácil* de regresar para la GRU que los latentes de peso igual enredados del AE, así que PCA supera al AE en toda dimensión ≥ 64 .

La trampa de la colección equivocada. Ambos anteriores se ajustan *solo* desde la fuente leak-safe `spotify_tracks_content` (campos intrínsecos de contenido/acústica/catálogo; sin campo conductual ni objetivo). La colección por defecto `spotify_tracks` de 200 dimensiones es un embedding *conductual* de co-escucha que filtra suavemente el comportamiento de repetición y **nunca** debe usarse como espacio de ítems.

3. Tabla de clasificación de pista siguiente

La Tabla 1 es la tabla vigente de «mejor registrada». Está sobre la única partición next-distinct sin fugas y ordenada por recall@10. Desde 2026-07-18 la familia de secuencias lleva un contrato de

servicio de ranking, así que el blend campeón de proyección aprendida es un modelo *promovido y servible* (**blend-gru-markov-content-proj**, rango 1 del grupo de mejores modelos), no una mera fila de tabla (Sección 12); los blends anteriores debajo de él, y las ramas en solitario, siguen siendo referencias fuera del servidor. Los espacios de ítems se ajustan todos desde la fuente de contenido leak-safe (Sección 2). Desde 2026-07-22 la evaluación también lleva una suite *solo de visualización* de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10; Sección 15); no reordena este tablero (la métrica principal sigue siendo Recall@10), pero toma la huella del campeón como la fila más artist-eager.

Cuadro 1: Tabla de «mejor registrada» de pista siguiente, sobre la partición next-distinct sin fugas (1431 sesiones de prueba; IC bootstrap al 95 % sobre 2000 remuestreos). R@10, MRR, artist@10, genre@10, music@10 mejor cuanto más alto; el modelo de Markov de primer orden es la barra de referencia incumbente. Los valores de music@10 son el backfill offline (Sección 14); las filas sin un run mapeado se dejan en blanco. Fila campeona y campeones previos en negrita; mejor celda por métrica en negrita.

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	mus@10	Nota
$R'+M+C'$, PCA-192 (campeón, servible)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	0.454	nuevo campeón
R+M+C, PCA-192 (campeón de fusión previo)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	0.449	contenido aditivo
R+M+C, PCA-128	0.1824 [0.162, 0.203]	0.0993	0.332	0.396	—	contenido aditivo
R+M , AE-64 (campeón previo)	0.1726 [0.154, 0.192]	0.0963	0.322	0.397	0.441	ancla prod.; 3 sem
R+M+C, AE-64 (graded-preferred)	0.1740 [0.154, 0.194]	0.1014	0.330	0.400	—	contenido solo emp
R+M, PCA-192	0.1712 [0.151, 0.192]	0.0952	0.329	0.398	0.443	≈ campeón previo
R+M, PCA-128	0.1670 [0.148, 0.187]	0.0920	0.329	0.398	0.444	ganancia GRU no
R+A+M, AE-64	0.1684	0.0943	—	—	—	rama ANN redund
LSTM single, PCA-128	0.1272 [0.110, 0.145]	0.0495	0.335	0.458	0.451	mejor único; << bl
GRU single, PCA-192	0.1230 [0.106, 0.140]	0.0534	0.338	0.450	0.456	óptimo puntual de
GRU single, PCA-128 (base)	0.1146 [0.099, 0.132]	0.0489	0.333	0.452	0.457	espacio base confir
GRU single, PCA-256	0.1167 [0.101, 0.134]	0.0502	0.338	0.458	0.456	pasado el pico de c
B2 Markov de primer orden (barra)	0.1069 [0.092, 0.124]	0.0694	0.298	0.389	0.407	incumbente de la a
GRU single, AE-64 (control)	0.0957 [0.081, 0.111]	0.0411	0.294	0.450	0.432	control del bake-of
ANN pooled-MLP, PCA-128	0.0901 [0.076, 0.105]	0.0394	0.299	0.435	0.426	pierde ante la GRU
XGB stacker (M+G / M+G+A)	0.080–0.087	0.042–0.049	0.31	0.38	0.41	el combinador rinc
content-kNN (song-AE)	0.0636 [0.050, 0.077]	0.0321	0.272	0.405	—	la rama C aditiva
item2vec (SGNS solo entren.)	0.0517	0.0214	0.166	0.312	—	arrastra el blend
B0 popularidad / B1 recencia	0.0007	—	—	—	0.185	pisos

4. El barrido de secuencias: una GRU-infonce empata con la barra de Markov

Motivación. La campaña inaugural de la instancia planteó la pregunta fundacional: ¿un modelo de secuencias con contexto de sesión — una GRU/LSTM sobre el prefijo ordenado, prediciendo el latente song-AE de 64 dimensiones de la siguiente pista y recuperando por coseno — supera al modelo de transición de Markov de primer orden que la app hermana ya despacha, *hacia adelante*, sobre la partición de sesiones sin fugas? Cuatro ramas cruzaron la celda recurrente (GRU, LSTM), la capacidad (**hidden** 128, 256) y, decisivamente, la función de pérdida (coseno frente a InfoNCE), a 60 épocas.

Resultados. Ninguna rama superó la barra. La mejor rama (M3, GRU **hidden**128 InfoNCE) alcanzó un *empate* estadístico con la barra de Markov en R@10 (0,0894, el IC del paired- Δ incluye cero) pero *perdió* en MRR (0,0388 frente a 0,0694) y recall@20. La palanca dominante fue la

función de pérdida: InfoNCE fue $\approx 2,3\times$ el coseno en R@10 (0,0894 frente a 0,0391), mientras que la capacidad (h256) y la celda LSTM apenas movieron las ramas coseno (todas en $\sim 0.038-0.041$). Los pisos de popularidad y recencia quedaron cerca de cero (R@10 0,0007).

Interpretación. Un latente-más-un-solo-salto-coseno es una ruta más difícil a la *pista* siguiente *exacta* que un bigrama de co-escucha: el bigrama memoriza directamente “qué sigue a qué”, mientras que la GRU debe aterrizar cerca del punto correcto en un espacio de contenido de 64-d y luego recuperar, perdiendo en el ranking preciso (MRR). El hallazgo es consistente con una realidad de deriva de gusto — 0,55 de ítems fríos, comportamiento guiado por identidad/adyacencia — y fijó la agenda: InfoNCE es la pérdida base, y la rama natural siguiente es un *blend* de las puntuaciones de candidatos de la GRU con el bigrama de Markov. *Fuente: 2026-07-13-nexttrack-sequence-sweep.md.*

5. Barrido de topología: profundidad, anchura y dirección son una palanca agotada

Motivación. Con la pérdida fijada en InfoNCE, este barrido aisló la *topología* de red: ¿la profundidad (capas apiladas), la anchura (hidden 256), una pila residual entre capas o la bidireccionalidad elevan el modelo de secuencias por encima de la barra de Markov? Como una RNN bidireccional bajo teacher forcing por paso filtraría ítems futuros, la rama bidireccional usó un objetivo leak-free de último ítem (codificar el prefijo completo, predecir solo el siguiente ítem retenido).

Resultados. Refutado. Ninguna rama superó la barra en ambas métricas. La mejor rama (anchura h256, R@10 0,0957) es un *empate* en R@10 y pierde en MRR (0,0411 frente a 0,0694). La profundidad es plana de 1→2 capas (0,0894→0,0922, dentro de banda) y *perjudica* con 3 capas (0,0825, fuera de banda por debajo de la barra); la pila residual sobre profundidad-2/h256 no añadió nada. La rama bidireccional colapsó (0,0482), pero esto es un artefacto del *objetivo*, no un veredicto sobre la direccionalidad: el objetivo leak-free de último ítem aporta ~ 1 objetivo de entrenamiento por sesión frente a los ~ 13 pares de siguiente-paso del teacher forcing, así que entrenó con $\sim 13\times$ menos señal.

Interpretación. La arquitectura no es la palanca para pista siguiente en este corpus. La señal transferible de recuperación por latente se estanca en R@10 $\sim 0.09-0.10$ a través de profundidad, anchura, residual y dirección, por debajo del bigrama de co-escucha — consistente con todo el arco: la función de pérdida movió la aguja y la capacidad/topología no. La única palanca inexplorada restante era el encuadre de candidatos / la fusión, que la campaña siguiente accionó decisivamente. *Fuente: 2026-07-13-nexttrack-topology-scan.md.*

6. El campeón de fusión GRU×Markov, y por qué más ensamblado falla

Motivación. El barrido y el escaneo de topología coincidieron en que la mejor GRU individual solo *empata* con la barra de Markov en R@10 mientras pierde en MRR. Esta campaña preguntó si *combinar* modelos supera la barra, y hasta dónde llega el ensamblado. Se definieron tres ramas, cada una emitiendo puntuaciones de candidatos sobre todo el vocabulario: **M** = el bigrama de Markov solo de entrenamiento (la barra), **R** = la recurrencia GRU-infonce-h256, y **A** = un MLP ANN de bolsa-de-prefijo (un gemelo feed-forward de R). Se combinaron con un z-blend ponderado y, como alternativa aprendida, un stacker XGB.

Resultados. El **z-blend R+M** ($\alpha=0,5$) supera la barra de forma decisiva: R@10 0,1726 [0,154, 0,192], MRR 0,0963, un Δ pareado sobre Markov de +0,0657 [+0,049, +0,083] (IC enteramente por encima de cero) — $\sim +61\%$ de R@10, +39% de MRR — en una meseta robusta a lo largo de $\alpha \in [0,25, 0,75]$ y reproducido a través de tres semillas (0,1705 / 0,1726 / 0,1726). Se registró como el predictor **seq-blend** y la definición **blend-gru-markov**, el primer campeón de pista siguiente. Más ensamblado luego *no logró* mejorarlo (Tabla 2): R+A+M (0,1684) es levemente peor, R+A ($\approx$ GRU sola, 0,0894) es mucho peor, y ambas variantes del stacker XGB (M+R 0,1020; M+R+A 0,0887) apenas superan a Markov sola.

Cuadro 2: La campaña de fusión: el z-blend R+M supera la barra de Markov de forma decisiva, y ningún ensamble más rico lo mejora. R@10 y MRR mejor cuanto más alto; campeón en negrita.

Modelo	R@10 [IC 95 %]	MRR	Nota
z-blend R+M $\alpha=0,5$ (campeón)	0.1726 [0.154, 0.192]	0.0963	Δ vs Markov +0,066 [+0,05, +0,08]
z-blend R+A+M	0.1684	0.0943	rama ANN redundante con GRU
B2 barra de Markov (M)	0.1069 [0.092, 0.123]	0.0694	la referencia
XGB stacker M+R	0.1020	0.0561	combinador aprendido $\ll$ z-blend
GRU sola (R)	0.0957	0.0411	empata la barra solo en R@10
z-blend R+A	0.0894	0.0377	$\approx$ GRU sola
XGB stacker M+R+A	0.0887	0.0572	apenas supera a Markov

Interpretación. La victoria es sobre *diversidad* de señal, no número de modelos. La GRU (similitud de latente) y Markov (conteos de co-ocurrencia) ordenan pistas correctas *distintas*, así que fusionarlas aproximadamente duplica la tasa de acierto; amontonar más del *mismo* tipo de señal — otro predictor neuronal de latente (A), redundante con R — no añade nada. El stacker XGB aprendido *rinde por debajo* del z-blend simple, en contra de la intuición habitual de que “apilar supera a mezclar”: su entrenamiento puntual binario-con-negativos no optimiza el objetivo de ranking tan bien como fusionar directamente puntuaciones normalizadas. El margen restante está acotado por la tasa de ítems fríos de 0,55 y requiere *señal genuinamente nueva*, no más fusión de modelos — la hipótesis que la campaña siguiente pone a prueba. *Fuente: 2026-07-14-nexttrack-blend-and-ensemble.md.*

7. Métricas de relevancia graduada y nuevos aprendices base: el contenido es la única señal aditiva

Motivación. Dos hilos en una campaña. (A) Hacer que la evaluación acredite aterrizar la *banda/ambiente* correcto aunque la pista exacta esté mal — la observación de que “la primera elección normalmente no es la pista exacta, pero el artista normalmente es correcto” — promoviendo *artist@k*, *genre@k* y *artist_mrr* a métricas de primera clase cableadas de extremo a extremo (`seq_common.eval_from_scores` $\rightarrow$ `Metrics / MetricsSpec` de Rust $\rightarrow$ `domain.toml` $\rightarrow$ UI). (B) Probar aprendices base leak-free genuinamente nuevos — **C** = content-kNN, **M2** = un trigram de Markov de segundo orden con back-off, e **I** = un item2vec SGNS solo de entrenamiento — evaluados tanto en las métricas exactas como en las nuevas graduadas.

Resultados. La ruta de la métrica exacta fue idéntica byte a byte (claves puramente aditivas); el campeón reprodujo R@10 0,1726 / MRR 0,0963 exactamente. Ningún aprendiz base nuevo superó la barra en solitario (M2 0,1076 $\approx$ M 0,1069 — el trigram cae al bigram; item2vec 0,0517 es la rama más débil). Mezclado en el campeón, **el contenido es la única señal aditiva: R+M+C** (añadiendo la rama de contenido) es el mejor blend en MRR (0,0963 $\rightarrow$ 0,1014), *artist@10*

(0,3215→0,3298) y `artist_mrr`, y empató al campeón en R@10 exacto (Δ pareado +0,0014, IC cruza cero). `item2vec` *arrastra* el blend (R+M+I 0,1349); el trigramma es neutral.

Interpretación. `content-kNN` ordena pistas cuasi-correctas *distintas* (similitud de ambiente por latente) frente a la GRU (recurrencia de sesión) y Markov (co-ocurrencia), justo la diversidad que la campaña de fusión predijo que necesitaría la señal nueva. Sobre el espacio AE-64 la rama de contenido solo *empató* al campeón en recall exacto mientras elevaba las métricas graduadas, así que se llevó adelante como la tercera rama `graded-preferred`, no como un nuevo campeón exacto. Ese “empate” se vuelve una *victoria* cuando el espacio de ítems es más rico (Sección 10): sobre PCA-192 la misma construcción R+M+C es la más fuerte registrada. El `item2vec` de co-escucha y el trigramma de Markov no añadieron nada en estos datos. *Fuente: 2026-07-14-nexttrack-graded-relevance-and-new-legs.md.*

8. El bake-off de compresión de la representación de ítems

Motivación. El espacio de ítems del campeón — un latente AE de 64 dimensiones — fue una elección temprana arbitraria, y la GRU de secuencias predice *hacia* y recupera *sobre* cualquier geometría que ese espacio imponga. Esta campaña pregunta qué *compresión* es el mejor espacio para la GRU: PCA lineal frente al autoencoder no lineal, cada uno a dimensión latente 32 / 64 / 128. Se hornearon seis espacios alternativos desde la *misma* fuente de contenido leak-safe de 384 dimensiones (`spotify_tracks_content`), cada uno ajustado sin supervisión sobre los 23 529 ítems usando solo campos intrínsecos de contenido/acústica/catálogo, y luego evaluados bajo un readout GRU *congelado* (`gru-infonce-h256`), de modo que el espacio latente de ítems es el único eje que se mueve. La apuesta del diseño era que la pérdida de reconstrucción de peso igual por bloque del AE *preservaría* los pequeños bloques de acústica/catálogo que la varianza global dominada por texto de PCA muriera de hambre; la hipótesis nula era que la dimensión, no el compresor, fija el techo.

Resultados. La puerta de paridad pasó: el control AE-64 reprodujo su R@10 registrado de 0,0957. Los seis espacios entrenaron limpiamente (Tabla 3; Figura 1). **PCA-128** es el ganador GRU-individual con R@10 0,1146, un Δ pareado de +0,0189 [+0,0042, +0,0335] sobre el control AE-64 — un IC *enteramente por encima de cero*, la única rama que supera el control significativamente — y también encabeza MRR, `artist@10` y `artist_mrr`. PCA-64 es el segundo (0,1041, empate). Los dos espacios de 32 dimensiones quedan muy por debajo del control de 64 dimensiones (ambos IC por debajo de cero). La sonda `content-kNN` sin entrenamiento es plana en ~ 0.06 a través de los seis espacios y *no* sigue el ranking de la GRU.

La victoria GRU-individual **no** sobrevive al blend de producción: re-fusionar la rama GRU PCA-128 ganadora con la rama de Markov da R@10 0,1670, *por debajo* del blend campeón AE-64 (0,1726) con IC solapados. No se promovió nada; PCA-128 se llevó adelante solo como el espacio base sancionado para la Fase 2.

Interpretación. La dimensionalidad latente es la palanca dominante y el compresor es secundario. La hipótesis de preservación acústica del diseño queda *refutada*: en dimensión generosa el PCA lineal supera al AE no lineal, y aunque AE-32 preserva los bloques numérico/acústico casi a la perfección queda cerca del fondo. Lo que ayuda es una geometría objetivo *ordenada por varianza y decorrelacionada* que la GRU encuentra más fácil de regresar que los latentes de peso igual enredados del AE. La ventaja del AE en dim 32 es un fenómeno puramente de baja capacidad que se revierte una vez que la dimensión es generosa. La sonda `content-kNN` plana que no sigue el ranking de la GRU es una divergencia señalada: la victoria viene de la *aprendibilidad* de la geometría objetivo de PCA, no de un espacio demostrablemente más rico. Y la salvedad de peso es el resultado del blend:

Cuadro 3: El bake-off de compresión de la representación de ítems: seis espacios de ítems (PCA lineal frente al AE no lineal $\times$ dimensión latente 32 / 64 / 128), cada uno evaluado bajo el *mismo* readout congelado **gru-infonce-h256** (1431 sesiones de prueba; paired- Δ vs el control AE-64 del mismo lote). R@10, MRR, artist@10, genre@10 mejor cuanto más alto. Ganador (PCA-128) en negrita; mejor celda por métrica en negrita.

Espacio	Run id	R@10 [IC 95 %]	Δ vs AE-64	MRR	art@10	gen@10
PCA-128 (ganador)	run-20260715-042100-a1d9d	0.1146 [0.099, 0.132]	+0,019 [+0,004, +0,034]	0.0489	0.3326	0.4521
PCA-64 (segundo)	run-20260715-042100-8851d	0.1041 [0.088, 0.121]	+0,008 (empate)	0.0416	0.3117	0.4598
AE-64 (control)	run-20260715-042059-dd261	0.0957 [0.081, 0.111]	— (control)	0.0411	0.2942	0.4500
AE-128	run-20260715-042059-e96ae	0.0929 [0.078, 0.108]	−0,003 (empate)	0.0398	0.3026	0.4640
AE-32	run-20260715-042059-d3f9e	0.0545 [0.043, 0.066]	−0,041	0.0274	0.2376	0.3955
PCA-32	run-20260715-042059-b1242	0.0412 [0.031, 0.052]	−0,055	0.0224	0.2187	0.3816

una rama GRU claramente más fuerte no compró *nada* en el blend, porque la rama de Markov es independiente de la representación y las pistas extra que la mejor GRU recupera se solapan con lo que Markov ya aporta. *Fuente: 2026-07-15-nexttrack-compression-representation-bakeoff.md.*

9. El techo de dimensión: PCA hace pico en 192

Motivación. Con la dimensión establecida como la palanca y PCA aún subiendo en 128, este tramo extendió el barrido de PCA hacia arriba (PCA-192, PCA-256) para localizar el óptimo real antes de que la Fase 2 comprometiera un espacio base, y añadió AE-192 para probar si $\text{PCA} \geq \text{AE}$ se sostiene a mayor dimensión. El protocolo fue idéntico (el mismo readout congelado **gru-infonce-h256**, la misma puerta de paridad); la referencia es PCA-128 (run-20260715-042100-a1d9d).

Resultados. La curva de R@10 frente a dimensión de PCA **hace pico en ~ 192** (R@10 0,1230) y *se revierte* hacia 256 (0,1167); no seguía subiendo. La tendencia completa es $32 \rightarrow 0,041$, $64 \rightarrow 0,104$, $128 \rightarrow 0,115$, **$192 \rightarrow 0,123$** , $256 \rightarrow 0,117$ (Figura 2). PCA-192 es el óptimo puntual, pero su Δ pareado frente a PCA-128 es +0,0084 [−0,0007, +0,0189] — falla la barra de “IC enteramente por encima de cero” por 0,0007, un pelo — así que **PCA-128 se mantiene como la base de la Fase 2**, con PCA-192 marcado como el candidato a confirmar-y-promover. $\text{PCA} \geq \text{AE}$ se sostiene con fuerza y la brecha es máxima en 192 (PCA-192 0,123 frente a AE-192 0,098); el AE se estanca plano en ~ 0.09 –0.10 desde dim 64 hacia arriba.

Interpretación. La varianza extra más allá de ~ 192 (PCA-256 captura un ratio de varianza explicada acumulado de 0,997) son dimensiones de baja señal / ruido que la GRU no puede explotar y que diluyen levemente la geometría objetivo. La meseta plana del AE reconfirma la hipótesis refutada de preservación acústica a mayor dimensión: su objetivo de reconstrucción de




Figura 1: La dimensión latente, no el compresor, es la palanca. Ambas series suben abruptamente de dim 32 a 64; PCA (azul) luego sigue subiendo hasta 128 y *sobrepasa* al AE, mientras que el AE (gris) se estanca — su punto de 128 dim de hecho cae por debajo de su propio control de 64 dim. En dim 32 el AE roza a PCA, un cruce de baja capacidad que se revierte una vez que la dimensión es generosa. El control AE-64 (anillo rojo) es el espacio de ítems del campeón; el ganador PCA-128 (estrella verde) es la única rama cuyo IC del paired- Δ supera cero. Las barras de error son IC bootstrap al 95 %; los IC vecinos se solapan, así que la victoria descansa en el test *pareado*.

peso igual sigue gastando capacidad en los pequeños bloques numérico/acústico (reconstrucción $R^2 \approx 0,999$ en 192) en lugar de la estructura de texto/catálogo de alta varianza que la GRU necesita. Como antes, la sonda content-kNN sin entrenamiento sigue plana y no reproduce el pico de la GRU, así que el óptimo de dimensión es sobre la *aprendibilidad* del objetivo, no la riqueza intrínseca de recuperación. *Fuente: 2026-07-15b-nexttrack-compression-dim-extension.md*.

10. El barrido de familia de modelos y el nuevo campeón, R+M+C sobre PCA-192

Motivación. Con el eje de compresión zanjado (base PCA-128, candidato PCA-192), esta campaña barrió la *familia* de modelos sobre los espacios elegidos: ¿una celda recurrente distinta (LSTM), un MLP agregado no recurrente (ANN) o un stacker XGB *aprendido* superan al z-blend fijo GRU×Markov — y añadir la tercera rama content-kNN (R+M+C) sobre el espacio PCA *rico* finalmente supera al campeón? Una configuración fija corrió a través de todas las ramas; solo variaron la familia de modelos y la representación, y el servidor se serializó (`--max-runs 1`) para evitar una trampa de rendimiento por sobresuscripción de hilos.

Resultados. Una **nueva fila «mejor registrada»**: el **z-blend R+M+C sobre PCA-192** (GRU × Markov solo de entrenamiento × content-kNN, tercios iguales) alcanza R@10 0,1859 [0,166, 0,207], MRR 0,1025, un Δ pareado sobre el campeón previo de +0,0133 [+0,0007, +0,0259] — enteramente por encima de cero, sin regresión de MRR (Tabla 4; Figura 3). La rama de contenido es genuinamente aditiva sobre el espacio rico, superando al R+M del mismo espacio en +0,0154




Figura 2: Se encuentra el techo de dimensión. Extendiendo el barrido de compresión de la Figura 1 a PCA-192/256 y AE-192, la curva PCA (azul) hace pico en ~192 ($R@10$ 0,123) y se revierte hacia 256, mientras que el AE (gris) se estanca plano en ~0.09–0.10 y nunca lo alcanza — la brecha $PCA \geq AE$ es máxima en 192. PCA-192 es el óptimo puntual (estrella verde) pero su Δ pareado sobre PCA-128 roza cero, así que PCA-128 se mantiene como la base individual de la Fase 2. Las barras de error son IC bootstrap al 95 % sobre las 1431 sesiones de prueba.

(PCA-128) / +0,0147 (PCA-192), ambos IC por encima de cero — *más fuerte* que el R+M+C de AE-64 que solo empató (Sección 7), porque el espacio más rico y de mayor EVR hace que la rama de contenido rinda. El **stacker XGB aprendido rinde muy por debajo** del z-blend fijo (0,080–0,087, perdiendo incluso ante su propia rama base GRU individual); la **LSTM es el mejor modelo individual** (PCA-128 0,1272, Δ pareado sobre la GRU +0,0126, IC por encima de cero) pero muy por debajo de los blends; y la base individual de la Fase 2 **se mantiene en PCA-128**.

La coronación, y sus dos salvedades honestas. El candidato a evento de tabla se confirmó reproduciendo la rama GRU-192 cinco veces (la original más cuatro re-ejecuciones) y recalculando R+M+C cada vez; el Δ pareado sobre el campeón previo fue +0,0133 [+0,0007, +0,0259] en *cada* re-ejecución, con la ventaja de MRR intacta, así que R+M+C sobre PCA-192 se registró como la nueva fila campeona. Dos salvedades viajan con la coronación y no deben omitirse. Primera, **la dispersión de reproducción fue exactamente cero** porque el entrenamiento de **seq-nexttrack** es determinista en esta CPU — los cinco checkpoints GRU-192 fueron idénticos byte a byte — así que la confirmación verificó *determinismo, no robustez a la semilla*; la única incertidumbre cuantificada es el bootstrap de partición única. Segunda, **el límite inferior del Δ pareado es +0,0007**: la coronación supera cero por un pelo en una única partición. La coronación es real según el criterio pre-acordado, pero el margen sobre el campeón previo es delgado, y endurecerla requiere una segunda partición de prueba sin fugas (o ramas con semillas variadas una vez que el blend se generalice a tres ramas).

Interpretación. El hilo de compresión-más-familia-de-modelos queda por lo demás cerrado: PCA-128 es la base individual, la LSTM es el mejor modelo individual, el stacker aprendido está muerto como combinador, y el z-blend fijo es el combinador de referencia. El resultado de peso es que *el contenido es la única rama que añade señal de ranking genuinamente nueva, y rinde más*

Cuadro 4: Barrido de familia de modelos de la Fase 2 sobre los espacios PCA ricos, ordenado por R@10 (mejor cuanto más alto). El z-blend fijo es el combinador de referencia; el stacker XGB aprendido rinde muy por debajo. Fila campeona y campeón previo en negrita; mejor celda por métrica en negrita. El Δ pareado es por sesión contra la referencia nombrada.

Modelo	Run id / fuente	R@10 [IC 95 %]	MRR	Δ pareado
R+M+C, PCA-192 (fila camp.)	analyze_rmc (A4)	0.1859 [0.166, 0.207]	0.1025	vs camp. +0,0133 [+0,001, +0,026]
R+M+C, PCA-128	analyze_rmc (A2)	0.1824 [0.162, 0.203]	0.0993	vs camp. +0,0098 (empate)
R+M, AE-64 (campeón previo)	run-20260714- 170928-645ae	0.1726 [0.154, 0.192]	0.0963	— (referencia)
R+M, PCA-192	run-20260715- 142440-96f53	0.1712 [0.151, 0.192]	0.0952	vs camp. -0,0014 (empate)
R+M, PCA-128	run-20260715- 044920-36dce	0.1670 [0.148, 0.187]	0.0920	vs camp. -0,0056 (empate)
LSTM single, PCA-128	run-20260715- 142440-546d0	0.1272 [0.110, 0.145]	0.0495	vs GRU-128 +0,0126 (> 0)
GRU single, PCA-192	run-20260715- 142440-89d6a	0.1230 [0.106, 0.140]	0.0534	vs GRU-128 +0,0084 (empa- te)
ANN pooled-MLP, PCA-128	run-20260715- 142440-7e528	0.0901 [0.076, 0.105]	0.0394	vs GRU-128 -0,0245
XGB stacker M+G, PCA-128	run-20260715- 142440-371b1	0.0867 [0.073, 0.101]	0.0493	vs GRU-128 -0,0280
XGB stacker M+G+A, PCA-192	run-20260715- 142440-f111d	0.0853 [0.071, 0.099]	0.0490	vs GRU-192 -0,0377

sobre el espacio PCA de mayor EVR — la excepción a la regla vigente de que las ganancias de modelo individual / representación no se trasladan al blend (el par R+M sobre los espacios PCA ricos solo empata al campeón AE-64). La brecha de productización persiste: el campeón es solo de entrenamiento y fuera del servidor, así que el campeón previo R+M sobre AE-64 sigue siendo el ancla desplegable hasta que el blend de tres ramas se registre con un subcomando `predict`.
Fuente: 2026-07-15c-nexttrack-phase2-model-sweep.md.

11. La proyección de contenido aprendida: un nuevo campeón de la campaña de ajuste-a-la-literatura

Motivación. El campeón R+M+C (Sección 10) llevaba dos salvedades delgadas — una confirmación por reproducción solo-determinista y un límite inferior del paired- Δ de solo +0,0007 — y su margen estaba acotado por la tasa de ítems fríos de 0,55, que solo la señal *nueva* puede atacar. Guiada por un estudio de la literatura establecida de recomendación en sesión (la línea de session-kNN de Jannach-Ludewig, reglas secuenciales / Markov factorizado, trucos de entrenamiento de GRU4Rec, fusión de rankings y learning-to-rank, recomendación en sesión consciente de contenido / arranque en frío), esta campaña pre-registró tres niveles de métodos clásicos y preguntó cuáles mejoran realmente el ajuste a *este* problema — una tarea de *recuperación* de pista siguiente distinta, de un solo usuario, basada en sesión, con 55 % de objetivos fríos. Todas las ramas se midieron fuera del servidor sobre el artefacto campeón PCA-192 seq-20260715-131139, reutilizando el driver sancionado que reproduce al campeón (R+M+C 0,1859) exactamente; el estadístico de decisión es el Δ pareado por sesión contra ese campeón.




Figura 3: El barrido de familia de modelos de la Fase 2. El z-blend fijo es el combinador de referencia: R+M+C sobre PCA-192 (verde) es la nueva fila campeona, la rama de contenido es genuinamente aditiva sobre el espacio rico, y el stacker XGB aprendido (rojo) rinde muy por debajo — pierde incluso ante su propia rama base GRU individual. LSTM roza a GRU como el mejor modelo individual (gris) pero queda muy por debajo de los blends. La barra de Markov de primer orden (0,107) es la referencia incumbente; la fila campeona está en 0,186.

Resultados — la única victoria. Una **proyección de contenido aprendida** supervisada es una nueva fila «mejor registrada». Ajustar un mapa métrico lineal W del espacio de contenido PCA-192 hacia la adyacencia de pista siguiente (InfoNCE sobre pares consecutivos de entrenamiento, auto-bucles descartados) y luego recuperar *ambas* la rama de contenido (C') y la GRU (R') en ese espacio proyectado da **z-blend** $R'+M+C'$ **R@10** 0,2117 [0,191, 0,233], **MRR** 0,1220 — un Δ pareado sobre el campeón de +0,0259 [+0,012, +0,041], enteramente por encima de cero (Tabla 5). A diferencia de la coronación R+M+C, es **robusta a la semilla** (tres semillas; Δ pareado +0,026 / +0,025 / +0,029, todos IC > 0 — una confirmación genuina con semillas variadas, ya que la proyección tiene init aleatorio y lotes barajados) y **alcanza ítems fríos**: la rama de contenido proyectada C' puntúa objetivos fríos 0,152 $\approx$ cálidos 0,151, frente a los cálidos 0,226 / fríos 0,010 de Markov, así que alcanza ítems nunca vistos tan bien como los vistos — generalización de contenido genuina, el único canal que alcanza la mayoría fría del 55 %. El mapa simétrico único supera al two-tower direccional, y rango-192 = rango-64 (la ganancia es la supervisión, no la capacidad). Como efecto secundario, la GRU individual proyectada R' ($\sim$ 0,176) casi iguala al blend campeón *antiguo* y aplasta al mejor individual previo (LSTM 0,127).

Las vías que se cerraron. Toda otra dirección de ajuste-a-la-literatura no logró superar al z-blend fijo, exactamente como el estudio predijo para un corpus de un solo usuario y con muchos fríos (Tabla 6). El suavizado principiado de Markov (descuento absoluto + un piso de continuación de Kneser–Ney) es una ganancia de estimador en solitario real pero minúscula (0,1069 $\rightarrow$ 0,1104) que se diluye en el blend (−0,0021, IC cruza 0 — la rama de contenido ya cubre la masa fría marginal

Cuadro 5: Nivel A1 de la campaña de ajuste-a-la-literatura: la proyección de contenido aprendida sobre PCA-192, frente al campeón R+M+C (1431 sesiones de prueba; IC bootstrap al 95 %; Δ pareado por sesión vs el campeón). Ganador ($R'+M+C'$) en negrita; mejor celda por métrica en negrita.

Modelo	R@10 [IC 95 %]	MRR	art@10	gen@10	Δ pareado vs campeón
R+M+C campeón (tercios)	0.1859 [0.166, 0.207]	0.1025	0.331	0.394	— (referencia)
$R'+M+C'$ (ambas proyectadas)	0.2117 [0.191, 0.233]	0.1220	0.333	0.401	+0,0259 [+0,012, +0,041] > 0
R+M+C+C' (4 ramas)	0.2061 [0.185, 0.227]	0.1148	0.345	0.410	+0,0203 [+0,013, +0,029] > 0
R+M+C' (cambia C→C')	0.1971 [0.177, 0.218]	0.1107	0.334	0.400	+0,0112 [−0,000, +0,023] cand.
C' proj-contenido (sim, r192)	0.1516	0.0708	0.305	0.401	vs C no-sup. 0.0685: +0,083
C' two-tower dir. (r192)	0.1349	0.0552	0.291	0.393	gana simétrica

que recupera). Un combinador consciente de ranking no tiene margen honesto: incluso los pesos *oráculo*, ajustados directamente sobre las etiquetas de prueba, alcanzan solo 0,1901 (+0,0042, cruza 0), y la fusión de ranking RRF *perjudica* el recall (−0,029, IC<0, descartando la magnitud de puntuación que el z-blend conserva). Un kNN de sesión V-SKNN con puerta es solo-cálido frente al 55 % de objetivos fríos y *arrastra* el blend (−0,038, IC<0) — el escenario de un solo usuario elimina el vecindario colaborativo entre usuarios que impulsa sus victorias de benchmark multiusuario. Y los negativos por importancia de GRU4Rec (un banco de negativos ponderado por soporte más grande) dan un tick en solitario dentro del ruido (+0,005) que también se diluye (−0,0014, empate). **La única ganancia aditiva viene de señal nueva, no de fusión más astuta.**

Cuadro 6: Las vías de ajuste-a-la-literatura que se cerraron: cada método prestado no logra superar al z-blend fijo campeón (1431 sesiones de prueba; Δ pareado del blend por sesión vs el campeón).

Vía	R@10 en solitario	Δ del blend vs campeón	Veredicto
Suavizado KN de Markov (Nivel A2)	0.1069→0.1104	−0,0021 (cruza 0)	nulo en el blend
Combinador de ranking, <i>oráculo</i> (B1)	0.1901 (blend)	+0,0042 (cruza 0)	sin margen honesto
Fusión de ranking RRF (B1)	0.1572 (blend)	−0,029 (IC<0)	perjudica recall
V-SKNN kNN de sesión (B2)	0.0671	−0,038 (IC<0)	arrastra (solo cálidos)
Negativos por importancia GRU (C)	0.1230→0.1279	−0,0014 (empate)	se diluye

Interpretación. La proyección de contenido supervisada es la primera señal nueva genuinamente aditiva desde la propia rama de contenido, y funciona por la razón que el estudio señaló: el contenido es el único canal con alcance a ítems fríos, y reemplazar la geometría PCA no supervisada y ordenada por varianza por una ajustada al objetivo eleva *ambas* ramas que la comparten. Los métodos prestados vistosos — session-kNN, combinadores aprendidos, trucos de pérdida del lado GRU — son callejones sin salida aquí porque o rebarajan las mismas tres ramas (sin margen sobre el z-blend, incluso para el oráculo) o importan una suposición colaborativa que el corpus de un solo usuario viola. El único eje secundario movable es la relevancia graduada: los reponderados oráculo / RRF y la proyección empujan artist@10 / genre@10, una palanca que el eje de recall exacto no comparte. *Fuente: 2026-07-18-nexttrack-literature-fit-campaign.md.*

12. Registro, el barrido de objetivo / rango / τ , y endurecimiento en segunda partición

Motivación. La victoria de la proyección aterrizó como driver fuera del servidor — la misma brecha de productización que tenía la coronación R+M+C. Este seguimiento implementó la proyección como capacidad de primera clase del predictor **seq-blend** (hiperparámetros **projection**, **projection_rank**, **projection_objective**, **projection_tau**, ...: ajusta el mapa métrico desde los pares consecutivos de entrenamiento, lo guarda como **projection.npz** en el directorio del run, y lo hornea en el modelo promovido para servicio), luego (1) reprodujo la victoria on-server y la registró + promovió, y (2) corrió un barrido de ablación pre-aprobado de objetivo / rango / τ para confirmar que el default es la config robusta a promover.

Registro. El run de verificación (**run-20260718-191539-1b89c-seq-blend**, default de la definición = InfoNCE / rango completo / τ 0,07) reprodujo el driver fuera del servidor a cuatro decimales — R@10 0,21174, MRR 0,12199 — y se promovió vía la API como **blend-gru-markov-content-proj**, con la matriz de proyección horneada en el directorio del modelo para servicio. **GET /api/best-models** lo confirma en **rango 1** (0,21174), por encima del campeón servible previo **blend-gru-markov-content** (rango 2, 0,18588). Con el contrato de servicio de ranking de la familia de secuencias este es un modelo genuinamente desplegable, servible vía **POST /api/models/blend-gru-markov-content-proj/predict**.

El barrido. La regla de decisión — re-promover solo una config que supere al default en *ambos* R@10 y MRR por más que la banda de ruido de $\sim \pm 0,015$ — confirma el default (Tabla 7). **InfoNCE** $\gg$ **BPR** es el eje más agudo: ambas celdas BPR (0,1579, 0,1523) caen $\sim 0,055$ bajo el default InfoNCE y aterrizan *por debajo incluso del viejo campeón R+M+C* (0,1859), así que el mapa BPR por pares produce una geometría materialmente peor para ambas ramas de latente compartido. **Rango completo** $\geq$ **rango-64** ($-0,006$, un empate — reconfirmando “la ganancia es la supervisión, no la capacidad”). Y τ es **levemente sensible y monótona hacia arriba** en el rango probado ($0,05 \rightarrow 0,1929$, $0,07 \rightarrow 0,2117$, $0,10 \rightarrow 0,2229$) — pero la celda superior nominal $\tau-0,10$ supera al default por solo $+0,0112$ en recall, *dentro* de la banda de ruido, así que es un empate y el default se **MANTUVO**. A diferencia del eje de reponderación de la Sección 11, aquí las métricas graduadas *siguen* al recall (mejor y peor juntas), porque el barrido mueve la *calidad de señal* en vez de refusionar ramas fijas.

12.1. Endurecimiento en segunda partición

Motivación. La coronación de la proyección se midió sobre una única partición sin fugas. Este pase solo-de-validación la re-corrió — más los dos blends de referencia — sobre una **segunda partición disjunta y sin fugas** para zanjar si la victoria es específica de la partición. Nada se promueve ni re-promueve. La partición **seq-20260718-211238** es una banda cronológica de *holdout-temprano* 60–80 % sobre el mismo espacio PCA-192 (train 4.292 [60 % más temprano] / test 1.431 [banda 60–80 %]); el espacio de ítems es idéntico byte a byte al de la partición campeona, y la ventana de prueba es **disjunta en índice y tiempo** respecto al test 80–100 % de la partición campeona. Su **tasa de ítems fríos** es 0,64 (frente a 0,55), un test de estrés de alcance a fríos más fuerte e independiente — así que el R@10 absoluto aterrizó *por debajo* del 0,212 de la primera partición por construcción, y el veredicto es el Δ pareado por sesión sobre *esta* partición, no la reproducción absoluta.

Veredicto — coronación endurecida. La regla de decisión (Δ pareado vs R+M+C con IC 95 % enteramente > 0 y MRR sin regresión) se cumple: Δ pareado $+0,0426$ [$+0,0280$, $+0,0573$], MRR $+0,0234$ (sin regresión). La ventaja de la proyección no es específica de la partición — de hecho

Cuadro 7: El barrido de ablación on-server de objetivo / rango / τ (6 celdas, ordenadas por recall@10). Todas superponen la definición promovida; hit@10 = recall@10 por construcción. Campeón promovido (default, mantenido) en negrita; mejor celda por métrica en negrita (todas de la celda sub-ruido τ -0,10).

Config	recall@10	MRR	art@10	gen@10	run id
S2 infonce / full / τ 0,10	0.2229	0.1273	0.3424	0.4032	run-20260718-193111-a781c
infonce / full / τ 0,07 (promovido, mantenido)	0.2117	0.1220	0.3326	0.4011	run-20260718-191539-1b89c
S3 infonce / rank 64 / τ 0,07	0.2055	0.1169	0.3326	0.3990	run-20260718-193650-66c96
S1 infonce / full / τ 0,05	0.1929	0.1111	0.3354	0.3997	run-20260718-192443-57432
S4 bpr / full / τ 0,07	0.1579	0.0939	0.3187	0.3913	run-20260718-194228-4cc06
S5 bpr / rank 64 / τ 0,07	0.1523	0.0909	0.3194	0.3906	run-20260718-194832-d070f

Cuadro 8: Endurecimiento en segunda partición sobre la partición disjunta de holdout-temprano con 0.64 de fríos seq-20260718-211238 (1431 sesiones de prueba; solo-validación, nada promovido). Métricas puntuales (arriba) y el Δ pareado por sesión (abajo, bootstrap de 2000 remuestreos, semilla 1337). Campeón de proyección en negrita.

Config	recall@10	MRR	art@10	gen@10	run id
$R' + M + C'$ campeón de proyección	0.1705	0.1050	0.2991	0.3417	run-20260718-212639-50e1d
Coronación R+M+C (referencia primaria)	0.1279	0.0816	0.2956	0.3410	run-20260718-213156-cf1dd
R+M 2 ramas (referencia de contexto)	0.1174	0.0791	0.2844	0.3368	run-20260718-214114-93bad
Δ pareado recall@10 (proyección – referencia):					
PROY vs R+M+C (primaria)	+0,0426	[+0,0280, +0,0573] — enteramente > 0; MRR +0,0234 (sin regresión)			
PROY vs R+M (contexto)	+0,0531	[+0,0391, +0,0678] — enteramente > 0			

el margen es *más ancho* aquí (+0,0426) que en la primera partición (+0,0259), consistente con el mecanismo de alcance a fríos (Figura 4). Combinado con la robustez a la semilla de tres semillas y la descomposición de alcance a fríos previas, la coronación está ahora endurecida en dos particiones disjuntas sin fugas — resolviendo ambas salvedades que viajaban con la coronación R+M+C. *Fuente: 2026-07-18b-nexttrack-projection-registration-and-scan.md.*

13. Representación del vector de ítem: ¿es la geometría el cuello de botella?

Motivación. El eje de compresión (Secciones 8–9) halló que la *dimensión* latente domina pero nunca preguntó si la *composición* del vector de ítem de 192-d — el PCA de 4 bloques de peso igual (texto / numérico / acústico / categórico) — es en sí misma un lastre. Un preflight de ratio de varianza explicada (EVR) dijo que podría serlo: el presupuesto de varianza de entrada crudo es 44 % acústico + 43 % numérico frente a solo 2.5 % texto (el texto está L2-normalizado, así que




Figura 4: La ventaja de la proyección *se ensancha* en la partición más fría. Sobre la partición canónica con 0.55 de fríos el campeón de proyección supera a la coronación R+M+C por Δ pareado +0,0259; sobre una partición disjunta y más fría de holdout-temprano con 0.64 de fríos el margen *crece* a +0,0426 (ambos IC enteramente > 0). El R@10 absoluto es menor en la partición más fría por construcción (más objetivos son fríos); el veredicto es el Δ pareado, inequívoco en ambas. El mecanismo: en una partición más fría las ramas Markov / content-kNN de la coronación alcanzan menos objetivos, y la rama de contenido C' de la proyección, que alcanza fríos, carga proporcionalmente más de la victoria.

su escala por dimensión es minúscula), así que el PCA-192 de matriz completa gasta **87% de su presupuesto de varianza** reconstruyendo los bloques numérico + acústico a $R^2 = 1,000$ mientras que el bloque de texto portador de señal alcanza solo $R^2 = 0,717$; la estandarización por columna (whitening) voltea el presupuesto capturado a 73% texto / 21% categórico (texto R^2 0,905) (Figura 5). Se construyeron ocho espacios de latentes de ítems alternativos (whitening $\times$ drop-acústico, solo-texto, texto+categórico, y la geometría métrica de distancia musical) con puerta de paridad respecto a la partición campeona (vocab / partición idénticos byte a byte; solo difiere `item_latents.f32`) y cada uno se evaluó bajo *dos* readouts: **(A)** la proyección campeona `blend-gru-markov-content-proj` (el mapa InfoNCE se reajusta sobre ese espacio — el techo del espacio bajo la receta ganadora) y **(C)** la GRU individual congelada `gru-infonce-h256` (calidad de representación cruda). Solo-validación; nada promovido.

Veredicto — recall exacto. **Readout A:** ninguna variante supera al campeón PCA-192 con IC del Δ pareado enteramente > 0. Los dos espacios nominalmente positivos (V3 std-noaco +0,0049, V5 balanced-pca192 +0,0042) cruzan cero; dos espacios son significativamente *peores* (V4 textcat -0,0168, dejar caer numérico+acústico le cuesta señal real a la proyección; V6 sonic-64 -0,0182, el lastre esperado de 64-d). **Readout C:** seis de ocho variantes superan a la GRU congelada con IC del Δ pareado enteramente > 0 (+0,025 a +0,036; mejor V5 balanced +0,0356, V3 std-noaco +0,0342). Así que la geometría PCA-192 de matriz completa cruda *es un lastre* — suprimir las direcciones acústicas / numéricas ruidosas eleva la GRU cruda en ~20-29% relativo — **pero la ganancia es absorbida por completo por la proyección:** el




Figura 5: Por qué el vector de ítem es un lastre para un modelo crudo — y por qué la proyección es el arreglo. El PCA-192 de peso igual ordena las dimensiones por varianza cruda, así que 87 % de su presupuesto capturado reconstruye los bloques numérico + acústico conductualmente inertes (popularidad / era / volumen) mientras que el bloque de texto portador de señal (2,5 % de la varianza de entrada cruda, L2-normalizado) queda infra-preservedo (R^2 0,717). La estandarización por columna voltea el presupuesto capturado a 73 % texto / 21 % categórico (texto R^2 0,905). La proyección InfoNCE aprendida aprende esta misma reponderación de los datos.

whitening eleva el readout C, no el readout A, porque el mapa InfoNCE aprendido ya reponderó fuera esas direcciones de los datos. El whitening y la proyección aprendida son el *mismo arreglo*, y el campeón ya lo accionó (Figura 6).

Graduadas y music@10. Las palancas de representación mueven el eje *graduado* más limpiamente que el recall exacto: el whitening eleva el genre@10 de la GRU congelada a $\sim 0,47$ (V7 std-txtcatup 0,4717, V3 std-noaco 0,4710 vs línea base 0,4500), y bajo la proyección un espacio solo-texto (V10) publica los máximos de readout A en artist@10 (0,3466) y genre@10 (0,4144) mientras cede $-0,0119$ de recall exacto. La métrica continua **music@10** (Sección 14) *corrobora* el veredicto de recall exacto en vez de revertirlo: el campeón de proyección la lidera (0,4538) sobre la coronación R+M+C (0,4491), y bajo la proyección campeona es plana a través de las ocho representaciones ($\sim 0,447$ – $0,460$). Re-basar la geometría mueve el emparejamiento de banda / ambiente, pero la adyacencia exacta de pista siguiente en el techo del campeón es inamovible — que es precisamente el eje que la proyección supervisada posee.

Interpretación. El vector de ítem PCA-192 de peso igual es un lastre genuino para un modelo *crudo*, y la proyección aprendida es exactamente la respuesta correcta a él — esta campaña valida de forma independiente *por qué* la proyección es el campeón (es el arreglo de representación, aprendido) y confirma que no queda almuerzo gratis en re-basar la geometría de entrada. La única precaución: dejar caer numérico+acústico *por completo* (V4 textcat) perjudica al campeón aunque ayude a la GRU cruda, así que el bloque numérico porta algo que la proyección usa — conservar numérico, hacer whitening / dejar caer solo acústico. La dirección abierta más prometedora es componer los dos arreglos: ajustar la proyección *sobre* un espacio whitened / std-noaco / métrico para ver si alcanza más lejos o es redundante. *Fuente:*

Cuadro 9: Exploración de representación del vector de ítem: ocho espacios de ítems de 192-d alternativos vs el campeón PCA-192, bajo readout A (proyección campeona) y readout C (GRU congelada). Δ pareado sobre hit@10 exacto (bootstrap de 2000 remuestreos, rng 1337) vs la línea base del mismo readout; una mejora necesita el IC enteramente > 0 . Filas de línea base y la mejor mejora de readout C (V5) en negrita.

Variante (espacio)	dataset id	Readout A (proyección)		Readout C (GRU congelada)	
		R@10	Δ hit@10 [IC]	R@10	Δ hit@10 [IC]
full — PCA-192 (línea base)	seq-20260715-131139	0.2117	(línea base)	0.1230	(línea base)
V1 noaco	seq-20260718-222742	0.2089	-0,0028 [-0,013, +0,008]	0.1481	+0,0252 [+0,009, +0,041]
V2 std (whiten todo)	seq-20260718-222754	0.2082	-0,0035 [-0,015, +0,008]	0.1530	+0,0300 [+0,011, +0,049]
V3 std-noaco	seq-20260718-222807	0.2166	+0,0049 [-0,008, +0,017]	0.1572	+0,0342 [+0,015, +0,055]
V4 textcat	seq-20260718-222820	0.1950	-0,0168 [-0,029, -0,006]	0.1565	+0,0335 [+0,015, +0,051]
V5 balanced-pca192	seq-20260718-222834	0.2159	+0,0042 [-0,006, +0,015]	0.1586	+0,0356 [+0,019, +0,052]
V7 std-txtcatup	seq-20260718-222848	0.2055	-0,0063 [-0,019, +0,006]	0.1488	+0,0259 [+0,006, +0,046]
V10 text-only	seq-20260718-222901	0.1999	-0,0119 [-0,025, +0,001]	0.1377	+0,0147 [-0,005, +0,034]
V6 sonic-64 (64-d)	seq-20260718-222905	0.1936	-0,0182 [-0,031, -0,005]	0.1216	-0,0014 [-0,017, +0,013]

2026-07-18c-nexttrack-representation-exploration.md.

14. La métrica music@10: el campeón de recall no es el más cercano musicalmente

Motivación. El recall@10 exacto es implacable sobre un corpus de un solo usuario con 55 % de fríos, y los diagnósticos artist@10 / genre@10 son aciertos de categoría toscos. Esta campaña introduce una métrica graduada *continua* de tipo “suena parecido”, **music@10**, y la back-fillea a través de cada run de pista siguiente. Se define como la media sobre casos de prueba del mejor coseno (máximo), en un espacio intrínseco *balanceado* de distancia musical (spotify_tracks_content_metric: una fusión con pesos por bloque, parcialmente whitened, del latente song-AE de 64-d whitened, el embedding de texto de nombre/tag de 384-d, cinco numéricos de metadatos, y un prototipo AE por género), entre la siguiente pista verdadera y los diez candidatos recuperados. Un top-diez que contiene la verdad exacta puntúa 1,0, así que music@10 es un *superconjunto suave* de recall@10 — acredita aterrizar algo que *suena como* la verdad incluso en un fallo exacto / de artista / de género. Es solo de visualización; la métrica principal sigue siendo recall@10.

Resultados. music@10 se recalculó offline y de forma no destructiva a través de los 53 runs de pista siguiente (desde el predictions.json almacenado de cada run y su items.json de dataset, sobre la partición compartida de 1431 casos). **Correlaciona** con recall@10 ($r = 0,609$) — un mejor ranker también aterriza fallos más cercanos — pero está lejos de ser redundante, y corona a un ganador *distinto* (Tabla 10; Figura 7). El campeón de recall@10 es un run seq-blend (0,223), pero las predicciones *más cercanas musicalmente* vienen de seq-nexttrack — que regresa directamente el latente de contenido de la siguiente pista y recupera por coseno — con mejor music@10 0,482 y la media de familia más alta (0,448). Cuando un modelo de pista siguiente falla la pista exacta, aún tiende a hacer aflorar algo que *suena bien*; el piso seq-popularity es correctamente el peor (music@10 0,185), confirmando que la métrica no está trivialmente saturada.

Interpretación. music@10 es una vista genuinamente distinta y no saturada de la calidad de pista siguiente: premia la proximidad *sónica*, que la métrica de acierto exacto ignora. El desacople recall-versus-music tiene un mecanismo limpio — un modelo que regresa el latente de contenido (seq-nexttrack) aterriza *cerca* de la verdad en el espacio de contenido incluso cuando falla la pista exacta, así que sus fallos “suenan bien” más a menudo que los del blend, que optimiza el




Figura 6: El lastre de representación es real para la GRU *cruda* pero *absorbido* por la proyección campeona. Seis de ocho espacios de whitening / drop-acústico / métricos elevan la GRU congelada (readout C, verde; los seis con IC del paired-Δ enteramente > 0 , $+0,025$ a $+0,036$), pero ninguno eleva la proyección campeona (readout A, azul; los dos espacios nominalmente positivos cruzan 0, y V4/V6 regresan significativamente). El mapa InfoNCE aprendido ya reponderó fuera las direcciones acústicas / numéricas ruidosas, así que hacer whitening a la entrada primero es redundante en el techo del campeón: el whitening y la proyección son el mismo arreglo.

rango exacto. Por eso la métrica es solo de visualización y no debe volverse silenciosamente un objetivo de selección: la promoción aún ordena por recall@10. La métrica hereda una circularidad leve del dial *balanced* (el bloque de texto embebe el nombre del artista; el bloque de género es un prototipo de género), así que premia parcialmente la proximidad de mismo-artista / género — pensada para “suena / se siente parecido”, no una verdad perceptual de referencia. Un endpoint compañero GET /api/pathfinder/similar sirve “canciones como esta” sobre el mismo índice. Fuente: 2026-07-20-musical-distance-metric.md.

15. Métricas de holisticidad de sesión y las palancas anti-eager (MMR λ / eager β)

Motivación. Una queja cualitativa recurrente sobre los mejores blends es que sus predicciones se sienten “demasiado album-eager / de tipo bigrama” — repiten como loro el artista actual en lugar de curar una continuación holística. Esta campaña cuantifica ese síntoma con una nueva suite *solo de visualización* de métricas de *holisticidad de sesión*, pone a prueba la hipótesis del usuario de que *la GRU supera a la LSTM porque es más eager* (más ansiosa por repetir el artista actual), y mide si dos nuevas palancas de la Fase 2 reducen esa eagerness a un costo de recall aceptable: un re-ranqueo MMR en evaluación (mmr_lambda) y un regularizador anti-eager de entrenamiento (eager_beta). Es un pase de medición / exploratorio: no se promueve nada, la métrica principal sigue siendo Recall@10 y la decisión sobre el objetivo de holisticidad se difiere explícitamente al

Cuadro 10: music@10 por familia de predictor, del backfill offline sobre los 53 runs de pista siguiente (una partición compartida de 1431 casos). El campeón de recall@10 (**seq-blend**) *no* es el campeón de music@10 (**seq-nexttrack**). Mejor celda por columna en negrita.

Familia de predictor	runs	mejor recall@10	mejor music@10	music@10 medio
seq-blend	23	0.223	0.461	0.441
seq-nexttrack	24	0.159	0.482	0.448
seq-markov	1	0.107	0.407	0.407
seq-ann	1	0.090	0.426	0.426
seq-stacker	3	0.087	0.418	0.411
seq-popularity	1	0.001	0.185	0.185

usuario. Cada rama corre sobre la partición *canónica* PCA-192 del campeón **seq-20260715-131139** (1431 sesiones de test; tasa de ítems fríos 0,55), y el campeón reprodujo exactamente su Recall@10 de registro 0,2117 (0,211 74).

Las nuevas métricas de holisticidad solo de visualización. Cableadas de extremo a extremo junto a music@10 (`seq_common.eval_from_scores` → Rust → `domain.toml` → UI); la métrica principal no cambia.

artist_adj@10 (↓). Fracción del top-10 que comparte el artista de la pista *semilla* — la tasa de “repite como loro el artista actual”. **Menor es mejor.**

album_adj@10. Lo mismo sobre (artista, álbum); **omitida en este dataset** porque su `items.json` no lleva el campo de álbum (esperado, no un error — cubierto por un dataset separado que sí lleva álbum).

mood_coh@10 (↑). Coseno medio del top-10 al centroide de mood del prefijo en el espacio content-metric; mayor es más coherente en mood.

ild@10 (↑). Diversidad intra-lista (distancia sónica media por pares) del top-10; mayor es menos duplicativo.

suffix_recall@10 / cont_prec@10. Cobertura de continuación multi-paso, producida solo por el arnés bajo demanda `seq_continuation_eval.py` (Fase E, abajo), no por los runs normales.

La puerta de sanidad pasó: music@10 / mood_coh@10 / ild@10 se pueblan en todos los runs de blend y GRU, de modo que los vectores content-metric cargaron y las palancas MMR / mood / ild están vivas, no son no-ops. Ambas palancas nuevas están APAGADAS por defecto y verificadas byte-idénticas al estar apagadas.

Resultados — la huella de holisticidad (Fase A). La Tabla 11 toma la huella de la familia de modelos. **La eagerness sigue a Recall@10 dentro de la familia de blends** — el campeón (Recall@10 0,2117) es el modelo *más* artist-eager medido (artist_adj@10 0,610), con R+M a continuación (0,579) — pero la eagerness vive en la pata de *Markov*, no en la RNN: la barra de Markov de primer orden por sí sola ya está en 0,543, mientras que la GRU / LSTM individuales quedan mucho más abajo, en artist_adj@10 $\approx$ 0,345. Así que los blends compran su ventaja en Recall@10 siendo artist-adyacentes (de tipo bigrama), que es exactamente lo que la suite de holisticidad señala. Las RNN individuales son, en cambio, los modelos *coherentes en mood y de baja eagerness* (el mayor mood_coh@10, el menor artist_adj@10 entre modelos reales). Crucialmente,




Figura 7: music@10 frente a recall@10 a través de los 53 runs de pista siguiente, un punto por run, coloreado por familia de predictor. Los dos ejes correlacionan ($r = 0,609$: un mejor ranker también aterriza fallos más cercanos) pero coronan ganadores distintos — el campeón de recall@10 (un run **seq-blend** en 0,223) no es el más cercano musicalmente, que es un run **seq-nexttrack** (music@10 0,482) que regresa el latente de contenido y recupera por coseno. El piso **seq-popularity** es correctamente el peor en ambos. music@10 es solo de visualización; recall@10 sigue siendo la métrica principal.

las métricas *no se juegan trivialmente*: el suelo de popularidad maximiza ild@10 (0,898) y minimiza artist_adj@10 (0,003) pero puntúa ≈ 0 recall y mood_coh@10 *negativo* — se maximizan siendo aleatorio, así que los modelos de baja eagerness / alta diversidad con sentido son las RNN individuales reales.

GRU frente a LSTM (Fase B) — la hipótesis no se sostiene. Con los hiperparámetros igualados (h256, InfoNCE, 40 épocas, lr 1×10^{-3}), la GRU y la LSTM quedan estadísticamente *empatadas*: Recall@10 0,1230 frente a 0,1188 ($\Delta +0,0042$, dentro de la banda $\pm 0,015$), y artist_adj@10 0,347 frente a 0,344 (un $+0,003$ despreciable). La GRU no es mediblemente más eager que la LSTM en esta partición, así que la hipótesis “la GRU gana porque repite el artista actual con más fuerza” queda **refutada aquí**.

La palanca MMR λ (Fase C) — la palanca fuerte. MMR es un re-ranqueo puramente en evaluación, así que los cuatro runs de entrenamiento por- λ lanzados originalmente fueron *cancelados* (no experimentos fallidos); el barrido se computó offline desde el único checkpoint del campeón (la celda $\lambda=\text{off}$ reprodujo exactamente el Recall@10 0,2117 del campeón). A medida que λ cae de off hacia 0,3 (Tabla 12; Figura 8), Recall@10 baja — lo *único* que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (des-eagerness). $\lambda=0,9$ es **esencialmente gratis**: el Δ de recall es $-0,0014$, bien dentro de la banda $\pm 0,015$ (un empate), pero ya eleva ild@10 $0,406 \rightarrow 0,436$ y recorta la eagerness $0,610 \rightarrow 0,603$. $\lambda \approx 0,7$ sacrifica ~ 2 puntos de recall ($\Delta -0,0181$, justo fuera de la banda) por una gran ganancia de ild@10 ($0,406 \rightarrow 0,520$) y una caída real de eagerness ($0,610 \rightarrow 0,571$). Un efecto colateral notable: **music@10 sube monótonamente** a medida que se diversifica ($0,454 \rightarrow 0,492$)

Cuadro 11: Huella de holisticidad de la Fase A a través de la familia de modelos, ordenada por Recall@10 (1431 sesiones de test). Todos los runs comparten el prefijo `run-20260722-165345-`; la columna `id` lista el sufijo distintivo. Recall@10 (aciertos crudos de 1431), MRR, `artist@10`, `genre@10`, `music@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Fila del campeón y mejor celda por métrica en negrita. [†] Los valores extremos de `artist_adj@10` / `ild@10` del suelo de popularidad son *degenerados* (ignora la semilla): aterrizaje ≈ 0 recall y `mood_coh@10` negativo, probando que las métricas no se juegan bajo/alto por un buen modelo.

Config	id	R@10 (crudo)	MRR	art@10	gen@10	mus@10	artadj@10↓	mood@10↑	ild@10↑
A1 campeón $R'+M+C'$	82a8f	0.2117 (303)	0.122	0.333	0.401	0.454	0.610	0.398	0.406
A2 R+M (blend)	28dbb	0.1712 (245)	0.095	0.329	0.398	0.443	0.579	0.399	0.403
A3 GRU sola ($\beta=0$)	e39c9	0.1230 (176)	0.053	0.338	0.450	0.456	0.347	0.479	0.454
B LSTM (resto igual a A3)	bb387	0.1188 (170)	0.049	0.328	0.455	0.449	0.344	0.458	0.463
A4 markov (primer orden)	047cc	0.1069 (153)	0.069	0.298	0.389	0.407	0.543	0.310	0.462
A5 popularidad	34614	0.0007 (1)	0.001	0.014	0.085	0.185	0.003[†]	−0,041	0.898[†]

— cercanía sónica y diversidad de lista no están en tensión; solo se sacrifica el recall exacto.

Cuadro 12: Barrido MMR λ de la Fase C sobre el campeón, computado offline desde su checkpoint (`mmr_pool` 200; 1431 sesiones de test). Recall@10 (aciertos crudos), MRR, `artist@10`, `music@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Mejor celda por métrica en negrita; recall / MRR del default del campeón ($\lambda=\text{off}$) en negrita.

λ	R@10 (crudo)	Δ vs off	MRR	art@10	mus@10	artadj↓	mood↑	ild↑
off (1.0)	0.2117 (303)	—	0.122	0.333	0.454	0.610	0.398	0.406
0.9	0.2103 (301)	−0,0014 (EMPATE)	0.121	0.341	0.462	0.603	0.391	0.436
0.7	0.1936 (277)	−0,0181	0.116	0.347	0.476	0.571	0.364	0.520
0.5	0.1642 (235)	−0,0475	0.108	0.359	0.487	0.486	0.315	0.653
0.3	0.1097 (157)	−0,1020	0.100	0.358	0.492	0.293	0.238	0.815

El regularizador anti-eager β (Fase D) — la palanca débil. Una penalización de entrenamiento sobre la predicción casi-copia del latente de la pista actual (`eager_margin` 0,0) apenas mueve la aguja (Tabla 13): a lo largo de β 0 a 0,2, `artist_adj@10` solo se desplaza 0,347→0,340 (Δ −0,0074) e `ild@10` solo 0,454→0,458, con Recall@10 plano (las cuatro dentro de $\pm 0,015$). La GRU individual ya es de baja eagerness (0,347), así que queda poco comportamiento de copia para penalizar — β no es una palanca de holisticidad útil en estos ajustes.

Cuadro 13: Barrido del regularizador anti-eager β de la Fase D sobre la GRU individual (`eager_margin` 0,0; 1431 sesiones de test). Recall@10, `artist@10`, `mood_coh@10`, `ild@10` mejor-mayor; **`artist_adj@10` mejor-menor**. Mejor celda por métrica en negrita.

run id	β	R@10 (crudo)	MRR	art@10	artadj↓	mood↑	ild↑
run-20260722-165345-e39c9	0.0	0.1230 (176)	0.053	0.338	0.347	0.479	0.454
run-20260722-165345-353b5	0.05	0.1237 (177)	0.053	0.337	0.346	0.478	0.455
run-20260723-002044-af11a	0.1	0.1202 (172)	0.053	0.335	0.344	0.477	0.456
run-20260723-002044-17cf8	0.2	0.1202 (172)	0.051	0.336	0.340	0.475	0.458

Continuación multi-paso (Fase E). El arnés bajo demanda (`seq_continuation_eval.py -m 3 -k 10`, 1172 casos de continuación) muestra que la GRU *supera* al bigrama de Markov en ambas métricas multi-paso (Tabla 14): la ventaja de la RNN *se ensancha* más allá de la pista siguiente




Figura 8: El trade-off de MMR λ sobre el campeón de pista siguiente. A medida que λ cae de off hacia 0,3, Recall@10 (rojo, eje izquierdo) baja — lo único que se sacrifica — mientras ild@10 sube y artist_adj@10 baja (eje derecho; más diverso, menos artist-eager) y music@10 incluso *sube*. $\lambda=0,9$ queda dentro de la banda de empate de recall $\pm 0,015$ pero ya eleva ild@10 en 0,030; $\lambda \approx 0,7$ compra una gran ganancia de ild@10 y des-eagerness real por ~ 2 puntos de recall. MMR es la palanca de holisticidad fuerte; β (Tabla 13) es débil.

inmediata, porque la co-ocurrencia de un solo paso del bigrama no se compone en buenas continuaciones de 3 pasos, mientras que el estado de secuencia aprendido de la GRU sí — la imagen especular del tablero de un solo paso, donde el blend con bigrama gana el Recall@10 crudo.

Cuadro 14: Continuación multi-paso de la Fase E (arnés -m 3 -k 10, 1172 casos) sobre seq-20260715-131139: la GRU (checkpoint A3) supera al bigrama de Markov de primer orden en ambas métricas (mejor-mayor). Ganador en negrita.

Modelo	suffix_recall@10	cont_prec@10
markov (bigrama de primer orden)	0.0869	0.0236
GRU (gru-infonce-h256, A3)	0.0963	0.0273

Interpretación y la decisión diferida. La campaña entrega un relato mecanístico limpio del síntoma de eagerness: proviene de la pata de bigrama de Markov (que repite como loro el artista actual vía co-ocurrencia cruda), no de la pata neural, así que cualquier des-eagerness futuro debería apuntar al bigrama / la fusión, no a la RNN. De las dos nuevas palancas, el re-ranqueo MMR en evaluación es la palanca *fuerte* y el regularizador β de entrenamiento es *débil*. No se promueve nada — la métrica principal sigue siendo Recall@10 y el campeón no cambia — pero $\lambda \approx 0,9$ queda señalado como una mejora de holisticidad casi gratis para una futura decisión de promoción del usuario (Recall@10 empate dentro del ruido, ild@10 0,406→0,436, eagerness 0,610→0,603), con $\lambda \approx 0,7$ como el punto de operación de “des-eagerness significativo por ~ 2 puntos de recall”; adoptar cualquiera de los dos requiere una decisión del usuario más una confirmación de 3 semillas / run nativo. El regularizador β no se recomienda como palanca en estos ajustes.

16. Conclusiones

Doce campañas (jul 2026) sobre la tarea de recuperación de pista siguiente convergen en una historia clara. (1) Un modelo de secuencias de sesión, incluso en su mejor forma (GRU-infonce), solo *empata* con la barra de Markov de co-escucha de primer orden en recall@10 y pierde en MRR: predecir un latente del siguiente ítem y recuperar por un salto coseno es una ruta más difícil a la pista siguiente exacta que un bigrama que memoriza la adyacencia directamente. (2) La *pérdida* de entrenamiento es la palanca individual dominante (InfoNCE $\approx 2,3\times$ el coseno); la *topología* de red — profundidad, anchura, residual, dirección — es una palanca agotada, y ninguna arquitectura supera la barra. (3) El avance es la *fusión de rankings*: un z-blend R+M de las ramas GRU y Markov supera la barra en $\sim +61\%$ de recall@10 (confirmado con 3 semillas), porque las dos ramas ordenan pistas correctas *distintas*. La victoria es sobre *diversidad* de señal, no número de modelos — añadir una rama neuronal redundante no ayuda, y un stacker XGB aprendido *rinde por debajo* del z-blend fijo, porque su entrenamiento puntual no captura el objetivo de ranking. (4) Un barrido de representación de ítems halló que la *dimensión* latente, no el compresor, es la palanca: el PCA lineal supera al autoencoder no lineal en toda dimensión ≥ 64 (la hipótesis de preservación acústica queda refutada), la curva hace pico en PCA-192 y se revierte hacia 256, y PCA-128 es la base individual confirmada. (5) Sobre el espacio PCA rico la única señal nueva genuinamente aditiva — *content-kNN*, que solo *empató* al campeón sobre el espacio AE-64 — se vuelve una victoria: un z-blend R+M+C de tres ramas sobre PCA-192 es la fila «mejor registrada» actual con recall@10 0,1859, MRR 0,1025 (Δ pareado sobre el campeón previo +0,0133, IC por encima de cero, confirmado a través de cinco reproducciones). (6) Dos salvedades honestas acotan la coronación: la confirmación por reproducción tuvo dispersión cero porque *seq-nexttrack* es determinista en esta CPU (así que verifiqué determinismo, no robustez a la semilla), y el límite inferior del paired- Δ supera cero por solo +0,0007 en una única partición — endurecerla requiere una segunda partición de prueba sin fugas. (7) Todo predictor de ranking aquí es solo de entrenamiento y fuera del servidor, así que la coronación es una fila «mejor registrada», no un modelo promovido y exportable a la app; el campeón previo R+M sobre AE-64 sigue siendo el ancla de productización, y registrar un blend de tres ramas con un subcomando *predict* es el trabajo futuro principal vigente. (8) Una campaña posterior de ajuste-a-la-literatura *superó* luego la coronación con la primera señal nueva genuinamente aditiva desde el contenido: una *proyección de contenido aprendida* supervisada ($R'+M+C'$), un mapa métrico InfoNCE del espacio de ítems PCA-192 ajustado hacia la adyacencia de pista siguiente en el que recuperan tanto la GRU como la rama de contenido, con recall@10 0,2117, MRR 0,1220 (paired Δ sobre R+M+C +0,0259, IC>0). Resuelve ambas salvedades de R+M+C — es robusta a la semilla a través de tres semillas y alcanza ítems fríos (su rama de contenido puntúa objetivos fríos tan bien como cálidos) — y fue *registrada, promovida y servible* (*blend-gru-markov-content-proj*, rango 1 del grupo de mejores modelos), cerrando la brecha de productización; un barrido de objetivo / rango / τ confirma InfoNCE $\gg$ BPR y mantiene el default, y la coronación luego se endureció en una segunda partición disjunta con 0.64 de fríos (paired Δ +0,0426, IC>0, el margen *más ancho* en la partición más fría). Todo método prestado de ajuste-a-la-literatura (session-kNN, fusión de rankings / combinadores aprendidos, trucos de pérdida del lado GRU, suavizado de Markov) se cerró — la única ganancia aditiva vino de señal nueva, no de fusión más astuta. (9) Una exploración de representación del vector de ítem confirmó luego *por qué* la proyección es el campeón: la geometría PCA-192 de peso igual es un lastre real para un modelo crudo (seis de ocho espacios whitened / drop-acústico / métricos elevan la GRU

congelada, IC del Δ pareado > 0), pero la ganancia es *absorbida* por completo por la proyección aprendida (ningún espacio supera al campeón en readout A) — el whitening y la proyección son el mismo arreglo, y el campeón ya lo accionó. (10) Finalmente, se introdujo una métrica continua de tipo “suena parecido”, *music@10*, y se back-filleó a través de los 53 runs: correlaciona con recall@10 ($r = 0,609$) pero corona a un ganador distinto (el **seq-nexttrack** que regresa contenido aterriza los fallos más cercanos musicalmente, mejor 0,482), corroborando los hallazgos de recall exacto sin revertirlos; es solo de visualización y la métrica principal sigue siendo recall@10. (11) Finalmente, una campaña de medición añadió una suite *solo de visualización* de holisticidad de sesión (artist_adj@10 / mood_coh@10 / ild@10) y dos palancas anti-eager. Encontró que el síntoma de eagerness *sigue* a Recall@10 dentro de la familia de blends — el campeón es el modelo más artist-eager (artist_adj@10 0,610) — pero la eagerness proviene de la pata de bigrama de *Markov*, no de la RNN (GRU / LSTM individuales con artist_adj@10 $\approx 0,345$), y la GRU y la LSTM están estadísticamente empatadas tanto en recall como en eagerness (la hipótesis “la GRU gana por ser más eager” queda refutada). De las dos palancas, el re-ranqueo MMR en evaluación es la palanca fuerte ($\lambda=0,9$ casi gratis: recall empate, ild@10 $0,406 \rightarrow 0,436$; $\lambda \approx 0,7$ des-eagers por ~ 2 puntos de recall; music@10 incluso sube al diversificar la lista) mientras que el regularizador β de entrenamiento es débil (β 0 a 0,2 mueve artist_adj@10 solo $-0,0074$); no se promovió nada, y $\lambda \approx 0,9$ queda señalado para una futura decisión de holisticidad del usuario (Sección 15).

17. Informes fuente

Esta síntesis consolida doce informes de campaña de pista siguiente de **experiments/**:

- **2026-07-13-nexttrack-sequence-sweep.md** — la campaña fundacional de pista siguiente: un barrido de secuencias GRU/LSTM contra la barra de Markov de primer orden; la mejor GRU-infonce empatada en R@10 pero pierde en MRR (Sección 4).
- **2026-07-13-nexttrack-topology-scan.md** — el barrido de topología profundidad / anchura / residual / bidireccional; la arquitectura es una palanca agotada, todas las ramas quedan bajo la barra de Markov (Sección 5).
- **2026-07-14-nexttrack-blend-and-ensemble.md** — el z-blend R+M GRU $\times$ Markov supera la barra en +61 % de R@10 (el primer campeón de pista siguiente); ningún ensamble más rico lo mejora y el stacker XGB aprendido rinde por debajo (Sección 6).
- **2026-07-14-nexttrack-graded-relevance-and-new-legs.md** — métricas de relevancia graduada de primera clase (artist@k / genre@k / artist_mrr) y nuevos aprendices base leak-free; content-kNN es la única señal aditiva, empatando al campeón sobre AE-64 (Sección 7).
- **2026-07-15-nexttrack-compression-representation-bakeoff.md** — el bake-off de compresión de la representación de ítems (PCA frente a autoencoder $\times$ dimensión latente 32/64/128) bajo un readout GRU congelado; PCA-128 es el ganador GRU-individual pero la victoria no se traslada al blend (Sección 8).
- **2026-07-15b-nexttrack-compression-dim-extension.md** — el barrido de dimensión PCA/AE extendido a 192/256; la curva hace pico en PCA-192 y se revierte, así que PCA-128 se mantiene como la base de la Fase 2 (Sección 9).

- `2026-07-15c-nexttrack-phase2-model-sweep.md` — el barrido de familia de modelos sobre los espacios PCA ricos; el z-blend fijo supera al stacker aprendido, la LSTM es el mejor modelo individual, y R+M+C sobre PCA-192 se corona como la nueva fila «mejor registrada» (Sección 10).
- `2026-07-18-nexttrack-literature-fit-campaign.md` — una exploración guiada por bibliografía; una proyección de contenido aprendida supervisada ($R'+M+C'$) es la nueva fila «mejor registrada» ($R@10$ 0,2117, paired Δ sobre R+M+C +0,0259 IC>0, robusta a la semilla, alcanza fríos), y cada método prestado (session-kNN, fusión de rankings, combinador aprendido, suavizado de Markov, negativos por importancia de GRU) se cierra (Sección 11).
- `2026-07-18b-nexttrack-projection-registration-and-scan.md` — la proyección reproducida on-server, registrada + promovida + servible como `blend-gru-markov-content-proj` (rango 1 del grupo de mejores modelos); un barrido de objetivo / rango / τ (InfoNCE $\gg$ BPR; default mantenido) y endurecimiento en segunda partición sobre una partición disjunta con 0.64 de fríos (paired Δ +0,0426 IC>0) (Sección 12).
- `2026-07-18c-nexttrack-representation-exploration.md` — una auditoría de representación del vector de ítem; la geometría PCA-192 de peso igual lastra la GRU cruda (seis de ocho espacios alternativos la elevan IC>0) pero la ganancia es absorbida por la proyección (ningún espacio supera al campeón en readout A) (Sección 13).
- `2026-07-20-musical-distance-metric.md` — la métrica continua de tipo “suena parecido” `music@10` y su backfill offline de 53 runs; correlaciona con `recall@10` ($r = 0,609$) pero corona a un ganador distinto, el `seq-nexttrack` que regresa contenido (Sección 14).
- `2026-07-22-session-holisticness-and-antieager-levers.md` — una suite solo de visualización de holisticidad de sesión (`artist_adj@10` / `mood_coh@10` / `ild@10`) y dos palancas anti-eager (MMR en evaluación `mmr_lambda`, y `eager_beta` de entrenamiento); el campeón es el modelo más artist-eager, la eagerness proviene de la pata de Markov, $GRU \approx LSTM$, y MMR λ es la palanca fuerte (Sección 15).