

Tu gusto, leído desde los modelos

Un retrato de cómo escuchás música, trazado no a partir de contar reproducciones sino desarmando el modelo entrenado de “próxima canción” para preguntarle qué tuvo que aprender de vos con tal de acertar qué ponés después. Usamos varios métodos independientes y —lo tranquilizador— todos apuntan al mismo lado. Los números de reproducción crudos aparecen recién sobre el final, como contraste. Es exploratorio y cariñoso; no un veredicto.

Una nota sobre la matemática (liviana)

No hace falta saber de machine learning: alcanza con un poco de álgebra lineal, algo de probabilidad y la idea de sistema dinámico.

- **Cada tema es un punto.** El modelo convierte cada canción en un vector dentro de un “**espacio de sonido**” de **192 dimensiones** que aprendió solo. Una sesión de escucha es, entonces, un recorrido por ese espacio.
- **El predictor es una recurrencia.** Leyendo la sesión tema por tema, arrastra una memoria h_t que actualiza así:

$$h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1},$$

es decir, en cada paso interpola —coordenada a coordenada ($\odot$ es elemento a elemento)— entre la memoria anterior h_{t-1} y un candidato nuevo n_t , con una **fracción de retención** $z_t \in (0, 1)$ aprendida (la “compuerta de actualización”). Ese es todo el mecanismo que después inspeccionamos.

- **Para leer la memoria, la factorizamos.** Buscamos un diccionario D y códigos *ralos* c tales que $h \approx Dc$ con muy pocas entradas no nulas (un *autoencoder disperso*). Cada columna del diccionario (un “átomo”) termina comportándose como un concepto: casi siempre un artista o un género.
- **El flujo es una matriz y un grafo.** El modelo de co-ocurrencia (“Markov”) no es más que la matriz de transición $P(\text{próximo} \mid \text{actual})$; la **tasa de permanencia** de un género es su entrada diagonal. Tomando los géneros como un grafo dirigido y pesado, **PageRank** (la distribución estacionaria de un paseo aleatorio) encuentra los *hubs*, y la **intermediación** (fracción de caminos más cortos que pasan por un nodo) encuentra los *puentes*.
- **Las sesiones se agrupan** con k-means (cada sesión $\rightarrow$ su vector promedio $\rightarrow$ agrupadas por centro más cercano), y los **atractores** salen de *iterar el mapa* (poné una semilla, predecí la siguiente, saltá al tema real más cercano, repetí) y mirar dónde se asienta la órbita.

Todo lo que sigue se lee de estas construcciones, desde adentro del modelo.

1. Un mapa de tu escucha

Si representamos cada sesión por su punto promedio en el espacio de sonido y las agrupamos, aparecen seis **modos** nítidos. El “terreno” sombreado de abajo es su densidad: los valles son donde se te amontonan las sesiones.

**Tu gusto como un paisaje — cada punto es una sesión de escucha;
los valles (oscuros) son los modos en los que te instalás**




Figura 1: Cada punto es una sesión; los valles más oscuros son los modos en los que te instalás. La música argentina (naranja) y los dos modos electrónicos (verde azulado) son grandes y separados; la cuenca de Rammstein/metal (rojo) queda aparte.

- **Dos modos electrónicos, ~60 % de todo.** Uno de club/**UK garage** (Four Tet, Joy Orbison, Aphex Twin, Daphni — 31 %) y otro de **big-beat/trip-hop** (The Avalanches, Underworld, Massive Attack, Air — 29 %).
- **La música argentina se parte en dos:** un modo **indie** contemporáneo (Peces Raros, Laika Perra Rusa — 17 %) y un modo **canon** (Babasonicos, Gustavo Cerati — 9 %).
- **Un modo metal/rock (Rammstein, 10 %) — y es el corto:** ~9 temas por sesión contra ~14 en el resto. El metal lo escuchás en ráfagas breves y autocontenidas.
- **Un modo chico kraut/ambient (Kraftwerk, Nicolás Jaar — 4 %).**

2. Qué considera central el modelo

A cada concepto le tocan tantos átomos del diccionario como el modelo necesite para representarlo; por eso **la cantidad de átomos es su propia medida de importancia**, independiente de cuánto lo hayas escuchado.




Figura 2: Artistas ordenados por cuántas direcciones internas les dedica el modelo.

Four Tet encabeza al modelo aunque no sea tu más escuchado: es el que más direcciones distintas exige para quedar capturado. Y un resultado en sí mismo: aun estirando a **500 átomos**, siguen mapeando a solo **~25 artistas y ~13 géneros**. Pero ese “reparto chico” hay que leerlo con cuidado — ver la sección que sigue.

El otro 99,6 % — tu amplitud (lo que el modelo *no* ve)

El “reparto chico” se presta a una lectura equivocada. **No** es a cuántos artistas escuchás; es a cuántos el modelo les puede armar *estructura*. Por construcción, el autoencoder disperso solo le hace crecer

un átomo a un concepto que se repite lo suficiente como para ayudar a predecir la próxima canción: un artista de una sola escucha nunca se gana uno. Y lo tuyo es, en su enorme mayoría, de una sola escucha:




Figura 3: Vas muy a lo ancho, pero fino. Reproducciones acumuladas vs. artistas acumulados (una curva de Lorenz): cuanto más se arquea lejos de la diagonal, más concentrado. El punto rojo marca tus 25 top — todo el “reparto” del modelo.

Escuchaste **5.594 artistas**, pero el reparto es extremo (Gini **0,88**): al **42 %** lo escuchaste una sola vez y al **56 %** no más de dos — la mediana es dos reproducciones. Tus 25 top —todo el reparto del modelo— son el **0,4 % de tus artistas y, aun así, un tercio de todas las reproducciones**. Así que la foto honesta es lo contrario de “acotada”: sos un **explorador de amplitud enorme** con un núcleo chico y pesado. Todo el resto de este documento describe ese núcleo, porque la repetición es lo único sobre lo que el modelo puede razonar; la cola inmensa y fina de todo-lo-que-probaste-una-vez es igual de real y, sencillamente, **invisible para esta lente**.

3. Valles y pasos de montaña — “bloques” vs “puentes”

El hallazgo más sólido, porque **dos métodos sin relación entre sí lo producen por separado**. Para cada género calculamos su **tasa de permanencia** de Markov (con qué frecuencia lleva a sí mismo) y, aparte, el **tamaño del salto en la memoria neuronal** $\|\Delta h\|$ cuando llega un tema de ese género. Coinciden:

- **Bloques** — los valles donde te instalás: **alternative metal (permanencia 0,71)**, la dusseldorf-electronic de Kraftwerk (0,55), rock/indie argentino (0,51).
- **Puentes** — los pasos entre valles: melodic techno (0,21), deep house (0,23), dance pop (0,23), art pop. Su *llegada* fuerza la mayor reorganización de la memoria (el estado neuronal salta **1,5×** más en un cambio de género que dentro del mismo).

La alegoría es literal y es la misma foto del §1: tu gusto es un **terreno de valles** (metal, rock argentino,




Figura 4: A la derecha/abajo, te quedás (bloques); a la izquierda/arriba, el estado se reorganiza (puentes). El modelo de co-ocurrencia y la red neuronal dicen lo mismo.

Kraftwerk) unidos por **pasos de montaña electrónicos** (house/techno). El núcleo electrónico no es solo música que ponés: es la *red de transporte* entre todo lo demás.

4. La gramática de flujo

La misma idea, explícita como grafo: los nodos son géneros, las flechas son pases, y el tamaño del nodo es su puntaje de “hub” (PageRank).

La gramática de flujo: cómo se pasan la posta los géneros (tamaño = 'hub')




Figura 5: Cómo se pasan la posta los géneros. Un clúster argentino muy interconectado (naranja), una red electrónica enlazada (verde azulado) y puentes que los cruzan.

- **Hubs** (donde un caminante pasaría el tiempo): alternative dance, argentine indie, downtempo. **Puentes** (cuellos de botella entre regiones, por intermediación): alternative dance y — curiosamente— **alternative metal**.
- **El metal te abre y te cierra las sesiones:** es tu forma más habitual tanto de **arrancar** (7,8 %) como de **terminar** (7,5 %) una sesión, pese a ser apenas el 10 % de ellas. Abrís y cerrás con él, y después te vas.
- Puentes con nombre: **Kraftwerk** → **Babasonicos** (electrónica alemana hacia rock argentino) y **Rammstein** ↔ **Daft Punk** / **Grimes**.

5. Pozos gravitacionales — hacia dónde “rueda” el modelo

Pensá el modelo entrenado como un sistema dinámico: poné una semilla, dejá que prediga el siguiente, saltá al tema real más cercano y repetí 30 veces. Donde se asienta la órbita es una **cuenca de**

atracción — literalmente, adónde rodaría una bolita sobre el terreno del §1.




Figura 6: Hacé rodar el modelo desde una semilla. Verde = se queda en casa; rojo = fluye hacia otra región. El largo de la barra es la proporción de los 30 pasos que pasa en el género destino.

- **Pozos profundos (de los que no se sale):** Kraftwerk → 100 % dusseldorf electronic, Aphex Twin → 100 % ambient, Radiohead → 100 % alternative rock, Rammstein → 70 % metal: arrancás ahí y el modelo se queda, igual que las sesiones cortas y autocontenidas de “bloque”.
- **Trampolines (fluyen):** Four Tet desemboca en ambient (90%); The xx, DIIV y Underworld derivan hacia un sumidero de album-rock / alternative-rock. Así que tu núcleo electrónico es donde *empiezan* los viajes; una cuenca genérica de rock/ambient es donde *terminan* los poco guiados.

6. Adentro del mecanismo — cómo decide quedarse o cambiar

La compuerta de actualización z_t se puede leer exacta (reconstruir la recurrencia desde los pesos reproduce el modelo a 5×10^{-8}). Dos cosas, una de ellas un negativo limpio:

- **No hay “celdas de memoria” de prendido/apagado.** La fracción de retención z_t se queda en $\sim 0,51$ para cada una de las 256 coordenadas (rango 0,42–0,63) y casi no se mueve: no existe una unidad que se *prenda* para “metal” y se *apague* para “house”. La memoria está **distribuida**, no es un tablero de interruptores etiquetados.
- **Pero el estado se mueve $1,5\times$ más en los cambios** — y esa reorganización es justo lo que miden los puentes del §3. Así que la conducta de “decidir cambiar” es real; solo que vive en el

movimiento de todo el estado, no en ninguna celda interpretable.

7. ¿Coincide con lo que hacés en la práctica?

Como contraste contra los registros crudos (el único lugar donde entran los conteos): el núcleo electrónico de mayor relevancia para el modelo es también tu música **más escuchada del último año**; sus “bloques” (Rammstein, rock argentino) son tus mayores totales **históricos**; y la cuenca de Rammstein —aislada y corta— encaja con tu propia observación de que *hace rato que no lo ponés*: el modelo, que aprende cronológicamente, **bajó la fase apagada** aunque el conteo de toda la vida lo siga poniendo #1.

En una línea

Desde adentro, tu gusto es un **núcleo** chico y pesado —~25 artistas que se llevan un tercio de tus reproducciones, flotando sobre una cola ancha y fina de ~5.600 artistas que en su mayoría probaste una vez— y ese núcleo está dispuesto como un **terreno**: valles profundos donde te instalás — Rammstein/metal industrial (en ráfagas cortas, aparte de todo), rock argentino en el linaje Cera-ti/Babasonicos, Kraftwerk— unidos por una **red electrónica de pasos de montaña** (Four Tet, Caribou, Aphex Twin, house/techno) que todos los métodos coinciden en señalar como la verdadera estructura conectiva, sobre un núcleo dream-pop (DIIV, The xx); y, como el modelo aprende en el tiempo, codifica el **presente electrónico** al que te mudaste.

*Salvedades y método: las figuras salen de un modelo sobre una única partición cronológica; la cantidad de átomos, la tasa de permanencia, $\|\Delta h\|$ y “atractor” son constructos interpretativos (un autoencoder disperso sobre el estado oculto de la GRU, la matriz de transición de co-ocurrencia, la reconstrucción de las compuertas y k-means sobre vectores de sesión); la huella neuronal incorpora los nombres de artista, así que los conceptos tienden a tener forma de artista; solo se representan conceptos frecuentes y predictivos, no toda tu biblioteca. Método completo: *sae-interpretability-note.pdf*.*